



第一课 机器学习简介

授课教师：潘贤丽、张晓会



大纲

01 什么是机器学习?

02 机器学习发展史

03 机器学习包含什么?

04 机器学习通用流程

05 基础概念介绍

一. 什么是机器学习？



人工智能

(Artificial Intelligence)



机器学习

(Machine Learning)




深度学习

(Deep Learning)



大模型

(Foundation/LLM)



大数据


(Big Data)



数据挖掘


(Data Mining)

大数据 = 规模大 + 类型多 + 信息量低 + 产生快 + 参差不齐



大数据

(Big Data)



单位	名称	大小
b	位 (bit)	1/8B
B	字节 (Byte)	1B
KB	千字节 (KiloByte)	1024B
MB	兆字节 (MegaByte)	1024KB
GB	吉字节 (GigaByte)	1024MB
TB	太字节 (TeraByte)	1024GB

PB	拍字节 (PetaByte)	1024TB
EB	艾字节 (ExaByte)	1024PB
ZB	泽字节 (ZetaByte)	1024EB
YB	尧字节 (YottaByte)	1024ZB
BB	珀字节 (Brontobyte)	1024YB
NB	诺字节 (NonaByte)	1024BB
DB	刀字节 (DoggaByte)	1024NB

大数据



添加说明

2026年2月28日 星期六 09:20

调整

IMG_3244

Apple iPhone 16 Pro Max

HEIF

超广角相机 — 13 mm f2.2

12 MP • 3024 × 4032 • 1.6 MB

珠光

ISO 125 | 24 mm | 0 ev | f2.2 | 1/100 s

设备和驱动器



WPS云盘

双击进入WPS云盘



百度网盘

双击运行百度网盘



本地磁盘 (C:)

172 GB 可用, 共 296 GB



各种软件 (D:)

94.4 GB 可用, 共 197 GB



潘贤丽文件盘 (E:)

858 GB 可用, 共 1.33 TB



本地磁盘 (F:)

5.46 GB 可用, 共 1.81 TB



DVD RW 驱动器 (H:)



🔍 抖音一天产生多少数据 🔊

网页 图片 视频 学术 词典 地图 更多

约 119,000 个结果



6000万条

抖音每天大约产生 **6000万条新视频**。根据统计，抖音的日活跃用户已突破 **6亿**，假设每位用户每天平均上传 **0.1 个视频**，则每日新增视频量约为 **6000万条**。

↔ 知乎 +1

$$2M * 6000w \approx 114T$$


学术论文里有一个可用的量级：Douyin 上传视频平均大小约 **1.96 MB** (论文引用的统计口径)。

arXiv

全球数据圈的规模 (2010-2025)



资料来源: 数据时代 2025, 赞助商: 希捷, 数据来自 IDC 全球数据圈, 2018 年 11 月




大数据

(Big Data)

数 据

知 识




数据挖掘



数据挖掘

(Data Mining)

数据挖掘：从**数据**中**挖掘**
有用的信息或知识的过程



关联规则分析（购物篮分析）：

沃尔玛超市想根据顾客的购买清单，调整货架摆放



规则	支持度	置信度
$A \Rightarrow D$	2/5	2/3
$C \Rightarrow A$	2/5	2/4
$A \Rightarrow C$	2/5	2/3
$B \& C \Rightarrow D$	1/5	1/3

发现：购买尿布的顾客中，有67%的人同时买了啤酒

策略：把尿布和啤酒摆在一起销售

微博热搜

点击刷新

我的

热搜

- 1 王一博聊天记录 当前爆词 爆
- 2 迪丽热巴 嘉行 昨晚霸榜
- 3 BLACKPINK回归成绩 58532 新
- 4 国家线 砍一刀 09:34登顶 热
- 5 曝敖瑞鹏合约到期不续 32408
- 6 嘉行传媒21年给迪丽热... 60567
- 7 范丞丞方说不认识没... 上午霸榜 热
- 8 考研查分 08:39登顶 沸
- 9 奥黛丽厚本正完骨... 22:39登顶 热
- 10 王一博回消息爱用表... 1287972 新

查看完整热搜榜单 >

平台运营

品牌/明星公关

媒体机构

数据分析团队

- ① 预测话题未来走势
- ② 判断舆情立场（变好 / 变坏）
- ③ 评估公关是否有效（声明）
- ④ 识别异常热度（水军 / 刷榜）
- ⑤ 分析关注人群（谁在讨论）

一. 什么是机器学习？



人工智能

(Artificial Intelligence)



机器学习

(Machine Learning)



深度学习

(Deep Learning)



大模型

(Foundation/LLM)



大数据

(Big Data)




数据挖掘

(Data Mining)

原料

从数据中获取
知识的方法

一. 什么是机器学习？



- “能否开发出一台机器，使其在进行特定任务时的表现无法被人类区分开来？”——艾伦·图灵

人工智能最早期的定义之一，侧重于机器是否能**模仿人类的智能行为**

- “使机器能够执行需要人类智能的任务。”——1956年，达特茅斯会议

这个定义更加广泛，涵盖了任何**模拟人类智能行为**的计算机程序或机器



图灵（模仿游戏）

Sonny, Viki（我，机器人）

Hal9000（2001太空漫游）

Chappie（超能查派）

Baymax（超能陆战队）

Ultron（复仇者联盟2：奥创纪元）

Jarvis（钢铁侠）

Agent Smith（黑客帝国）

The Machine Leader（黑客帝国3矩阵**）

Andrew Martin（机器管家）

Robot（机器人与弗兰克）

WALL-E（机器人总动员）

Ava（机械姬）

Addie（绝密飞行）

David, Joe（人工智能）

Red Queen（生化危机）

Arthur（太空旅客）

TARS（星际穿越）

BB-8（星球大战7：原力觉醒）

R2-D2（星球大战前传1：幽灵的威胁）

Call（异形4）

David（异形前传2：契约）

ARIIA（鹰眼）

Gerty（月球）

T-800（终结者2：审判日，终结者：创世纪）

T-1000（终结者2：审判日，终结者：创世纪）


T-850（终结者3：机器的觉醒）

T-3000（终结者：创世纪）

T-X（终结者3：机器的觉醒）







A.I. 类型



弱人工智能

Artificial Narrow Intelligence (ANI)

描述

- 仅有**单一方面**的A.I., 如导航A.I., 仅有单一功能

思考速度

- 超越人类

思考质量

- 不及人类



强人工智能

Artificial General Intelligence (AGI)

- **人类级别**的A.I., 各方面与人类比肩, 包括思考质量

- 超越人类

- 比肩人类



超人工智能

Artificial Super Intelligence (ASI)

- 在几乎**所有领域**都比最聪明的人类大脑都聪明很多的A.I.

- 超越人类

- **超越人类**



一. 什么是机器学习？



人工智能

(Artificial Intelligence)



机器学习

(Machine Learning)



深度学习

(Deep Learning)



大模型

(Foundation/LLM)



大数据

(Big Data)



数据挖掘

(Data Mining)

目标/愿景

原料

从数据中获取
知识的方法





图1-2 机器学习：一种新的编程范式



机器学习是赋予计算机学习能力的研究领域，它**不需要明确的编程**，就能让计算机学习。

—— Arthur Samuel, 1959




```
{
  if (!empty($_POST)) {
    $msg = '';
    if ($_POST['user_name']) {
      if ($_POST['user_password_new']) {
        if ($_POST['user_password_new'] === $_POST['user_password_repeat']) {
          if (strlen($_POST['user_password_new']) > 5) {
            if (strlen($_POST['user_name']) < 65 && strlen($_POST['user_name']) > 1) {
              if (preg_match('/^[a-z\d]{2,64}$/i', $_POST['user_name'])) {
                $user = read_user($_POST['user_name']);
                if (!isset($user['user_name'])) {
                  if ($_POST['user_email']) {
                    if (strlen($_POST['user_email']) < 65) {
                      if (filter_var($_POST['user_email'], FILTER_VALIDATE_EMAIL)) {
                        create_user();
                        $_SESSION['msg'] = 'You are now registered so please';
                        header('Location: ' . $_SERVER['PHP_SELF']);
                        exit();
                      } else $msg = 'You must provide a valid email address';
                    } else $msg = 'Email must be less than 64 characters';
                  } else $msg = 'Email cannot be empty';
                } else $msg = 'Username already exists';
              } else $msg = 'Username must be only a-z, A-Z, 0-9';
            } else $msg = 'Username must be between 2 and 64 characters';
          } else $msg = 'Password must be at least 6 characters';
        } else $msg = 'Passwords do not match';
      } else $msg = 'Empty Password';
    }
  }
}
```



如果一个计算机程序对于某项**任务 T** 和某项**性能衡量指标 P**，其性能随着**经验 E** 的提高而提高，则可认为该程序可以从经验 E 中学习。

——Tom Mitchell, 1997



识别垃圾邮件:

T: 将邮件归类为垃圾邮件和非垃圾邮件

E: 用户标记为垃圾邮件/非垃圾邮件的历史记录

P: ML标记垃圾邮件、非垃圾邮件的正确率

一. 什么是机器学习？



人工智能

(Artificial Intelligence)

目标/愿景



机器学习

(Machine Learning)

实现AI的
核心技术




深度学习

(Deep Learning)



大模型

(Foundation/LLM)



大数据

(Big Data)

原料




数据挖掘

(Data Mining)

从数据中获取
知识的方法


机器学习

你如何设计最好的特征？




深度学习

如何引导模型找到最佳的特征？



维度	机器学习 (ML)	深度学习 (DL)
定义	AI 的一种实现方式, 依赖人工特征设计	ML 的子集, 基于多层神经网络
特征提取	手动提取: 人定义哪些数据重要	自动提取: 模型自动挖掘深层特征
模型结构	浅层模型 (线性回归、SVM 等)	多层模型 (CNN、RNN、Transformer)
训练数据量	千级~万级即可表现良好	通常需十万~百万级样本
计算资源	要求低, 适合普通CPU	高性能GPU或TPU更适合
训练时间	较快, 调参少	慢, 需要大规模计算和调参
适用数据类型	结构化数据 (如表格、数值)	非结构化数据 (图像、文本、语音)
可解释性	高, 模型容易理解	低, 通常被视为“黑箱”



一. 什么是机器学习？



人工智能

(Artificial Intelligence)

目标/愿景



机器学习

(Machine Learning)

实现AI的
核心技术



深度学习

(Deep Learning)

一种特殊
的ML方法



大模型

(Foundation/LLM)



大数据

(Big Data)


原料



数据挖掘


(Data Mining)

从数据中获取
知识的方法




大模型：大规模预训练 + 下游迁移/指令适配

- **Scaling Law**
性能连续提升
- **Emergence**
能力突然出现



伸缩法则：知识密集型任务



涌现能力：多步骤构成的任务

知乎@张俊林

一. 什么是机器学习？



人工智能

(Artificial Intelligence)

目标/愿景



机器学习

(Machine Learning)

实现AI的
核心技术



深度学习

(Deep Learning)


一种特殊
的ML方法



大模型

(Foundation/LLM)

更通用的模型



大数据

(Big Data)

原料




数据挖掘

(Data Mining)

从数据中获取
知识的方法

一. 什么是机器学习？



一. 什么是机器学习？

习题：下面哪些属于机器学习问题？

- ① 按固定公式计算圆面积
- ② 根据历史房价预测新房价格
- ③ 用规则库做身份证号校验
- ④ 根据用户浏览记录推荐商品
- ⑤ 用 ChatGPT 续写一段文字
- ⑥ 输入法联想

参考答案：2、4、5 属于机器学习或其应用

一. 什么是机器学习？

能力	当前LLM	真正AGI需要
相关学习	✓	✓
因果建模	✗	✓
一次性训练	✓	✗
持续学习	✗	✓
物理交互	✗	✓



大纲

01 什么是机器学习?


02 机器学习发展史

03 机器学习包含什么?


04 机器学习通用流程

05 基础概念介绍


推荐书籍：



人工智能简史（第2版）



智慧的疆界：从图灵...



人工智能极简史

二. 机器学习发展史

图灵测试：1950年，图灵发表了一篇名为《计算机机械和智能》（Computing Machinery and Intelligence）的论文，提出一种测试，用于判断机器是否具有智能。

A. M. Turing (1950) Computing Machinery and Intelligence. *Mind* 49: 433-460.

COMPUTING MACHINERY AND INTELLIGENCE

By A. M. Turing

1. The Imitation Game

I propose to consider the question, "Can machines think?" This should begin with definitions of the meaning of the terms "machine" and "think." The definitions might be framed so as to reflect so far as possible the normal use of the words, but this attitude is dangerous. If the meaning of the words "machine" and "think" are to be found by examining how they are commonly used it is difficult to escape the conclusion that the meaning and the answer to the question, "Can machines think?" is to be sought in a statistical survey such as a Gallup poll. But this is absurd. Instead of attempting such a definition I shall replace the question by another, which is closely related to it and is expressed in relatively unambiguous words.

The new form of the problem can be described in terms of a game which we call the 'imitation game.' It is played with three people, a man (A), a woman (B), and an interrogator (C) who may be of either sex. The interrogator stays in a room apart from the other two. The object of the game for the interrogator is to determine which of the other two is the man and which is the woman. He knows them by labels X and Y, and at the end of the game he says either "X is A and Y is B" or "X is B and Y is A." The interrogator is allowed to put questions to A and B thus:


C: Will X please tell me the length of his or her hair?

Now suppose X is actually A, then A must answer. It is A's object in the game to try and cause C to make the wrong identification. His answer might therefore be:

"My hair is shingled, and the longest strands are about nine inches long."

In order that tones of voice may not help the interrogator the answers should be written, or better still, typewritten. The ideal arrangement is to have a teleprinter communicating between the two rooms. Alternatively the question and answers can be repeated by an intermediary. The object of the game for the third player (B) is to help the interrogator. The best strategy for her is probably to give truthful answers. She can add such things as "I am the woman, don't listen to him!" to her answers, but it will avail nothing as the man can make similar remarks.

We now ask the question, "What will happen when a machine takes the part of A in this game?" Will the interrogator decide wrongly as often when the game is played like this as he does when the game is played between a man and a woman? These questions replace our original, "Can machines think?"




We can only see
a short distance
ahead, but we
can see plenty
there that needs
to be done.


Alan Turing

(COMPUTING MACHINERY AND INTELLIGENCE 1950)

二. 机器学习发展史



John McCarthy



Claude Shannon

1956年，他们一起编撰了一本论文集叫做《**自动机研究**》。

- ✓ **大脑是如何工作的？**
- ✓ **我们能否设计一个机器来模拟大脑？**

McCarthy认为**对于机器如何能够具备智能这方面还缺乏明确的探讨**，应当**为这个问题阐明内涵和外延**，进而明确领地将其作为一个**研究领域和方向**确立下来，从而获得更多来自政府和学术界的支持。

他把这个领域命名为“Artificial Intelligence”（**人工智能**），简称AI。

二. 机器学习发展史

达特茅斯学院数学系助理教授
1971年图灵奖获得者
麦卡锡(J. McCarthy)

哈佛大学数学系和神经学系青年研究员
1969年图灵奖获得者
明斯基(M. L. Minsky)

贝尔实验室数学家
“信息论之父”
香农(C. Shannon)

国际商业机器公司(IBM)信息研究主管
IBM第一代商用计算机IBM 701的主设计师
罗切斯特(N. Rochester)

4位学者向美国洛克菲勒基金会递交了一份题为 **《关于举办达特茅斯人工智能暑期研讨会的提议》** 的建议书，希望得到基金会资助，研究“用计算机模拟人的智能”的科学。

1955 年达特茅斯人工智能暑期研讨会建议书中所提的 7 个研究问题

研究问题	当前的拓展性解读
自动计算机	通过编程让机器自动完成特定工作，如语音识别或图像分类
使用语言对计算机进行编程	通过 AI 编程语言来实现某些功能
神经网络	设计神经网络让计算机从感知数据中抽象出概念
计算复杂度	寻找一种方法来度量计算机完成特定任务时所耗费的运行时间和储存空间等开销
算法自我改进能力	AI 算法从过往经验中学习，不断提高其性能
算法抽象能力	从海量数据中归纳出数据中隐藏知识
算法随机性和创造力	模拟人类思维中所特有的创造能力

二. 机器学习发展史



达特茅斯会议

宣言：“1956年夏天，我们将在达特茅斯学院进行一项由10个人组成的为期两个月的人工智能研究……研究的主题是：**如何让机器使用语言、进行抽象思考和形成概念，让它们解决目前只能由人类解决的问题，并自我改善。**我们认为，如果仔细甄选一些科学家，组成一个团队，在一起工作一个夏天，就能在一个或多个问题上取得重大进展！”

二. 机器学习发展史




John MacCarthy

图灵奖获得者




Marvin Minsky

图灵奖获得者



Claude Shannon

信息论创始人



Ray Solomonoff

算法概率论的创始人



Alan Newell

图灵奖获得者



Herbert Simon

图灵奖获得者
诺贝尔经济学
奖获得者



Arthur Samuel

机器学习一词
的创立者
发明第一个电
脑跳棋程序



Oliver Selfridge

机器知觉之父



Nathaniel Rochester

IBM第一代商
用计算机IBM
701的主设计师



Trenchard More

二. 机器学习发展史



Arthur Lee Samuel, 1901年12月5日—1990年7月29日

- 评分函数
- 剪枝算法

- 1952年，在IBM701上研制了一个西洋跳棋程序，打败了自己
- 在达特茅斯会议上介绍了该程序，后来打败了美国某州跳棋冠军
- 提出“**机器学习**”一词，并把它定义为“不显示编程地赋予计算机能力的研究领域”

二. 机器学习发展史



Allan Newell


Herbert Simon

Presentaron el programa de razonamiento automático

Logic Theorist 

开发了世界上最早的自动定理证明系统
—— “逻辑理论家”LT(Logic Theorist)

证明了著名数学家罗素和怀特海的名著《数学原理》中的全部52条定理，其中一条定理的证明比罗素和怀特海更巧妙。



二. 机器学习发展史






图18 网上流传的漫画：人工智能发展成熟度曲线

二. 机器学习发展史

Prompt: A stylish woman walks down a Tokyo street filled with warm glowing neon and animated city signage. She wears a black leather jacket, a long red dress, and black boots, and carries a black purse. She wears sunglasses and red lipstick. She walks confidently and casually. The street is damp and reflective, creating a mirror effect of the colorful lights. Many pedestrians walk about.




Sora OpenAI 2024-2-16



二. 机器学习发展史

EMO: Emote Portrait Alive - Generating Expressive Portrait Videos with Audio2Video Diffusion Model under Weak Conditions

Linrui Tian, Qi Wang, Bang Zhang, Liefeng Bo
Institute for Intelligent Computing, Alibaba Group





二. 机器学习发展史

[爆肝2周，ChatGPT发布700天后，你需要知道的真相！ 哔哩哔哩 bilibili](#)

二. 机器学习发展史

案例：垃圾邮件过滤的三代方法

■ 第一代：人工写规则

例如：标题含“中奖”“免费”就判为垃圾邮件

■ 第二代：传统机器学习


人工提取词频特征，用朴素贝叶斯/逻辑回归分类

■ 第三代：深度学习/大模型

自动学习文本表示，理解上下文语义

二. 机器学习发展史

支付方式




二. 机器学习发展史

推荐系统



二. 机器学习发展史

刑侦犯罪



二. 机器学习发展史

聊天机器人



1960 ELIZA



1972 PARRY



2005 Siri



2022



2023



2025

二. 机器学习发展史

排名	企业名称	核心技术/业务领域	国家	成立时间	市值 (亿美元)
1	微软 (Microsoft)	自然语言处理、计算机视觉、云计算	美国	1975年	25,000
2	谷歌 (Google)	计算机视觉、自然语言处理、深度学习	美国	1998年	15,000
3	英伟达 (NVIDIA)	智能芯片、深度学习	美国	1993年	8,000
4	特斯拉 (Tesla)	自动驾驶、计算机视觉	美国	2003年	6,000
5	OpenAI	自然语言处理、深度学习	美国	2015年	800
6	字节跳动 (ByteDance)	跨媒体分析推理、深度学习、自然语言处理	中国	2012年	3000
7	百度 (Baidu)	计算机视觉、自然语言处理、知识图谱	中国	2001年	500
8	商汤科技 (SenseTime)	计算机视觉、深度学习	中国	2014年	100
9	科大讯飞 (iFlytek)	智能语音、自然语言处理	中国	1998年	150
10	IBM Watson	深度学习、智适应学习技术	美国	1911年	1,300
11	Graphcore	智能芯片、机器学习	英国	2016年	20
12	Brainco	脑机接口	美国	2015年	10
13	DeepMind	深度学习、强化学习	英国	2010年	N/A (被Google收购)
14	广汽奔腾 (GAC)	计算机视觉	中国	2011年	450
15	大象电子 (DJI)	智能芯片、智能自主技术	中国	2013年	250
16	亚马逊 (Amazon)	自然语言处理、云计算	美国	1994年	12,000
17	Meta (Facebook)	计算机视觉、自然语言处理	美国	2004年	7,000
18	阿里巴巴 (Alibaba)	自然语言处理、计算机视觉	中国	1999年	2,500
19	腾讯 (Tencent)	自然语言处理、计算机视觉	中国	1998年	4,000
20	苹果 (Apple)	自然语言处理、计算机视觉	美国	1976年	28,000

二. 机器学习发展史

国家新一代人工智能开放创新平台是国家认可、由企业主导的AI开放创新平台，目前已经有15家公司的平台入选：

Autonomous Driving  Baidu	City Brain  Alibaba	Medical Image  Tencent	Intelligent Voice  iFLYTEK	Computer Vision  SenseTime
Visual Computing  YITU	Marketing Intelligence  Mininglamp	Basic Software & hardware  Huawei	Inclusive Finance  Pingan	Video Perception  Hikvision
Intelligent Supply Chain  JingDong	Image Perception  Megvii	Security Brain  360	Intelligent Education  TAL	Smart Home  Xiaomi

前十名				
排名	企业	企业价值 (亿元人民币)	优势产品	总部城市
1	寒武纪	6,300	AI芯片	北京
2	摩尔线程	3,100	GPU	北京
3	沐曦股份	2,500	GPU	上海
4	科大讯飞	1,300	语音识别/自然语言处理	合肥
5	地平线	1,200	自动驾驶芯片	北京
6	稀宇极智	960	AIGC大模型	上海
7	商汤科技	900	视觉识别及AIGC	上海
8	芯原股份	890	IP模块授权/设计	上海
9	瑞芯微	790	AI应用处理器芯片	福州
10	壁仞科技	730	GPU	上海
来源：《2025胡润中国人工智能企业50强》				

二. 机器学习发展史


第一梯队，几乎一定要提

- **GPT 系列 (OpenAI)** : 目前 OpenAI 在官方文档里把 **GPT-5.4**列为复杂推理、编程和专业工作流的前沿模型。 OpenAI开发者
- **Gemini 系列 (Google)** : Google 在 2025 年推出并持续强化 **Gemini 2.5** 系列，把它定位为“最智能”的 Gemini 模型，并重点强调推理与代码能力。 blog.google +1
- **DeepSeek 系列 (DeepSeek)** : 这两年热度非常高，尤其是 **DeepSeek-R1** (推理) 和 **DeepSeek-V3/V3.1/V3.2** (通用/代理导向) 这一条线。官方更新页显示，R1 于 2025 年 1 月发布，之后还有 V3.1、V3.2 等迭代。 DeepSeek API D... +2

第二梯队，也很值得补充

- **Claude 系列 (Anthropic)** : 在写作、长文本、代码和企业使用里一直非常强，虽然你这页如果只想放“最火”的三个，可以不放，但讲“主流通用大模型版图”时很难绕开 Claude。
- **Llama 系列 (Meta)** : 开源生态里影响力极大，很多研究和应用都建立在它之上。
- **Grok 系列 (xAI)** : 这两年讨论度也很高，尤其在社交平台和实时信息结合方面常被提到。
- **Qwen / 通义千问 (阿里)** : 中文场景和开源生态里非常重要，国内课程里通常值得单列。
- **文心大模型 / ERNIE (百度)** : 如果你想兼顾国内主流厂商，也可以提。

二. 机器学习发展史



01 什么是机器学习?

02 机器学习发展史


03 机器学习包含什么?

04 机器学习通用流程

05 基础概念介绍

三. 机器学习包含什么？

按照问题类别划分：



三. 机器学习包含什么？

基本术语

数据： 创业学员的各种信息以及他们是否优秀的记录

输入 x (特征、属性)

输出 y (标签)

学员姓名	年龄	性别	学历	创业前身份	行业	是否优秀
吴良专	46	男	博士	科研人员	微电子	是
赵文军	40	男	博士	科研人员	金融	否
江峰	37	男	博士	企业管理者	半导体	是
...	...	...	...	...	...	...


样本: (x, y)

又称: 示例、样例

训练数据集 $D = \{(x_i, y_i)\}_{i=1}^l$

三. 机器学习包含什么？

按照问题类别划分：



三. 机器学习包含什么？

监督学习：训练数据**有标签**

数据： $(x_i, y_i)_{i=1}^l$

学习： $f: x \rightarrow y$

目标： 对未知 x ，预测对应 $y = f(x)$

- **分类：** y 取值离散
- **回归：** y 取值连续

三. 机器学习包含什么？

监督学习：训练数据**有标签**

数据： $(x_i, y_i)_{i=1}^l$

学习： $f: x \rightarrow y$

目标：对未知 x ，预测对应 $y = f(x)$

■ 分类： y 取值离散

■ 回归： y 取值连续



三. 机器学习包含什么？

监督学习：训练数据**有标签**

数据： $(x_i, y_i)_{i=1}^l$

学习： $f: x \rightarrow y$

目标：对未知 x ，预测对应 $y = f(x)$

■ 分类： y 取值离散

■ 回归： y 取值连续



我不是药神

2018 / 中国大陆 / 剧情 喜剧 / 文牧野 / 徐峥 王传君

★★★★★ 9.0



肖申克的救赎

1994 / 美国 / 剧情 犯罪 / 弗兰克·德拉邦特 / 蒂姆·罗宾斯 摩根·弗里曼

★★★★★ 9.7



盗梦空间

2010 / 美国 英国 / 剧情 科幻 悬疑 冒险 / 克里斯托弗·诺兰 / 莱昂纳多·迪卡普里奥 约瑟夫·高登-莱维特

★★★★★ 9.4



沙丘2

03月08日

剧情 / 动作 / 科幻

美国

137570人想看

预告片



★★★★★ 9.2



霸王别姬

1993 / 中国大陆 中国香港 / 剧情 爱情 同性 / 陈凯歌 / 张国荣 张丰毅

★★★★★ 9.6

三. 机器学习包含什么？

监督学习：训练数据**有标签**

数据： $(x_i, y_i)_{i=1}^l$

学习： $f: x \rightarrow y$

目标：对未知 x ，预测对应 $y = f(x)$

■ 分类： y 取值离散

■ 回归： y 取值连续



三. 机器学习包含什么？

无监督学习：训练数据**没有标签**

数据： $(x_i)_{i=1}^l$

目标：挖掘数据的内在结构和规律

- **聚类：**对数据分组
- **降维：**把数据投影到低维空间
- **生成：**生成类似数据

三. 机器学习包含什么？

无监督学习：训练数据**没有标签**

数据： $(x_i)_{i=1}^l$

目标：挖掘数据的内在结构和规律

- **聚类：**对数据分组
- **降维：**把数据投影到低维空间
- **生成：**生成类似数据



三. 机器学习包含什么？

无监督学习：训练数据**没有标签**

数据： $(x_i)_{i=1}^l$

目标：挖掘数据的内在结构和规律


- **聚类：**对数据分组
- **降维：**把数据投影到低维空间
- **生成：**生成类似数据

例：我想了解一下上咱们这门课的学生的学习情况
已知：姓名、**专业**、性别、年龄、身高、体重、**其他课成绩**、爱好.....



✓ 降低数据复杂度，减轻存储和计算压力

✓ 可视化





三. 机器学习包含什么？

无监督学习：训练数据**没有标签**

数据： $(x_i)_{i=1}^l$

目标：挖掘数据的内在结构和规律

- **聚类：**对数据分组
- **降维：**把数据投影到低维空间
- **生成：**生成类似数据



三. 机器学习包含什么？

半监督学习：训练数据**部分有标签**

数据： $(x_i, y_i)_{i=1}^l + (x_i)_{i=l+1}^{l+u}$

原因：数据标注困难



李飞飞



ImageNet: 来自全球 167 个国家近 5 万名工作者通过三年合作努力，标注出 1500 万图像，最终成为 AI 历史上的有标志性意义的数据集

情感分析

热门

认证用户

关注的人

共733条



键盘左边根号二：感情是双向的，鹿晗公布那一年，关晓彤也承受着鹿晗粉丝的巨大舆论攻击。两个人走到今天并不容易，是鹿晗的勇敢和担当，我很喜欢博主的那句话，他们没彼此消费过。感情没有杂糅其他事情。我很期待他们步入礼堂的那一天。

今天10:50



9794



至少today很快乐：你确定她没消费过鹿晗？随便甩出几张她作品带着鹿晗词条的热搜图hhhhh真笑了

今天10:59



1504



浪漫屏鸽：现在猜来猜去 没准人家突然来个结婚

今天10:54



1062



追逐记忆tt：没事过段时间又是鹿晗生日了 看关晓彤发不发微博

今天10:55



338



ii西米露：她是没有明着消费过，她爸妈做生意亏的那些钱不都还是lh出的

今天11:57



284



照烧薯条哈秋：.....人家两谈了这么久 8年啊 就算有矛盾甚至说万一分手了也不需要外人插嘴吧

今天11:29



606



丁敛Tieny：别带鹿晗了。评论配图

今天14:42



290



云外霜：我觉得他们现在的状态很像早期的谢娜和张杰分手那段时间 熬过了就踏入婚姻殿堂

三. 机器学习包含什么？


半监督学习：训练数据**部分有标签**

数据： $(x_i, y_i)_{i=1}^l + (x_i)_{i=l+1}^{l+u}$

已分类的垃圾

大量没分类的垃圾

目标：挖掘数据的内在结构和规律/预测y




机器学习过程






三. 机器学习包含什么？

强化学习的过程




智能体不断与环境进行交互，
根据经验调整其策略，
最大化其长远的所有奖励的累积值。



三. 机器学习包含什么？

按照问题类别划分：



三. 机器学习包含什么？

习题： 请判断下列任务分别属于监督学习、无监督学习、半监督学习还是强化学习：

- ① 根据历史成交价预测二手房价格
- ② 将电商用户自动分群
- ③ 只有少量猫狗图片有标签，大量图片无标签，要训练分类器
- ④ 训练一个智能体玩游戏，通过奖励不断提高得分
- ⑤ 银行根据历史违约记录判断贷款是否违约

01 什么是机器学习?


02 机器学习发展史


03 机器学习包含什么?

04 机器学习通用流程

05 基础概念介绍

四. 机器学习的基本流程






四. 机器学习的基本流程



四. 机器学习的基本流程



四. 机器学习的基本流程

1. 数据预处理

清洗数据：重复项、缺失值、错误数据等。

特征工程：选择、修改或创建新的特征。

2. 探索性数据分析

- 分析数据的分布、相关性和趋势。
- 使用可视化工具发现潜在的模式或异常。

3. 选择模型

- 基于问题的性质选择合适的机器学习算法。
- 考虑使用多个模型进行比较。

```
img = imread(os.path.join(image_dir, filename))  
img = resize(img, (64, 64)) # 调整图像大小为64x64  
img = img.flatten() # 展平图像数组
```

每张照片： $64*64*3=12288$ 维的向量，
并标注好类别

略

逻辑回归

四. 机器学习的基本流程

4. 训练模型


- 训练模型。
- 调整模型参数（调参）以提高性能。

```
# 训练模型  
model = LogisticRegression(max_iter=1000)  
model.fit(X, y)
```

5. 评估模型


- 评估模型性能。
- 选择合适的评估指标，如准确率、召回率、F1 分数、均方误差等。

测试集：



四. 机器学习的基本流程

Predicted: zhang



Predicted: zhang



Predicted: zhang



Predicted: pan



正确率: $3/4$

01 什么是机器学习?

02 机器学习发展史

03 机器学习包含什么?

04 机器学习通用流程

05 基础概念介绍

五. 基础概念介绍

■ 高等数学

导数、微分、泰勒公式.....

■ 线性代数

向量、矩阵、行列式、秩、线性方程组

■ 概率论与数理统计

随机事件和概率、概率的基本性质

■ 最优化方法

凸优化、梯度下降、拉格朗日.....

■ 编程

python、matlab

■ **线性代数**：表示数据和模型参数

■ **概率统计**：描述不确定性、评估模型效果

■ **高等数学**：理解梯度、优化过程

■ **最优化**：训练模型本质上是求最优参数

■ **Python**：实现算法和实验

五. 基础概念介绍

基本术语

数据： 创业学员的各种信息以及他们是否优秀的记录

输入 x (特征、属性)

输出 y (标签)

学员姓名	年龄	性别	学历	创业前身份	行业	是否优秀
吴良专	46	男	博士	科研人员	微电子	是
赵文军	40	男	博士	科研人员	金融	否
江峰	37	男	博士	企业管理者	半导体	是
...	...	...	...	...	...	...


样本: (x, y)

又称: 示例、样例

训练数据集 $D = \{(x_i, y_i)\}_{i=1}^l$

五. 基础概念介绍

模型、参数、超参数




模型: $f(x)$ 具体长啥样, 比如多项式函数

参数: 多项式函数里要学习的参数

超参数: 多项式到底要几项?

五. 基础概念介绍

训练集、验证集、测试集



训练集用来“学”

验证集用来“调”

测试集用来“考”

损失函数、评价指标




损失函数：训练时告诉模型“错了多少”

评估指标：测试时用来衡量模型整体表现

五. 基础概念介绍

过拟合、泛化

通过损失曲线判断模型训练状态



过拟合：在训练集效果好，在测试集效果差

01 什么是机器学习?

02 机器学习发展史

03 机器学习包含什么?

04 机器学习通用流程

05 基础概念介绍

谢谢



首都师范大学

CAPITAL NORMAL UNIVERSITY

不提交

1. 配置实验环境（见附件，也可自己查阅资料）

2. 初步尝试一个机器学习任务

使用老师提供的数据集，借助 AI 工具或相关资料，尝试完成一个简单的机器学习任务（可在sk-learn下载，也可自行找AI提供）。

例如：

- ✓ 数据读取与查看
- ✓ 简单的数据预处理
- ✓ 调用现有工具完成分类或回归
- ✓ 查看结果并进行初步分析

目的：对“机器学习项目大致在做什么”形成直观认识

要提交

作业 1：数据发现与问题设计

围绕一个你感兴趣的现实问题，自主寻找一个可用于分析的数据集，并完成简要说明。

提交：一份简短文档（不超过一页），包含四部分：问题描述、数据来源（附链接）、数据说明、初步设想说明。

目的：锻炼问题意识和数据发现能力，不要求完成建模。

作业 2：AI在我生活中的一天

以“AI在我生活中的一天”为题，结合自己的真实生活经历，描述从早上醒来到晚上休息这一天中，你接触到的与人工智能相关的应用、系统或场景，并尝试分析其背后可能涉及的模型、算法或技术原理。

提交：身边的AI技术清单（不超过一页）

目的：了解身边的AI，培养好奇心。

附. 主要工具与环境配置

Scikit-learn (Sklearn)

- 一个基于Python编程语言的开源机器学习库
- 提供包括分类、回归、聚类、降维等丰富的算法，可高效的实现数据预处理、特征选择及模型评估等工作
- 广泛应用于数据挖掘、数据分析和机器学习任务



安装

- Python 3.7及以上版本
- Windows、macOS、Linux操作系统均可
- 可用pip或者conda安装



[scikit-learn: machine learning in Python — scikit-learn 1.6.1 documentation](https://scikit-learn.org/stable/index.html)

Jupyter 是一个开源的交互式计算环境，广泛用于数据科学、机器学习和科研工作

Jupyter Notebook 是一种结合了代码、文本、数学公式 (LaTeX)、可视化和富媒体的文档格式。

文本

读取小批量

为了使我们在读取训练集和测试集时更容易，我们使用内置的数据迭代器，而不是从零开始创建。回顾一下，在每次迭代中，数据加载器每次都会**读取一小批量数据，大小为 `batch_size`**]。通过内置数据迭代器，我们可以随机打乱了所有样本，从而无偏见地读取小批量。

```
In [26]: ▶ batch_size = 256

def get_dataloader_workers(): #@save
    """使用4个进程来读取数据"""
    return 4

train_iter = data.DataLoader(mnist_train, batch_size, shuffle=True,
                             num_workers=get_dataloader_workers())
```

代码

我们看一下读取训练数据所需的时间。

运行结果

```
In [27]: ▶ timer = d2l.Timer()
for X, y in train_iter:
    continue
f' {timer.stop():.2f} sec'
```

```
Out[27]: ' 4.41 sec'
```


附. 主要工具与环境配置

- Python 安装

① Python官网 (Python.org) 下载最新版本Python 3.14.3

[Python](#)

② 安装并本地配置

[Python安装与环境配置全程详细教学（包含Windows版和Mac版）_python环境-CSDN博客](#)

③ 验证：“运行” 输入cmd----窗口中输入python---出现python版本即可

```
C:\Users\xhzha>python
Python 3.14.3 (tags/v3.14.3:323c59a, Feb  3 2026, 16:04:56) [MSC v.1944 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license" for more information.
>>> |
```

附. 主要工具与环境配置

pip安装是Python包管理工具，提供一些Python包的查找、下载、安装及卸载等

Python 2.7.9 + 或 Python 3.4+ 以上版本自带pip工具

- Jupyter安装 cmd改目录等操作自行检索 cd.....

① “运行” 输入cmd----窗口中输入 `pip install jupyter notebook` (有外网代理的, 关掉代理)

② 验证: 窗口中输入jupyter notebook ---出现版本即可

- Sklearn安装

① “运行” 输入cmd----窗口中输入 `pip install scikit-learn`

② 验证: 当前cmd目录中输入jupyter notebook。在该目录下即生成了对应的jupyter noetbook的界面。Kernel菜单中选择安装的Python内核, 确保特定环境的Python版本; 新建Notebook, 输入以下代码并运行验证

```
import sklearn
print(sklearn.__version__)

1.8.0
```

自行搜索Jupyter的基本操作指南即可

具体任务：

搜索相关教程，熟悉Jupyter notebook的界面

如何启动Jupyter notebook?

尝试修改Jupyter notebook的默认路径

如何建立虚拟环境?

