




上一课总结

- 一. 什么是机器学习?
- 二. 机器学习发展史
- 三. 机器学习包含什么?
- 四. 机器学习通用流程
- 五. 基础概念介绍






无监督学习

数据 (无标签) : $(x_i)_{i=1}^l$

目标: 挖掘数据的内在结构和规律

■ **聚类**: 对数据分组

■ **降维**: 把数据投影到低维空间





第二课

聚类简介

授课教师：潘贤丽



大纲

01 聚类是什么

02 聚类的应用场景


03 聚类方法的发展图谱

04 经典聚类方法与案例实践

05 从经典方法到前沿方法

06 聚类结果的评价

一. 聚类是什么




Intuitively, clustering is the task of grouping a set of objects such that *similar objects end up in the same group* and *dissimilar objects are separated into different groups*.

——《understanding machine learning》 P_{307}




目的：将样本划分为若干个不相交的“簇” (cluster)

条件：簇内相似度高 且 簇间相似度低



一. 聚类是什么

核心问题：什么样的数据算一组？



如果是高维情况呢？

一. 聚类是什么

核心问题： 什么样的数据算一组？

用户编号	日均观看时长 (min)	日均滑动次数	完播率	点赞数/天	评论数/天	分享数/天	收藏数/天	关注作者数/周	夜间活跃占比	偏好内容类别数	广告点击率
用户01	128	342	0.71	18	3	2	4	6	0.62	5	0.08
用户02	46	185	0.38	4	0	0	1	1	0.21	2	0.03
用户03	173	401	0.79	25	5	4	6	8	0.74	6	0.11
用户04	92	267	0.55	9	1	1	2	3	0.48	4	0.05
用户05	214	463	0.83	31	6	5	8	10	0.81	7	0.14
用户06	38	142	0.29	2	0	0	0	0	0.16	2	0.02
用户07	156	376	0.76	22	4	3	5	7	0.69	6	0.10
用户08	64	223	0.47	6	1	0	1	2	0.33	3	0.04
用户09	189	428	0.81	28	5	4	7	9	0.77	7	0.12
用户10	57	204	0.41	5	0	1	1	1	0.27	3	0.03



大纲

01 聚类是什么

02 聚类的应用场景

03 聚类方法的发展图谱


04 经典聚类方法与案例实践

05 从经典方法到前沿方法

06 聚类结果的评价

二. 聚类的应用场景

精准营销




二. 聚类的应用场景

图像处理




图像压缩



图像分割

二. 聚类的应用场景

文本主题挖掘



美伊谈判真相几何？霍尔木兹海峡是一块不会说谎的试金石

美数课 18



夜读 | 君迁子

澎湃评论



3.6万条社媒评论告诉你，短剧的“人感”为什么越来越重要

美数课 21



一月内三次全国大断电，古巴正在发生什么？ | 907编辑部

澎湃世界观 31



澎湃漫评 | 马拉松不欢迎“打包哥”“劈叉姐”




【社论】长护险来了，以制度保障“体面养老”



马上评 | 什么样的热播剧才是真的“热”



马上评 | 大学生需要什么样的科普





大纲

01 聚类是什么

02 聚类的应用场景


03 聚类方法的发展图谱

04 经典聚类方法与案例实践

05 从经典方法到前沿方法

06 聚类结果的评价

三. 聚类方法的发展图谱



01 聚类是什么

02 聚类的应用场景

03 聚类方法的发展图谱

04 经典聚类方法与案例实践

05 从经典方法到前沿方法

06 聚类结果的评价

四.经典聚类方法与案例实践

基于中心

K-means

基于分布

GMM

基于密度

DBSCAN、Meanshift


基于图结构

谱聚类


四.经典聚类方法与案例实践

层次聚类

中心思想：不断按某种簇间相似性规则去合并，最后形成一棵树



层次聚类



聚类树

重点：如何度量距离(相似度)?

层次聚类

- 点与点间的距离:


e.g. 闵可夫斯基距离(Minkowski distance):

$$d(x_i, x_j) = (||x_i - x_j||^p)^{\frac{1}{p}}$$

$p = 1$: 曼哈顿距离

$p = 2$: 欧氏距离 (注意数量级)

余弦距离: 方向上的相似性



四.经典聚类方法与案例实践

举例：用户画像


用户	短视频娱乐	音乐	游戏直播	体育资讯	美食内容
用户A	40	30	20	5	5
用户B	8	6	4	1	1
用户C	5	5	10	35	25
用户D	4	3	2	1	0
用户E	2	25	30	3	5

四.经典聚类方法与案例实践


层次聚类

簇与簇间的距离:


$$d_{min}(C_i, C_j) = \min_{p \in C_i, q \in C_j} d(p, q)$$




$$d_{max}(C_i, C_j) = \max_{p \in C_i, q \in C_j} d(p, q)$$



$$d_{mean}(C_i, C_j) = d(u_i, u_j)$$




$$d_{avg}(C_i, C_j) = \frac{1}{|C_i||C_j|} \sum_{p \in C_i, q \in C_j} d(p, q)$$




四.经典聚类方法与案例实践

层次聚类


最小




最大









平均



均值



方差



四.经典聚类方法与案例实践

基于中心

K-means

基于分布

GMM


基于密度

DBSCAN、Meanshift

基于图结构

谱聚类

K-means



中心思想：每个簇都有个中心点（质心）

选取 k 个初始质心（人为设定）


repeat:

将每个样本点归类为距其最近的质心所在簇

重新计算 k 个簇对应的质心

until 质心不再发生变化

K-means



问题1：迭代会不会无限进行下去？

问题2：不同初始点是否会对结果产生影响？

四.经典聚类方法与案例实践

K-means

K-means的目标：找到K个质心，形成K个对应的簇，使每个样本到自己簇所在质心的距离比到别的质心的距离小：

$$\min G(u, C) = \sum_{i=1}^k \sum_{x \in C_i} d(x, u_i)^2$$

质心： $u = \{u_1, u_2, \dots, u_k\}$

簇： $C = \{C_1, C_2, \dots, C_k\}$

交替迭代求解：

初始化 u

已知 u ，求使 $G(u, C)$ 最小的 C

已知 C ，求使 $G(u, C)$ 最小的 u

选取k个初始质心；


repeat:

→ 将每个样本点归类为距其最近的质心所在簇

→ 重新计算k个簇对应的质心

until 质心不再发生变化

K-means



问题1：迭代会不会无限进行下去？

不会，目标函数值在不断下降





$$G(u^{(t)}, C^{(t)}) \leq G(u^{(t-1)}, C^{(t-1)})$$

问题2：不同初始点是否会对结果产生影响？

会，优化目标非凸，收敛到局部最优

四.经典聚类方法与案例实践


K-means



K-means


缺点：并非适用于所有数据情况

- 不同密度



K-means (3 Clusters)


- 非球状



K-means (2 Clusters)

K-means

应用举例：对一副高维度像素的图像进行相似像素色聚类



四.经典聚类方法与案例实践

基于中心

K-means

基于分布

GMM

基于密度

DBSCAN、Meanshift

基于图结构

谱聚类

四.经典聚类方法与案例实践

高斯混合模型 (GMM)

背景基础：统计上一般假设总体服从某分布D,样本点从该分布采样得到





Carl F. Gauss (1777 – 1855)

高斯分布（概率密度函数）：

$$P(x) = \frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}} e^{-\frac{1}{2} (x-\mu)^T \Sigma^{-1} (x-\mu)}$$

- 均值 μ
- 协方差矩阵 Σ




四.经典聚类方法与案例实践


高斯混合模型 (GMM)

原理:

任意连续的概率分布 $\approx$
多个高斯分布加权组合



近似



混合系数


高斯混合分布: $P_M(x) = \sum_{i=1}^k \alpha_i \cdot p(x|\mu_i, \Sigma_i)$

第*i*个高斯分布的概率密度函数

混合系数满足: $\alpha_i \geq 0, \sum_{i=1}^k \alpha_i = 1$

高斯混合模型 (GMM)

高斯混合聚类模型：任意一个簇由一个高斯分布函数（原型）刻画




四.经典聚类方法与案例实践

高斯混合模型 (GMM)

高斯混合分布的概率密度函数: $P_M(x) = \sum_{i=1}^k \alpha_i \cdot p(x|\mu_i, \Sigma_i)$

混合系数满足: $\alpha_i \geq 0, \sum_{i=1}^k \alpha_i = 1$



参数:

k : 人为设定

$\alpha_i, \mu_i, \Sigma_i$: 根据数据求解

任务: 根据数据, 估计高斯混合分布函数的参数

四.经典聚类方法与案例实践

高斯混合模型 (GMM)

问题：已知样本集 D ，如何估计参数 $\{(\alpha_i, \mu_i, \Sigma_i) | 1 \leq i \leq k\}$ ？

$$P_M(x) = \sum_{i=1}^k \alpha_i \cdot p(x | \mu_i, \Sigma_i)$$

方法：极大似然估计

$$\begin{aligned} LL(D) &= \ln \left(\prod_{j=1}^m P_M(x_j) \right) \\ &= \sum_{j=1}^m \ln \left(\sum_{i=1}^k \alpha_i \cdot p(x_j | \mu_i, \Sigma_i) \right) \end{aligned}$$

补充材料：统计中有一类问题，叫参数估计问题。说的是已知某个随机样本满足某种概率分布，但是其中具体的参数不清楚，我们需要估计它的值。**极大似然估计**是其中一种经典的方法。它的思想是：已知某个参数能使这个样本出现的概率最大，那我们就把这个参数作为估计的真实值。

四.经典聚类方法与案例实践

高斯混合模型 (GMM)

$$\begin{aligned}
 \max \quad & LL(D) = \sum_{j=1}^m \ln \left(\sum_{i=1}^k \alpha_i \cdot p(x_j | \mu_i, \Sigma_i) \right) \\
 \text{s.t.} \quad & \alpha_i \geq 0, \quad \sum_{i=1}^k \alpha_i = 1
 \end{aligned}
 \quad \rightarrow \quad
 \begin{cases}
 \frac{\partial LL(D)}{\partial \mu_i} = 0 \\
 \frac{\partial LL(D)}{\partial \Sigma_i} = 0 \\
 LL(D) + \lambda \left(\sum_{i=1}^k \alpha_i - 1 \right)
 \end{cases}$$

对 α_i 的导数为 0

$$\mu_i = \frac{\sum_{j=1}^m \gamma_{ji} x_j}{\sum_{j=1}^m \gamma_{ji}}$$

$$\Sigma_i = \frac{\sum_{j=1}^m \gamma_{ji} (x_j - \mu_i)(x_j - \mu_i)^T}{\sum_{j=1}^m \gamma_{ji}}$$

$$\alpha_i = \frac{1}{m} \sum_{j=1}^m \gamma_{ji}$$

高斯混合模型 (GMM)

样本由 k 个高斯混合分布产生: $P_M(x) = \sum_{i=1}^k \alpha_i \cdot p(x|\mu_i, \Sigma_i)$

样本 x_j 由第 i 个高斯分布生成的后验概率 (简记为 γ_{ji}) :

$$\gamma_{ji} = P_M(z_j = i | x_j) = \frac{P(z_j = i) \cdot P_M(x_j | z_j = i)}{P_M(x_j)} = \frac{\alpha_i \cdot p(x_j | \mu_i, \Sigma_i)}{\sum_{l=1}^k \alpha_l \cdot p(x_j | \mu_l, \Sigma_l)}$$

z_j : 生成样本 x_j 的高斯分布

四.经典聚类方法与案例实践

高斯混合模型 (GMM)

EM 算法:

- 选定 k , 并初始化 $\{(\alpha_i, \mu_i, \Sigma_i) | 1 \leq i \leq k\}$
- **(E步)** 根据当前参数计算每个样本属于每个高斯成分的后验概率 γ_{ji}

$$\gamma_{ji} = P_M(z_j = i | x_j) \quad (1 \leq i \leq k)$$



- **(M步)** 更新高斯分布参数 $\{(\alpha_i, \mu_i, \Sigma_i) | 1 \leq i \leq k\}$ 使样本出现概率最大

$$\mu_i = \frac{\sum_{j=1}^m \gamma_{ji} x_j}{\sum_{j=1}^m \gamma_{ji}} \quad \Sigma_i = \frac{\sum_{j=1}^m \gamma_{ji} (x_j - \mu_i)(x_j - \mu_i)^T}{\sum_{j=1}^m \gamma_{ji}} \quad \alpha_i = \frac{1}{m} \sum_{j=1}^m \gamma_{ji}$$

- 重复上述EM步骤直至收敛
- 根据每个数据点属于每个簇的**概率**确定簇划分









四.经典聚类方法与案例实践

高斯混合模型 (GMM)



四.经典聚类方法与案例实践

高斯混合模型 (GMM)



四.经典聚类方法与案例实践

基于中心

K-means

基于分布

GMM

基于密度

DBSCAN、Meanshift

基于图结构

谱聚类

DBSCAN

全称: Density-Based Spatial Clustering of [Applications with Noise](#)

主要思想:

找出样本点中所有的密集区域，形成**聚类**

不在密集区域内的样本作为**噪音**

四.经典聚类方法与案例实践

DBSCAN

给定数据集 $D = \{x_1, x_2, \dots, x_m\}$ 和邻域参数 $(\epsilon, MinPts)$

定义如下概念:

- **核心对象(core object):** 若 x_i 的 ϵ -邻域至少包含 $MinPts$ 个样本, 即 $|N_\epsilon(x_i)| \geq MinPts$, 则 x_i 是一个核心对象;
- **密度直达(directly density-reachable):** 若 x_j 位于 x_i 的 ϵ -邻域中, 且 x_i 是核心对象, 则称 x_j 由 x_i 密度直达;
- **密度可达(density-reachable):** 对 x_j 与 x_i , 若存在样本序列 $p_1, p_2, \dots, p_n$, 其中 $p_1 = x_i$, $p_n = x_j$ 且 p_{i+1} 由 p_i 密度直达, 则称 x_j 由 x_i 密度可达;
- **密度相连(density-connected):** 对 x_i 与 x_j , 若存在 x_k 使得 x_i 与 x_j 均由 x_k 密度可达, 则称 x_j 与 x_i 密度相连.

四.经典聚类方法与案例实践


DBSCAN

给定数据集

$$D = \{x_1, x_2, \dots, x_m\}$$

邻域参数

$(\epsilon, MinPts)$



四.经典聚类方法与案例实践

DBSCAN

设定: $MinPts = 5$, ϵ 如图


概念:

核心对象(红色点)

密度直达

密度可达(绿色箭头)

密度相连




异常点

白话备注: 把所有密度相连的样本聚在一起, 生成簇

DBSCAN定义“簇”为: 由密度可达关系导出的最大密度相连的样本集合


DBSCAN



DBSCAN

DBSCAN的优点:

- 对数据集形状无要求
- 可做异常点检测
- 自动确定聚类数目



epsilon = 1.00
minPoints = 4


Restart

Pause

Meanshift


基本思想： 沿着密度上升方向寻找同属一个簇的数据点

主要过程：



- ① 把每个样本点都当成一个初始 center
- ② 对每个 center 反复做**加权均值更新**
- ③ 直到 center 基本不动，认为收敛
- ④ 很多点会收敛到相同或很接近的位置
- ⑤ 把这些接近的收敛位置合并成一个簇中心
- ⑥ 每个样本所属的簇，就由它最终收敛到的峰决定

Meanshift



核心：均值计算公式

$$m(x_i) = \frac{\sum_{x_j \in N(x_i)} K \left(\left\| \frac{x_j - x_i}{h} \right\|^2 \right) x_j}{\sum_{x_j \in N(x_i)} K \left(\left\| \frac{x_j - x_i}{h} \right\|^2 \right)}$$

$$K(z) = \exp \left(-\frac{z}{2} \right)$$

四.经典聚类方法与案例实践

Meanshift

优点:

- 对数据集形状无要求
- 不受异常点影响 (鲁棒)
- 自动确定聚类数目

经典应用:

- 视频追踪



IEEE CVPR 2000

Real-Time Tracking of Non-Rigid Objects using Mean Shift

Dorin Comaniciu Visvanathan Ramesh

Imaging & Visualization Department

Siemens Corporate Research

755 College Road East, Princeton, NJ 08540

Peter Meer

Electrical & Computer Engineering Department

Rutgers University

94 Brett Road, Piscataway, NJ 08855

Abstract

A new method for real-time tracking of non-rigid objects seen from a moving camera is proposed. The central computational module is based on the mean shift iterations and finds the most probable target position in the current frame. The dissimilarity between the target model (its color distribution) and the target candidates is expressed by a metric derived from the Bhattacharyya coefficient. The theoretical analysis of the approach shows that it relates to the Bayesian framework while providing a practical, fast and efficient solution. The capability of the tracker to handle in real-time partial occlusions, significant clutter, and target scale variations, is demonstrated for several image sequences.

1 Introduction

The first step in the proposed method is to extract

2 Mean Shift Analysis

We define next the sample mean shift, introduce the iterative mean shift procedure, and present a new theorem showing the convergence for kernels with convex and monotonic profiles. For applications of the mean shift property in low level vision (filtering, segmentation) see [6].

2.1 Sample Mean Shift

Given a set $\{\mathbf{x}_i\}_{i=1\dots n}$ of n points in the d -dimensional space R^d , the *multivariate kernel density estimate* with kernel $K(\mathbf{x})$ and window radius (bandwidth) h , computed in the point $\mathbf{x}$ is given by

$$\hat{f}(\mathbf{x}) = \frac{1}{nh^d} \sum_{i=1}^n K\left(\frac{\mathbf{x} - \mathbf{x}_i}{h}\right). \quad (1)$$

四.经典聚类方法与案例实践

基于中心

K-means

基于分布

GMM

基于密度


DBSCAN、Meanshift

基于图结构

谱聚类

谱聚类

思想：利用图论的知识研究聚类问题，将其转化成“切图问题”




四.经典聚类方法与案例实践

谱聚类

图论相关知识复习:


图 $G(V, E)$: 由顶点(Vertexes)的集合 V 和边(Edges)的集合 E 构成



名称	特征
无向图	边没有方向的图
有向图	边有方向的图
加权无向图	边有权（值）但没有方向的图
加权有向图	边有权（值）但有方向的图

四.经典聚类方法与案例实践

谱聚类



w_{ij} : 点 v_i 和点 v_j 之间的权重

邻接矩阵 W :

$$\begin{pmatrix} 0 & 2 & 3 & 4 \\ 2 & 0 & 2 & 0 \\ 3 & 2 & 0 & 3 \\ 4 & 0 & 3 & 0 \end{pmatrix}$$

对于图中任意一点 v_i , 它的度 d_i 定义为 $d_i = \sum_j w_{ij}$

度矩阵 D :

$$\begin{pmatrix} d_1 & \cdots & \cdots \\ \vdots & \ddots & \vdots \\ \cdots & \cdots & d_n \end{pmatrix}$$

四.经典聚类方法与案例实践

谱聚类


拉普拉斯矩阵 (Laplacian matrix) :

定义: $L = D - W$

性质:

- 对于任意的向量 f ,我们有

$$f^T L f = \frac{1}{2} \sum_{i,j=1}^n w_{ij} (f_i - f_j)^2$$



$$W = \begin{pmatrix} 0 & 2 & 3 & 4 \\ 2 & 0 & 2 & 0 \\ 3 & 2 & 0 & 3 \\ 4 & 0 & 3 & 0 \end{pmatrix}$$


$$d_i = \sum_j w_{ij}$$

$$D = \begin{pmatrix} d_1 & \cdots & \cdots \\ \vdots & \ddots & \vdots \\ \cdots & \cdots & d_n \end{pmatrix}$$

四.经典聚类方法与案例实践

谱聚类

接下来我们回到聚类这件事情上来：



四.经典聚类方法与案例实践

谱聚类

基本思想： 距离较远的两点之间的边权重值较低，而距离较近的两点之间的边权重值较高

相似矩阵 S ： $S_{ij} = \exp(-\frac{\|x_i - x_j\|_2^2}{2\sigma^2})$


- 多项式核函数
- 高斯核函数 (RBF)
- Sigmoid核函数

邻接矩阵 W ：


全连接法： $W_{ij} = S_{ij} = \exp(-\frac{\|x_i - x_j\|_2^2}{2\sigma^2})$

KNN法：

$$W_{ij} = W_{ji} = \begin{cases} 0 & x_i \notin KNN(x_j) \text{ and } x_j \notin KNN(x_i) \\ \exp\left(-\frac{\|x_i - x_j\|_2^2}{2\sigma^2}\right) & x_i \in KNN(x_j) \text{ and } x_j \in KNN(x_i) \end{cases}$$



谱聚类



怎么做聚类？

切图：将图 $G(V, E)$ 切成相互没有连接的 K 个子图（簇）： $A_1, A_2, \dots, A_K$

自然的想法：我希望各子图之间的连接尽可能弱

四.经典聚类方法与案例实践

谱聚类


对于任意两个子图点的集合 $A, B \subset V, A \cap B = \emptyset$, 我们定义A和B之间的切图权重为:

$$W(A, B) = \sum_{i \in A, j \in B} w_{ij}$$

那么对于我们k个子图点的集合: $A_1, A_2, \dots, A_k$, 我们定义切图cut为:

$$cut(A_1, A_2, \dots, A_k) = \frac{1}{2} \sum_{i=1}^k W(A_i, A_i')$$

mincut problem
(最小割问题)



最小割问题容易单独切出边缘点或产生歪斜分割

谱聚类

RatioCut:
(比例割)

$$RatioCut(A_1, A_2, \dots, A_k) = \frac{1}{2} \sum_{i=1}^k \frac{W(A_i, A_i')}{|A_i|}$$

谱聚类就是一种近似求解最小化 *RatioCut* 问题的方法

四.经典聚类方法与案例实践

谱聚类

引入变量:
$$h_{ij} = \begin{cases} 0 & v_i \notin A_j \\ \frac{1}{\sqrt{|A_j|}} & v_i \in A_j \end{cases}$$
 由此定义的H矩阵是什么?

$$h_i^T L h_i = \frac{1}{2} \sum_{m=1} \sum_{n=1} w_{mn} (h_{im} - h_{in})^2$$

h_i : H 的第*i*列

$$= \frac{1}{2} \left(\sum_{m \in A_i, n \notin A_i} w_{mn} \left(\frac{1}{\sqrt{|A_i|}} - 0 \right)^2 + \sum_{m \notin A_i, n \in A_i} w_{mn} \left(0 - \frac{1}{\sqrt{|A_i|}} \right)^2 \right)$$

$$= \frac{1}{2} \left(\sum_{m \in A_i, n \notin A_i} w_{mn} \frac{1}{|A_i|} + \sum_{m \notin A_i, n \in A_i} w_{mn} \frac{1}{|A_i|} \right)$$

$$= \frac{1}{2} \left(W(A_i, A_i') \frac{1}{|A_i|} + W(A_i', A_i) \frac{1}{|A_i|} \right)$$

$$= \frac{W(A_i, A_i')}{|A_i|}$$

$$f^T L f = \frac{1}{2} \sum_{i,j=1}^n w_{ij} (f_i - f_j)^2$$

四.经典聚类方法与案例实践

谱聚类

$$\text{RatioCut}(A_1, A_2, \dots, A_k) = \frac{1}{2} \sum_{i=1}^k \frac{W(A_i, A_i')}{|A_i|}$$

引入变量:
$$h_{ij} = \begin{cases} 0 & v_i \notin A_j \\ \frac{1}{\sqrt{|A_j|}} & v_i \in A_j \end{cases} \quad h_i^T L h_i = \frac{W(A_i, A_i')}{|A_i|} \quad h_i: H \text{ 的第 } i \text{ 列}$$

$$\text{RatioCut}(A_1, A_2, \dots, A_k) = \sum_{i=1}^k h_i^T L h_i = \sum_{i=1}^k (H^T L H)_{ii} = \text{tr}(H^T L H)$$

四.经典聚类方法与案例实践

谱聚类

$$\text{RatioCut}(A_1, A_2, \dots, A_k) = \frac{1}{2} \sum_{i=1}^k \frac{W(A_i, A_i')}{|A_i|}$$



$$\arg \min \text{tr}(H^T L H) \quad \text{s.t. } H^T H = I$$

$$h_{ij} = \begin{cases} 0 & v_i \notin A_j \\ \frac{1}{\sqrt{|A_j|}} & v_i \in A_j \end{cases} \quad \text{NP-hard问题}$$

方法：找 L 的 K 个最小特征值，取对应的 K 个特征向量组成的矩阵作为 H

四.经典聚类方法与案例实践

- A 点: $[1, 0]$
- B 点: $[1, 0]$
- C 点: $[0, 1]$



- A 点: $[0.98, 0.05]$
- B 点: $[0.91, 0.12]$
- C 点: $[0.08, 0.95]$

四.经典聚类方法与案例实践

谱聚类

步骤:

一种降维手段，因此在处理高维数据聚类时的复杂度比传统聚类算法好

① 给定数据点

② 计算邻接矩阵 W ，度矩阵 D

③ 计算拉普拉斯矩阵 $L = D - W$

④ 找 L 的最小的 K 个特征值，取它们对应的 K 个特征向量组成的矩阵作为
 H （不是真实的解 H ，并不能直接导出聚类结果）

⑤ 对 H 按行标准化:

$$h_{ij}^* = \frac{h_{ij}}{(\sum_{t=1}^k h_{it}^2)^{1/2}}$$

⑥ 对标准化后的矩阵，每一行作为一个新样本（依旧是 m 个样本），采用K-means（或其它聚类方法）再进行聚类，取最终的聚类结果

谱聚类

应用： 图像区域分割 (*segmentation*)



四.经典聚类方法与案例实践

基于中心

K-means

基于分布

GMM

基于密度

DBSCAN、Meanshift

基于图结构

谱聚类

01 聚类是什么

02 聚类的应用场景

03 聚类方法的发展图谱

04 经典聚类方法与案例实践

05 从经典方法到前沿方法

06 聚类结果的评价

五.从经典方法到前沿方法

经典方法的统一视角：聚类方法到底在争论什么？


K-means

靠近同一个中心




GMM

来自同一个高斯成分




DBSCAN / Mean Shift

DBSCAN: 密度连通
Mean Shift: 趋向同一密度峰



谱聚类

组内连接强，组间连接弱



五.从经典方法到前沿方法

01

方向 1: 深度聚类

表示学习 + 聚类联合训练

- 输入数据 → 编码器 → 潜在表示 → 聚类损失

02

方向 2: 图聚类 / 社区发现

图结构 + 表示学习结合

- 社交网络
- 推荐
- 知识图谱

03

方向 3: 多视图聚类

多个模态 / 多种特征

- 图像 + 文本
- 表格 + 图结构
- 多传感器、多来源数据

04

方向 4: 非欧几里得聚类

流形 / 双曲空间中的聚类

- 层级关系
- 树状结构
- 复杂语义结构

- Zhou, S., Xu, H., Zheng, Z., et al. A Comprehensive Survey on Deep Clustering: Taxonomy, Challenges, and Future Directions. arXiv, 2022.
- Berahmand, K., Saberi-Movahed, F., Sheikhpour, R., et al. A Comprehensive Survey on Spectral Clustering with Graph Structure Learning. arXiv, 2025.
- Zhou, L., et al. A Survey and an Empirical Evaluation of Multi-View Clustering Approaches. ACM Computing Surveys, 2024.
- Jaćimović, V., & Crnković, A. Clustering in Hyperbolic Balls. arXiv, 2025.

01 聚类是什么

02 聚类的应用场景

03 聚类方法的发展图谱

04 经典聚类方法与案例实践

05 从经典方法到前沿方法

06 聚类结果的评价


六. 聚类结果的评价

内部评价

不需要标签

同组是否紧凑？不同组是否分开？

- ✓ 轮廓系数：越大越好
- ✓ DBI：越小越好




外部评价

需要参考标签

聚类分组与参考分组有多一致？

- ✓ ARI：比较样本分组的一致性
- ✓ NMI：衡量两种分组的共享信息

两者通常越大越好



任务导向评价

关注实际用途

分组是否帮助解决实际问题？

- ✓ 用户分群：营销效果是否提升？
- ✓ 图像分割：区域是否符合需求？



指标是参考，还要结合数据特点与实际目标

01 聚类是什么

02 聚类的应用场景

03 聚类方法的发展图谱

04 经典聚类方法与案例实践

05 从经典方法到前沿方法

06 聚类结果的评价


[Install](#)
[User Guide](#)
[API](#)
[Examples](#)
[More ▾](#)

scikit-learn

Machine Learning in Python

[Getting Started](#)
[Release Highlights for 1.0](#)
[GitHub](#)


- Simple and efficient tools for predictive data analysis
- Accessible to everybody, and reusable in various contexts
- Built on NumPy, SciPy, and matplotlib
- Open source, commercially usable - BSD license

Classification

Identifying which category an object belongs to.

Applications: Spam detection, image recognition.

Algorithms: SVM, nearest neighbors, random forest, and more...




Examples

Regression

Predicting a continuous-valued attribute associated with an object.

Applications: Drug response, Stock prices.

Algorithms: SVR, nearest neighbors, random forest, and more...




Examples

Clustering

Automatic grouping of similar objects into sets.

Applications: Customer segmentation, Grouping experiment outcomes

Algorithms: k-Means, spectral clustering, mean-shift, and more...



Examples

Dimensionality reduction

Reducing the number of random variables to consider.

Applications: Visualization, Increased efficiency

Algorithms: k-Means, feature selection, non-negative matrix factorization, and more...

Model selection

Comparing, validating and choosing parameters and models.

Applications: Improved accuracy via parameter tuning


Algorithms: grid search, cross validation, metrics, and more...

Preprocessing

Feature extraction and normalization.

Applications: Transforming input data such as text for use with machine learning algorithms.

Algorithms: preprocessing, feature extraction, and more...



“The observation of and the search for similarities and differences are the basis of all human knowledge.”

—— ALFRED B. NOBEL

“人类所有知识的基础就是观察和寻找相似与相异”

—— 阿尔弗雷德·伯恩哈德·诺贝尔



谢谢



首都师范大学

CAPITAL NORMAL UNIVERSITY