上一课总结

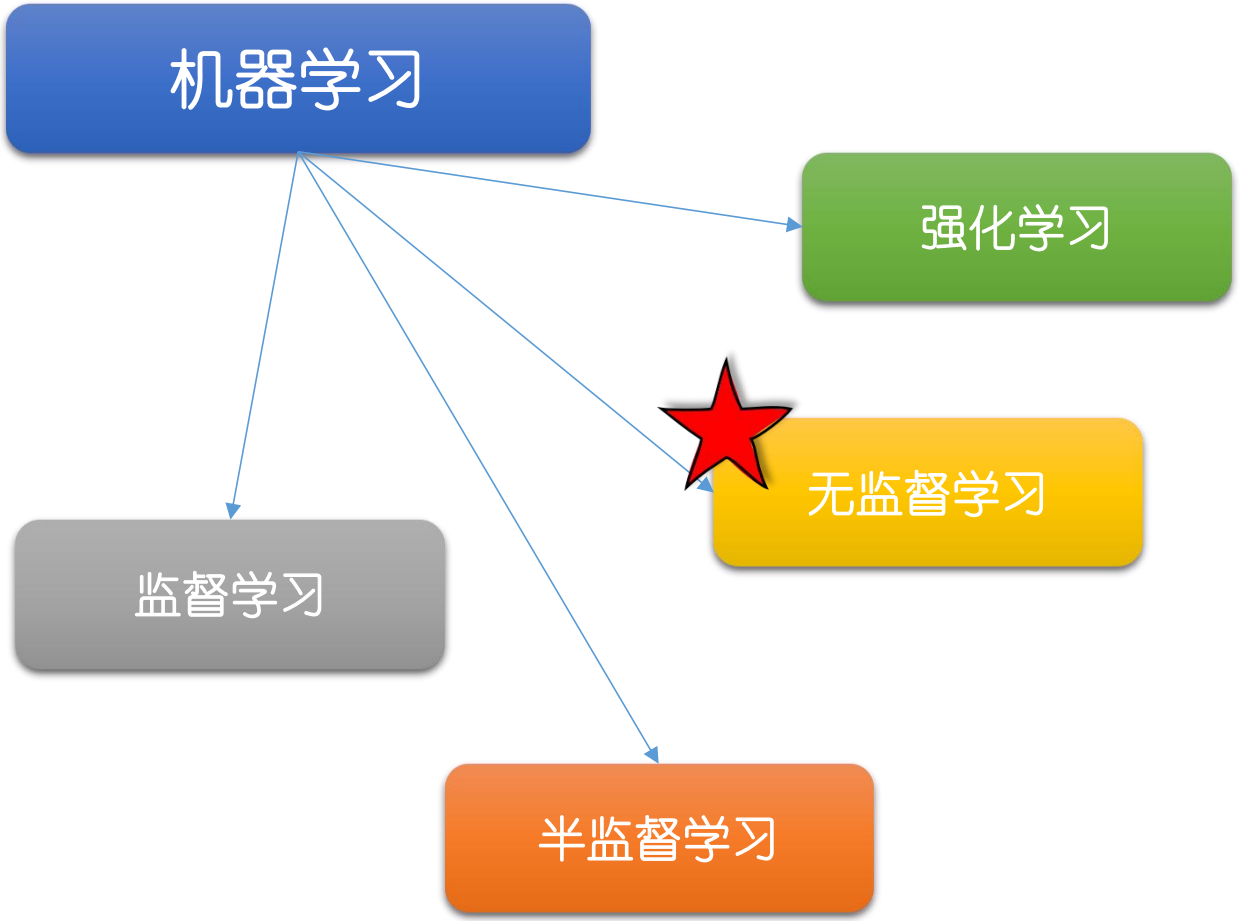
一．什么是机器学习?

二．机器学习发展史

三．机器学习包含什么?

四．机器学习通用流程

五．基础概念介绍

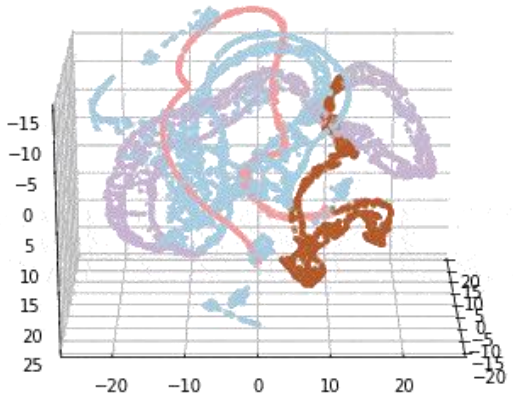


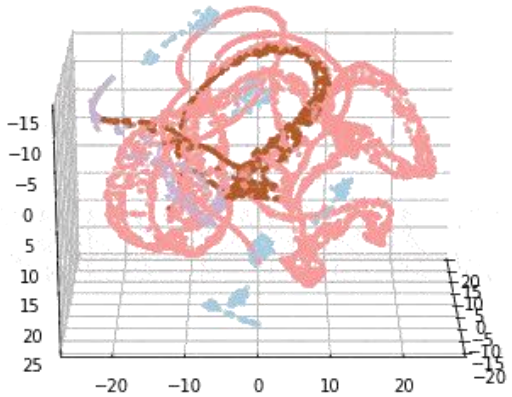
无监督学习

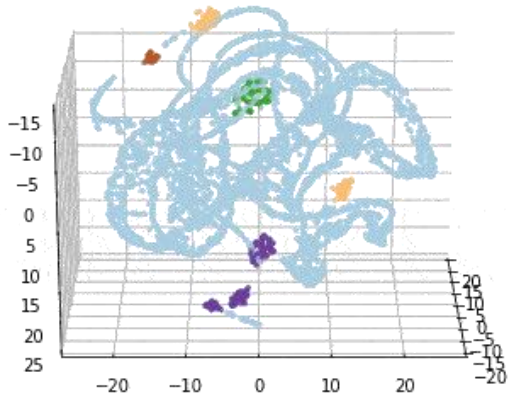
数据（无标签）： $(x_i)_{i=1}^{l}$

目标： 挖掘数据的内在结构和规律

- **聚类：** 对数据分组
- **降维：** 把数据投影到低维空间







首都师范大学
CAPITAL NORMAL UNIVERSITY



第二课
聚类简介

授课教师：潘贤丽

大纲

首都师范大学 CAPITAL NORMAL UNIVERSITY

01 聚类是什么

02 聚类的应用场景

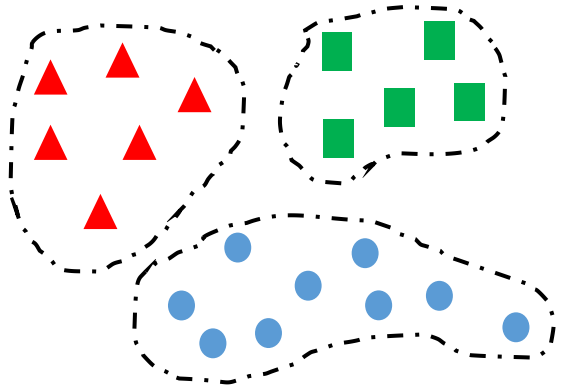
03 聚类方法的发展图谱

04 经典聚类方法与案例实践

05 从经典方法到前沿方法

06 聚类结果的评价

一. 聚类是什么

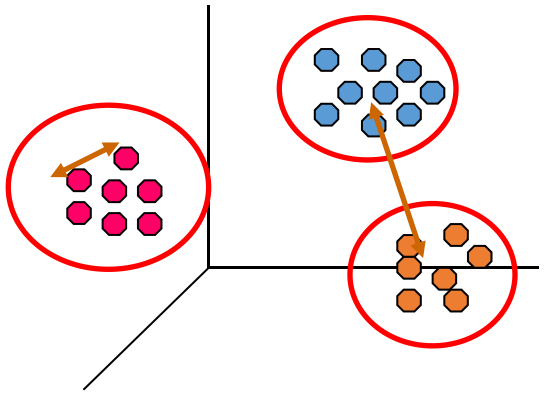


Intuitively, clustering is the task of grouping a set of objects such that ***similar objects end up in the same group*** and ***dissimilar objects are separated into different groups.***

——《understanding machine learning》 P_{307}

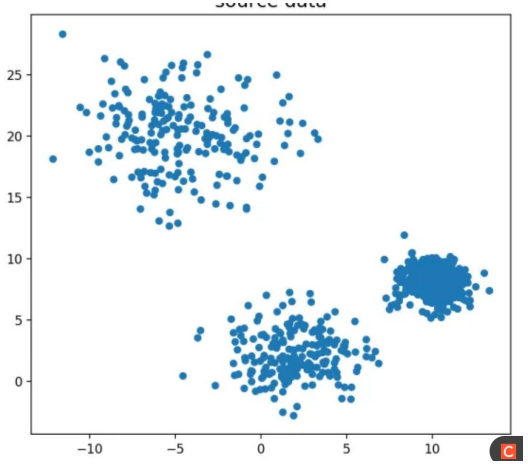
目的：将样本划分为若干个不相交的“簇”(cluster)

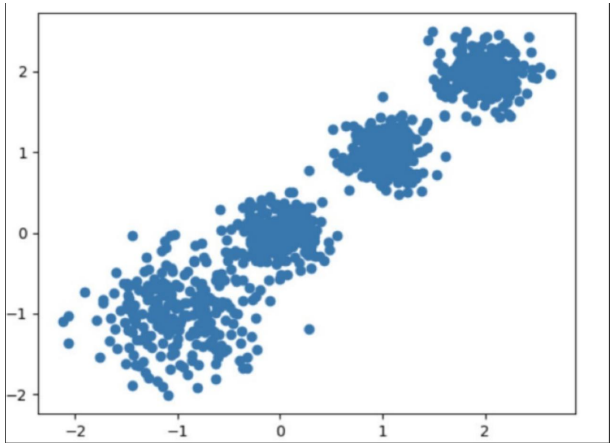
条件：簇内相似度高 且 簇间相似度低

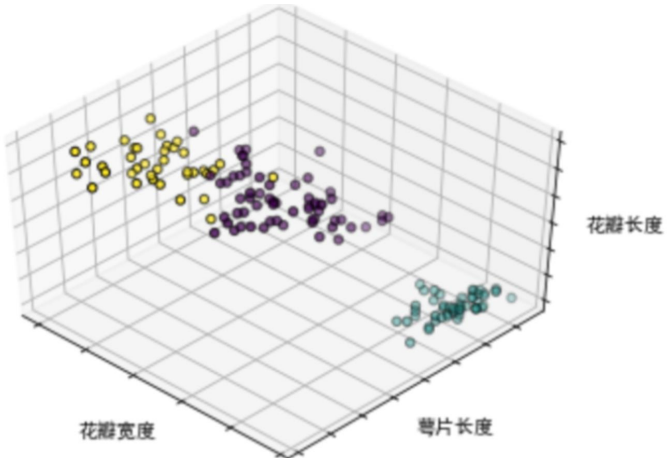


一. 聚类是什么

核心问题：什么样的数据算一组?







如果是高维情况呢?

一. 聚类是什么

首都师范大学 CAPITAL NORMAL UNIVERSITY

核心问题：什么样的数据算一组?

用户编号	日均观看时长(min)	日均滑动次数	完播率	点赞数/天	评论数/天	分享数/天	收藏数/天	关注作者数/周	夜间活跃占比	偏好内容类别数	广告点击率
用户01	128	342	0.71	18	3	2	4	6	0.62	5	0.08
用户02	46	185	0.38	4	0	0	1	1	0.21	2	0.03
用户03	173	401	0.79	25	5	4	6	8	0.74	6	0.11
用户04	92	267	0.55	9	1	1	2	3	0.48	4	0.05
用户05	214	463	0.83	31	6	5	8	10	0.81	7	0.14
用户06	38	142	0.29	2	0	0	0	0	0.16	2	0.02
用户07	156	376	0.76	22	4	3	5	7	0.69	6	0.10
用户08	64	223	0.47	6	1	0	1	2	0.33	3	0.04
用户09	189	428	0.81	28	5	4	7	9	0.77	7	0.12
用户10	57	204	0.41	5	0	1	1	1	0.27	3	0.03

大纲

首都师范大学 CAPITAL NORMAL UNIVERSITY

01 聚类是什么

02 聚类的应用场景

03 聚类方法的发展图谱

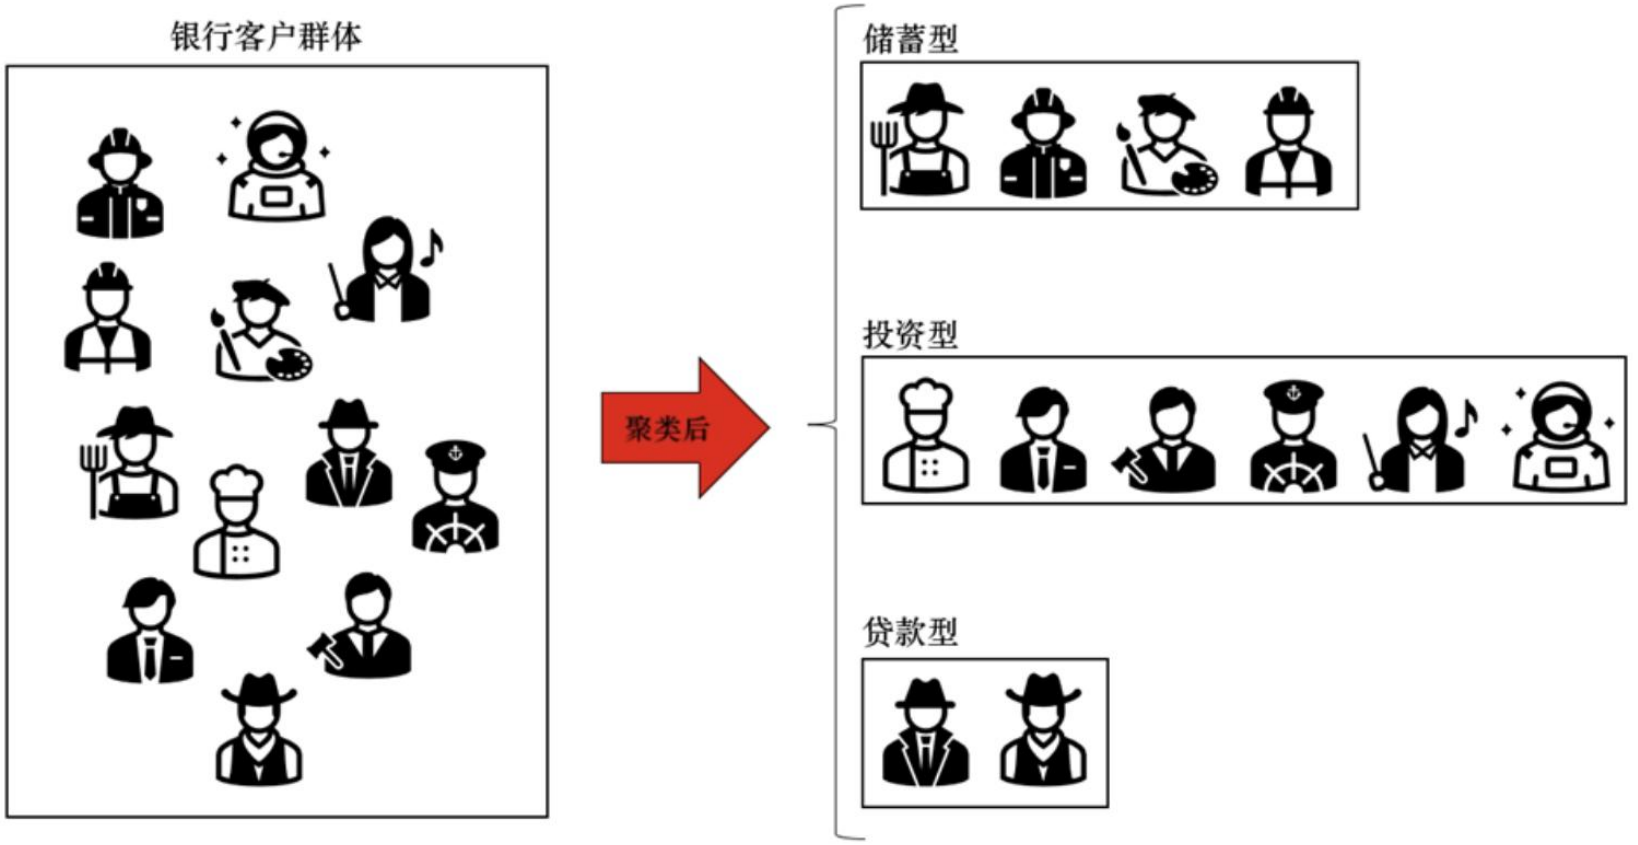
04 经典聚类方法与案例实践

05 从经典方法到前沿方法

06 聚类结果的评价

二. 聚类的应用场景

精准营销

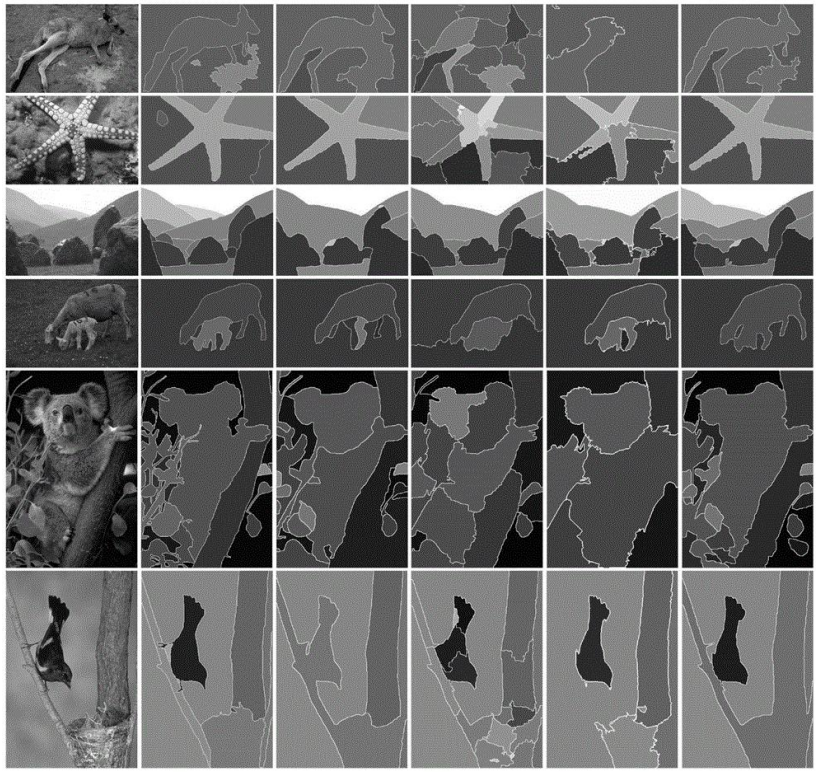


二. 聚类的应用场景

图像处理



图像压缩

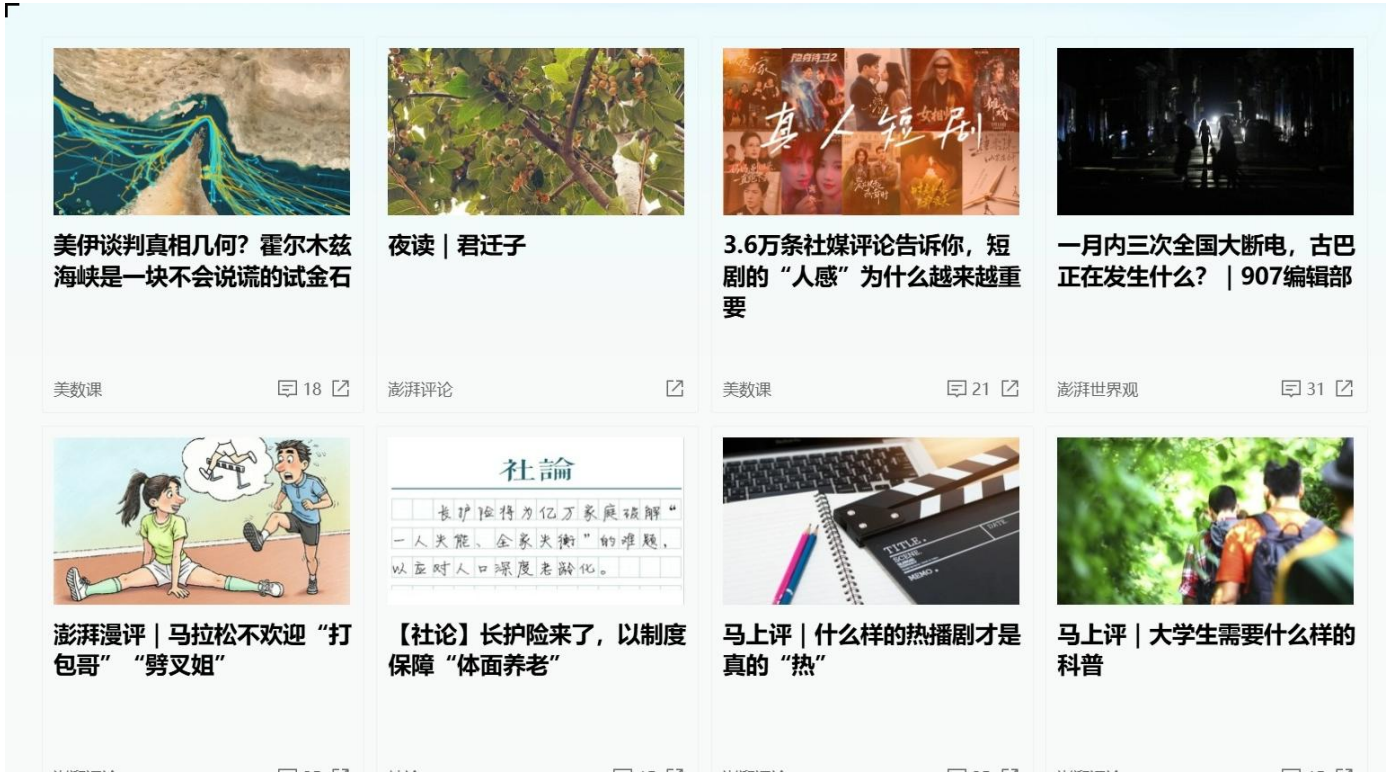


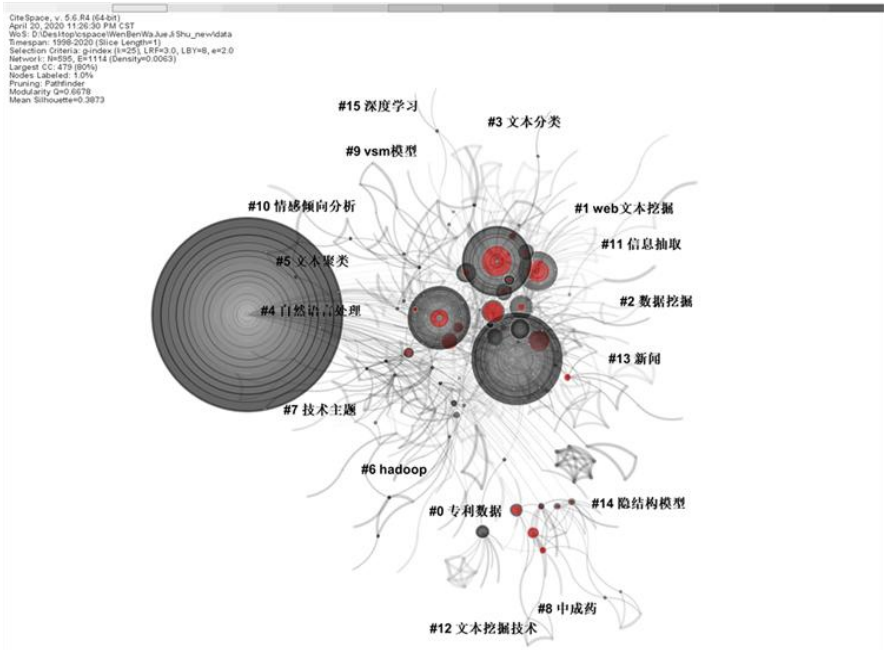
图像分割

二. 聚类的应用场景

首都师范大学 CAPITAL NORMAL UNIVERSITY

文本主题挖掘





CiteSpace Home

大纲

首都师范大学 CAPITAL NORMAL UNIVERSITY

01 聚类是什么

02 聚类的应用场景

03 聚类方法的发展图谱

04 经典聚类方法与案例实践

05 从经典方法到前沿方法

06 聚类结果的评价

三. 聚类方法的发展图谱

给定数据后，聚类的关键：如何定义“一组样本”？

基于中心
代表：K-means
核心：离同一个中心近

基于分布
代表：GMM
核心：来自同一概率分布

基于密度
代表：DBSCAN / MeanShift
核心：位于同一高密度区域

基于图结构
代表：谱聚类
核心：图上连接更紧密

现代发展方向

- 相似性：从手工定义走向可学习
- 数据空间：从欧式空间扩展到图空间、流形空间
- 数据表示：从原始特征走向表示学习与深度聚类
- 应用场景：从小规模静态数据走向高维、大规模、多模态数据

大纲

首都师范大学 CAPITAL NORMAL UNIVERSITY

01 聚类是什么

02 聚类的应用场景

03 聚类方法的发展图谱

04 经典聚类方法与案例实践

05 从经典方法到前沿方法

06 聚类结果的评价

四.经典聚类方法与案例实践

基于中心

K-means

基于分布

GMM

基于密度

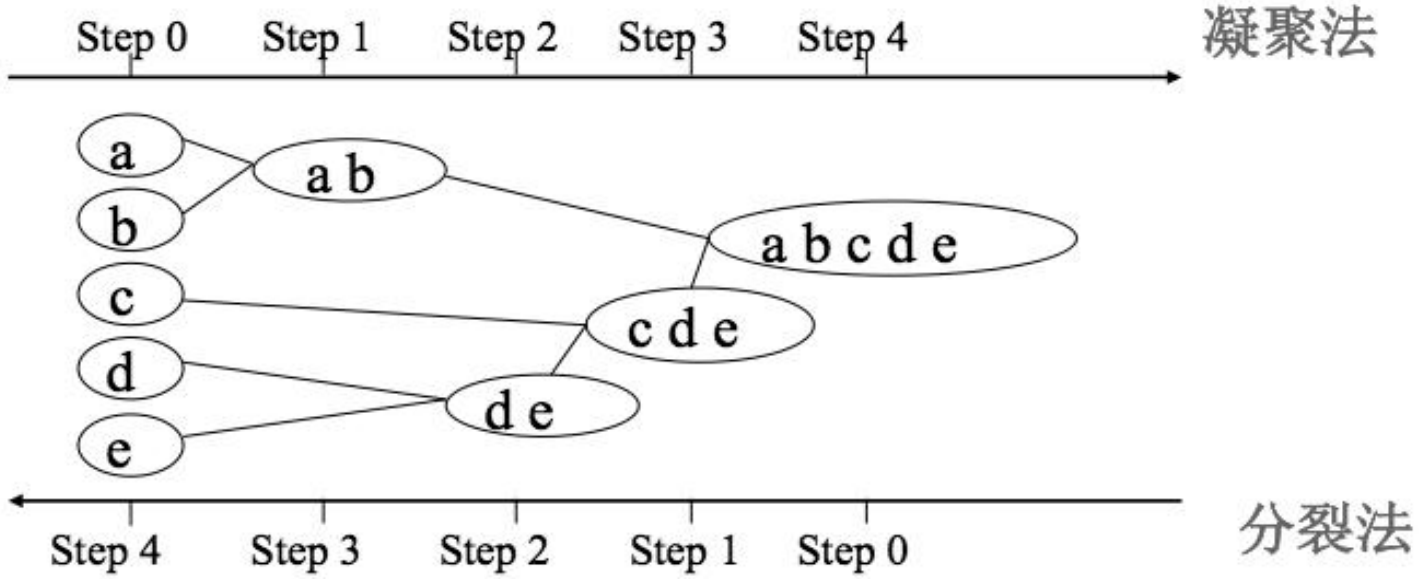
DBSCAN、Meanshift

基于图结构

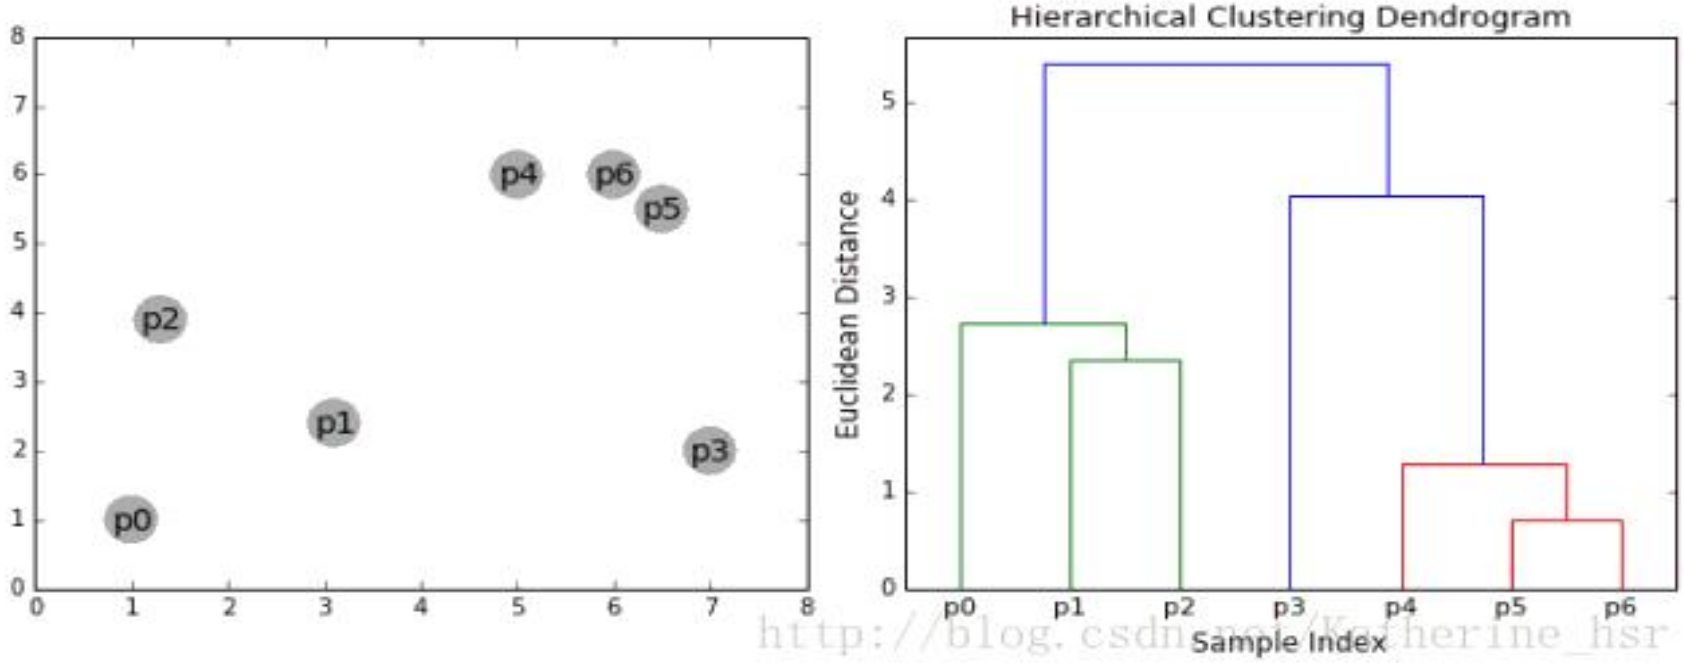
谱聚类

层次聚类

中心思想：不断按某种簇间相似性规则去合并，最后形成一棵树



层次聚类



聚类树

重点：如何度量距离(相似度)?

层次聚类

- **点与点间的距离：**

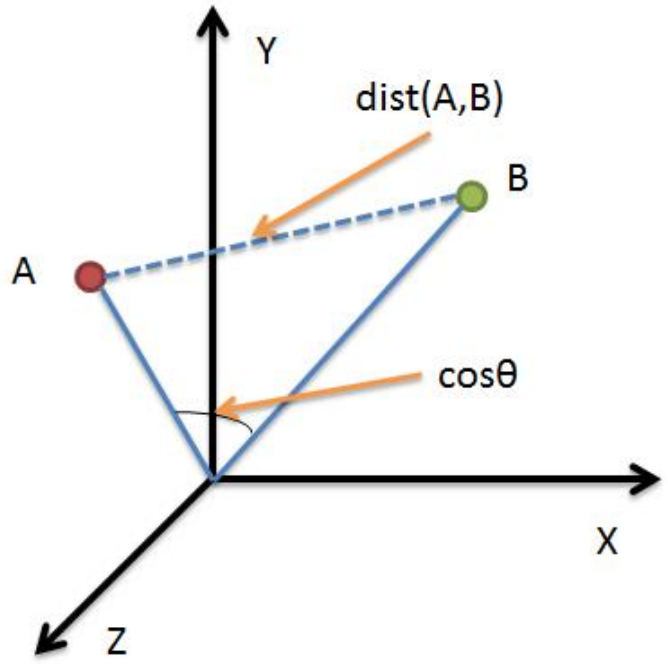
e.g. **闵可夫斯基距离(Minkowski distance)：**

$$d(x_i, x_j) = (||x_i - x_j||^p)^{\frac{1}{p}}$$

$p = 1$: 曼哈顿距离

$p = 2$: 欧氏距离 (注意数量级)

余弦距离：方向上的相似性



四.经典聚类方法与案例实践

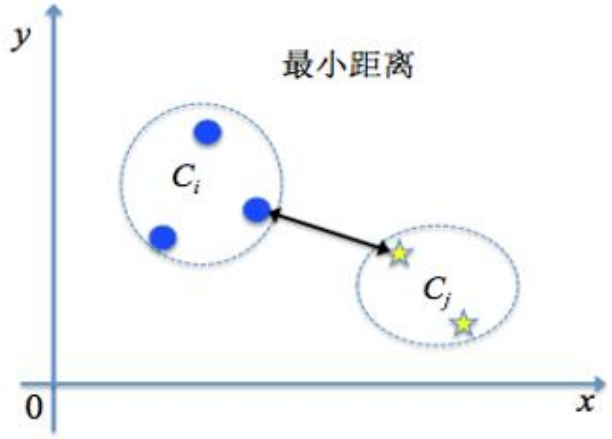
举例：用户画像

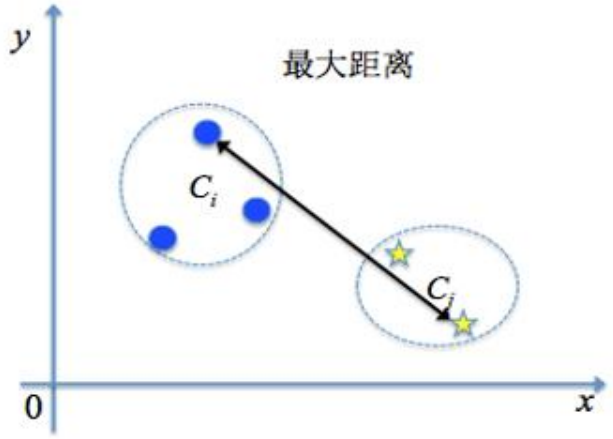
用户	短视频娱乐	音乐	游戏直播	体育资讯	美食内容
用户A	40	30	20	5	5
用户B	8	6	4	1	1
用户C	5	5	10	35	25
用户D	4	3	2	1	0
用户E	2	25	30	3	5

层次聚类

- **簇与簇间的距离:**

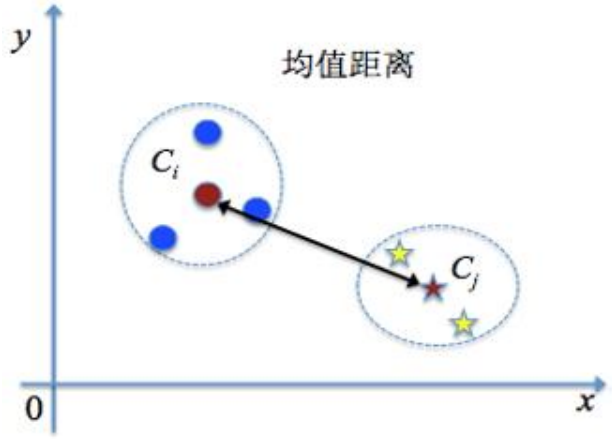
$$d_{min}(C_i, C_j) = \min_{p \in C_i, q \in C_j} d(p, q)$$

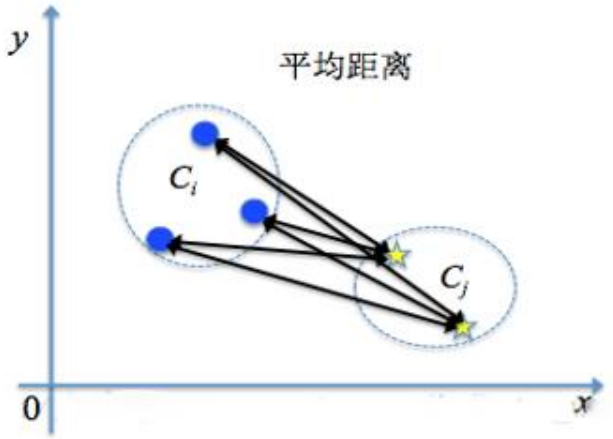




$$d_{max}(C_i, C_j) = \max_{p \in C_i, q \in C_j} d(p, q)$$

$$d_{mean}(C_i, C_j) = d(u_i, u_j)$$



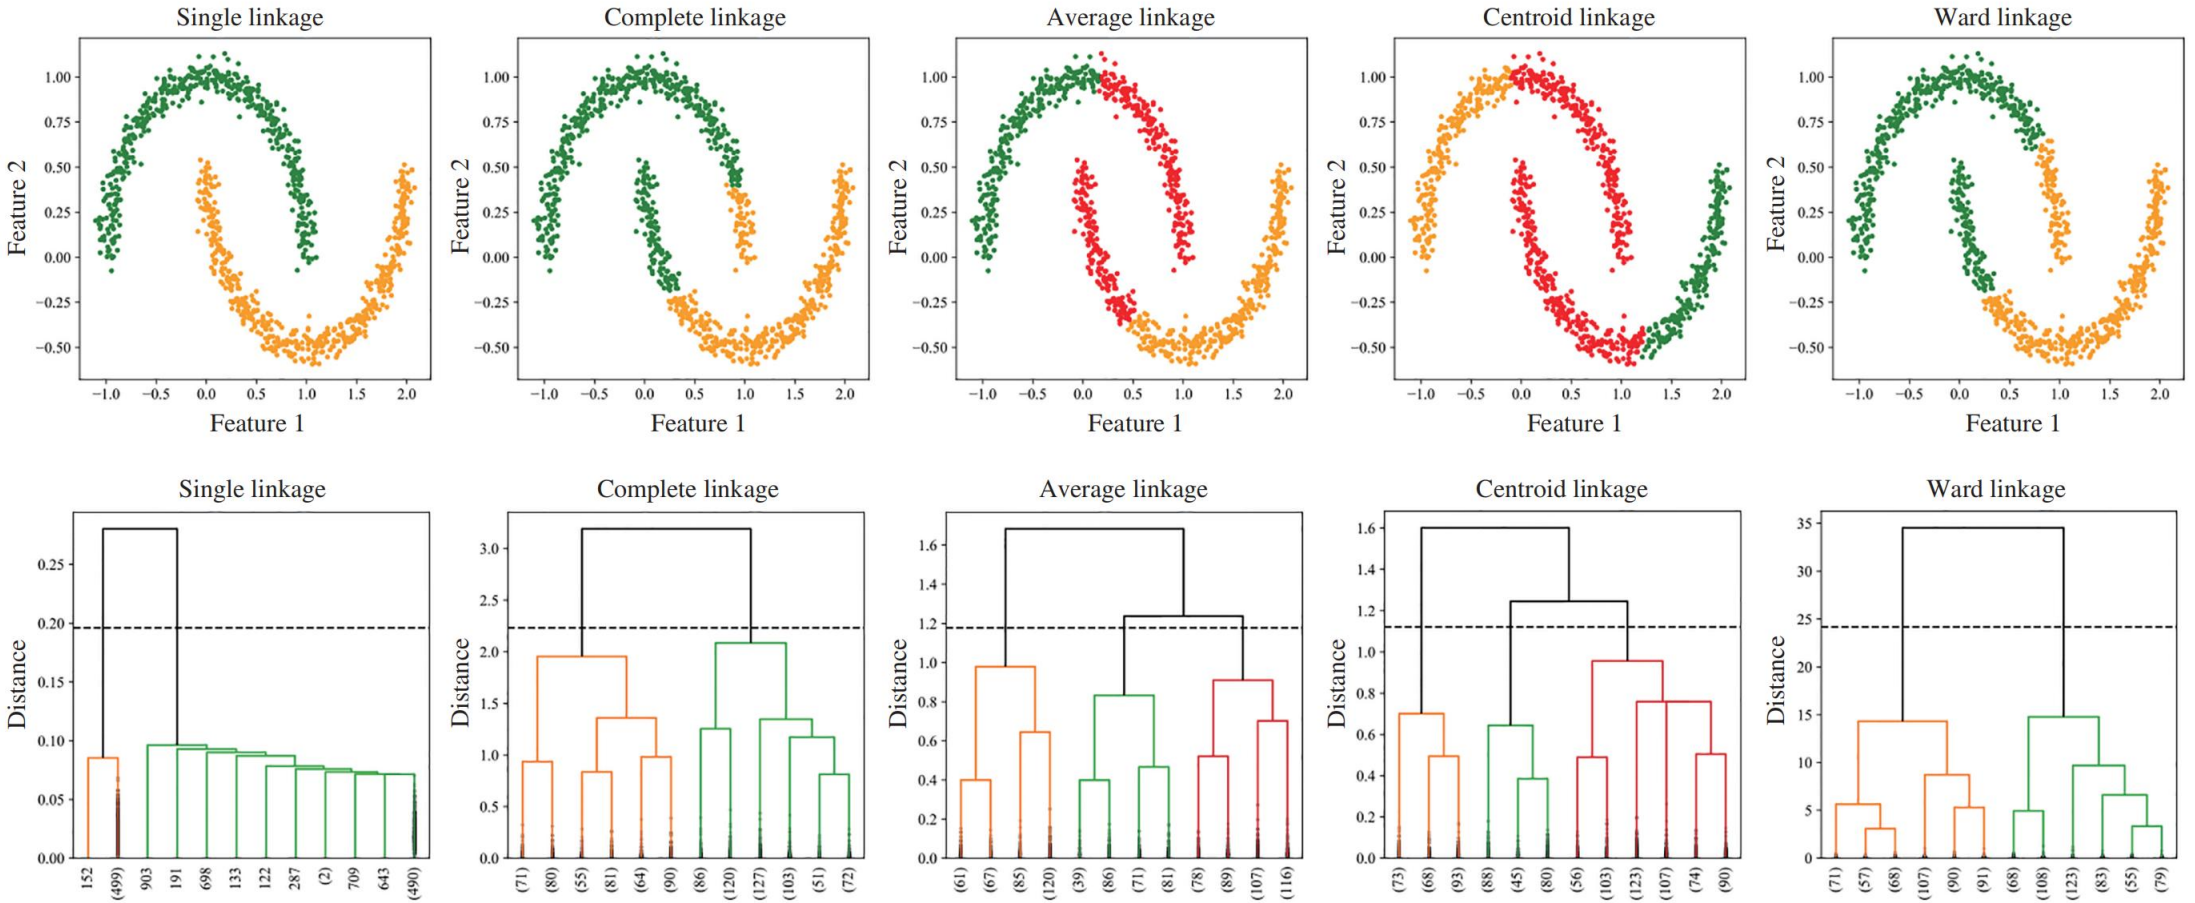


$$d_{avg}(C_i, C_j) = \frac{1}{|C_i||C_j|} \sum_{p \in C_i, q \in C_j} d(p, q)$$

四.经典聚类方法与案例实践

层次聚类

最小　最大　平均　均值　方差



四.经典聚类方法与案例实践

基于中心

K-means

基于分布

GMM

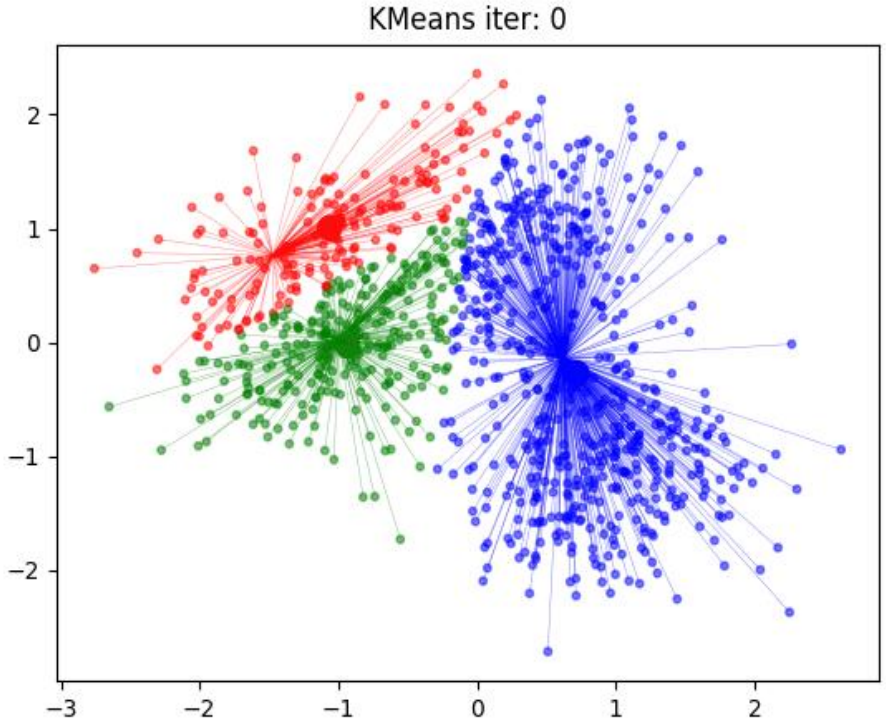
基于密度

DBSCAN、Meanshift

基于图结构

谱聚类

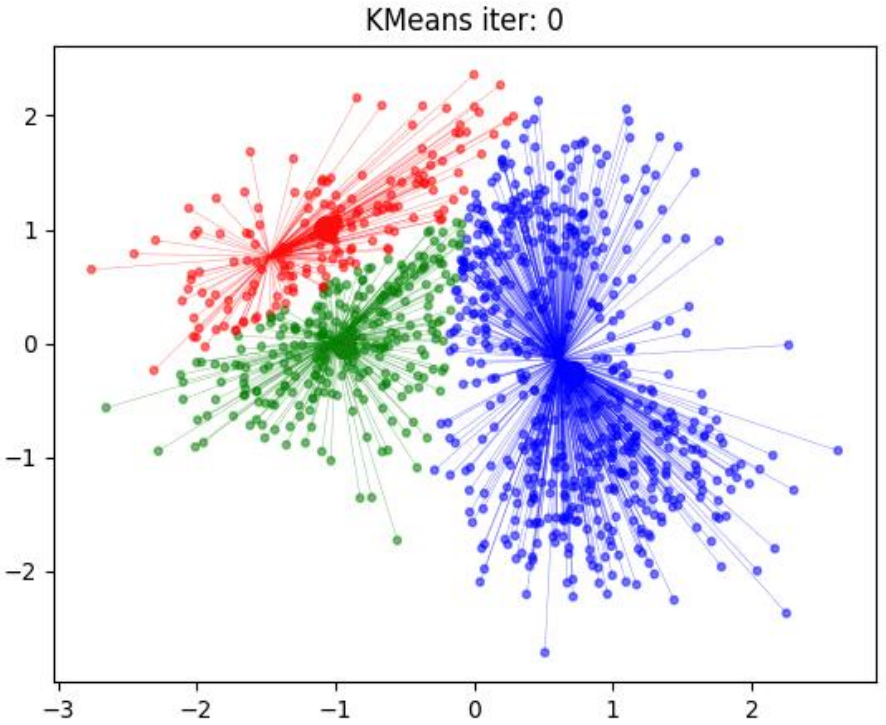
K-means



中心思想：每个簇都有个中心点（质心）

选取k个初始质心（人为设定）
repeat：
　　将每个样本点归类为距其最近的质心所在簇
　　重新计算k个簇对应的质心
until 质心不再发生变化

K-means



问题1：迭代会不会无限进行下去？

问题2：不同初始点是否会对结果产生影响？

K-means

K-means的目标：找到K个质心，形成K个对应的簇，使每个样本到自己簇所在质心的距离比到别的质心的距离小：

$$\min\ G(u,C)=\sum_{i=1}^{k}\sum_{x\in C_i} d(x,u_i)^2$$

质心：$u=\{u_1,u_2,\ldots\ldots,u_k\}$

簇: $C=\{C_1,C_2,\ldots\ldots,C_k\}$

交替迭代求解：

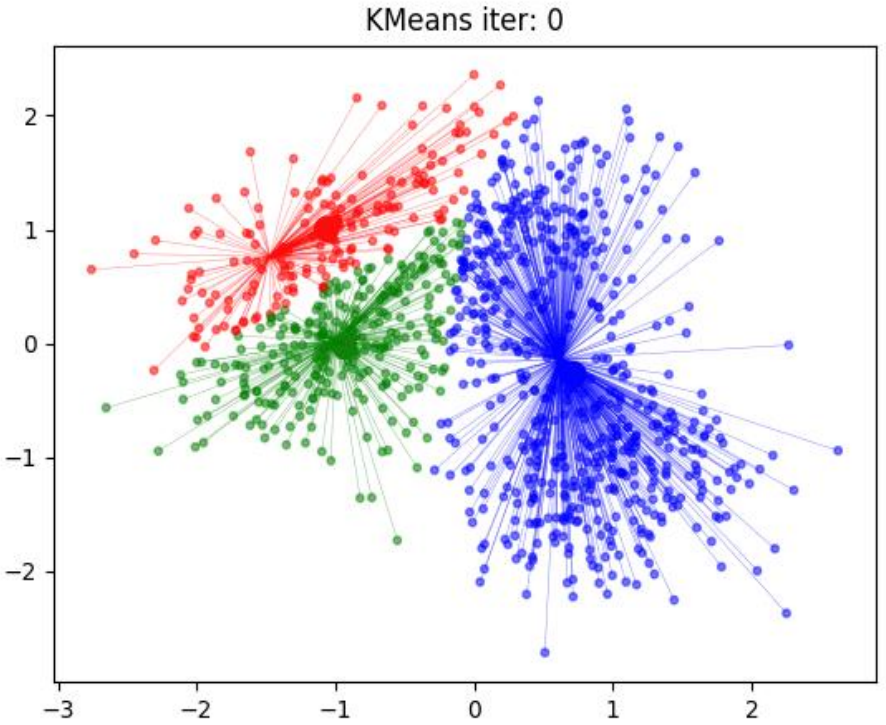
初始化u

已知u，求使$G(u,C)$最小的C

已知C，求使$G(u,C)$最小的u

选取k个初始质心；
repeat：
　将每个样本点归类为距其最近的质心所在簇
　重新计算k个簇对应的质心
until 质心不再发生变化

K-means



问题1：迭代会不会无限进行下去？

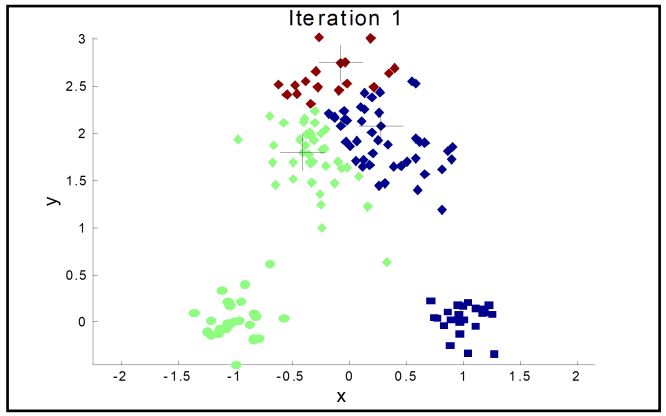
不会，目标函数值在不断下降

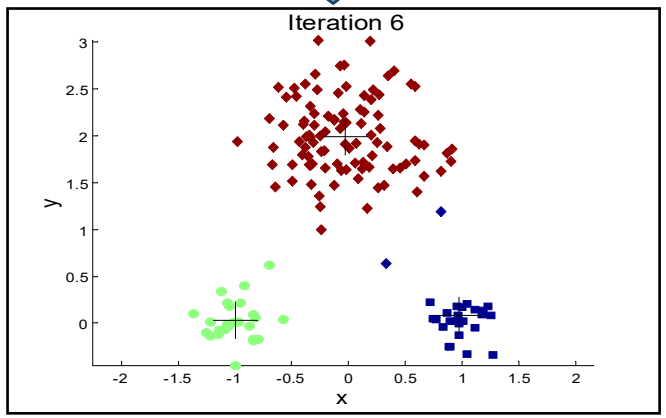
$$G\left(u^{(t)},\ C^{(t)}\right) \le G\left(u^{(t-1)},\ C^{(t-1)}\right)$$

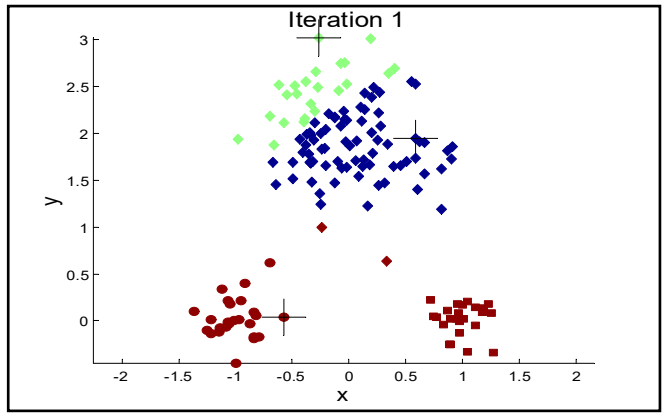
问题2：不同初始点是否会对结果产生影响？

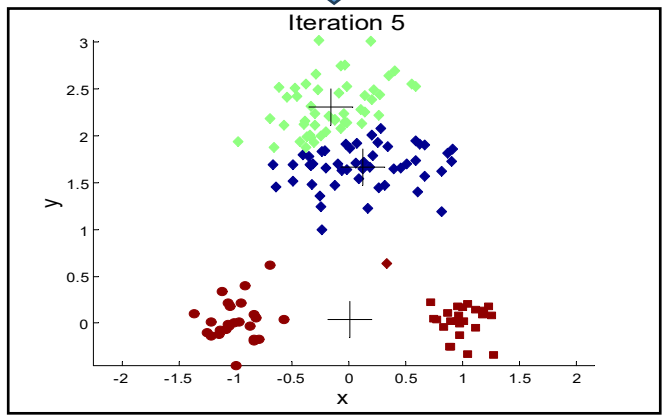
会，优化目标非凸，收敛到局部最优

K-means





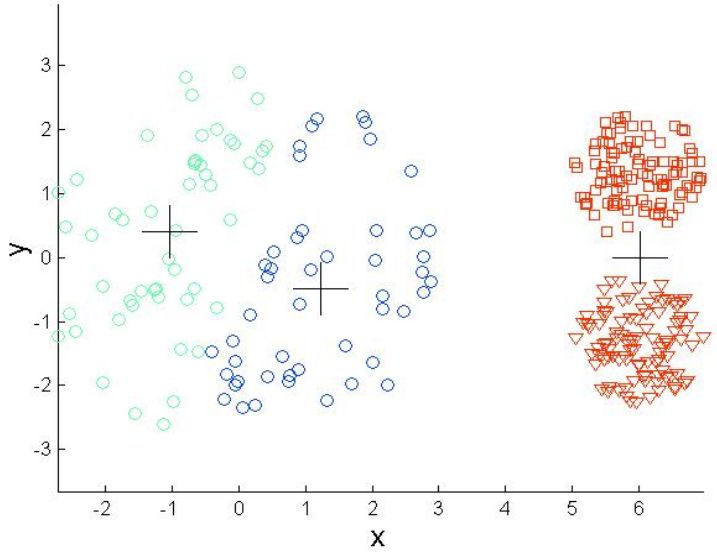




K-means

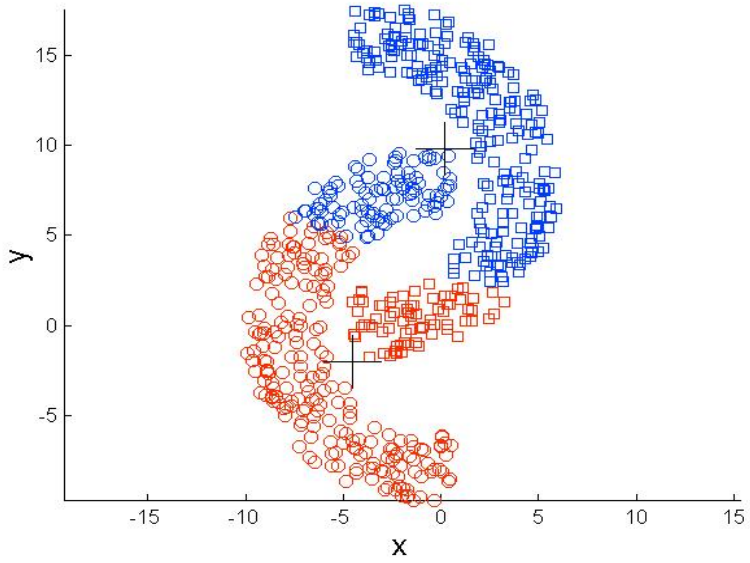
缺点：并非适用于所有数据情况

- 不同密度



K-means (3 Clusters)

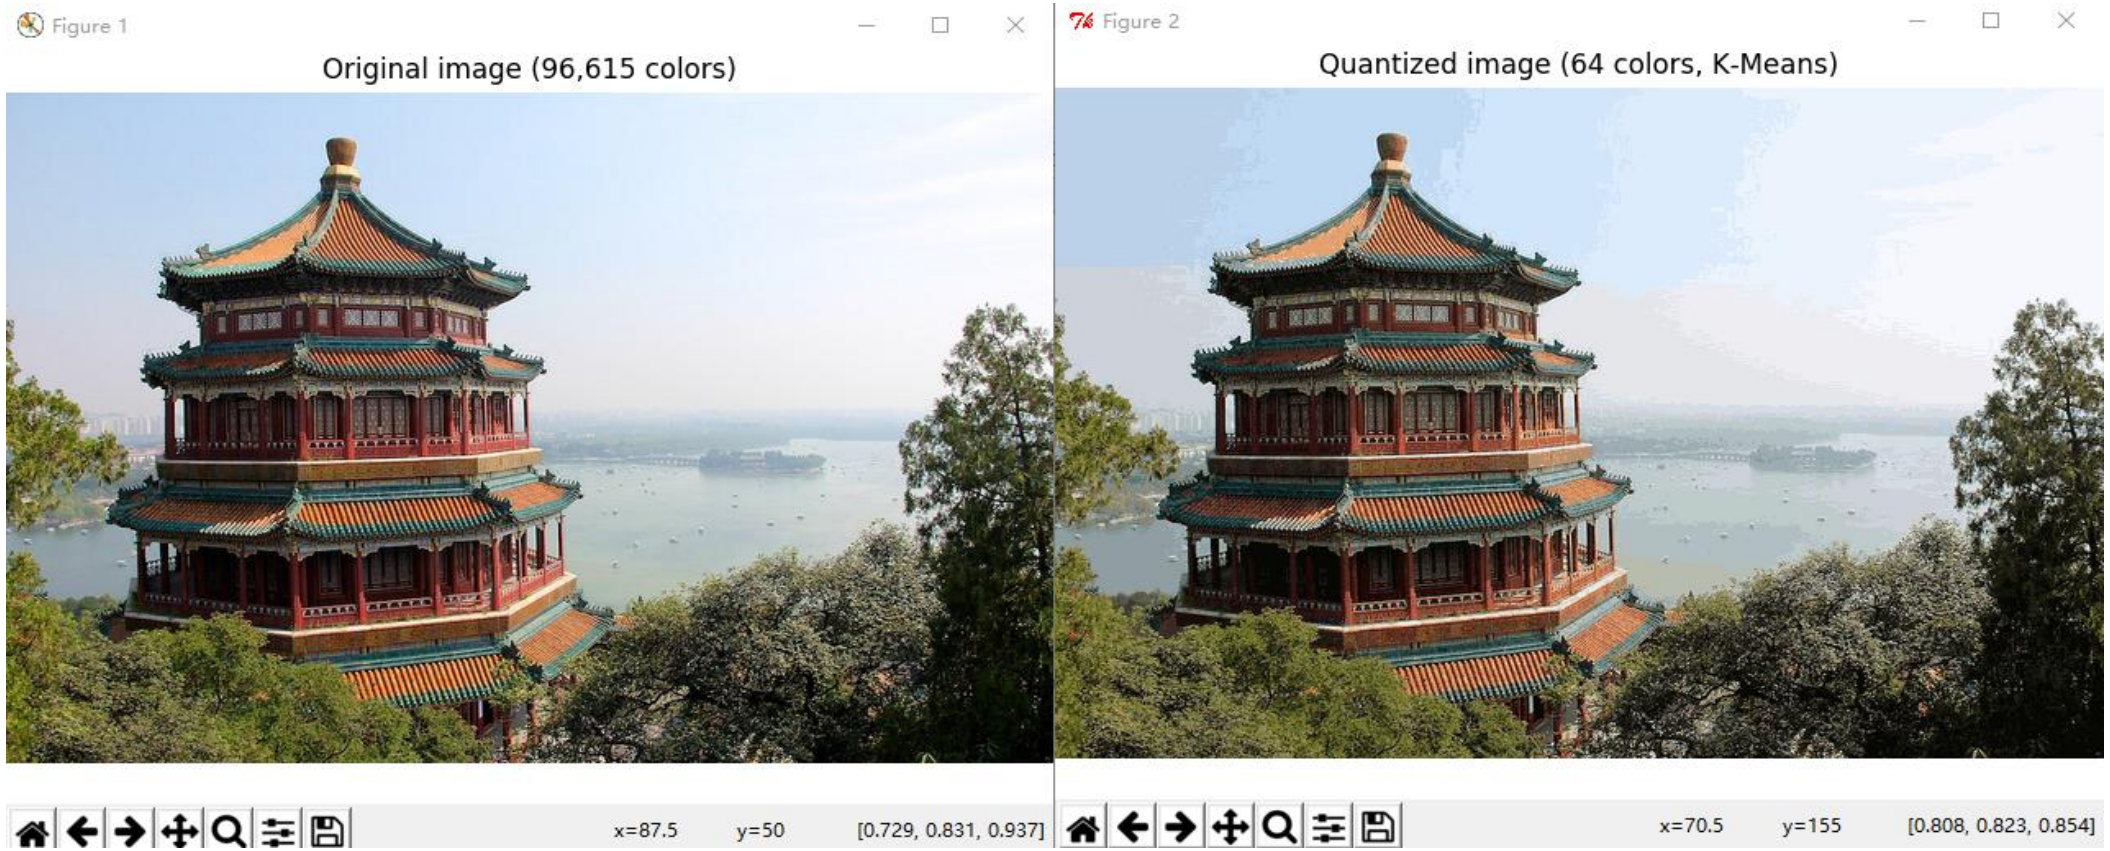
- 非球状



K-means (2 Clusters)

K-means

应用举例：对一副高维度像素的图像进行相似像素色聚类



四.经典聚类方法与案例实践

基于中心

K-means

基于分布

GMM

基于密度

DBSCAN、Meanshift

基于图结构

谱聚类

高斯混合模型（GMM）

背景基础：统计上一般假设总体服从某分布D,样本点从该分布采样得到

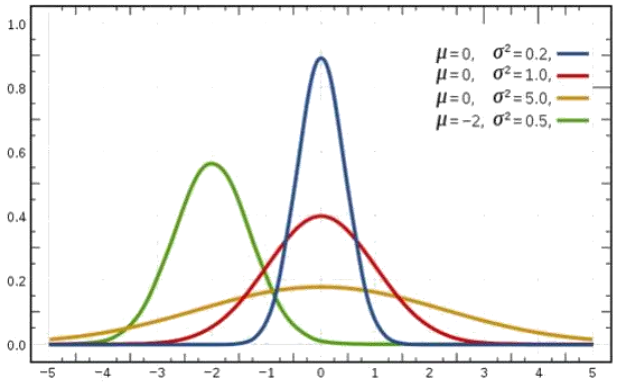


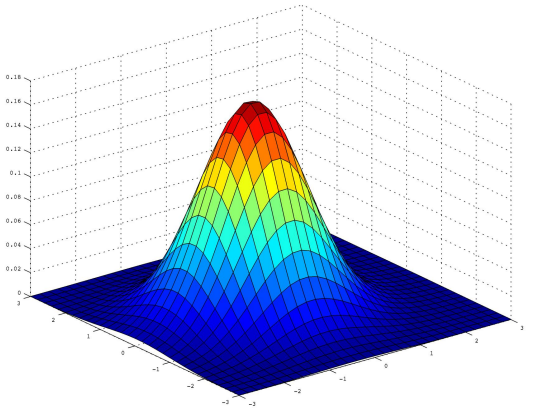
Carl F. Gauss (1777 – 1855)

高斯分布（概率密度函数）：

$$P(x) = \frac{1}{(2\pi)^{\frac{n}{2}}|\Sigma|^{\frac{1}{2}}} e^{-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)}$$

- 均值 u
- 协方差矩阵Σ



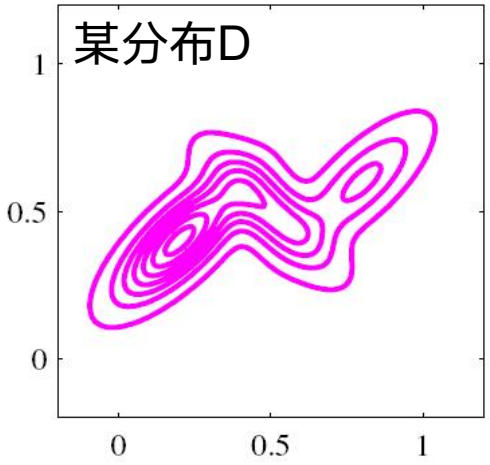


高斯混合模型（GMM）

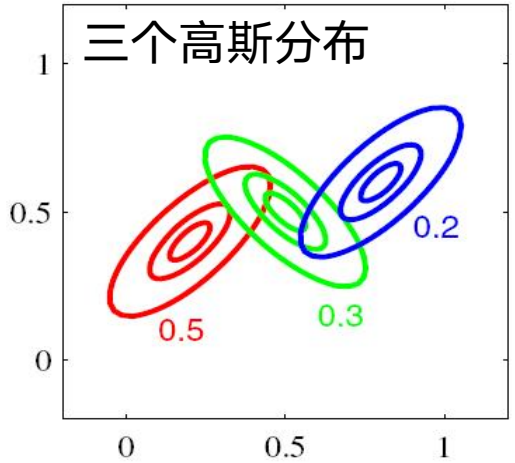
原理：

任意连续的概率分布≈

多个高斯分布加权组合



近似



混合系数

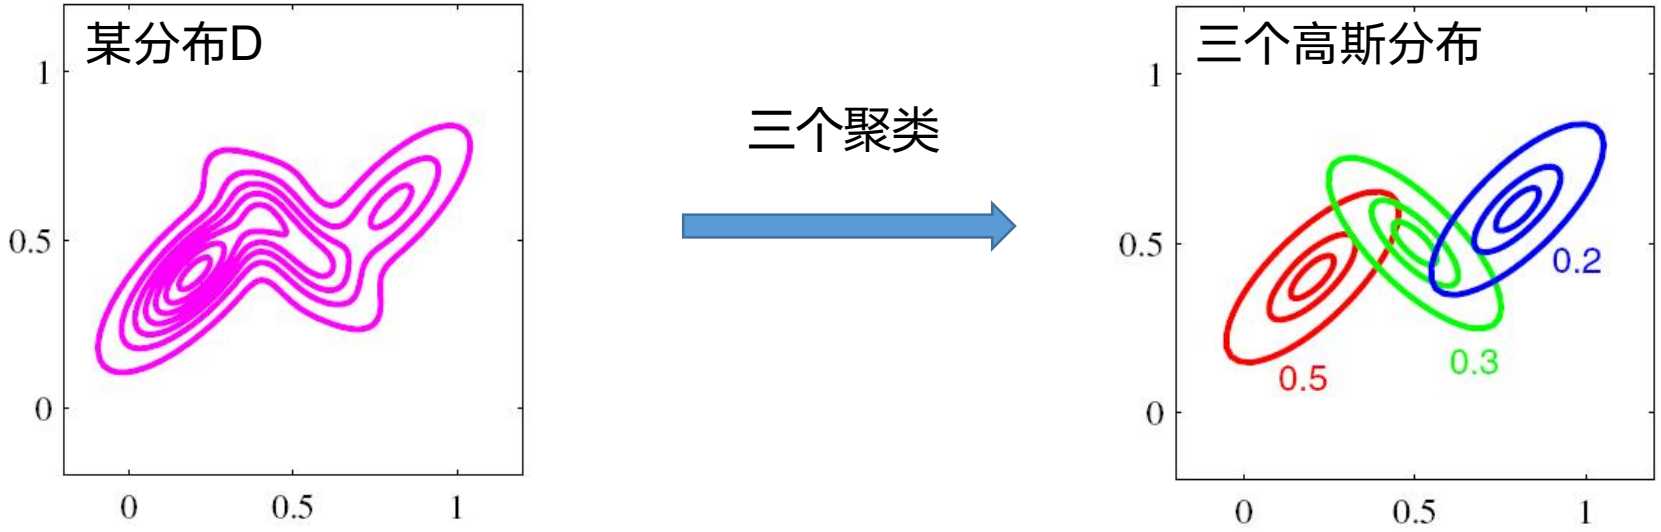
高斯混合分布： $P_M(x) = \sum_{i=1}^{k} \alpha_i \cdot p(x|\mu_i, \Sigma_i)$

第i个高斯分布的概率密度函数

混合系数满足： $\alpha_i \geq 0, \sum_{i=1}^{k} \alpha_i = 1$

高斯混合模型（GMM）

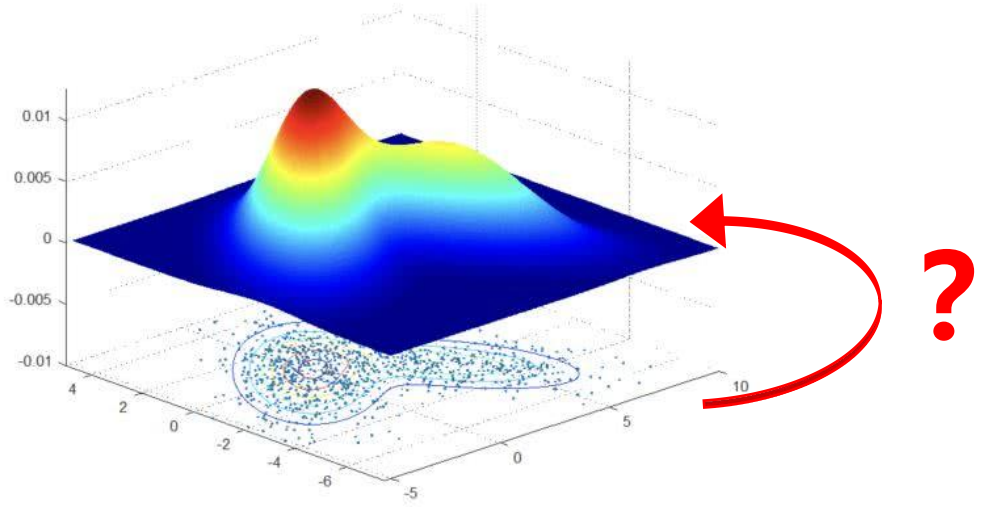
高斯混合聚类模型：任意一个簇由一个高斯分布函数**（原型）**刻画



高斯混合模型（GMM）

高斯混合分布的概率密度函数： $P_M(x) = \sum_{i=1}^{k} \alpha_i \cdot p(x|\mu_i, \Sigma_i)$

混合系数满足： $\alpha_i \geq 0, \sum_{i=1}^{k} \alpha_i = 1$



?

参数：

k：人为设定

$\alpha_i, \mu_i, \Sigma_i$：根据数据求解

任务：根据数据，估计高斯混合分布函数的参数

高斯混合模型（GMM）

问题：已知样本集 D，如何估计参数 $\{(\alpha_i, u_i, \Sigma_i)|1 \le i \le k\}$?

$$P_M(x) = \sum_{i=1}^{k} \alpha_i \cdot p(x|\mu_i,\Sigma_i)$$

方法：极大似然估计

$$LL(D) = \ln\left(\prod_{j=1}^{m} P_M(x_j)\right)$$
$$= \sum_{j=1}^{m} \ln\left(\sum_{i=1}^{k} \alpha_i \cdot p(x_j|\mu_i,\Sigma_i)\right)$$

补充材料：统计中有一类问题，叫参数估计问题。说的是已知某个随机样本满足某种概率分布，但是其中具体的参数不清楚，我们需要估计它的值。**极大似然估计**是其中一种经典的方法。它的思想是：已知某个参数能使这个样本出现的概率最大，那我们就把这个参数作为估计的真实值。

高斯混合模型（GMM）

$$\max \quad LL(D)=\sum_{j=1}^{m}\ln\left(\sum_{i=1}^{k}\alpha_i\cdot p(x_j\,|\mu_i,\Sigma_i)\right)$$

$$\text{s.t.} \quad \alpha_i\geq 0,\ \sum_{i=1}^{k}\alpha_i=1$$

$$\rightarrow \begin{cases} \dfrac{\partial LL(D)}{\partial \mu_i}=0 \\ \dfrac{\partial LL(D)}{\partial \Sigma_i}=0 \\ LL(D)+\lambda\left(\sum_{i=1}^{k}\alpha_i-1\right) \end{cases}$$

对α_i的导数为 0

$$\mu_i=\frac{\sum_{j=1}^{m}\gamma_{ji}x_j}{\sum_{j=1}^{m}\gamma_{ji}}$$

$$\Sigma_i=\frac{\sum_{j=1}^{m}\gamma_{ji}(x_j-\mu_i)(x_j-\mu_i)^{\mathrm{T}}}{\sum_{j=1}^{m}\gamma_{ji}}$$

$$\alpha_i=\frac{1}{m}\sum_{j=1}^{m}\gamma_{ji}$$

高斯混合模型（GMM）

样本由k个高斯混合分布产生： $P_M(x) = \sum_{i=1}^{k} \alpha_i \cdot p(x|\mu_i, \Sigma_i)$

样本x_j由第i个高斯分布生成的后验概率（简记为γ_{ji}）：

$$\gamma_{ji} = P_M(z_j = i|x_j) = \frac{P(z_j = i) \cdot P_M(x_j \mid z_j = i)}{P_M(x_j)} = \frac{\alpha_i \cdot p(x_j|\mu_i, \Sigma_i)}{\sum_{l=1}^{k} \alpha_l \cdot p(x_j|\mu_l, \Sigma_l)}$$

z_j：生成样本x_j的高斯分布

高斯混合模型（GMM）

EM 算法：

- 选定k，并初始化$\{(\alpha_i, \mu_i, \Sigma_i) | \ 1 \le i \le k\}$
- **(E步)** 根据当前参数计算每个样本属于每个高斯成分的后验概率γ_{ji}

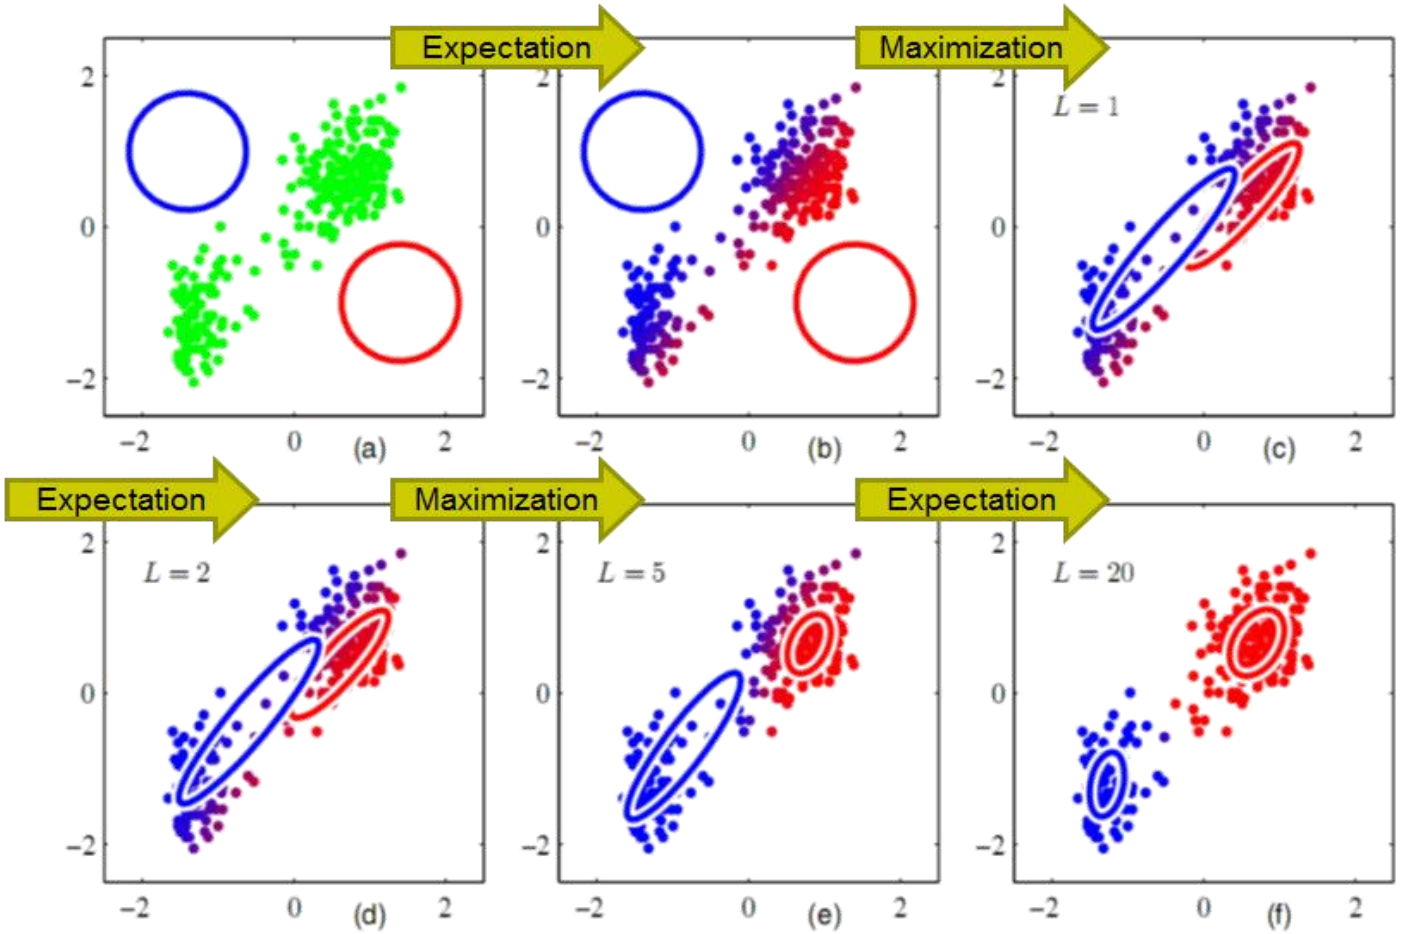
$$\gamma_{\mathrm{ji}} = P_M(z_j = i | x_j) \ (1 \le i \le k)$$

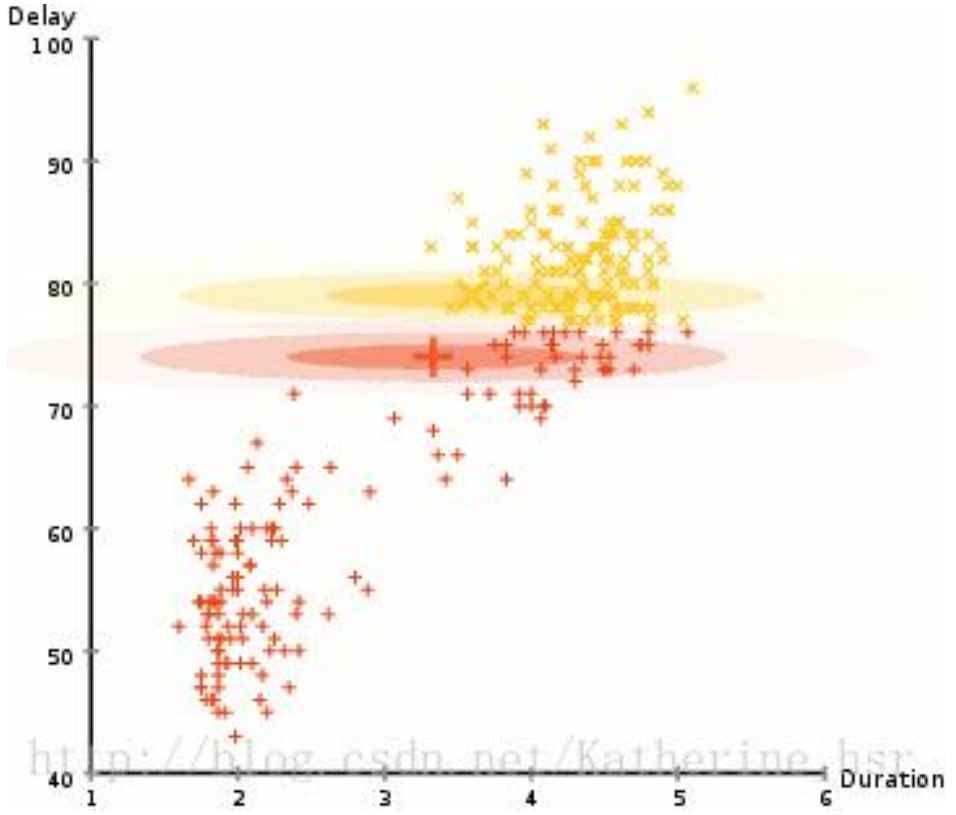
- **(M步)** 更新高斯分布参数$\{(\alpha_i, \mu_i, \Sigma_i) | \ 1 \le i \le k\}$使样本出现概率最大

$$\mu_i = \frac{\sum_{j=1}^{m} \gamma_{ji} x_j}{\sum_{j=1}^{m} \gamma_{ji}} \qquad \Sigma_i = \frac{\sum_{j=1}^{m} \gamma_{ji} (x_j - \mu_i)(x_j - \mu_i)^{\mathrm{T}}}{\sum_{j=1}^{m} \gamma_{ji}} \qquad \alpha_i = \frac{1}{m} \sum_{j=1}^{m} \gamma_{ji}$$

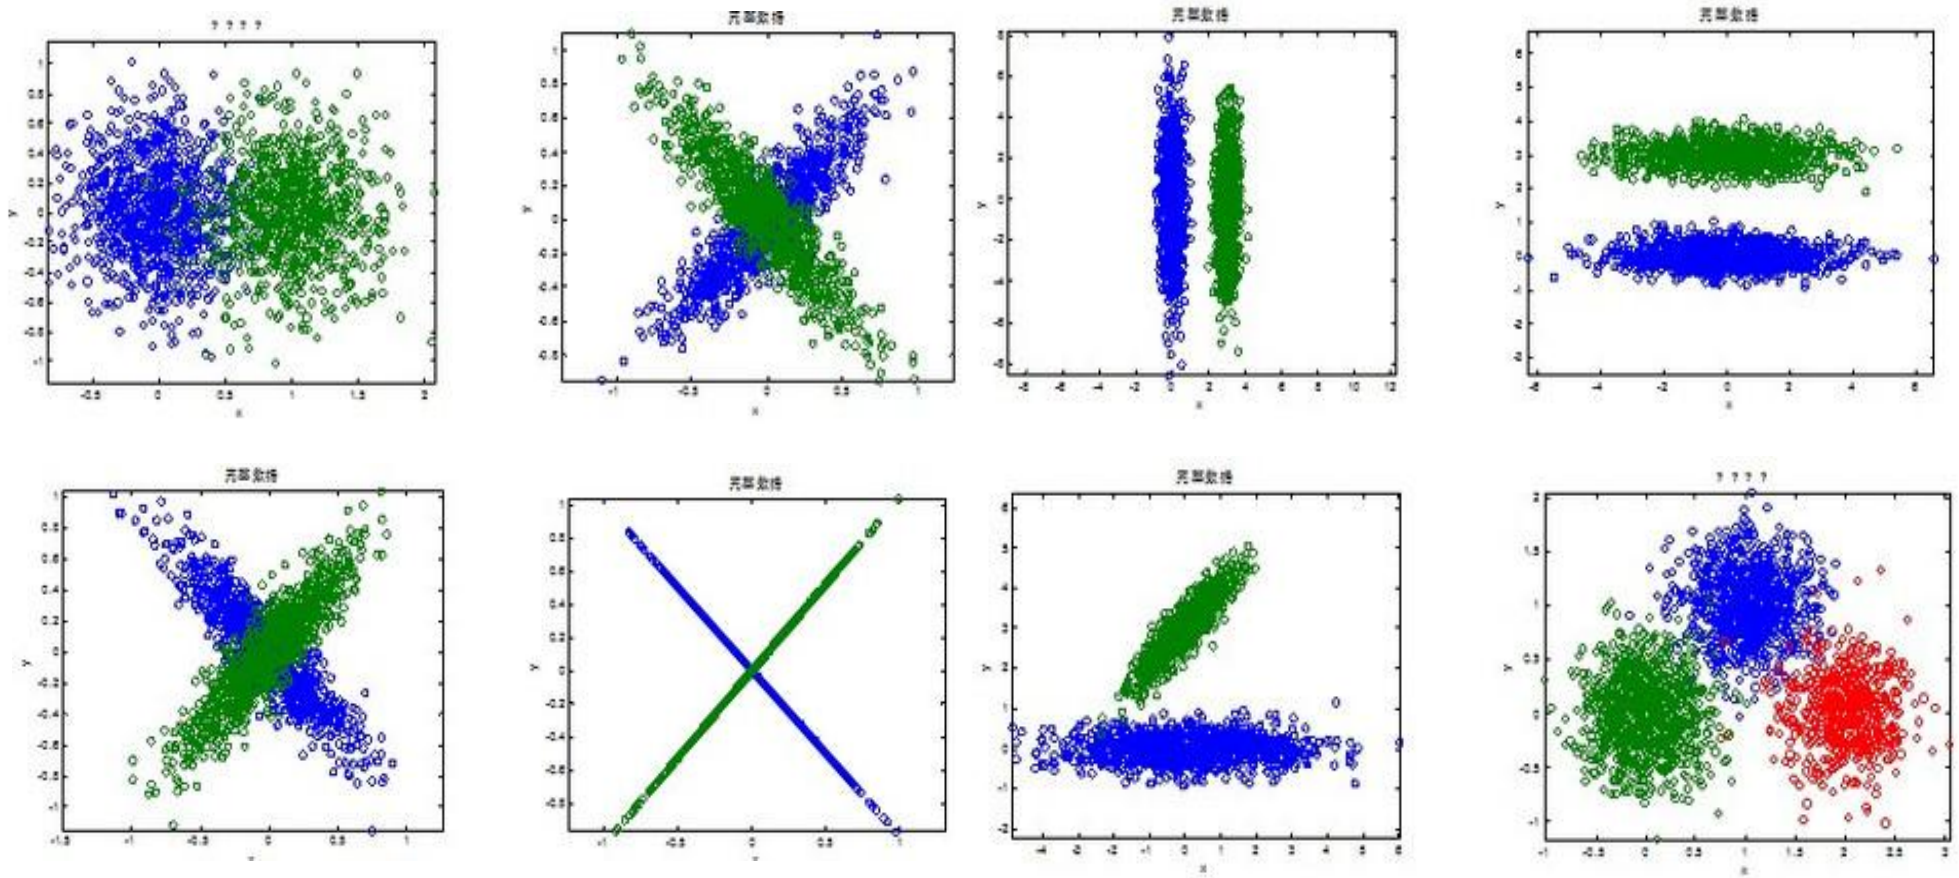
- 重复上述EM步骤直至收敛
- 根据每个数据点属于每个簇的**概率**确定簇划分

高斯混合模型（GMM）


Expectation
Maximization
Expectation
Maximization
Expectation
L = 1
L = 2
L = 5
L = 20
(a)
(b)
(c)
(d)
(e)
(f)


Delay
Duration
100
90
80
70
60
50
40
1
2
3
4
5
6

高斯混合模型（GMM）



四.经典聚类方法与案例实践

基于中心

K-means

基于分布

GMM

基于密度

DBSCAN、Meanshift

基于图结构

谱聚类

DBSCAN

全称： Density-Based Spatial Clustering of Applications with Noise

主要思想：

找出样本点中所有的密集区域，形成**聚类**

不在密集区域内的样本作为**噪音**

DBSCAN

给定数据集$D = \{x_1, x_2, \ldots\ldots x_m\}$和**邻域参数**$(\epsilon, MinPts)$

定义如下概念：

- **核心对象(core object):** 若x_i的ϵ-邻域至少包含$MinPts$个样本，即$|N_\epsilon(x_i)| \geq MinPts$, 则$x_i$是一个核心对象；

- **密度直达(directly density-reachable):** 若x_j位于x_i的ϵ-邻域中，且x_i是核心对象，则称x_j由 x_i密度直达；

- **密度可达(density-reachable):** 对x_j与x_i，若存在样本序列$p_1, p_2, \cdots, p_n$,其中$p_1 = x_i$, $p_n = x_j$且p_{i+1}由p_i密度直达，则称x_j由 x_i密度可达；

- **密度相连(density-connected):** 对 x_i与x_j，若存在x_k使得 x_i与x_j均由x_k密度可达，则称x_j与 x_i密度相连.

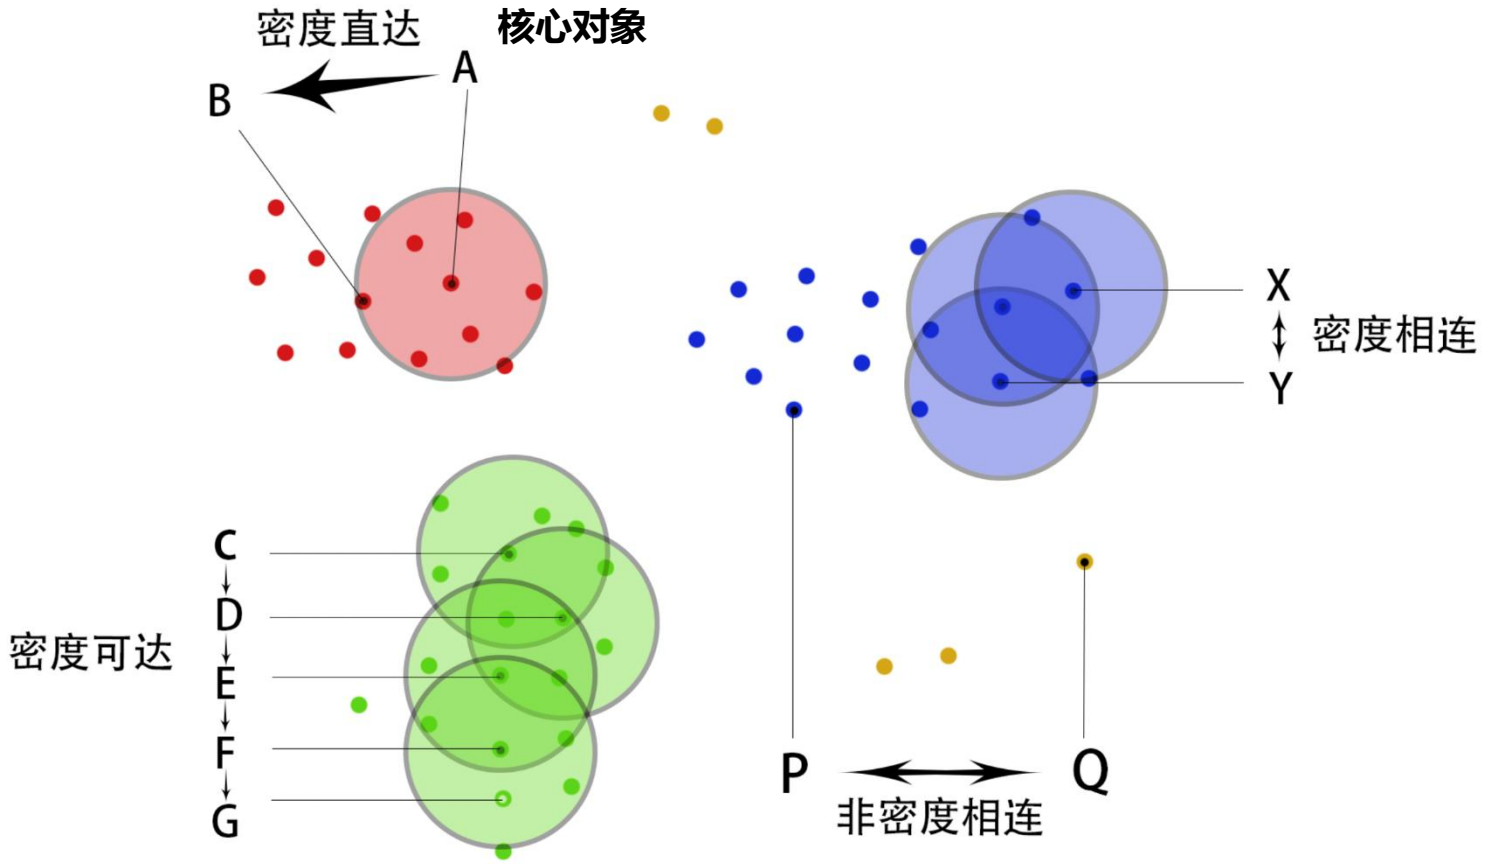
DBSCAN

给定数据集

$$D = \{x_1, x_2, \ldots\ldots x_m\}$$

邻域参数

$$(\epsilon, MinPts)$$



DBSCAN

设定： $MinPts = 5$，ϵ 如图

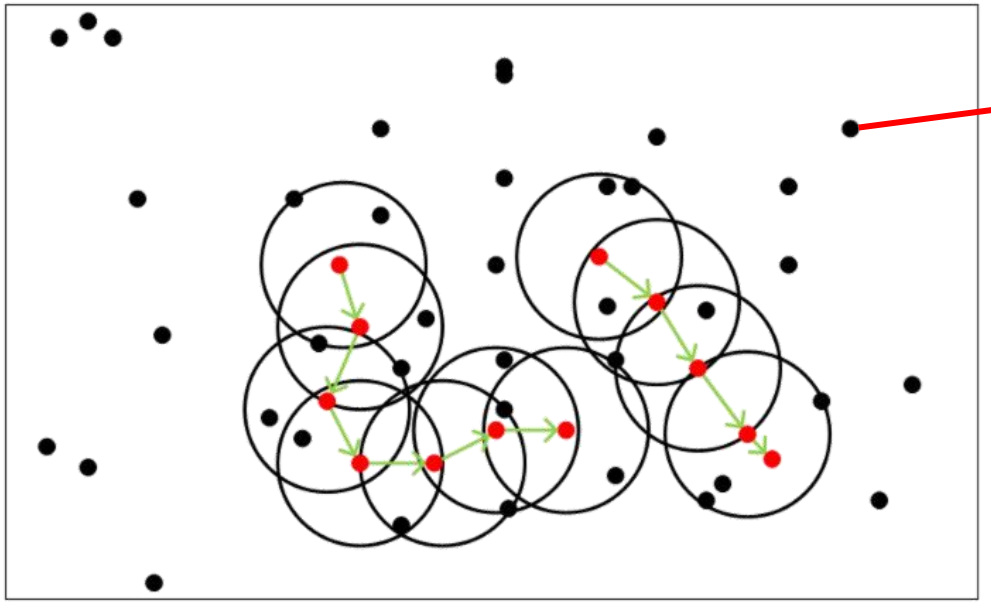
概念：

核心对象(红色点)

密度直达

密度可达(绿色箭头)

密度相连



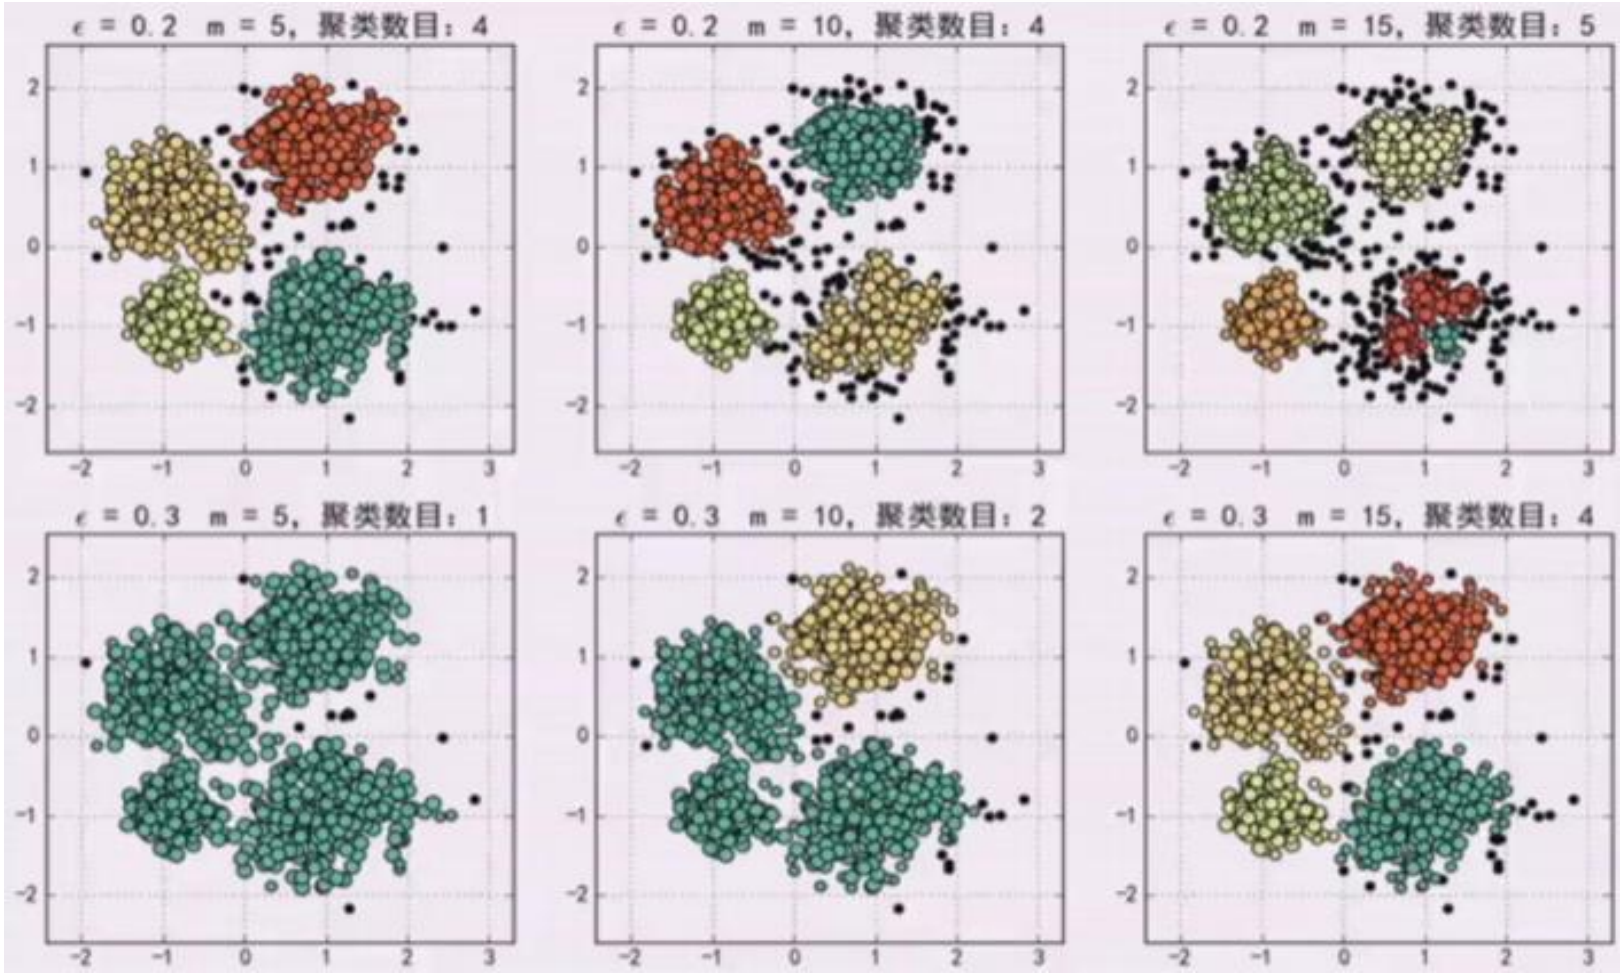
白话备注：把所有密度相连的样本聚在一起，生成簇

DBSCAN定义“簇”为：由密度可达关系导出的最大密度相连的样本集合

四.经典聚类方法与案例实践

首都师范大学 CAPITAL NORMAL UNIVERSITY

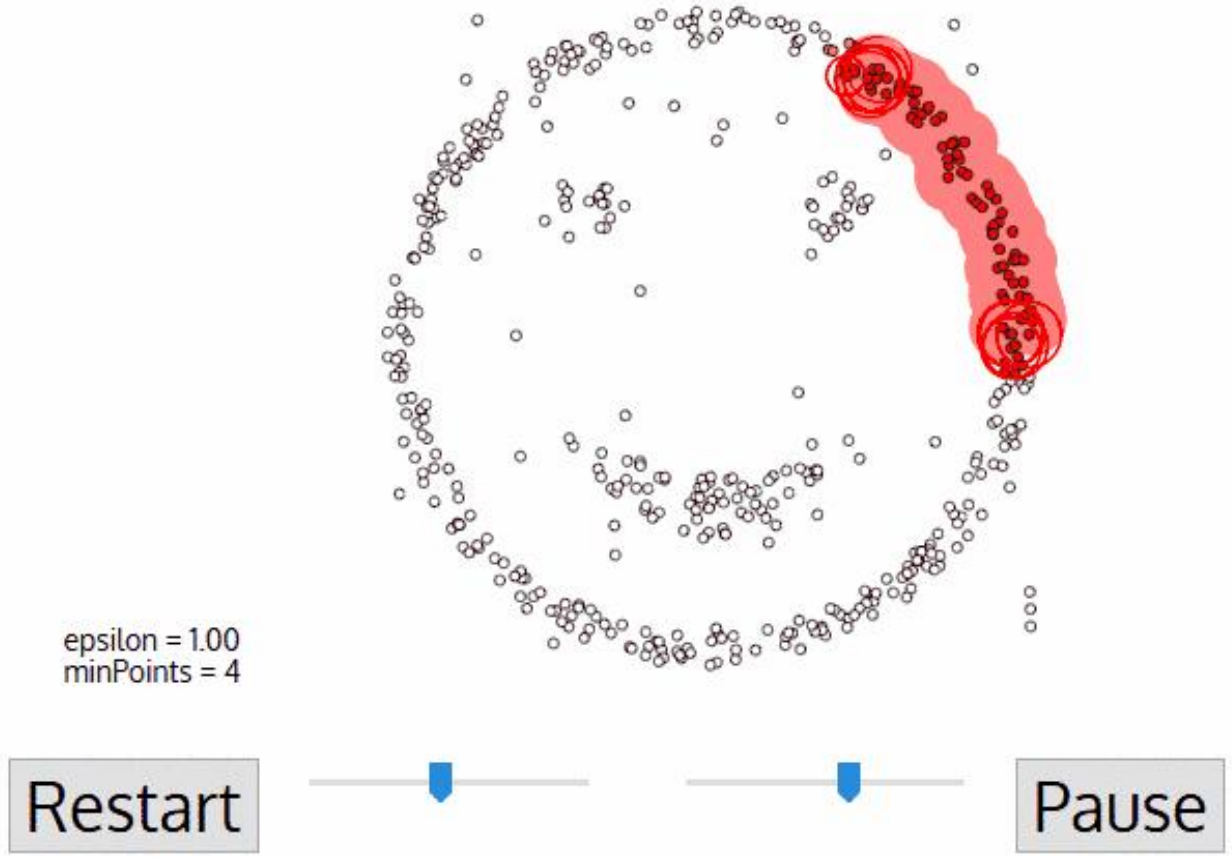
DBSCAN



DBSCAN

DBSCAN的优点：

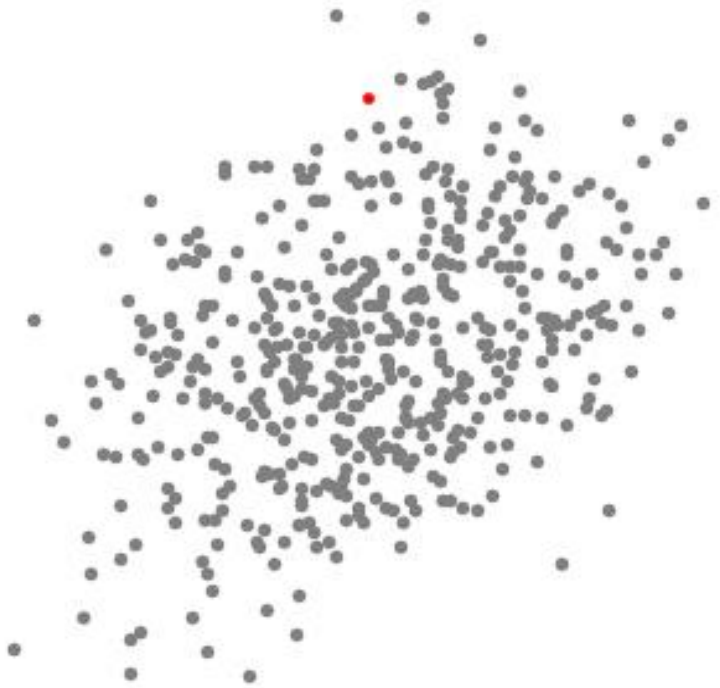
- 对数据集形状无要求
- 可做异常点检测
- 自动确定聚类数目



Meanshift

基本思想：沿着密度上升方向寻找同属一个簇的数据点

主要过程：



① 把每个样本点都当成一个初始 center

② 对每个 center 反复做**加权均值更新**

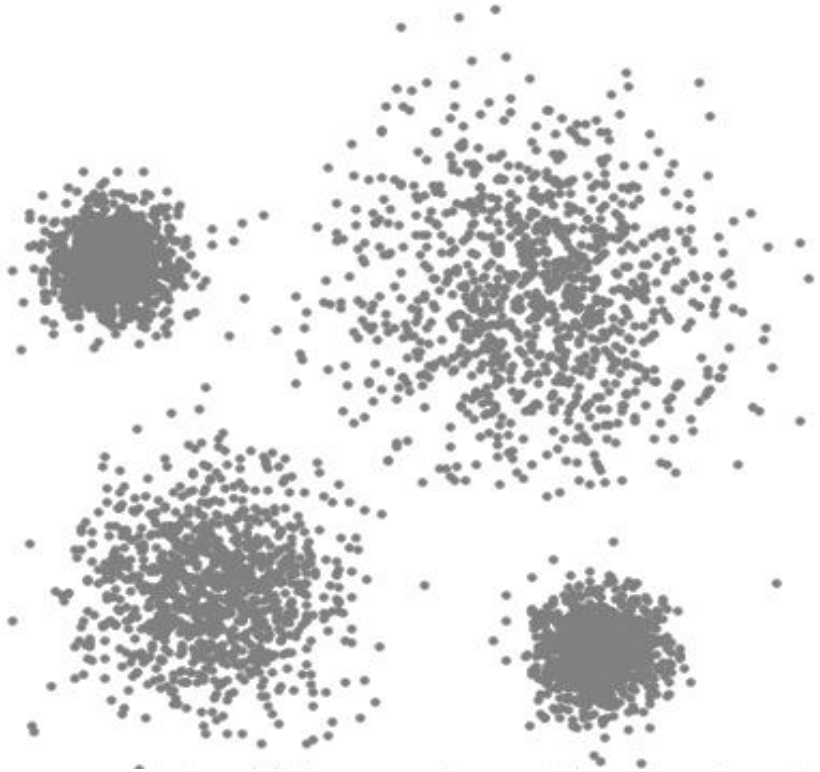
③ 直到 center 基本不动，认为收敛

④ 很多点会收敛到相同或很接近的位置

⑤ 把这些接近的收敛位置合并成一个簇中心

⑥ 每个样本所属的簇，就由它最终收敛到的峰决定

Meanshift



核心：均值计算公式

$$m(x_i) = \frac{\sum_{x_j \in N(x_i)} K\left(\left\| \frac{x_j - x_i}{h} \right\|^2\right) x_j}{\sum_{x_j \in N(x_i)} K\left(\left\| \frac{x_j - x_i}{h} \right\|^2\right)}$$

$$K(z) = \exp\left(-\frac{z}{2}\right)$$

四.经典聚类方法与案例实践

Meanshift

优点：

- 对数据集形状无要求
- 不受异常点影响（鲁棒）
- 自动确定聚类数目

经典应用：

- 视频追踪



四.经典聚类方法与案例实践

IEEE CVPR 2000

Real-Time Tracking of Non-Rigid Objects using Mean Shift

Dorin Comaniciu Visvanathan Ramesh
Imaging & Visualization Department
Siemens Corporate Research
755 College Road East, Princeton, NJ 08540

Peter Meer
Electrical & Computer Engineering Department
Rutgers University
94 Brett Road, Piscataway, NJ 08855

Abstract

A new method for real-time tracking of non-rigid objects seen from a moving camera is proposed. The central computational module is based on the mean shift iterations and finds the most probable target position in the current frame. The dissimilarity between the target model (its color distribution) and the target candidates is expressed by a metric derived from the Bhattacharyya coefficient. The theoretical analysis of the approach shows that it relates to the Bayesian framework while providing a practical, fast and efficient solution. The capability of the tracker to handle in real-time partial occlusions, significant clutter, and target scale variations, is demonstrated for several image sequences.

1 Introduction

2 Mean Shift Analysis

We define next the sample mean shift, introduce the iterative mean shift procedure, and present a new theorem showing the convergence for kernels with convex and monotonic profiles. For applications of the mean shift property in low level vision (filtering, segmentation) see [6].

2.1 Sample Mean Shift

Given a set $\{\mathbf{x}_i\}_{i=1\ldots n}$ of n points in the d-dimensional space R^d, the *multivariate kernel density estimate* with kernel $K(\mathbf{x})$ and window radius (bandwidth) h, computed in the point $\mathbf{x}$ is given by

$$\hat{f}(\mathbf{x}) = \frac{1}{nh^d} \sum_{i=1}^{n} K\left(\frac{\mathbf{x} - \mathbf{x}_i}{h}\right). \qquad (1)$$

四.经典聚类方法与案例实践

基于中心

K-means

基于分布

GMM

基于密度

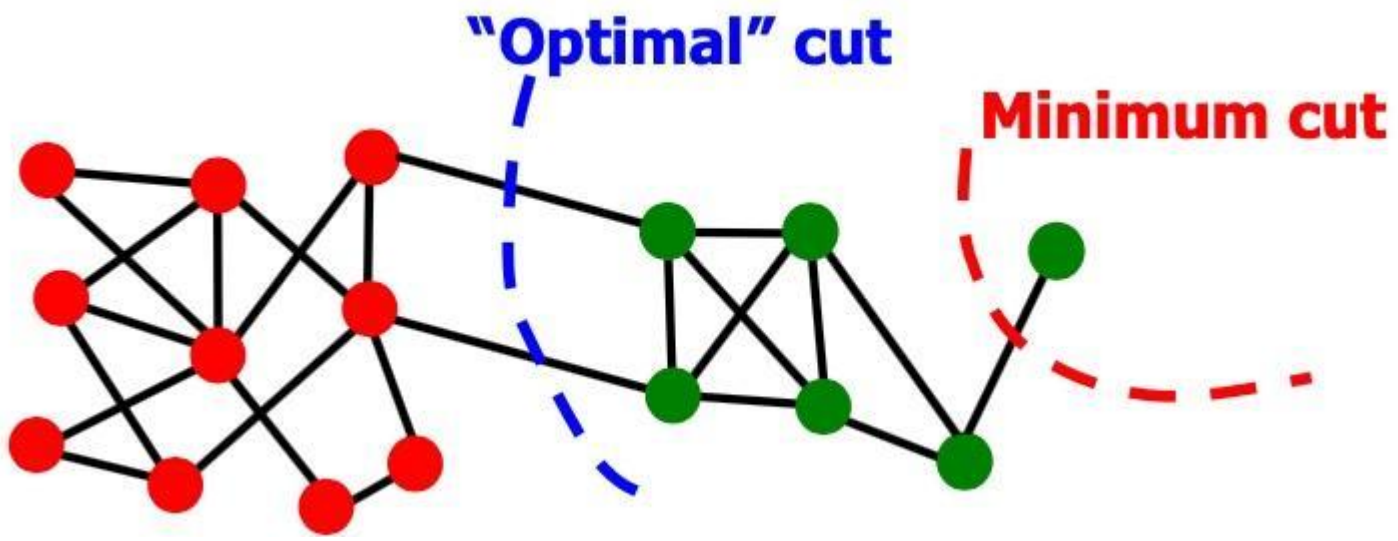
DBSCAN、Meanshift

基于图结构

谱聚类

谱聚类

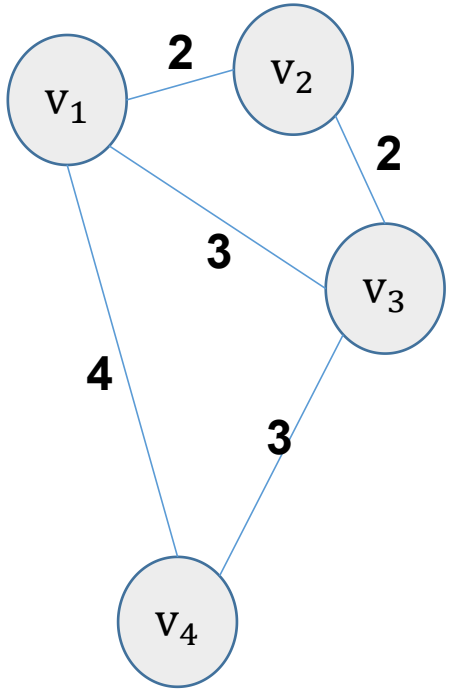
思想：利用图论的知识研究聚类问题，将其转化成“切图问题”



谱聚类

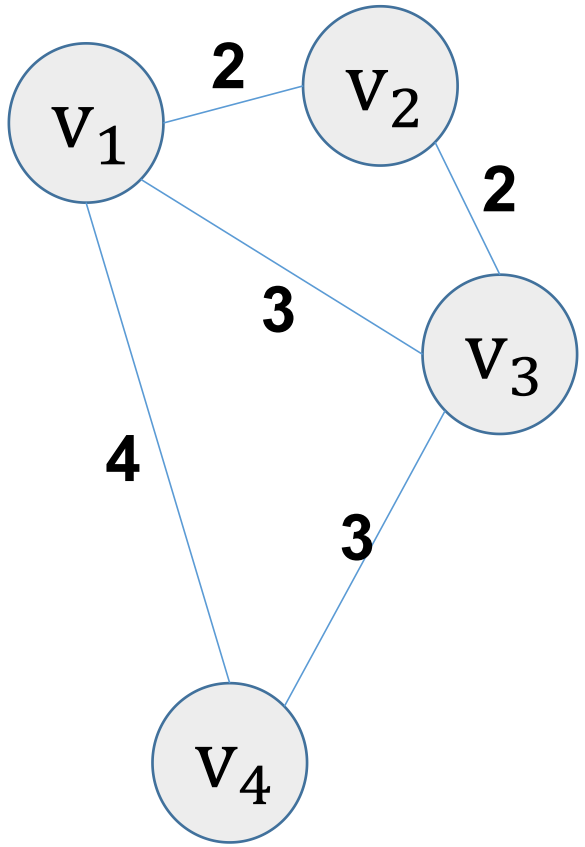
图论相关知识复习:

图 $G(V,E)$: 由顶点(Vertices)的集合V和边(Edges)的集合E构成



名称	特征
无向图	边没有方向的图
有向图	边有方向的图
加权无向图	边有权（值）但没有方向的图
加权有向图	边有权（值）但有方向的图

谱聚类



w_{ij}：点v_i和点v_j之间的权重

邻接矩阵W： $\begin{pmatrix} 0 & 2 & 3 & 4 \\ 2 & 0 & 2 & 0 \\ 3 & 2 & 0 & 3 \\ 4 & 0 & 3 & 0 \end{pmatrix}$

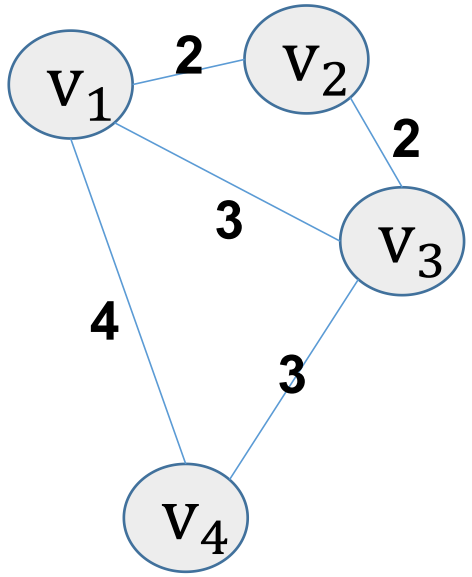
对于图中任意一点v_i，它的度d_i定义为 $d_i = \sum_j w_{ij}$

度矩阵D： $\begin{pmatrix} d_1 & \cdots & \cdots \\ \vdots & \ddots & \vdots \\ \cdots & \cdots & d_n \end{pmatrix}$

谱聚类

拉普拉斯矩阵（Laplacian matrix）：

定义： $L = D - W$



$$W = \begin{pmatrix} 0 & 2 & 3 & 4 \\ 2 & 0 & 2 & 0 \\ 3 & 2 & 0 & 3 \\ 4 & 0 & 3 & 0 \end{pmatrix}$$

$$d_i = \sum_j w_{ij}$$

$$D = \begin{pmatrix} d_1 & \cdots & \cdots \\ \vdots & \ddots & \vdots \\ \cdots & \cdots & d_n \end{pmatrix}$$

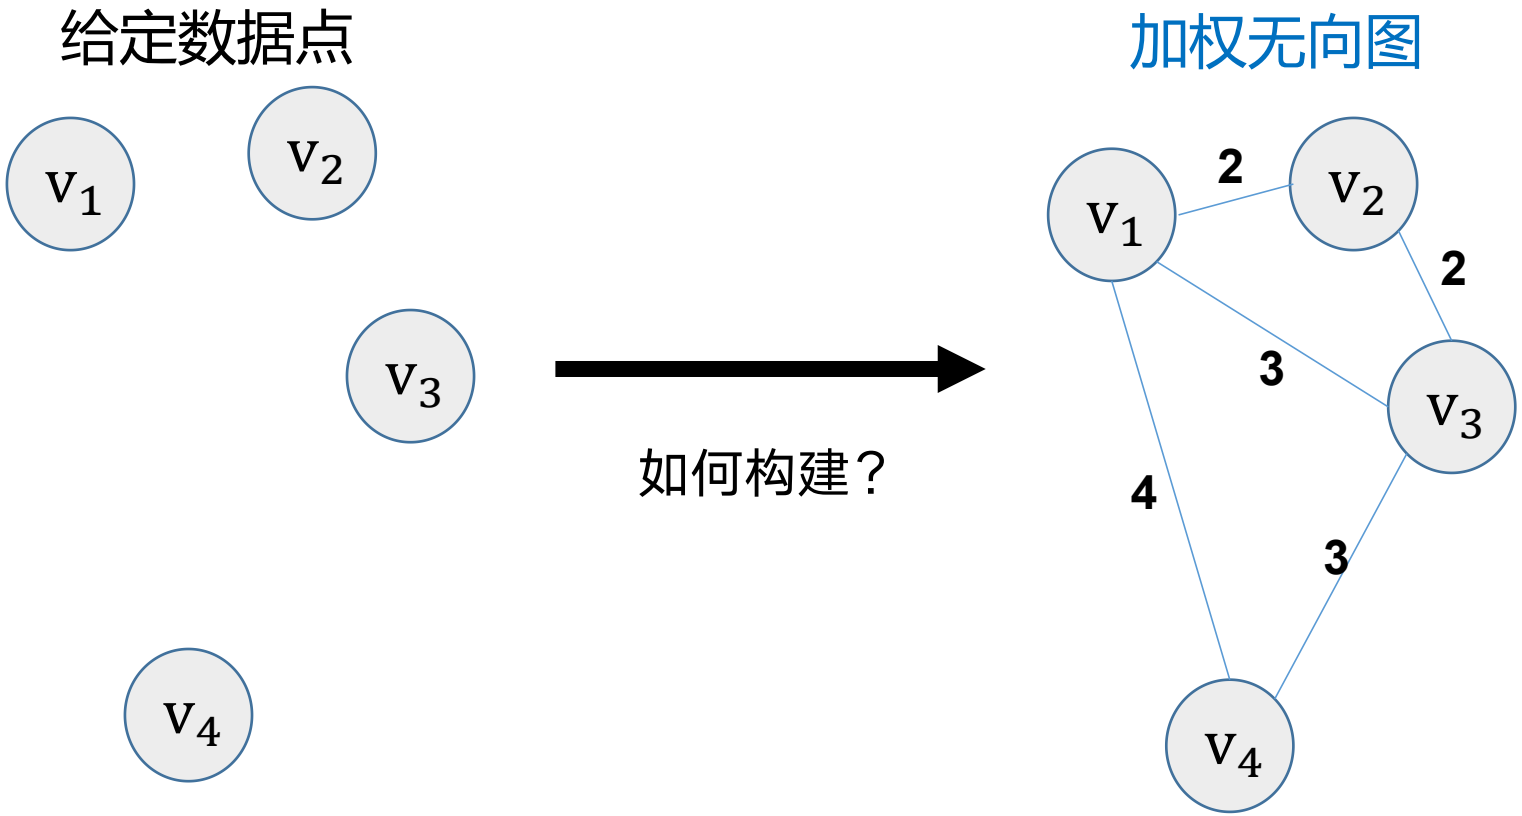
性质：

- 对于任意的向量f,我们有

$$f^T L f = \frac{1}{2} \sum_{i,j=1}^{n} w_{ij}(f_i - f_j)^2$$

谱聚类

接下来我们回到聚类这件事情上来：



谱聚类

基本思想：距离较远的两点之间的边权重值较低，而距离较近的两点之间的边权重值较高

相似矩阵S： $S_{ij} = \exp(-\frac{||x_i - x_j||_2^2}{2\sigma^2})$

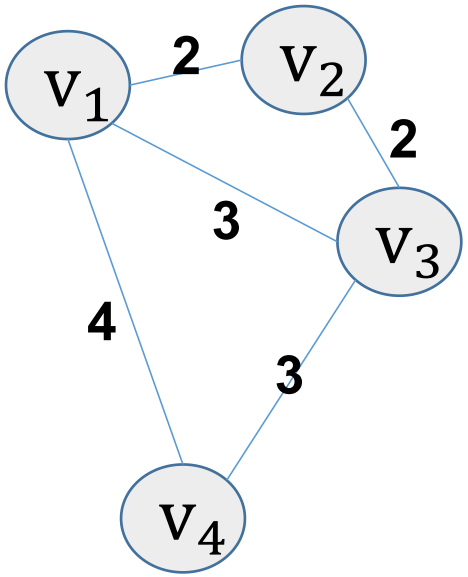
- 多项式核函数
- 高斯核函数（RBF）
- Sigmoid核函数

邻接矩阵W：

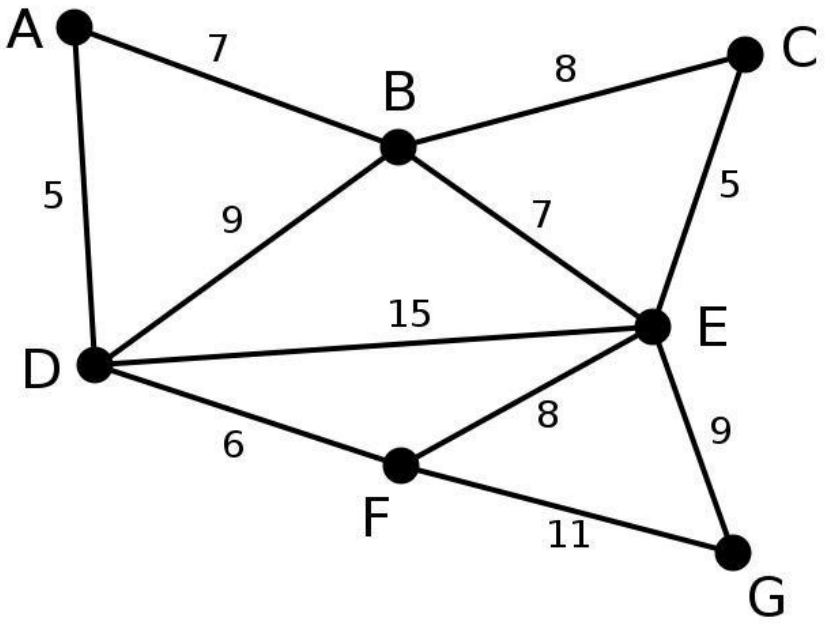
全连接法： $W_{ij} = S_{ij} = \exp(-\frac{||x_i - x_j||_2^2}{2\sigma^2})$

KNN法：

$$W_{ij} = W_{ji} = \begin{cases} 0 & x_i \notin KNN(x_j)\ and\ x_j \notin KNN(x_i) \\ \exp\left(-\frac{\left||x_i - x_j|\right|_2^2}{2\sigma^2}\right) & x_i \in KNN(x_j)\ and\ x_j \in KNN(x_i) \end{cases}$$



谱聚类



怎么做聚类?

切图：将图$G(V,E)$切成相互没有连接的K个子图（簇）：$A_1, A_2 \ldots\ldots A_K$

自然的想法：我希望各子图之间的连接尽可能弱

谱聚类

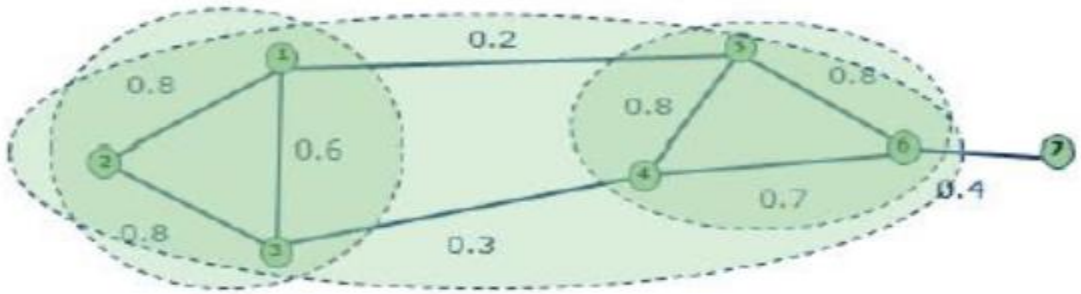
对于任意两个子图点的集合$A, B \subset V,\ A \cap B = \emptyset$， 我们定义A和B之间的切图权重为：

$$W(A, B) = \sum_{i \in A, j \in B} w_{ij}$$

那么对于我们k个子图点的集合：$A_1, A_2, \cdots, A_k$， 我们定义切图cut为：

$$cut(A_1, A_2, \cdots, A_k) = \frac{1}{2} \sum_{i=1}^{k} W(A_i, A_i')$$

mincut problem
(最小割问题)



最小割问题容易单独切出边缘点或产生歪斜分割

谱聚类

RatioCut:
(比例割)

$$RatioCut(A_1, A_2, \cdots, A_k) = \frac{1}{2}\sum_{i=1}^{k}\frac{W(A_i, A_i')}{|A_i|}$$

谱聚类就是一种近似求解最小化 ***RatioCut*** 问题的方法

谱聚类

引入变量: $h_{ij} = \begin{cases} 0 & v_i \notin A_j \\ \dfrac{1}{\sqrt{|A_j|}} & v_i \in A_j \end{cases}$

由此定义的H矩阵是什么?

$$h_i^T L h_i = \frac{1}{2}\sum_{m=1}\sum_{n=1} w_{mn}(h_{im} - h_{in})^2$$

h_i：H的第i列

$$= \frac{1}{2}\left(\sum_{m\in A_i,\ n\notin A_i} w_{mn}\left(\frac{1}{\sqrt{|A_i|}} - 0\right)^2 + \sum_{m\notin A_i,\ n\in A_i} w_{mn}\left(0 - \frac{1}{\sqrt{|A_i|}}\right)^2 \right)$$

$$= \frac{1}{2}\left(\sum_{m\in A_i,\ n\notin A_i} w_{mn}\frac{1}{|A_i|} + \sum_{m\notin A_i,\ n\in A_i} w_{mn}\frac{1}{|A_i|} \right)$$

$$= \frac{1}{2}\left(W(A_i, A_i')\frac{1}{|A_i|} + W(A_i', A_i)\frac{1}{|A_i|} \right)$$

$$= \frac{W(A_i, A_i')}{|A_i|}$$

$$f^T L f = \frac{1}{2}\sum_{i,j=1}^{n} w_{ij}(f_i - f_j)^2$$

谱聚类

$$RatioCut(A_1, A_2,\cdots, A_k) = \frac{1}{2}\sum_{i=1}^{k}\frac{W(A_i, A_i')}{|A_i|}$$

引入变量: $h_{ij} = \begin{cases} 0 & v_i \notin A_j \\ \dfrac{1}{\sqrt{|A_j|}} & v_i \in A_j \end{cases}$

$$h_i^T L h_i = \frac{W(A_i, A_i')}{|A_i|}$$

h_i：H的第i列

$$RatioCut(A_1, A_2,\cdots, A_k) = \sum_{i=1}^{k} h_i^T L h_i = \sum_{i=1}^{k}(H^T LH)_{ii} = tr(H^T LH)$$

谱聚类

$$RatioCut(A_1, A_2, \cdots, A_k) = \frac{1}{2}\sum_{i=1}^{k}\frac{W(A_i, A_i')}{|A_i|}$$

$$\arg\min tr(H^T L H) \quad s.t. H^T H = I$$

$$h_{ij} = \begin{cases} 0 & v_i \notin A_j \\ \dfrac{1}{\sqrt{|A_j|}} & v_i \in A_j \end{cases}$$

*NP-hard*问题

方法：找L的K个最小特征值，取对应的K个特征向量组成的矩阵作为H

四.经典聚类方法与案例实践

- A 点: $[1, 0]$
- B 点: $[1, 0]$
- C 点: $[0, 1]$



- A 点: $[0.98, 0.05]$
- B 点: $[0.91, 0.12]$
- C 点: $[0.08, 0.95]$

谱聚类

步骤：

一种降维手段，因此在处理高维数据聚类时的复杂度比传统聚类算法好

① 给定数据点

② 计算邻接矩阵W，度矩阵D

③ 计算拉普拉斯矩阵 $L = D - W$

④ 找L的最小的K个特征值，取它们对应的K个特征向量组成的矩阵作为H（不是真实的解H，并不能直接导出聚类结果）

⑤ 对H按行标准化：

$$h_{ij}^{*} = \frac{h_{ij}}{(\sum_{t=1}^{k} h_{it}^{2})^{1/2}}$$

⑥ 对标准化后的矩阵，每一行作为一个新样本（依旧是m个样本），采用K-means（或其它聚类方法）再进行聚类，取最终的聚类结果

四.经典聚类方法与案例实践

首都师范大学 CAPITAL NORMAL UNIVERSITY

方法	核心原理	计算量	主要优点	主要局限	典型应用
K-means 基于中心	就近分组，更新均值 最小化簇内平方误差	★☆☆☆☆ 较低	简单高效 适合大规模数据	需指定 K；初始化敏感 偏好紧凑、近球状簇	用户分群 颜色量化
GMM 基于分布	多个高斯成分拟合 按后验概率分组	★★★☆☆ 中等	提供软归属概率 适应不同椭球形簇	需指定 K；依赖分布假设 高维估计与退化问题	重叠群体识别 概率密度估计
DBSCAN 基于密度	连接高密度区域 识别稀疏噪声点	★★☆☆☆ 较低—中等	无需指定 K 识别非凸簇与噪声	邻域参数敏感 难兼顾密度差异大的簇	空间数据分析 点云分组
谱聚类 基于图结构	构建相似图 谱嵌入后再聚类	★★★★★ 高	发现复杂非凸结构 利用样本间关系	通常需指定 K；依赖构图 大样本耗时、耗内存	图像区域分割 关系网络划分
层次聚类 凝聚型	逐步合并相近簇 形成多层次聚类树	★★★★☆ 较高	展示层次关系 可事后选择分组粒度	合并通常不可逆 链接规则敏感；开销较大	基因表达分析 文档层次组织

四.经典聚类方法与案例实践

基于中心

K-means

基于分布

GMM

基于密度

DBSCAN、Meanshift

基于图结构

谱聚类

大纲

首都师范大学 CAPITAL NORMAL UNIVERSITY

01 聚类是什么

02 聚类的应用场景

03 聚类方法的发展图谱

04 经典聚类方法与案例实践

05 从经典方法到前沿方法

06 聚类结果的评价

五.从经典方法到前沿方法

经典方法的统一视角：聚类方法到底在争论什么？

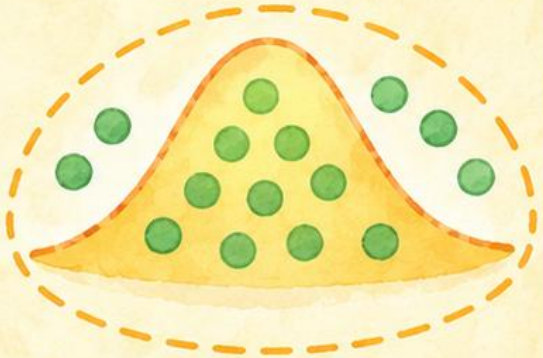
K-means

靠近同一个中心



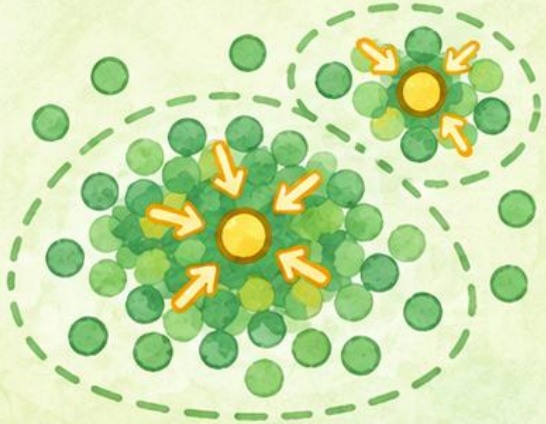
GMM

来自同一个高斯成分



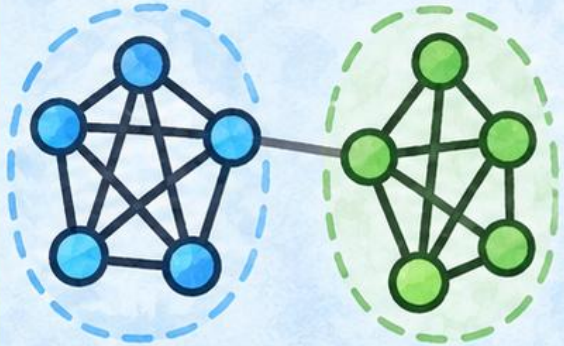
DBSCAN / Mean Shift

DBSCAN：密度连通
Mean Shift：趋向同一密度峰



谱聚类

组内连接强，组间连接弱



五.从经典方法到前沿方法

01

方向 1：深度聚类

表示学习 + 聚类联合训练

- 输入数据 → 编码器 → 潜在表示 → 聚类损失

02

方向 2：图聚类 / 社区发现

图结构 + 表示学习结合

- 社交网络
- 推荐
- 知识图谱

03

方向 3：多视图聚类

多个模态 / 多种特征

- 图像 + 文本
- 表格 + 图结构
- 多传感器、多来源数据

04

方向 4：非欧几里得聚类

流形 / 双曲空间中的聚类

- 层级关系
- 树状结构
- 复杂语义结构

- Zhou, S., Xu, H., Zheng, Z., et al. A Comprehensive Survey on Deep Clustering: Taxonomy, Challenges, and Future Directions. arXiv, 2022.
- Berahmand, K., Saberi-Movahed, F., Sheikhpour, R., et al. A Comprehensive Survey on Spectral Clustering with Graph Structure Learning. arXiv, 2025.
- Zhou, L., et al. A Survey and an Empirical Evaluation of Multi-View Clustering Approaches. ACM Computing Surveys, 2024.
- Jaćimović, V., & Crnkić, A. Clustering in Hyperbolic Balls. arXiv, 2025.

大纲

首都师范大学 CAPITAL NORMAL UNIVERSITY

01 聚类是什么

02 聚类的应用场景

03 聚类方法的发展图谱

04 经典聚类方法与案例实践

05 从经典方法到前沿方法

06 聚类结果的评价

六. 聚类结果的评价

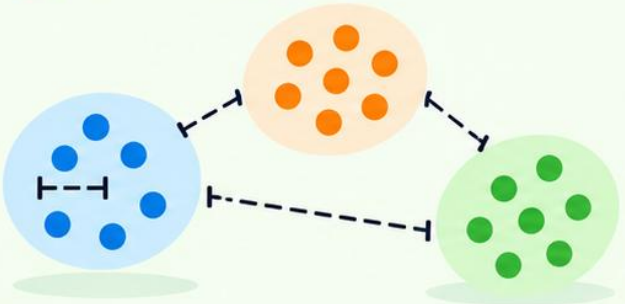
首都师范大学 CAPITAL NORMAL UNIVERSITY

内部评价

不需要标签

同组是否紧凑？不同组是否分开？

- 轮廓系数：越大越好
- DBI：越小越好



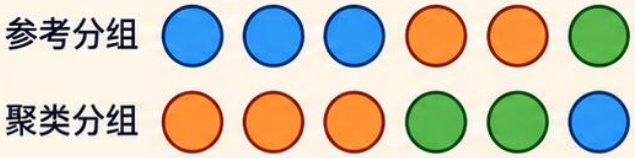
外部评价

需要参考标签

聚类分组与参考分组有多一致？

- ARI：比较样本分组的一致性
- NMI：衡量两种分组的共享信息

两者通常越大越好



任务导向评价

关注实际用途

分组是否帮助解决实际问题？

- 用户分群：营销效果是否提升？
- 图像分割：区域是否符合需求？



指标是参考，还要结合数据特点与实际目标

大纲

首都师范大学 CAPITAL NORMAL UNIVERSITY

01 聚类是什么

02 聚类的应用场景

03 聚类方法的发展图谱

04 经典聚类方法与案例实践

05 从经典方法到前沿方法

06 聚类结果的评价

scikit learn Install User Guide API Examples More Go

scikit-learn

Machine Learning in Python

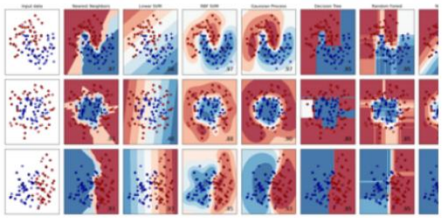
Getting Started | Release Highlights for 1.0 | GitHub

- Simple and efficient tools for predictive data analysis
- Accessible to everybody, and reusable in various contexts
- Built on NumPy, SciPy, and matplotlib
- Open source, commercially usable - BSD license

Classification

Identifying which category an object belongs to.

Applications: Spam detection, image recognition.
Algorithms: SVM, nearest neighbors, random forest, and more...

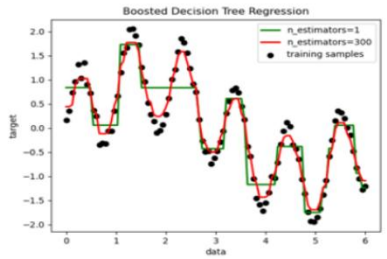


Examples

Regression

Predicting a continuous-valued attribute associated with an object.

Applications: Drug response, Stock prices.
Algorithms: SVR, nearest neighbors, random forest, and more...

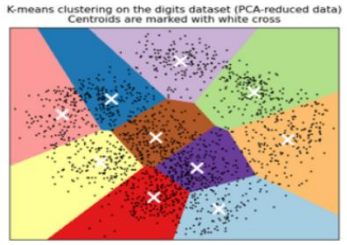


Examples

Clustering

Automatic grouping of similar objects into sets.

Applications: Customer segmentation, Grouping experiment outcomes
Algorithms: k-Means, spectral clustering, mean-shift, and more...



Examples

Dimensionality reduction

Reducing the number of random variables to consider.

Applications: Visualization, Increased efficiency
Algorithms: k-Means, feature selection, non-negative matrix factorization, and more...

Model selection

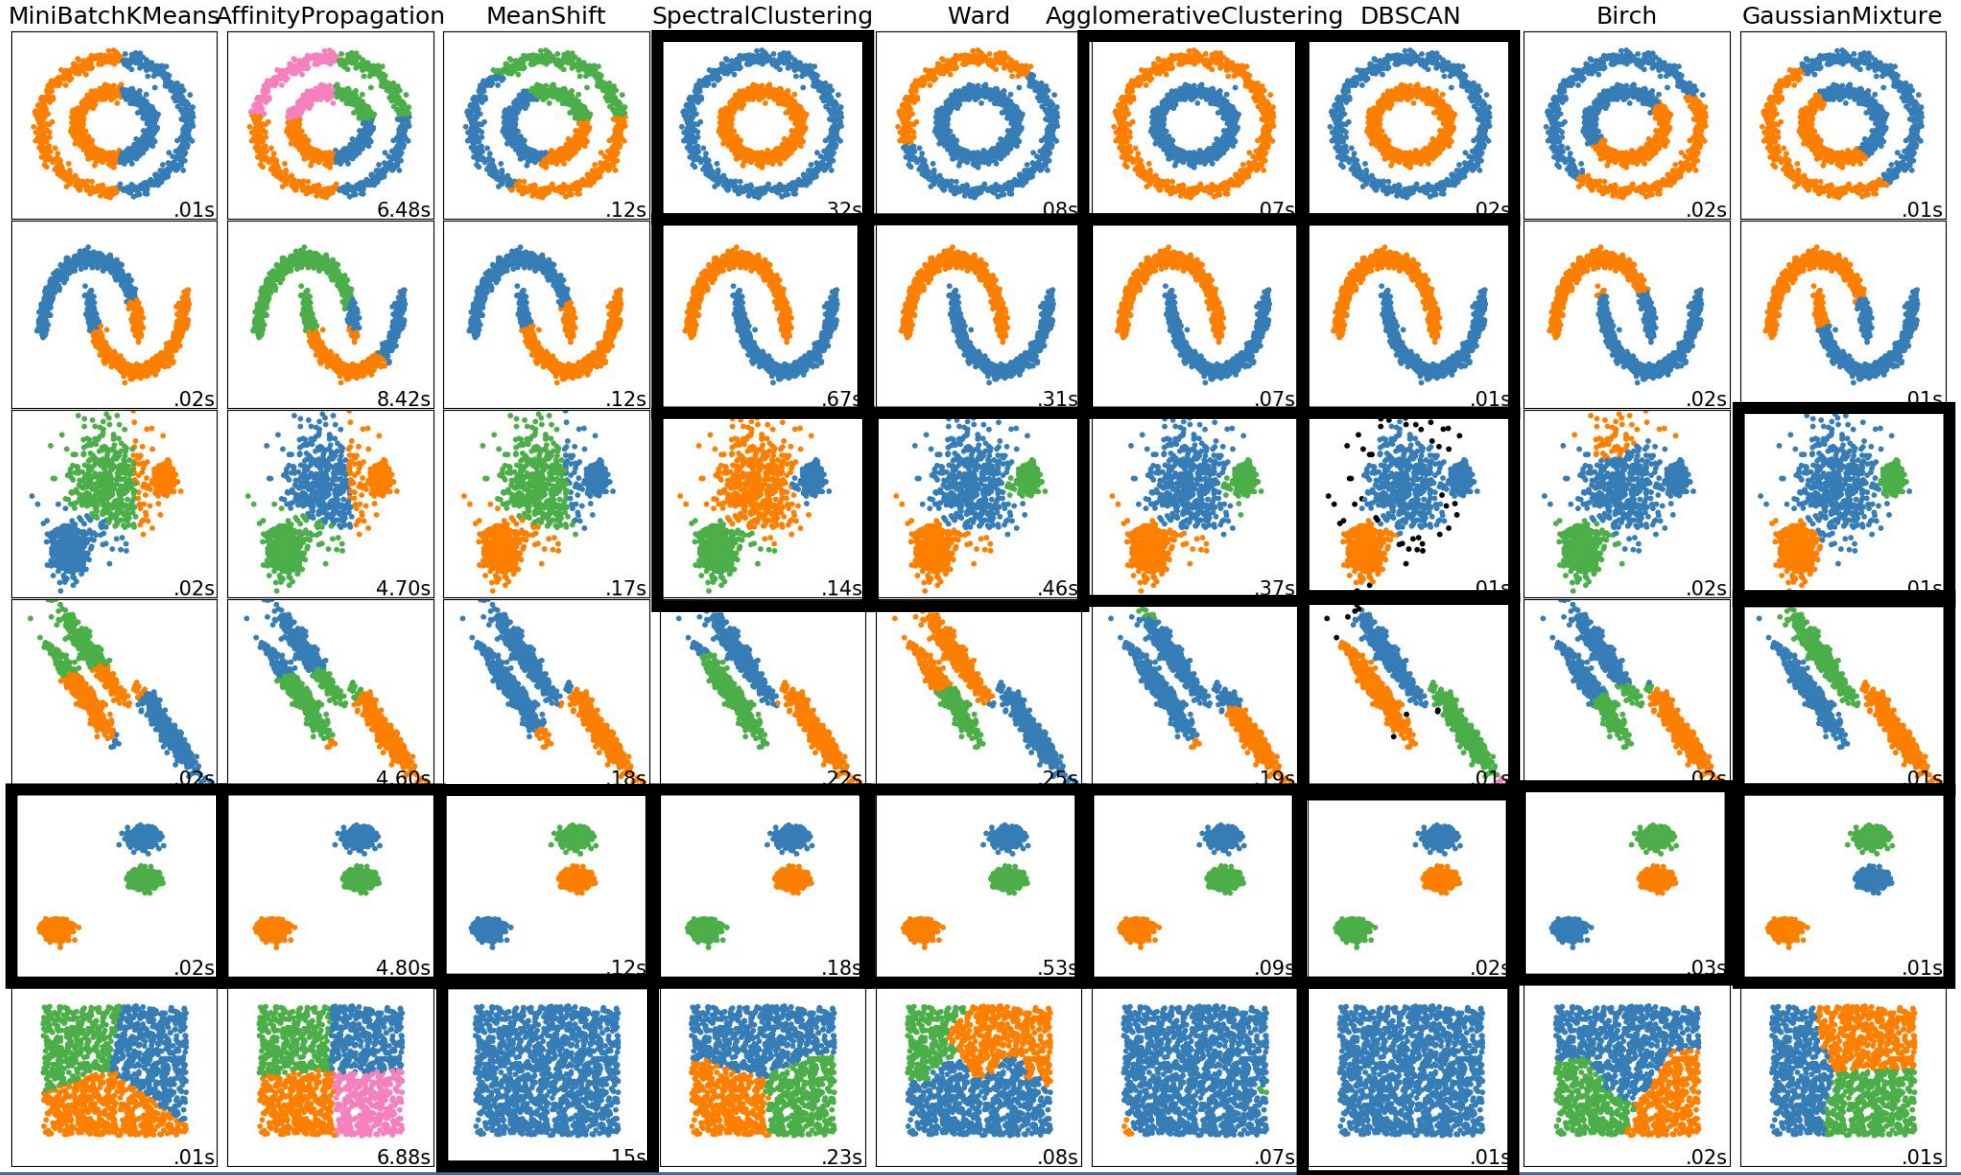
Comparing, validating and choosing parameters and models.

Applications: Improved accuracy via parameter tuning
Algorithms: grid search, cross validation, metrics, and more...

Preprocessing

Feature extraction and normalization.

Applications: Transforming input data such as text for use with machine learning algorithms.
Algorithms: preprocessing, feature extraction, and more...


MiniBatchKMeans
AffinityPropagation
MeanShift
SpectralClustering
Ward
AgglomerativeClustering
DBSCAN
Birch
GaussianMixture
.01s
6.48s
.12s
32s
08s
07s
02s
.02s
.01s
.02s
8.42s
.12s
67s
31s
07s
01s
.02s
01s
.02s
4.70s
.17s
14s
46s
37s
01s
.02s
01s
02s
4.60s
18s
22s
25s
19s
01s
02s
01s
.02s
4.80s
.12s
.18s
.53s
.09s
.02s
.03s
.01s
.01s
6.88s
15s
.23s
.08s
.07s
.01s
.02s
.01s

当数据包含一个分散的大簇和两个彼此较近的紧凑小簇时，即使设置 $K = 3$，K-means 仍可能拆开大簇、合并两个小簇，最直接的原因是什么？

A. 拆分大簇减少的平方误差，可能超过合并小簇增加的平方误差。
B. 算法要求各簇的样本数量尽量相同。
C. 更新中心的目的是使各中心之间的距离尽量相等。
D. 分配样本的依据是各簇的局部密度，而不是到中心的距离。

答案：A。

标准 GMM 的 E 步得到每个样本属于各成分的后验概率后，接下来的 M 步应如何使用这些概率？

A. 将样本分给后验概率最大的成分，再按硬标签估计参数。
B. 将这些概率作为权重，更新各成分的均值、协方差与混合权重。
C. 按这些概率随机抽取样本标签，再按抽样结果估计参数。
D. 仅用这些概率更新混合权重，各成分均值统一取全体样本的均值。

答案：B。

“DBSCAN 不需要预先指定簇数 K，因此同一数据集上改变 ε 和 MinPts 也不会改变最终簇数。”请判断并说明理由。

答案：错误。

对于非负边权的无向相似图，RatioCut 相比普通最小割引入簇大小归一化，主要是为了什么？

A. 强制每个簇包含完全相同数量的顶点。
B. 优先把度最大的顶点单独分成一簇。
C. 抑制仅因切边代价小就分离出极小簇的倾向。
D. 使划分不再依赖边权，只取决于顶点数量。

答案：C。

将 K 个拉普拉斯特征向量按列组成 $n \times K$ 的矩阵 U 后，为什么常见谱聚类还要对 U 的行做 K-means?

A. 每行是一个样本的连续表示，需要进一步转成离散簇标签。
B. 每行对应一个特征向量，需要把这些特征向量划分成不同组。
C. U 已经给出了原问题的离散最优解，K-means 只是重新编号。
D. 取特征向量只能压缩维数，对原有样本之间的几何关系没有影响。

答案：A。

某批零件由两台机器生产，已知每台机器生产的零件长度分别服从正态分布，但零件混合后失去了机器来源标签，请用 GMM 为观测到的长度数据 $x_1, \ldots, x_n$ 建模，写出单个样本的概率密度和待估计参数，无需求解。

参考答案：

引入隐变量 $z_i \in \{1, 2\}$，表示第 i 个零件来自哪台机器，设：

$$P(z_i = 1) = \pi, \qquad P(z_i = 2) = 1 - \pi,$$

$$x_i \mid z_i = 1 \sim \mathcal{N}(\mu_1, \sigma_1^2), \qquad x_i \mid z_i = 2 \sim \mathcal{N}(\mu_2, \sigma_2^2).$$

由于不知道零件来源，需要对两种可能来源求和，因此：

$$\boxed{p(x_i) = \pi \mathcal{N}(x_i \mid \mu_1, \sigma_1^2) + (1 - \pi) \mathcal{N}(x_i \mid \mu_2, \sigma_2^2)}$$

待估计参数为：

$$\theta = (\pi, \mu_1, \mu_2, \sigma_1^2, \sigma_2^2), \qquad 0 < \pi < 1, \quad \sigma_1^2, \sigma_2^2 > 0.$$

其中，π 表示来自第一台机器的零件比例，两组均值和方差分别描述两台机器的生产特征。

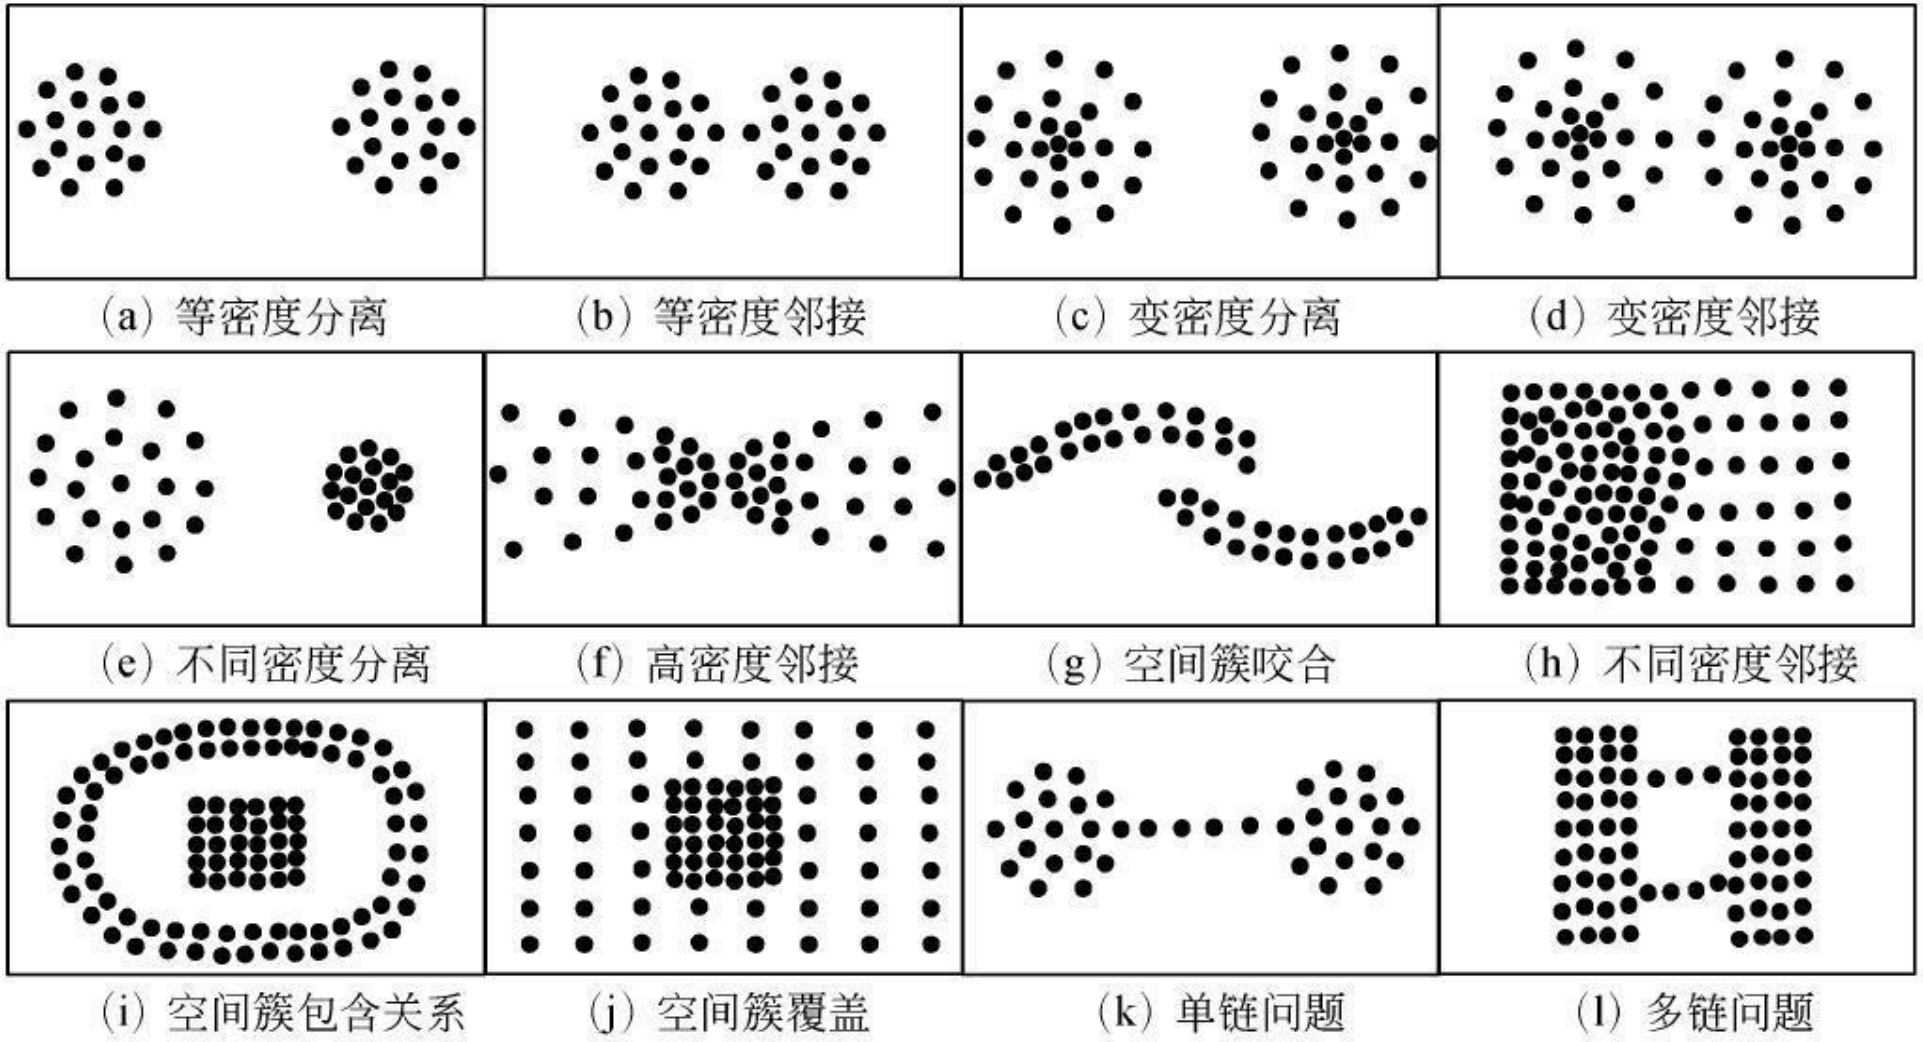


图 4.1　空间聚类中的典型问题

“The observation of and the search for similarities and differences are the basis of all human knowledge.”

—— ALFREDB. NOBEL

“人类所有知识的基础就是观察和寻找相似与相异”

—— 阿尔弗雷德·伯恩哈德·诺贝尔





首都师范大学
CAPITAL NORMAL UNIVERSITY