




上一课总结

- 一. 什么是机器学习?
- 二. 机器学习发展史
- 三. 机器学习包含什么?
- 四. 机器学习通用流程
- 五. 基础概念介绍




无监督学习

数据 (无标签) : $(x_i)_{i=1}^l$

目标: 挖掘数据的内在结构和规律

■ 聚类: 对数据分组

■ 降维: 把数据投影到低维空间





第三课 降维

授课教师：潘贤丽



大纲

01 什么是降维

02 降维方法的发展图谱

03 经典降维方法与案例实践

04 从经典方法到前沿方法

[illegible]

表格



文本



图片



声音信号

降维：用更少的变量表示原始数据，同时尽量保留对分析、理解和建模重要的信息

一种更数学的说法：找一映射函数 $f: \mathbf{x} \in \mathbb{R}^p \rightarrow \mathbf{z} \in \mathbb{R}^d, d < p$

$$z = f(x)$$

一.什么是降维

降低存储与计算开销

01

02

便于可视化和理解数据结构

维数灾难

03

04

去除冗余与噪声,提升后续建模效果

为什么要做降维?

一.什么是降维

便于可视化和理解数据结构

airplane
automobile
bird
cat
deer
dog
frog
horse
ship
truck



自动保存 赛力斯.xlsx · 已保存到这台电脑

文件 开始 插入 绘图 页面布局 公式 数据 审阅 视图 帮助 Acrobat 百度网盘

剪贴板 复制 格式刷 粘贴 格式刷

宋体 11 A⁺ A⁻ B I U 字体 对齐方式 数字 样式



条件格式 套用表格格式 检查单元格 解释性文本 警告文本 链接单元

	A	B	C	D	E	F	G	H	I	J
1	代码	名称	日期	开盘价	最高价	最低价	收盘价	涨跌幅	成交量	成交额(百万)
2	601127.SH	赛力斯	2016-06-15	6.97	8.37	6.97	8.37	0.4406	67300	0.56
3	601127.SH	赛力斯	2016-06-16	9.21	9.21	9.21	9.21	0.1004	20305	0.19
4	601127.SH	赛力斯	2016-06-17	10.13	10.13	10.13	10.13	0.0999	25466	0.26
5	601127.SH	赛力斯	2016-06-20	11.14	11.14	11.14	11.14	0.0997	31994	0.36
6	601127.SH	赛力斯	2016-06-21	12.25	12.25	12.25	12.25	0.0996	46762	0.57
7	601127.SH	赛力斯	2016-06-22	13.48	13.48	13.48	13.48	0.1004	44100	0.59
8	601127.SH	赛力斯	2016-06-23	14.83	14.83	14.83	14.83	0.1001	73009	1.08
9	601127.SH	赛力斯	2016-06-24	16.31	16.31	16.31	16.31	0.0998	319123	5.2
10	601127.SH	赛力斯	2016-06-27	17.94	17.94	17.94	17.94	0.0999	263218	4.72
11	601127.SH	赛力斯	2016-06-28	19.73	19.73	19.73	19.73	0.0998	264448	5.22
12	601127.SH	赛力斯	2016-06-29	21.7	21.7	21.7	21.7	0.0998	230094	4.99
13	601127.SH	赛力斯	2016-06-30	23.87	23.87	23.87	23.87	0.1	710858	16.97

	江峰	张久文	崔建勋
37	42	38	
男	男	男	
博士	博士	硕士	
企业管理者	企业管理者	企业管理者	
行业	行业	行业	
北京志锐科技有限公司--- (致晶科技)	大连三生科技发展有限公司	复朗德 (北京) 纳米科技有限公司	
2016/10/18	2011/8/18	2013/8/15	
>5	>5	>5	
国家	独资	独资	
北京	辽宁	北京	
京津冀	西南	京津冀	
产品推广	技术推广	产品推广	
研发能力	产品性价比	研发能力	
>10	>10	5-10	
器件与模组	器件与模组	器件与模组	
适中	容易	容易	
1-3	1-3	4-10	
技术驱动	市场驱动	技术驱动	
电子信息/泛半导体	生物医药	其他	
科技成果转化	医疗器械	科技成果转化	
>5	3-5	>5	
3-5	3-5	0-3	

一.什么是降维




便于可视化和理解数据结构



(a) 标签嵌入的 t-SNE 可视化结果

一.什么是降维

便于可视化和理解数据结构



一.什么是降维

降低存储与计算开销 01

02

便于可视化和理解数据结构

维数灾难 03

04


去除冗余与噪声,提升后续建模效果

为什么要做降维?

一.什么是降维


维数灾难

维数灾难(Curse of Dimensionality):
是指随着维度升高, 高维空间中会出现一系列反常现象, 使得数据分析、统计估计和机器学习都变得更加困难。



一.什么是降维






维数灾难



所需样本量指数级增长

一.什么是降维

维数灾难




$$\lim_{d \rightarrow \infty} \frac{dist_max(\vec{x}_i) - dist_min(\vec{x}_i)}{dist_min(\vec{x}_i)} \approx 0$$

距离/几何直觉失效

一.什么是降维

维数灾难



一.什么是降维

降维：用更少的变量表示原始数据，同时尽量保留对分析、理解和建模重要的信息



算得快、看得清、学得动、效果好



大纲

01 什么是降维

02 降维方法的发展图谱

03 经典降维方法与案例实践

04 从经典方法到前沿方法

二.降维方法的发展图谱

特征选择


- **过滤式** (快,和模型无关)
代表:方差阈值、卡方、互信息
- **包裹式** (用模型效果选特征)
代表:前向选择、后向消除、RFE
- **嵌入式** (训练过程中自动选择)
代表:Lasso、随机森林、GBDT

这次课要讲的内容

特征提取

二.降维方法的发展图谱

降维：用更少的变量表示原始数据，同时尽量保留对分析、理解和建模重要的信息




01 什么是降维

02 降维方法的发展图谱

03 经典降维方法与案例实践

04 从经典方法到前沿方法

二.降维方法的发展图谱



降维的数学定义： 找一映射函数 $f: x \in \mathbb{R}^p \rightarrow z \in \mathbb{R}^d$, $d < p$


$$z = f(x)$$

线性降维： $z = f(x) = Wx$, $W \in \mathbb{R}^{d \times p}$

基础知识回顾

向量内积的几何含义是什么？

例： $A = (x_1, y_1)$, $B = (x_2, y_2)$ $A \cdot B = |A||B|\cos(\alpha)$




假设：B是单位向量

A 与 B 的内积 = A 向 B 所在直线投影的标量大小

基础知识回顾

向量在某组基下的坐标怎么计算？


例：求向量 $(3, 2)$ 在 $(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}})$ 和 $(-\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}})$ 这组基下的坐标



$$\begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix} \begin{pmatrix} 3 \\ 2 \end{pmatrix} = \begin{pmatrix} 5/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}$$

主成分分析 (PCA)


$$Z = Wx$$



三.经典降维方法与案例实践

主成分分析 (PCA)

中心思想：降维后的数据可以保留尽可能多的原始数据信息



最大方差

三.经典降维方法与案例实践

主成分分析 (PCA)

中心思想：降维后的数据可以保留尽可能多的原始数据信息

原数据： $\{x_i\}, i = 1, \dots, N$

降维方向 u_1 : $u_1^T u_1 = 1$

降维后数据 y_n : $y_n = u_1^T x_n$

最大方差

均值： $\bar{y} = u_1^T \bar{x}, \bar{x} = \frac{1}{N} \sum_n x_n$

方差： $var(y) = \frac{1}{N} \sum_n (u_1^T x_n - u_1^T \bar{x})^2 = u_1^T \mathbf{S} u_1$

协方差矩阵： $S = \frac{1}{N} \sum_n (x_n - \bar{x})(x_n - \bar{x})^T$

主成分分析 (PCA)

$$\begin{aligned} \max_{u_1} \text{var}(y) &= u_1^T S u_1 \\ \text{s.t. } u_1^T u_1 &= 1 \end{aligned}$$

$$S = \frac{1}{N} \sum_n (x_n - \bar{x})(x_n - \bar{x})^T$$

拉格朗日乘子法

$$L = -u_1^T S u_1 + \lambda_1 (u_1^T u_1 - 1)$$

$$S u_1 = \lambda_1 u_1$$

最大特征值对应的
特征向量

三.经典降维方法与案例实践

主成分分析 (PCA)

$$\begin{aligned} \max_{u_2} \text{var}(y) &= u_2^T S u_2 \\ \text{s.t. } u_2^T u_2 &= 1, u_1^T u_2 = 0 \end{aligned}$$

$$S = \frac{1}{N} \sum_n (x_n - \bar{x})(x_n - \bar{x})^T$$

拉格朗日乘子法

$$L = -u_2^T S u_2 + \lambda_2(u_2^T u_2 - 1) + \gamma(u_1^T u_2 - 0)$$

$$S u_2 = \lambda_2 u_2$$

第二大特征值对应的
特征向量

主成分分析 (PCA)

线性降维: $z = Wx, W \in \mathbb{R}^{d \times p}$



$$S = \frac{1}{N} \sum_n (x_n - \bar{x})(x_n - \bar{x})^T$$

S 的前 d 个最大特征值对应的特征向量组成的矩阵

主成分分析 (PCA)

输入： 样本集 $X = [x_1, x_2, \dots, x_N] \in R^{p \times N}$; 低维空间维数 d .

过程：

1. 对所有样本**中心化**: $x_i \leftarrow x_i - \frac{1}{N} \sum_n x_n$
2. 计算样本的**协方差矩阵** $S = \frac{1}{N} \sum_n x_n x_n^T$
3. 对协方差矩阵 S 进行**特征值分解**
4. 取最大的 d 个特征值所对应的特征向量

$$U = [w_1, w_2, \dots, w_d] \in R^{p \times d}$$

输出： 投影后数据

$$Y = U^T X$$

三.经典降维方法与案例实践

主成分分析 (PCA)

累积方差
贡献率

$$Su_1 = \lambda_1 u_1$$




$$\begin{aligned} \max_{u_1} \text{var}(y) &= u_1^T Su_1 = \lambda_1 \\ \text{s.t. } u_1^T u_1 &= 1 \end{aligned}$$

$$r_i = \frac{\lambda_i}{\sum_{j=1}^p \lambda_j} \times 100$$

$$\sum_{i=1}^d r_i \geq 98$$

三.经典降维方法与案例实践

主成分分析 (PCA)



假设原始数据矩阵中心化后是 X_c , 取前 d 个主成分组成矩阵 U_d 。

第一步：降维

$$Z = U_d^T X_c$$

第二步：从低维再重构回原空间

$$\hat{X}_c = U_d Z = U_d U_d^T X_c$$

如果要回到原始坐标系, 再加回均值:

$$\hat{X} = \hat{X}_c + \mu$$

第三步：看重构误差





最常见就是均方误差:

$$\text{Reconstruction Error} = \frac{1}{N} \sum_{i=1}^N \|x_i - \hat{x}_i\|^2$$

$$\begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix} \begin{pmatrix} 3 \\ 2 \end{pmatrix} = \begin{pmatrix} 5/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}$$

三.经典降维方法与案例实践

主成分分析 (PCA)




三.经典降维方法与案例实践

主成分分析 (PCA)



	England	N Ireland	Scotland	Wales
Alcoholic drinks	375	135	458	475
Beverages	57	47	53	73
Carcase meat	245	267	242	227
Cereals	1472	1494	1462	1582
Cheese	105	66	103	103
Confectionery	54	41	62	64
Fats and oils	193	209	184	235
Fish	147	93	122	160
Fresh fruit	1102	674	957	1137
Fresh potatoes	720	1033	566	874
Fresh Veg	253	143	171	265
Other meat	685	586	750	803
Other Veg	488	355	418	570
Processed potatoes	198	187	220	203
Processed Veg	360	334	337	365
Soft drinks	1374	1506	1572	1256
Sugars	156	139	147	175

三.经典降维方法与案例实践



<https://setosa.io/ev/principal-component-analysis/>

三.经典降维方法与案例实践

主成分分析 (PCA)

Eigenfaces for Recognition

Matthew Turk and Alex Pentland

Vision and Modeling Group
The Media Laboratory
Massachusetts Institute of Technology

论文: [Eigenfaces for Recognition \(mitpressjournals.org\)](http://mitpressjournals.org)



三.经典降维方法与案例实践

主成分分析 (PCA)



Figure 1. (b) The average face Ψ .



Figure 2. Seven of the eigenfaces calculated from the input images of Figure 1.

三.经典降维方法与案例实践

主成分分析 (PCA)



Figure 3. An original face image and its projection onto the face space defined by the eigenfaces of Figure 2.


三.经典降维方法与案例实践

主成分分析 (PCA)


- 1.核主成分分析 (Kernel PCA)** : 通过使用核技巧将数据映射到高维特征空间, 核主成分分析可以捕捉到数据在原始空间中的非线性结构。
- 2.稀疏主成分分析 (Sparse PCA)** : 通过在PCA的基础上增加稀疏性约束, 稀疏主成分分析旨在产生易于解释的主成分。
- 3.增量主成分分析 (Incremental PCA)** : 针对大数据集或在线实时数据分析设计的。
- 4.鲁棒主成分分析 (Robust PCA)** : 旨在对异常值和噪声具有鲁棒性的PCA变体。
- 5.功能主成分分析 (Functional PCA, FPCA)** : 用于分析时间序列数据或其他形式的函数数据。
- 6.概率主成分分析 (Probabilistic PCA)** : 是PCA的概率形式, 通过假设数据是从某个潜在的低维高斯分布生成的, 它提供了一种评估数据生成模型的方法。

.....

二.降维方法的发展图谱



多维尺度缩放 (MDS)



数据结构怎么刻画?


距离矩阵

$$D: m \times m$$

中心思想：降维前后，距离矩阵应尽可能保持不变

三.经典降维方法与案例实践

多维尺度缩放 (MDS)





三.经典降维方法与案例实践

多维尺度缩放 (MDS)

给定: m 个 p 维的样本点 $\{x_i\}$

想要: m 个 d 维的样本点 $\{z_i\}$


$$D: m \times m$$



$$D_{ij} = \|z_i - z_j\|_2$$

根据上面的距离等式, 求出 z_i

多维尺度缩放 (MDS)

Z: 降维后样本矩阵 ($d * m$)

$$\mathbf{B} = \mathbf{Z}^T \mathbf{Z}, \quad b_{ij} = \mathbf{z}_i^T \mathbf{z}_j$$

中心化: $\sum_{i=1}^m \mathbf{z}_i = 0$, 有 $\sum_{i=1}^m b_{ij} = \sum_{j=1}^m b_{ij} = 0$

$$\begin{aligned} D_{ij}^2 &= \|\mathbf{z}_i\|^2 + \|\mathbf{z}_j\|^2 - 2\mathbf{z}_i^T \mathbf{z}_j \\ &= b_{ii} + b_{jj} - 2b_{ij} \end{aligned}$$



$$\mathbf{b}_{ij} = -\frac{1}{2} (D_{ij}^2 - D_{i\cdot}^2 - D_{\cdot j}^2 + D_{\cdot\cdot}^2)$$

$$D_{i\cdot}^2 = \frac{1}{m} \sum_{j=1}^m D_{ij}^2 = \frac{1}{m} [\text{tr}(\mathbf{B}) + mb_{ii}]$$


$$D_{\cdot j}^2 = \frac{1}{m} \sum_{i=1}^m D_{ij}^2 = \frac{1}{m} [\text{tr}(\mathbf{B}) + mb_{jj}]$$

$$D_{\cdot\cdot}^2 = \frac{1}{m^2} \sum_{i=1}^m \sum_{j=1}^m D_{ij}^2 = \frac{2}{m} \text{tr}(\mathbf{B})$$


三.经典降维方法与案例实践

多维尺度缩放 (MDS)

给定: m 个 p 维的样本点 $\{x_i\}$


$$D: m \times m$$

想要: m 个 d 维的样本点 $\{z_i\}$



$$D_{ij} = \|z_i - z_j\|_2$$

- $B = Z^T Z$
- 对 B 做特征值分解, $B = V \Lambda V^T$
- 取 Λ 为前 d 个最大特征值构成的对角阵, V 为对应特征向量矩阵, 最后输出矩阵 $Z^T = V \Lambda^{1/2} \in R^{m \times d}$

多维尺度缩放 (MDS)

降维的定义： 找一映射函数 $f: x \in \mathbb{R}^p \rightarrow z \in \mathbb{R}^d, d < p$

非线性降维： $z = f(x)$


没有学 f , 直接给出了 z

思考中.....




来一个新的高维样本点，怎么用MDS做降维？

二.降维方法的发展图谱




三.经典降维方法与案例实践



在计算距离时
欧式距离是不是永远合适？


三.经典降维方法与案例实践

流形



假设：数据可能位于高维空间的某个低维流形上


流形



流形上的距离怎么算？流形**测地距离**，用**局部欧氏距离**逼近


三.经典降维方法与案例实践

流形




三.经典降维方法与案例实践

图论



最短路问题

最短路问题 { 单源最短路: 从A到任意一点的最短路
多源最短路: 任意两点间的最短路



Edsger W.Dijkstra (1930– 2002)
1972年图灵奖得主


■ Dijkstra算法

论文: E. Dijkstra. A note on two problems in connexion with graphs. Numerische Mathematik. 1: 269–271, 1959.

三.经典降维方法与案例实践

图论

■ 问题：求a到各点的最短距离及对应路线




把所有可能性
都算一遍？



欲言又止 稍加思考

三.经典降维方法与案例实践




看起来像是在思考
实际上大脑里一片空白呢

从a出发	第一轮	第二轮	第三轮	第四轮	第五轮	第六轮	第七轮
b	4 a-b	4 a-b	4 a-b				
c	5 a-c	3 a-d-c					
d	2 a-d						
e	inf a-e	inf a-e	6 a-d-c-e	6 a-d-c-e			
f	inf a-f	inf a-f	12 a-d-c-f	12 a-d-c-f	8 a-d-c-e-f	8 a-d-c-e-f	
g	inf a-g	10 a-d-g	6 a-d-c-g	6 a-d-c-g	6 a-d-c-g		
h	inf a-h	inf a-h	inf a-h	inf a-h	18 a-d-c-e-h	18 a-d-c-e-h	18 a-d-c-e-h
集合	d	c	b	e	g	f	h


图论

应用案例：
机器人路线寻优



三.经典降维方法与案例实践

流形



三.经典降维方法与案例实践

等距特征映射 (Isomap)

MDS


Isomap

给定: m 个 p 维的样本点 $\{x_i\}$

$D: m \times m$


$$B: \mathbf{b}_{ij} = -\frac{1}{2}(D_{ij}^2 - D_{i.}^2 - D_{.j}^2 + D_{..}^2)$$

对 B 做特征值分解, $B = V\Lambda V^T$




三.经典降维方法与案例实践


等距特征映射 (Isomap)




(a) The “Swiss roll” data set




(b) ISOMAP with $k = 8$




(c) ISOMAP with $k = 40$




(d) ISOMAP with $k = 100$




(e) The toroidal helix data set



(f) ISOMAP with $k = 8$



(g) ISOMAP with $k = 40$



(h) ISOMAP with $k = 100$

Figure 1: ISOMAP examples with different k values. The first and second rows of figures correspond to the “Swiss roll” and the toroidal data sets, respectively.


三.经典降维方法与案例实践

等距特征映射 (Isomap)


698张64x64 (4096维) 的人脸:

主观判断, 影响人脸的因素有三个:

- 光照方向
- 是否上下抬头
- 是否左右偏头



二.降维方法的发展图谱



三.经典降维方法与案例实践

t分布邻域嵌入算法(t-SNE)

Journal of Machine Learning Research 9 (2008) 2579-2605

Submitted 5/08; Revised 9/08; Published 11/08

Visualizing Data using t-SNE

Laurens van der Maaten

TiCC

Tilburg University

P.O. Box 90153, 5000 LE Tilburg, The Netherlands

LVDMAATEN@GMAIL.COM

Geoffrey Hinton

Department of Computer Science

University of Toronto

6 King's College Road, M5S 3G4 Toronto, ON, Canada

Editor: Yoshua Bengio



三.经典降维方法与案例实践

t分布邻域嵌入算法(t-SNE)

高维空间中样本间的结构要在低维空间保持



只保持**局部邻域结构**就可以了

在高维空间中，用**高斯分布**
刻画相似关系

在低维空间中，用**t分布**
刻画相似关系

损失函数：要求两个**分布一致**

t分布邻域嵌入算法(t-SNE)

点与点间的距离
(相似度)

条件概率

高维空间:

$$\|x_i - x_j\|^2$$

$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma^2)}$$

高斯分布

低维空间:

$$\|y_i - y_j\|^2$$



$$q_{j|i} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq i} (1 + \|y_i - y_k\|^2)^{-1}}$$

t分布

$$KL(P||Q) = \sum_i \sum_j p_{ij} \log \frac{p_{ij}}{q_{ij}}$$

三.经典降维方法与案例实践

t分布邻域嵌入算法(t-SNE)



三.经典降维方法与案例实践



t分布邻域嵌入算法(t-SNE)

SNE

将低维空间中的
高斯分布换成t分布

t-SNE

拥挤问题



三.经典降维方法与案例实践

t分布邻域嵌入算法(t-SNE)

高维空间中样本间的结构要在低维空间保持

只保持**局部邻域结构**就可以了

$$p_{j|i} = \frac{\exp(-||x_i - x_j||^2 / 2\sigma^2)}{\sum_{k \neq i} \exp(-||x_i - x_k||^2 / 2\sigma^2)}$$

在高维空间中，用**高斯分布**
刻画相似关系

$$q_{j|i} = \frac{(1 + ||y_i - y_j||^2)^{-1}}{\sum_{k \neq i} (1 + ||y_i - y_k||^2)^{-1}}$$


在低维空间中，用**t分布**
刻画相似关系

$$KL(P||Q) = \sum_i \sum_j p_{ij} \log \frac{p_{ij}}{q_{ij}}$$

损失函数：要求两个**分布一致**

t分布邻域嵌入算法(t-SNE)

$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma^2)}$$




三.经典降维方法与案例实践


A selection from the 64-dimensional digits dataset




Principal Components projection of the digits (time 0.03s)




MDS embedding of the digits (time 3.64s)




Isomap projection of the digits (time 1.44s)



Linear Discriminant projection of the digits (time 0.01s)




t-SNE embedding of the digits (time 15.92s)



http://scikit-learn.org/stable/auto_examples/manifold/plot_lle_digits.html

三.经典降维方法与案例实践

t分布邻域嵌入算法(t-SNE)



三.经典降维方法与案例实践

t分布邻域嵌入算法(t-SNE)

高维空间中样本间的结构要在低维空间保持

只保持**局部邻域结构**就可以了

在高维空间中，用**高斯分布**
刻画相似关系

在低维空间中，用**t分布**
刻画相似关系


损失函数：要求两个**分布一致**

主要做可视化
(全局信息破坏)

对参数敏感

计算复杂度高

二.降维方法的发展图谱




三.经典降维方法与案例实践

UMAP

全称: Uniform Manifold Approximation and Projection

核心思想: 流形假设 $\rightarrow$ 局部邻域建模 $\rightarrow$ 低维拓扑保持



三.经典降维方法与案例实践

UMAP

核心思想：流形假设 → **局部邻域建模** → 低维拓扑保持

找邻居

计算边权

拼成整张图






$$\mathcal{N}_k(x_i) = \{x_{i1}, x_{i2}, \dots, x_{ik}\}$$

$$\rho_i = \min\{d(x_i, x_{ij}) \mid 1 \leq j \leq k, d(x_i, x_{ij}) > 0\}$$

$$v_{j|i} = \exp\left(-\frac{\max(0, d(x_i, x_j) - \rho_i)}{\sigma_i}\right)$$

$$v_{ij} = v_{j|i} + v_{i|j} - v_{j|i}v_{i|j}$$

3-nearest neighbors



三.经典降维方法与案例实践

UMAP

核心思想：流形假设 → 局部邻域建模 → **低维拓扑保持**

找低维点



计算边权

拓扑保持

$$y_i \in \mathbb{R}^m$$

$$w_{ij} = \frac{1}{1 + a\|y_i - y_j\|^{2b}}$$

$$\mathcal{L} = \sum_{i \neq j} \left[v_{ij} \log \frac{v_{ij}}{w_{ij}} + (1 - v_{ij}) \log \frac{1 - v_{ij}}{1 - w_{ij}} \right]$$



$$\begin{bmatrix} 0 & 0.2 & 0 & 0 & 0.8 \\ 0.2 & 0 & 0.5 & 0 & 0 \\ 0 & 0.5 & 0 & 0.7 & 0 \\ 0 & 0 & 0.7 & 0 & 0.6 \\ 0.8 & 0 & 0 & 0.6 & 0 \end{bmatrix}$$


$$\begin{bmatrix} 0 & 0.3 & 0.4 & 0 & 0 \\ 0.3 & 0 & 0.2 & 0.5 & 0 \\ 0.4 & 0.2 & 0 & 0 & 0.9 \\ 0 & 0.5 & 0 & 0 & 0.1 \\ 0 & 0 & 0.9 & 0.1 & 0 \end{bmatrix}$$

三.经典降维方法与案例实践


UMAP

核心思想：流形假设 $\rightarrow$ 局部邻域建模 $\rightarrow$ **低维拓扑保持**


[UMAP Playground](#)



三.经典降维方法与案例实践



二.降维方法的发展图谱





大纲

01 什么是降维

02 降维方法的发展图谱

03 经典降维方法与案例实践

04 从经典方法到前沿方法

四.从经典方法到前沿方法


可视化、数据结构探索分析



可视化、下游任务驱动

四.从经典方法到前沿方法

神经网络降维中间过程的可视化



谢谢



首都师范大学

CAPITAL NORMAL UNIVERSITY