上一课总结

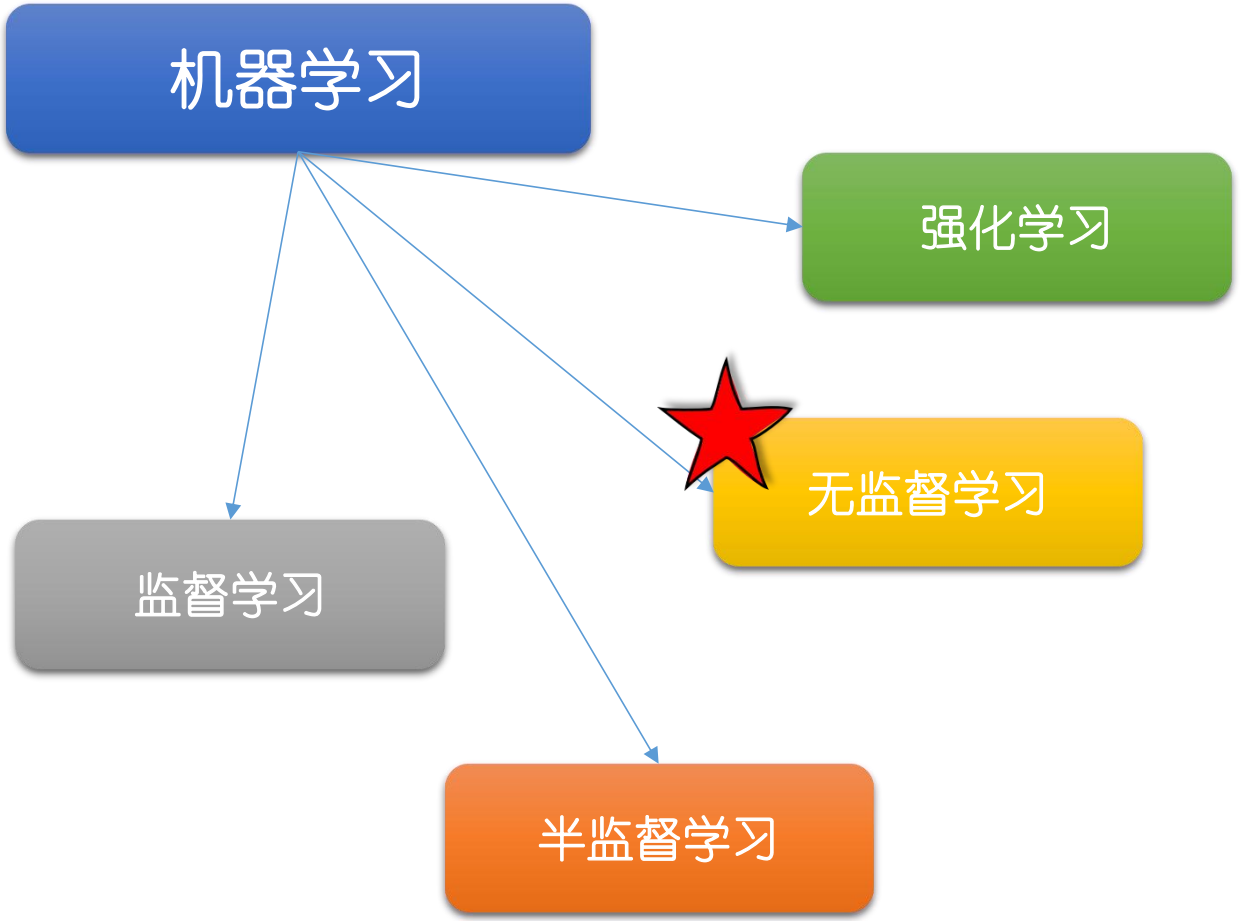
一．什么是机器学习?

二．机器学习发展史

三．机器学习包含什么?

四．机器学习通用流程

五．基础概念介绍

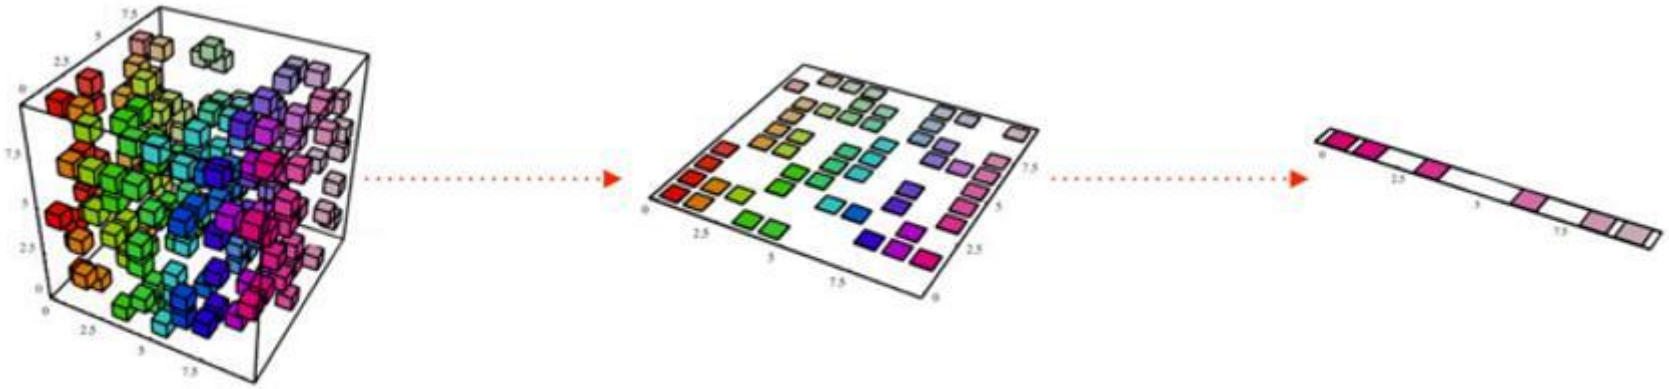


无监督学习

数据（无标签）： $(x_i)_{i=1}^{l}$

目标： 挖掘数据的内在结构和规律

- **聚类：** 对数据分组
- **降维：** 把数据投影到低维空间



首都师范大学
CAPITAL NORMAL UNIVERSITY



第三课　降维

授课教师：潘贤丽

大纲

01 什么是降维

02 降维方法的发展图谱

03 经典降维方法与案例实践

04 从经典方法到前沿方法

一.什么是降维



表格



文本



图片



声音信号

降维：用更少的变量表示原始数据，同时尽量保留对分析、理解和建模重要的信息

一种更数学的说法：找一映射函数$f: \boldsymbol{x} \in \mathbb{R}^p \longrightarrow \boldsymbol{z} \in \mathbb{R}^d$, $\boldsymbol{d < p}$

$$z = f(x)$$

一.什么是降维



01 降低存储与计算开销

02 便于可视化和理解数据结构

03 维数灾难

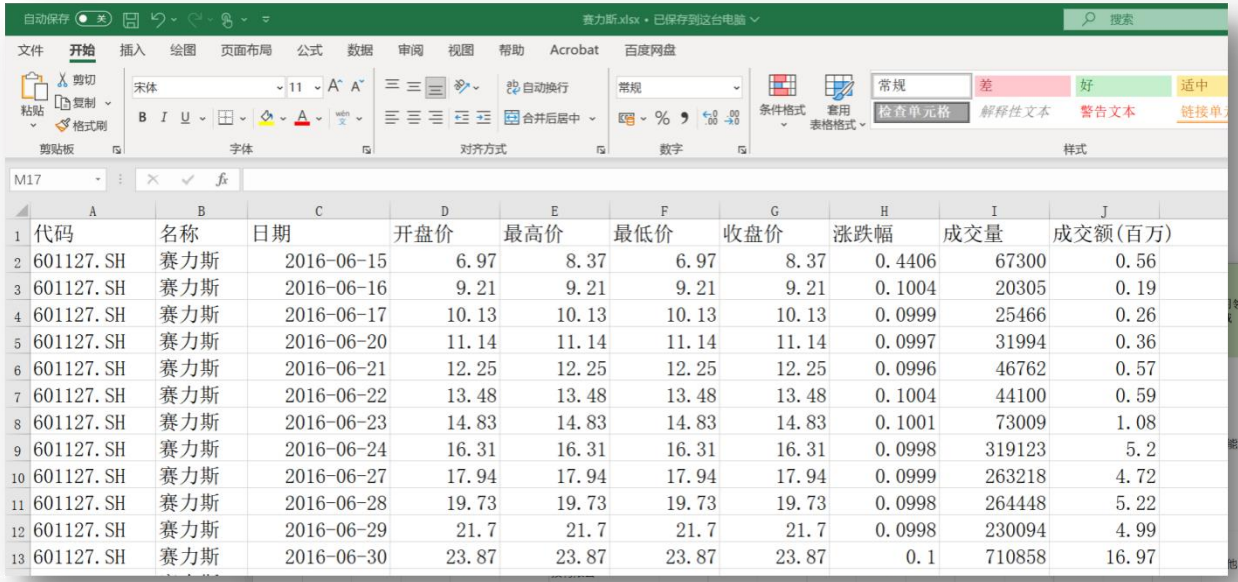
04 去除冗余与噪声,提升后续建模效果

一.什么是降维

首都师范大学 CAPITAL NORMAL UNIVERSITY

便于可视化和理解数据结构

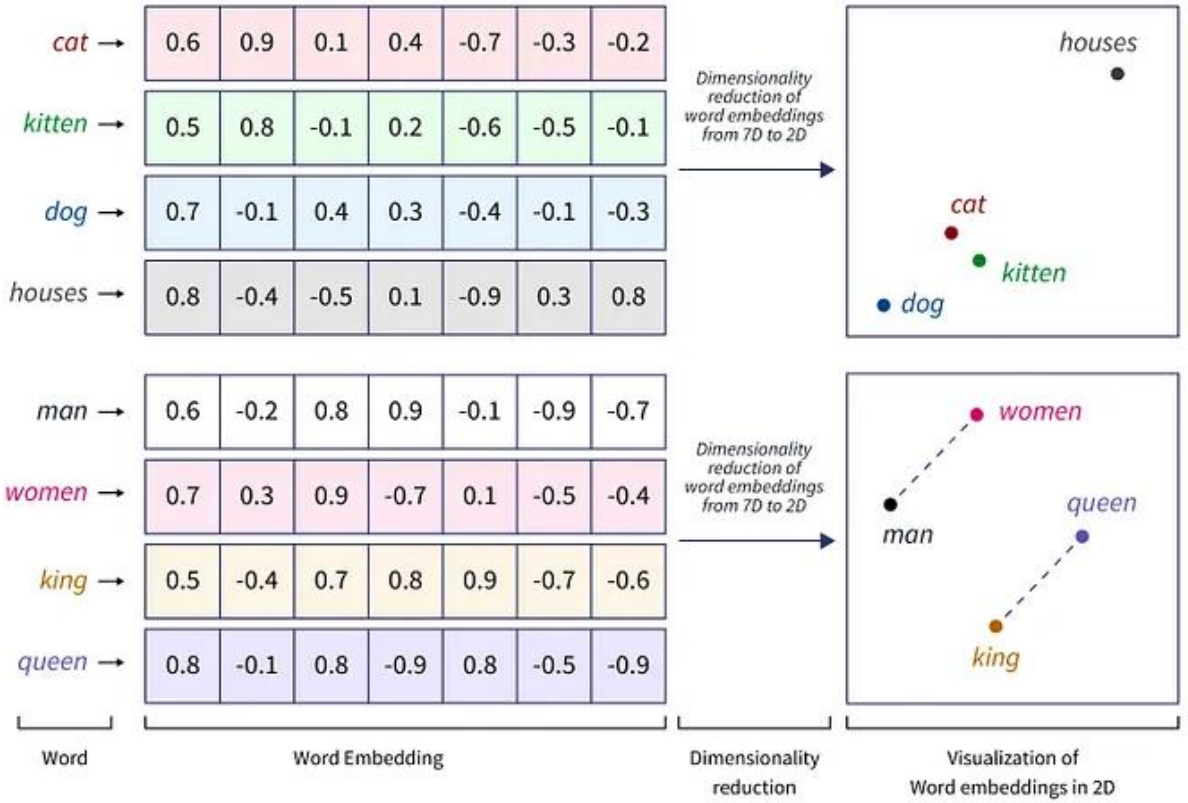


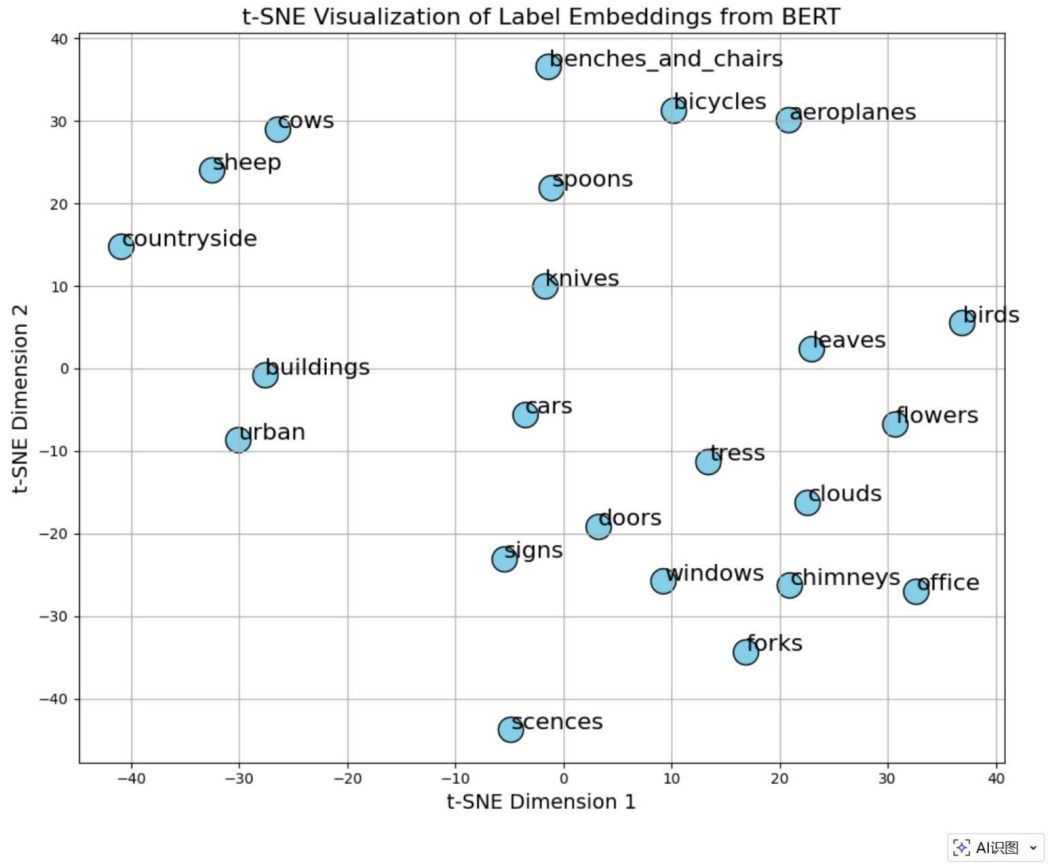


代码	名称	日期	开盘价	最高价	最低价	收盘价	涨跌幅	成交量	成交额(百万)
601127.SH	赛力斯	2016-06-15	6.97	8.37	6.97	8.37	0.4406	67300	0.56
601127.SH	赛力斯	2016-06-16	9.21	9.21	9.21	9.21	0.1004	20305	0.19
601127.SH	赛力斯	2016-06-17	10.13	10.13	10.13	10.13	0.0999	25466	0.26
601127.SH	赛力斯	2016-06-20	11.14	11.14	11.14	11.14	0.0997	31994	0.36
601127.SH	赛力斯	2016-06-21	12.25	12.25	12.25	12.25	0.0996	46762	0.57
601127.SH	赛力斯	2016-06-22	13.48	13.48	13.48	13.48	0.1004	44100	0.59
601127.SH	赛力斯	2016-06-23	14.83	14.83	14.83	14.83	0.1001	73009	1.08
601127.SH	赛力斯	2016-06-24	16.31	16.31	16.31	16.31	0.0998	319123	5.2
601127.SH	赛力斯	2016-06-27	17.94	17.94	17.94	17.94	0.0999	263218	4.72
601127.SH	赛力斯	2016-06-28	19.73	19.73	19.73	19.73	0.0998	264448	5.22
601127.SH	赛力斯	2016-06-29	21.7	21.7	21.7	21.7	0.0998	230094	4.99
601127.SH	赛力斯	2016-06-30	23.87	23.87	23.87	23.87	0.1	710858	16.97

一.什么是降维

便于可视化和理解数据结构

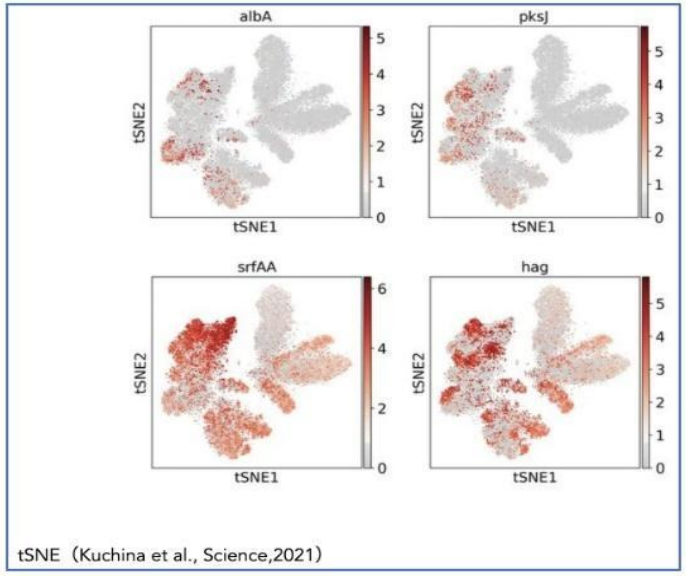




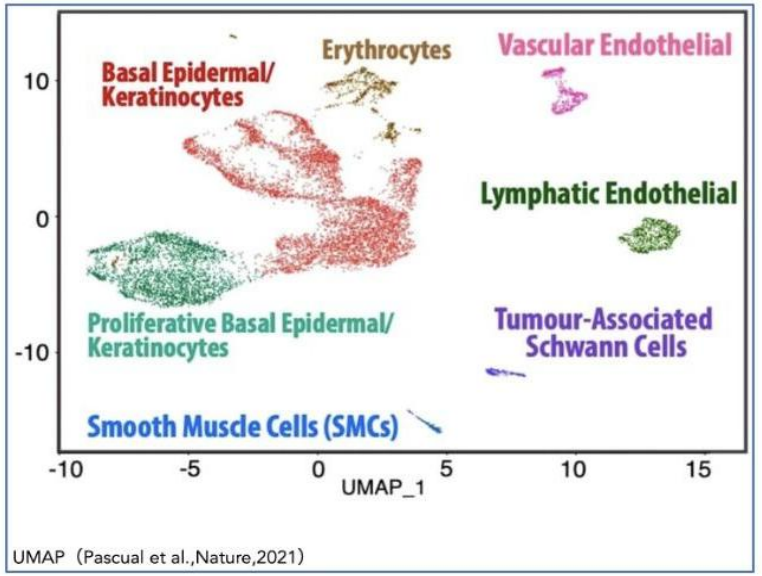
(a) 标签嵌入的 t-SNE 可视化结果

一.什么是降维

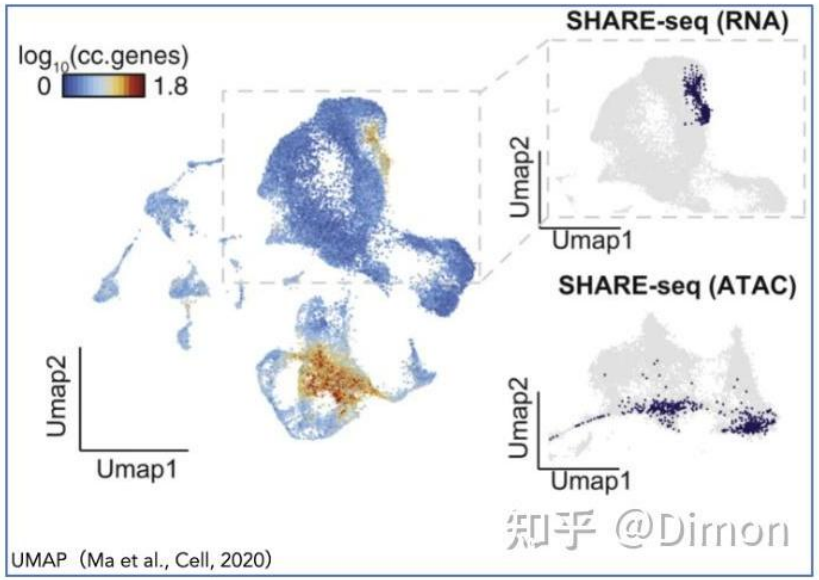
便于可视化和理解数据结构



tSNE（Kuchina et al., Science,2021）



UMAP（Pascual et al.,Nature,2021）



UMAP（Ma et al., Cell, 2020）

知乎 @Dimon

一.什么是降维



01 降低存储与计算开销

02 便于可视化和理解数据结构

03 维数灾难

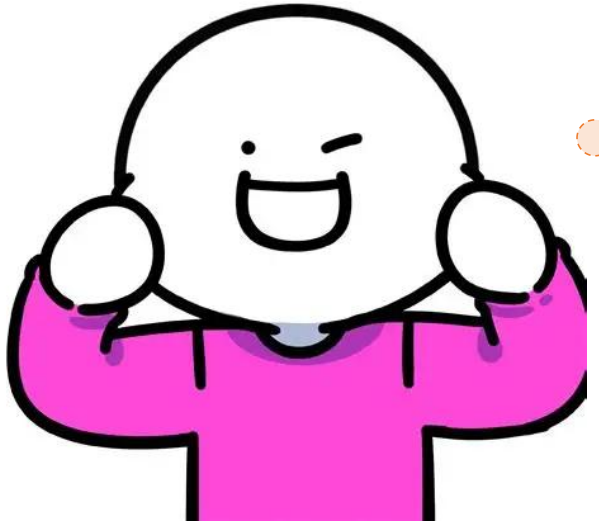
04 去除冗余与噪声,提升后续建模效果

一.什么是降维

维数灾难

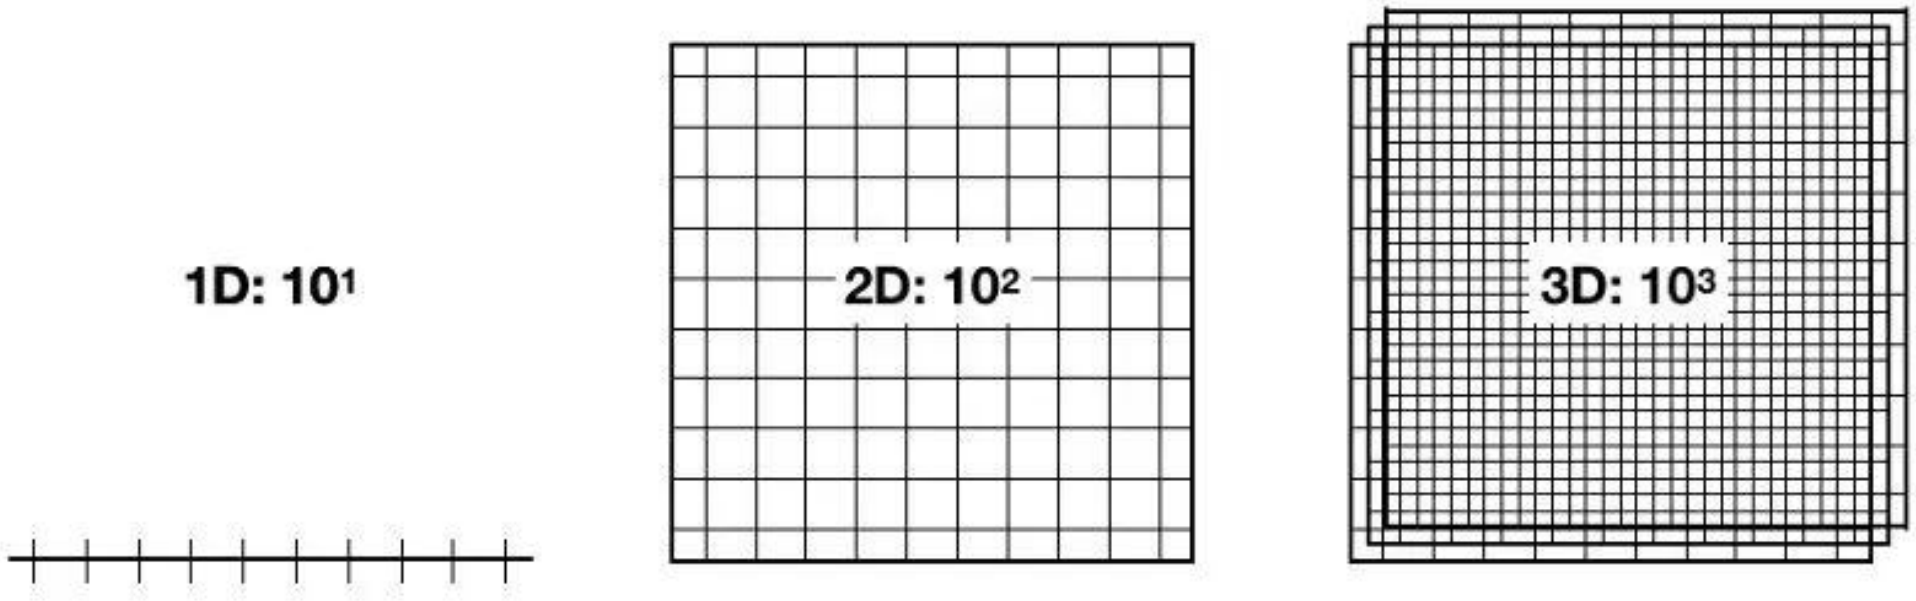
维数灾难(Curse of Dimensionality)：

是指随着维度升高，高维空间中会出现一系列反常现象，使得数据分析、统计估计和机器学习都变得更加困难。



一.什么是降维

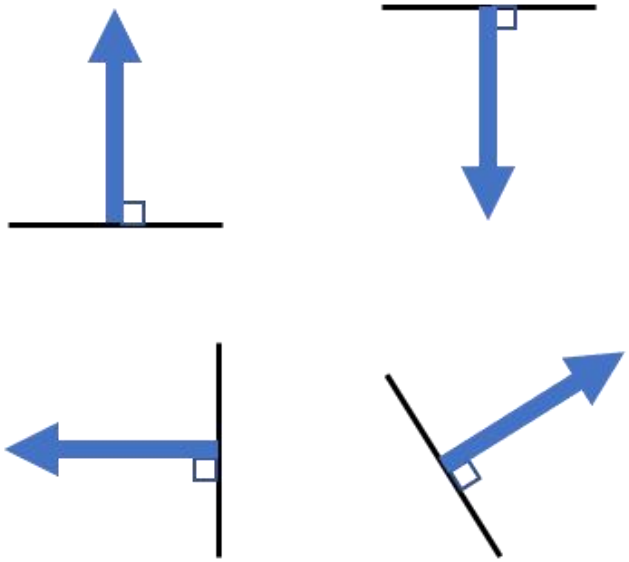
维数灾难

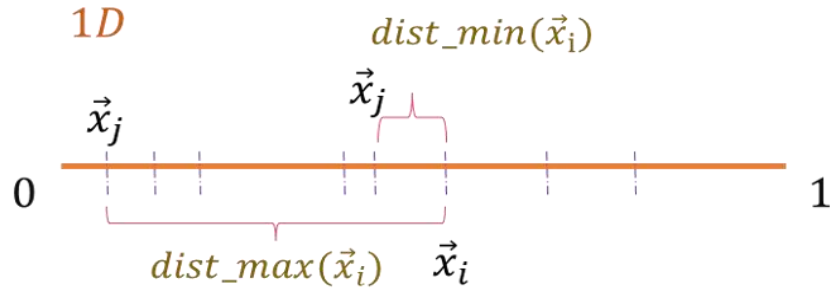


所需样本量指数级增长

一.什么是降维

维数灾难



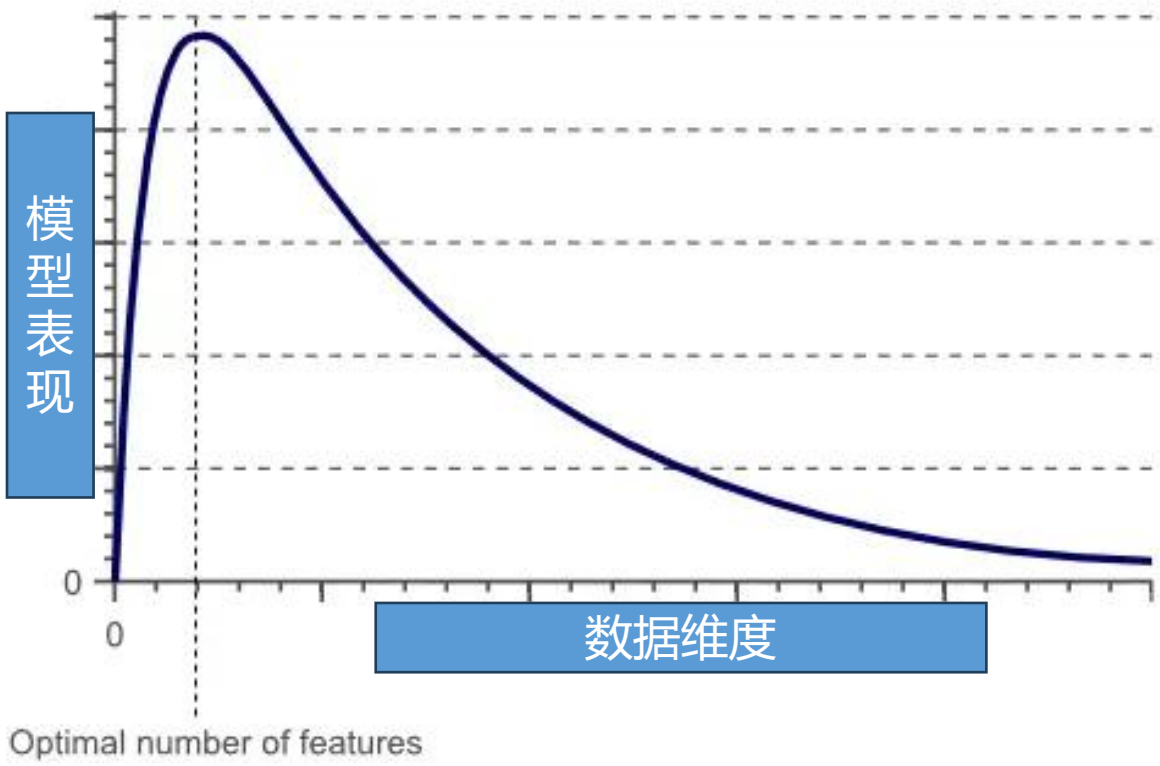


$$\lim_{d\to\infty} \frac{dist_max(\vec{x}_i) - dist_min(\vec{x}_i)}{dist_min(\vec{x}_i)} \approx 0$$

距离/几何直觉失效

一.什么是降维

维数灾难



一.什么是降维

降维：用更少的变量表示原始数据，同时尽量保留对分析、理解和建模重要的信息



01 降低存储与计算开销

02 便于可视化和理解数据结构

03 维数灾难

04 去除冗余与噪声,提升后续建模效果

算得快、看得清、学得动、效果好

大纲

01 什么是降维

02 降维方法的发展图谱

03 经典降维方法与案例实践

04 从经典方法到前沿方法

二.降维方法的发展图谱

特征选择

- **过滤式**（快,和模型无关）

代表:方差阈值、卡方、互信息

- **包裹式**（用模型效果选特征）

代表:前向选择、后向消除、RFE

- **嵌入式**（训练过程中自动选择）

代表:Lasso、随机森林、GBDT

这次课要讲的内容

特征提取

二.降维方法的发展图谱

降维：用更少的变量表示原始数据，同时尽量保留对分析、理解和建模重要的信息

保全局线性信息

PCA（1901）

MDS（1964）
Isomap（2000）

保样本间几何关系

保局部邻域结构

LLE（2000）
t-SNE（2008）
UMAP（2018）

Autoencoder（1986）
VAE（2013）

让模型自己学习低维表示

大纲

首都师范大学 CAPITAL NORMAL UNIVERSITY

01 什么是降维

02 降维方法的发展图谱

03 经典降维方法与案例实践

04 从经典方法到前沿方法

二.降维方法的发展图谱


保全局线性信息
PCA（1901）
MDS（1964）
Isomap（2000）
保样本间几何关系
保局部邻域结构
LLE（2000）
t-SNE（2008）
UMAP（2018）
Autoencoder（1986）
VAE（2013）
让模型自己学习低维表示

三.经典降维方法与案例实践

降维的数学定义：找一映射函数$f: \boldsymbol{x} \in \mathbb{R}^p \longrightarrow \boldsymbol{z} \in \mathbb{R}^d$, $\boldsymbol{d < p}$

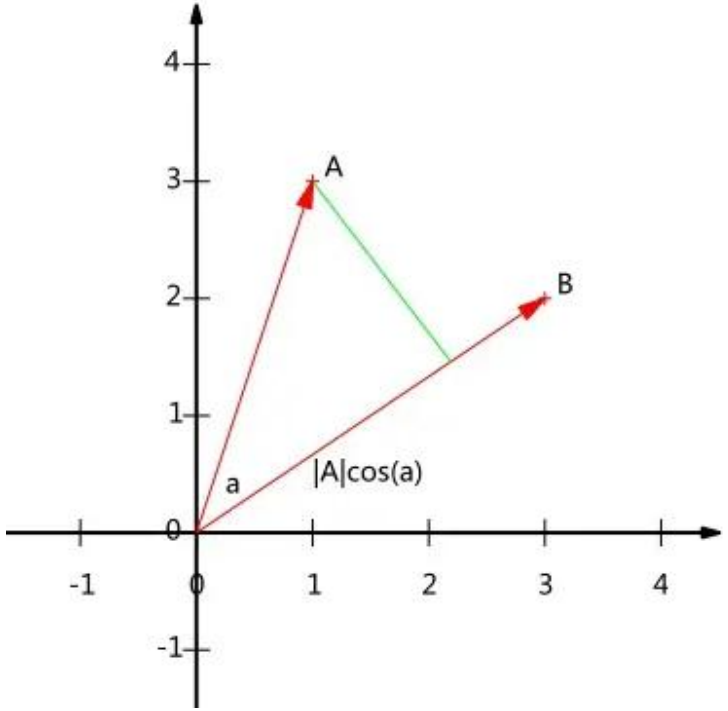
$$z = f(x)$$

线性降维： $z = f(x) = Wx, W \in \mathbb{R}^{d \times p}$

基础知识回顾

向量内积的几何含义是什么?

例: $A=(x_1,y_1),\ B=(x_2,y_2)\ A\cdot B=|A||B|cos(\alpha)$



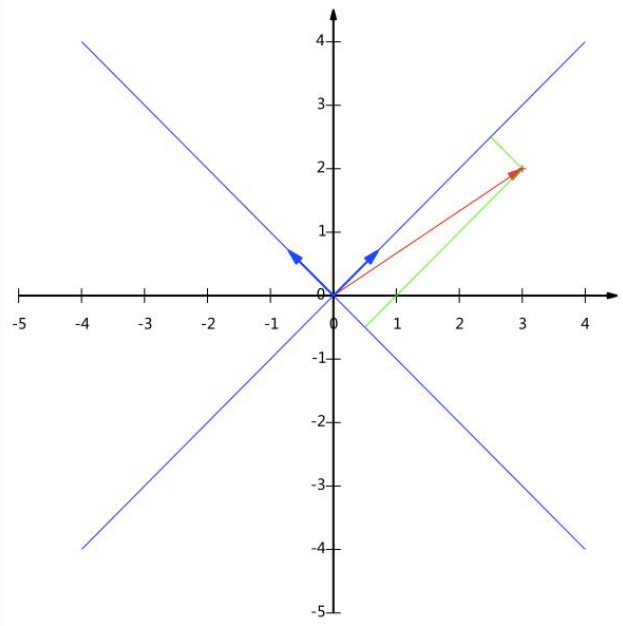
假设：B是单位向量

A 与 B 的内积 = A 向 B 所在直线投影的标量大小

基础知识回顾

向量在某组基下的坐标怎么计算?

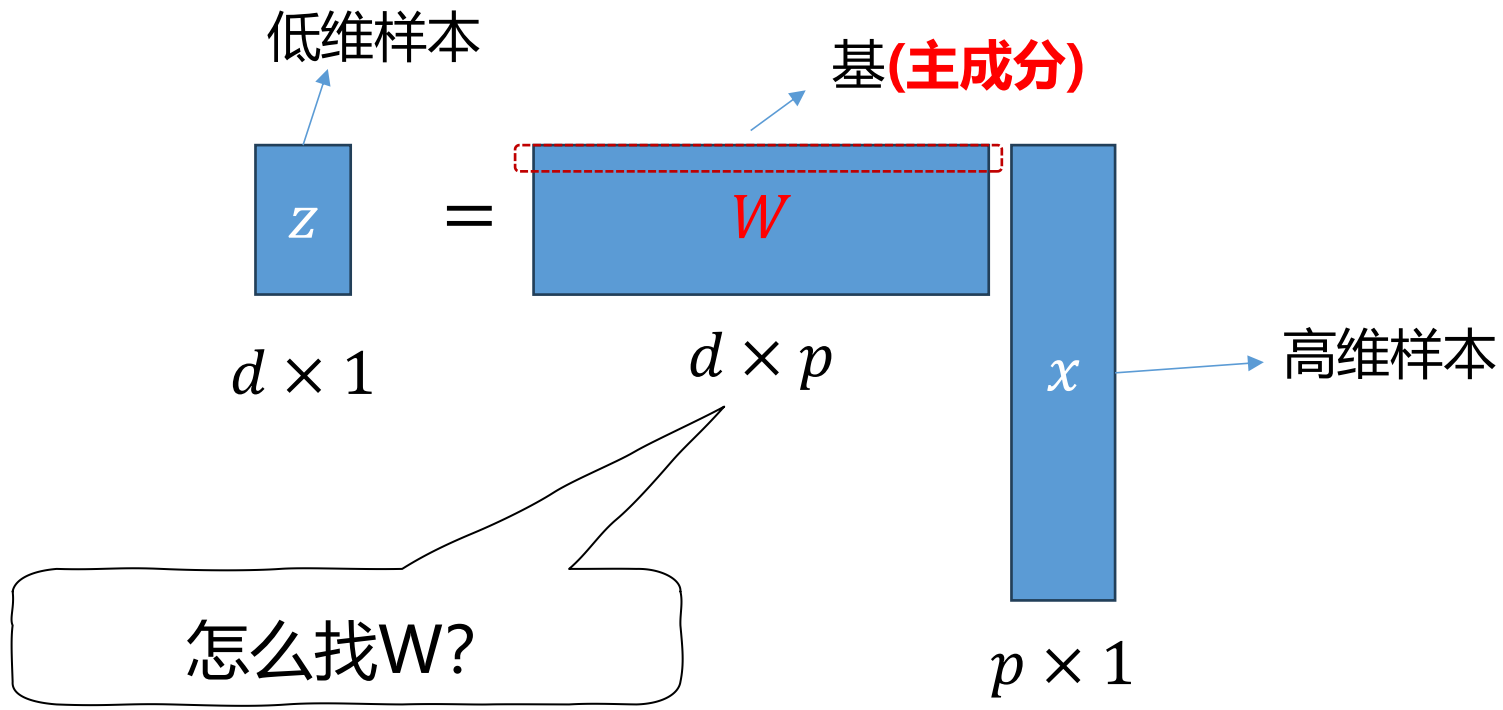
例： 求向量$(3,\ 2)$在$(\frac{1}{\sqrt{2}},\frac{1}{\sqrt{2}})$和$(-\frac{1}{\sqrt{2}},\frac{1}{\sqrt{2}})$这组基下的坐标



$$\begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix} \begin{pmatrix} 3 \\ 2 \end{pmatrix} = \begin{pmatrix} 5/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}$$

主成分分析（PCA）

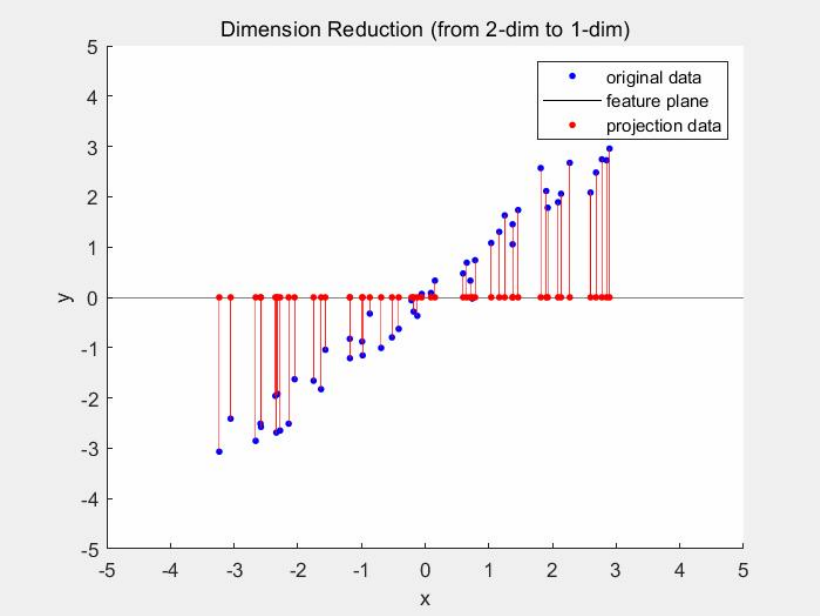
$$z = Wx$$



三.经典降维方法与案例实践

主成分分析（PCA）

中心思想：降维后的数据可以**保留尽可能多的原始数据信息**



最大方差

主成分分析（PCA）

中心思想：降维后的数据可以**保留尽可能多的原始数据信息**

原数据： $\{x_i\},\ i = 1, \ldots, N$

降维方向u_1： $u_1^T u_1 = 1$

降维后数据y_n： $y_n = u_1^T x_n$

最大方差

均值： $\bar{y} = u_1^T \bar{x}, \bar{x} = \frac{1}{N}\sum_n x_n$

方差： $var(y) = \frac{1}{N}\sum_n (u_1^T x_n - u_1^T \bar{x})^2 = u_1^T \boldsymbol{S} u_1$

协方差矩阵： $S = \frac{1}{N}\sum_n (x_n - \bar{x})(x_n - \bar{x})^T$

主成分分析（PCA）

$$\max_{u_1} var(y) = u_1^T S u_1$$
$$s.t.\ \ u_1^T u_1 = 1$$

$$S = \frac{1}{N}\sum_n (x_n - \bar{x})(x_n - \bar{x})^T$$

拉格朗日乘子法

$$L = -u_1^T S u_1 + \lambda_1(u_1^T u_1 - 1)$$

$$S u_1 = \lambda_1 u_1$$

最大特征值对应的特征向量

主成分分析（PCA）

$$\max_{u_2} var(y) = u_2^T S u_2$$
$$s.t.\ \ u_2^T u_2 = 1, u_1^T u_2 = 0$$

$$S = \frac{1}{N}\sum_n (x_n - \bar{x})(x_n - \bar{x})^T$$

拉格朗日乘子法

$$L = -u_2^T S u_2 + \lambda_2(u_2^T u_2 - 1) + \gamma(u_1^T u_2 - 0)$$

$$S u_2 = \lambda_2 u_2$$

第二大特征值对应的特征向量

主成分分析（PCA）

线性降维： $z = Wx, W \in \mathbb{R}^{d \times p}$

$$S = \frac{1}{N}\sum_{n}(x_n - \bar{x})(x_n - \bar{x})^T$$

S的前d个最大特征值对应的特征向量组成的矩阵

主成分分析（PCA）

输入： 样本集$X = [x_1, x_2, ..., x_N] \in R^{p \times N}$；低维空间维数$d$.

过程： 1. 对所有样本**中心化**:$x_i \leftarrow x_i - \frac{1}{N}\sum_n x_i$

2. 计算样本的**协方差矩阵**$S = \frac{1}{N}\sum_n x_n x_n^T$

3. 对协方差矩阵S进行**特征值分解**

4. 取最大的d个特征值所对应的特征向量

$$U = [w_1, w_2, ..., w_d] \in R^{p \times d}$$

输出： 投影后数据

$$Y = U^T X$$

主成分分析（PCA）

累积方差贡献率

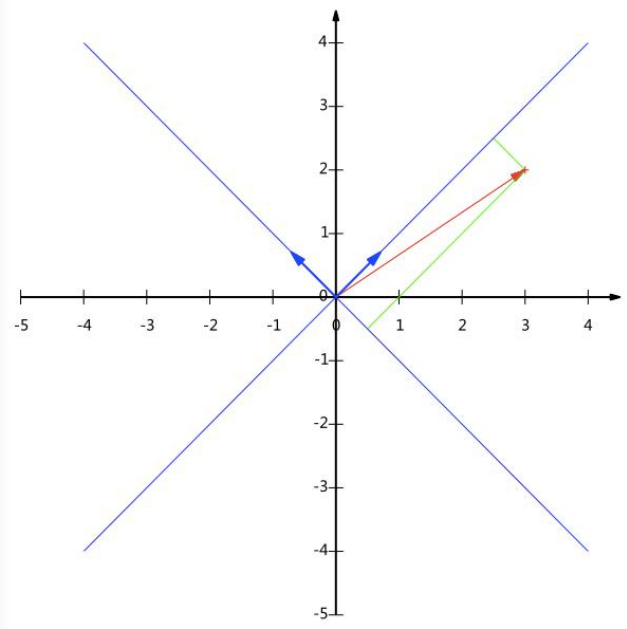
$$Su_1 = \lambda_1 u_1$$

$$\max_{u_1} var(y) = u_1^T S u_1 = \boldsymbol{\lambda_1}$$
$$s.t.\ \ u_1^T u_1 = 1$$

$$r_i = \frac{\lambda_i}{\sum_{j=1}^{p} \lambda_j} \times 100$$

$$\sum_{i=1}^{d} r_i \geq 98$$

主成分分析（PCA）



$$\begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix} \begin{pmatrix} 3 \\ 2 \end{pmatrix} = \begin{pmatrix} 5/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}$$

假设原始数据矩阵中心化后是 X_c，取前 d 个主成分组成矩阵 U_d。

第一步：降维

$$Z = U_d^T X_c$$

第二步：从低维再重构回原空间

$$\hat{X}_c = U_d Z = U_d U_d^T X_c$$

如果要回到原始坐标系，再加回均值：

$$\hat{X} = \hat{X}_c + \mu$$

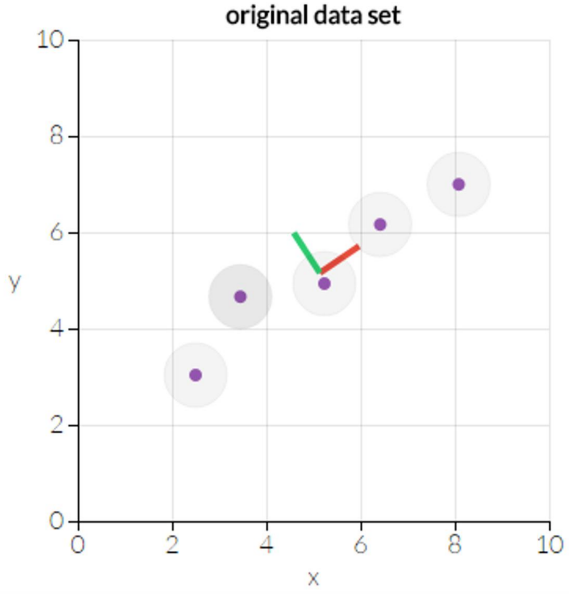
第三步：看重构误差

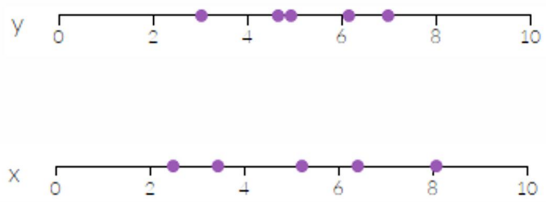
最常见就是均方误差：

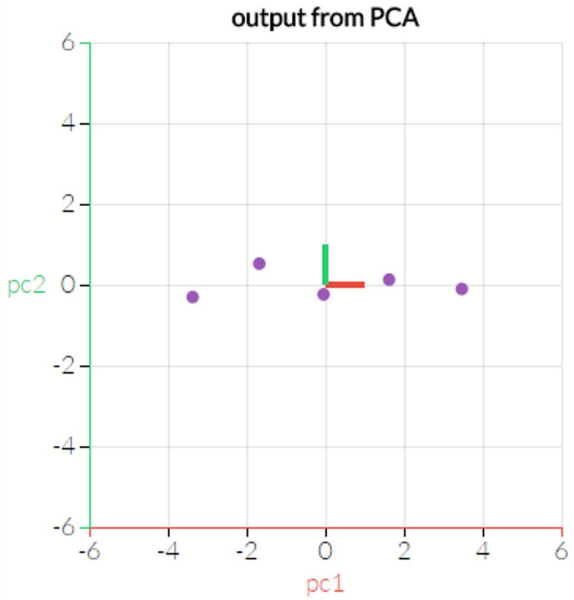
$$\text{Reconstruction Error} = \frac{1}{N} \sum_{i=1}^{N} \|x_i - \hat{x}_i\|^2$$

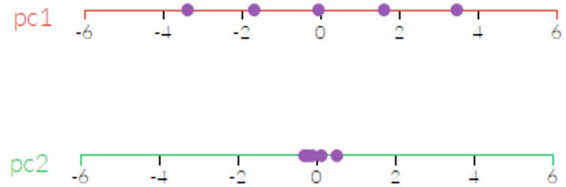
三.经典降维方法与案例实践

主成分分析（PCA）









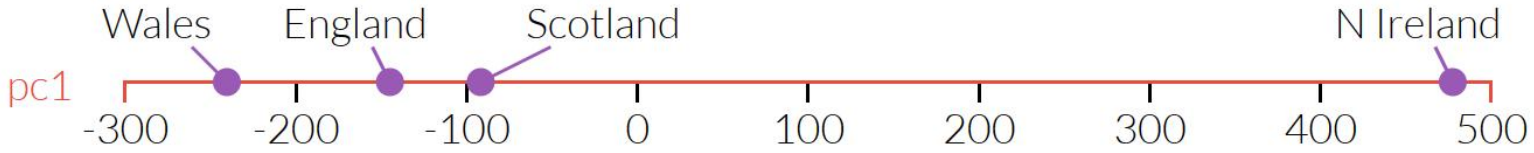
三.经典降维方法与案例实践

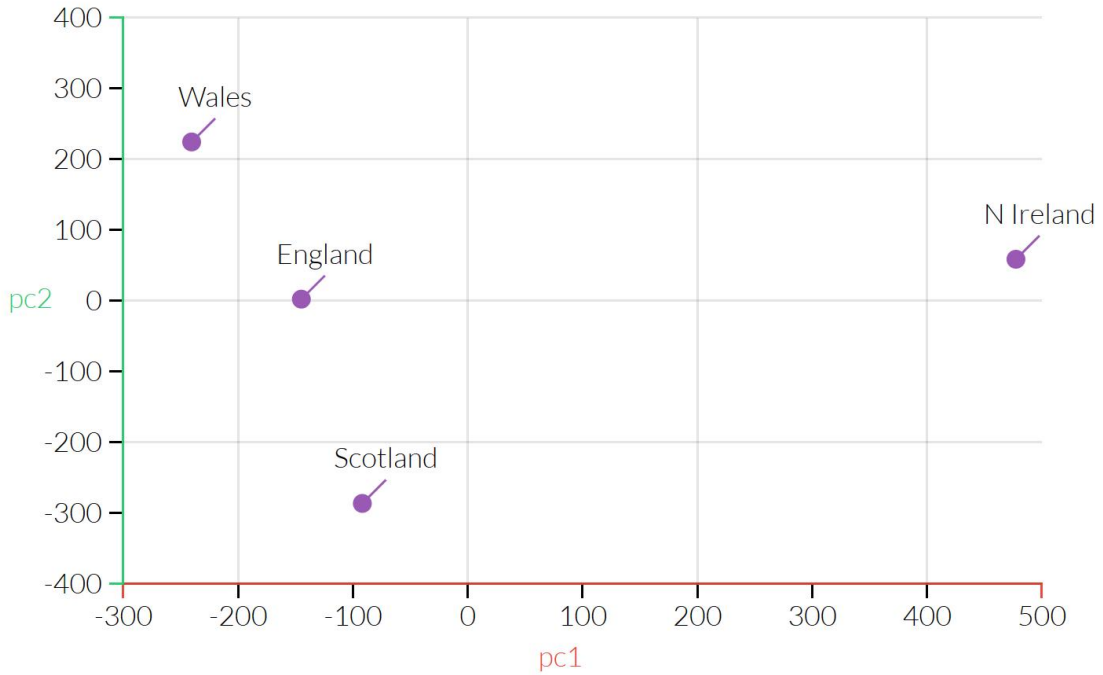
主成分分析（PCA）



	England	N Ireland	Scotland	Wales
Alcoholic drinks	375	135	458	475
Beverages	57	47	53	73
Carcase meat	245	267	242	227
Cereals	1472	1494	1462	1582
Cheese	105	66	103	103
Confectionery	54	41	62	64
Fats and oils	193	209	184	235
Fish	147	93	122	160
Fresh fruit	1102	674	957	1137
Fresh potatoes	720	1033	566	874
Fresh Veg	253	143	171	265
Other meat	685	586	750	803
Other Veg	488	355	418	570
Processed potatoes	198	187	220	203
Processed Veg	360	334	337	365
Soft drinks	1374	1506	1572	1256
Sugars	156	139	147	175

三.经典降维方法与案例实践





https://setosa.io/ev/principal-component-analysis/

三.经典降维方法与案例实践

主成分分析（PCA）

Eigenfaces for Recognition

Matthew Turk and Alex Pentland
Vision and Modeling Group
The Media Laboratory
Massachusetts Institute of Technology



论文：Eigenfaces for Recognition (mitpressjournals.org)

三.经典降维方法与案例实践

主成分分析（PCA）



Figure 1. (b) The average face Ψ.

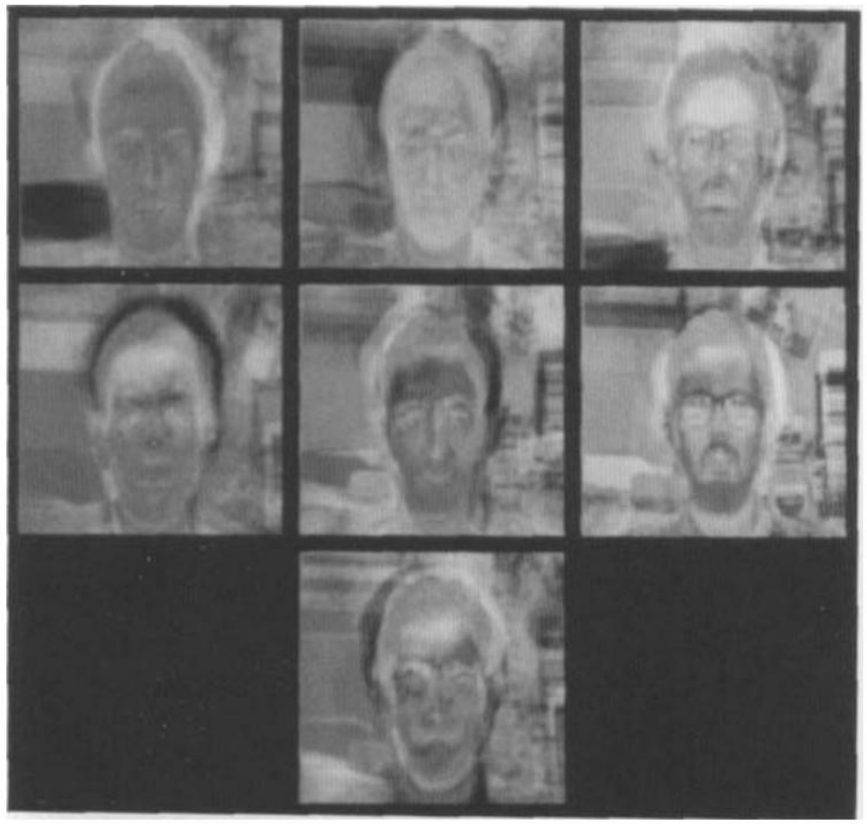


Figure 2. Seven of the eigenfaces calculated from the input images of Figure 1.

三.经典降维方法与案例实践

主成分分析（PCA）



Figure 3. An original face image and its projection onto the face space defined by the eigenfaces of Figure 2.

三.经典降维方法与案例实践

主成分分析（PCA）

1.核主成分分析（Kernel PCA）：通过使用核技巧将数据映射到高维特征空间，核主成分分析可以捕捉到数据在原始空间中的非线性结构。

2.稀疏主成分分析（Sparse PCA）：通过在PCA的基础上增加稀疏性约束，稀疏主成分分析旨在产生易于解释的主成分。

3.增量主成分分析（Incremental PCA）：针对大数据集或在线实时数据分析设计的。

4.鲁棒主成分分析（Robust PCA）：旨在对异常值和噪声具有鲁棒性的PCA变体。

5.功能主成分分析（Functional PCA, FPCA）：用于分析时间序列数据或其他形式的函数数据。

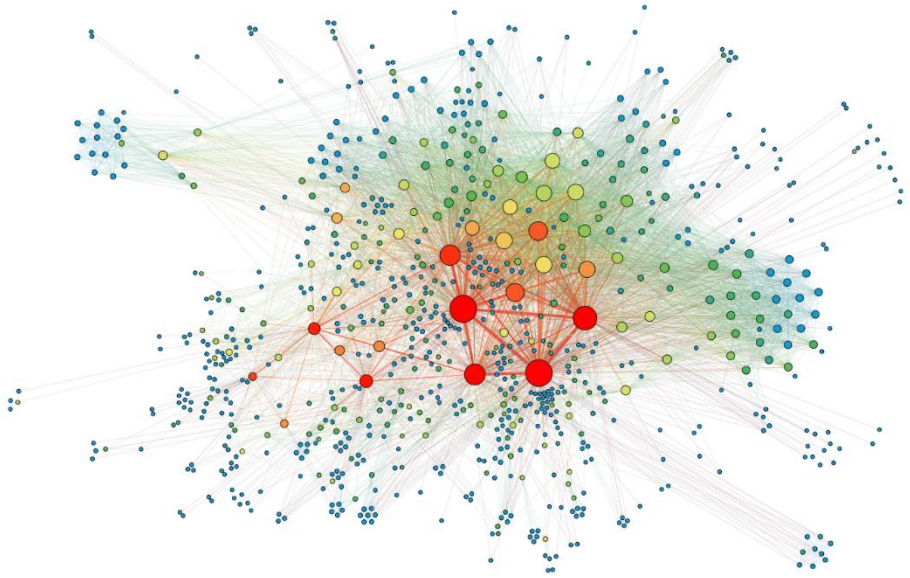
6.概率主成分分析（Probabilistic PCA）：是PCA的概率形式，通过假设数据是从某个潜在的低维高斯分布生成的，它提供了一种评估数据生成模型的方法。

.....

二.降维方法的发展图谱


保全局线性信息
PCA（1901）
MDS（1964）
Isomap（2000）
保样本间几何关系
保局部邻域结构
LLE（2000）
t-SNE（2008）
UMAP（2018）
Autoencoder（1986）
VAE（2013）
让模型自己学习低维表示

多维尺度缩放（MDS）



数据结构怎么刻画？

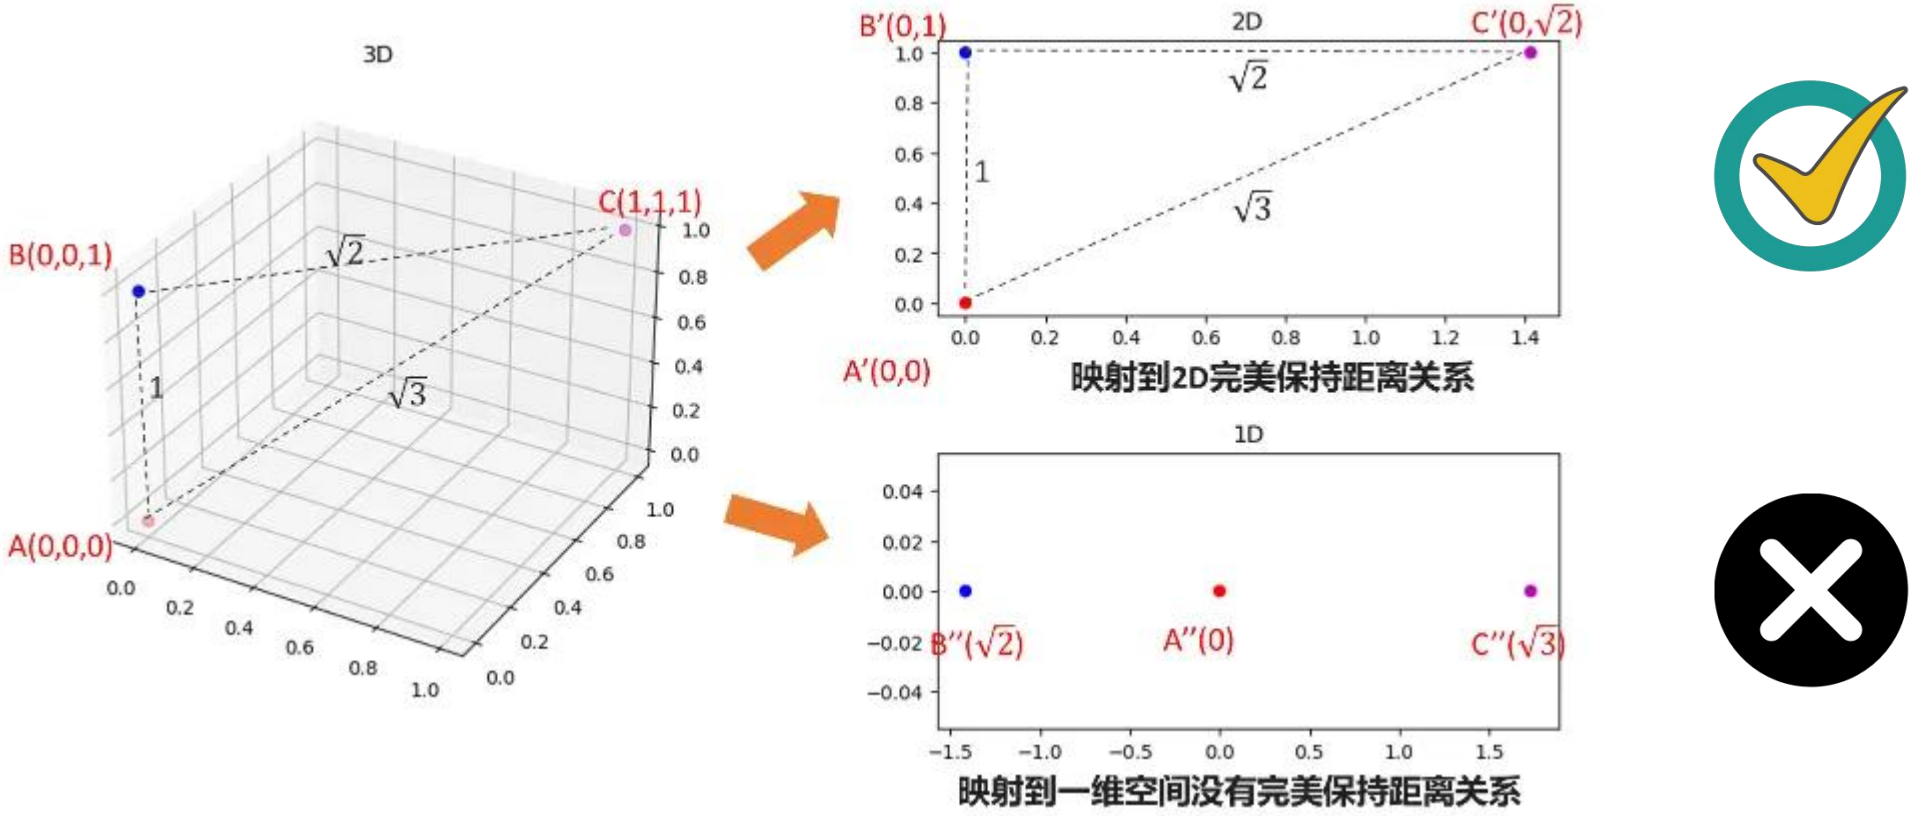
距离矩阵

D: $m \times m$

中心思想： 降维前后，距离矩阵应尽可能保持不变

三.经典降维方法与案例实践

多维尺度缩放（MDS）

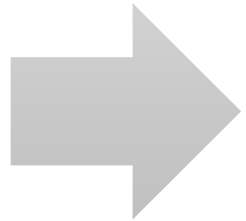


多维尺度缩放（MDS）

给定： m个p维的样本点$\{x_i\}$

想要： m个d维的样本点$\{z_i\}$

D: $m \times m$



$$D_{ij} = ||z_i - z_j||_2$$

根据上面的距离等式，求出z_i

多维尺度缩放（MDS）

$\boldsymbol{Z}$：降维后样本矩阵（$d * \mathrm{m}$）

$\boldsymbol{B} = Z^T Z$，$b_{ij} = z_i^T z_j$

中心化：$\sum_{i=1}^{m} \boldsymbol{z_i} = 0$，有$\sum_{i=1}^{m} b_{ij} = \sum_{j=1}^{m} b_{ij} = 0$

$$D_{ij}^2 = \|z_i\|^2 + \left\|z_j\right\|^2 - 2z_i^T z_j$$
$$= b_{ii} + b_{jj} - 2b_{ij}$$

$$\boldsymbol{b_{ij}} = -\frac{1}{2}\left(D_{ij}^2 - D_{i\cdot}^2 - D_{\cdot j}^2 + D_{\cdot\cdot}^2\right)$$

$$D_{i\cdot}^2 = \frac{1}{m}\sum_{j=1}^{m} D_{ij}^2 = \frac{1}{m}\left[\mathrm{tr}(B) + mb_{ii}\right]$$

$$D_{\cdot j}^2 = \frac{1}{m}\sum_{i=1}^{m} D_{ij}^2 = \frac{1}{m}\left[\mathrm{tr}(B) + mb_{jj}\right]$$

$$D_{\cdot\cdot}^2 = \frac{1}{m^2}\sum_{i=1}^{m}\sum_{j=1}^{m} D_{ij}^2 = \frac{2}{m}\mathrm{tr}(B)$$

多维尺度缩放（MDS）

给定： m个p维的样本点$\{x_i\}$

想要： m个d维的样本点$\{z_i\}$

D: $m \times m$

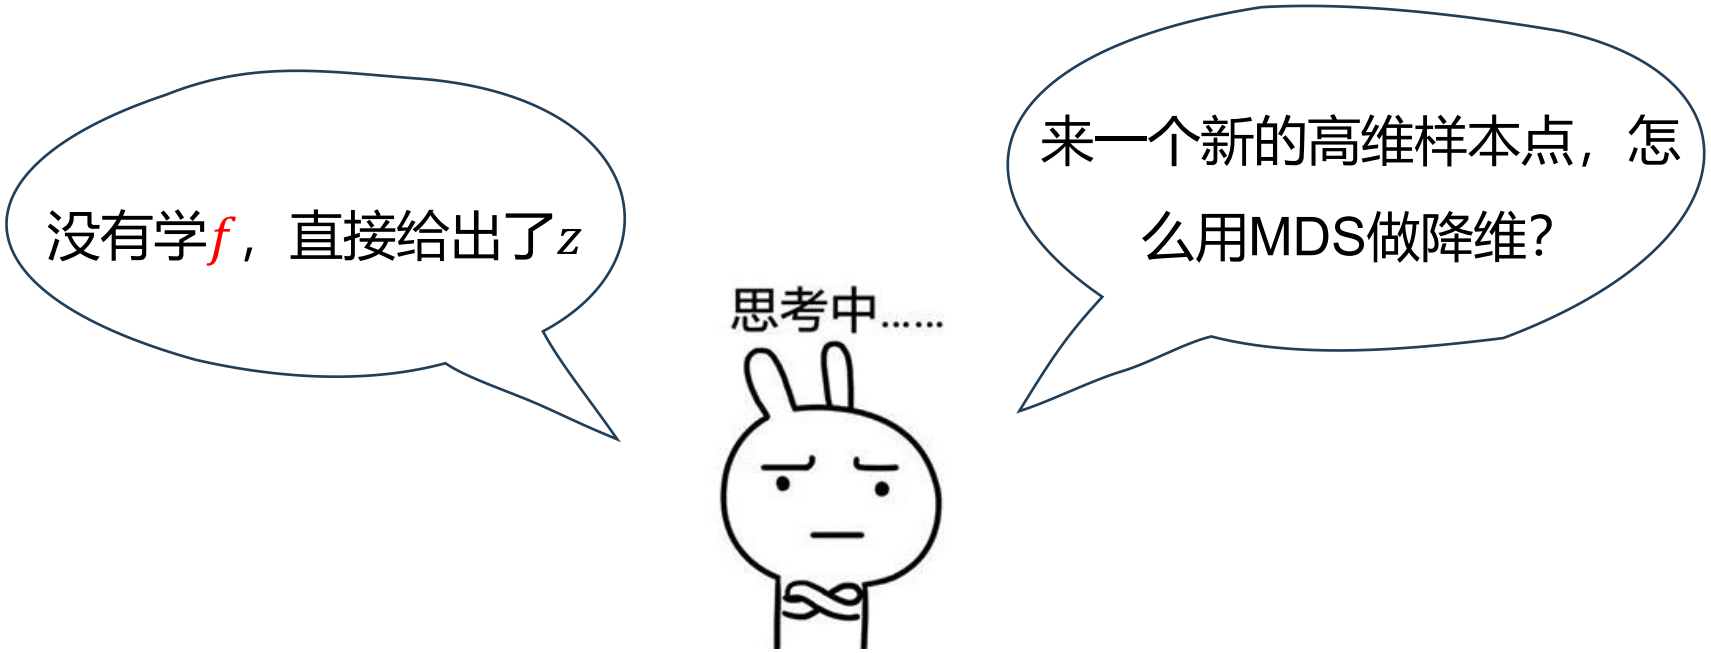
$$D_{ij} = ||z_i - z_j||_2$$

- $\boldsymbol{B} = Z^T Z$
- 对**B**做特征值分解，$B = V\Lambda V^T$
- 取**Λ**为前d个最大特征值构成的对角阵，**V**为对应特征向量矩阵，最后输出矩阵$\mathbf{Z}^T = \mathbf{V}\boldsymbol{\Lambda}^{\mathbf{1/2}} \in R^{m \times d}$

多维尺度缩放（MDS）

降维的定义：找一映射函数$\boldsymbol{f}: \boldsymbol{x} \in \mathbb{R}^p \longrightarrow \boldsymbol{z} \in \mathbb{R}^d, \boldsymbol{d < p}$

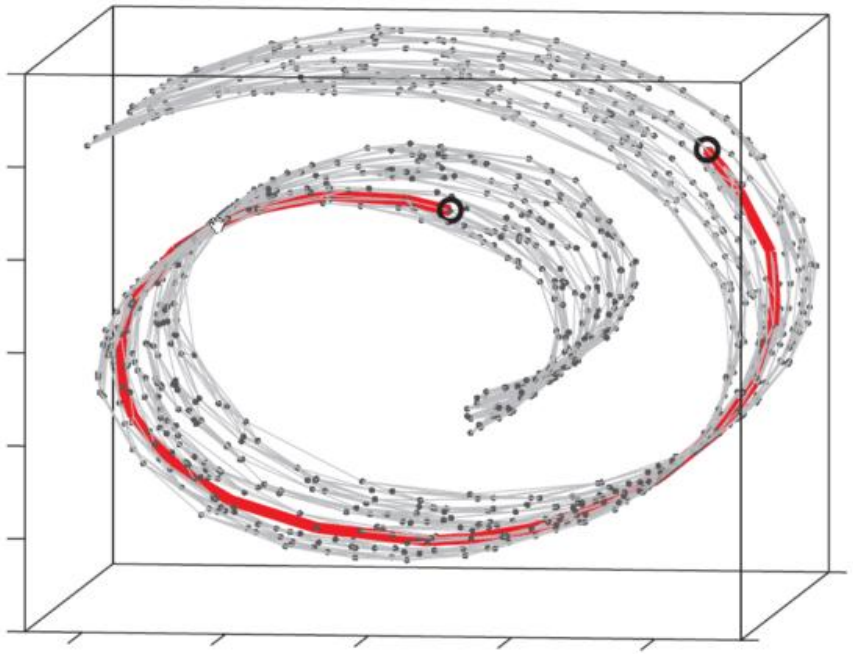
非线性降维：$z = \boldsymbol{f}(x)$



二.降维方法的发展图谱


保全局线性信息
PCA（1901）
MDS（1964）
Isomap（2000）
保样本间几何关系
保局部邻域结构
LLE（2000）
t-SNE（2008）
UMAP（2018）
Autoencoder（1986）
VAE（2013）
让模型自己学习低维表示

三.经典降维方法与案例实践

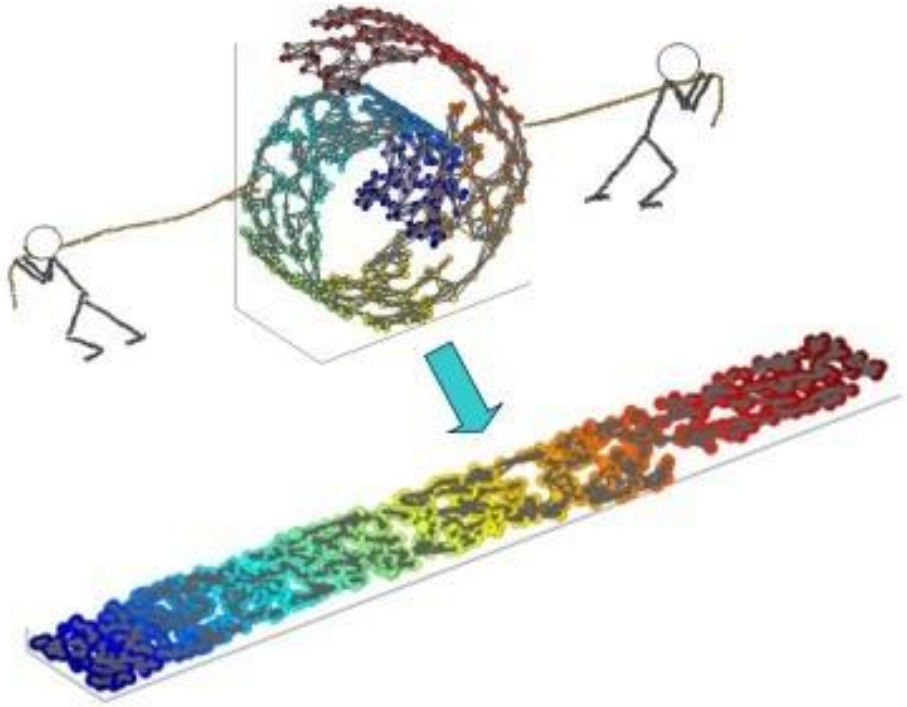


在计算距离时

欧式距离是不是永远合适？

三.经典降维方法与案例实践

流形





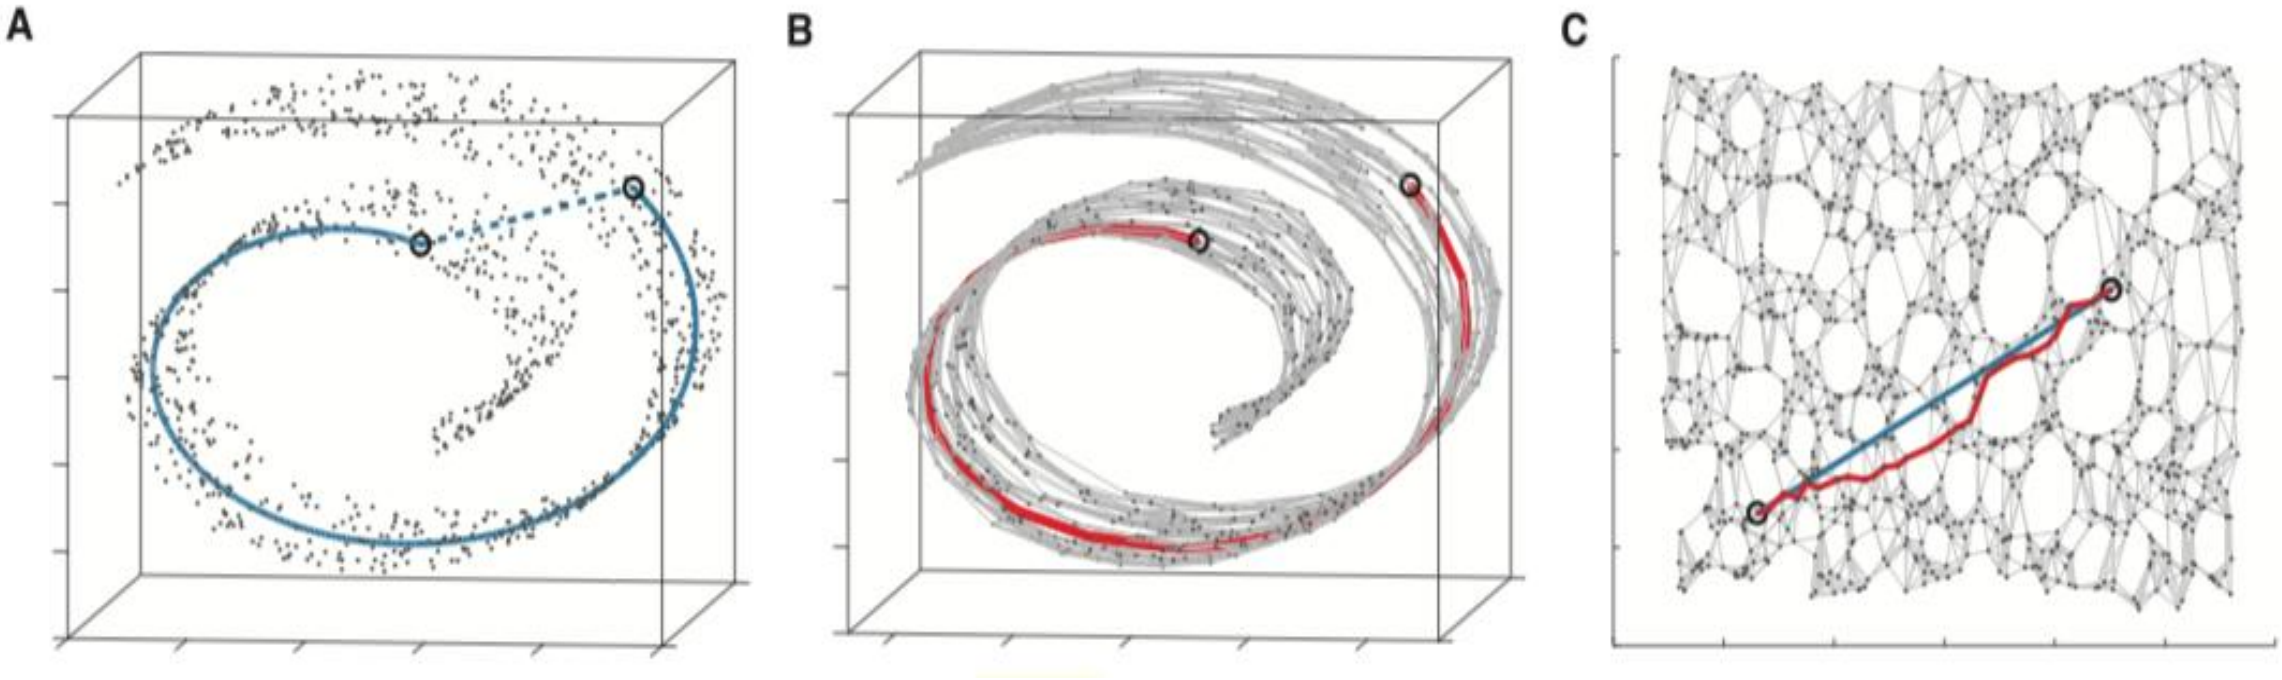
知乎 @我爱C编程

假设：数据可能位于高维空间的某个低维流形上

三.经典降维方法与案例实践

首都师范大学 CAPITAL NORMAL UNIVERSITY

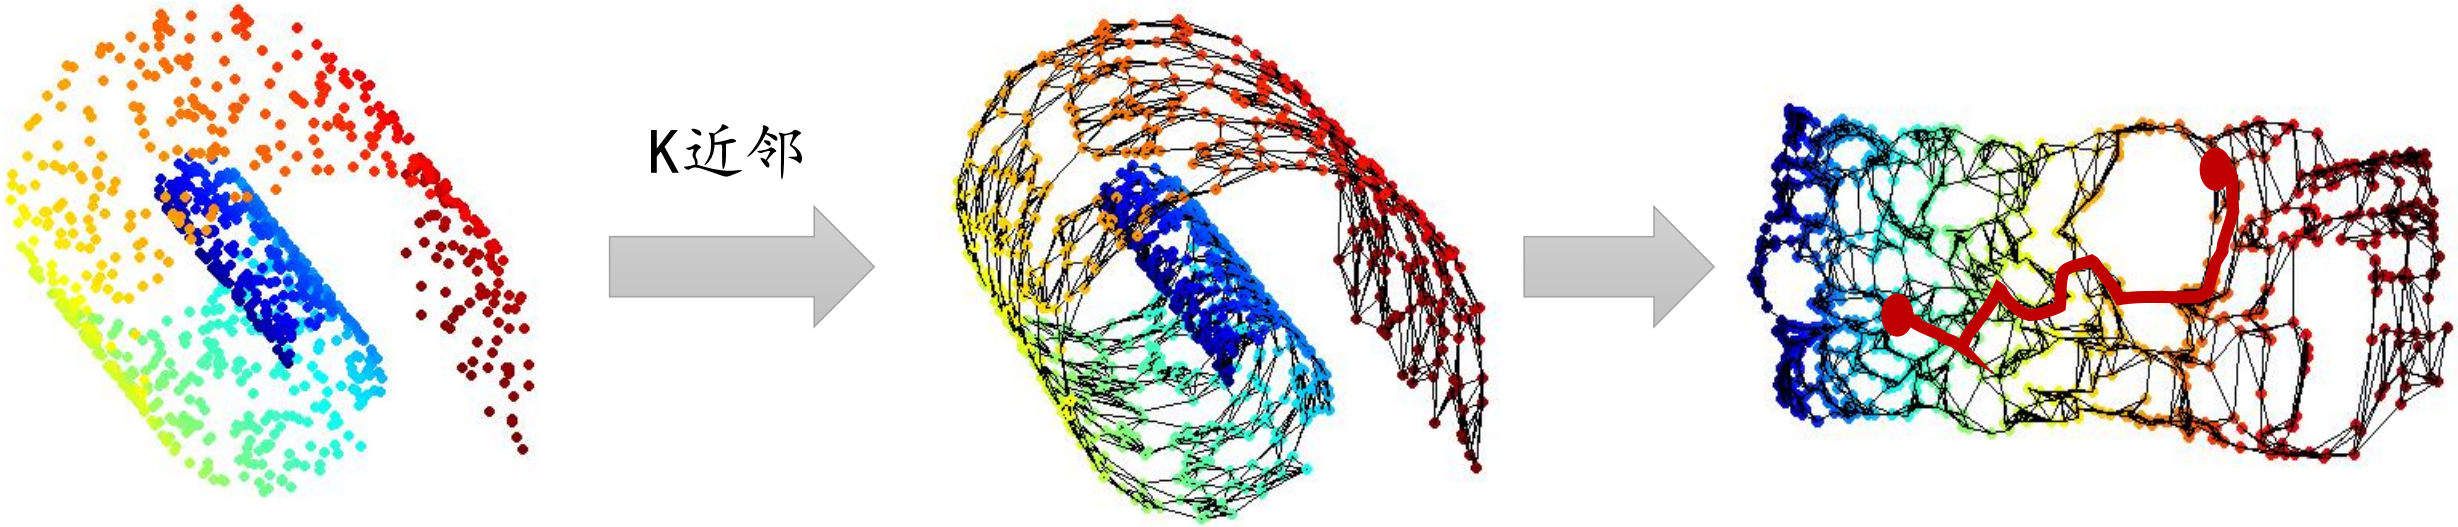
流形



流形上的距离怎么算？流形**测地距离**，用**局部欧氏距离**逼近

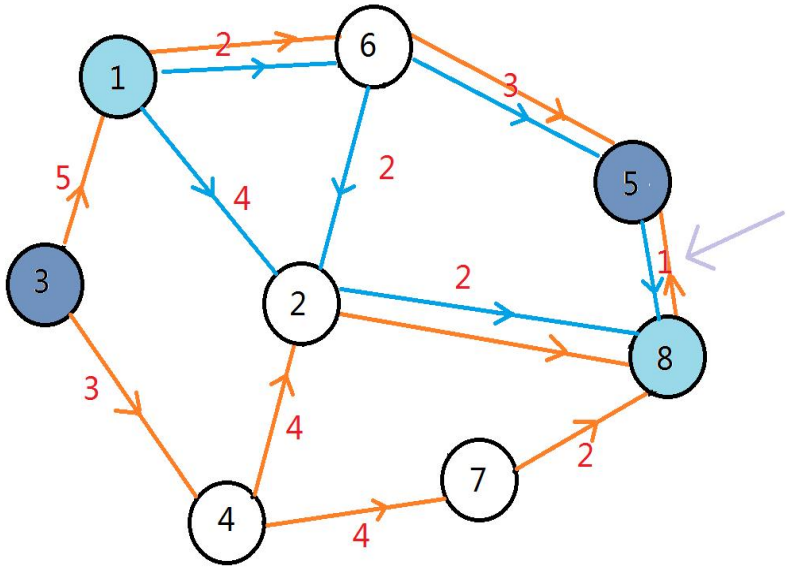
三.经典降维方法与案例实践

流形



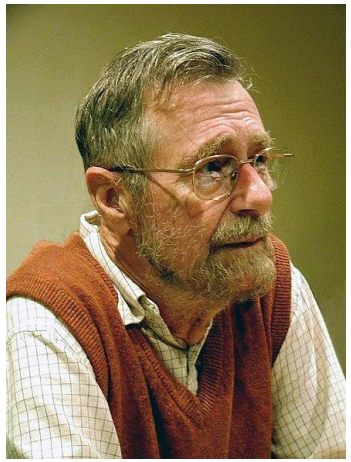
三.经典降维方法与案例实践

图论



最短路问题

最短路问题 {
- **单源**最短路：从A到任意一点的最短路
- **多源**最短路：任意两点间的最短路



Edsger W.Dijkstra（1930– 2002）
1972年图灵奖得主

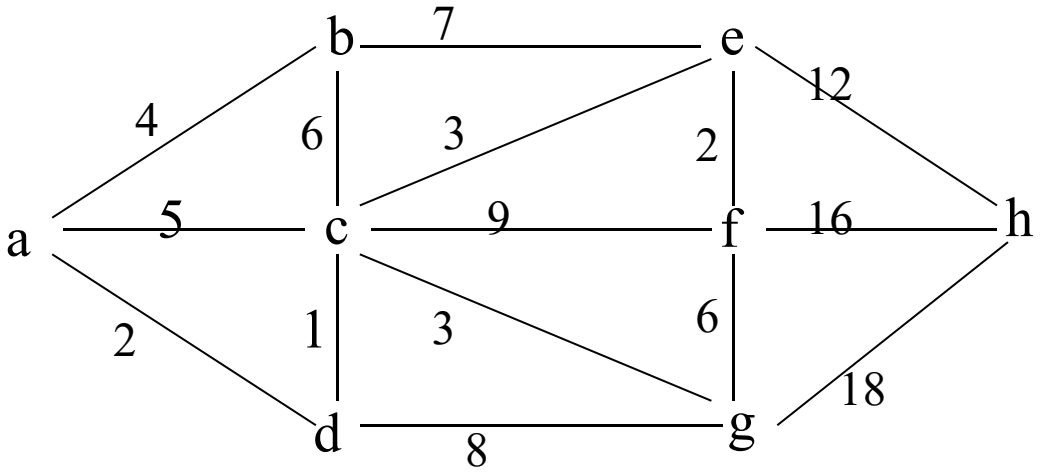
- **Dijkstra算法**

论文：E. Dijkstra. A note on two problems in connexion with graphs. Numerische Mathematik. 1: 269–271, 1959.

三.经典降维方法与案例实践

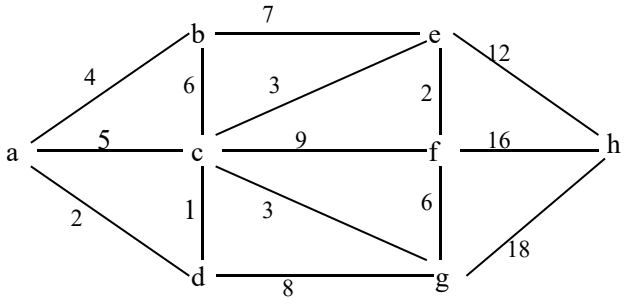
图论

- **问题：**求a到各点的最短距离及对应路线





三.经典降维方法与案例实践



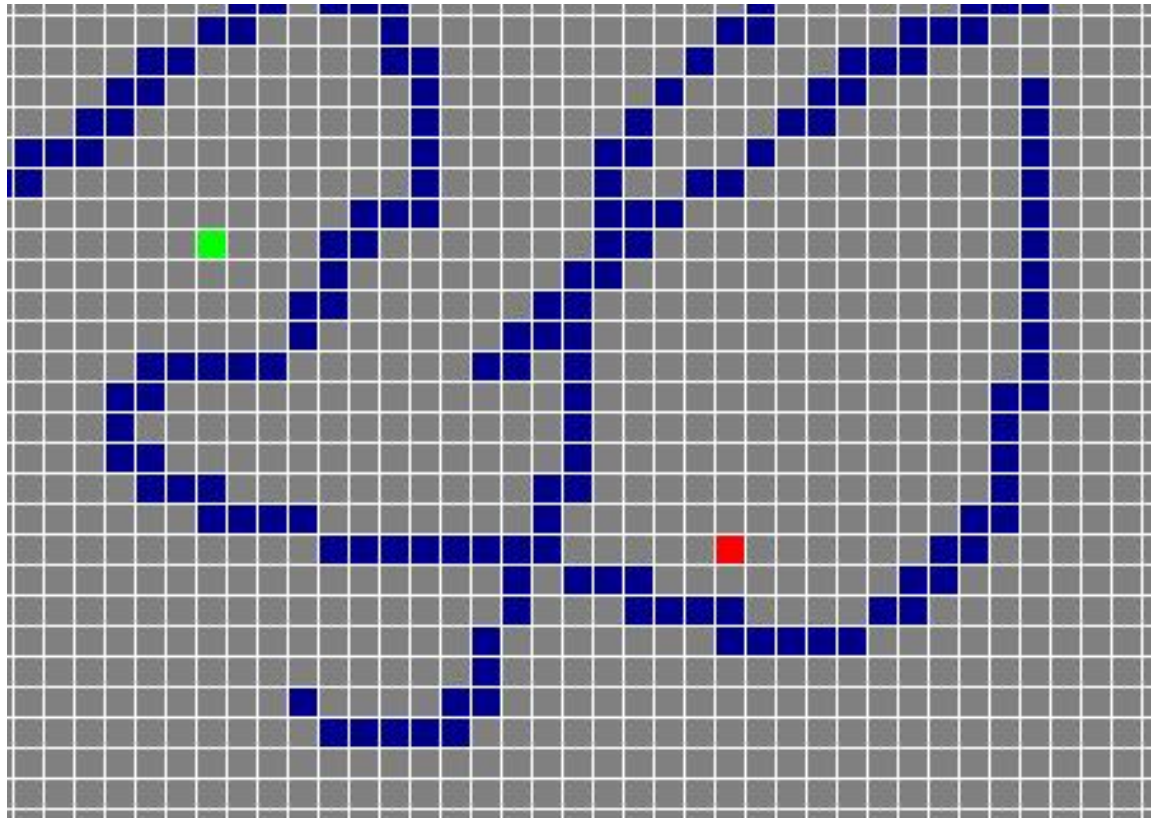


从a出发	第一轮	第二轮	第三轮	第四轮	第五轮	第六轮	第七轮
b	4 a-b	4 a-b	4 a-b				
c	5 a-c	3 a-d-c					
d	2 a-d						
e	inf a-e	inf a-e	6 a-d-c-e	6 a-d-c-e			
f	inf a-f	inf a-f	12 a-d-c-f	12 a-d-c-f	8 a-d-c-e-f	8 a-d-c-e-f	
g	inf a-g	10 a-d-g	6 a-d-c-g	6 a-d-c-g	6 a-d-c-g		
h	inf a-h	inf a-h	inf a-h	inf a-h	18 a-d-c-e-h	18 a-d-c-e-h	18 a-d-c-e-h
集合	d	c	b	e	g	f	h

图论

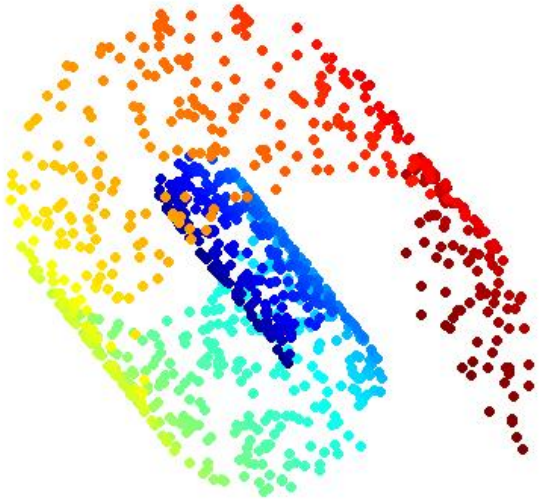
应用案例：

机器人路线寻优

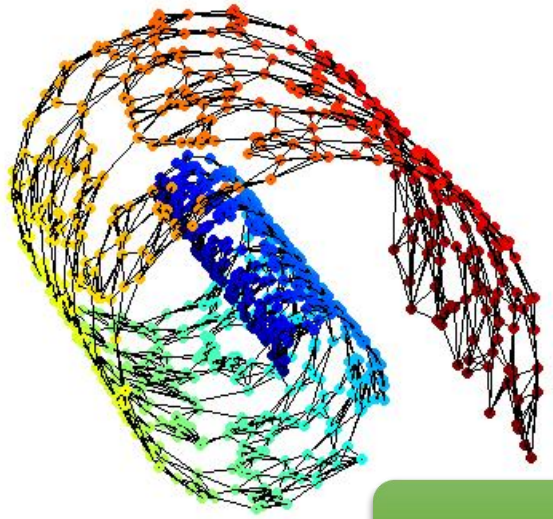


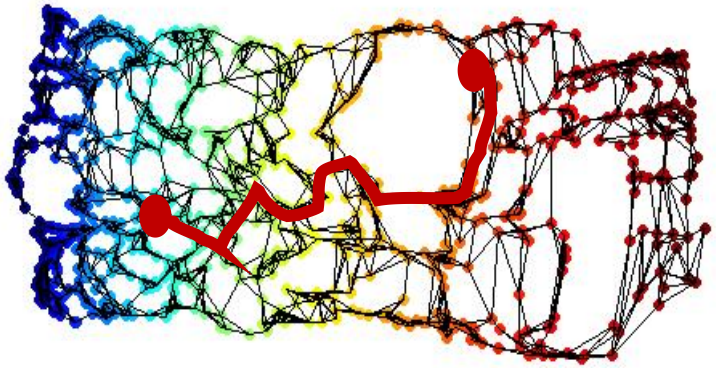
三.经典降维方法与案例实践

流形



K近邻





图论中的最短路算法

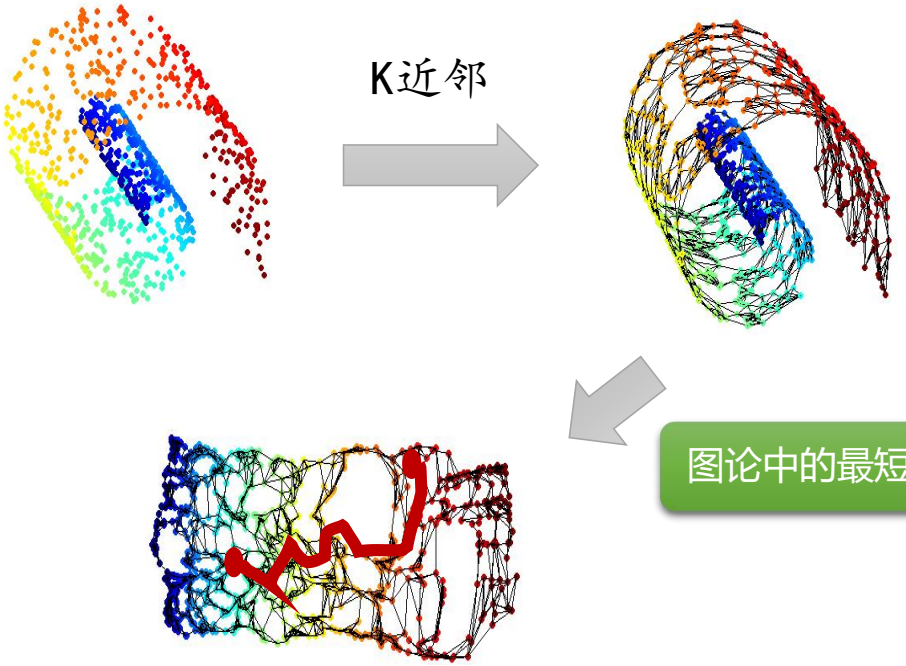
等距特征映射（Isomap）

MDS

Isomap

给定： m个p维的样本点$\{x_i\}$

D: $m \times m$

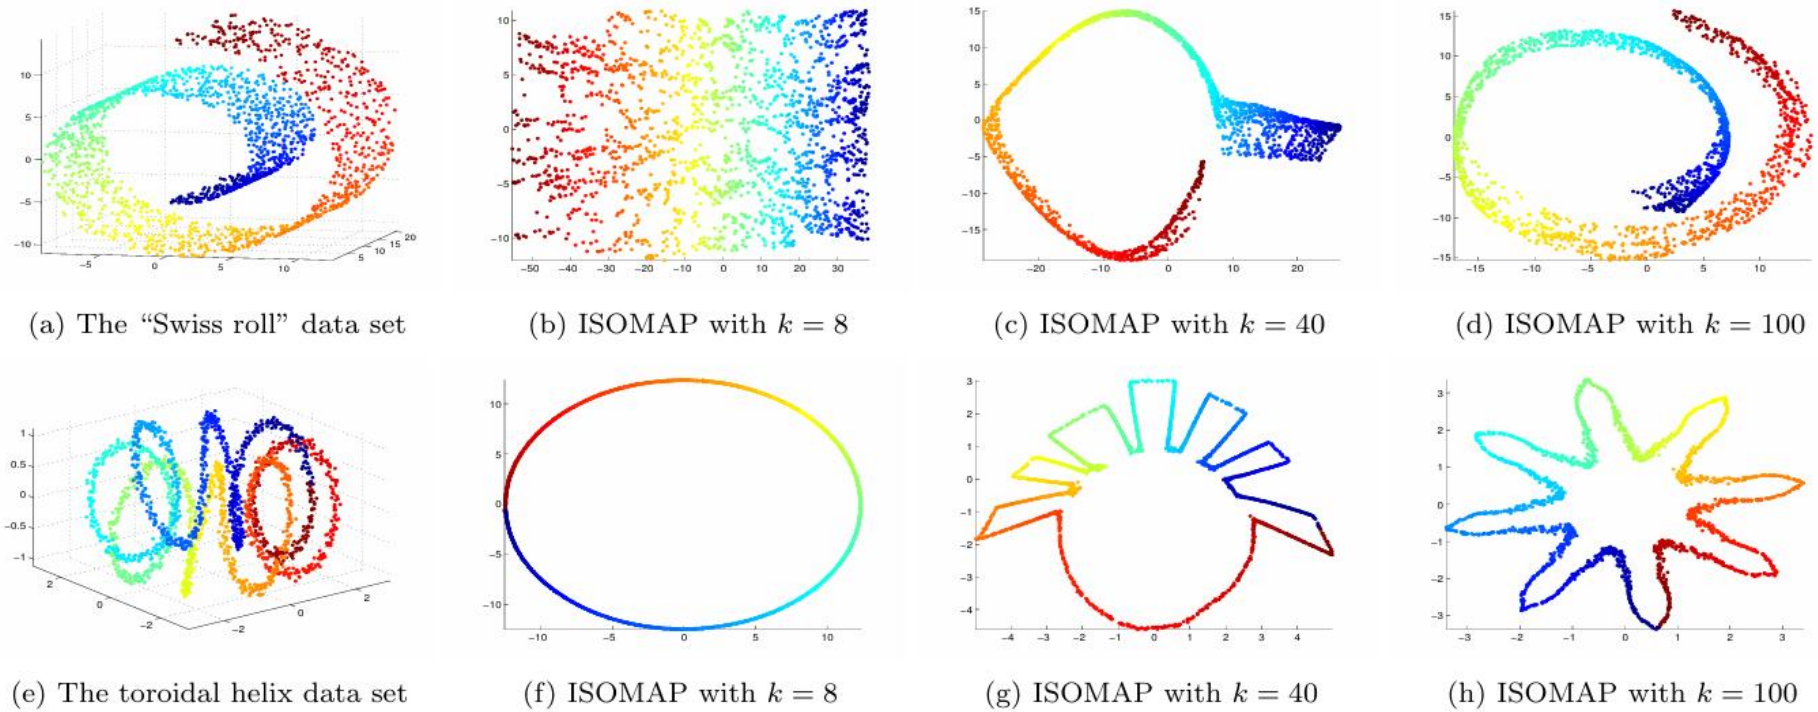


$\boldsymbol{B}$： $b_{ij} = -\frac{1}{2}\left(D_{ij}^2 - D_{i\cdot}^2 - D_{\cdot j}^2 + D_{\cdot\cdot}^2\right)$

对$\boldsymbol{B}$做特征值分解，$B = V\Lambda V^T$

三.经典降维方法与案例实践

等距特征映射（Isomap）



(a) The "Swiss roll" data set (b) ISOMAP with $k = 8$ (c) ISOMAP with $k = 40$ (d) ISOMAP with $k = 100$

(e) The toroidal helix data set (f) ISOMAP with $k = 8$ (g) ISOMAP with $k = 40$ (h) ISOMAP with $k = 100$

Figure 1: ISOMAP examples with different k values. The first and second rows of figures correspond to the "Swiss roll" and the toroidal data sets, respectively.

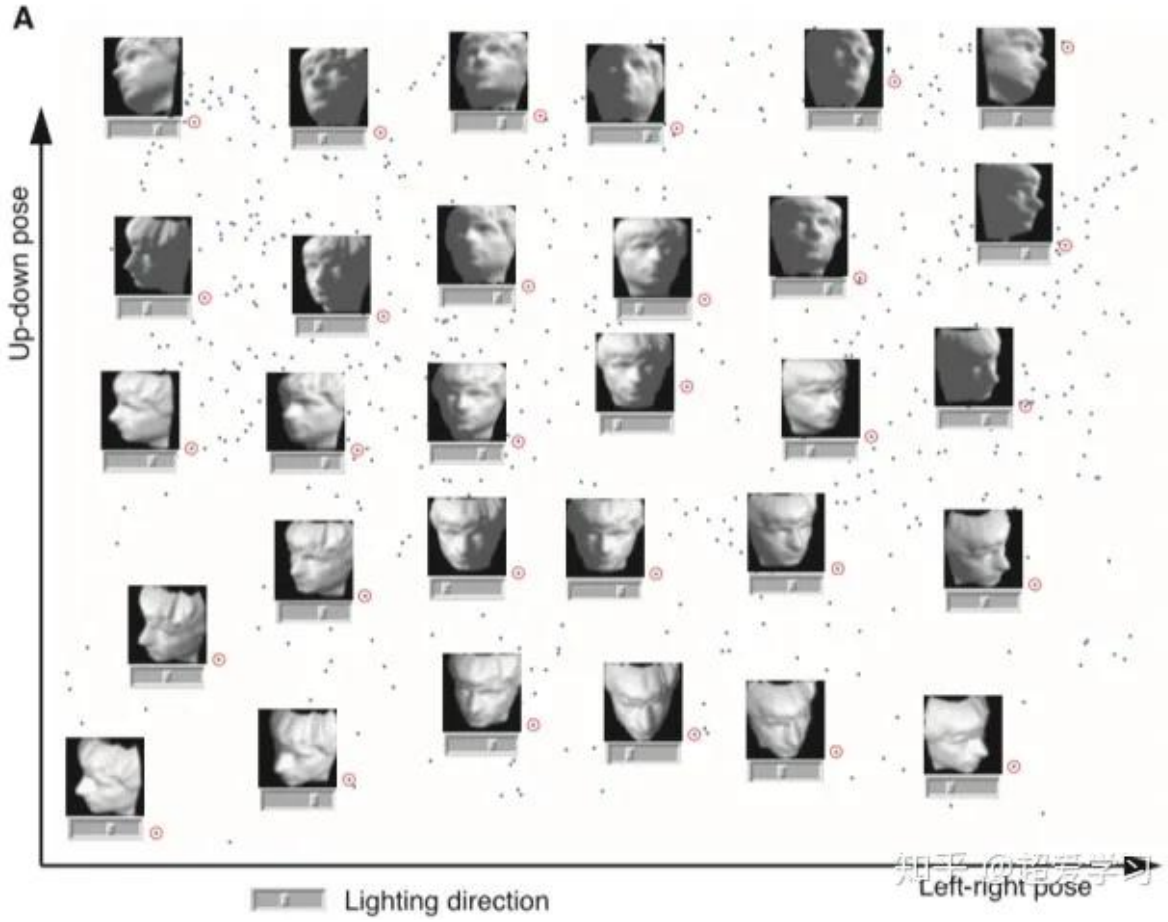
三.经典降维方法与案例实践

等距特征映射（Isomap）

698张64x64（4096维）的人脸:

主观判断，影响人脸的因素有三个:

- 光照方向
- 是否上下抬头
- 是否左右偏头



二.降维方法的发展图谱

保全局线性信息

PCA（1901）

MDS（1964）
Isomap（2000）

保样本间几何关系

保局部邻域结构

~~LLE（2000）~~
t-SNE（2008）
UMAP（2018）

Autoencoder（1986）
VAE（2013）

让模型自己学习低维表示

三.经典降维方法与案例实践

首都师范大学 CAPITAL NORMAL UNIVERSITY

t分布邻域嵌入算法(t-SNE)

Journal of Machine Learning Research 9 (2008) 2579-2605 Submitted 5/08; Revised 9/08; Published 11/08

Visualizing Data using t-SNE

Laurens van der Maaten LVDMAATEN@GMAIL.COM
TiCC
Tilburg University
P.O. Box 90153, 5000 LE Tilburg, The Netherlands

Geoffrey Hinton
Department of Computer Science
University of Toronto
6 King's College Road, M5S 3G4 Toronto, ON, Canada

Editor: Yoshua Bengio



三.经典降维方法与案例实践

t分布邻域嵌入算法(t-SNE)

高维空间中样本间的结构要在低维空间保持

只保持**局部邻域结构**就可以了

在高维空间中，用**高斯分布**刻画相似关系

在低维空间中，用**t分布**刻画相似关系

损失函数：要求两个**分布一致**

三.经典降维方法与案例实践

首都师范大学 CAPITAL NORMAL UNIVERSITY

t分布邻域嵌入算法(t-SNE)

点与点间的距离
(相似度)

条件概率

$$p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}$$

高维空间：

$$\|x_i - x_j\|^2$$

$$p_{j|i} = \frac{\exp\left(-\|x_i - x_j\|^2/(2\sigma_i^2)\right)}{\sum_{k\neq i}\exp(-\|x_i - x_k\|^2/(2\sigma_i^2))}$$

高斯分布

低维空间：

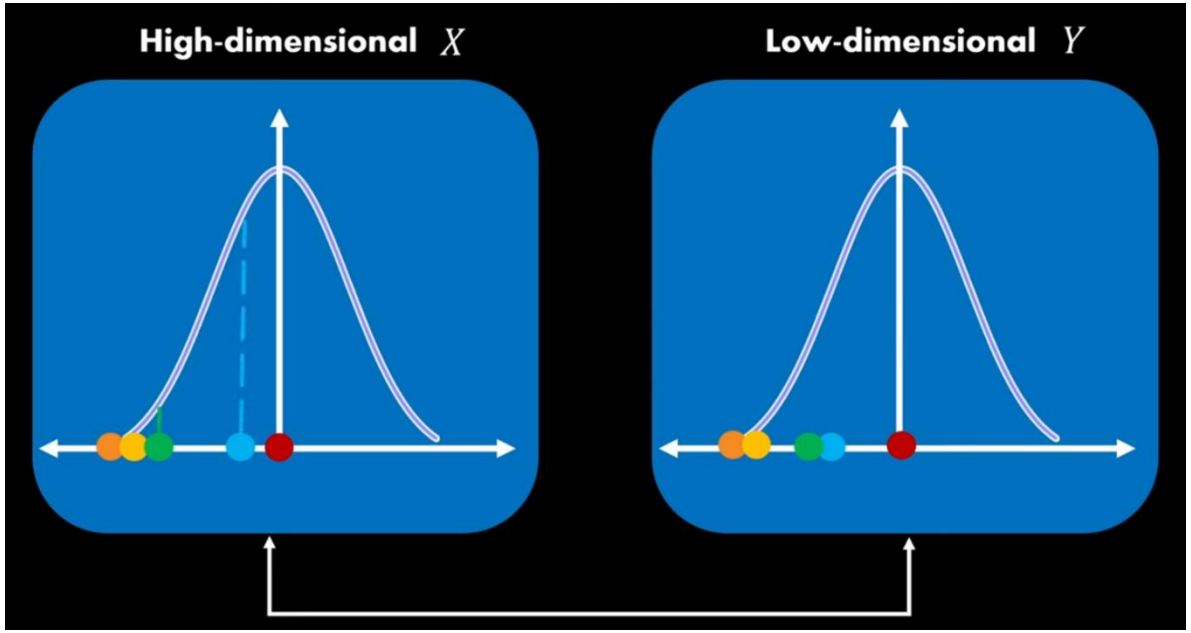
$$\|y_i - y_j\|^2$$

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{a\neq b}(1 + \|y_a - y_b\|^2)^{-1}}$$

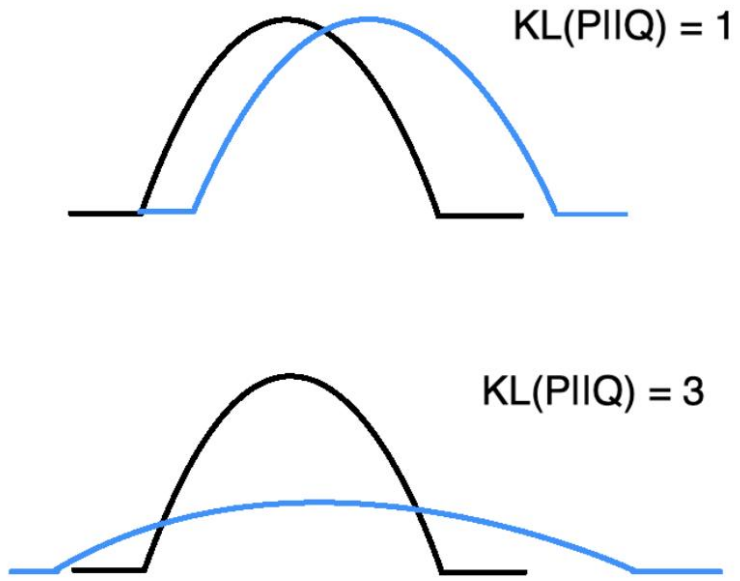
t分布

三.经典降维方法与案例实践

t分布邻域嵌入算法(t-SNE)



$$\min_{y_1,\ldots,y_n} \mathrm{KL}(P\|Q) = \sum_{i\neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}$$



三.经典降维方法与案例实践

t分布邻域嵌入算法(t-SNE)

高维空间中样本间的结构要在低维空间保持

只保持局部邻域结构就可以了

$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2/(2\sigma_i^2))}{\sum_{k\neq i}\exp(-\|x_i - x_k\|^2/(2\sigma_i^2))}$$

$$p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}$$

在高维空间中，用高斯分布刻画相似关系

在低维空间中，用t分布刻画相似关系

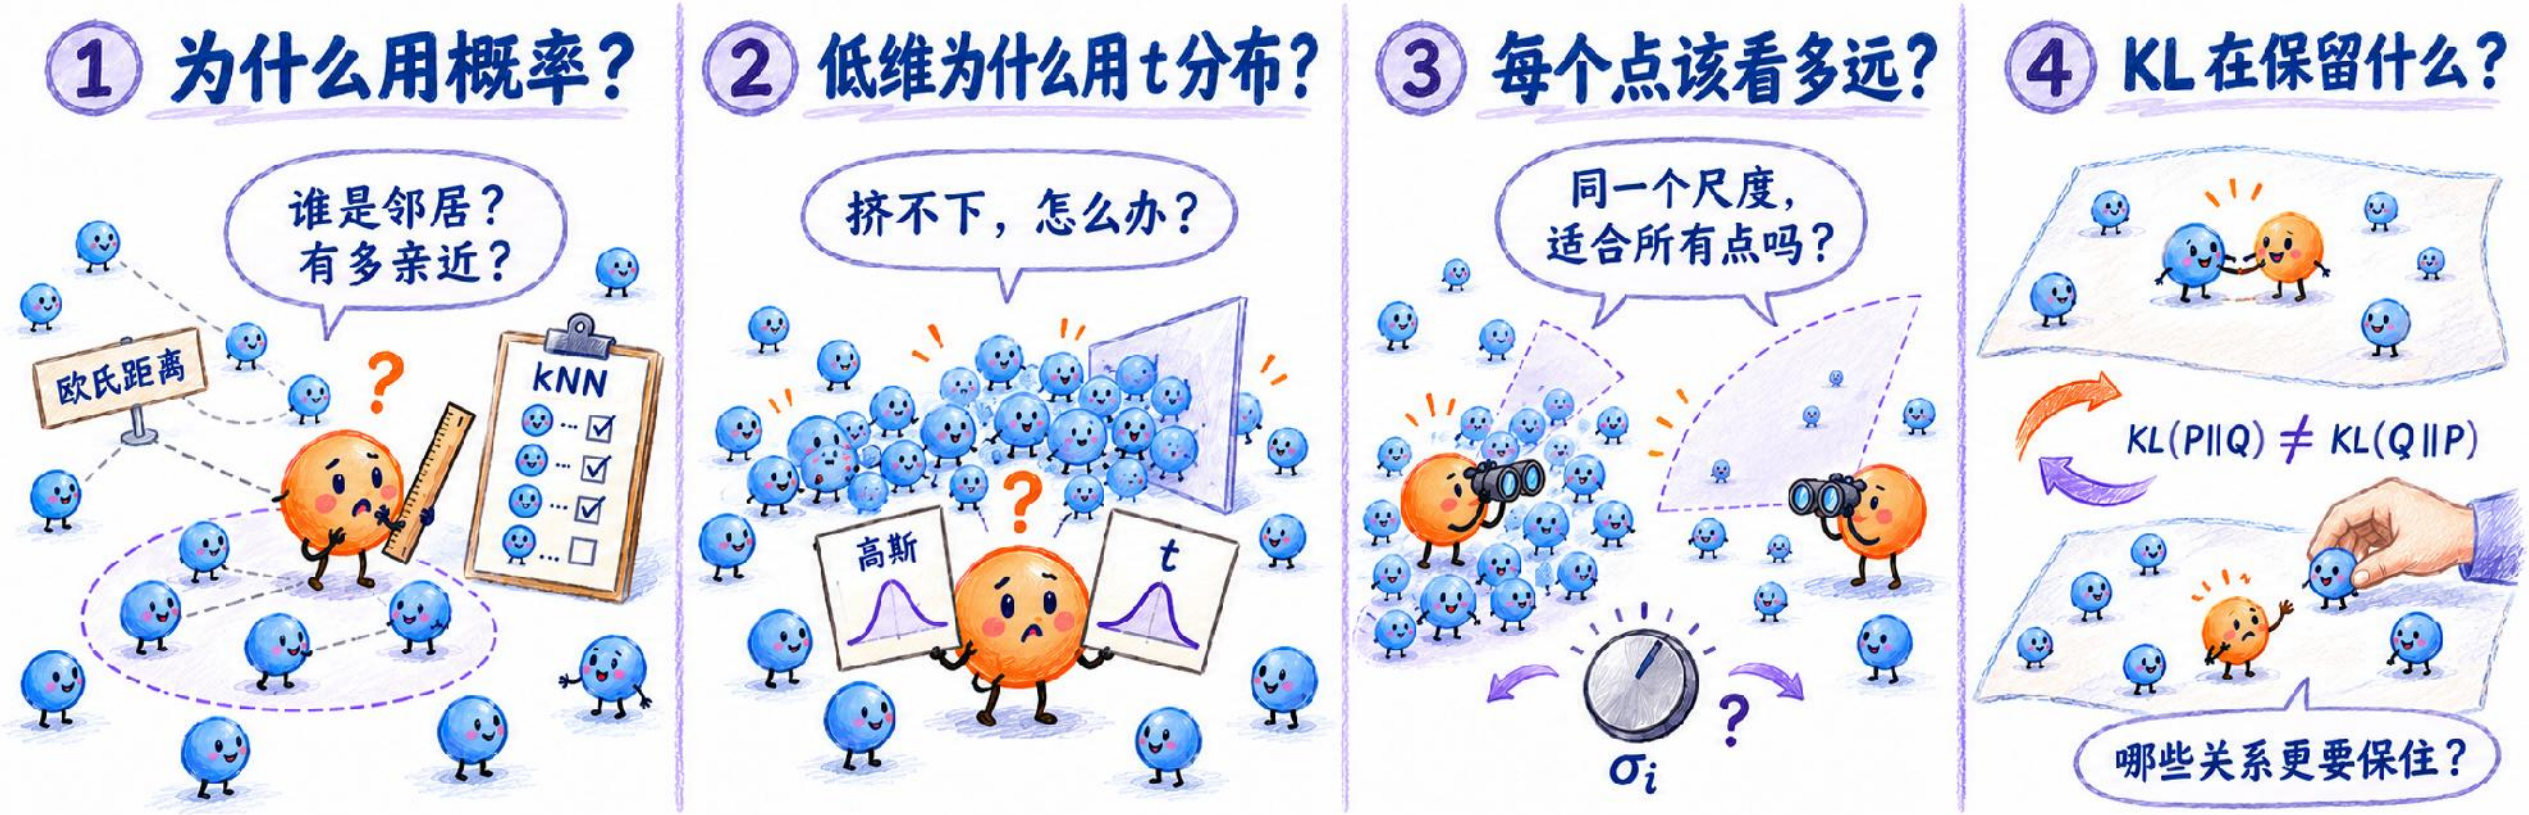
$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{a\neq b}(1 + \|y_a - y_b\|^2)^{-1}}$$

损失函数：要求两个分布一致

$$\min_{y_1,\ldots,y_n} \mathrm{KL}(P\|Q) = \sum_{i\neq j} p_{ij}\log\frac{p_{ij}}{q_{ij}}$$

三.经典降维方法与案例实践

t分布邻域嵌入算法(t-SNE)

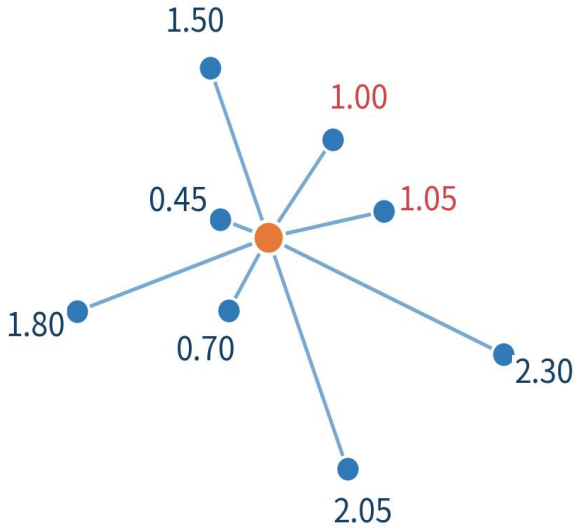


三.经典降维方法与案例实践

首都师范大学 CAPITAL NORMAL UNIVERSITY

t分布邻域嵌入算法(t-SNE)

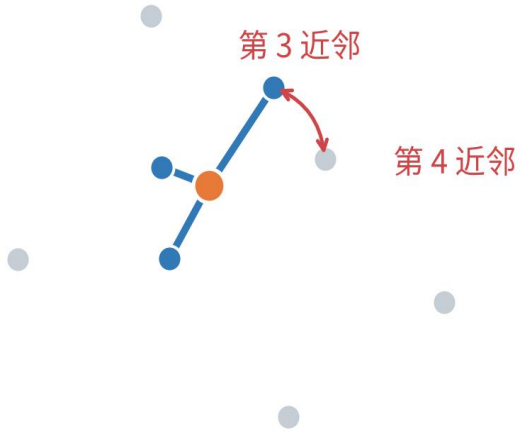
欧氏距离



相隔多远?

局限：单一距离忽略局部环境

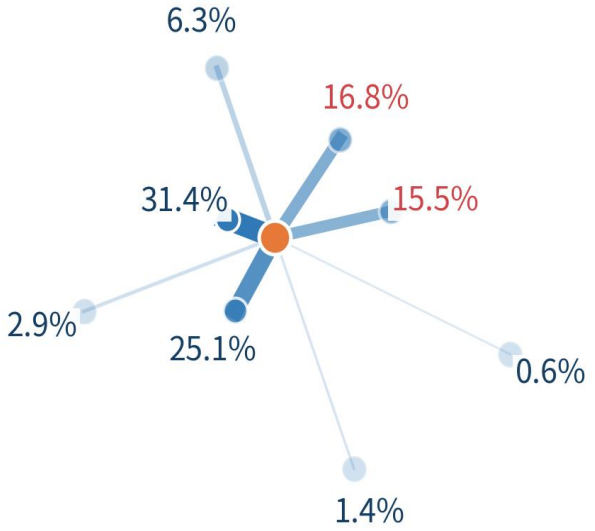
不加权 kNN（k = 3）



是否入选?

局限：硬性截断，边界突变

概率邻域



关系有多强?

优势：软权重，平滑表达强弱

t分布邻域嵌入算法(t-SNE)

$$p_{j|i} = \frac{\exp\left(-\|x_i - x_j\|^2/(2\sigma_i^2)\right)}{\sum_{k\neq i}\exp(-\|x_i - x_k\|^2/(2\sigma_i^2))}$$



对第 i 个点的邻居概率分布 P_i，定义：

$$H(P_i) = -\sum_{j\neq i} p_{j|i}\log_2 p_{j|i},$$

$$\boxed{\mathrm{Perp}(P_i) = 2^{H(P_i)}}.$$

困惑度可以理解为**具有相同熵的均匀分布所包含的邻居数量**，也就是“有效邻居数”。

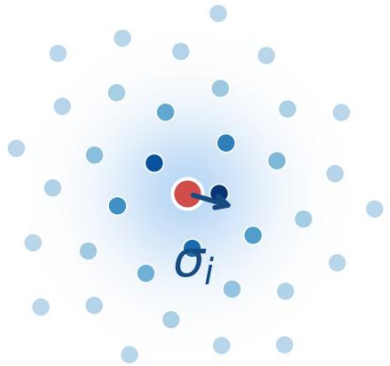
三.经典降维方法与案例实践

t分布邻域嵌入算法(t-SNE)

邻居权重	困惑度	直观含义
$(1, 0, 0, 0)$	1	只重视一个邻居
$(0.5, 0.5, 0, 0)$	2	同等重视两个邻居
$(0.25, 0.25, 0.25, 0.25)$	4	同等重视四个邻居
$(0.7, 0.1, 0.1, 0.1)$	约 2.56	四个点有权重，但重要性集中在少数点

相同困惑度，不同的观察尺度

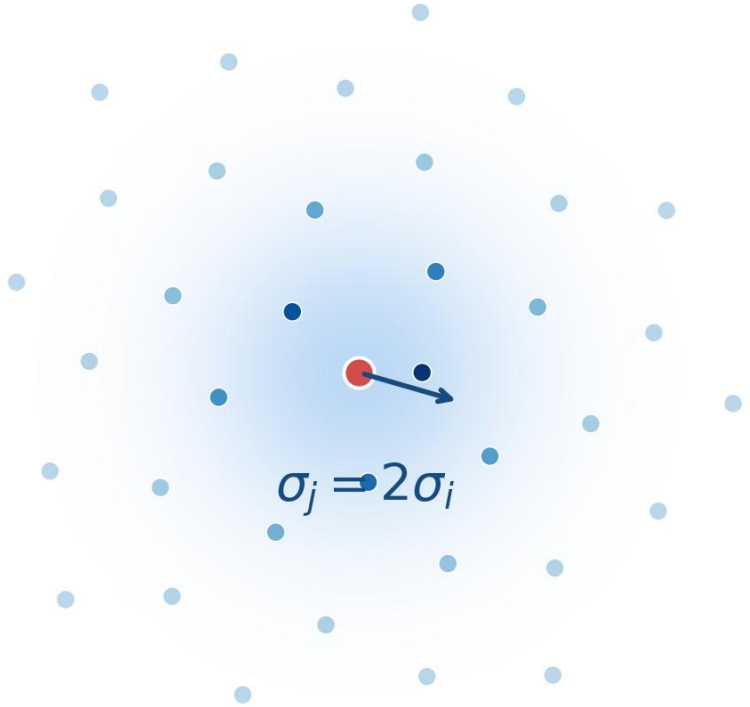
密集区域



小带宽 · 看得近

有效邻居数相同：Perplexity ≈ 15.3

稀疏区域



大带宽 · 看得远

有效邻居数相同：Perplexity ≈ 15.3

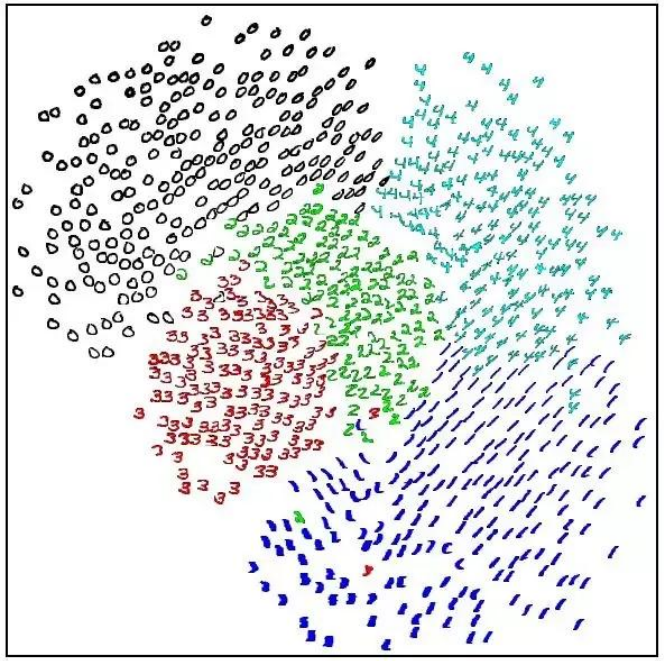
距离与带宽同比例放大，邻居概率不变

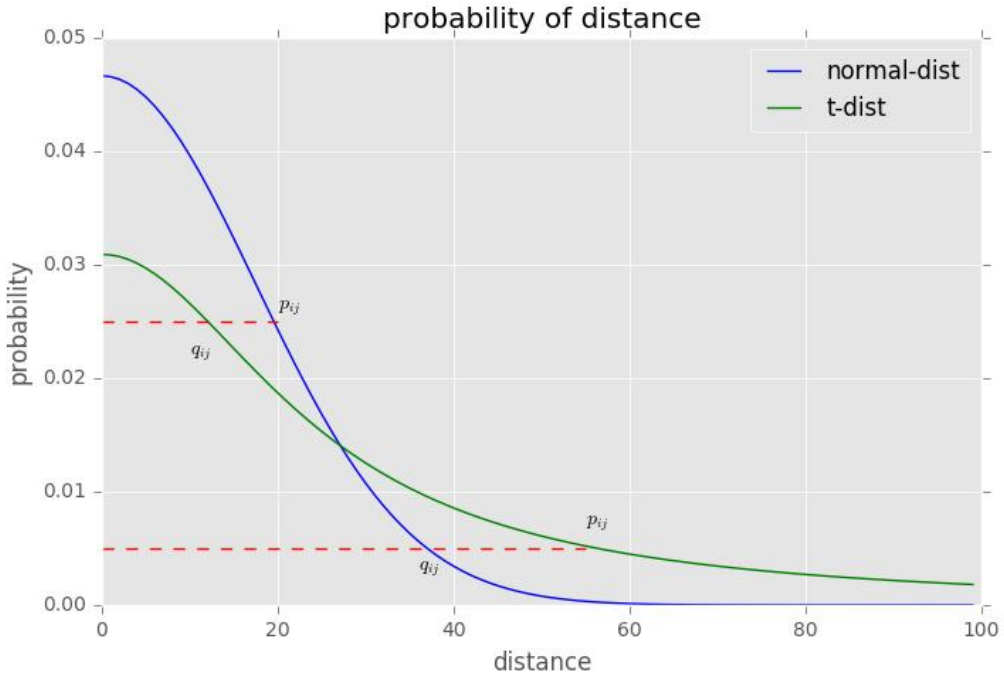
三.经典降维方法与案例实践

t分布邻域嵌入算法(t-SNE)

SNE → 将低维空间中的高斯分布换成t分布 → t-SNE

拥挤问题





三.经典降维方法与案例实践

t分布邻域嵌入算法(t-SNE)

$$\min_{y_1,\ldots,y_n} \mathrm{KL}(P\|Q) = \sum_{i\neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}$$

三.经典降维方法与案例实践

t分布邻域嵌入算法(t-SNE)

高维空间中样本间的结构要在低维空间保持

只保持局部邻域结构就可以了

$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2/(2\sigma_i^2))}{\sum_{k\neq i}\exp(-\|x_i - x_k\|^2/(2\sigma_i^2))}$$

$$p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}$$

在高维空间中，用高斯分布刻画相似关系

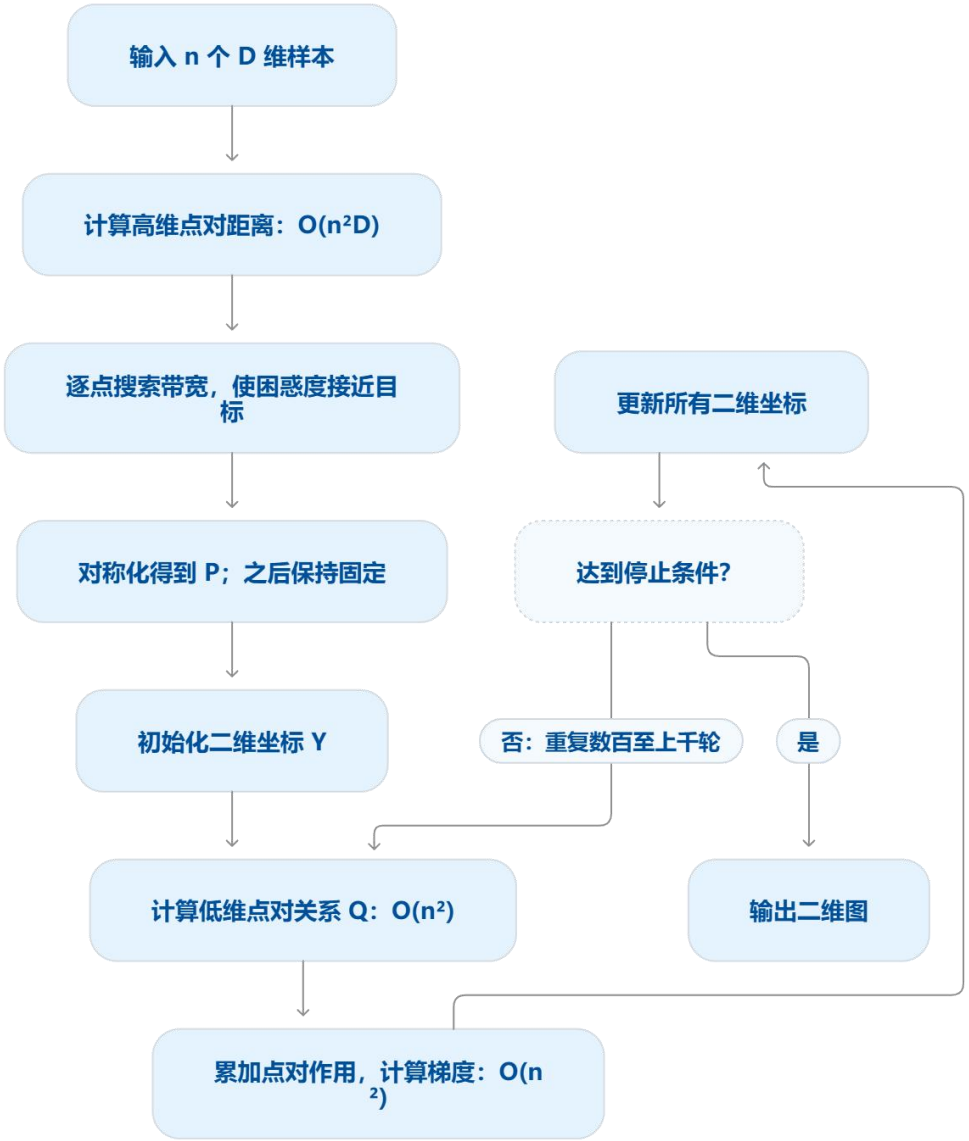
在低维空间中，用t分布刻画相似关系

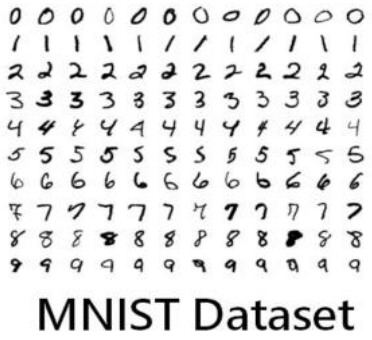
$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{a\neq b}(1 + \|y_a - y_b\|^2)^{-1}}$$

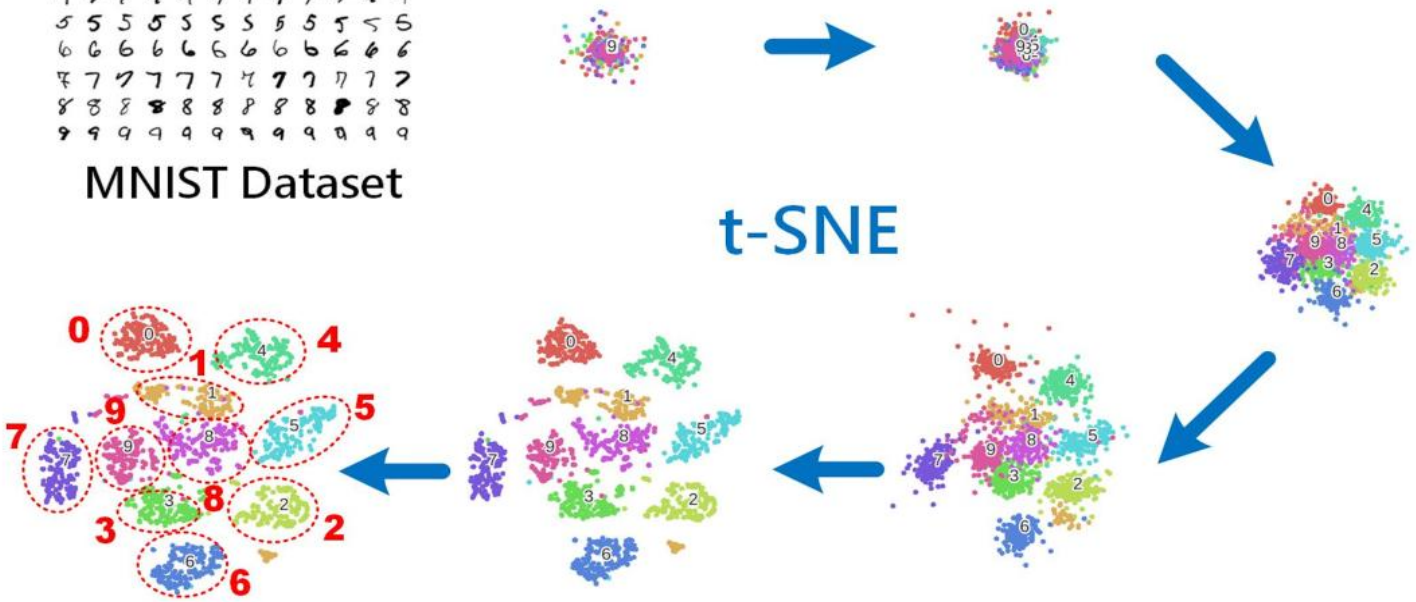
损失函数：要求两个分布一致

$$\min_{y_1,\ldots,y_n} \mathrm{KL}(P\|Q) = \sum_{i\neq j} p_{ij}\log\frac{p_{ij}}{q_{ij}}$$

三.经典降维方法与案例实践

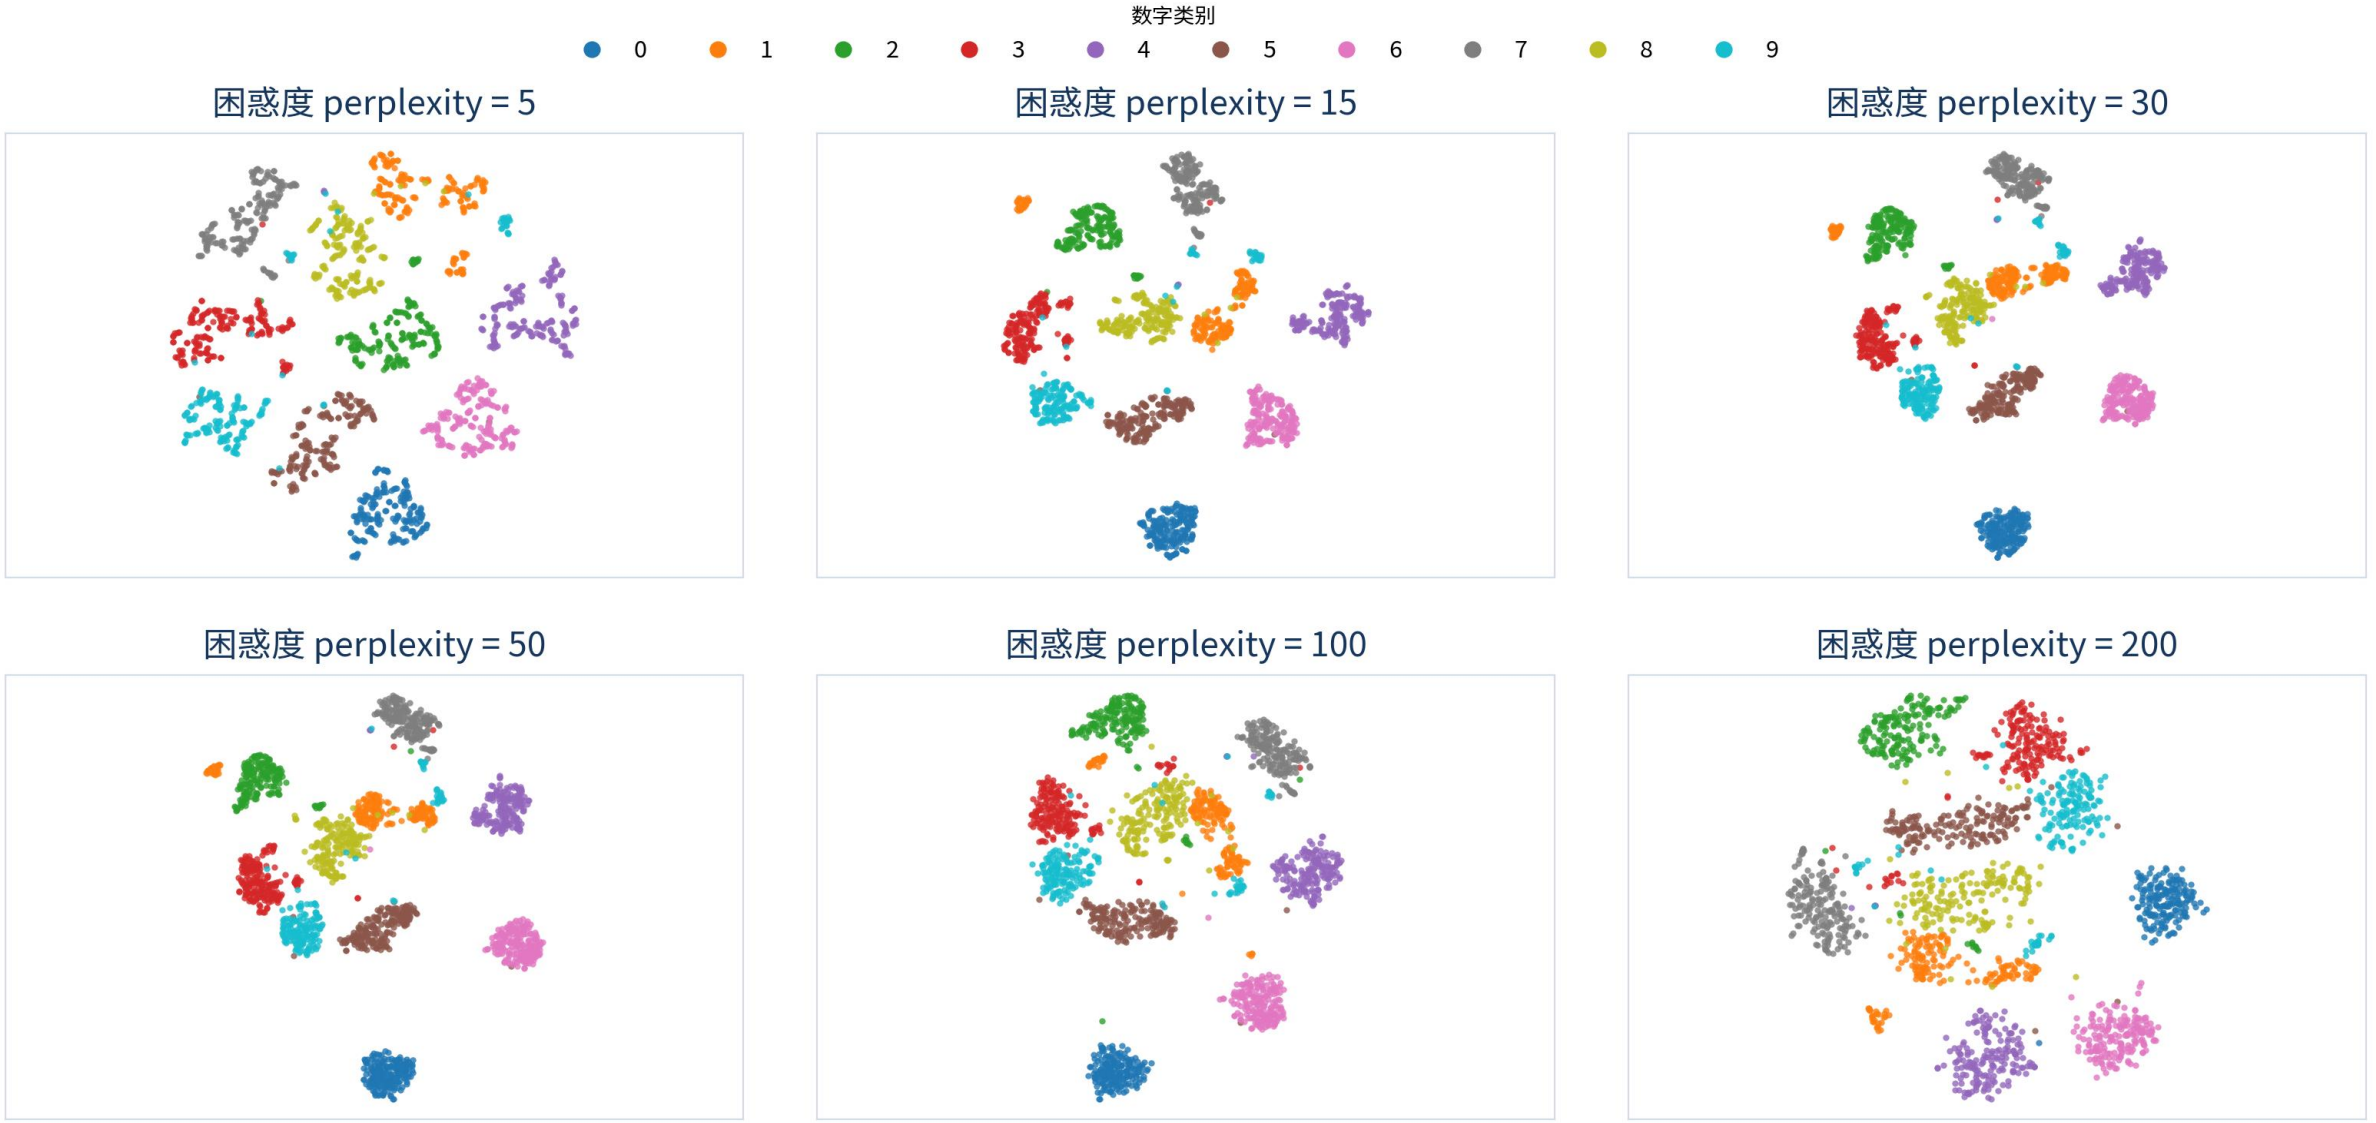






[tSNEJS demo]

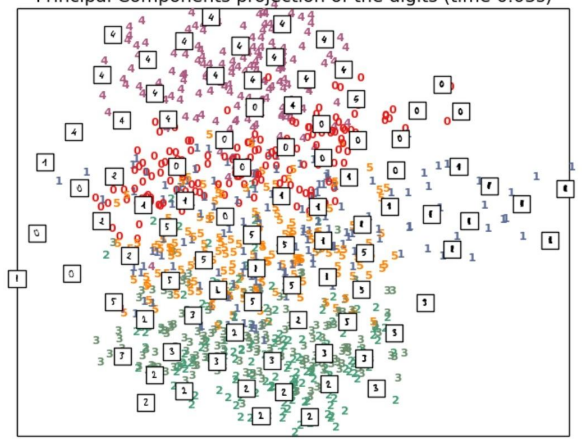
三.经典降维方法与案例实践

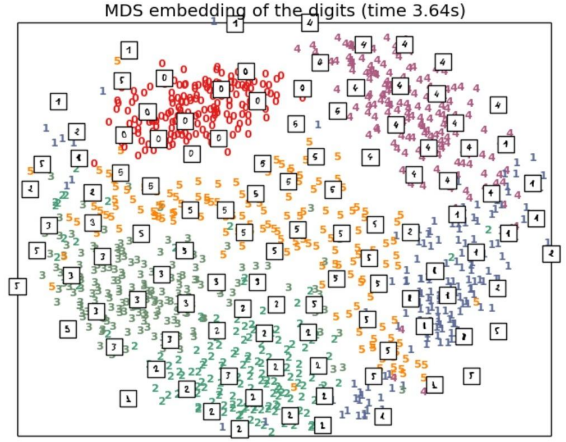


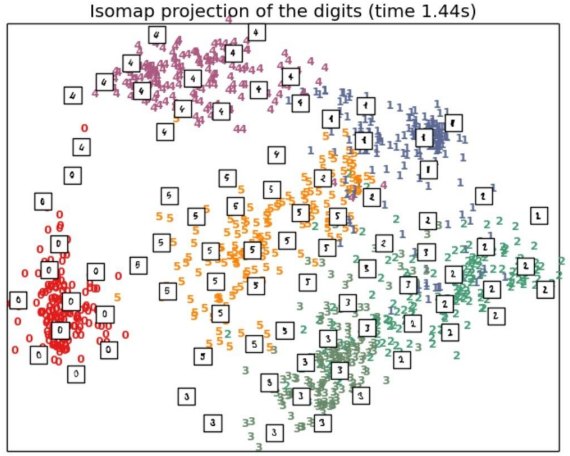
三.经典降维方法与案例实践

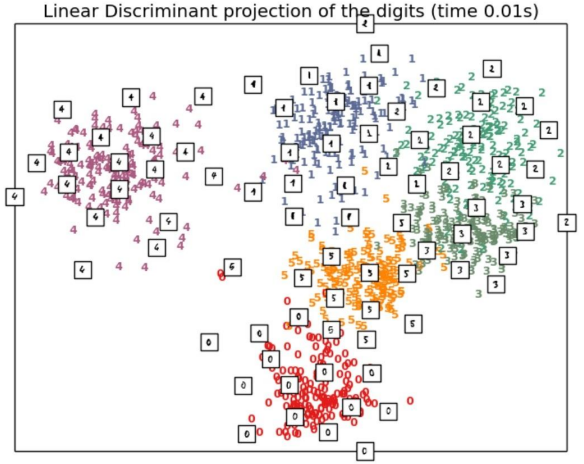
A selection from the 64-dimensional digits dataset

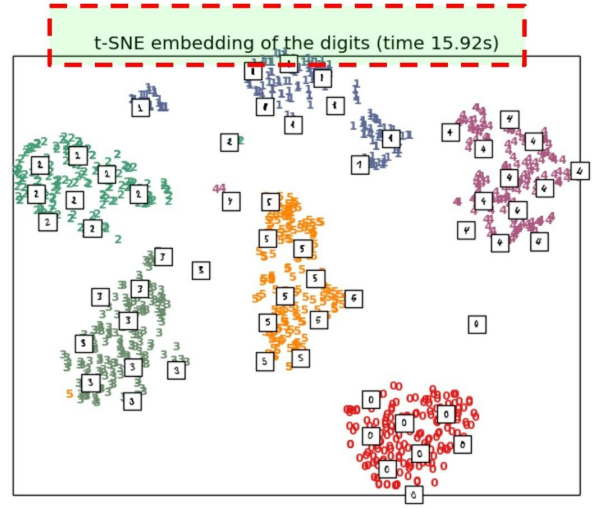












http://scikit-learn.org/stable/auto_examples/manifold/plot_lle_digits.html

三.经典降维方法与案例实践

t分布邻域嵌入算法(t-SNE)

高维空间中样本间的结构要在低维空间保持

只保持**局部邻域结构**就可以了

在高维空间中，用**高斯分布**刻画相似关系

在低维空间中，用**t分布**刻画相似关系

损失函数：要求两个**分布一致**

主要做可视化
(全局信息破坏)

对参数敏感

计算复杂度高

二.降维方法的发展图谱

保全局线性信息

PCA（1901）

MDS（1964）
Isomap（2000）

保样本间几何关系

保局部邻域结构

~~LLE（2000）~~
t-SNE（2008）
UMAP（2018）

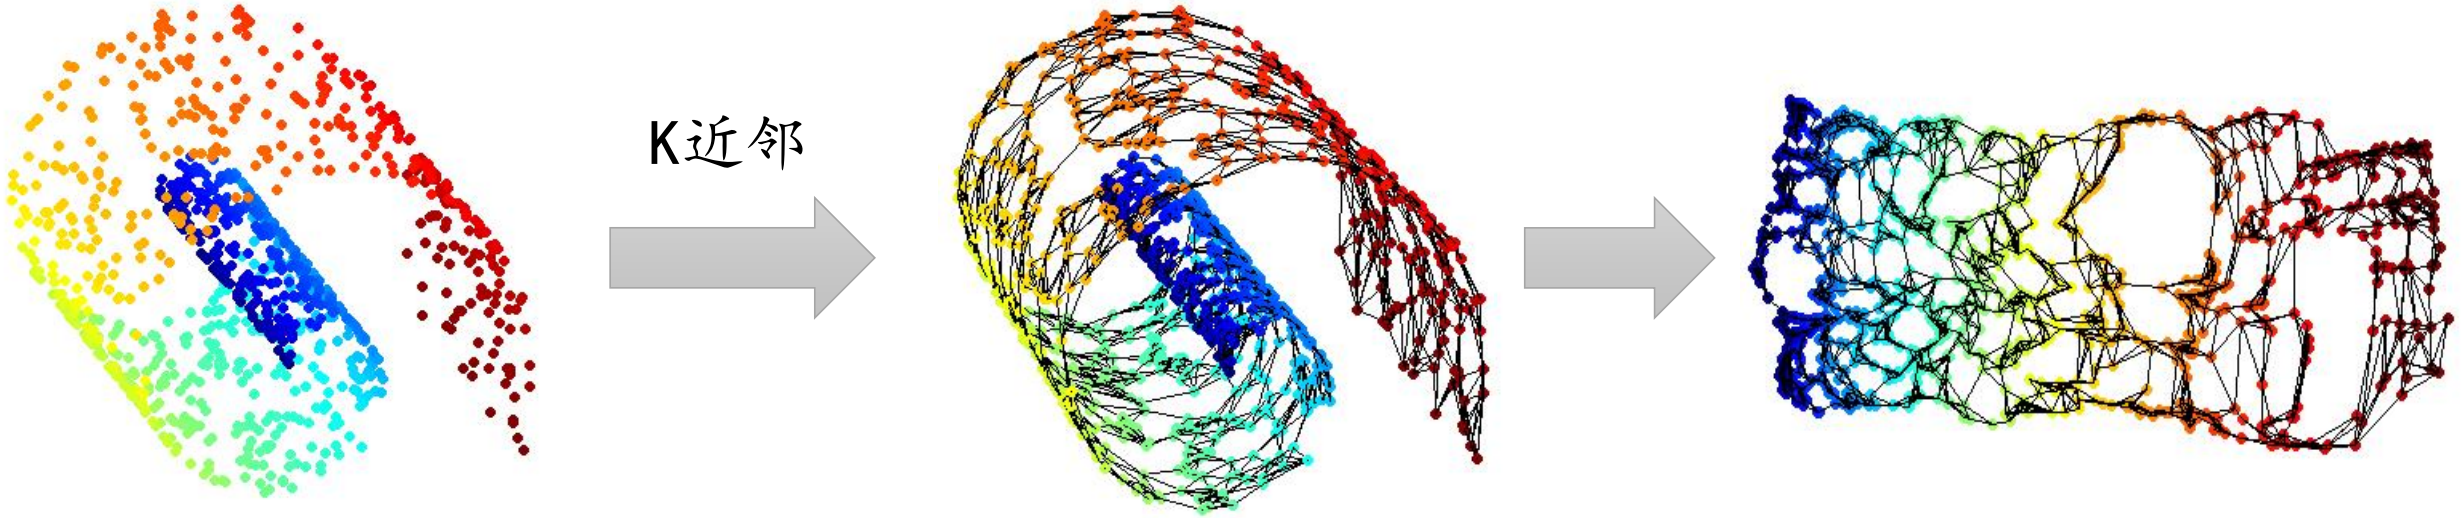
Autoencoder（1986）
VAE（2013）

让模型自己学习低维表示

UMAP

全称： Uniform Manifold Approximation and Projection

核心思想： 流形假设 → 局部邻域建模 → 低维拓扑保持



三.经典降维方法与案例实践

UMAP

核心思想： 流形假设 → **局部邻域建模** → 低维拓扑保持

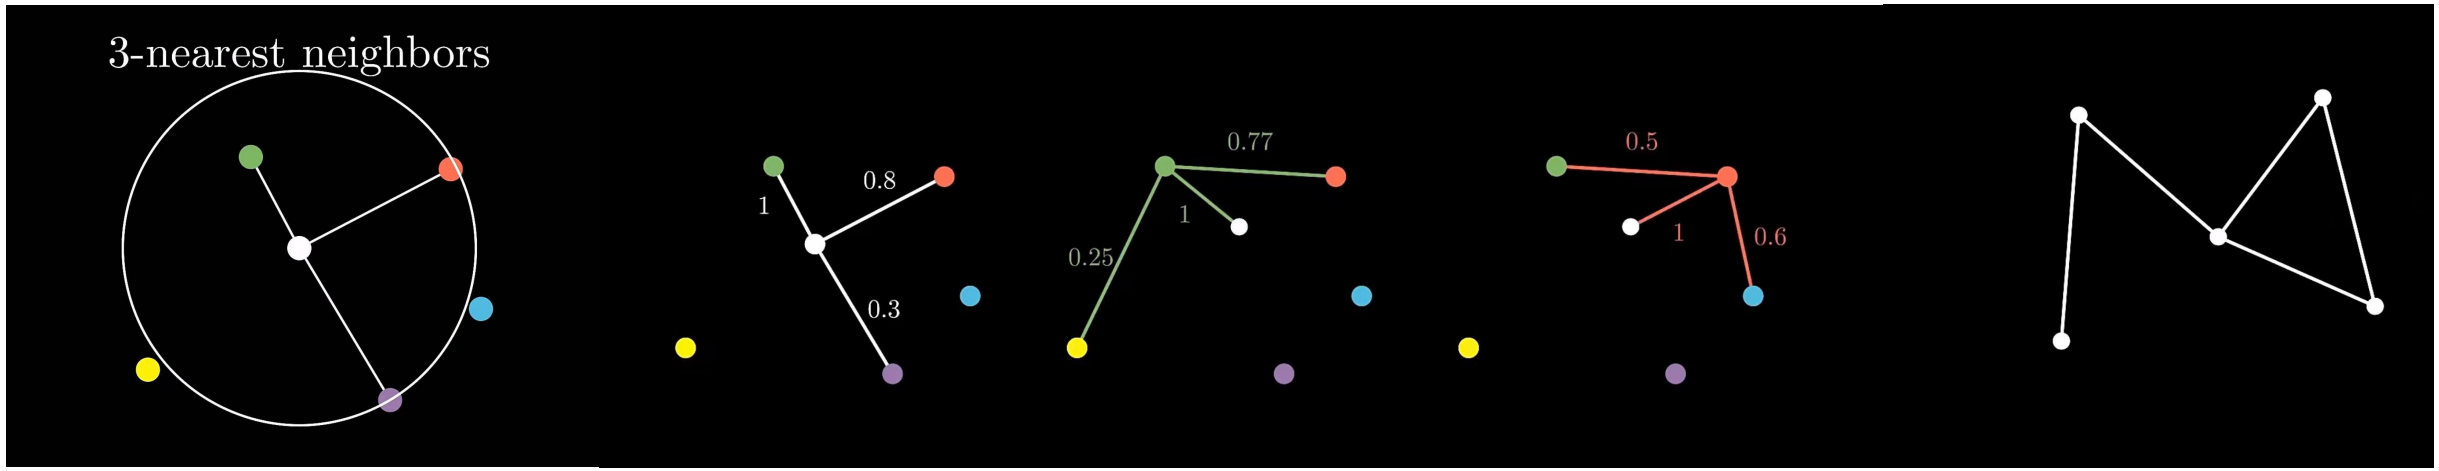
找邻居 → **计算边权** → **拼成整张图**

$$\mathcal{N}_k(x_i) = \{x_{i1}, x_{i2}, \ldots, x_{ik}\}$$

$$\rho_i = \min\{\, d(x_i, x_{ij}) \mid 1 \le j \le k,\ d(x_i, x_{ij}) > 0 \,\}$$

$$v_{j|i} = \exp\left(-\frac{\max(0, d(x_i, x_j) - \rho_i)}{\sigma_i}\right)$$

$$v_{ij} = v_{j|i} + v_{i|j} - v_{j|i}v_{i|j}$$



三.经典降维方法与案例实践

UMAP

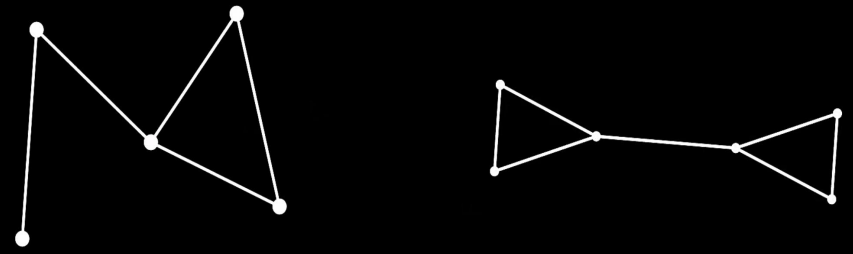
核心思想： 流形假设 → 局部邻域建模 → **低维拓扑保持**

找低维点 → **计算边权** → **拓扑保持**

$$y_i \in \mathbb{R}^m$$

$$w_{ij} = \frac{1}{1 + a\|y_i - y_j\|^{2b}}$$

$$\mathcal{L} = \sum_{i \neq j} \left[v_{ij} \log \frac{v_{ij}}{w_{ij}} + (1 - v_{ij}) \log \frac{1 - v_{ij}}{1 - w_{ij}} \right]$$



$$\begin{bmatrix} 0 & 0.2 & 0 & 0 & 0.8 \\ 0.2 & 0 & 0.5 & 0 & 0 \\ 0 & 0.5 & 0 & 0.7 & 0 \\ 0 & 0 & 0.7 & 0 & 0.6 \\ 0.8 & 0 & 0 & 0.6 & 0 \end{bmatrix}$$

$$\begin{bmatrix} 0 & 0.3 & 0.4 & 0 & 0 \\ 0.3 & 0 & 0.2 & 0.5 & 0 \\ 0.4 & 0.2 & 0 & 0 & 0.9 \\ 0 & 0.5 & 0 & 0 & 0.1 \\ 0 & 0 & 0.9 & 0.1 & 0 \end{bmatrix}$$

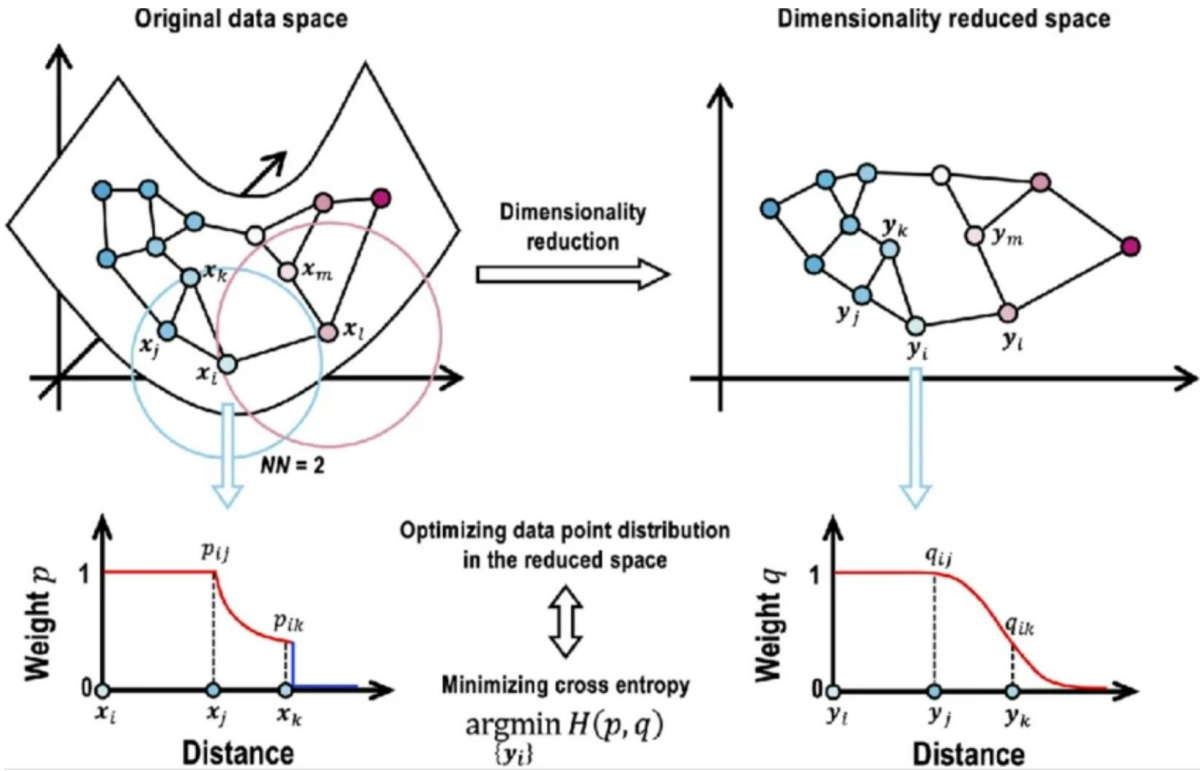
三.经典降维方法与案例实践

首都师范大学 CAPITAL NORMAL UNIVERSITY

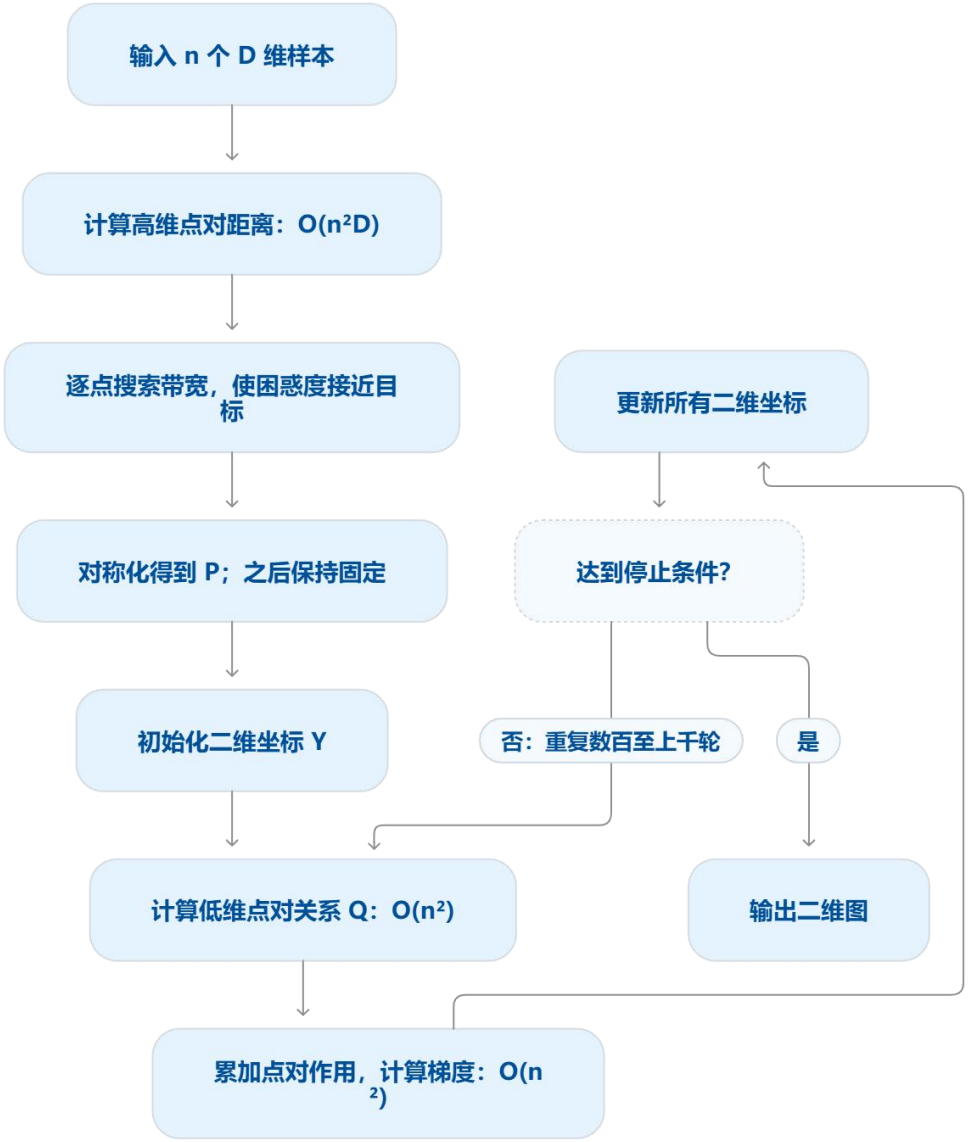
UMAP

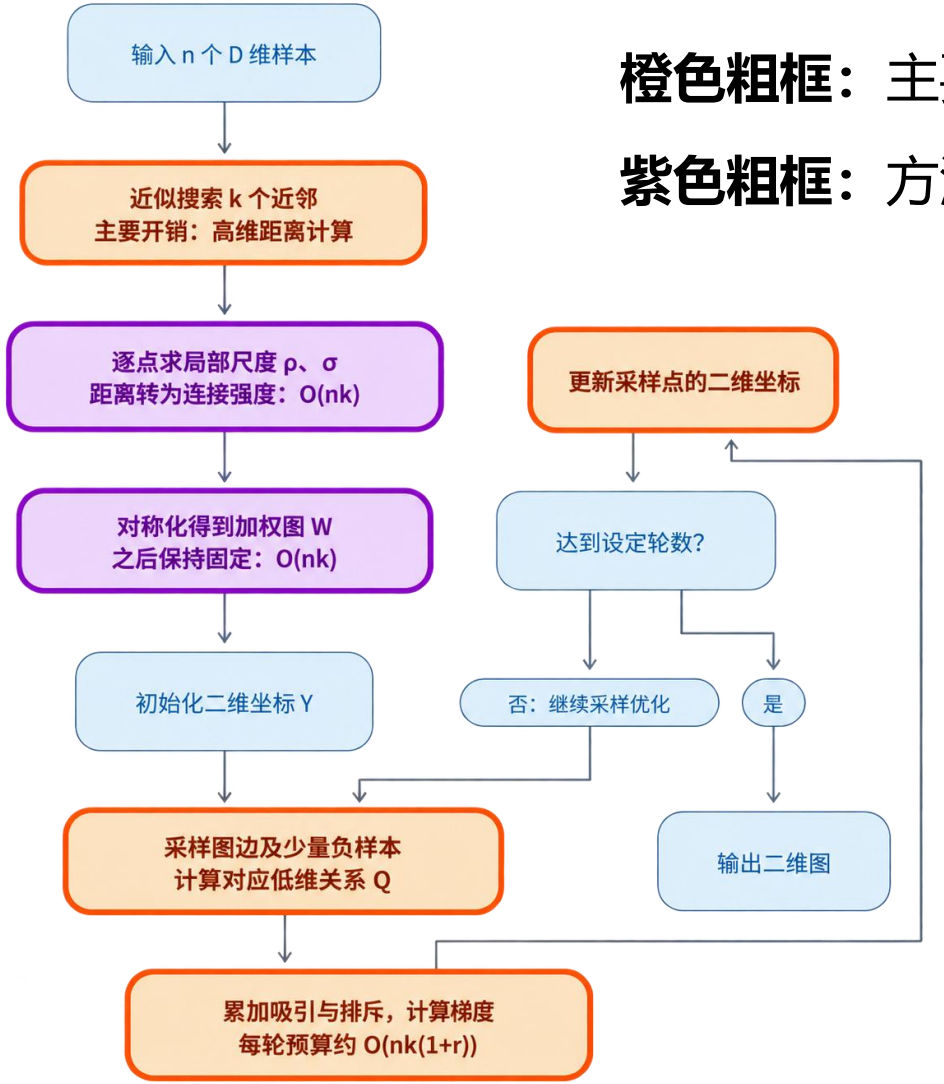
核心思想： 流形假设 → 局部邻域建模 → **低维拓扑保持**

UMAP Playground



三.经典降维方法与案例实践

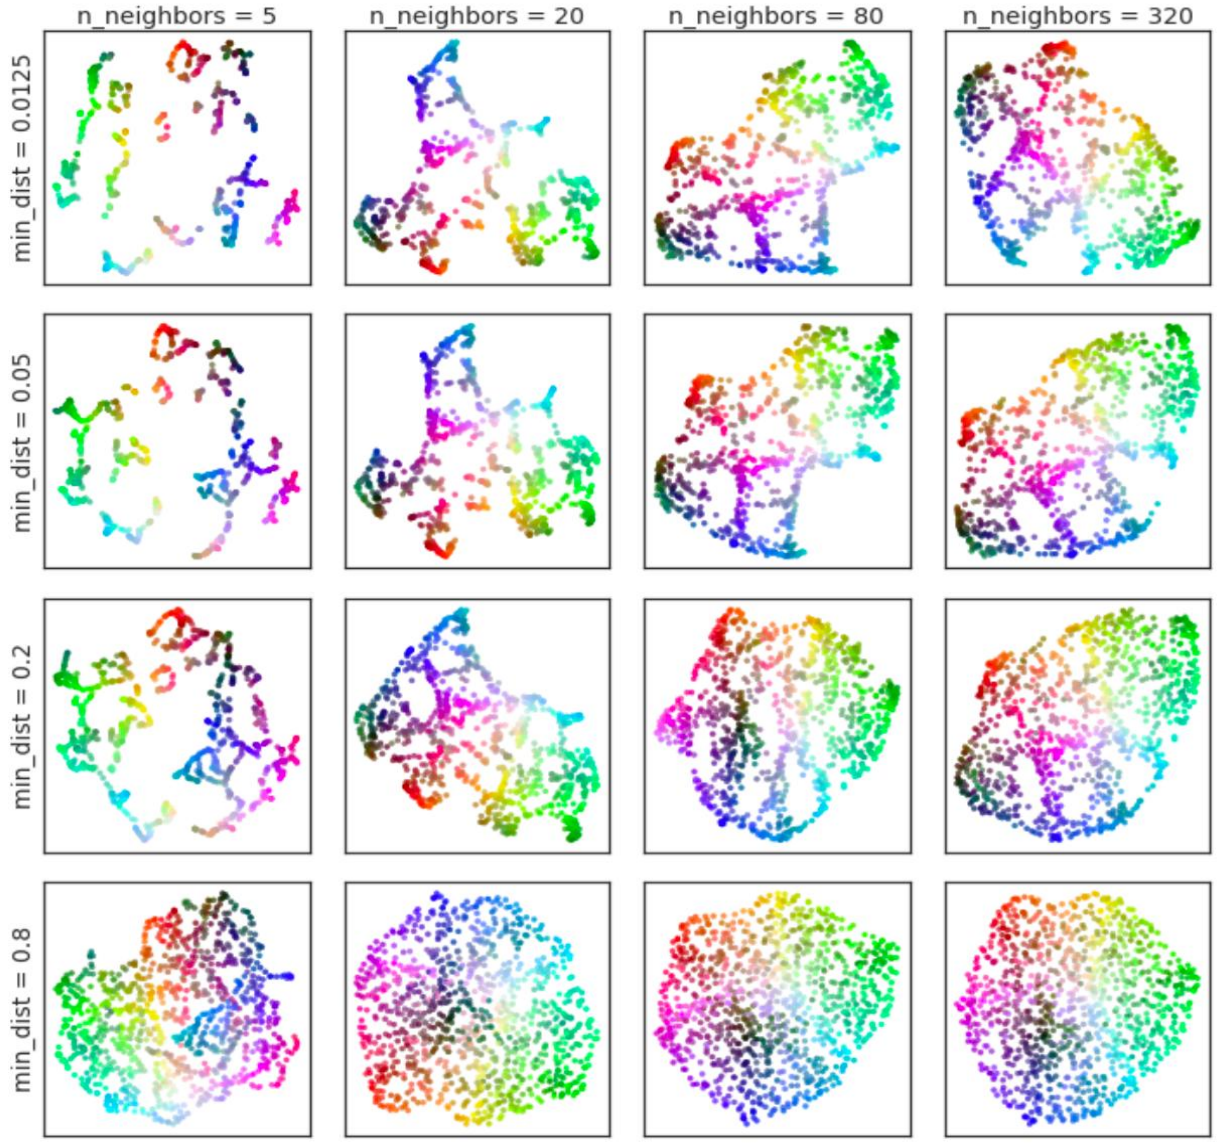




橙色粗框：主要加速环节

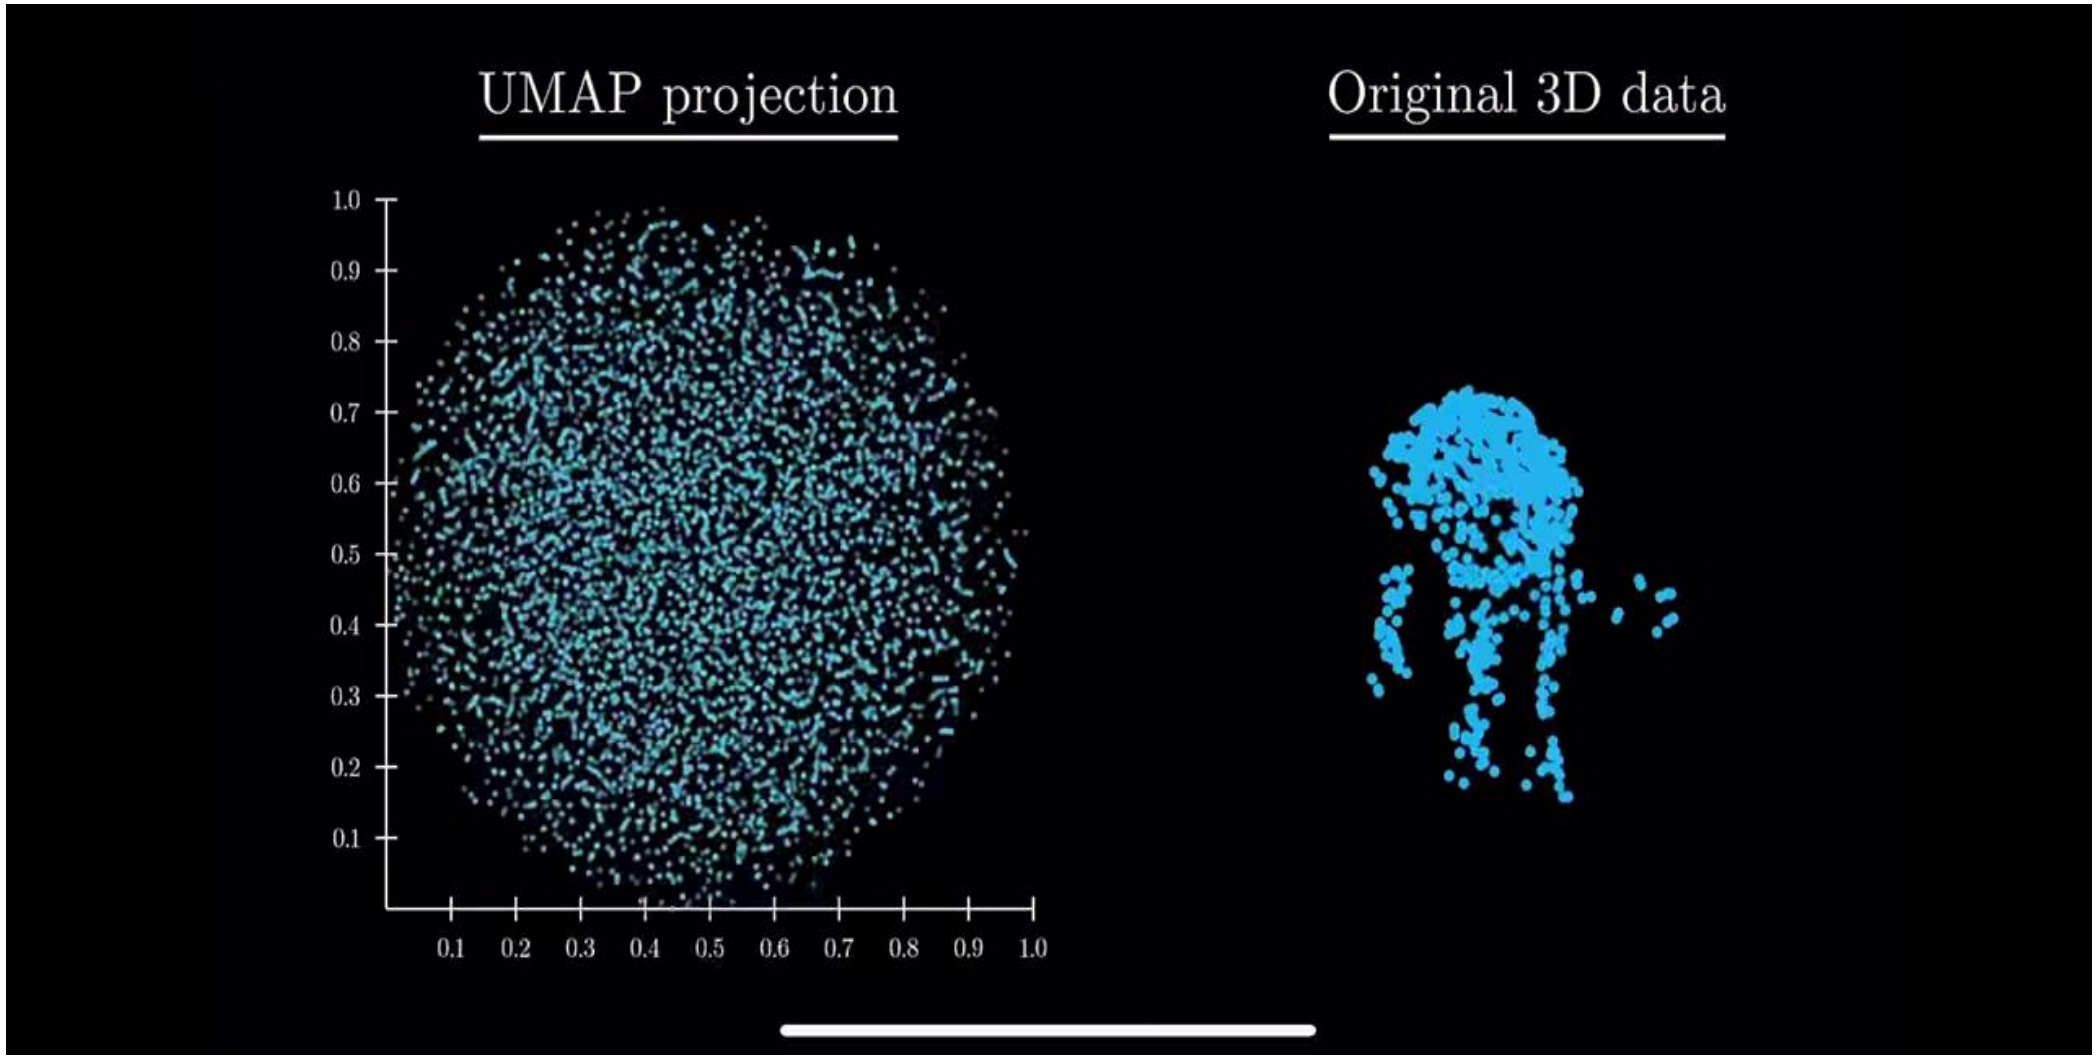
紫色粗框：方法差异

三.经典降维方法与案例实践



`n_neighbors`	改变建图的邻域范围；小值强调局部细节，大值关注更大尺度结构
`min_dist`	改变低维点的紧凑程度；小值通常形成更紧的团块，大值更松散

三.经典降维方法与案例实践



三.经典降维方法与案例实践

UMAP

高维空间中样本间的邻域关系要在低维空间保持

用**加权近邻图**刻画局部连接结构

在高维空间中，用**局部尺度**构建加权近邻图

在低维空间中，用距离函数刻画**连接强度**

优化目标：保持连接关系
边采样吸引，**负采样**排斥

可视化与一般降维
(支持新样本映射)

受参数与随机性影响

稀疏建图与负采样
通常计算更快

二.降维方法的发展图谱

保全局线性信息

PCA（1901）

MDS（1964）
Isomap（2000）

保样本间几何关系

保局部邻域结构

~~LLE（2000）~~
t-SNE（2008）
UMAP（2018）

Autoencoder（1986）
VAE（2013）

让模型自己学习低维表示

大纲

01 什么是降维

02 降维方法的发展图谱

03 经典降维方法与案例实践

04 从经典方法到前沿方法

四.从经典方法到前沿方法

可视化、数据结构探索分析

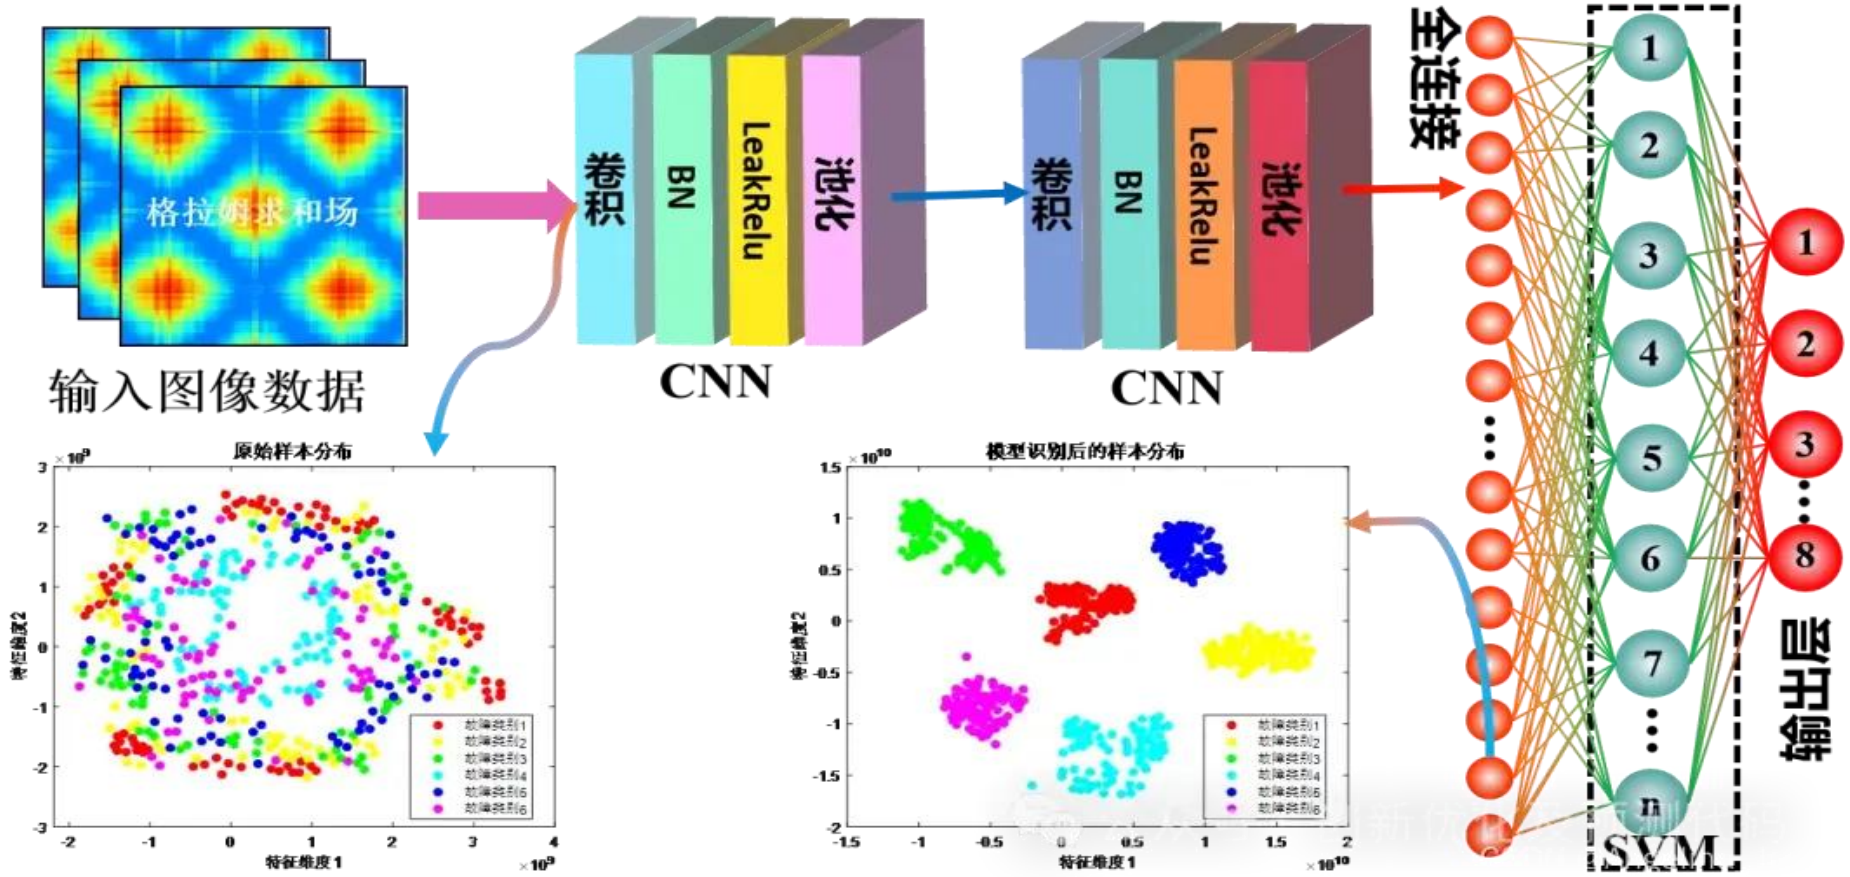


可视化、下游任务驱动

四.从经典方法到前沿方法

首都师范大学 CAPITAL NORMAL UNIVERSITY

神经网络降维中间过程的可视化





首都师范大学
CAPITAL NORMAL UNIVERSITY