




上一课总结

- 一. 什么是机器学习?
- 二. 机器学习发展史
- 三. 机器学习包含什么?
- 四. 机器学习通用流程
- 五. 基础概念介绍





上一课总结


无监督学习

数据 (无标签) : $(x_i)_{i=1}^l$

目标: 挖掘数据的内在结构和规律

■ 聚类: 对数据分组

■ 降维: 把数据投影到低维空间





第四课 线性模型

从线性模型了解机器学习基本流程

授课教师：潘贤丽



大纲



首都师范大学
CAPITAL NORMAL UNIVERSITY



机器学习
完整流程
(基础知识点)

线性回归

回顾机器学习基本流程




数据准备：收集数据

A1		房源编号																
	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R
1	房源编号	区域	小区名称	建筑面积	使用面积	卧室数	客厅数	卫生间数	所在楼层	总楼层	建成年份	房龄_年	朝向	装修程度	有无电梯	最近地铁站	距地铁站距离	步行到地铁
2	H0001	滨河区	晴川小筑	183.5平米	151.04	4	1	2	6	18	2022	4	南向	简装	有	松月里站	2.461公里	34.2
3	H0002	滨河区	青禾雅苑	152.2m²	124.99	4	1	2	5	6	2002	24	非南向	毛坯	无	青禾公馆站	1340米	19.5
4	H0003	滨河区	映湖雅苑	159.6平米	130.61	4	1	2	5	6	2002	24	非南向	简装	无	春和府邸站	0.302公里	4.8
5	H0004	大学城区	锦溪花园	151.2m²	123.54	4	1	2	2	12	2018	8	非南向	精装	有	松月花园站	256米	5.2
6	H0005	中心城区	锦溪府邸	149.2平米	122.35	4	1	2	13	26	2008	18	非南向	简装	有	松月家园站	0.197公里	4.2
7	H0006	中心城区	青禾公馆	150.4m²	123.79	4	1	2	7	12	2007	19	南向	毛坯	有	青禾花园站	876米	12.2
8	H0007	中心城区	星河府邸	171.6平米	140.61	4	1	2	3	6	1999	27	非南向	简装	无	锦溪里站	1.415公里	20.1
9	H0008	滨河区	望舒小筑	166.9m²	136.88	4	1	2	3	26	2006	20	南向	毛坯	有	春和家园站	942米	13.9
10	H0009	科技园区	春和里	34.7平米	28.38	1	1	1	15	18	2019	7	非南向	毛坯	有	云杉小区站	1.837公里	25.3
11	H0010	中心城区	和悦公馆	94.1m²	77.21	3	1	1	1	18	2008	18	南向	毛坯	有	映湖花园站	2250米	30.5
12	H0011	科技园区	晴川里	27.7平米	22.4	1	1	1	7	26	2006	20	非南向	简装	有	松月小区站	2.232公里	30.5
13	H0012	大学城区	晴川华庭	74.7m²	61.77	2	1	1	1	12	2023	3	非南向	简装	有	松月小筑站	2333米	32.7
14	H0013	大学城区	书香花园	64.6平米	52.8	2	1	1	5	12	2021	5	非南向	精装	有	锦溪花园站	0.940公里	13.6
15	H0014	滨河区	松月小筑	55.1m²	45.43	2	1	1	5	6	2005		南向	精装	无	云杉家园站	1102米	15.2
16	H0015	城北区	栖霞新村	85.6平米	69.77	3	1	1	2	6	2002	24	非南向		无	望舒小筑站	0.836公里	12.3
17	H0016	大学城区	青禾华庭	81.6m²	66.36	2	1	1	11	18	2017	9	非南向	简装	有	青禾雅苑站	1579米	21.6
18	H0017	中心城区	听雨公馆	102.3平米	83.53	3	1	2	12	12	2019	7	非南向	精装	有	映湖华庭站	2.478公里	34.5
19	H0018	中心城区	云杉府邸	47.9m²	39.31	1	1	1	2	6	2001		南向	简装	无	青禾里站	1964米	27.9
20	H0019	城北区	晴川新村	-35m²	73.83	3	1	1	12	12	2019	7	非南向	简装	有	松月小筑站	2.047公里	28.7
21	H0020	城北区	晴川新村	106.2m²	87.17	3	1	2	8	12	2019	7	南向	精装	有	松月小筑站	2105米	28.7
22	H0021	中心城区	映湖府邸	31.5平米	26.18	1	1	1	2	6	2005	21	非南向	简装	无	春和里站	2.365公里	32.7
23	H0022	滨河区	云杉小筑	58.9m²	48.33	2	1	1	1	6	1997	29	南向	毛坯	无	青禾里站	483米	8.3
24	H0023	中心城区	望舒府邸	69.4平米	56.92	2	1	1	7	26	2023	3	南向	毛坯	有	春和家园站	1.179公里	16.9
25	H0024	滨河区	星河小筑	45.0m²	36.82	1	1	1	4	12	2017	9	南向	精装	有	锦溪里站	1780米	25.7
26	H0025	大学城区	云杉华庭	88.4平米	72.33	3	1	1	4	6	1997	29	南向	毛坯	无	青禾小筑站	2.138公里	30.2
27	H0026	大学城区	清枫华庭	53.8m²	44.08	2	1	1	5	6	1999	27	南向	毛坯	无	晴川雅苑站		30.3
28	H0027	大学城区	星河花园	81.3平米	66.9	2	1	1	2	18	2017		南向		有	锦溪华庭站	1.895公里	27.1
29	H0028	中心城区	南苑公馆	41.7m²	34.63	1	1	1	6	18	2012	14	非南向	精装	有	望舒花园站	1851米	25.4
30	H0029	滨河区	映湖雅苑	35.7平米	28.93	1	1	1	1	6	2002	24	南向	简装	无	春和府邸站	0.395公里	5.8
31	H0030	滨河区	青禾小筑	90.6m²	74.06	3	1	1	2	6	1996	30	非南向	毛坯	无	青禾家园站	-300米	5.2
32	H0031	滨河区	松月小筑	92.5平米	75.76	3	1	1	1	6	2005	21	非南向	毛坯	无	云杉家园站	1.096公里	15.4
33	H0032	城北区	竹语小区	57.8m²	47.2	2	1	1	5	6	2003	23	非南向	毛坯	无	晴川小区站	793米	11.2
34	H0033	大学城区	晴川花园	106.0平米	86.81	2	1	2	2	26	2022	2	非南向	精装	有	松月华庭站	1.168公里	16.4



房源原始数据_v2.csv

回顾机器学习基本流程



先观察：这个
数据长啥样，
可以直接用吗？

400

条样本

38

个原始特征

1

个回归标签

典型回归问题：根据房屋信息，预测房屋月租金


X = 房屋各种信息

Y = 月租金

回顾机器学习基本流程







测试集只应用规则，不参与规则学习

标准化小例子

1 训练集确定

均值 = 60m^2
标准差 = 20m^2

2 保存这两个数

- 填补值
- 类别表
- 均值、标准差

3 测试房源: 80m^2

$$(80 - 60) \div 20 = 1$$

简化示例

案例代码分析

修正内容

缺失
异常
重复
信息泄露

转换形式

统一单位
编码类别
编码文字

对齐尺度

标准化

转换形式：让不同信息变成数值

单位数字 | 解析与换算

同一个指标，先统一单位

1.2公里 → 1200米

类别信息 | 编码

二元用0/1；无序多类别用独热编码

有 / 无 → 1 / 0

日期信息 | 提取时间特征

从日期或年份，提取任务相关的信息

建成年份 → 房龄

自由文字 | 提取特征

用关键词等方法，把文字表达成数值

“有阳台” → 提及 = 1

对齐尺度：减少数值范围的差异，让不同特征更容易共同参与计算

标准化

StandardScaler

$$x'_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}$$

$$\mu_j = \frac{1}{n} \sum_{i=1}^n x_{ij}, \quad \sigma_j = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_{ij} - \mu_j)^2}$$

归一化（最小-最大缩放）

MinMaxScaler

$$x'_{ij} = \frac{x_{ij} - x_{j,\min}}{x_{j,\max} - x_{j,\min}}$$


$$x_{j,\min} = \min_{1 \leq i \leq n} x_{ij}, \quad x_{j,\max} = \max_{1 \leq i \leq n} x_{ij}$$

数据准备：整理数据

原始数据



缺失、错误、格式与尺度问题



可用数据


X1	X2	X3	X4	X5
0.3	-0.8	1.2	0.0	1.0
-1.1	0.5	0.3	1.0	0.0
0.8	1.1	-0.6	0.0	1.0
-0.4	0.2	0.9	1.0	0.0
1.2	-1.0	-0.3	0.0	1.0
0.0	0.7	1.5	1.0	0.0
-0.9	-0.4	0.1	0.0	1.0
0.6	1.3	-1.1	1.0	...
...	...	...	...	...

- ✓ 无缺失与明显错误
- ✓ 无重复记录
- ✓ 全部数值化
- ✓ 数值尺度已对齐

杂乱的房源记录 → 整齐の数値特征表

案例代码分析


回顾机器学习基本流程



A	B	C	D	E	F	G	H	I
user_id	age	gender	province	city	registration_date	member_level	account_balance	credit_score
U000001	35	男	湖北	深圳	38:35.7	铜牌会员	5761.97	611
U000002	30	男	浙江	厦门	38:35.7	普通会员	1690.84	674
U000003	37	女	云南	杭州	38:35.7	银牌会员	139.39	800
U000004	44	男	江西	福州	38:35.7	铜牌会员	1114.76	540
U000005	30	男	河南	长沙	38:35.7	普通会员	2552.27	657
U000006	30	女	湖北	郑州	38:35.7	铜牌会员	916.99	693
U000007								659
U000008								651
U000009								611
U000010								654
U000011								650
U000012								636
U000013								686
U000014								697
U000015								690
U000016								683
U000017								670
U000018								719
U000019	24	女	河南	西安	38:35.7	钻石会员	3752.78	629
U000020	20	女	重庆	苏州	38:35.7	金牌会员	3754.17	641
U000021	43	女	上海	天津	38:35.7	普通会员	7171.9	539
U000022	30	女	陕西	重庆	38:35.7	钻石会员	2222.05	765
U000023	32	女	广西	西安	38:35.7	银牌会员	6307.97	575
U000024	20	女	湖北	上海	38:35.7	金牌会员	4314.84	707
U000025	27	男	陕西	北京	38:35.7	铜牌会员	16330.55	708
U000026	32	女	四川	上海	38:35.7	铜牌会员	2432.98	681
U000027	22	男	陕西	合肥	38:35.7	铜牌会员	11574.12	631

训练数据：
(X_train, Y_train)

12大机器学习算法



回归算法 | 决策树 | 随机森林 | 聚类算法
关联规则 | 贝叶斯算法 | 神经网络算法



监督学习：回归

数据： $(x_i, y_i)_{i=1}^l$

学习： $f: x \rightarrow y$

目标：对未知 x ，预测 $y = f(x)$

$$f(x) = w^T x + b$$

线性模型

$$f(x) = ae^{bx}$$

$$f(x) = ax^5 + bx^3 + cx$$

.....

结构简单

把各项特征加权相加



便于解释

查看各特征的模型系数



计算高效

通常训练快，预测开销小



适合作为基准

先建立一个可比较的起点



房租预测的线性模型，长什么样？



一套房源 → 269个特征

标准化后的面积

是否有电梯 (0/1)

描述是否提及采光 (0/1)


...

16个数值 + 250个独热 + 3个关键词

$$\hat{y} = w_1x_1 + w_2x_2 + \cdots + w_{269}x_{269} + b$$

$$\hat{y} = w^T x + b$$

每个特征，对应一个权重



b : 截距
(整体偏移)



$\hat{y}$: 预测月租金

单位：元/月


x : 房源提供的已知信息

w 、 b : 需要从数据中学出的参数

该怎么确定 w ， b 的具体取值？



回顾机器学习基本流程



要先定义清楚模型怎么才算表现得好？

然后找出让模型表现好的参数的取值

定义损失函数

确定训练目标

求解模型参数


模型训练：训练模型

① 一套房子：预测与实际差多少？

$$\hat{y}_i = \mathbf{w}^\top \mathbf{x}_i + b \quad e_i = y_i - \hat{y}_i$$

② 所有房子：整体预测得怎样？ MSE/MAE

$$L(\mathbf{w}, b) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \mathbf{w} - b)^2$$



损失函数： 量化预测值与真实值之间的差异。

模型训练：训练模型

矩阵等价表达式：

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix} \in \mathbb{R}^{n \times p}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \in \mathbb{R}^n$$

$$\mathbf{w} = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_p \end{bmatrix} \in \mathbb{R}^p, \quad \mathbf{1} = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} \in \mathbb{R}^n$$

$$L(\mathbf{w}, b) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \mathbf{w} - b)^2$$

$$= \|\mathbf{y} - \mathbf{X}\mathbf{w} - b\mathbf{1}\|_2^2$$

如何处理截距项b，简化模型：

方法一：合并参数——将截距纳入参数向量

给每个样本增加一个恒为 1 的特征：

$$\tilde{\mathbf{x}}_i = \begin{bmatrix} 1 \\ \mathbf{x}_i \end{bmatrix}, \quad \tilde{\mathbf{w}} = \begin{bmatrix} b \\ \mathbf{w} \end{bmatrix}$$

模型统一写为：

$$\hat{y}_i = \tilde{\mathbf{x}}_i^\top \tilde{\mathbf{w}}$$

截距与权重一起求解，无需单独处理。

方法二：中心化——先求权重，再恢复截距

将训练集的每个特征和标签分别减去各自均值：

$$\mathbf{x}_{i,c} = \mathbf{x}_i - \bar{\mathbf{x}}, \quad y_{i,c} = y_i - \bar{y}$$

在中心化数据上求解不含截距的最小二乘问题：

$$\{\hat{\mathbf{w}} = \arg \min_{\mathbf{w}} \sum_{i=1}^n (y_{i,c} - \mathbf{x}_{i,c}^\top \mathbf{w})^2$$

求解后恢复截距：

$$\hat{b} = \bar{y} - \bar{\mathbf{x}}^\top \hat{\mathbf{w}}$$

预测时使用完整模型：

$$\hat{y}_{\text{new}} = \mathbf{x}_{\text{new}}^\top \hat{\mathbf{w}} + \hat{b}$$

定义损失函数

$$L(\boldsymbol{w}) = \|\boldsymbol{y}_c - \boldsymbol{X}_c \boldsymbol{w}\|_2^2$$

确定训练目标

$$\min_{\boldsymbol{w}} L(\boldsymbol{w}) = \min_{\boldsymbol{w}} \|\boldsymbol{y}_c - \boldsymbol{X}_c \boldsymbol{w}\|_2^2$$

求解模型参数

最优化方法

① 展开损失函数

$$\begin{aligned} L(w) &= \|y_c - X_c w\|_2^2 \\ &= (y_c - X_c w)^\top (y_c - X_c w) \\ &= y_c^\top y_c - 2w^\top X_c^\top y_c + w^\top X_c^\top X_c w \end{aligned}$$

② 对参数 w 求导

$$\nabla_w L(w) = -2X_c^\top y_c + 2X_c^\top X_c w$$

③ 令梯度为零，得到正规方程

$$-2X_c^\top y_c + 2X_c^\top X_c w = 0$$

$$X_c^\top X_c w = X_c^\top y_c$$

④ 当 $X_c^\top X_c$ 可逆时，得到唯一解

$$w^* = (X_c^\top X_c)^{-1} X_c^\top y_c$$

但实际上，我们一般不这么求解

SVD (奇异值分解)

</> Python



运行

```
import numpy as np

w, *_ = np.linalg.lstsq(X_centered, y_centered, rcond=None)
```

</> Python



运行

```
from sklearn.linear_model import LinearRegression

model = LinearRegression()
model.fit(X_train, y_train)

w = model.coef_
b = model.intercept_
```

要先定义清楚模型怎么才算表现得好？

然后找出让模型表现好的参数的取值

定义损失函数

确定训练目标

求解模型参数

把三个概念分清

模型

用什么形式预测？

线性加权求和再加上截距

损失函数

怎样比较预测好坏？

用平方误差衡量整体偏差


求解方法

怎样找到合适参数？

解析方法或梯度下降等

案例代码分析

回顾机器学习基本流程



这个模型好不好用怎么看？

01

拟合效果

训练时见过的房子，预测得准吗？

02

稳定性

数据变化了，模型稳定吗？

03

泛化能力

没见过的房子，预测得好吗？

本节先讲这两项

拟合效果：平均差多少，是否有大误差？

MAE 平均绝对误差

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

RMSE 均方根误差

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

评估指标不要求方便计算，也不必与训练损失相同。


稳定性：改变什么，观察什么？

怎样改变训练数据	参数稳定性	预测稳定性
小幅扰动 给训练租金加入少量噪声	同一个权重 是否明显变化？	同一套房子的预测租金 是否明显变化？
重复抽样 从训练集中反复抽取房源	换一批训练样本 权重是否稳定？	换一批训练样本 对同一套房的预测是否稳定？

参数变化大，预测不一定变化大；预测很稳定，也不代表预测很准确。

案例代码分析

回顾机器学习基本流程



① 展开损失函数

$$\begin{aligned} L(w) &= \|y_c - X_c w\|_2^2 \\ &= (y_c - X_c w)^\top (y_c - X_c w) \\ &= y_c^\top y_c - 2w^\top X_c^\top y_c + w^\top X_c^\top X_c w \end{aligned}$$

② 对参数 w 求导

$$\nabla_w L(w) = -2X_c^\top y_c + 2X_c^\top X_c w$$

③ 令梯度为零，得到正规方程

$$-2X_c^\top y_c + 2X_c^\top X_c w = 0$$

$$X_c^\top X_c w = X_c^\top y_c$$

④ 当 $X_c^\top X_c$ 可逆时，得到唯一解

$$w^* = (X_c^\top X_c)^{-1} X_c^\top y_c$$

$X_c^\top X_c$ 有可能不可逆


- 特征存在多重共线性
- 高维回归 (特征维度 $p >$ 样本数量 n)

什么是多重共线性？

多个特征之间存在精确或近似的线性关系。



例如：两种面积高度相关。



也可能是多个特征的线性组合相关。

可能带来什么？

1 系数很大，预测却变化不大

相关项相互抵消。

若 $x_2 = x_1$

$$2x_1 + 3x_2 = 100x_1 - 95x_2 = 5x_1。$$



2 单个系数难以解释

大小、正负可能不稳定。

难以区分各特征的独立贡献。



3 对某些微小扰动敏感

数据稍变，系数可能大幅变化。

预测是否变化，取决于特征关系。



参数不稳定 ≠ 预测一定不稳定。

1 发现问题



相关特征的系数可能相互抵消



换一批样本，估计可能变化

2 提出问题

?

拟合数据的同时，
能否**约束过大的系数**？


3 正则化



在拟合误差之外，
加入对参数的约束

下一次课：正则化 · Ridge 与 Lasso · 房租案例对比

回顾机器学习基本流程



这个模型好不好用怎么看？

01

拟合效果

训练时见过的房子，预测得准吗？

02

稳定性

数据变化了，模型稳定吗？

03

泛化能力

没见过的房子，预测得好吗？

指标：MSE、MAE

训练集评估



见过的房源



看拟合效果

测试集评估




没见过的新房源



看泛化表现

案例代码分析

回顾机器学习基本流程



① 数据准备

收集与了解数据

房源样本、特征与租金标签

规范化整理

统一文本与单位，识别缺失与异常

划分数据

训练集 / 测试集，避免数据泄露

学习预处理规则

仅用训练集学习填补值、编码与标准化参数
保存规则，应用到测试集

② 模型训练

选择模型

线性回归：特征 $\rightarrow$ 租金
权重与截距；向量、矩阵表达

训练求解

MSE损失与最小二乘
中心化；解析解及其适用条件
直接求逆 vs sklearn数值求解

评估模型

拟合效果：训练集 MAE、RMSE
稳定性：小扰动、重复抽样
观察参数与固定房源预测的波动
共线性：系数可相互抵消，解释需谨慎

参数不稳定 $\neq$ 预测不稳定

反馈改进 (下次课)

正则化：本次仅引出，
暂不展开

③ 测试与预测

输入新数据

沿用训练集的预处理规则

使用已训练模型

固定参数，只做预测

检验泛化能力

在未参与训练的数据上评估
仍用 MSE、MAE 等误差指标

指标没变，评估的数据变了

本次课核心概念速查

损失函数

01

衡量预测与真实标签的差距，
为训练提供优化目标。

思考：损失函数 vs 评价指标？

模型参数

02

通过训练确定的数值，决定
如何把输入转换为预测。

训练与测试

03

训练：利用训练数据学习参数。

测试：固定模型，用新数据检验。

多重共线性

04

某个特征可由其他特征的线性
组合精确或近似表示。

稳定性

05

训练数据变化后，重新训练的
参数或预测结果变化有多大。

泛化能力

06

模型对未参与训练的新数据
的预测能力。

谢谢



首都师范大学

CAPITAL NORMAL UNIVERSITY