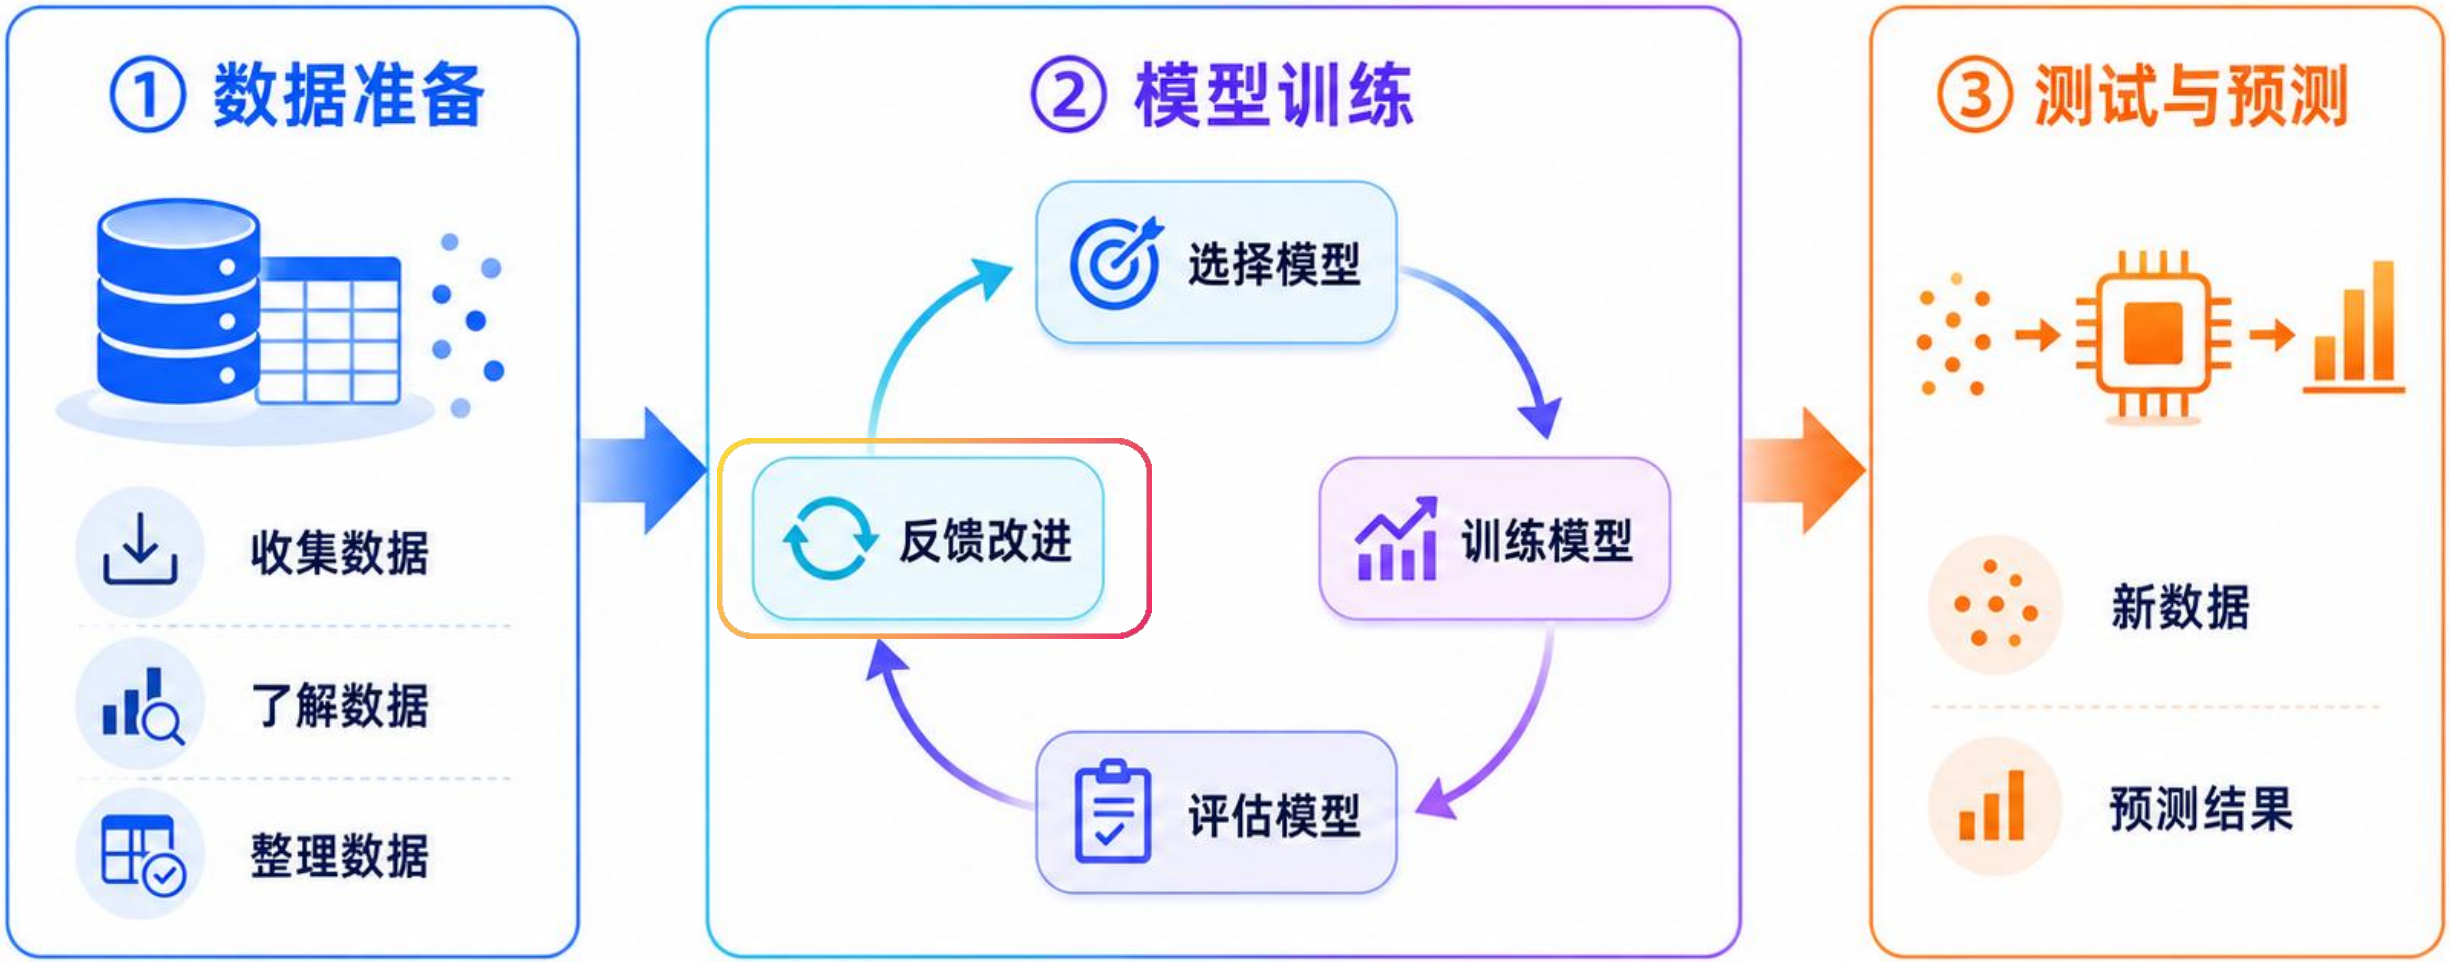
首都师范大学
CAPITAL NORMAL UNIVERSITY



第五课　正则化

授课教师：潘贤丽

回顾机器学习基本流程


① 数据准备
收集数据
了解数据
整理数据
② 模型训练
选择模型
训练模型
评估模型
反馈改进
③ 测试与预测
新数据
预测结果

模型训练：反馈改进

首都师范大学 CAPITAL NORMAL UNIVERSITY

① 展开损失函数

$$
\begin{aligned}
L(\boldsymbol{w}) &= \|\boldsymbol{y}_c - \boldsymbol{X}_c\boldsymbol{w}\|_2^2 \\
&= (\boldsymbol{y}_c - \boldsymbol{X}_c\boldsymbol{w})^{\mathsf{T}}(\boldsymbol{y}_c - \boldsymbol{X}_c\boldsymbol{w}) \\
&= \boldsymbol{y}_c^{\mathsf{T}}\boldsymbol{y}_c - 2\boldsymbol{w}^{\mathsf{T}}\boldsymbol{X}_c^{\mathsf{T}}\boldsymbol{y}_c + \boldsymbol{w}^{\mathsf{T}}\boldsymbol{X}_c^{\mathsf{T}}\boldsymbol{X}_c\boldsymbol{w}
\end{aligned}
$$

② 对参数 w 求导

$$
\nabla_{\boldsymbol{w}} L(\boldsymbol{w}) = -2\boldsymbol{X}_c^{\mathsf{T}}\boldsymbol{y}_c + 2\boldsymbol{X}_c^{\mathsf{T}}\boldsymbol{X}_c\boldsymbol{w}
$$

③ 令梯度为零，得到正规方程

$$
-2\boldsymbol{X}_c^{\mathsf{T}}\boldsymbol{y}_c + 2\boldsymbol{X}_c^{\mathsf{T}}\boldsymbol{X}_c\boldsymbol{w} = \boldsymbol{0}
$$

$$
\boxed{\boldsymbol{X}_c^{\mathsf{T}}\boldsymbol{X}_c\boldsymbol{w} = \boldsymbol{X}_c^{\mathsf{T}}\boldsymbol{y}_c}
$$

④ 当 $\boldsymbol{X}_c^{\mathsf{T}}\boldsymbol{X}_c$ 可逆时，得到唯一解

$$
\boxed{\boldsymbol{w}^* = \left(\boldsymbol{X}_c^{\mathsf{T}}\boldsymbol{X}_c\right)^{-1}\boldsymbol{X}_c^{\mathsf{T}}\boldsymbol{y}_c}
$$

$X_c^T X_c$有可能不可逆

- 特征存在**多重共线性**
- 高维回归（特征维度p >样本数量n）

大纲

01 正则化

02 完善机器学习基本流程

正则化

特征存在多重共线性

高维回归（特征维度p >样本数量n）

解不唯一

系数估计不稳定

算特征间的相关系数，去掉相关性很强的特征

正则化

高维回归（特征维度p >样本数量n）

存在多个特征的隐性线性依赖

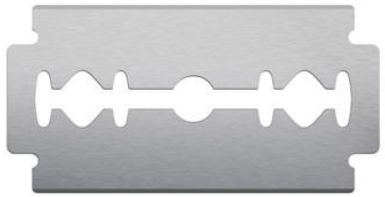
降维，如PCA、UMAP

还有没有别的办法呢?



奥卡姆剃刀原则





OCCAM'S RAZOR

The simplest explanation is usually the correct one.

总结：简单点，解决问题的方式简单点~



在线性回归里，什么叫简单的模型?

系数小

非零系数少

正则化

归纳偏好

模型：

$$min \quad \underbrace{\frac{1}{2}||y - Xw||_2^2}_{\text{损失函数}} + \underbrace{\boldsymbol{\lambda||w||_p}}_{\text{正则化项}}$$

岭回归（$p = 2$）

Lasso（$p = 1$）

p **−范数定义：** $||w||_p = (\sum_{i=1}^{m} |w_i|^p)^{\frac{1}{p}}$

正则化:岭回归

模型： $\min_w \frac{1}{2}||y - Xw||_2^2 + \boldsymbol{\lambda}||w||_2^2$

等价形式：

$$\min_w \frac{1}{2}||y - Xw||_2^2$$
$$s.t. \quad ||w||_2^2 \leq \boldsymbol{t}$$

非负参数$\boldsymbol{\lambda}$和$\boldsymbol{t}$是模型的调整参数（在机器学习里也称**“超参数”**），需人为确定其取值。

正则化:岭回归

岭回归模型：

$$\min_{w} \frac{1}{2}||y - Xw||_2^2 + \lambda||w||_2^2$$

求解： $w^*(\lambda) = (X^TX + 2\lambda I)^{-1}X^Ty$

若X^TX是奇异矩阵，添加λI可保证该项可逆，增强模型稳定性

随着λ的增大，$w^*(\lambda)$各元素的取值（绝对值）不断变小，最终趋于0

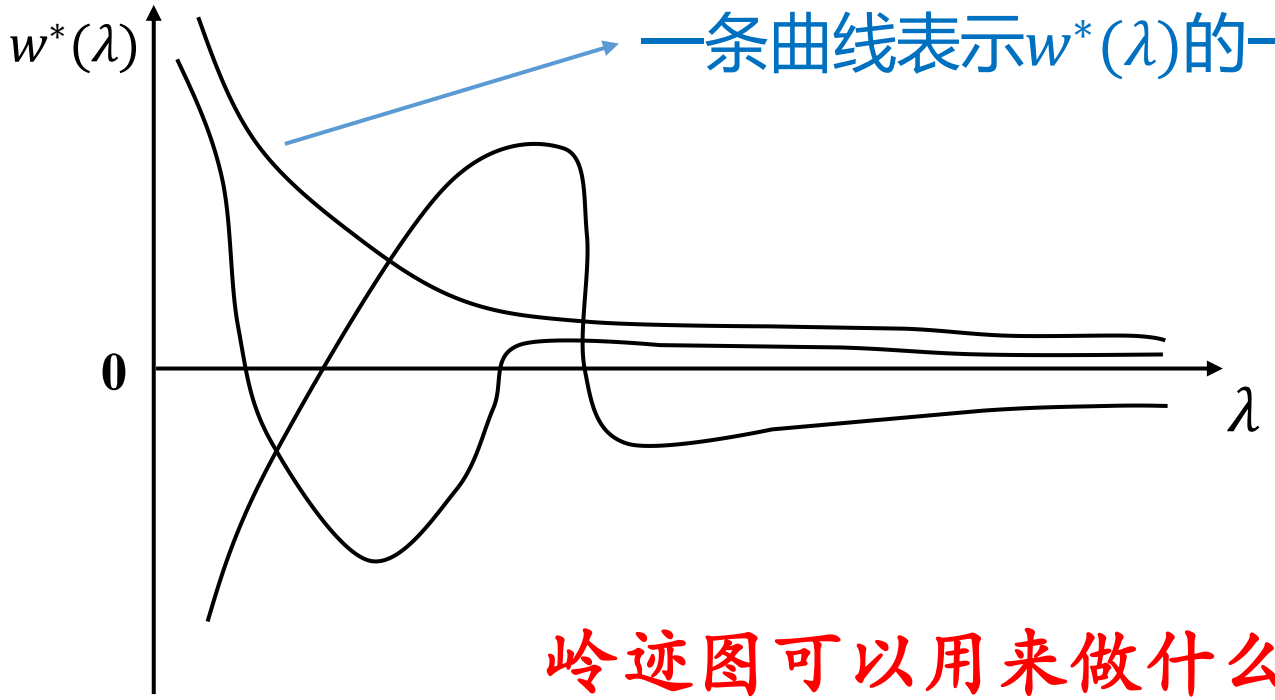
最小二乘解： $w^* = (X^TX)^{-1}X^Ty$

正则化:岭回归

岭迹图： 模型系数$w^*(\lambda)$随参数λ变化的曲线图

模型： $\min_w \frac{1}{2}||y - Xw||_2^2 + \lambda||w||_2^2$

解： $w^*(\lambda) = (X^TX + 2\lambda I)^{-1}X^Ty$

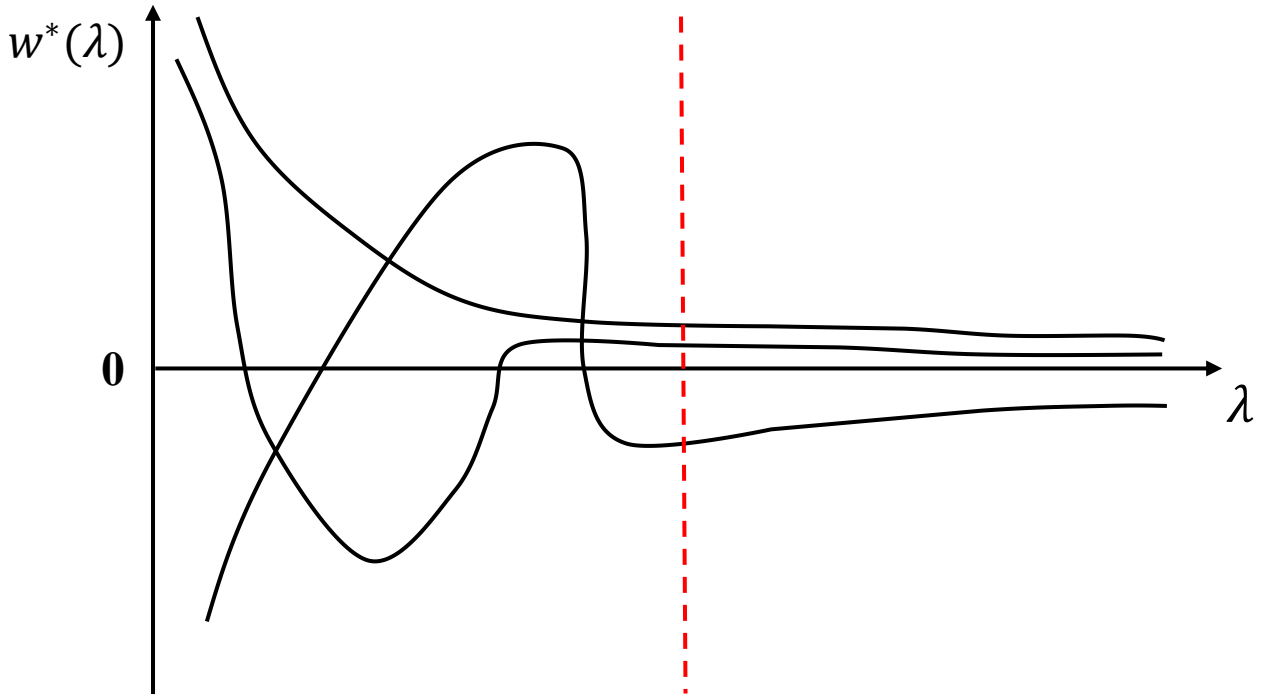


岭迹图可以用来做什么？

正则化:岭回归

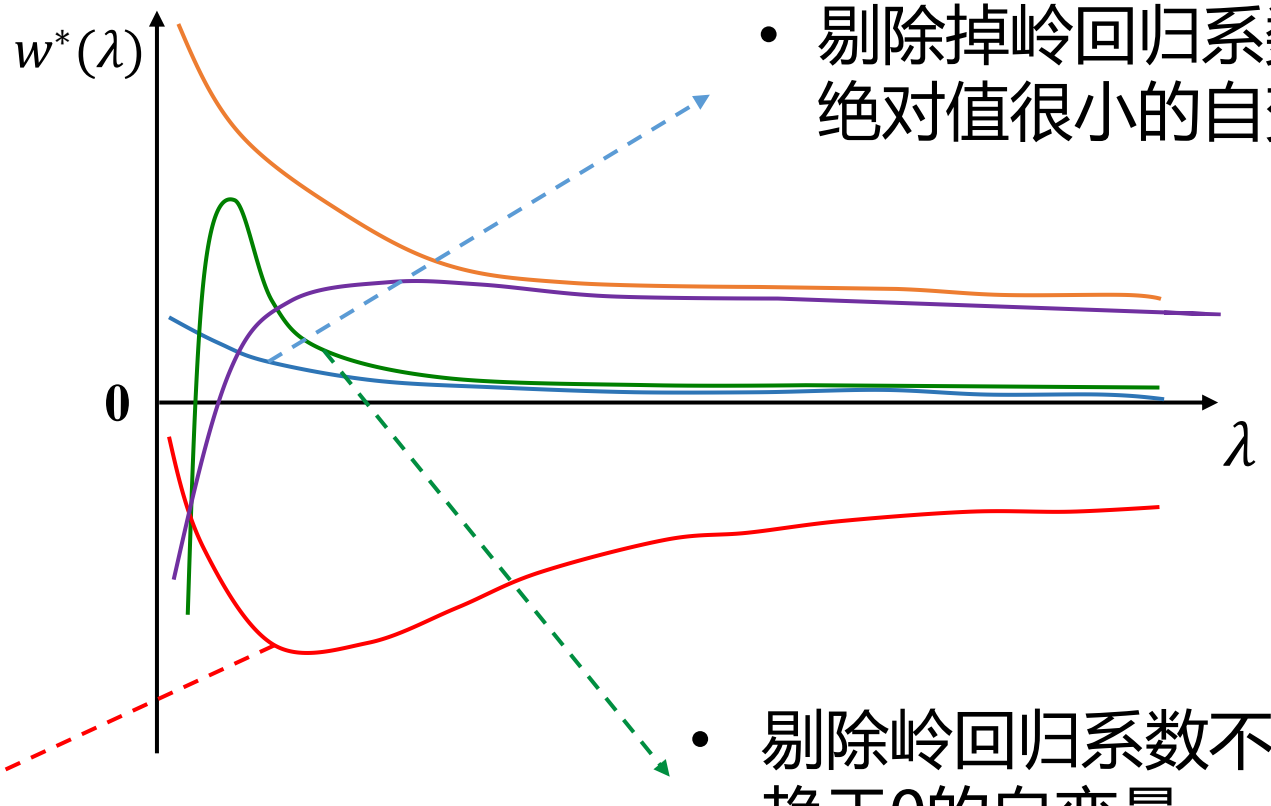
岭回归模型的解：

$$w^*(\lambda) = (X^T X + 2\lambda I)^{-1} X^T y$$



作用一：确定适当的λ

正则化:岭回归



- 剔除掉岭回归系数比较稳定且绝对值很小的自变量
- 剔除岭回归系数不稳定且震动很快趋于0的自变量
- 在最小二乘中被低估的变量

作用二：分析/选择自变量

正则化:岭回归

最小二乘:

$$\min_w \frac{1}{2}||y - Xw||_2^2$$

解:

$$w^* = (X^T X)^{-1} X^T y$$

岭回归:

$$\min_w \frac{1}{2}||y - Xw||_2^2 + \boldsymbol{\lambda}||\boldsymbol{w}||_2^2$$

解:

$$w^*(\lambda) = (X^T X + 2\boldsymbol{\lambda}\boldsymbol{I})^{-1} X^T y$$

- 正则化项，解决不可逆问题
- 会缩小系数

正则化

归纳偏好

模型：

$$min \quad \underbrace{\frac{1}{2}||y - Xw||_2^2}_{\text{损失函数}} + \underbrace{\boldsymbol{\lambda}||\boldsymbol{w}||_{\boldsymbol{p}}^{\boldsymbol{p}}}_{\text{正则化项}}$$

岭回归（$p = 2$）

Lasso（$p = 1$）

p **−范数定义：** $||w||_p = (\sum_{i=1}^{m} |w_i|^p)^{\frac{1}{p}}$

正则化:Lasso

模型： $\min_w \frac{1}{2}||y - Xw||_2^2 + \lambda||w||_1$

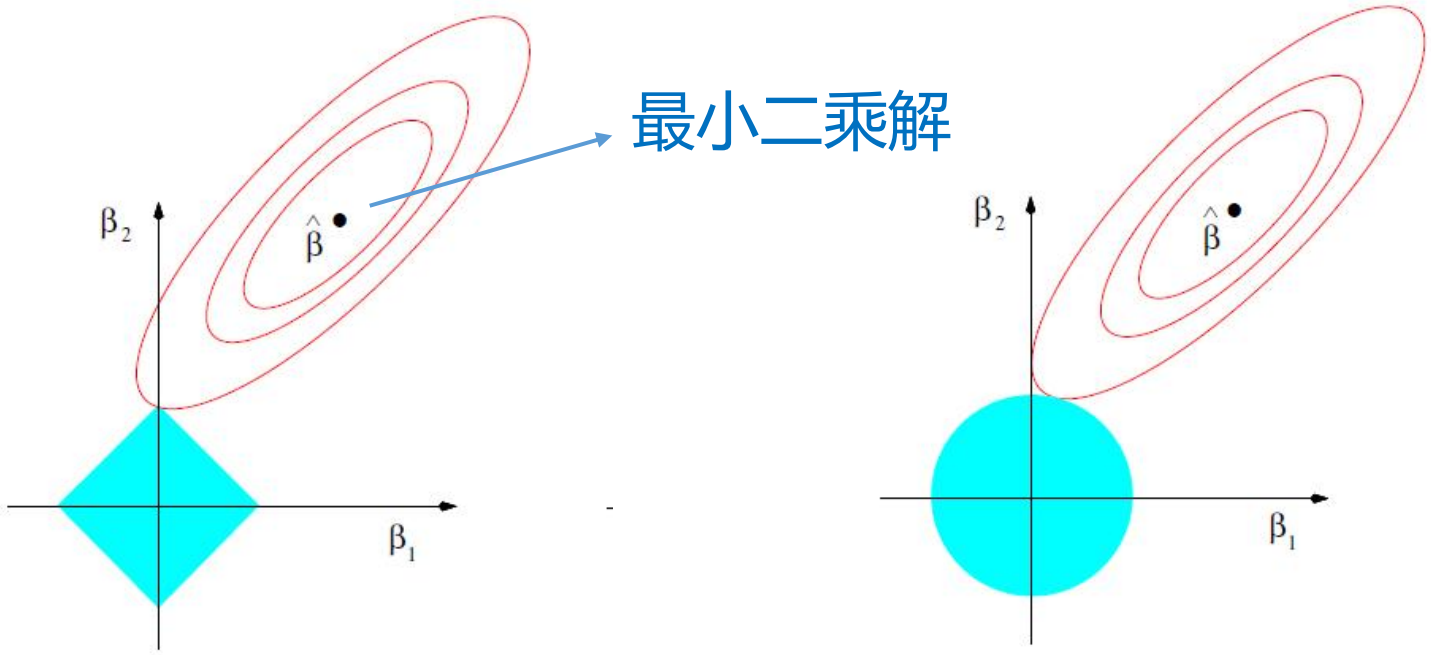
等价形式：

$$\min_w \frac{1}{2}||y - Xw||_2^2$$

$$s.t. ||w||_1 \leq t$$

为什么换成一范数，
就实现了特征选择?

正则化:岭回归 vs Lasso



Lasso:

$$\min_{\beta_1,\beta_2} \frac{1}{2}||y - x_1\beta_1 - x_2\beta_2||_2^2$$

$$s.t. \quad |\beta_1| + |\beta_2| \leq 1$$

岭回归:

$$\min_{\beta_1,\beta_2} \frac{1}{2}||y - x_1\beta_1 - x_2\beta_2||_2^2$$

$$s.t. \quad \beta_1^2 + \beta_2^2 \leq 1$$

正则化:Lasso

模型： $\min_w \frac{1}{2}||y - Xw||_2^2 + \lambda||w||_1$

等价形式：

$$\min_w \frac{1}{2}||y - Xw||_2^2$$

$$s.t. ||w||_1 \leq t$$

解有没有显式表达式?

回归：Lasso

最小二乘: $\min_w \frac{1}{2}||y - Xw||_2^2$

解： $w^* = (X^T X)^{-1} X^T y$

岭回归: $\min_w \frac{1}{2}||y - Xw||_2^2 + \boldsymbol{\lambda}||\boldsymbol{w}||_2^2$

解： $w^*(\lambda) = (X^T X + 2\boldsymbol{\lambda I})^{-1} X^T y$

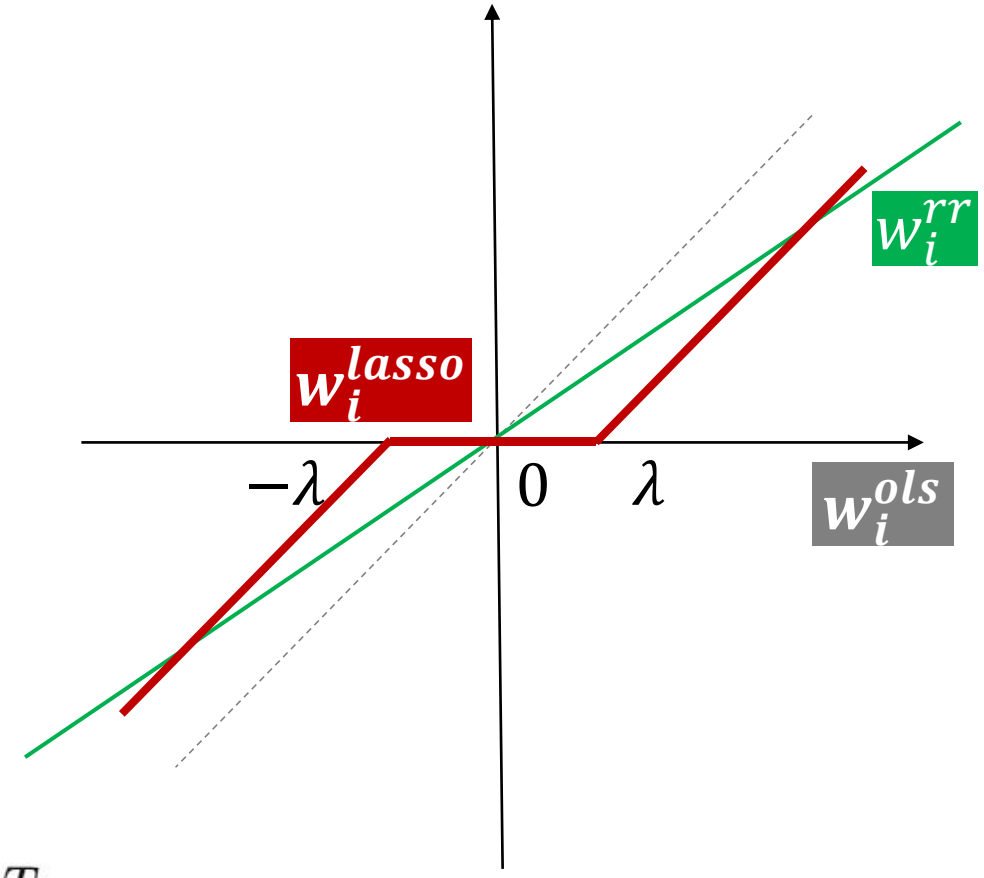
Lasso: $\min_w \frac{1}{2}||y - Xw||_2^2 + \boldsymbol{\lambda}||\boldsymbol{w}||_1$

解： ？

$$\hat{w}_j = \begin{cases} z_j - \lambda, & z_j > \lambda \\ 0, & |z_j| \le \lambda \\ z_j + \lambda, & z_j < -\lambda \end{cases} = \text{sign}(z_j) \cdot \max(|z_j| - \lambda, 0)$$

$$z = X^T y$$

考虑若$\boldsymbol{X^T X = I}$:



正则化:Lasso

模型： $\min_w \frac{1}{2}||y - Xw||_2^2 + \lambda||w||_1$

等价形式：

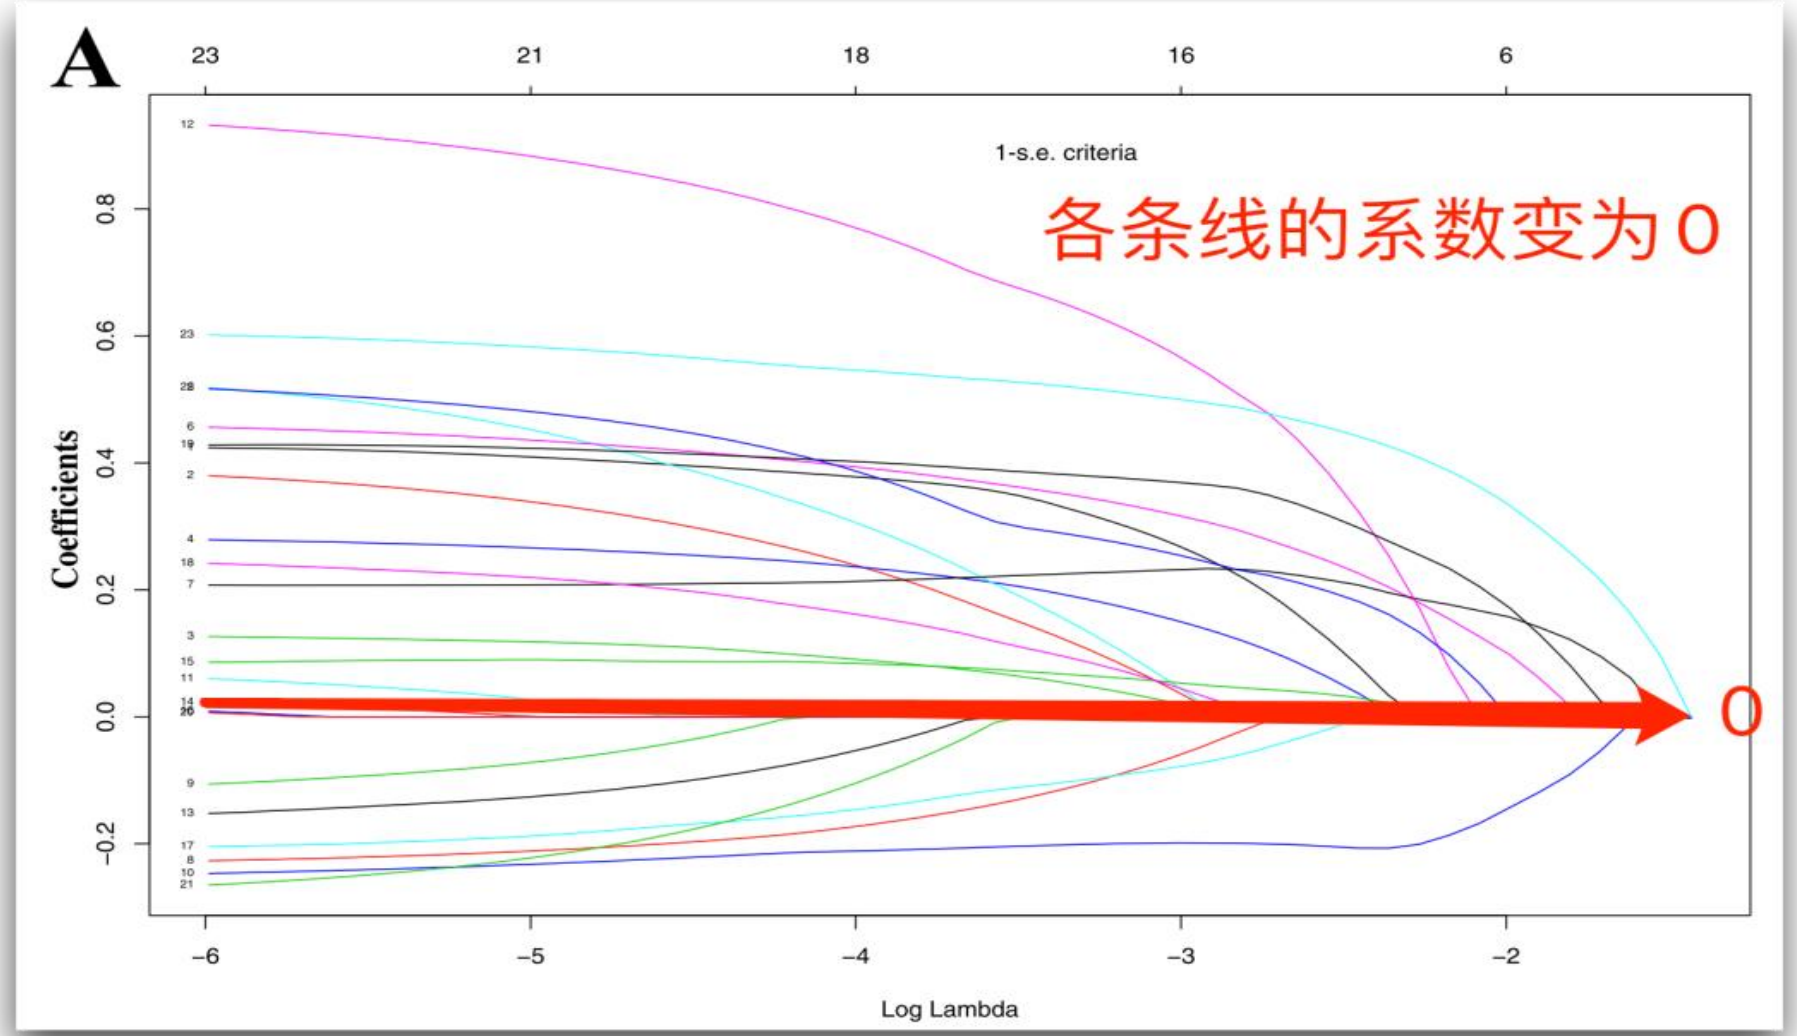
$$\min_w \frac{1}{2}||y - Xw||_2^2$$

$$s.t.\ ||w||_1 \leq t$$

解关于λ怎么变化?

正则化:Lasso

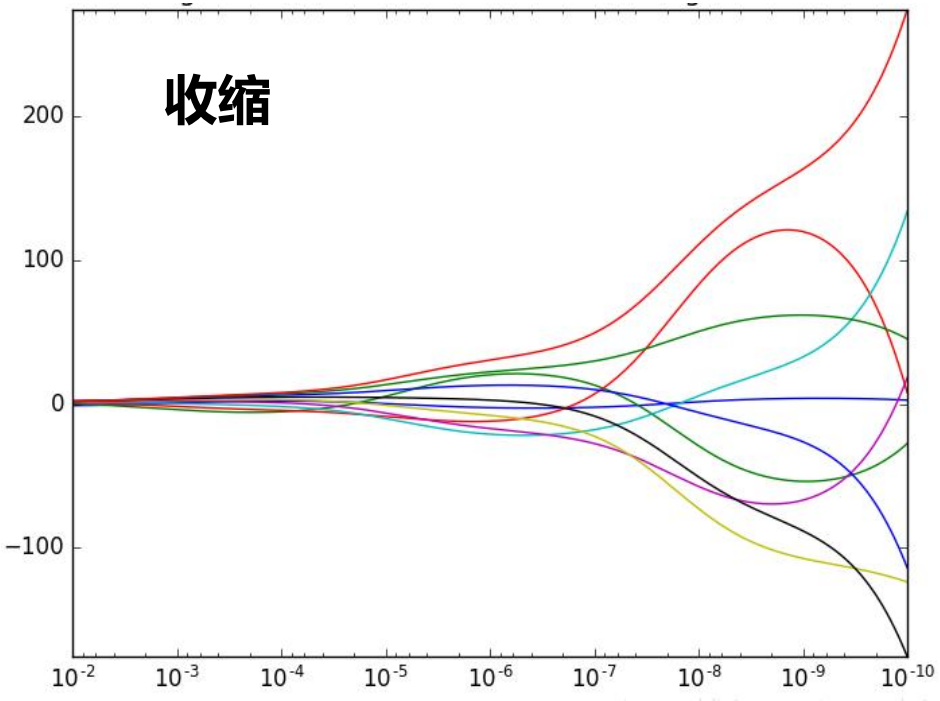
Lasso: $\min_w \frac{1}{2}||y - Xw||_2^2 + \boldsymbol{\lambda}||\boldsymbol{w}||_1$

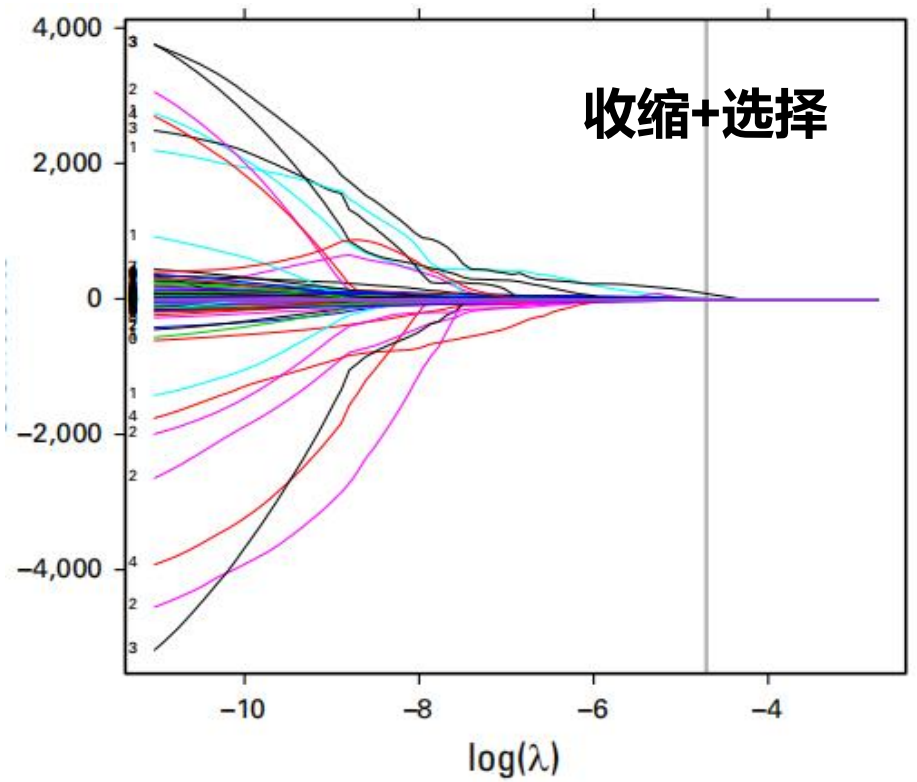


正则化:Lasso

岭回归: $\min_w \frac{1}{2}||y - Xw||_2^2 + \boldsymbol{\lambda}||\boldsymbol{w}||_{\boldsymbol{2}}^{\boldsymbol{2}}$

Lasso: $\min_w \frac{1}{2}||y - Xw||_2^2 + \boldsymbol{\lambda}||\boldsymbol{w}||_{\boldsymbol{1}}$





正则化:岭回归 vs Lasso

最小二乘： $\min_w \frac{1}{2}||y - Xw||_2^2$

解： $w^* = (X^T X)^{-1} X^T y$

岭回归：

$\min_w \frac{1}{2}||y - Xw||_2^2 + \boldsymbol{\lambda}||\boldsymbol{w}||_2^2$

解： $w^*(\lambda) = (X^T X + 2\boldsymbol{\lambda I})^{-1} X^T y$

Lasso: $\min_w \frac{1}{2}||y - Xw||_2^2 + \boldsymbol{\lambda}||\boldsymbol{w}||_1$

解：还不知道

正则化:拓展

首都师范大学 CAPITAL NORMAL UNIVERSITY

从贝叶斯的角度看

P范数的拓展

正则化的拓展

正则化:拓展

从贝叶斯的角度看

对于线性回归问题，假设模型形式为：$y = w^T x + \varepsilon$

给定训练样本: $X = (x_1, ..., x_n)' \in R^{n \times d}, y \in R^{n \times 1}$　　求参数：w？

- **最小二乘：**假设 $\varepsilon \sim N(0, \sigma^2 I)$，故有 $y \sim N(X\mathrm{w}, \sigma^2 I)$

$$\max_w L(w)$$

$$= ln \prod_{i=1}^{n} \frac{1}{\sigma\sqrt{2\pi}} exp\left(-\frac{1}{2}\left(\frac{y_i - w^T x_i}{\sigma}\right)^2\right)$$

$$= -\frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i - w^T x_i)^2 - nln\sigma\sqrt{2\pi}$$

正则化:拓展

从贝叶斯的角度看

对于线性回归问题，假设模型形式为：$y = w^T x + \varepsilon$

给定训练样本: $X = (x_1, ..., x_n)' \in R^{n \times d}, y \in R^{n \times 1}$　　求参数：w？

- **岭回归**：假设$\varepsilon \sim N(0, \sigma^2 I)$，$w \sim N(0, \frac{1}{\lambda} I)$

$$\max_w L(w)$$

$$= P(x, y|w) \times P(w)$$

$$= \ln\{\prod_{i=1}^{n} \frac{1}{\sigma\sqrt{2\pi}} exp\left(-\frac{1}{2}\left(\frac{y_i - w^T x_i}{\sigma}\right)^2\right) \cdot \prod_{j=1}^{d} \frac{1}{\sqrt{2\pi/\lambda}} exp\left(-\frac{1}{2}\left(\frac{w_i}{1/\sqrt{\lambda}}\right)^2\right)\}$$

$$= -\frac{1}{2\sigma^2} \sum_{i=1}^{n} (y_i - w^T x_i)^2 - \lambda \sum_{j=1}^{d} w_j^2 + const$$

正则化:拓展

从贝叶斯的角度看

对于线性回归问题，假设模型形式为：$y = w^T x + \varepsilon$

给定训练样本: $X = (x_1, ..., x_n)' \in R^{n \times d}, y \in R^{n \times 1}$　　求参数：w？

- **LASSO**：假设 $\varepsilon \sim N(0, \sigma^2 I)$，$w \sim Laplace(0, b)$

$$\max_w L(w)$$
$$= P(x, y|w) \times P(w)$$
$$= \ln\{\prod_{i=1}^{n} \frac{1}{\sigma\sqrt{2\pi}} exp\left(-\frac{1}{2}\left(\frac{y_i - w^T x_i}{\sigma}\right)^2\right) \cdot \prod_{j=1}^{d} \frac{1}{2b} exp\left(-\frac{|w_j|}{b}\right)\}$$
$$= -\frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i - w^T x_i)^2 - \lambda\sum_{j=1}^{d}|w_j| + const$$

正则化:拓展

P范数的拓展

$$min\underbrace{\frac{1}{2}||y-Xw||_2^2}_{\text{损失函数}}+\underbrace{\boldsymbol{\lambda||w||_p^p}}_{\textbf{正则化项}}$$

p **−范数定义：** $||w||_p=(\sum_{i=1}^{m}|w_i|^p)^{\frac{1}{p}}$

岭回归（$p=2$）

Lasso（$p=1$）

正则化:拓展

$$\|w\|_\infty = \max_j |w_j|.$$

$$\|w\|_0 = \sum_{j=1}^{d} \mathbf{1}_{\{w_j \neq 0\}} = \#\{j : w_j \neq 0\}$$

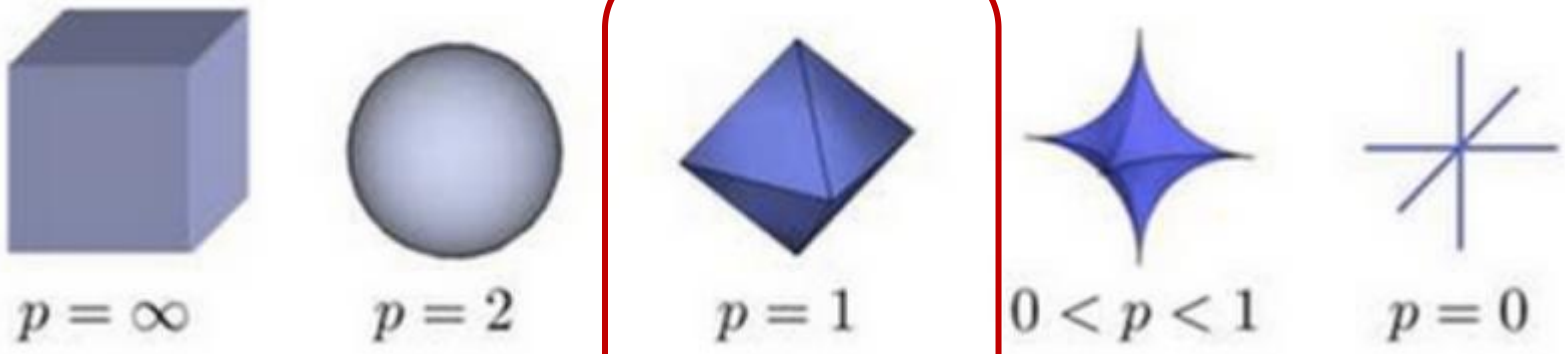
$$\|w\|_p = \left(\sum_{j=1}^{d} |w_j|^p\right)^{1/p}, \qquad 0 < p < 1$$

P范数的拓展

$$\min_w \frac{1}{2}||y - Xw||_2^2$$

$$s.t. \ ||w||_p^p \leq t$$

兼顾凸优化和稀疏



正则化:拓展

训练目标 = 拟合误差 + λR

模型偏好	代表方法	正则化项 R	直观理解
稀疏 + 稳定	Elastic Net 弹性网	$\alpha\|\boldsymbol{w}\|_1 + \frac{1-\alpha}{2}\|\boldsymbol{w}\|_2^2$	结合 L_1 的稀疏与 L_2 的收缩
按组选择	Group Lasso 组套索	$\sum_g a_g \|\boldsymbol{w}_g\|_2$	整组保留或整组剔除
组间 + 组内稀疏	Sparse Group Lasso	$\alpha\|\boldsymbol{w}\|_1 + (1-\alpha)\sum_g a_g \|\boldsymbol{w}_g\|_2$	选出重要组，再筛选组内特征
相邻系数一致	Fused Lasso 融合套索	$\alpha\|\boldsymbol{w}\|_1 + (1-\alpha)\sum_{j=1}^{p-1} \|w_{j+1} - w_j\|$	促进稀疏，形成分段常数
矩阵低秩	核范数正则化	$\|\boldsymbol{W}\|_* = \sum_i \sigma_i(\boldsymbol{W})$	用少量潜在因素解释矩阵

w_g：第 g 组系数；a_g：组权重；$\sigma_i(W)$：奇异值；$0 \le \alpha \le 1$

正则化:拓展

首都师范大学 CAPITAL NORMAL UNIVERSITY

想法：在很多实际问题中，我们希望相关性大的特征们能在问题中共同起作用/不起作用

模型： $\min_{\beta} \frac{1}{2}||y - X\beta||_2^2 + \boldsymbol{\lambda}[\frac{\mathbf{1}}{\mathbf{2}}(\mathbf{1}-\boldsymbol{\alpha})||\boldsymbol{\beta}||_{\mathbf{2}}^{\mathbf{2}} + \boldsymbol{\alpha}||\boldsymbol{\beta}||_{\mathbf{1}}]$

使相关性大的特征们对应的系数相似

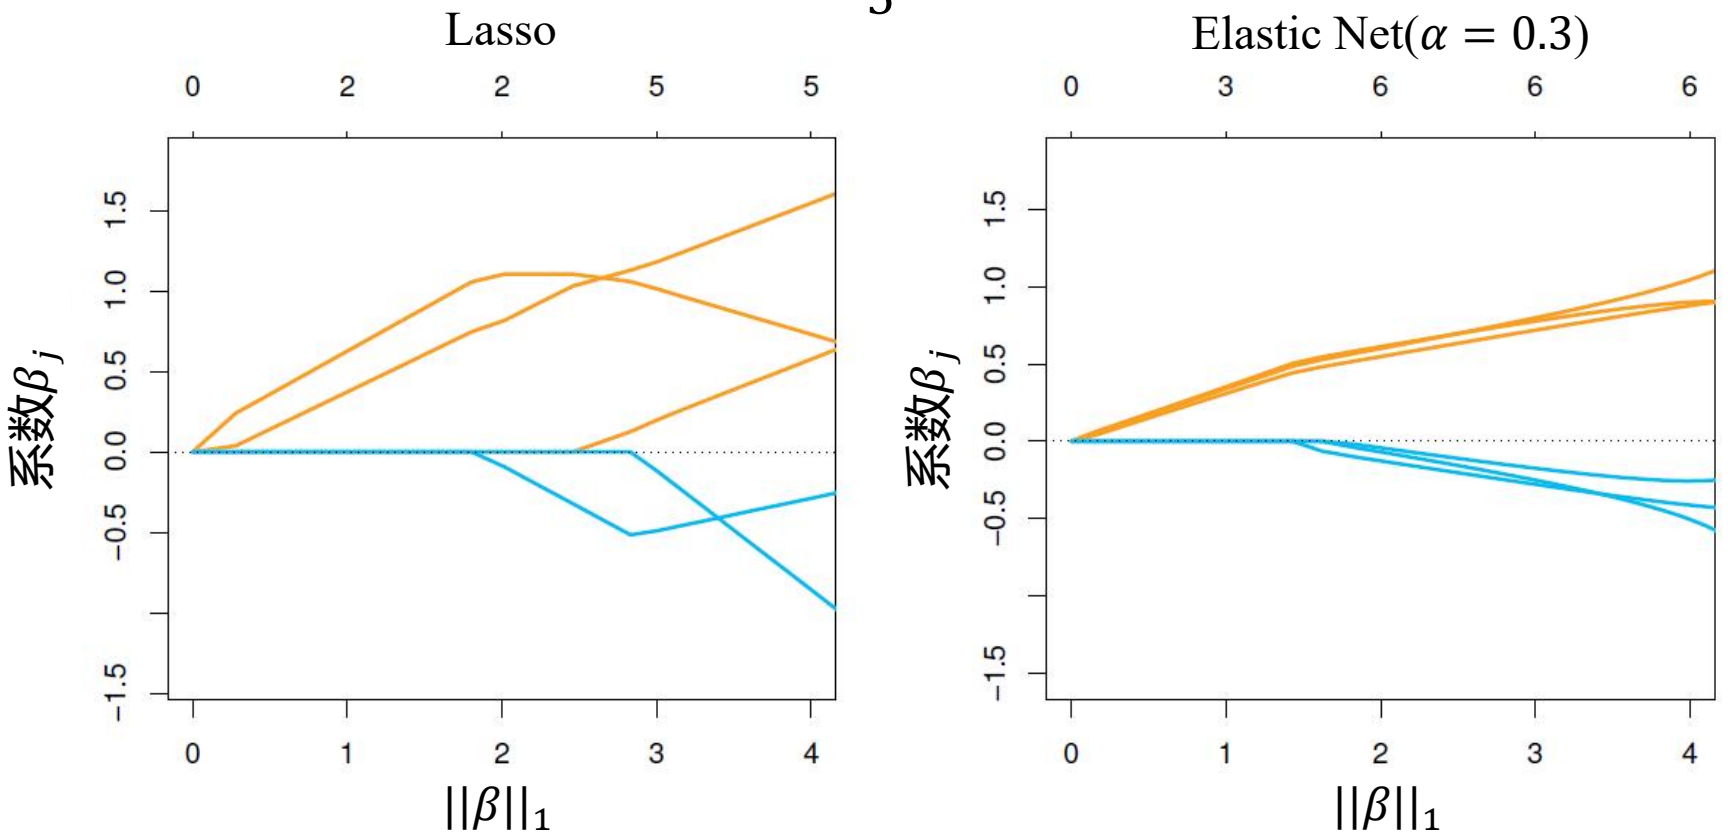
正则化:拓展

举例：

$$Y = 3Z_1 - 1.5Z_2 + 2\varepsilon,\ Z_1,\ Z_2,\ \varepsilon \sim N(0,1)$$

$$X_j = Z_1 + \frac{\xi_j}{5}, \xi_j \sim N(0,1),\ j = 1,2,3$$

$$X_j = Z_2 + \frac{\xi_j}{5}, \xi_j \sim N(0,1),\ j = 4,5,6$$



正则化:拓展

想法： 在很多实际问题中，特征有分组的情况

数据： $X = (Z_1, \ldots, Z_J)$，假设特征有J组，$Z_j \in \mathbb{R}^{n \times p_j}$是第$j$组的数据

模型：

$$\min_{\beta_j \in \mathbb{R}^{p_j}} \frac{1}{2} \sum_{i=1}^{N} (y_i - \sum_{j=1}^{J} z_{i,j} \beta_j)^2 + \boldsymbol{\lambda} \sum_{\boldsymbol{j=1}}^{\boldsymbol{J}} \sqrt{\boldsymbol{p_j}} \|\boldsymbol{\beta_j}\|_2$$

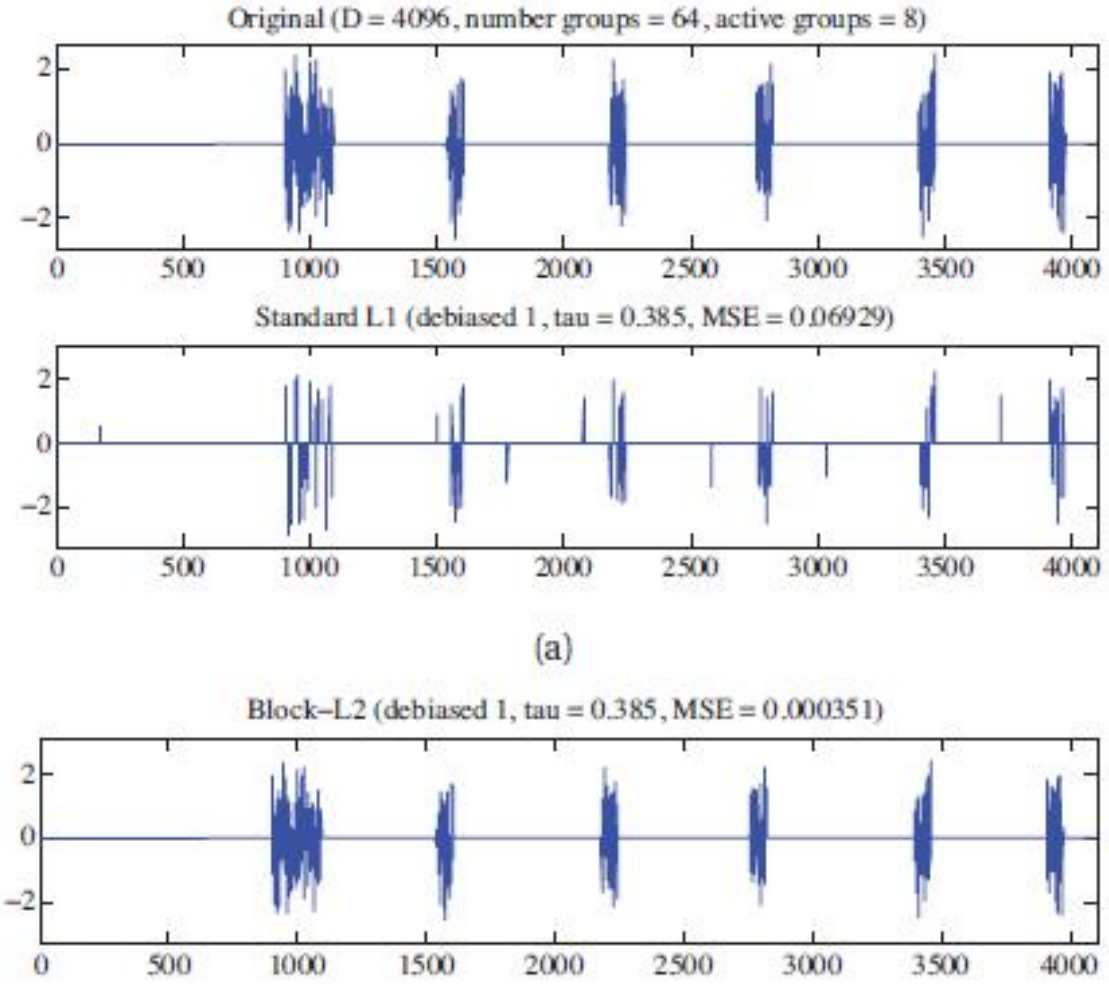
按组做选择

正则化:拓展

真实系数

Lasso

Group Lasso



正则化:拓展

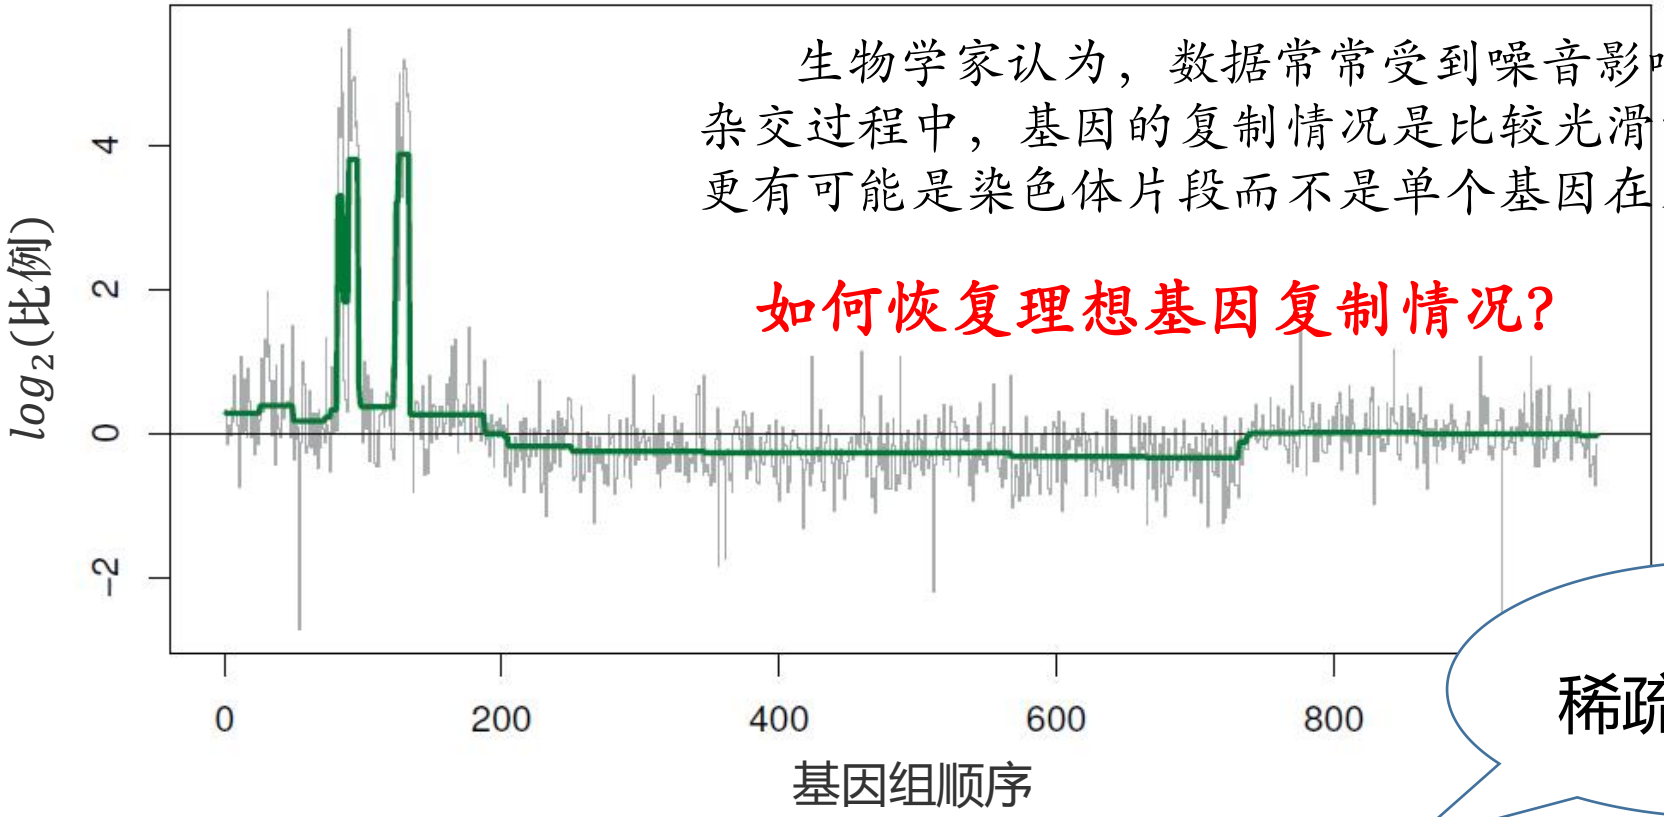
想法：在很多实际问题中，我们希望在选出有用的特征组之后，还能进一步找到组内真正起作用的特征

模型：
$$\min_{\beta_j \in \mathbb{R}^{p_j}} \frac{1}{2} ||Y - \sum_{j=1}^{J} Z_j \beta_j ||_2^2 + \boldsymbol{\lambda} \sum_{\boldsymbol{j=1}}^{\boldsymbol{J}} [\,(\mathbf{1}-\boldsymbol{\alpha})||\boldsymbol{\beta_j}||_2 + \boldsymbol{\alpha}||\boldsymbol{\beta_j}||_1]$$

组稀疏 + 组内稀疏

正则化:拓展

举例： 比较基因组杂交 (comparative genomic hybridization CGH)



生物学家认为，数据常常受到噪音影响，理想杂交过程中，基因的复制情况是比较光滑的，同时，更有可能是染色体片段而不是单个基因在复制

如何恢复理想基因复制情况?

稀疏 + 光滑

模型：

$$\min_{\theta\in\mathbb{R}^N} \frac{1}{2}\sum_{i=1}^{N}(y_i-\theta_i)^2 + \lambda_1\sum_{i=1}^{N}|\theta_i| + \lambda_2\sum_{i=2}^{N}|\theta_i-\theta_{i-1}|$$

正则化:拓展

首都师范大学 CAPITAL NORMAL UNIVERSITY

案例：电影评分预测与矩阵补全

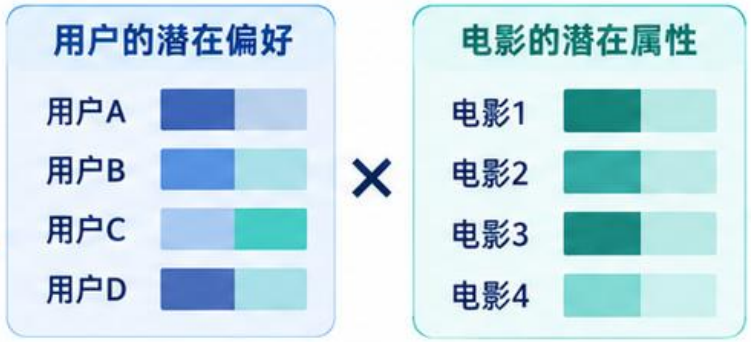
1 观测：评分矩阵有大量空白

	电影1	电影2	电影3	电影4
用户A	★★★	?	★★	?
用户B	?	★★	?	★★★
用户C	★	?	★★★	?
用户D	?	★★★	?	★

行：用户　列：电影

空白 = 未评分，不是 0 分

2 先验：少量潜在因素



用少量因素解释评分差异

$$W \approx UV^{T}$$

少量潜在因素 → 低秩结构

3 预测：补全缺失评分

	电影1	电影2	电影3	电影4
用户A	★★★	★★	★★	★
用户B	★	★★	★★	★★★
用户C	★	★★	★★★	★★
用户D	★★	★★★	★	★

★ 蓝色：已观测　★ 绿色：预测

核范数惩罚什么？

$$\|W\|_* = \sum_i \sigma_i(W)$$

惩罚奇异值之和，
促进矩阵低秩。

与 Lasso 的联系

Lasso：　鼓励系数稀疏

核范数：　鼓励奇异值稀疏

正则化:拓展

$$\min_{W} \frac{1}{2} \sum_{(i,j)\in\Omega} (W_{ij} - R_{ij})^2 + \lambda \|W\|_*.$$

相关研究：

[1] Lee C P, Liang L, Tang T, et al. Accelerating nuclear-norm regularized low-rank matrix optimization through Burer-Monteiro decomposition[J]. Journal of Machine Learning Research, 2024, 25(379): 1–52.
主要贡献：提出 BM-Global 算法，将低秩矩阵分解与近端梯度步骤结合，在自动调整秩的同时加速核范数正则化优化，并保证收敛到原凸问题的全局最优解。

[2] Choi J, Kwon H, Liao Y. Inference for low-rank completion without sample splitting with application to treatment effect estimation[J]. Journal of Econometrics, 2024, 240(1): 105682. DOI: 10.1016/j.jeconom.2024.105682.
主要贡献：提出核范数估计后进行两步最小二乘重拟合的方法，无需样本拆分即可消除影响统计推断的收缩偏差、建立渐近正态性，并用于平均处理效应的统计推断。

大纲

01 正则化

02 完善机器学习基本流程

回顾机器学习基本流程

首都师范大学 CAPITAL NORMAL UNIVERSITY

① 数据准备



- 收集数据
- 了解数据
- 整理数据

② 模型训练



③ 测试与预测



- 新数据
- 预测结果

正则化:岭回归 vs Lasso

最小二乘： $\min_w \frac{1}{2}||y - Xw||_2^2$

解： $w^* = (X^T X)^{-1} X^T y$

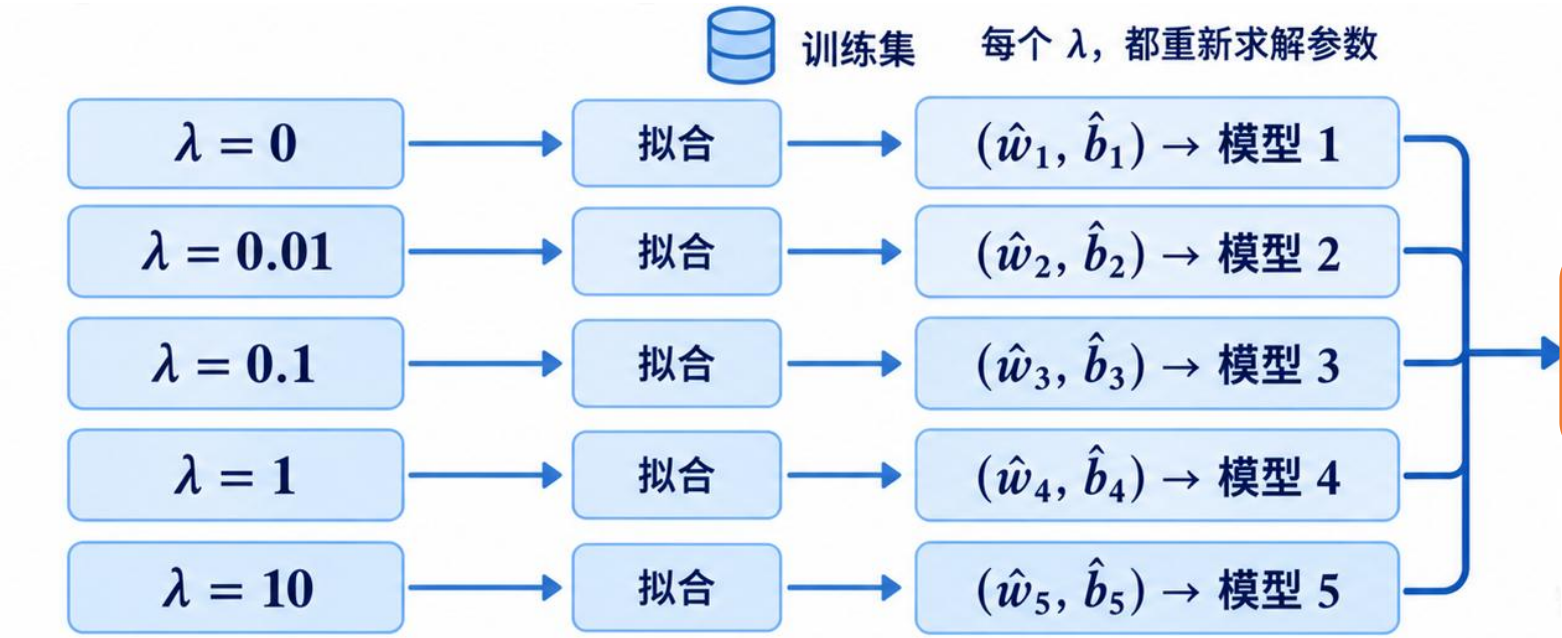
岭回归：

$$\min_w \frac{1}{2}||y - Xw||_2^2 + \boldsymbol{\lambda}||\boldsymbol{w}||_2^2$$

Lasso: $\min_w \frac{1}{2}||y - Xw||_2^2 + \boldsymbol{\lambda}||\boldsymbol{w}||_1$

完善机器学习基本流程

怎么选超参数呢?

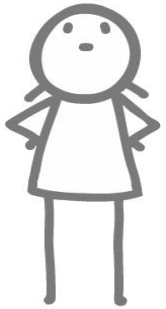


怎么比较不同模型的表现?



训练集?

测试集?



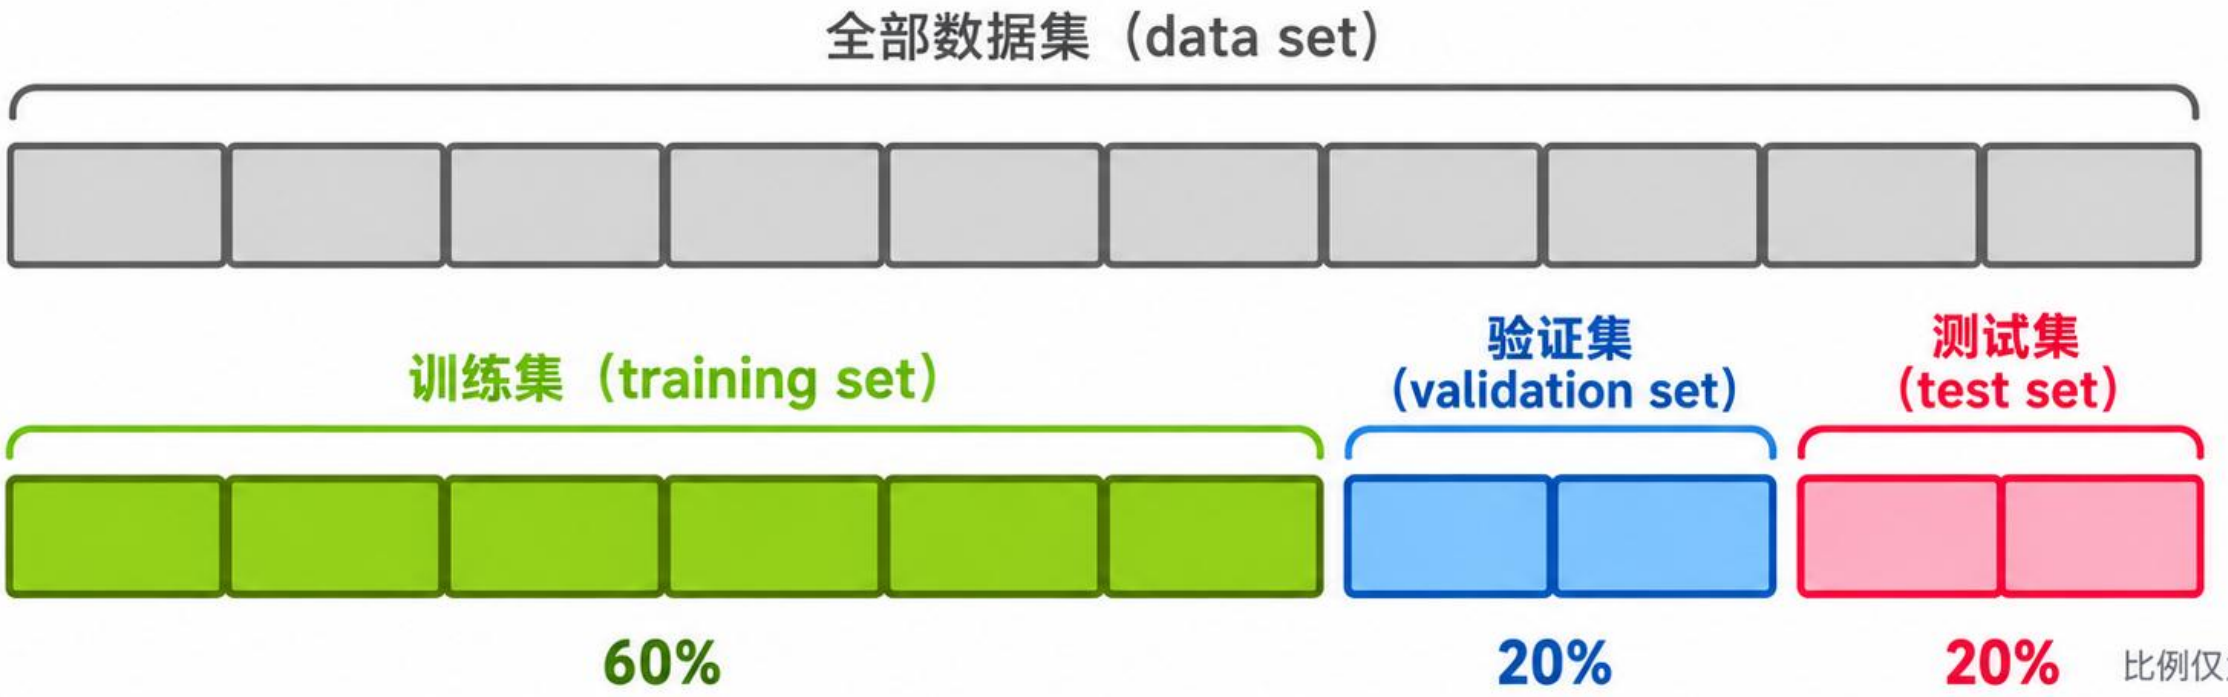
完善机器学习基本流程

训练集 → 既学参数，又学超参数
容易过度学习
（过拟合）

测试集 → 用来评价最终模型的效果
不能拿来参与模型选择和训练



完善机器学习基本流程



训练集：学习参数

用来拟合模型

例如：求解回归系数 w 和截距 b

验证集：选择模型

比较模型形式与超参数

例如：选择正则化强度 λ

测试集：最终评价

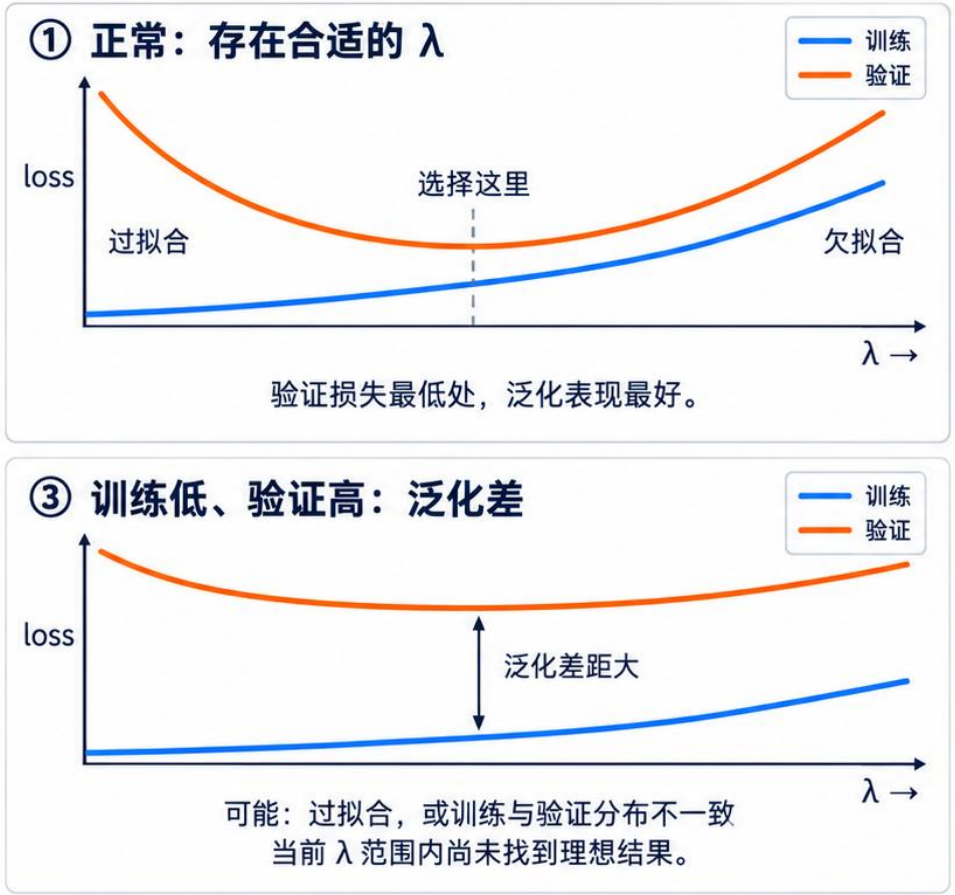
评价最终模型的泛化表现

不参与参数拟合和超参数选择

完善机器学习基本流程

$$\mathrm{MSE}_{\mathrm{train}}(\lambda)=\frac{1}{n_{\mathrm{train}}}\sum_{i\in\mathrm{train}}\left(y_i-\hat{f}_\lambda(x_i)\right)^2,$$

$$\mathrm{MSE}_{\mathrm{val}}(\lambda)=\frac{1}{n_{\mathrm{val}}}\sum_{i\in\mathrm{val}}\left(y_i-\hat{f}_\lambda(x_i)\right)^2.$$



完善机器学习基本流程

首都师范大学 CAPITAL NORMAL UNIVERSITY

① 数据准备



收集数据

了解数据

整理数据

划分训练集、验证集、测试集

预处理统计量仅从训练集学习

② 模型训练与选择

选择模型

设定模型形式与超参数 λ

训练模型

训练集：学习参数 w、b

评估模型

验证集：比较预测误差

反馈改进

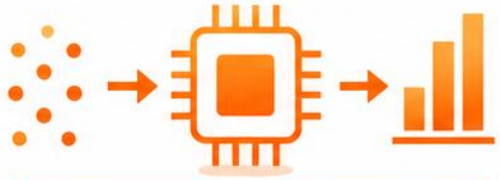
根据验证表现调整配置

训练集学参数

验证集选配置

确定配置后：可用训练集 + 验证集重新拟合最终模型

③ 测试与预测



测试集：最终评价

不参与模型选择与调参

新数据

预测结果



首都师范大学
CAPITAL NORMAL UNIVERSITY