首都师范大学
CAPITAL NORMAL UNIVERSITY



第六课
逻辑回归和贝叶斯分类

授课教师：潘贤丽

上一课总结

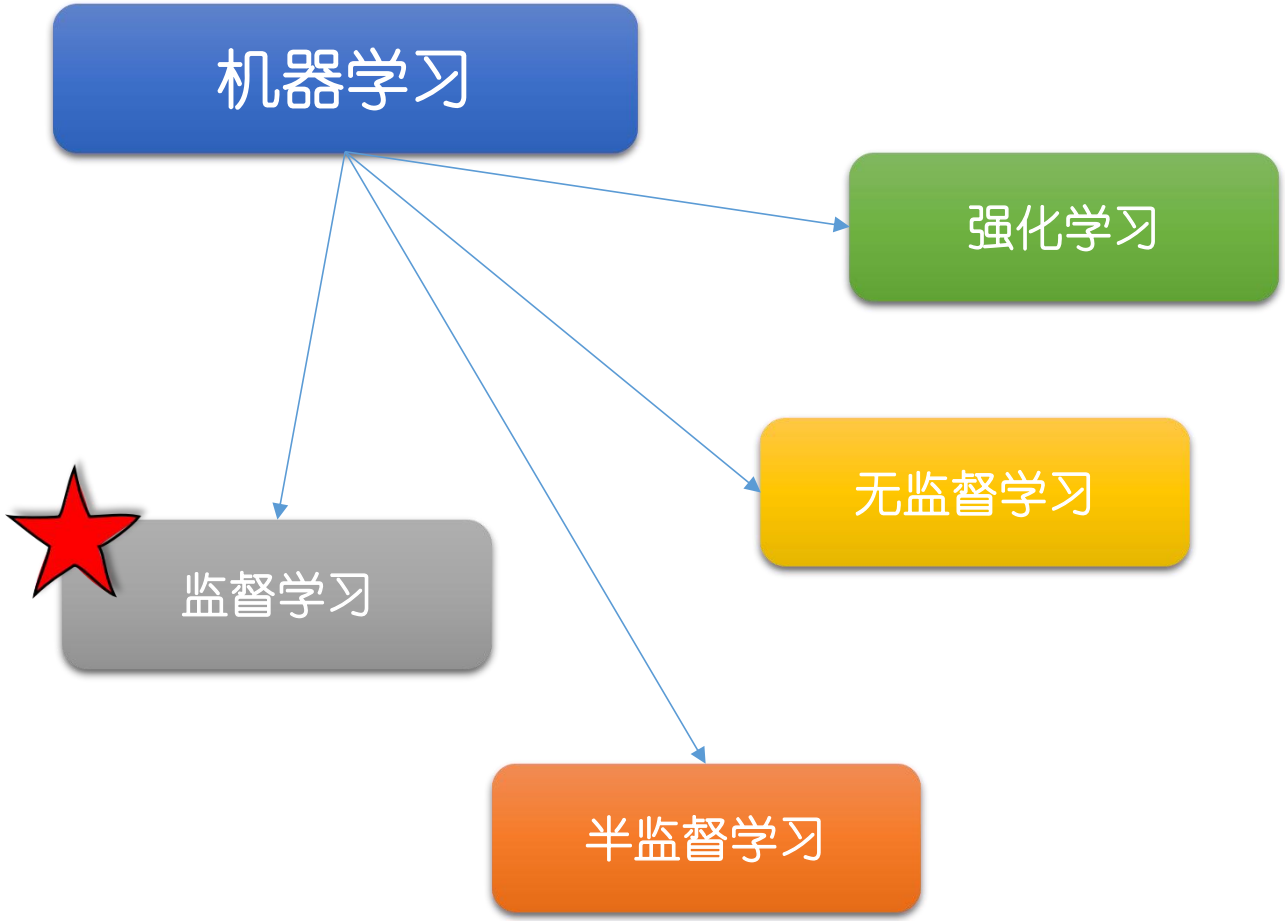
一．什么是机器学习?

二．机器学习发展史

三．机器学习包含什么?

四．机器学习通用流程

五．基础概念介绍



三. 机器学习包含什么？

监督学习：训练数据**有标签**

数据： $(x_i, y_i)_{i=1}^{l}$

学习： $f: x \to y$

目标：对未知x，预测对应$y = f(x)$

分类：逻辑回归、贝叶斯分类

回归：线性回归+正则化

大纲

01 逻辑回归

02 贝叶斯分类

03 生成式 vs 判别式模型

逻辑回归

逻辑回归处理什么问题?

分类！！！



说三遍能记住吗?

逻辑回归

表 4-2　授信额度与工资房产的关系

贷款编号	姓　　名	每月工资（元）	存款余额（元）	房产面积（平方米）	授信额度（元）
1	张三	6000	12000	55	30000
2	李四	8000	10000	65	45300
3	王五	7500	16000	60	46000
4	赵六	10000	15000	75	55500
5	钱七	9000	21000	70	58000
6	孙八	12000	19000	85	75400
7	周九	11000	26000	90	81000
8	吴十	13000	32000	80	76800

用回归思想处理分类问题

贷款编号	姓　　名	月工资（元）	存款余额（元）	房产面积（平方米）	贷款金额（元）	是否授予
1	张三	6000	12000	55	30000	拒绝
2	李四	8000	10000	65	45300	授予
3	王五	7500	16000	60	46000	授予
4	赵六	10000	15000	75	55500	授予
5	钱七	9000	21000	70	58000	拒绝
6	孙八	12000	19000	85	75400	授予
7	周九	11000	26000	90	81000	拒绝
8	吴十	13000	32000	80	76800	授予

回归： $y_i \in R$

$$f(x) = w^T x + b$$

分类： $y_i \in \{-1, +1\}$

？

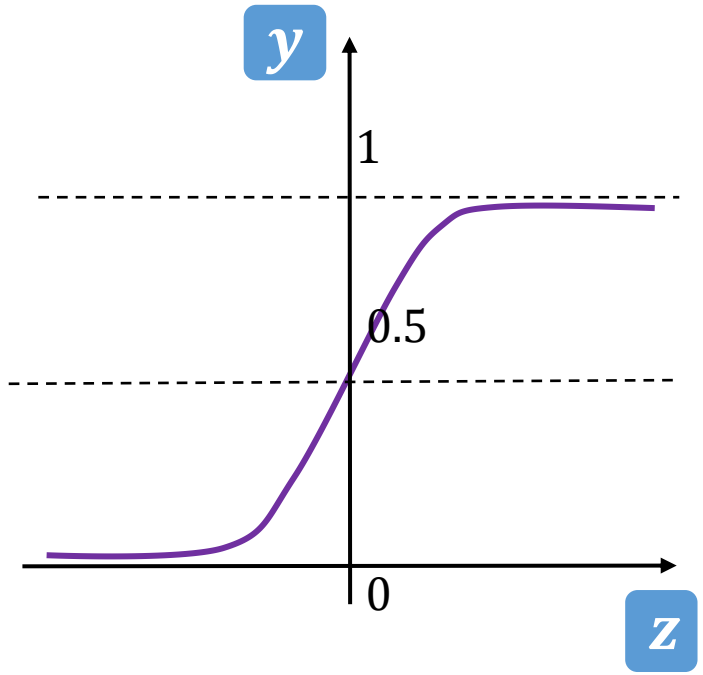
逻辑回归

给定训练集$T = \{(x_1, y_1), (x_2, y_2), ..., (x_m, y_m)\}$，其中$x_i \in R^d$，$y_i \in \{0, +1\}$

$$z = w^T x + b$$

$$y = \frac{1}{1+e^{-z}} \text{(sigmoid函数)}$$

$$P(Y = 1|X) = \frac{1}{1 + e^{-(w^T x+b)}}$$



注：一般我们可以通过给x增加一维去掉参数b

逻辑回归

假设：概率的**对数几率**是关于特征的**线性函数**

$$\log \frac{P(Y=1 \mid x)}{1-P(Y=1 \mid x)} = w^T x + b$$

- **几率（odds）**：$\frac{p}{1-p}$
- **对数几率（log-odds / logit）**：$\log \frac{p}{1-p}$

$$\log \frac{p(x)}{1-p(x)} = w^T x + b$$

$$\frac{p(x)}{1-p(x)} = e^{w^T x+b}$$

$$p(x) = \frac{e^{w^T x+b}}{1+e^{w^T x+b}}$$

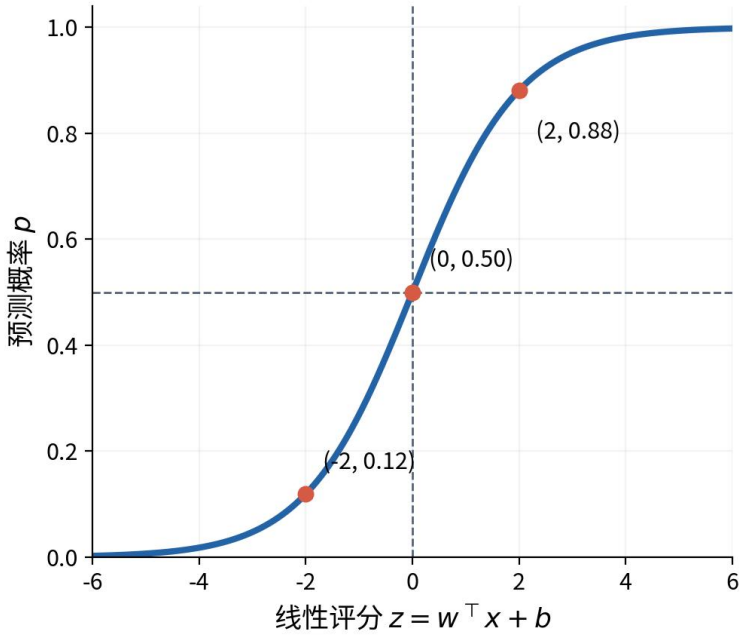
$$p(x) = \frac{1}{1+e^{-(w^T x+b)}}$$

逻辑回归

首都师范大学 CAPITAL NORMAL UNIVERSITY

$p = \sigma(z) = 1/(1 + e^{-z})$

① Sigmoid：把评分映射为概率

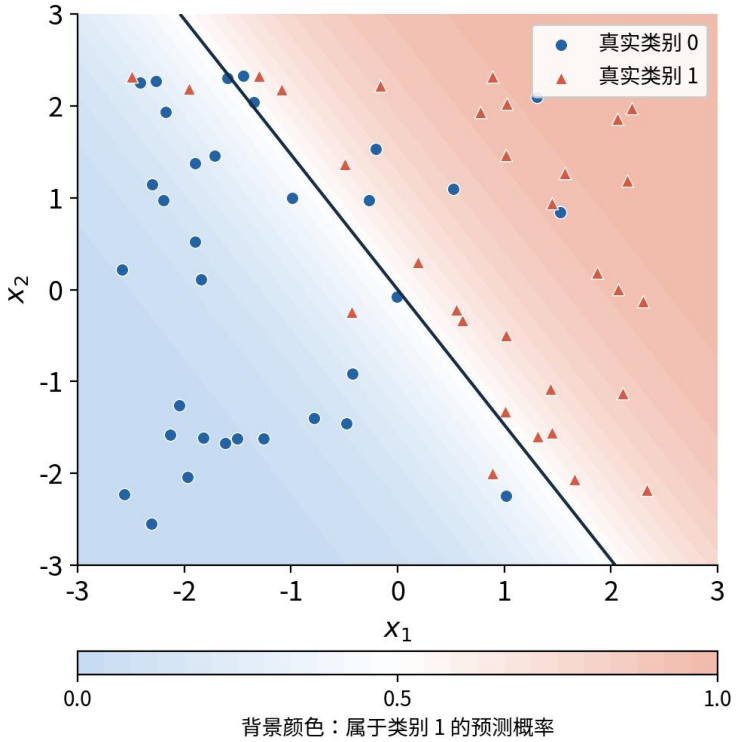


评分越大，属于类别 1 的概率越大

评分为 0 时，概率为 0.5

$p = \sigma(1.25x_1 + 0.85x_2)$

② 概率背景：每个位置都有一个 p

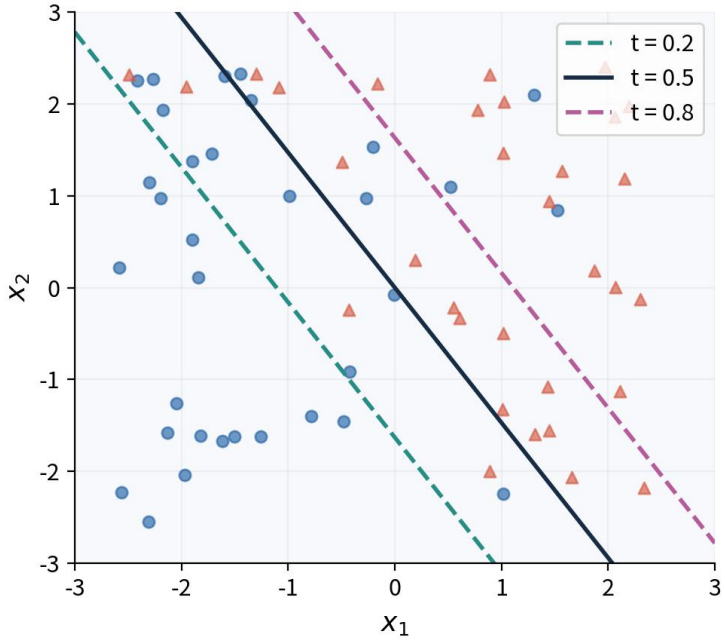


散点表示真实类别，背景表示预测概率

真实标签与预测类别可以不同

$\hat{y} = \mathbf{1}(p \geq t)$

③ 改变阈值：分类边界随之移动



模型参数与概率不变，只改变决策阈值

阈值越高，被判为类别 1 的区域越小

逻辑回归

求解：极大似然估计

给定训练集$T = \{(x_1, y_1), (x_2, y_2), \ldots, (x_m, y_m)\}$，其中$x_i \in R^d$，$y_i \in \{0, +1\}$

$$h(x) = \frac{1}{1 + e^{-w^T x}}$$

$$\left.\begin{array}{l} p(y = 1|x; w) = h(x) \\ p(y = 0|x; w) = 1 - h(x) \end{array}\right\} \quad p(y|x; w) = (h(x))^y (1 - h(x))^{1-y}$$

似然函数为：$\mathrm{L}(w) = \prod_{i=1}^{m} P\,(y^{(i)}|x^{(i)}; w) = \prod_{i=1}^{m} (\,h(x^{(i)}))^{y^{(i)}} (1 - h(x^{(i)}))^{1-y^{(i)}}$

$$l(w) = \log \mathrm{L}(w) = \sum_{i=1}^{m} (\,y^{(i)} \log(h(x^{(i)})) + (1 - y^{(i)}) \log(1 - h(x^{(i)})))$$

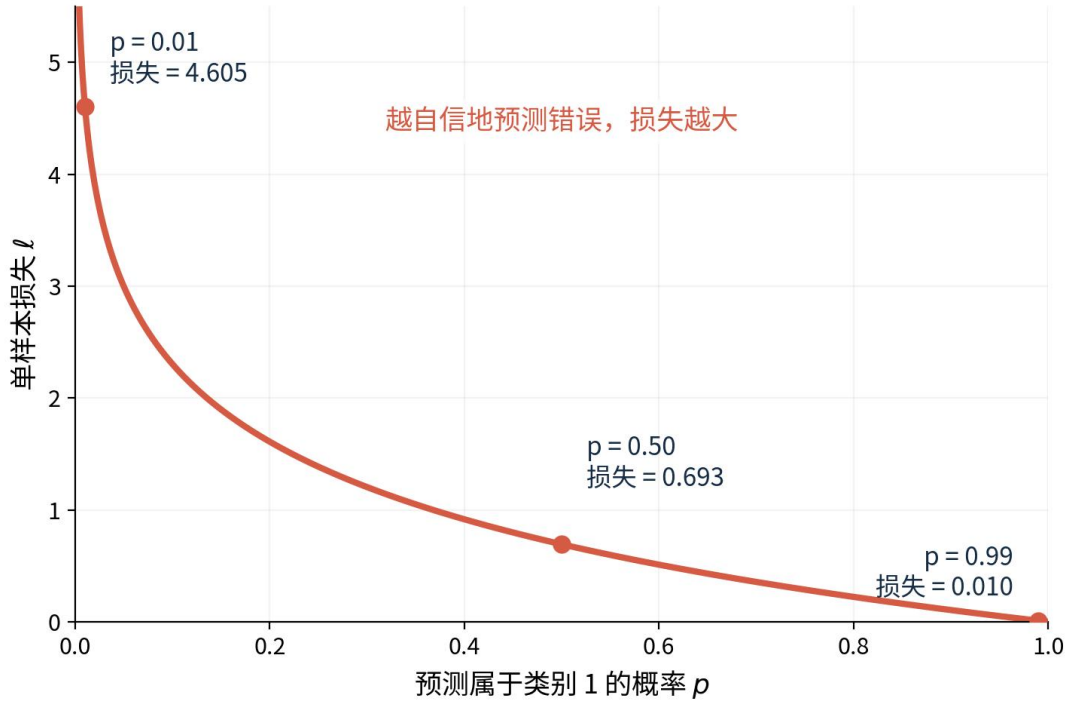
逻辑回归

交叉熵损失

$$\mathcal{L} = -\frac{1}{n}\sum_{i=1}^{n}\left[y_i \log p_i + (1-y_i)\log(1-p_i)\right]$$

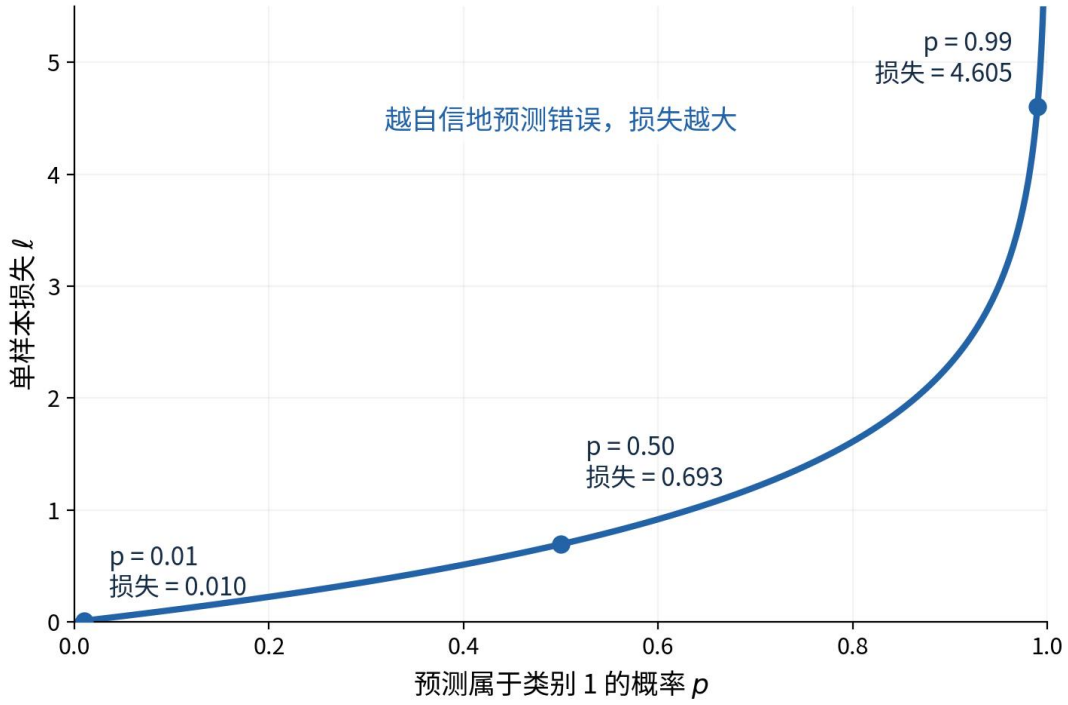
其中，$y_i \in \{0,1\}$，$p_i = P(Y_i = 1 \mid x_i)$。

真实标签 1：$\ell = -\log p$



真实为 1：p 越接近 1，损失越小

真实标签 0：$\ell = -\log(1-p)$



真实为 0：p 越接近 0，损失越小

逻辑回归

给定训练集$T = \{(x_1, y_1), (x_2, y_2), \ldots, (x_m, y_m)\}$，其中$x_i \in R^d$，$y_i \in \{0, +1\}$

$$h(x) = \frac{1}{1 + e^{-w^T x}}$$

$$\min_w \quad J(w) = -\frac{1}{m}\sum_{i=1}^{m}(y^{(i)}\log(h(x^{(i)})) + (1 - y^{(i)})\log(1 - h(x^{(i)})))$$

这个模型可以直接求解吗？

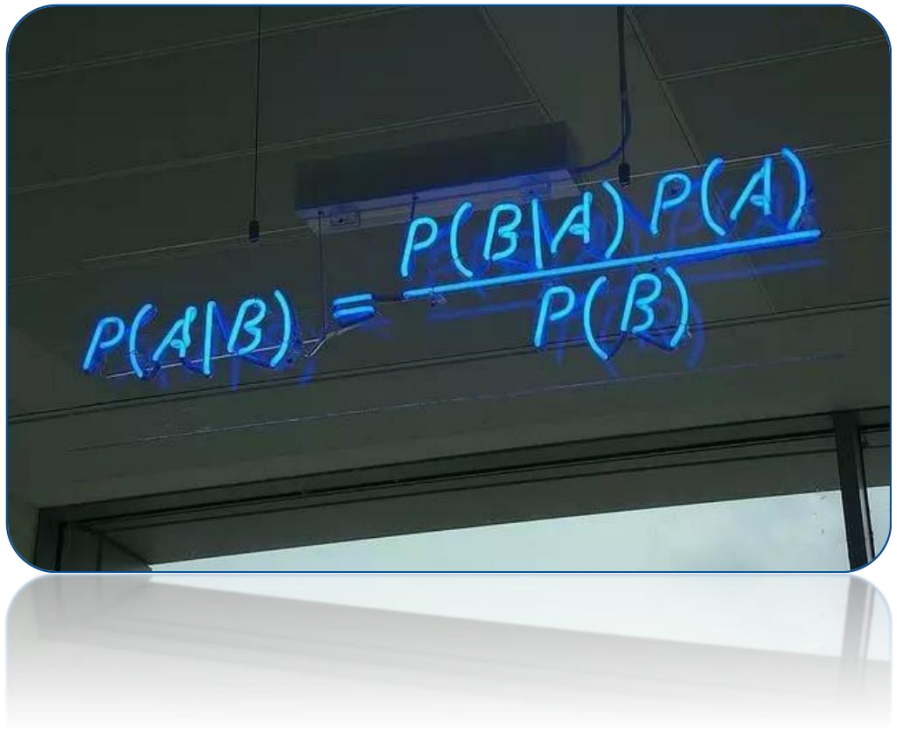
大纲

01 逻辑回归

02 贝叶斯分类

03 生成式 vs 判别式模型

贝叶斯分类



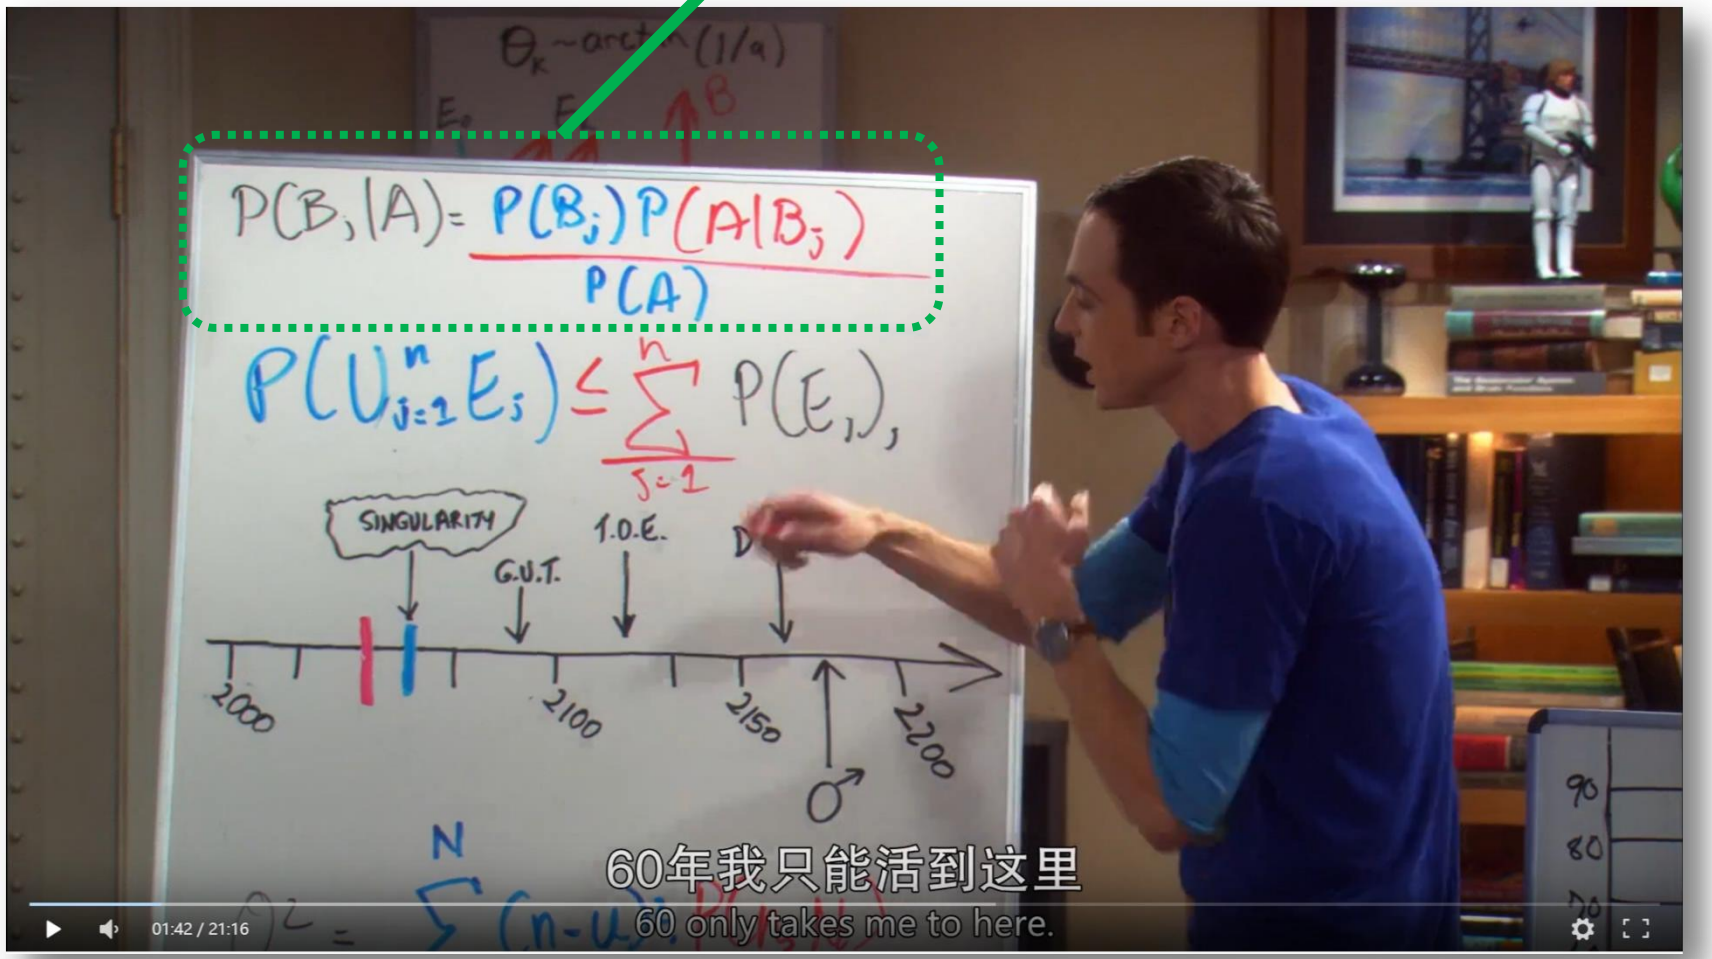
贝叶斯定理

特征条件独立假设

朴素贝叶斯分类

贝叶斯分类

贝叶斯定理


$P(B_i|A) = \frac{P(B_j)P(A|B_j)}{P(A)}$
$P(\bigcup_{j=1}^{n} E_j) \leq \sum_{j=1}^{n} P(E_j)$
SINGULARITY
G.U.T.
T.O.E.
2000
2100
2150
2200
60年我只能活到这里
60 only takes me to here.
01:42 / 21:16

贝叶斯分类

我们对事情的印象 → 观察到一些情况 → 更新印象




好吃

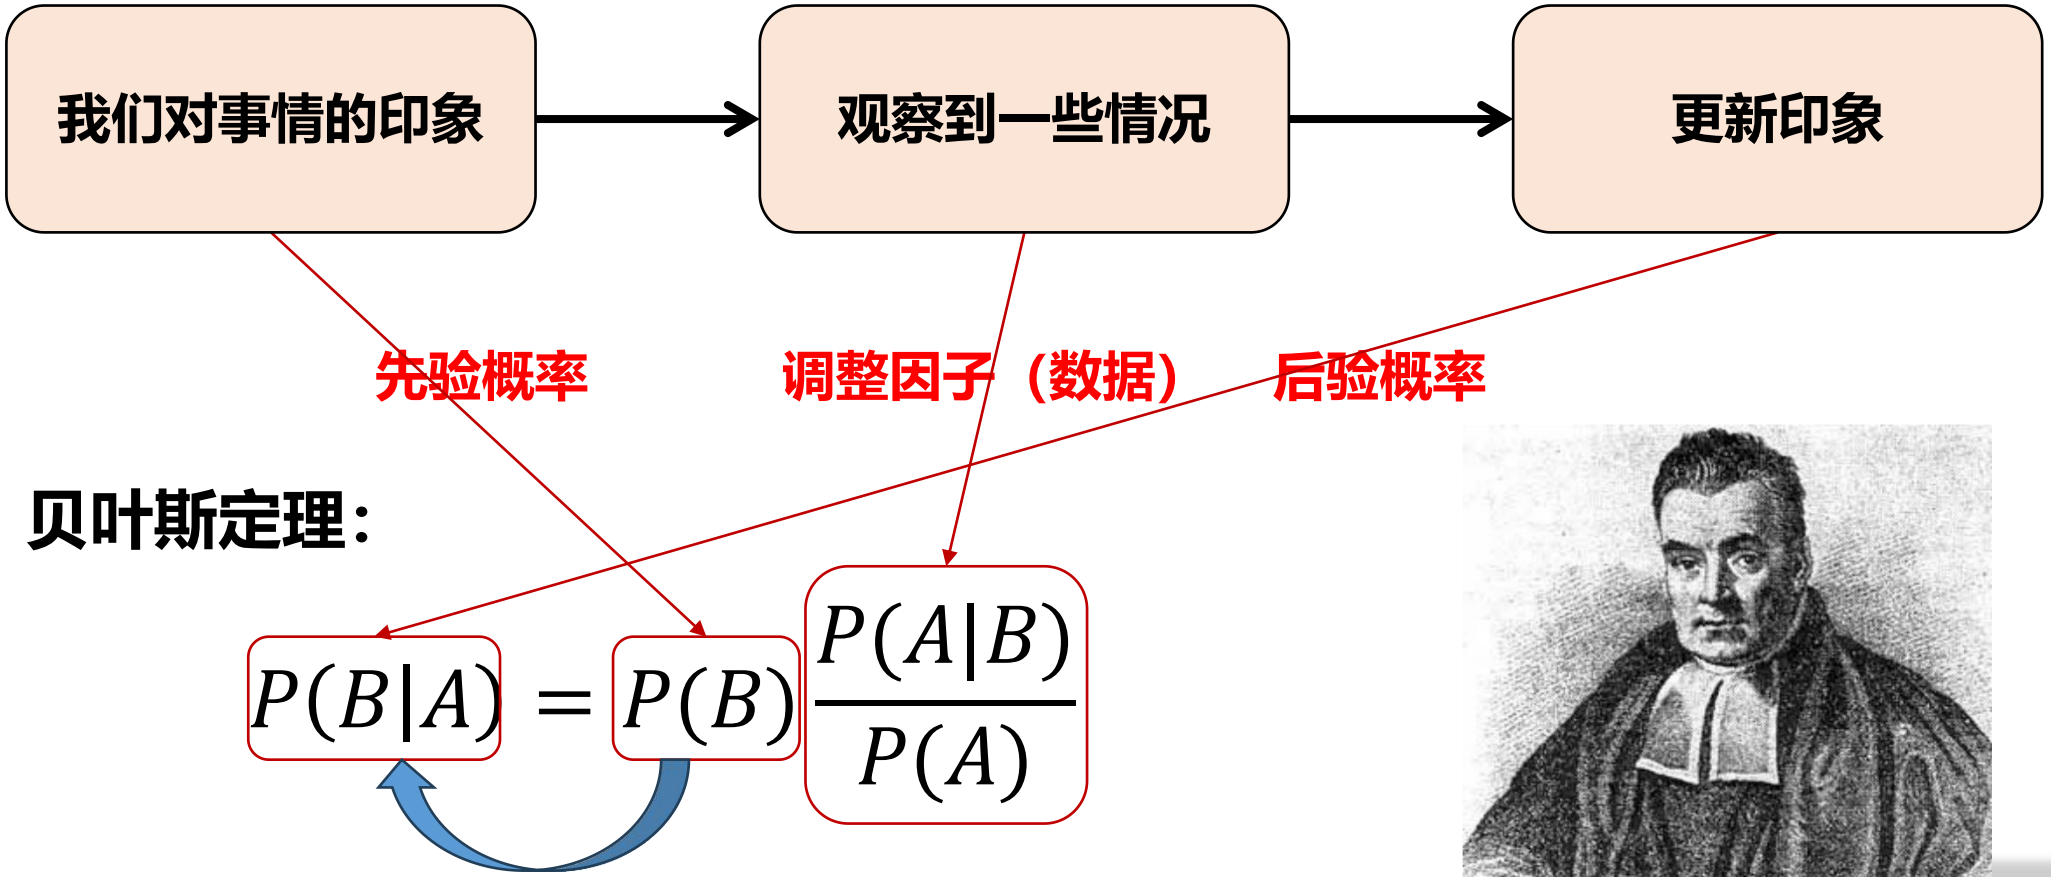

好吃


好吃


好吃



贝叶斯分类



贝叶斯定理：

$$P(B|A) = P(B)\frac{P(A|B)}{P(A)}$$

利用新信息，更新概率



贝叶斯分类

首师大出现小偷的概率是0.1%



为了加强校园安全，学校保卫科斥巨资（999）购买了一批警报器：



如果有小偷，警报响起的概率是99%

如果没有小偷，误报的概率是5%

问：某天警报突然响了，真的出现小偷的概率有多大？

1.94%

贝叶斯分类

首都师范大学 CAPITAL NORMAL UNIVERSITY

已知条件

1. 
小偷出现的概率：
$P(偷)=0.1\%=0.001$

2. 
有小偷时警报响：
$P(响|偷)=99\%=0.99$

3. 
没有小偷时误报：
$P(响|非偷)=5\%=0.05$

4. 
没有小偷的概率：
$P(非偷)=1-0.001=0.999$

1 目标 求警报响起时，真的有小偷的概率：$P(偷|响)$

2 套用贝叶斯公式

$$P(偷|响)=\frac{P(响|偷)P(偷)}{P(响)}$$

其中，$P(响)=P(响|偷)P(偷)+P(响|非偷)P(非偷)$

3 代入数值

$$P(偷|响)=\frac{0.99\times 0.001}{0.99\times 0.001+0.05\times 0.999}$$

4 计算结果

$$P(偷|响)=\frac{0.00099}{0.00099+0.04995}=\frac{0.00099}{0.05094}\approx 0.0194=1.94\%$$

贝叶斯分类

贝叶斯定理

$$P(B|A) = P(B)\frac{P(A|B)}{P(A)}$$

特征条件独立假设

朴素贝叶斯分类

贝叶斯分类

训练集： $D = \{(\boldsymbol{x_1}, y_1), (\boldsymbol{x_2}, y_2), \ldots, (\boldsymbol{x_n}, y_n)\}$，其中$x_i \in R^p$，$y_i \in \{c_1, c_2, \ldots, c_K\}$

目标： 预测新的样本 $\boldsymbol{x}$ 所属类别

$$y = f(\boldsymbol{x})$$

$$arg \max_{i=1,2,\ldots,K} P(c_i|\boldsymbol{x})$$

贝叶斯分类

贝叶斯定理： $P(B|A) = P(B)\frac{P(A|B)}{P(A)}$

$$P(c_i|\boldsymbol{x}) = P(c_i)\frac{P(\boldsymbol{x}|c_i)}{\boldsymbol{P(x)}}, i = 1,2, \ldots, K$$

$$arg\max_{i=1,2,\ldots,K} P(c_i|\boldsymbol{x})$$

$$P(c_i)P(\boldsymbol{x}|c_i), i = 1,2, \ldots, K$$

贝叶斯分类

$$P(c_i)P(\boldsymbol{x}|c_i), i = 1,2, \ldots, K$$

关于类别的先验概率

用在训练数据上的
频率近似概率

类条件概率

$$P(x^1, x^2, \ldots, x^p|c_i)$$

假设：各特征间相互独立

$$\prod_{j=1,\ldots,p} P(x^j|c_i)$$

贝叶斯分类

$$P(x^j \mid c_i)$$

x^j取值离散

计数： $\frac{|D_{c_i,\ x^j}|}{|D_{c_i}|}$

x^j取值连续

分布假设：
- **高斯分布**
- **多项式分布**
- **伯努利分布**

假设 $P(x^j \mid c_i) \sim \mathrm{N}(u_{c_i,\ x^j},\ \sigma^2_{c_i,\ x^j})$

第c_i类样本在第j个属性上取值的均值和方差

$$P(x^j \mid c_i) = \frac{1}{\sqrt{2\pi}\sigma_{c_i,\ x^j}} \exp\left(-\frac{(x^j - u_{c_i,\ x^j})^2}{2\sigma^2_{c_i,\ x^j}}\right)$$

贝叶斯分类

不同分布假设及适用场景

分布类型	对应模型	适用特征类型	假设	使用场景例子
多项式分布	Multinomial NB	离散/计数字符	特征是**单词计数/频率**	文本分类（词袋模型）
伯努利分布	Bernoulli NB	二值型特征	特征是**是否出现**	垃圾邮件识别、点击预测
高斯分布	Gaussian NB	连续型特征	特征在类内服从**正态分布**	图像、医疗指标等连续变量
Kernel 密度估计	KDE-NB (自定义)	连续型特征	非参数估计	不满足高斯的连续特征场景
拉普拉斯分布	Laplace NB（非主流）	连续型特征	更适用于有尖峰+长尾数据	噪声鲁棒性要求较高场景

贝叶斯分类

$y = f(\boldsymbol{x})$

$arg\max_{i=1,2,\ldots,K} P(c_i|\boldsymbol{x})$

$$P(c_i|\boldsymbol{x}) = P(c_i)\frac{P(\boldsymbol{x}|c_i)}{P(\boldsymbol{x})}, i = 1,2,\ldots,K$$

贝叶斯定理

$P(c_i)P(\boldsymbol{x}|c_i), i = 1,2,\ldots,K$

用在训练数据上的频率近似概率

$P(x^1, x^2, \ldots, x^p|c_i)$

假设：各特征间相互独立

$$\prod_{j=1,\ldots,p} P(x^j|c_i)$$

x^j取值离散

计数：$\frac{|D_{c_i,\ x^j}|}{|D_{c_i}|}$

分布假设：
- 高斯分布
- 多项式分布
- 伯努利分布

x^j取值连续

假设$P(x^j|c_i) \sim N(u_{c_i,\ x^j},\ \sigma^2_{c_i,\ x^j})$

$$P(x^j|c_i) = \frac{1}{\sqrt{2\pi}\sigma_{c_i,\ x^j}}\exp\left(-\frac{(x^j - u_{c_i,\ x^j})^2}{2\sigma^2_{c_i,\ x^j}}\right)$$

贝叶斯分类

首都师范大学 CAPITAL NORMAL UNIVERSITY

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
测 1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	?

贝叶斯分类

首先估计类先验概率 $P(c)$, 显然有

$$P(\text{好瓜}=\text{是}) = \frac{8}{17} \approx 0.471 ,$$
$$P(\text{好瓜}=\text{否}) = \frac{9}{17} \approx 0.529 .$$

然后, 为每个属性估计条件概率 $P(x_i \mid c)$:

$$P_{\text{青绿}|\text{是}} = P(\text{色泽}=\text{青绿} \mid \text{好瓜}=\text{是}) = \frac{3}{8} = 0.375 ,$$
$$P_{\text{青绿}|\text{否}} = P(\text{色泽}=\text{青绿} \mid \text{好瓜}=\text{否}) = \frac{3}{9} \approx 0.333 ,$$
$$P_{\text{蜷缩}|\text{是}} = P(\text{根蒂}=\text{蜷缩} \mid \text{好瓜}=\text{是}) = \frac{5}{8} = 0.375 ,$$
$$P_{\text{蜷缩}|\text{否}} = P(\text{根蒂}=\text{蜷缩} \mid \text{好瓜}=\text{否}) = \frac{3}{9} \approx 0.333 ,$$
$$P_{\text{浊响}|\text{是}} = P(\text{敲声}=\text{浊响} \mid \text{好瓜}=\text{是}) = \frac{6}{8} = 0.750 ,$$
$$P_{\text{浊响}|\text{否}} = P(\text{敲声}=\text{浊响} \mid \text{好瓜}=\text{否}) = \frac{4}{9} \approx 0.444 ,$$
$$P_{\text{清晰}|\text{是}} = P(\text{纹理}=\text{清晰} \mid \text{好瓜}=\text{是}) = \frac{7}{8} = 0.875 ,$$
$$P_{\text{清晰}|\text{否}} = P(\text{纹理}=\text{清晰} \mid \text{好瓜}=\text{否}) = \frac{2}{9} \approx 0.222 ,$$
$$P_{\text{凹陷}|\text{是}} = P(\text{脐部}=\text{凹陷} \mid \text{好瓜}=\text{是}) = \frac{6}{8} = 0.750 ,$$
$$P_{\text{凹陷}|\text{否}} = P(\text{脐部}=\text{凹陷} \mid \text{好瓜}=\text{否}) = \frac{2}{9} \approx 0.222 ,$$
$$P_{\text{硬滑}|\text{是}} = P(\text{触感}=\text{硬滑} \mid \text{好瓜}=\text{是}) = \frac{6}{8} = 0.750 ,$$
$$P_{\text{硬滑}|\text{否}} = P(\text{触感}=\text{硬滑} \mid \text{好瓜}=\text{否}) = \frac{6}{9} \approx 0.667 ,$$

$$p_{\text{密度: 0.697}|\text{是}} = p(\text{密度}=0.697 \mid \text{好瓜}=\text{是}) = \frac{1}{\sqrt{2\pi}\cdot 0.129} \exp\left(-\frac{(0.697-0.574)^2}{2\cdot 0.129^2}\right) \approx 1.959 ,$$
$$p_{\text{密度: 0.697}|\text{否}} = p(\text{密度}=0.697 \mid \text{好瓜}=\text{否}) = \frac{1}{\sqrt{2\pi}\cdot 0.195} \exp\left(-\frac{(0.697-0.496)^2}{2\cdot 0.195^2}\right) \approx 1.203 ,$$
$$p_{\text{含糖: 0.460}|\text{是}} = p(\text{含糖率}=0.460 \mid \text{好瓜}=\text{是}) = \frac{1}{\sqrt{2\pi}\cdot 0.101} \exp\left(-\frac{(0.460-0.279)^2}{2\cdot 0.101^2}\right) \approx 0.788 ,$$
$$p_{\text{含糖: 0.460}|\text{否}} = p(\text{含糖率}=0.460 \mid \text{好瓜}=\text{否}) = \frac{1}{\sqrt{2\pi}\cdot 0.108} \exp\left(-\frac{(0.460-0.154)^2}{2\cdot 0.108^2}\right) \approx 0.066 .$$

$$P(\text{好瓜}=\text{是}) \times P_{\text{青绿}|\text{是}} \times P_{\text{蜷缩}|\text{是}} \times P_{\text{浊响}|\text{是}} \times P_{\text{清晰}|\text{是}} \times P_{\text{凹陷}|\text{是}} \times P_{\text{硬滑}|\text{是}} \times p_{\text{密度: 0.697}|\text{是}} \times p_{\text{含糖: 0.460}|\text{是}} \approx 0.038 ,$$

$$P(\text{好瓜}=\text{否}) \times P_{\text{青绿}|\text{否}} \times P_{\text{蜷缩}|\text{否}} \times P_{\text{浊响}|\text{否}} \times P_{\text{清晰}|\text{否}} \times P_{\text{凹陷}|\text{否}} \times P_{\text{硬滑}|\text{否}} \times p_{\text{密度: 0.697}|\text{否}} \times p_{\text{含糖: 0.460}|\text{否}} \approx 6.80 \times 10^{-5} .$$

贝叶斯分类

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响					.237	是
7	乌黑	稍蜷	浊响					.149	是
8	乌黑	稍蜷	浊响					.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

$P_{\text{清脆}|\text{是}} = 0?$

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
测 1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	?

贝叶斯分类

$P(c_i)$

↓

计数：$\frac{|D_{c_i}|}{|D|}$

↓

$\frac{|D_{c_i}|+1}{|D|+K}$

$P(x^j|c_i)$

↓

x^j取值离散

↓

计数：$\frac{|D_{c_i,x^j}|}{|D_{c_i}|}$

↓

$\frac{|D_{c_i,x^j}|+1}{|D_{c_i}|+N_i}$

拉普拉斯平滑：

贝叶斯分类

贝叶斯定理

$$P(B|A) = P(B)\frac{P(A|B)}{P(A)}$$

特征条件独立假设

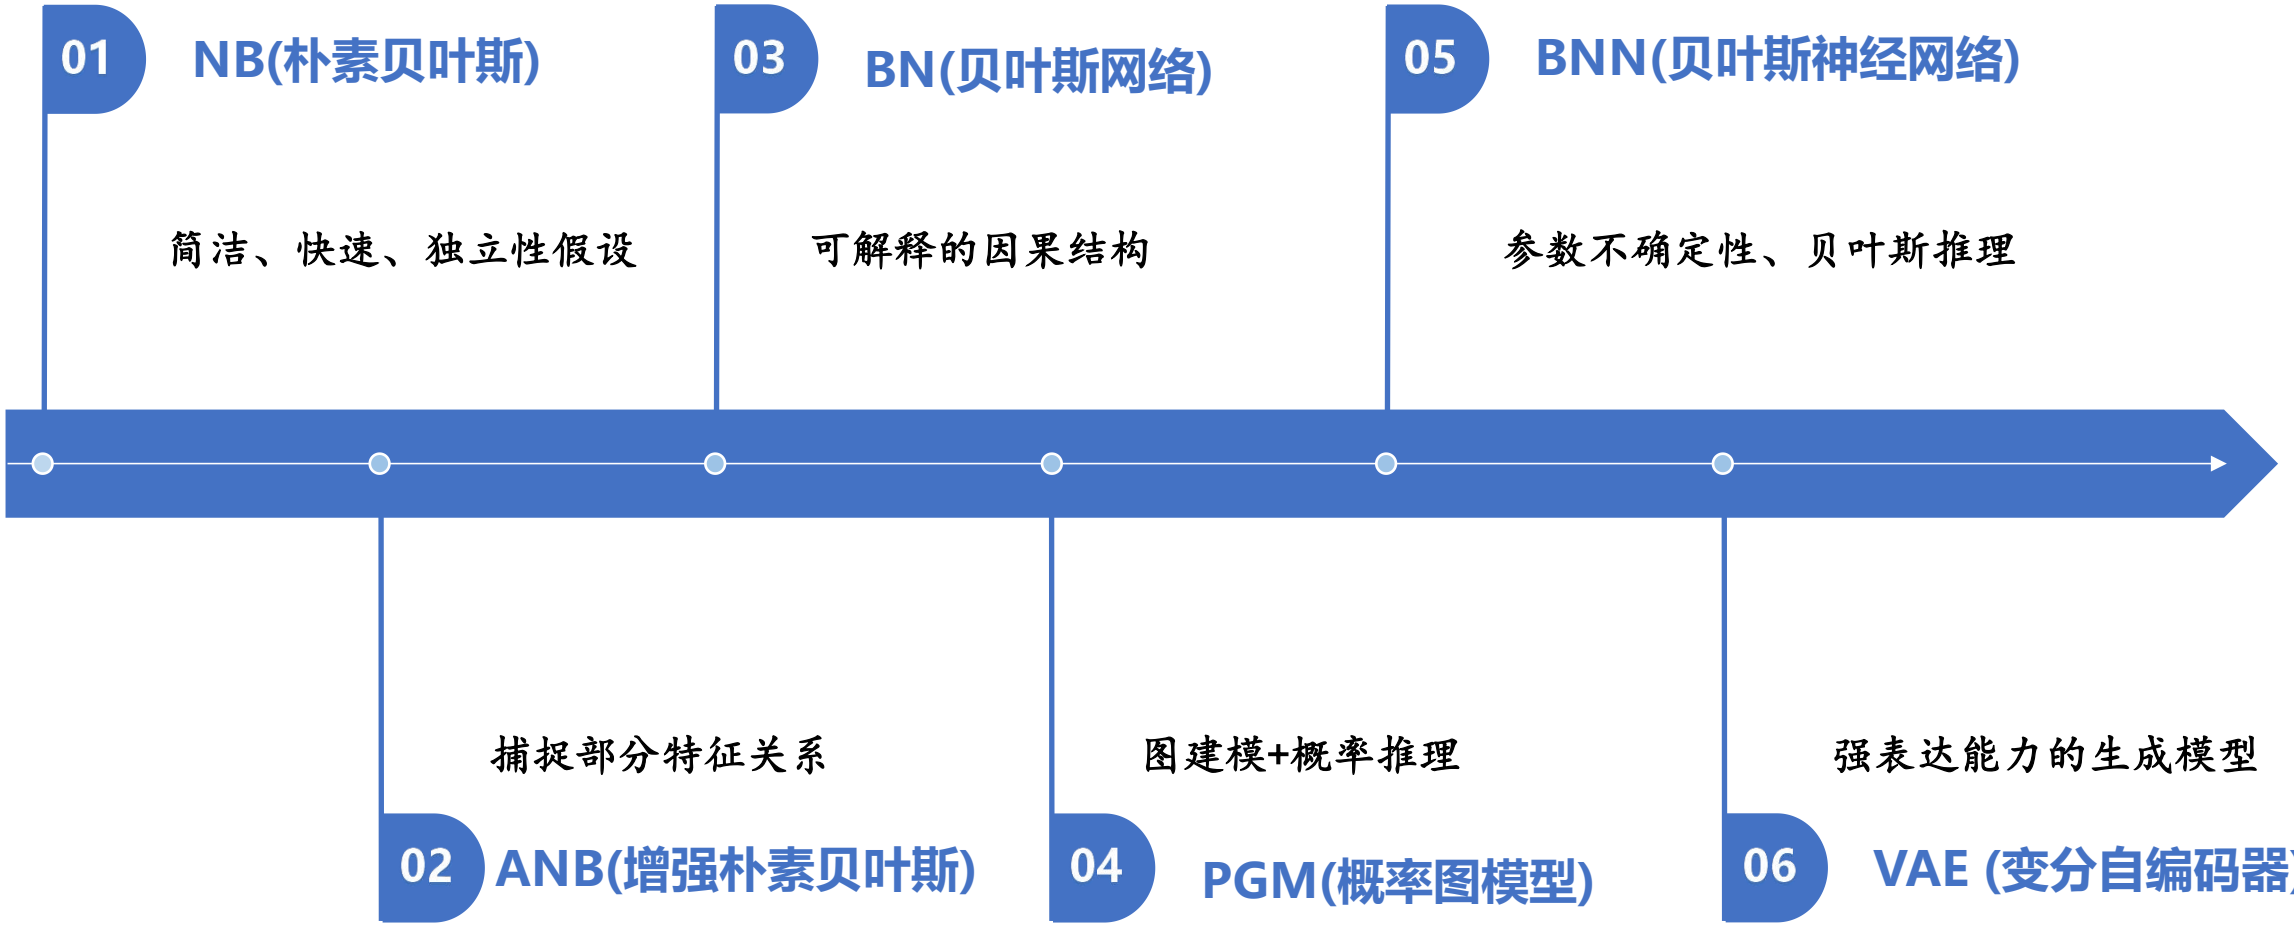
$$P(x^1, x^2, \ldots, x^p|c_i) = \prod_{j=1,\ldots,K} P(x^j|c_i)$$

朴素贝叶斯分类

$$arg \max_{i=1,2,\ldots,K} P(c_i) \prod_{j=1,\ldots,p} P(x^j|c_i)$$

贝叶斯分类

首都师范大学 CAPITAL NORMAL UNIVERSITY



大纲

01 逻辑回归

02 贝叶斯分类

03 生成式 vs 判别式模型

01 同一个分类问题，两种学习思路



正常邮件，
还是垃圾邮件？

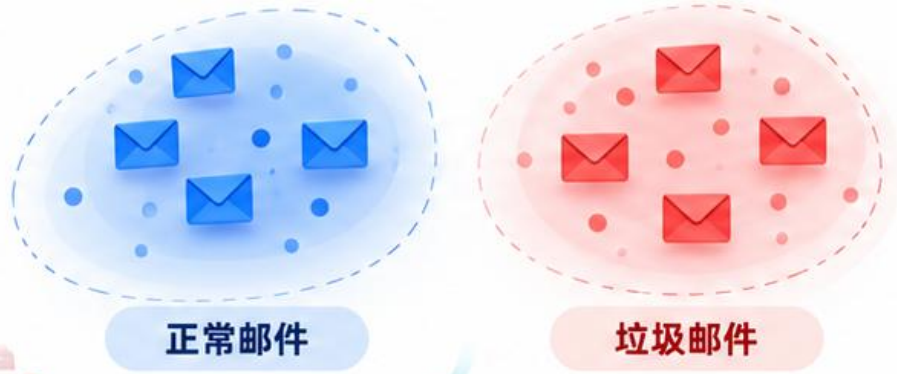
判别式

直接学习**如何区分**



生成式

先学习**每一类的样子**





🎯 目标都是分类，**学习的对象不同**

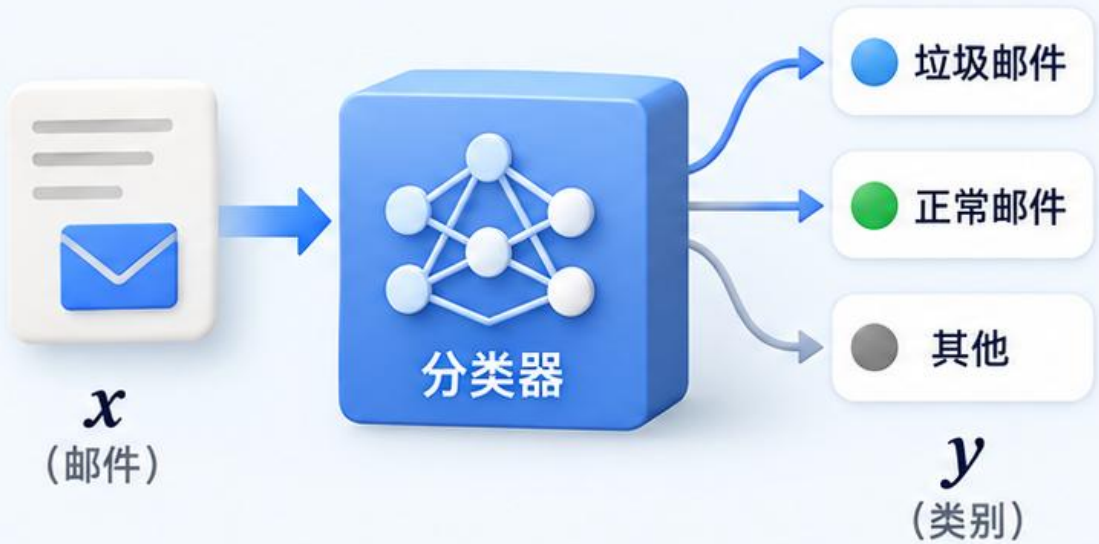
02 生成式与判别式：定义

x：特征　y：类别

判别式

直接建模类别后验

$$P_\theta(y \mid x)$$



也可直接学习决策函数 $f_\theta(x)$。

生成式分类模型

$P_\theta(y)$　　$P_\theta(x \mid y)$



$$P_\theta(x, y) = P_\theta(y) P_\theta(x \mid y)$$

贝叶斯公式

$$P_\theta(y \mid x) = \frac{P_\theta(x, y)}{\sum_{k=1}^{K} P_\theta(x, k)}$$

更一般的生成模型：学习数据分布 $P_\theta(x)$，并从中采样。

03 回看逻辑回归与朴素贝叶斯

逻辑回归 LR

直接拟合后验

$$P(y=1|\boldsymbol{x})=\sigma(\boldsymbol{w}^T\boldsymbol{x}+b)$$

邮件特征 $\boldsymbol{x}$

- 包含关键词
- 包含附件
- 发件人特征
- 正文长度
- ...

加权分类

w^Tx+b

类别概率

$P(y=1|x)$ 0.93

$P(y=0|x)$ 0.07

条件最大似然 ↔ 交叉熵最小化

朴素贝叶斯 NB

先拟合先验与类条件分布

$$P(\boldsymbol{x},y)=P(y)\prod_{j=1}^{d}P(x_j|y)$$

垃圾邮件 $y=1$

特征概率档案 $P(x_j|y=1)$

关键词 0.8

包含附件 0.6

正文长度 0.3

...

正常邮件 $y=0$

特征概率档案 $P(x_j|y=0)$

关键词 0.1

包含附件 0.2

正文长度 0.7

...

贝叶斯推断

$P(y|x)=\frac{P(x,y)}{P(x)}$

类别概率

$P(y=1|x)$ 0.93

$P(y=0|x)$ 0.07

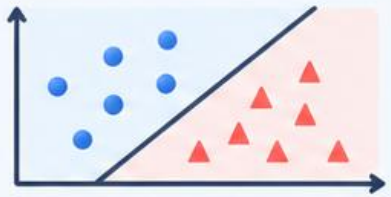
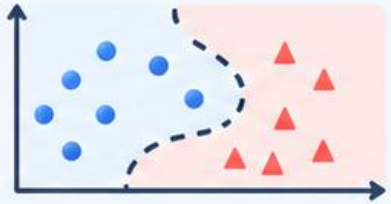
给定类别后，特征条件独立

都能得到 $P(y|x)$

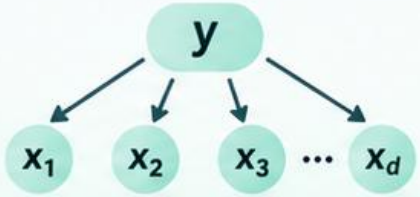
后验可以相似，学习方式并不相同。

04 如何选择：看假设、数据与目标

逻辑回归 LR

假设		对数几率是特征的线性函数
优势		联合学习权重，正则化灵活
局限		复杂非线性需特征或表示学习
优先尝试		文本 / 表格；特征存在相关性

朴素贝叶斯 NB

假设		给定类别后，特征条件独立
优势		训练快，计算省
局限		相关证据可能导致过度自信
优先尝试		快速基线；样本或算力有限



最终用验证集比较；少数据用 NB 不是定律。

05 从朴素贝叶斯到现代生成式 AI

共同思想：学习数据分布 → 采样生成

朴素贝叶斯



简单词袋，缺少词序与上下文

$$P(w_1, \ldots, w_T \mid y) = \prod_{t=1}^{T} P(w_t \mid y)$$

自回归语言模型



每一步依赖前文，学习复杂关系

$$P(w_1, \ldots, w_T) = \prod_{t=1}^{T} P(w_t \mid w_{<t})$$

扩散：逐步去噪生成



共享建模思想，不是算法的简单放大

现代生成模型并不都用交叉熵



首都师范大学
CAPITAL NORMAL UNIVERSITY