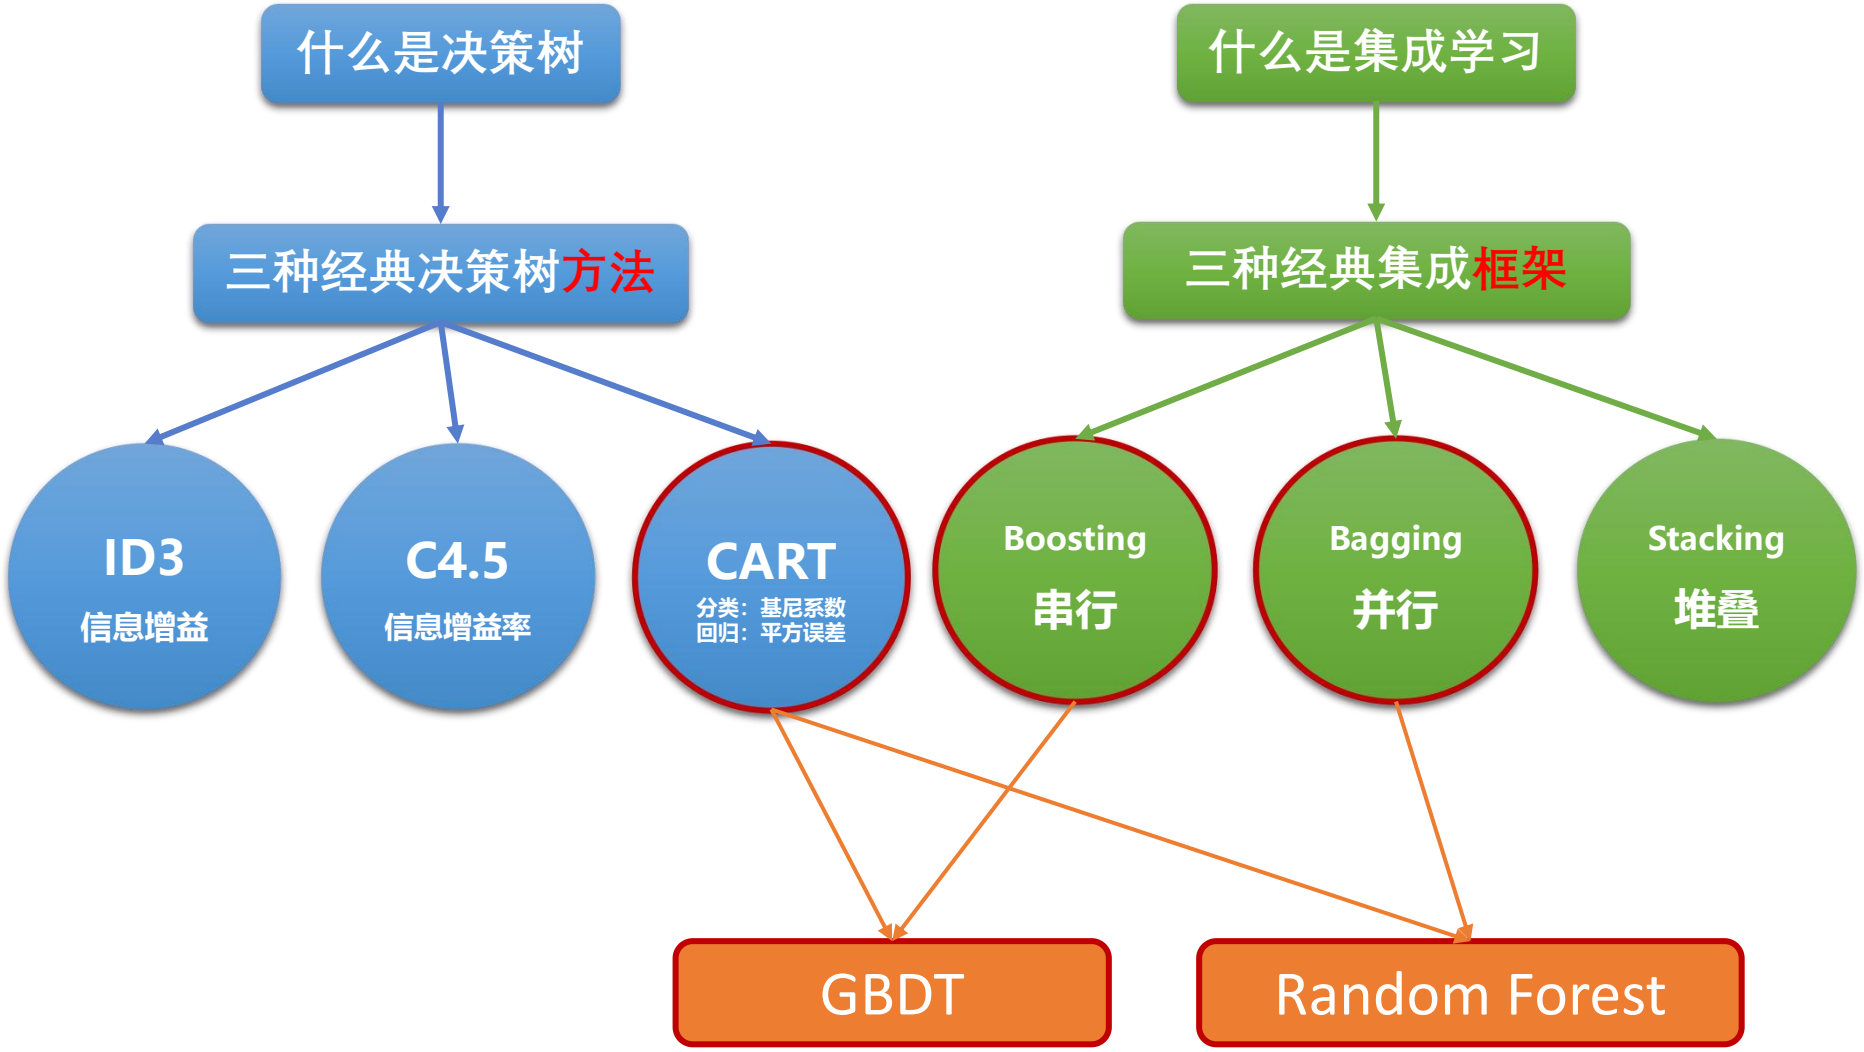
首都师范大学
CAPITAL NORMAL UNIVERSITY



第九课
决策树和集成学习

授课教师：潘贤丽

大纲


什么是决策树
三种经典决策树方法
ID3
信息增益
C4.5
信息增益率
CART
分类：基尼系数
回归：平方误差
什么是集成学习
三种经典集成框架
Boosting
串行
Bagging
并行
Stacking
堆叠
GBDT
Random Forest

人是怎么做
决策的?



决策树

选课

出门带
不带伞

点外卖



买手机

找对象

找工作

决策树



高级算法工程师 [北京·大兴区·亦庄]

100-150K·16薪 经验不限 本科 李先生 招聘专家

京东集团

电子商务 已上市 10000人以上

业务导向 | 搜索/推荐

交通补助，包吃，零食下午茶，年终奖，股票期权，五险一…

图像算法工程师 [北京·海淀区·上地]

25-45K·16薪 3-5年 本科 黄女士 HR 在线

小米

互联网 已上市 10000人以上

大模型算法 | 图像算法 | Python | C/C++

股票期权，五险一金，年终奖，带薪年假，餐补，节日福利…

光学工程师 [北京·海淀区·西北旺]

22-40K 在校/应届 硕士 陈先生 算法

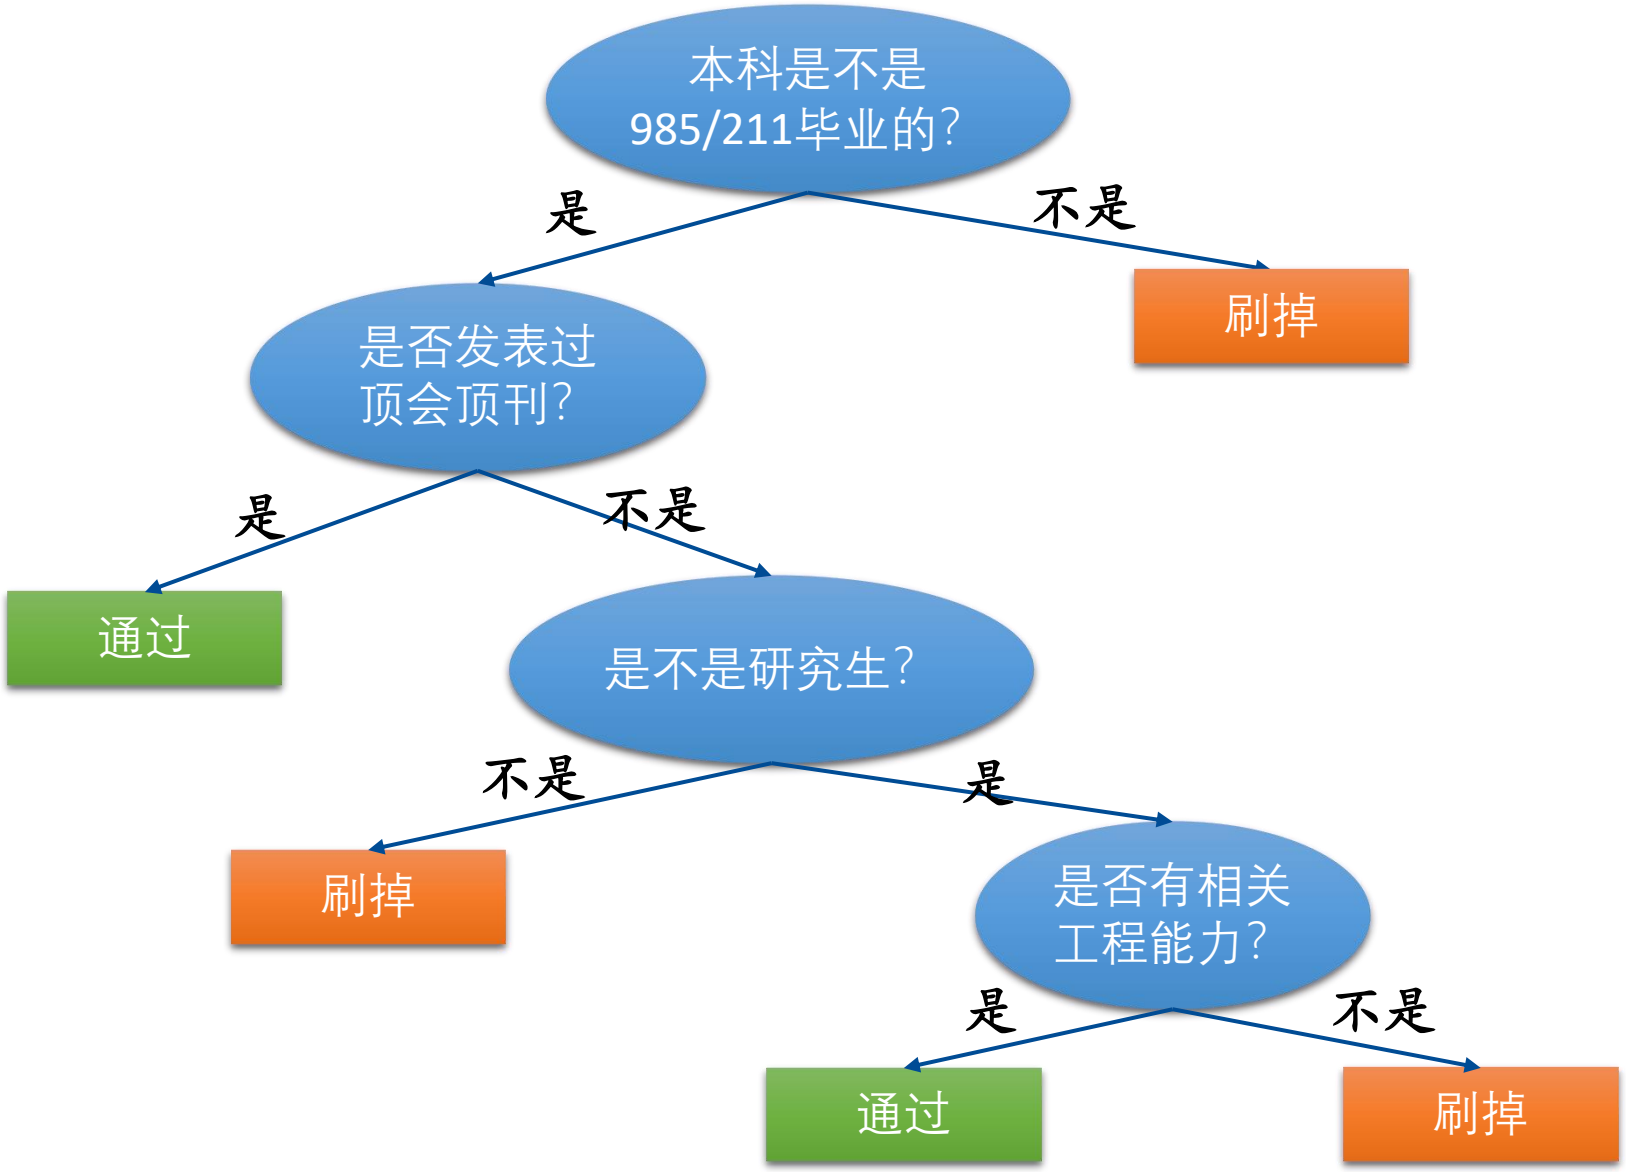
荣耀终端

互联网 未融资 10000人以上

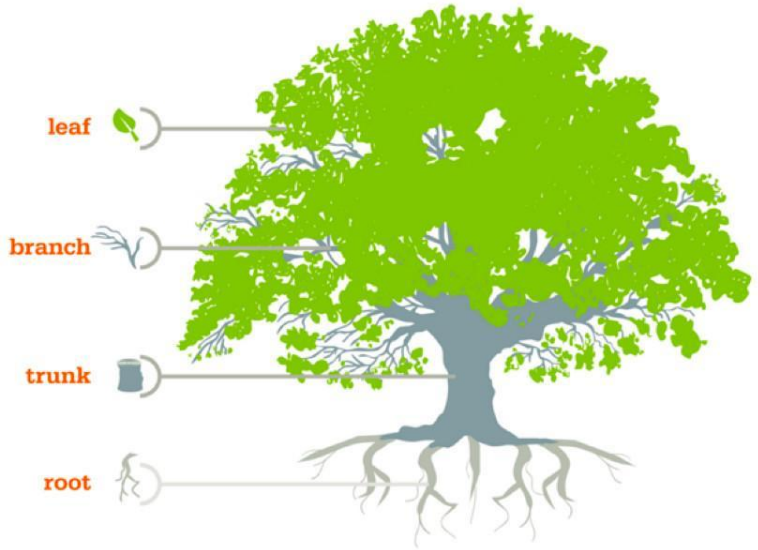
算法设计 | C++

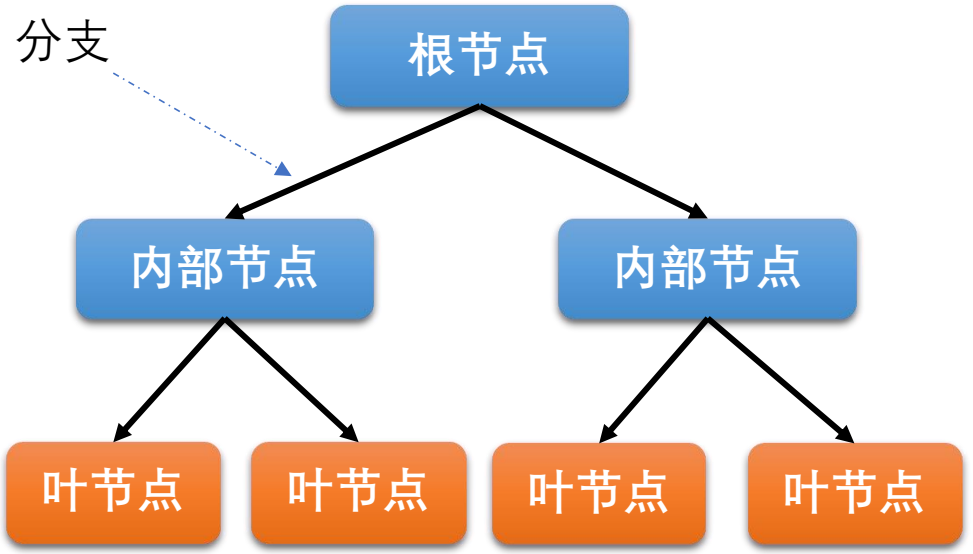
股票期权，节日福利，加班费，免费班车，员工旅游，夜班…

决策树


本科是不是
985/211毕业的?
是
不是
刷掉
是否发表过
顶会顶刊?
是
不是
通过
是不是研究生?
不是
是
刷掉
是否有相关
工程能力?
是
不是
通过
刷掉

决策树：从训练数据中学习得出一个树状结构的模型

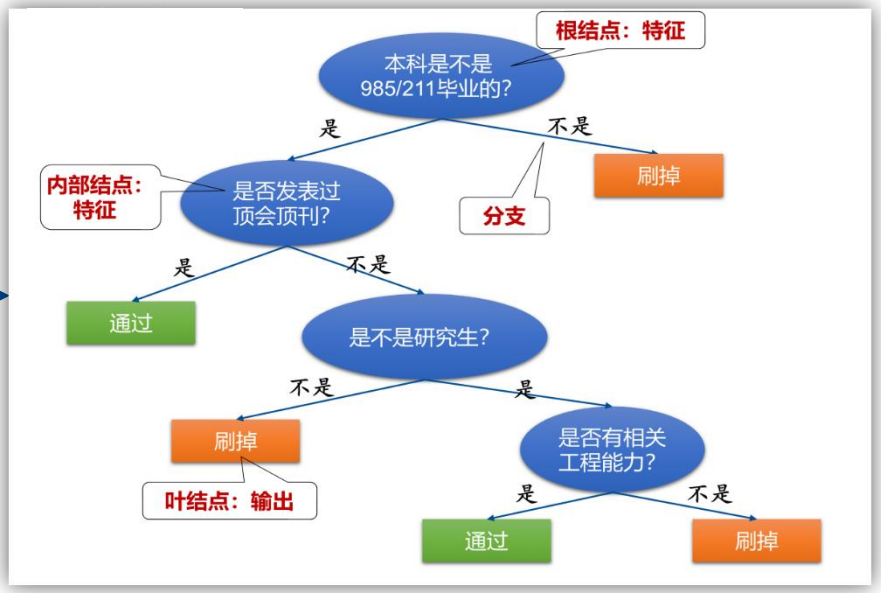




决策树

构造决策树模型

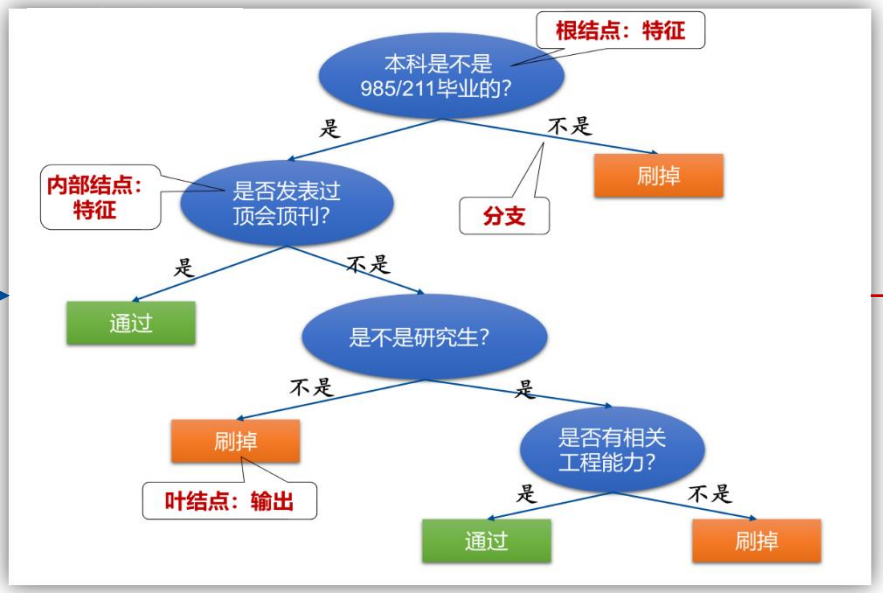
姓名	本科	学历	论文	项目	编程	结论
张三	非985/211	本科	1	无	不会	刷掉
李四	211	专科	1	无	不会	刷掉
王五	211	硕士	无	有	会	通过
赵六	985	博士	2	有	会	通过
…	…	…	…	…	…	…



决策树

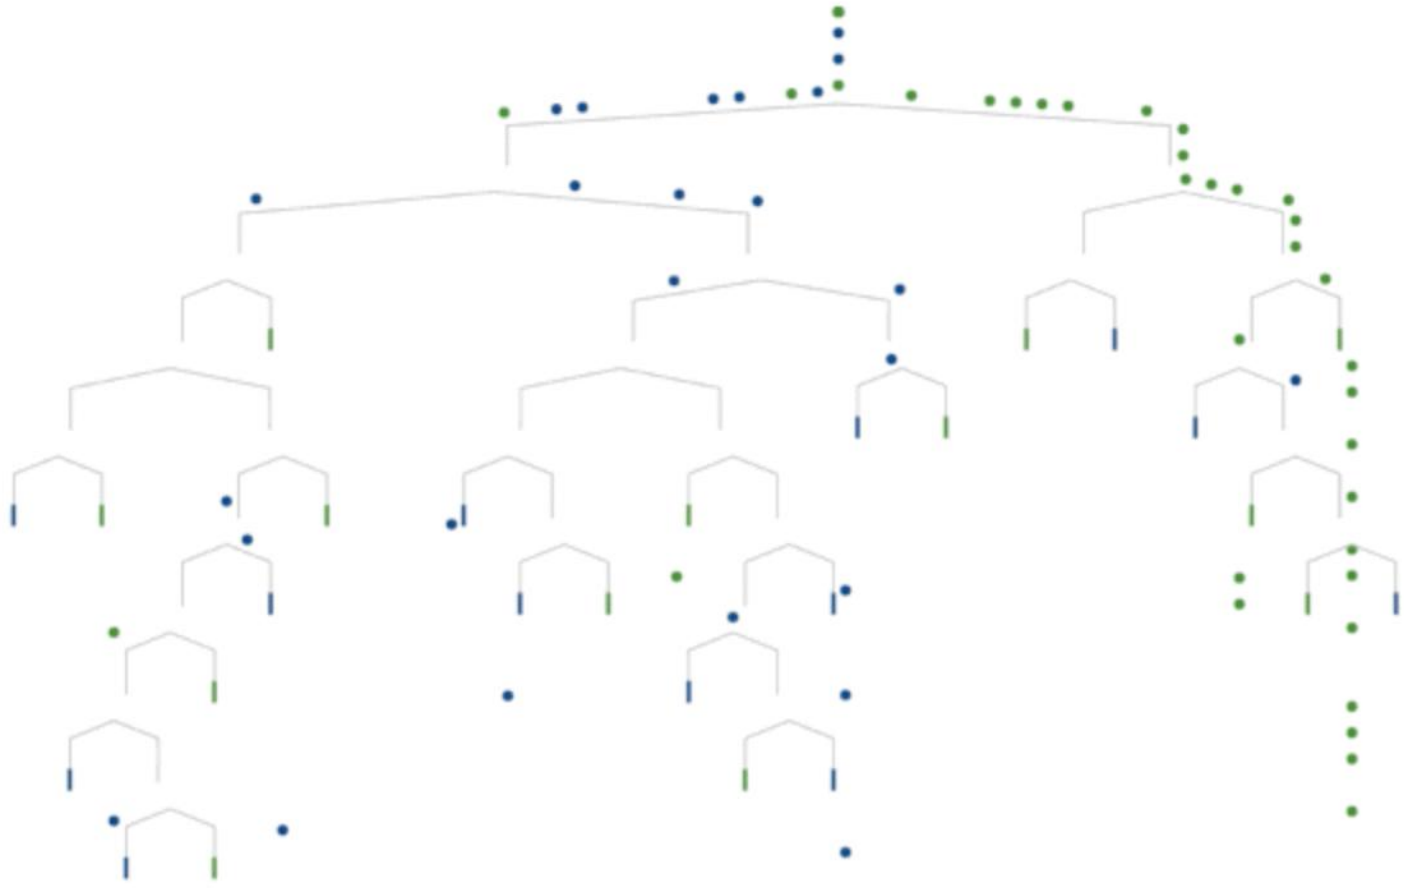
构造决策树模型

姓名	本科	学历	论文	项目	编程	结论
张三	非985/211	本科	1	无	不会	刷掉
李四	211	专科	1	无	不会	刷掉
王五	211	硕士	无	有	会	通过
赵六	985	博士	2	有	会	通过
…	…	…	…	…	…	…
钱七	985	硕士	无	有	会	?



对新样本做判断

决策树



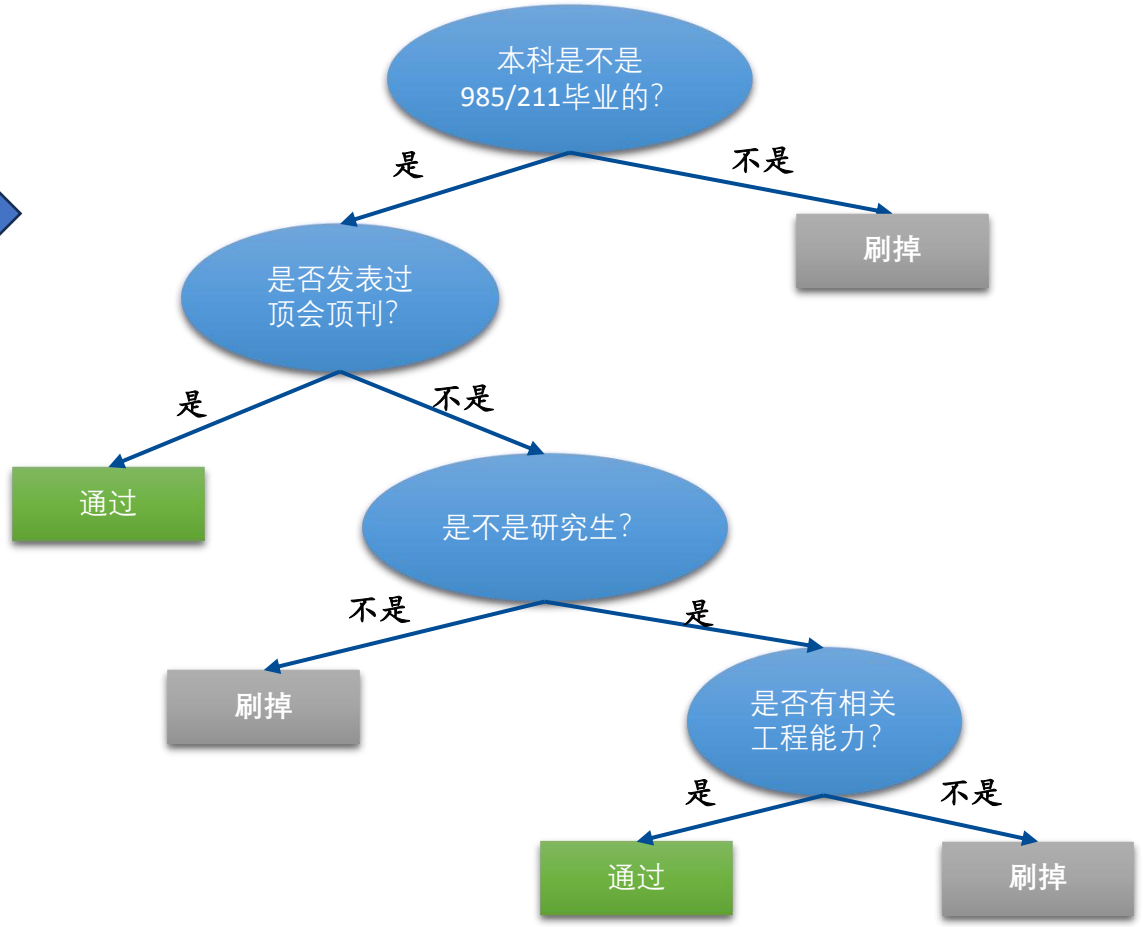
怎么构造决策树?



决策树

姓名	本科	学历	论文	项目	编程	结论
张三	非985/211	本科	1	无	不会	刷掉
李四	211	专科	1	无	不会	刷掉
王五	211	硕士	无	有	会	通过
赵六	985	博士	2	有	会	通过
…	…	…	…	…	…	…





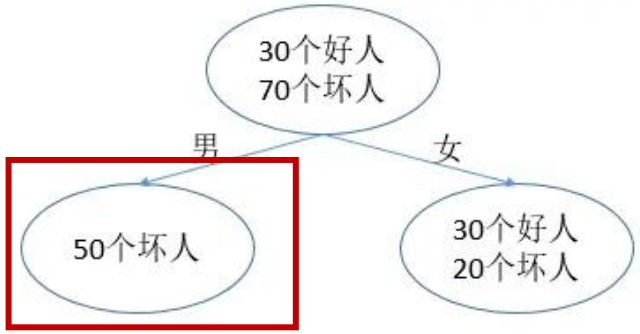
- 每次选哪个特征分裂?
- 怎么分裂?
- 什么时候停止分裂?

决策树

举个栗子：生成决策树用于判断一个人是好人还是坏人。样本集是100个人，可用的特征有三个：性别：{男，女}，年龄段：{青年，中年，老年}，地域：{北京，深圳}。

停止条件1

当前结点包含的样本都属于同一类



决策树

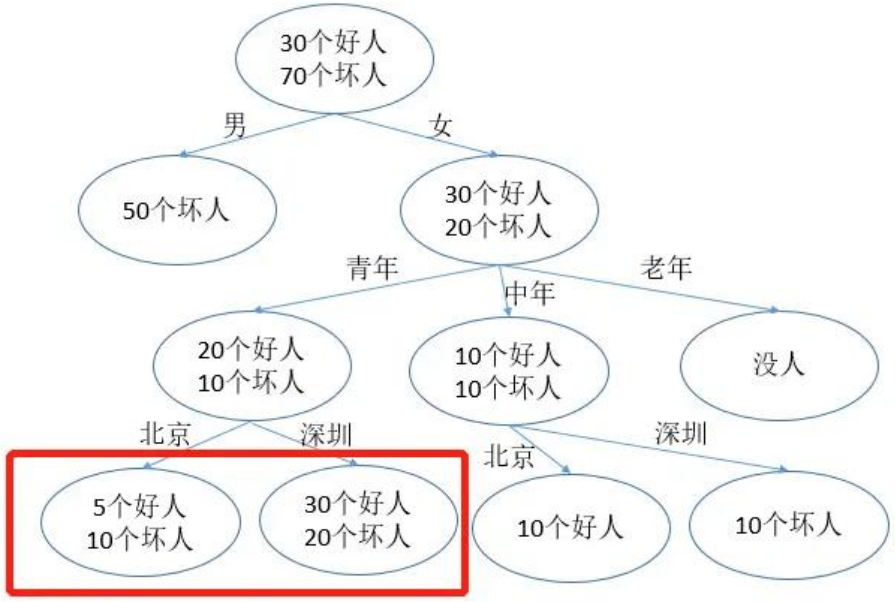
举个栗子：生成决策树用于判断一个人是好人还是坏人。样本集是100个人，可用的特征有三个：性别：{男，女}，年龄段：{青年，中年，老年}，地域：{北京，深圳}。

停止条件1

当前结点包含的样本都属于同一类

停止条件2

样本属性取值都相同或属性集为空



决策树

举个栗子：生成决策树用于判断一个人是好人还是坏人。样本集是100个人，可用的特征有三个：性别：{男，女}，年龄段：{青年，中年，老年}，地域：{北京，深圳}。

停止条件1

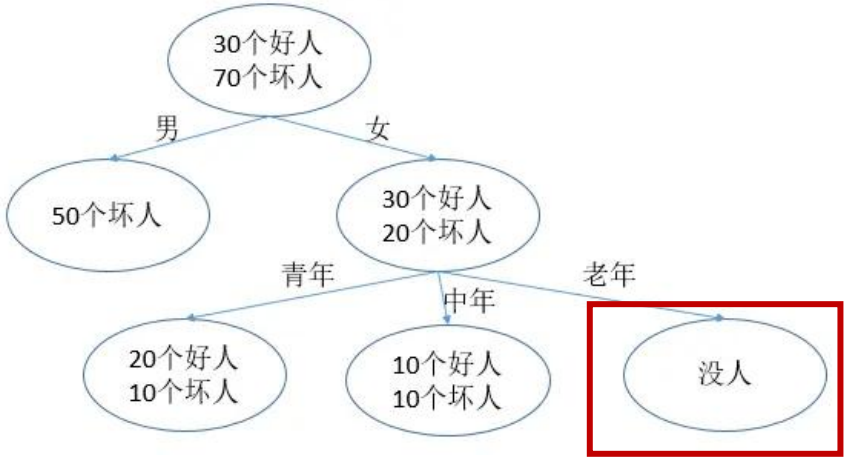
当前结点包含的样本都属于同一类

停止条件2

样本属性取值都相同或属性集为空

停止条件3

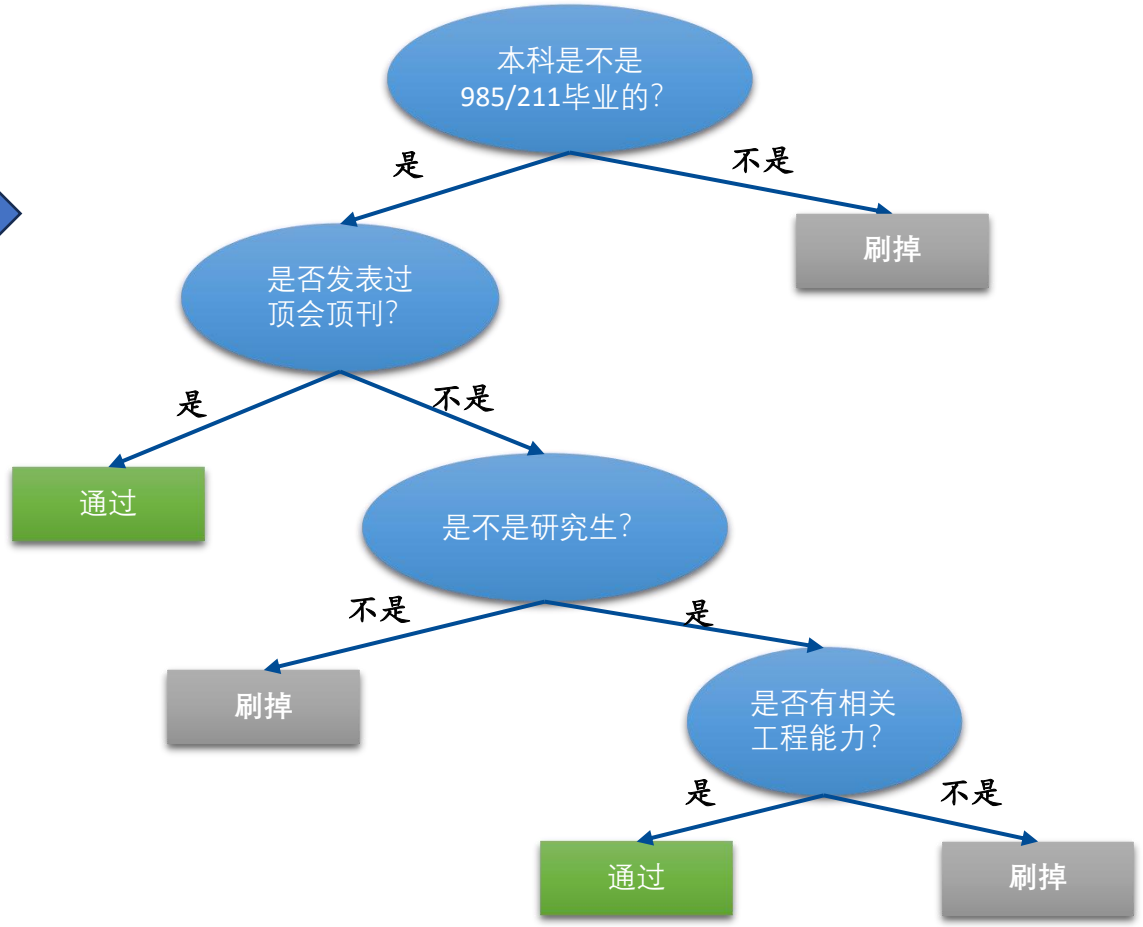
当前结点包含的样本集合为空



决策树

姓名	本科	学历	论文	项目	编程	结论
张三	非985/211	本科	1	无	不会	刷掉
李四	211	专科	1	无	不会	刷掉
王五	211	硕士	无	有	会	通过
赵六	985	博士	2	有	会	通过
…	…	…	…	…	…	…





- 每次选哪个特征分裂?
- 怎么分裂?
- 什么时候停止分裂?

决策树



分类特征　　连续特征

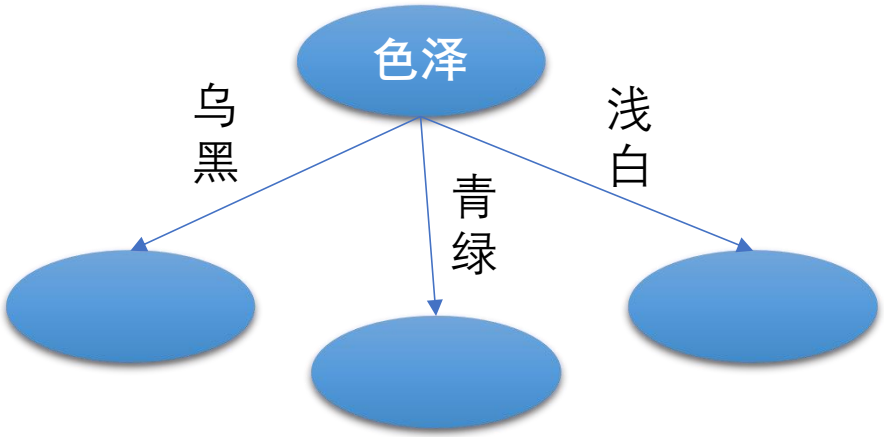
编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

决策树

分类特征

色泽：乌黑、青绿、浅白

根蒂：蜷缩、稍蜷、硬挺

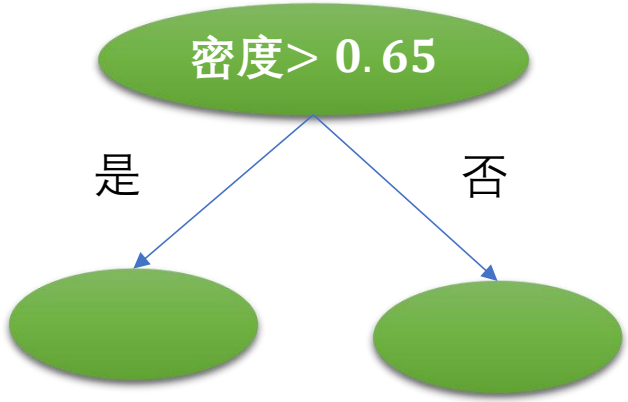


多叉树

连续特征

密度：0.697、0.774、0.634……

年龄：48、27、19……

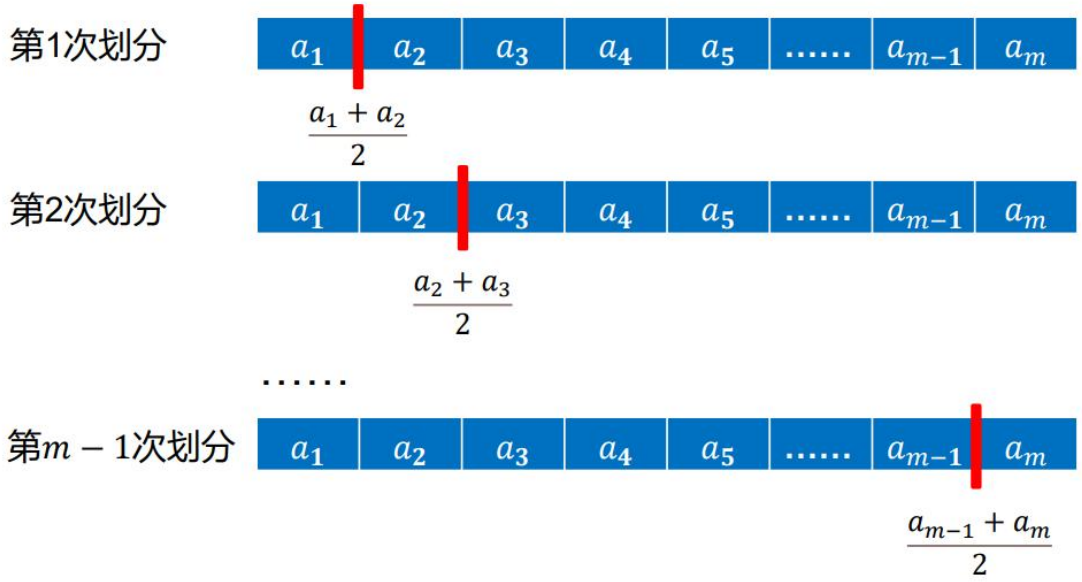


二叉树

决策树

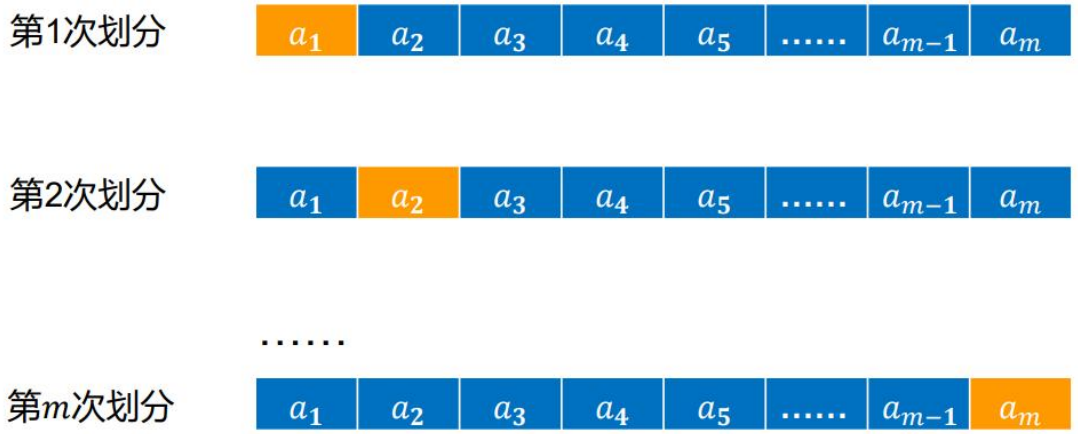
连续特征构造二叉树

- 先从小到大排序
- 从中选一个最优划分



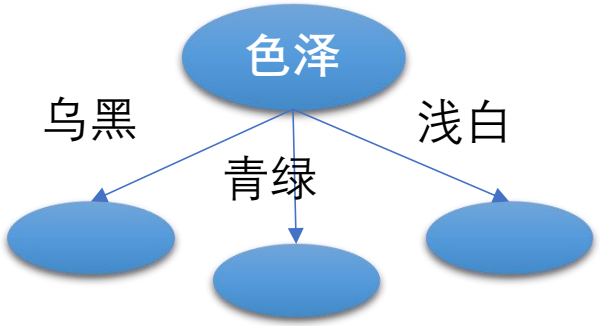
分类特征构造二叉树

- 选一个最优属性值



决策树

① 分类特征+多叉树



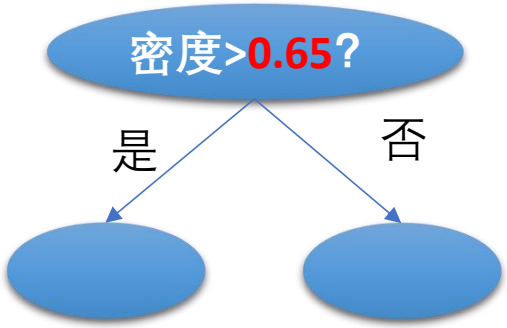
特征不可重复利用

② 分类特征+二叉树



特征可重复利用

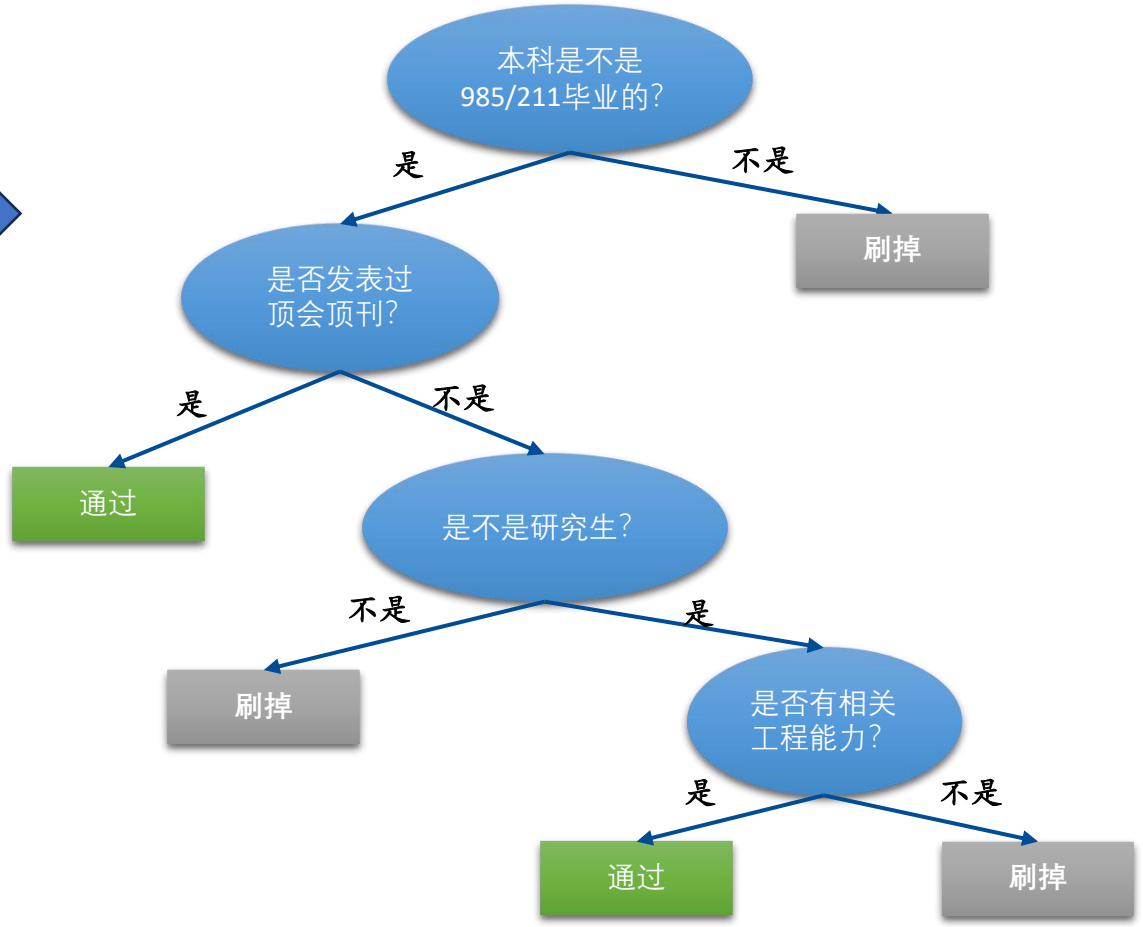
③ 连续特征+二叉树



决策树

姓名	本科	学历	论文	项目	编程	结论
张三	非985/211	本科	1	无	不会	刷掉
李四	211	专科	1	无	不会	刷掉
王五	211	硕士	无	有	会	通过
赵六	985	博士	2	有	会	通过
…	…	…	…	…	…	…





- 每次选哪个特征分裂?
- 怎么分裂?
- 什么时候停止分裂?

分类

信息增益

信息增益率

基尼指数

回归

平方误差

抛硬币



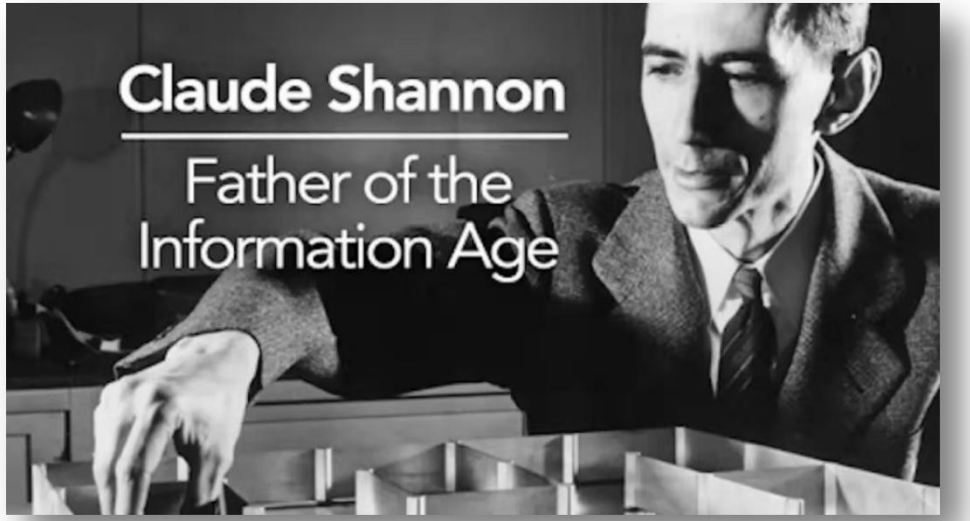
掷骰子



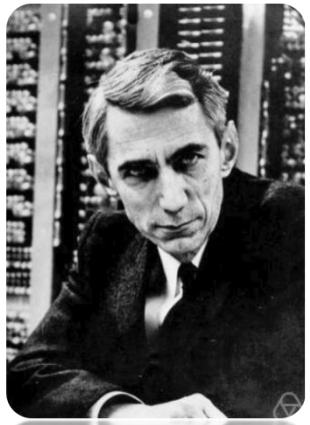
哪个不确定性更强？



如何理解信息熵_哔哩哔哩_bilibili



【天才简史-香农】一个能和牛顿、爱因斯坦比肩的神级天才，但你可能连他名字都没听过！_哔哩哔哩_bilibili



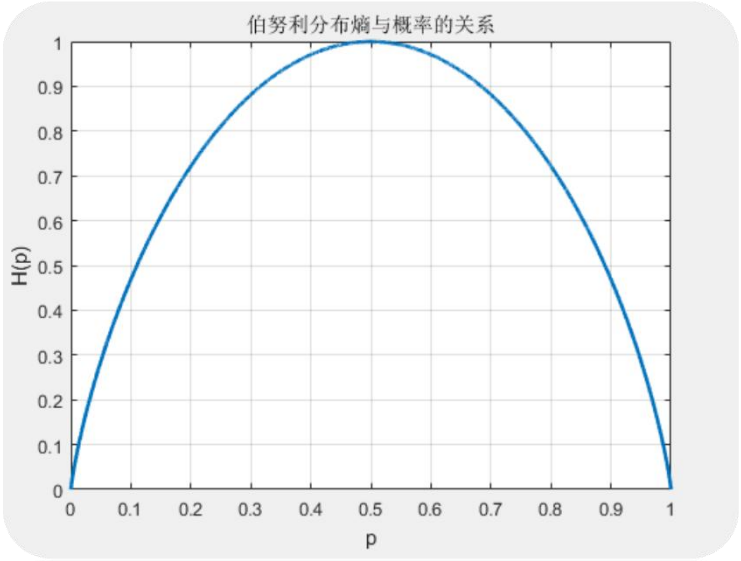
熵

随机变量X可能的取值为$\{x_1, x_2, ..., x_n\}$，其概率分布为 $P(X = x_i) = p_i,\ i = 1,\ 2,\ ...,\ n$，则随机变量$X$的熵定义为$\mathrm{H}(X)$：

$$\mathrm{H}(X) = -\sum_{i=1}^{n} p_i log p_i$$

熵越大，表示X的不确定性越大

- 若$p = 0$, 则$p log_2 p = 0$
- $\mathrm{H}(X) \in [0, log_2 n]$



抛硬币



$$\mathrm{H}(X) = -\left(\frac{1}{2}log\frac{1}{2} + \frac{1}{2}log\frac{1}{2}\right) = 1$$

掷骰子



$$\mathrm{H}(X) = -6 * \left(\frac{1}{6}log\frac{1}{6}\right) = log6$$

熵：$\mathrm{H(X)} = -\sum_{i=1}^{n} p_i log p_i$

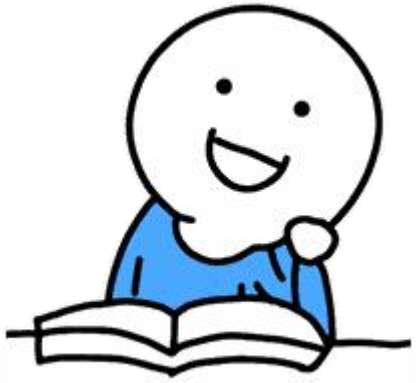
条件熵：

$$\mathrm{H(Y|X)} = \sum_{i=1}^{n} P(\mathrm{X} = x_i)\, \mathrm{H(Y|X} = x_i)$$

互信息：

$$\mathrm{I(X}, Y) = H(X) - H(X|Y)$$

$$= H(Y) - H(Y|X)$$



分类问题

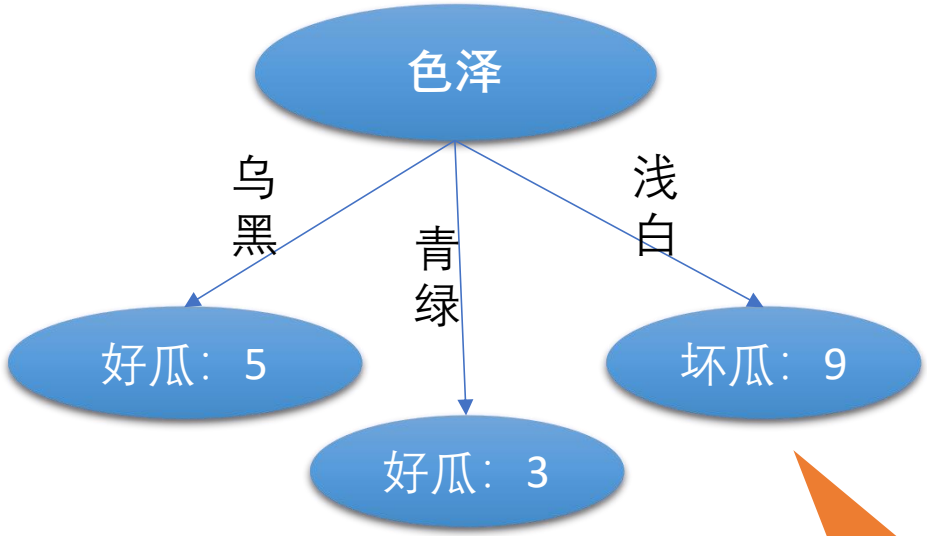
分类特征

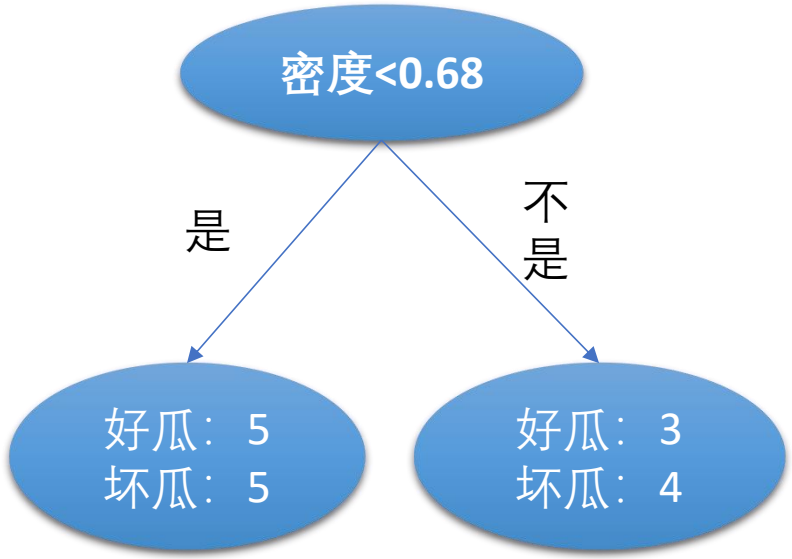
连续特征

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响				0.403	0.237	是
7	乌黑	稍蜷	浊				481	0.149	是
8	乌黑	稍蜷					37	0.211	是
9	乌黑	稍蜷	沉				566	0.091	否
10	青绿	硬挺	清脆				0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

选择什么特征
先进行分裂呢？

决策树





分裂之后Y的不确定性降低

互信息： $\mathrm{I}(X, Y) = H(X) - H(X|Y)$

假设样本集D中共有K类，其中第k类样本所占比例为p_k，

得知特征a的信息后，标签Y的不确定性减少的程度

衡量指标：信息增益

$$Gain(D, a) = Ent(D) - Ent(D|a)$$

标签Y的信息熵：

$$\mathrm{Ent}(D) = -\sum_{k=1}^{K} p_k log_2 p_k$$

特征a给定条件下Y的条件熵：

$$\mathrm{Ent}(\mathrm{D}|a) = \sum_{i=1}^{n} P(a = a_i)\,\mathrm{Ent}(\mathrm{D}|a = a_i)$$

西瓜数据集（离散特征，二分类）

编号	色泽	根蒂	敲声	纹理	脐部	触感	是否好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

是否好瓜
是
是
是
是
是
是
是
是
否
否
否
否
否
否
否
否
否

$$\mathrm{Ent}(D) = -\sum_{k=1}^{2} p_k \log_2 p_k = -\left(\frac{8}{17}\log_2\frac{8}{17} + \frac{9}{17}\log_2\frac{9}{17}\right) = 0.998$$

属性：色泽

取值：青绿（D^1）、乌黑（D^2）、浅白（D^3）

编号	色泽	根蒂	敲声	纹理	脐部	触感	是否好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

$$\mathrm{Ent}(D^1) = -\left(\frac{3}{6}\log_2\frac{3}{6} + \frac{3}{6}\log_2\frac{3}{6}\right) = 1.000$$

是否好瓜
是
是
是
是
是
是
是
是
否
否
否
否
否
否
否
否
否

$$\mathrm{Ent}(D) = -\sum_{k=1}^{2} p_k \log_2 p_k = -\left(\frac{8}{17}\log_2\frac{8}{17} + \frac{9}{17}\log_2\frac{9}{17}\right) = 0.998$$

属性：色泽

取值：青绿（D^1）、乌黑（D^2）、浅白（D^3）

编号	色泽	根蒂	敲声	纹理	脐部	触感	是否好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

$$\mathrm{Ent}(D^2) = -\left(\frac{4}{6}\log_2\frac{4}{6} + \frac{2}{6}\log_2\frac{2}{6}\right) = 0.918$$

是否好瓜
是
是
是
是
是
是
是
是
否
否
否
否
否
否
否
否
否

$$\mathrm{Ent}(D) = -\sum_{k=1}^{2} p_k \log_2 p_k = -\left(\frac{8}{17}\log_2\frac{8}{17} + \frac{9}{17}\log_2\frac{9}{17}\right) = 0.998$$

属性：色泽

取值：青绿（D^1）、乌黑（D^2）、浅白（D^3）

编号	色泽	根蒂	敲声	纹理	脐部	触感	是否好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

$$\mathrm{Ent}(D^3) = -\left(\frac{1}{5}\log_2\frac{1}{5} + \frac{4}{5}\log_2\frac{4}{5}\right) = 0.722$$

是否好瓜
是
是
是
是
是
是
是
是
否
否
否
否
否
否
否
否
否
否

$$\mathrm{Ent}(D) = -\sum_{k=1}^{2} p_k \log_2 p_k = -\left(\frac{8}{17}\log_2\frac{8}{17} + \frac{9}{17}\log_2\frac{9}{17}\right) = 0.998$$

属性：色泽

取值：

青绿（D^1）

乌黑（D^2）

浅白（D^3）

$$\mathrm{Ent}(D^1) = -\left(\frac{3}{6}\log_2\frac{3}{6} + \frac{3}{6}\log_2\frac{3}{6}\right) = 1.000$$

$$\mathrm{Ent}(D^2) = -\left(\frac{4}{6}\log_2\frac{4}{6} + \frac{2}{6}\log_2\frac{2}{6}\right) = 0.918$$

$$\mathrm{Ent}(D^3) = -\left(\frac{1}{5}\log_2\frac{1}{5} + \frac{4}{5}\log_2\frac{4}{5}\right) = 0.722$$

$$\begin{aligned}\mathrm{Gain}(D, \text{色泽}) &= \mathrm{Ent}(D) - \sum_{v=1}^{3}\frac{|D^v|}{|D|}\mathrm{Ent}(D^v) \\ &= 0.998 - \left(\frac{6}{17}\times 1.000 + \frac{6}{17}\times 0.918 + \frac{5}{17}\times 0.722\right) \\ &= 0.109\ .\end{aligned}$$

是否好瓜
是
是
是
是
是
是
是
是
否
否
否
否
否
否
否
否
否
否

$$\begin{aligned}\mathrm{Gain}(D, \text{色泽}) &= \mathrm{Ent}(D) - \sum_{v=1}^{3} \frac{|D^v|}{|D|}\mathrm{Ent}(D^v) \\ &= 0.998 - \left(\frac{6}{17} \times 1.000 + \frac{6}{17} \times 0.918 + \frac{5}{17} \times 0.722\right) \\ &= 0.109 \ .\end{aligned}$$

$$\mathrm{Gain}(D, \text{根蒂}) = 0.143; \quad \mathrm{Gain}(D, \text{敲声}) = 0.141;$$

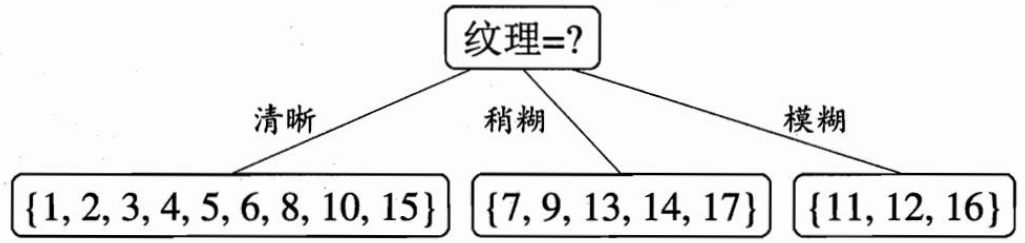
$$\mathrm{Gain}(D, \text{纹理}) = 0.381; \quad \mathrm{Gain}(D, \text{脐部}) = 0.289;$$

$$\mathrm{Gain}(D, \text{触感}) = 0.006.$$

决策树

西瓜数据集（离散特征，二分类）

编号	色泽	根蒂	敲声	纹理	脐部	触感	是否好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否



编号	色泽	根蒂	敲声	纹理	脐部	触感	是否好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否

$$\text{Gain}(D^1, \text{色泽}) = 0.043; \quad \text{Gain}(D^1, \text{根蒂}) = 0.458;$$
$$\text{Gain}(D^1, \text{敲声}) = 0.331; \quad \text{Gain}(D^1, \text{脐部}) = 0.458;$$
$$\text{Gain}(D^1, \text{触感}) = 0.458.$$

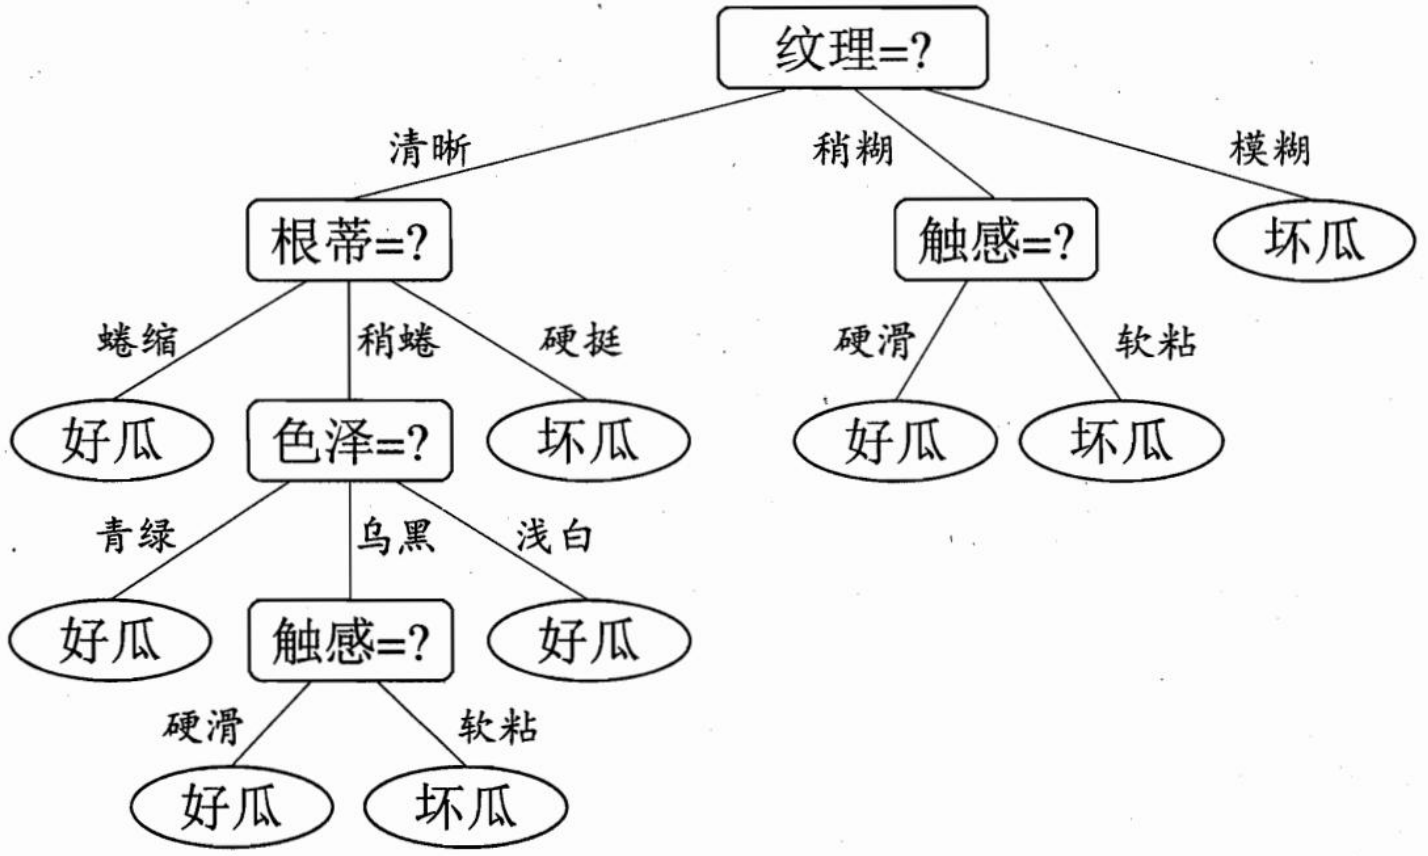


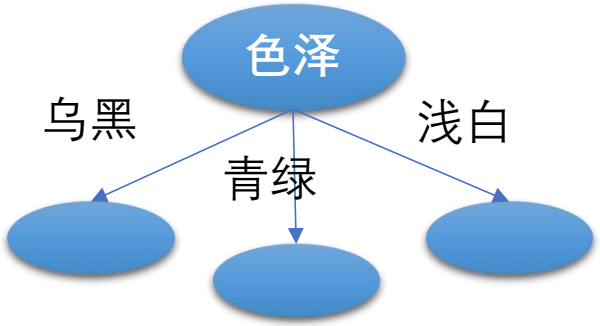
图 4.4 在西瓜数据集 2.0 上基于信息增益生成的决策树

决策树

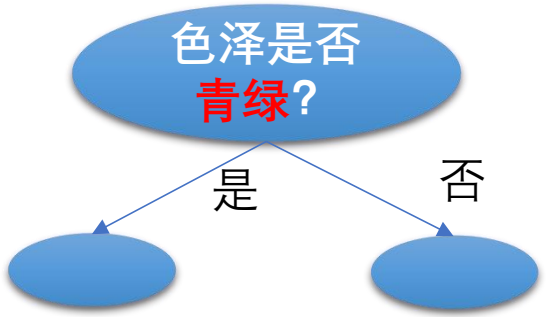
1. 开始：将所有训练数据作为根节点数据
2. 特征选择：根据最大信息增益选择一个特征进行分裂
3. 分裂节点：
    1. 根据选定特征，将当前节点数据分裂成若干子集，每个子集对应该特征的一个值
    2. 创建与这些子集相对应的节点，并将其作为当前节点的子节点
4. 递归分裂：对每个子节点，递归地重复步骤2和3，直到满足某停止条件
5. 完成：若所有节点满足停止条件，算法结束

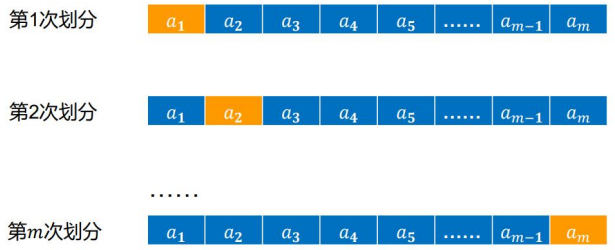
决策树

① 分类特征+多叉树

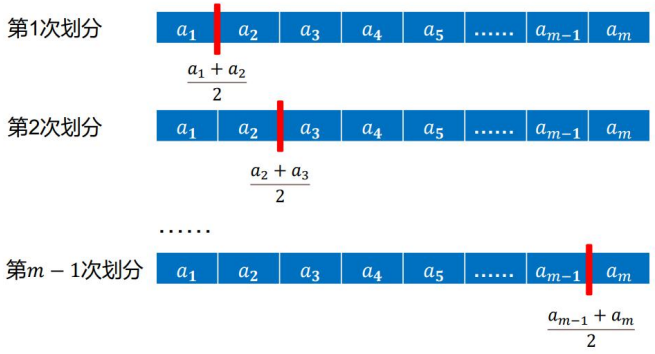


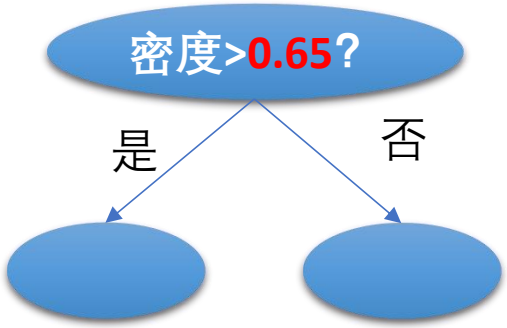
② 分类特征+二叉树





③ 连续特征+二叉树





选特征的同时，
还要选切分点

信息增益倾向于选择取值多的特征

西瓜数据集（离散特征，二分类）

编号	色泽	根蒂	敲声	纹理	脐部	触感	是否好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

衡量指标：信息增益 → 衡量指标：信息增益率

$$Gain(D,a) = Ent(D) - Ent(D|a)$$

$$Gain_ratio(D,a) = \frac{Gain(D,a)}{IV(a)}$$

$$IV(a) = -\sum_{i=1}^{n} \frac{|D(a=a_i)|}{|D|} \log \frac{|D(a=a_i)|}{|D|}$$

$IV(a)$：特征a的固有值

1. 开始：将所有训练数据作为根节点数据
2. 特征选择：根据最大信息增益率选择一个特征进行分裂
3. 分裂节点：
    1. 根据选定特征，将当前节点数据分裂成若干子集，每个子集对应该特征的一个值
    2. 创建与这些子集相对应的节点，并将其作为当前节点的子节点
4. 递归分裂：对每个子节点，递归地重复步骤2和3，直到满足某停止条件
5. 完成：若所有节点满足停止条件，算法结束

西瓜数据集（离散特征，二分类）

编号	色泽	根蒂	敲声	纹理	脐部	触感	是否好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

是否好瓜
是
是
是
是
是
是
是
是
否
否
否
否
否
否
否
否
否

$$\mathrm{Ent}(D) = -\sum_{k=1}^{2} p_k \log_2 p_k = -\left(\frac{8}{17}\log_2\frac{8}{17} + \frac{9}{17}\log_2\frac{9}{17}\right) = 0.998$$

属性：色泽

取值：青绿（D^1）、乌黑（D^2）、浅白（D^3）

$$\begin{aligned}\mathrm{Gain}(D, \text{色泽}) &= \mathrm{Ent}(D) - \sum_{v=1}^{3}\frac{|D^v|}{|D|}\mathrm{Ent}(D^v) \\ &= 0.998 - \left(\frac{6}{17}\times 1.000 + \frac{6}{17}\times 0.918 + \frac{5}{17}\times 0.722\right) \\ &= 0.109\ .\end{aligned}$$

$$\mathrm{IV}(\text{色泽}) = 1.580 \ (V = 3)$$

$$\boldsymbol{Gain_ratio(D, \text{色泽})} = \frac{\mathbf{0.109}}{\mathbf{1.580}}$$

决策树

分类

信息增益

信息增益率

基尼指数

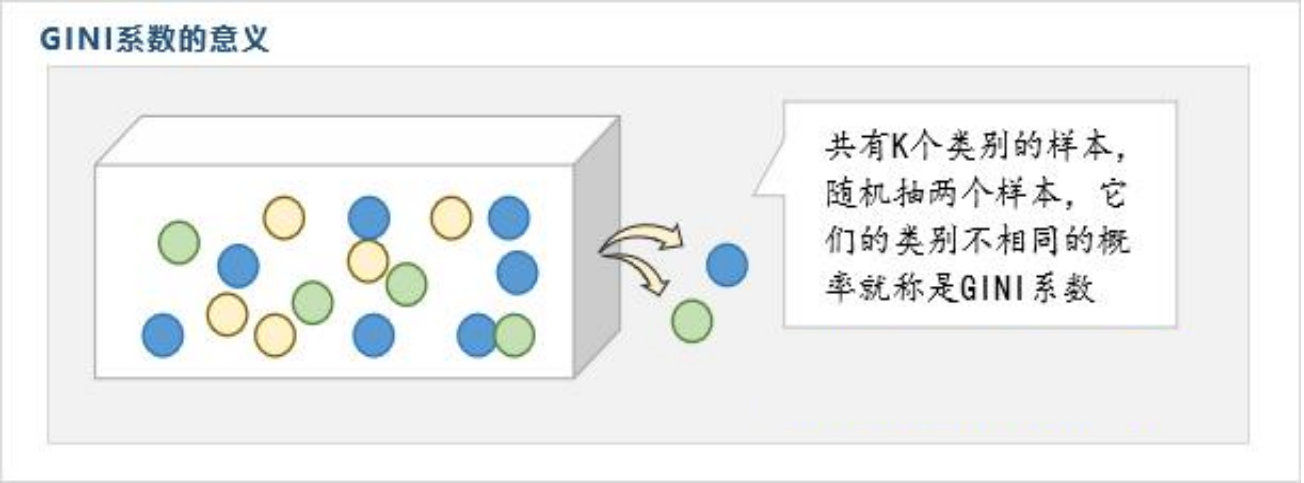
熵

回归

平方误差

衡量指标：基尼指数

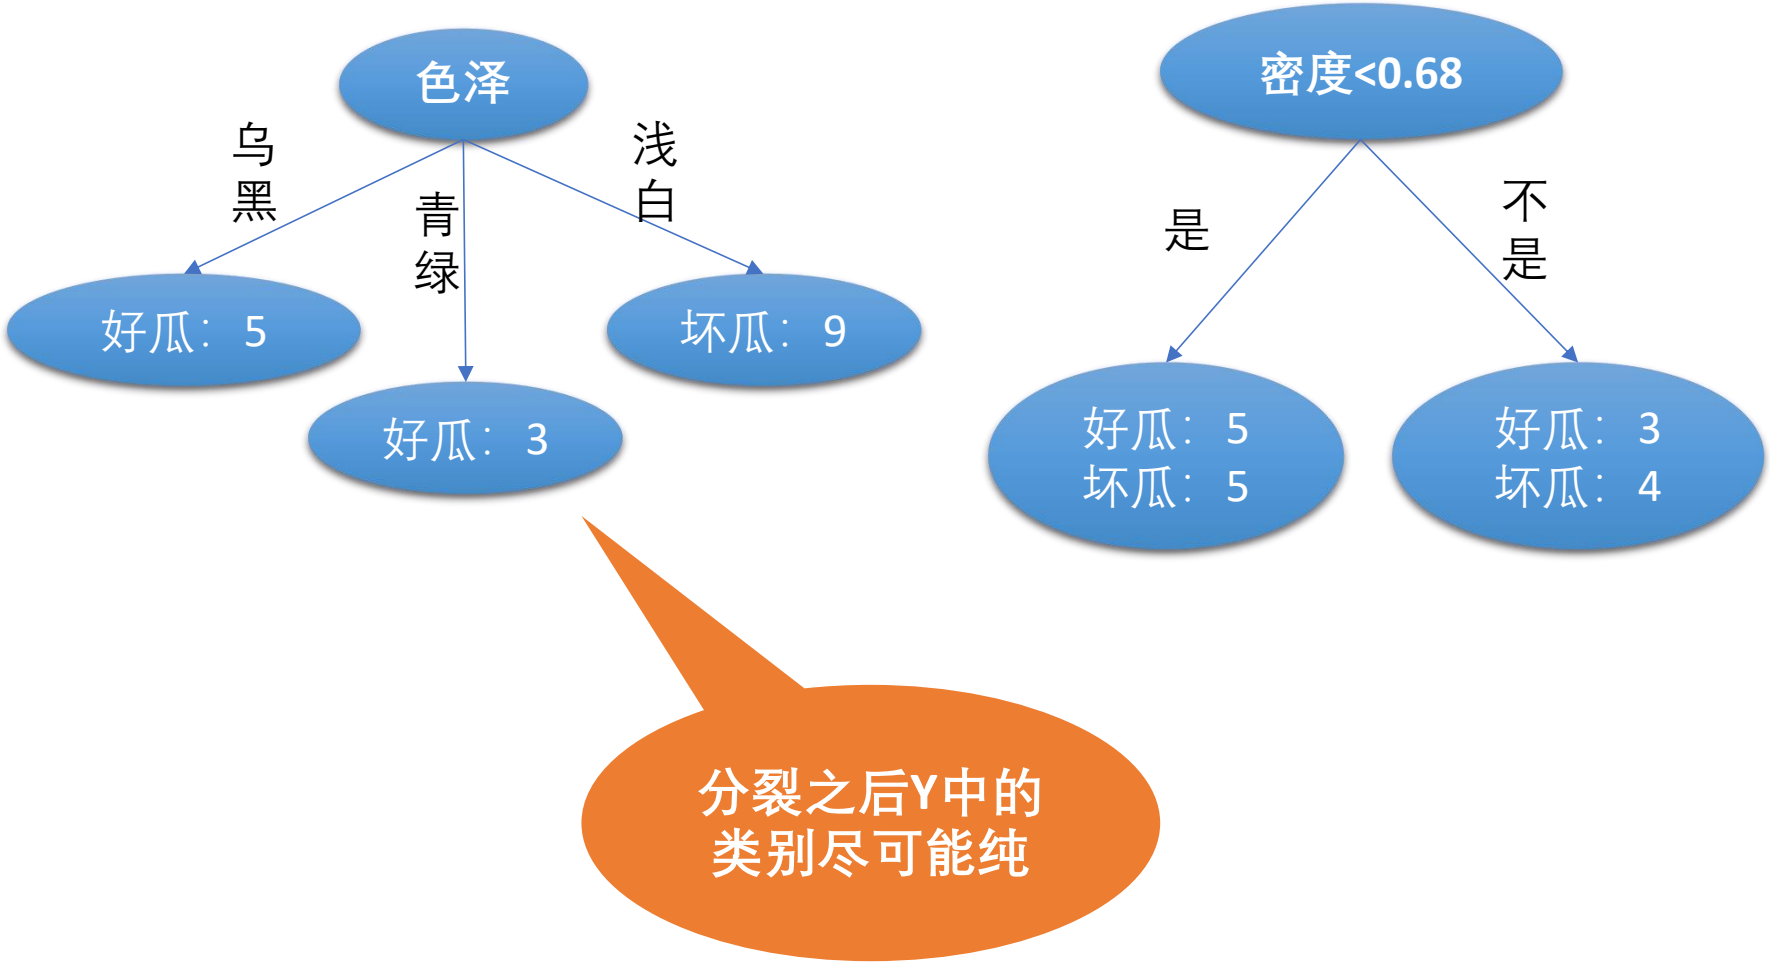
$$G = 1 - \sum_{k=1}^{K} P_k^2$$



$$Gini(D) = 1 - \sum_{k=1}^{K} \left(\frac{|C_k|}{|D|}\right)^2$$

$$Gini_index(D, a) = \sum_{i=1}^{n} \frac{|D(a = a_i)|}{|D|} Gini(D(a = a_i))$$

决策树


色泽
乌黑
青绿
浅白
好瓜：5
好瓜：3
坏瓜：9
密度<0.68
是
不是
好瓜：5
坏瓜：5
好瓜：3
坏瓜：4
分裂之后Y中的
类别尽可能纯

1. 开始：将所有训练数据作为根节点数据
2. 特征选择：根据最小基尼指数选择一个特征进行分裂
3. 分裂节点：
    1. 根据选定特征，将当前节点数据分裂成若干子集，每个子集对应该特征的一个值
    2. 创建与这些子集相对应的节点，并将其作为当前节点的子节点
4. 递归分裂：对每个子节点，递归地重复步骤2和3，直到满足某停止条件
5. 完成：若所有节点满足停止条件，算法结束

分类

衡量指标：信息增益

$$Gain(D,a) = Ent(D) - Ent(D|a)$$

衡量指标：信息增益率

$$Gain_ratio(D,a) = \frac{Gain(D,a)}{IV(a)}$$

$$IV(a) = -\sum_{i=1}^{n} \frac{|D(a=a_i)|}{|D|} \log \frac{|D(a=a_i)|}{|D|}$$

衡量指标：基尼指数

$$Gini(D) = 1 - \sum_{k=1}^{K} \left(\frac{|C_k|}{|D|}\right)^2$$

$$Gini_index(D,a) = \sum_{i=1}^{n} \frac{|D(a=a_i)|}{|D|} Gini(D(a=a_i))$$

决策树

分类

信息增益

信息增益率

基尼指数

熵

回归

平方误差

决策树

回归问题

分类特征

连续特征

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460
2	乌黑	蜷缩	沉闷	清		硬滑	0.774	0.376
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215
6	青绿	稍蜷	浊响	清晰	稍凹	软粘		0.237
7	乌黑	稍蜷	浊		稍凹	软		0.149
8	乌黑	稍蜷	浊响		稍凹	硬滑	0.437	0.211
9	乌黑	稍蜷	沉闷	稍	稍凹	硬滑	0.666	0.091
10	青绿	硬挺	清脆		平坦	软粘	0.243	0.267
11	浅白	硬挺				硬滑	0.245	0.057
12	浅白	蜷缩					0.343	0.099
13	青绿	稍蜷					0.639	0.161
14	浅白	稍蜷				滑	0.657	0.198
15	乌黑	稍蜷	浊响			软粘	0.360	0.370
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103

色泽

分裂之后Y的平方误差最小

甜度	0.05	0.15	0.25	0.35	0.45
好吃程度	5.5	7.6	9.5	9.7	8.2

Case 1 以甜度 $s = 0.1$ 进行划分

R_1 类是：

甜度	0.05
好吃程度	5.5

R_2 类是：

甜度	0.05	0.15	0.25	0.35	0.45
好吃程度	5.5	7.6	9.5	9.7	8.2

可以得出：R_1 类因为只有一个值，因此平均值 $\hat{c}_1$ 是它本身为 5.5。R_2 类的平均值就是：

$$\hat{c}_2 = \frac{7.6 + 9.5 + 9.7 + 8.2}{4} = 8.75$$

接着代入平方误差公式中：

$$\begin{aligned} &= \sum_{x_i \in R_1(j,s)} (y_i - c_1)^2 + \sum_{x_i \in R_2(j,s)} (y_i - c_2)^2 \\ &= 0 + (7.6 - 8.75)^2 + (9.5 - 8.75)^2 + (9.7 - 8.75)^2 + (8.2 - 8.75)^2 \\ &= 3.09 \end{aligned}$$

决策树

分类

信息增益

信息增益率

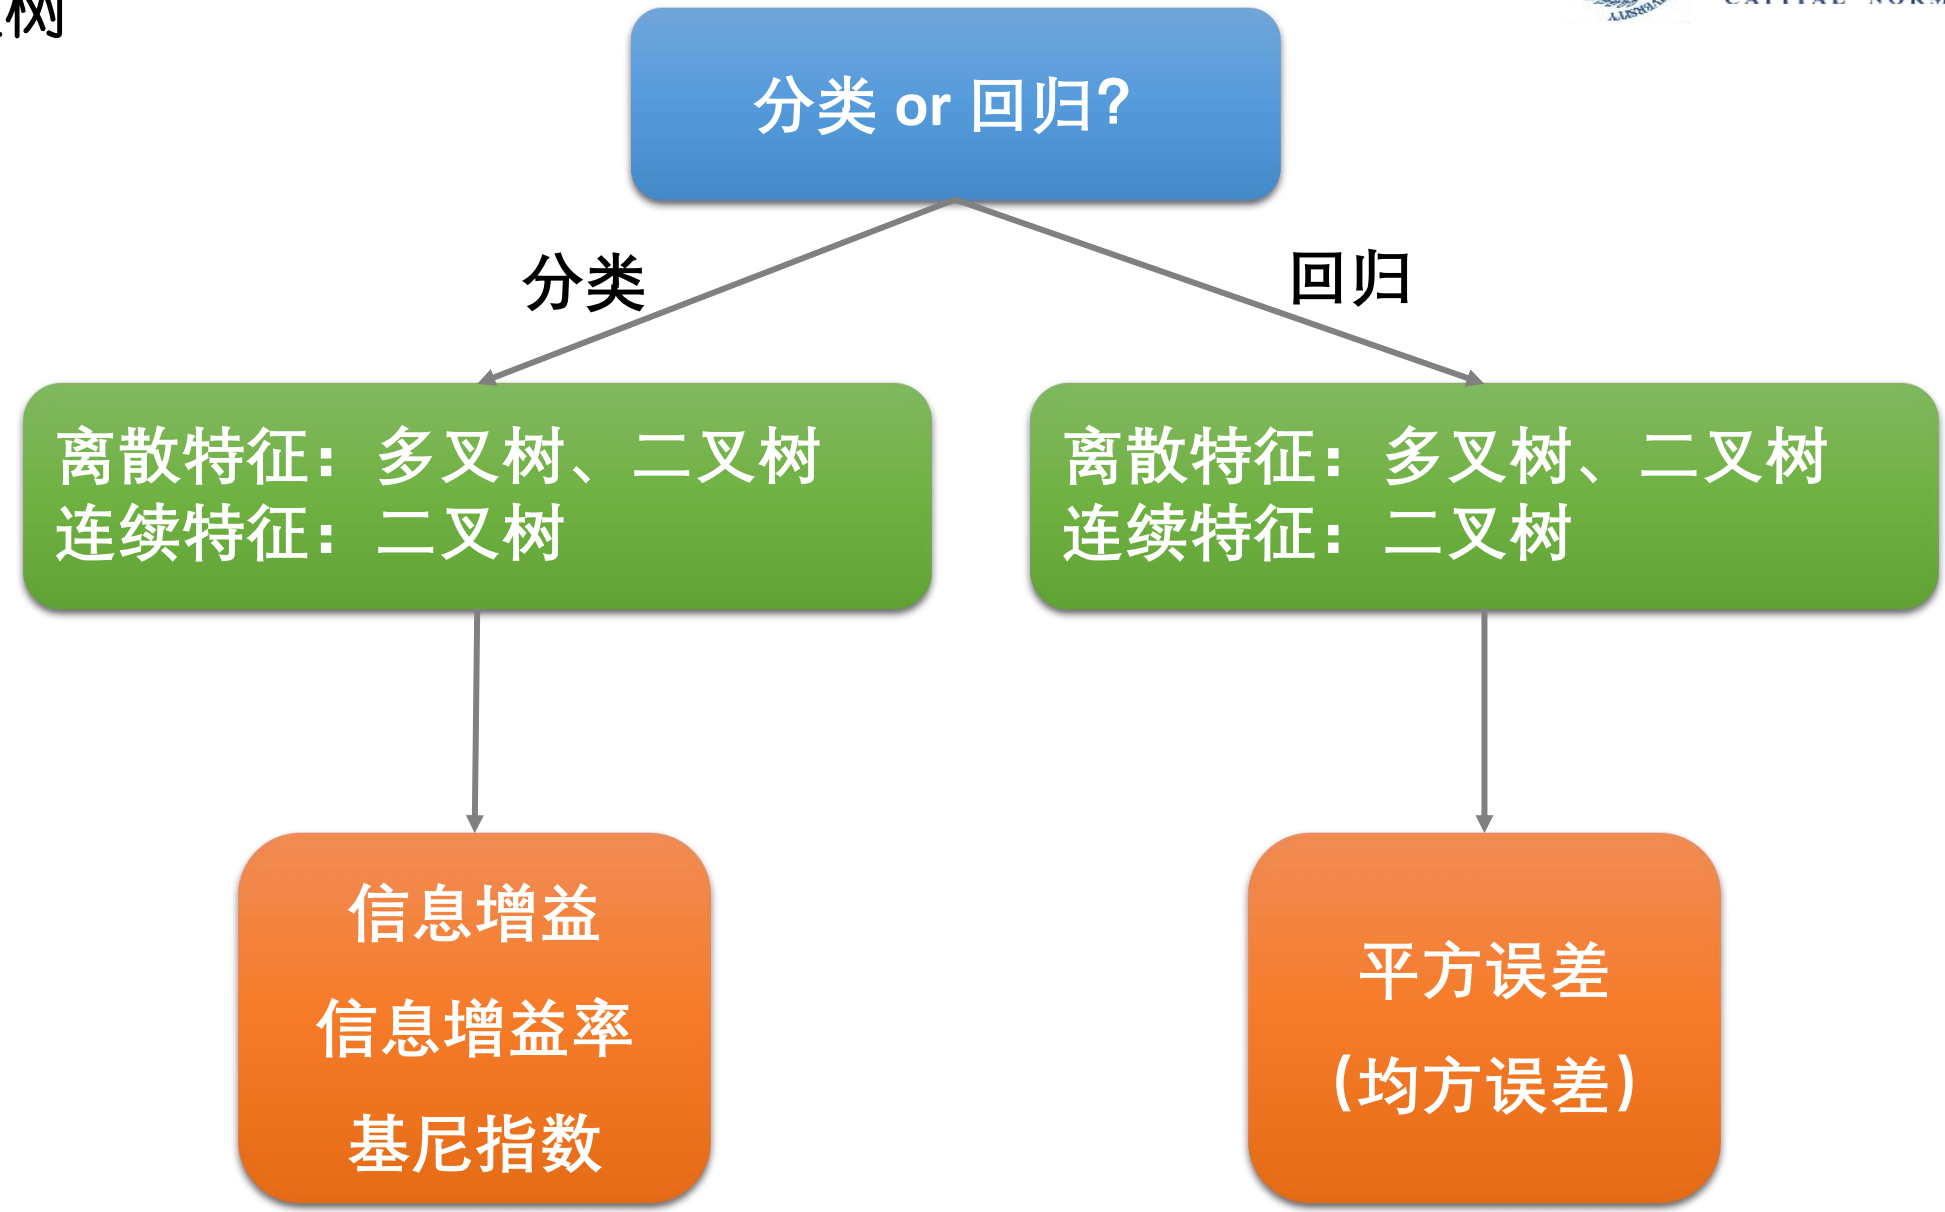
基尼指数

熵

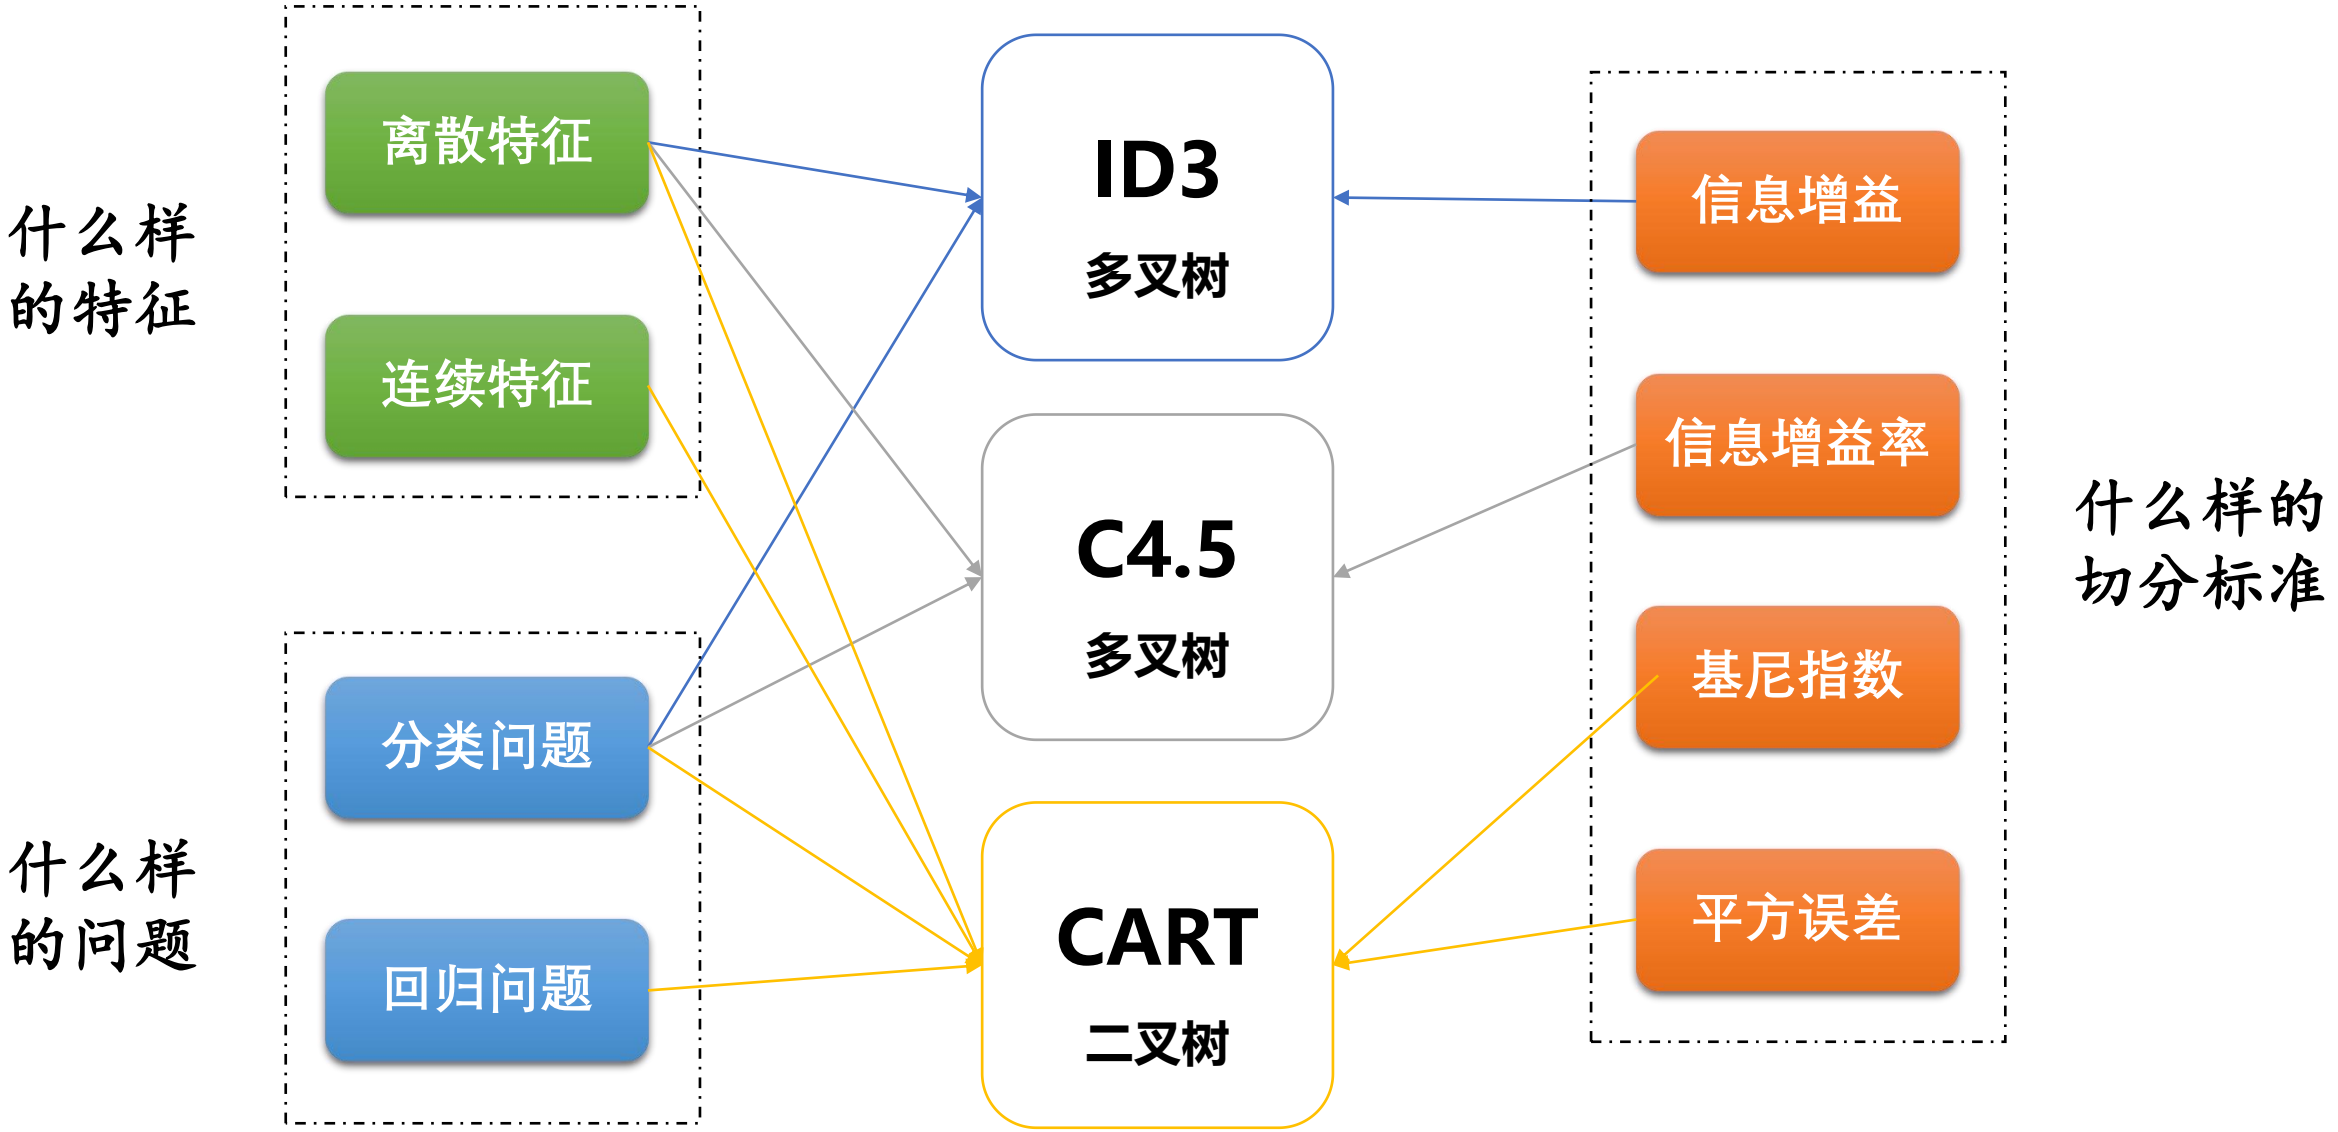
回归

平方误差

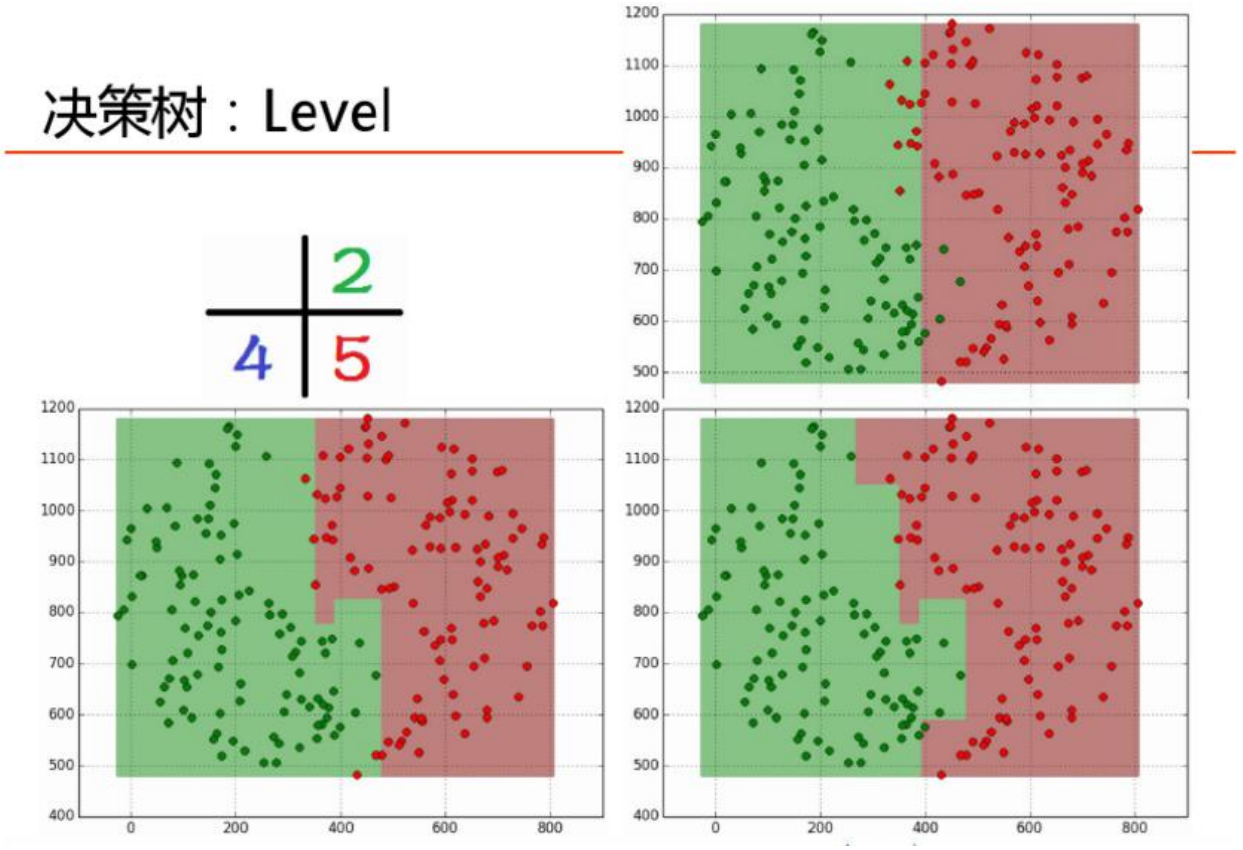
决策树

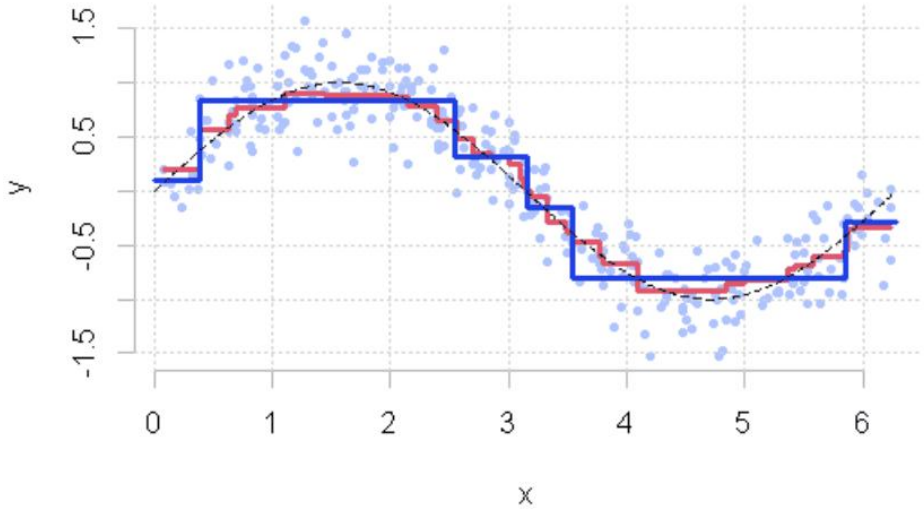

分类 or 回归?
分类
回归
离散特征：多叉树、二叉树
连续特征：二叉树
离散特征：多叉树、二叉树
连续特征：二叉树
信息增益
信息增益率
基尼指数
平方误差
（均方误差）

决策树


什么样的特征
离散特征
连续特征
什么样的问题
分类问题
回归问题
ID3
多叉树
C4.5
多叉树
CART
二叉树
什么样的切分标准
信息增益
信息增益率
基尼指数
平方误差

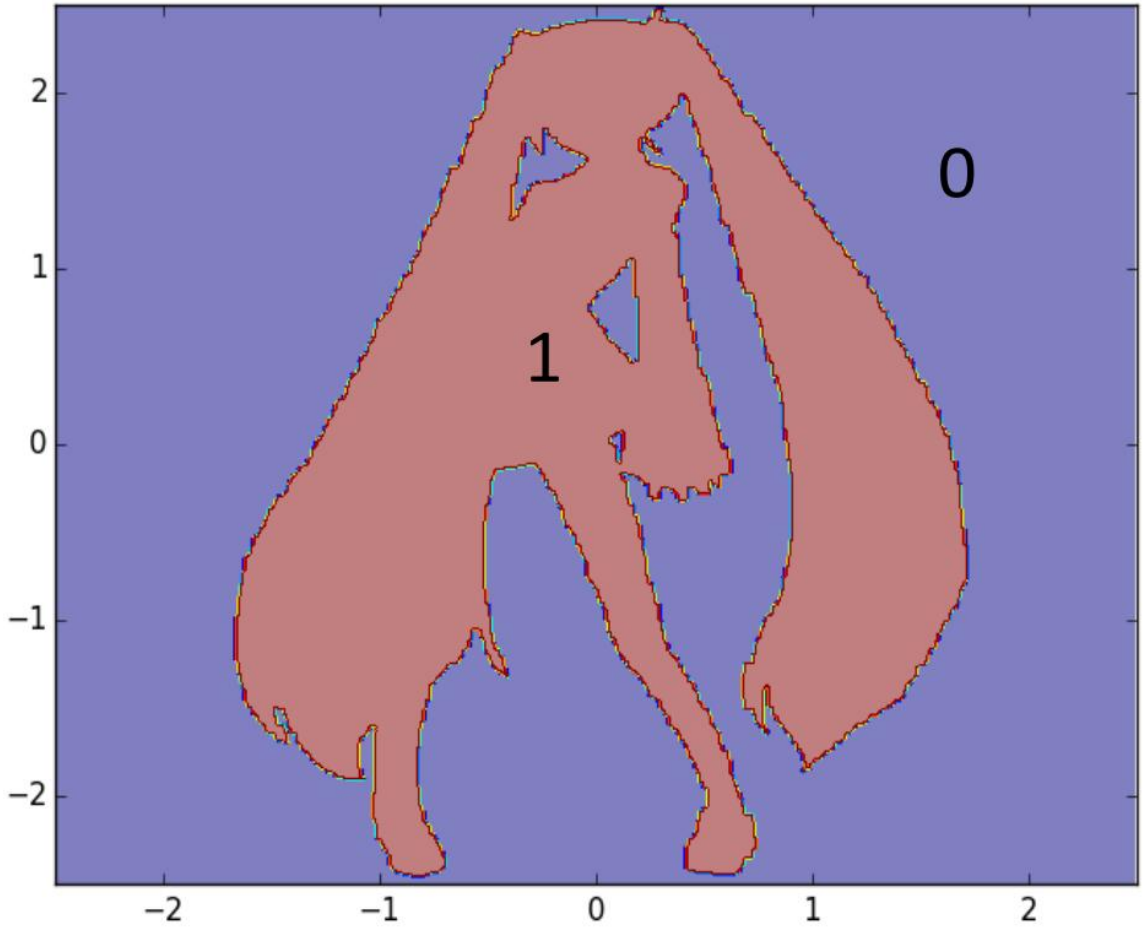
决策树的几何意义：对特征空间进行切割



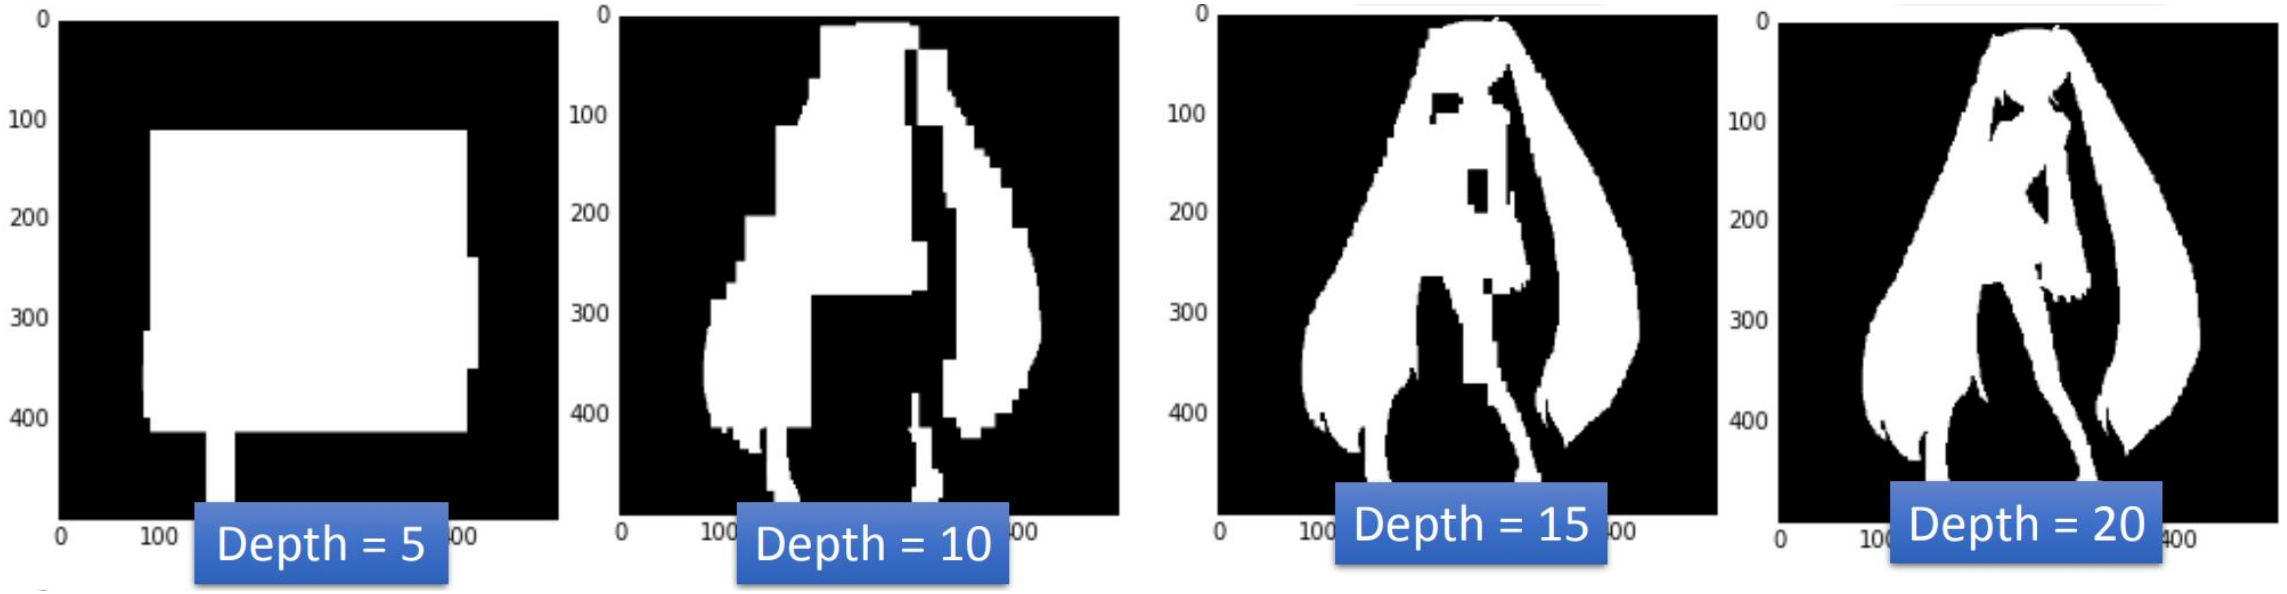


决策树



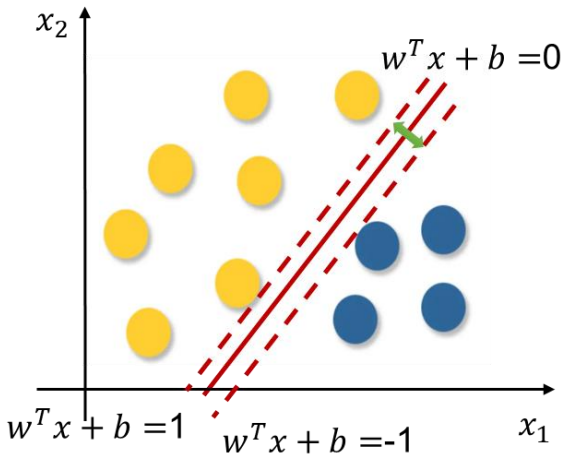


决策树

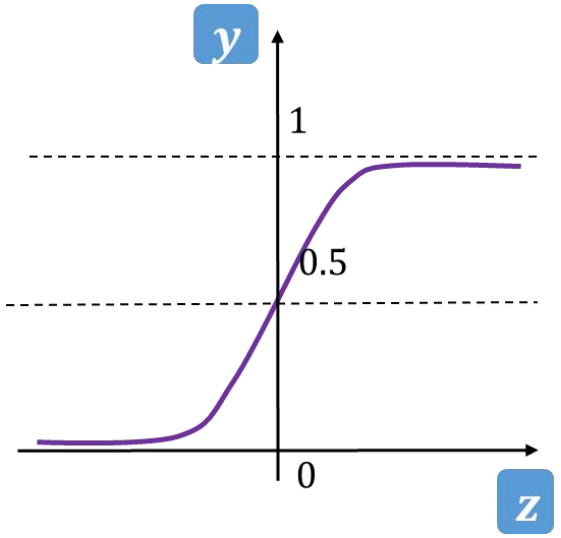

0
100
200
300
400
0
100
Depth = 5
0
100
200
300
400
0
100
Depth = 10
0
100
200
300
400
0
100
Depth = 15
0
100
200
300
400
0
100
Depth = 20

决策树

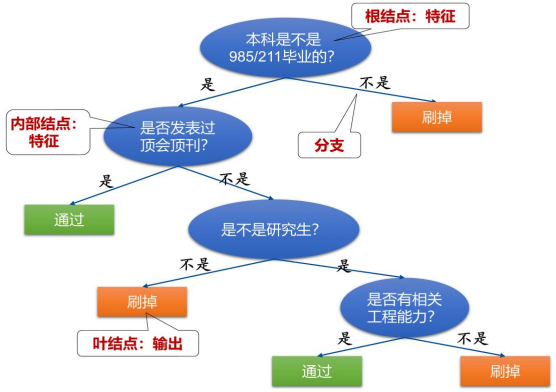
SVM



LR



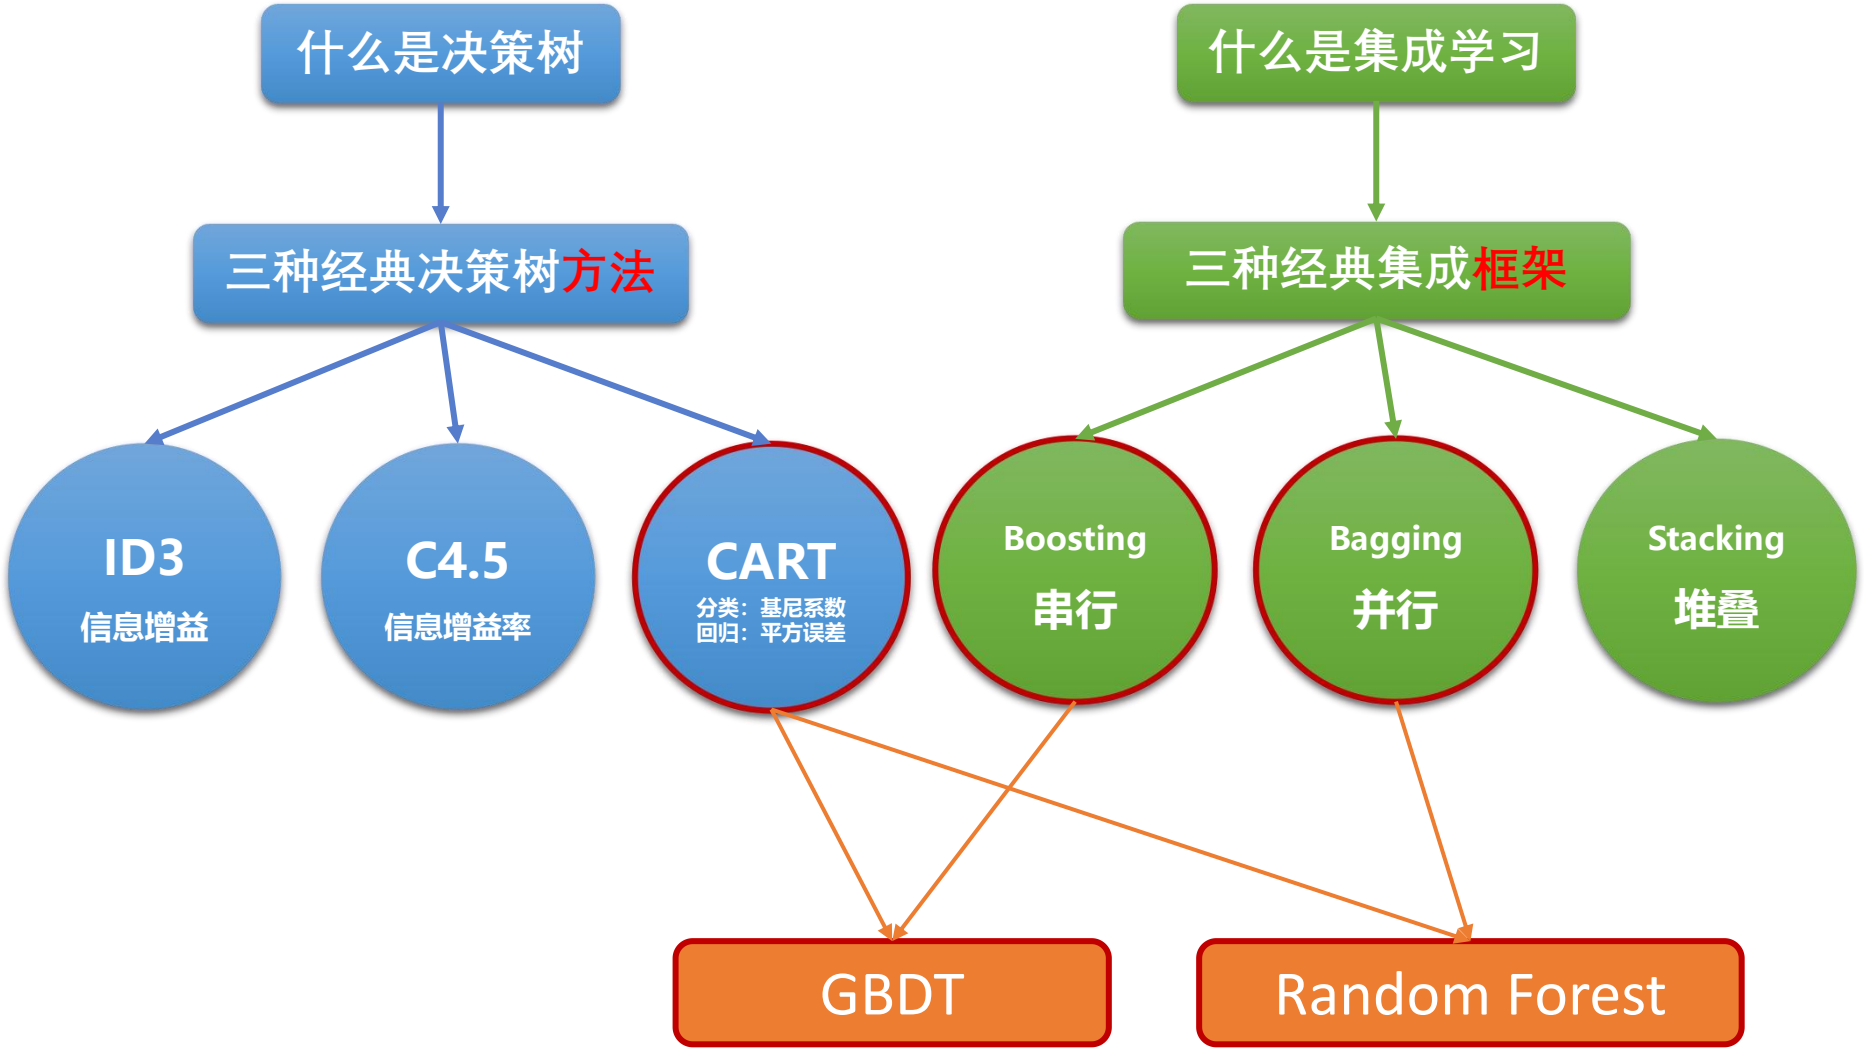
DT





它们各自有什么特点？
它们的输出是什么？
数据需要预先标准化吗？
它们怎么处理多分类问题？
它们可以处理非线性分类吗？
模型的可解释性怎么样？如何体现的？

大纲


什么是决策树
三种经典决策树方法
ID3
信息增益
C4.5
信息增益率
CART
分类：基尼系数
回归：平方误差
什么是集成学习
三种经典集成框架
Boosting
串行
Bagging
并行
Stacking
堆叠
GBDT
Random Forest

什么是集成学习?

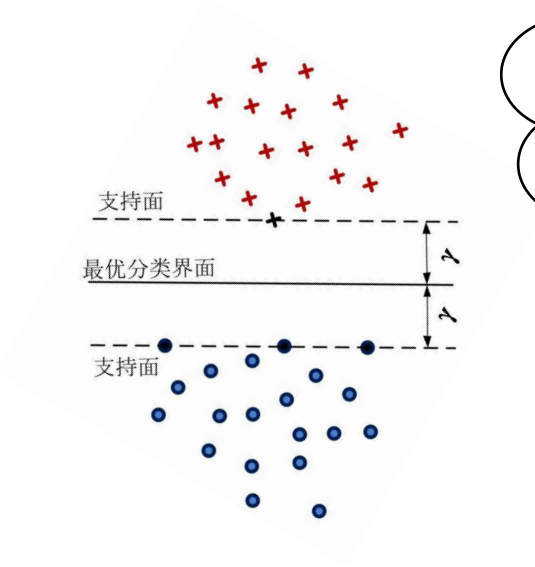


集成学习

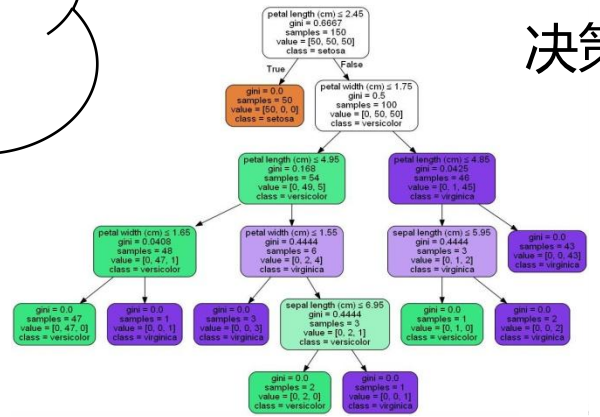
能不能基于此构建一类更强大的模型？



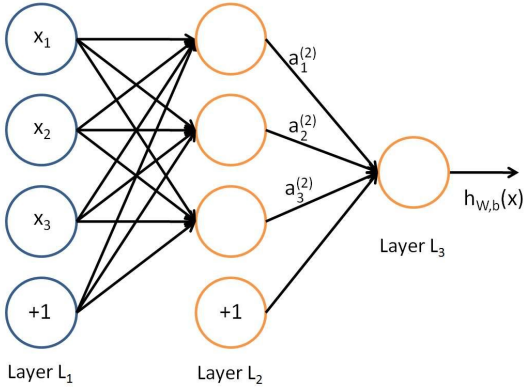
SVM



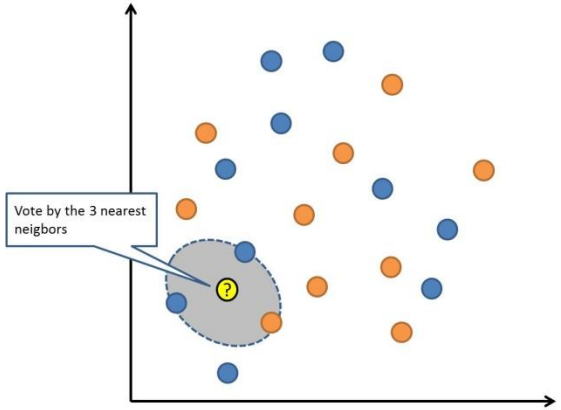
决策树（CART）



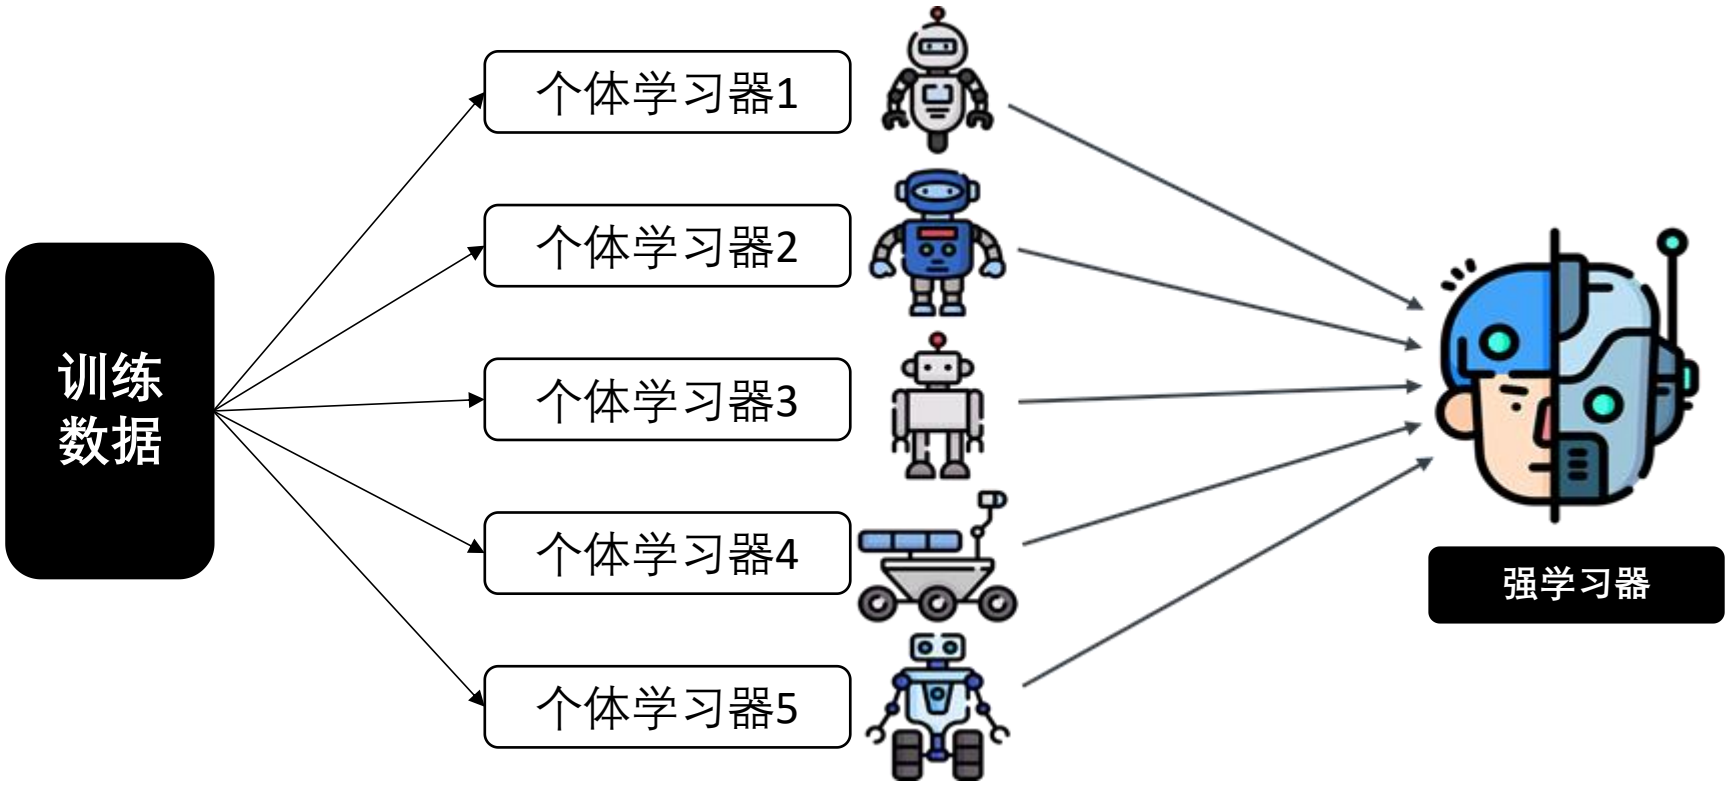
神经网络



KNN



集成学习是一个**学习框架**：“三个臭皮匠，顶个诸葛亮”



数据怎么用？

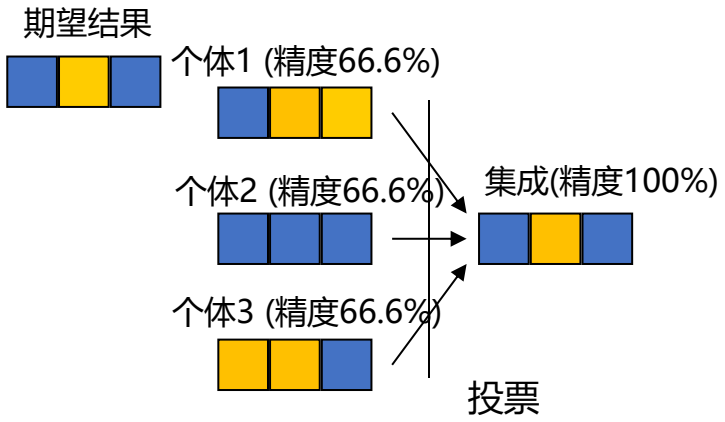
个体学习器怎么选？

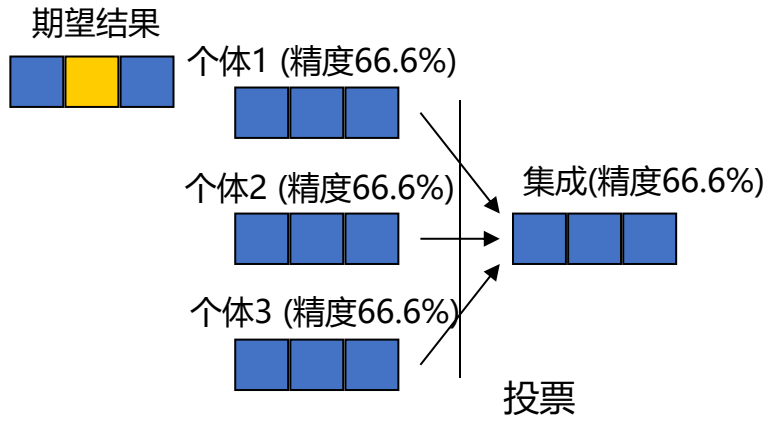
最后怎么组合？

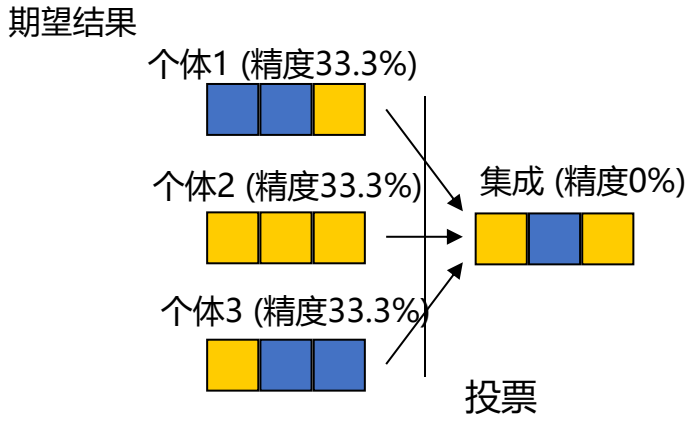
模型集成是不是一定
会有更好的表现?



集成学习







并不是任意集成都能得到好的结果

“好而不同”

误差-分歧分解

对于回归问题: 个体学习器： $h_1, h_2, \ldots, h_T$;集成后的学习器： $H = \sum_{i=1}^{T} w_i h_i$

给定x:

个体分歧： $A(h_i|x) = (h_i(x) - H(x))^2$

集成分歧： $\overline{A}(H|x) = \sum_{i=1}^{T} w_i A(h_i|x)$

个体误差： $E(h_i|x) = (f(x) - h_i(x))^2$

集成误差： $E(H|x) = (f(x) - H(x))^2$

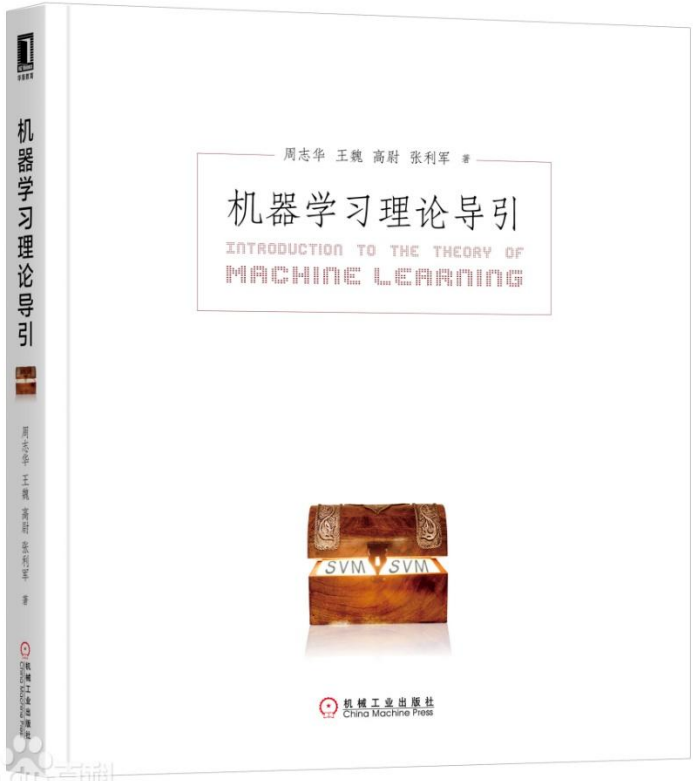
个体误差的加权平均： $\overline{E}(H|x) = \sum_{i=1}^{T} w_i E(h_i|x)$

$$E(H|x) = \overline{E}(H|x) - \overline{A}(H|x)$$

“好而不同”

PAC学习理论(1984，Leslie Valiant，2010年图灵奖)

Probably Approximate Correct，概率近似正确



- 什么样的问题天生无法有效地被学习？
- 什么样的问题能够被有效率的学习？
- 成功的学习需要多少样本？
- 学习有没有一个综合性的模型指导框架？

1990年，Schapire证明了一个关键定理（PAC弱可学习定理），奠定了集成学习的理论基础

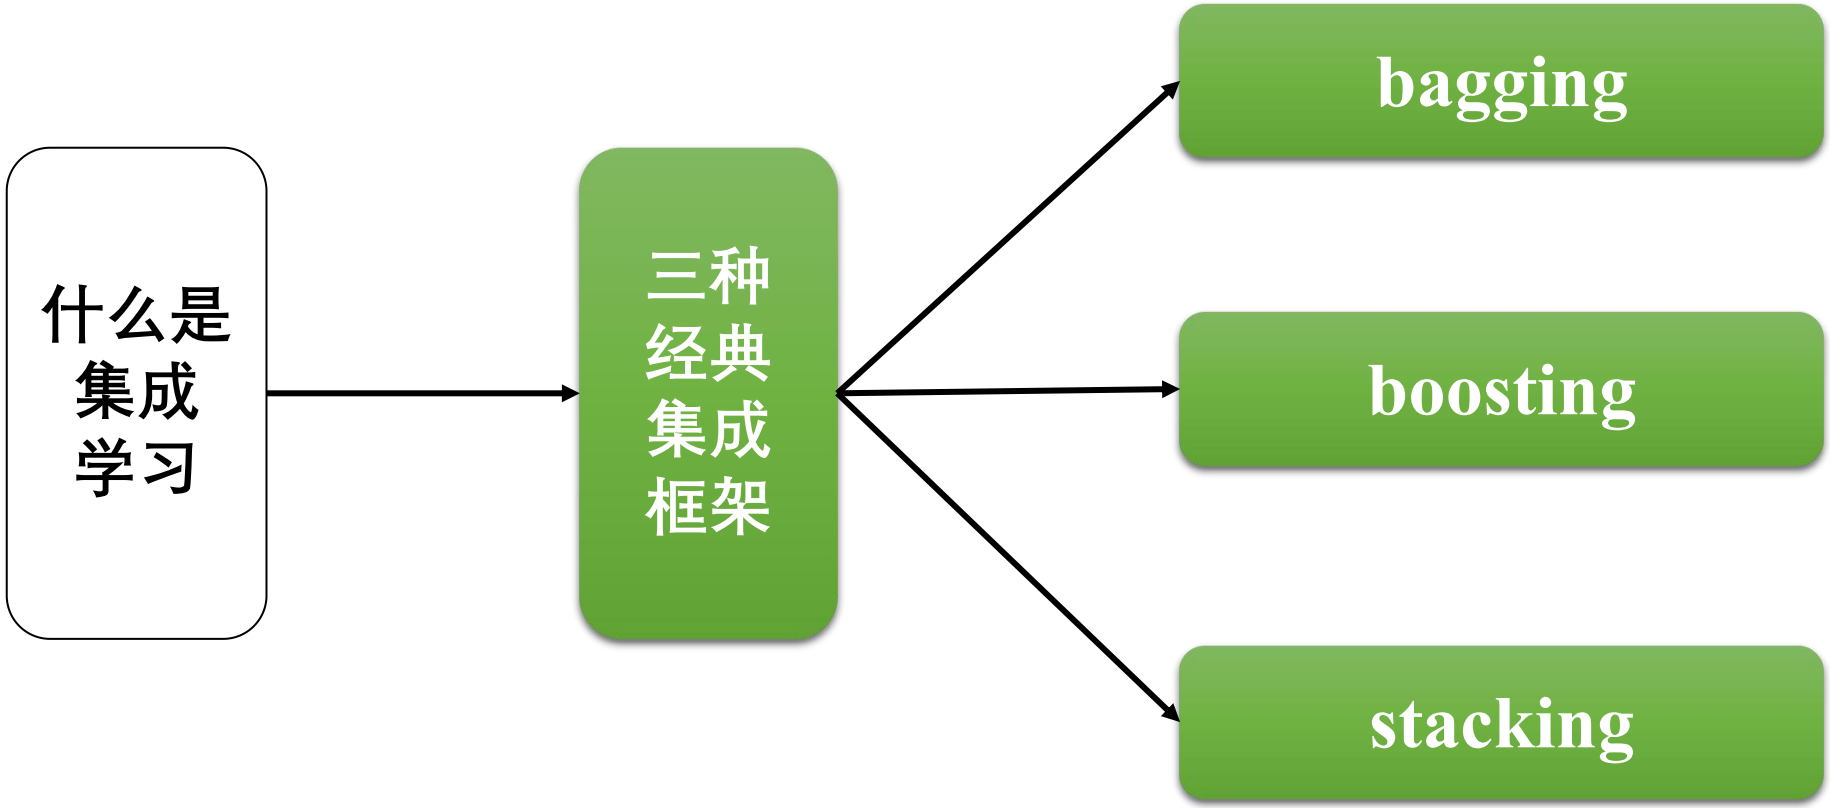
■ 一个问题是**弱**可学习的： $\forall 0 < \delta < 0.5, \boldsymbol{\varepsilon = 0.5 - \frac{1}{t}}$

$$P(E_{x\sim D}[\mathbb{I}(f(x) \neq y)] < \varepsilon) \geq 1 - \delta$$

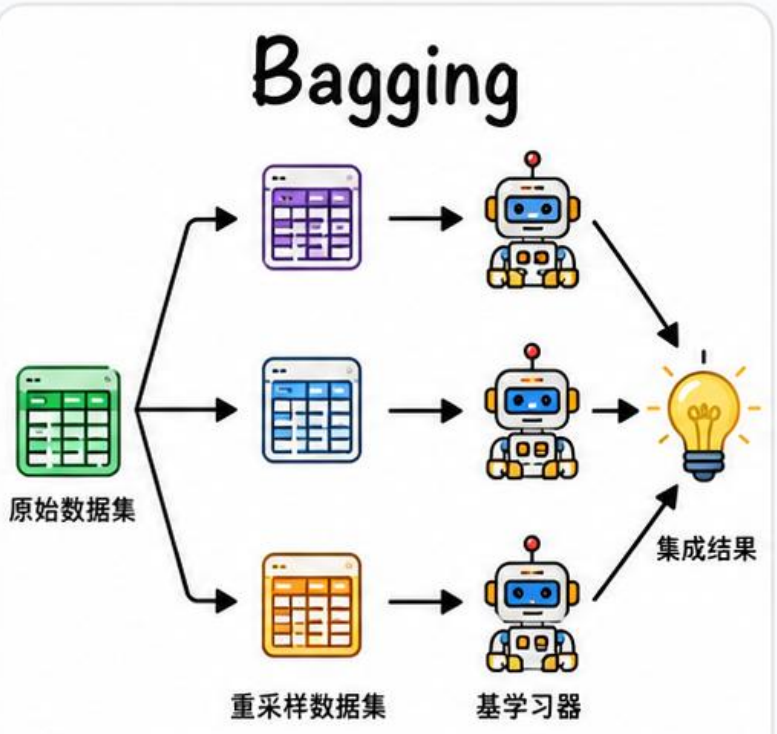
■ 一个问题是**强**可学习的： $\forall 0 < \varepsilon, \delta < 0.5$

$$P(E_{x\sim D}[\mathbb{I}(f(x) \neq y)] < \varepsilon) \geq 1 - \delta$$

定理：如果一个概念是弱可学习的，充要条件是它是强可学习的

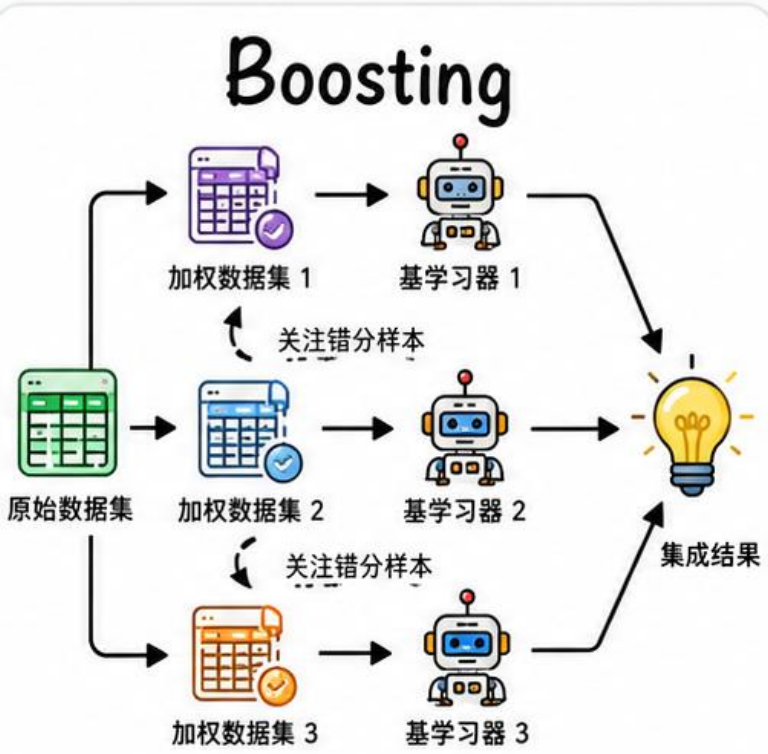

什么是集成学习
三种经典集成框架
bagging
boosting
stacking

集成学习



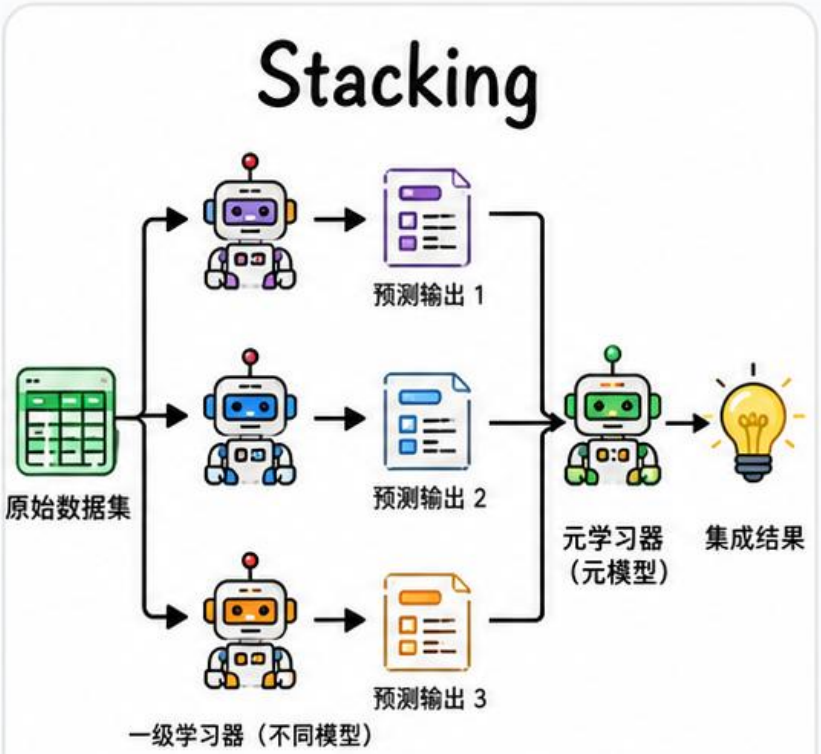
并联

Bootstrap 重采样 · 独立训练 · 投票/平均



串联

逐轮纠错 · 关注错分样本 · 加权组合

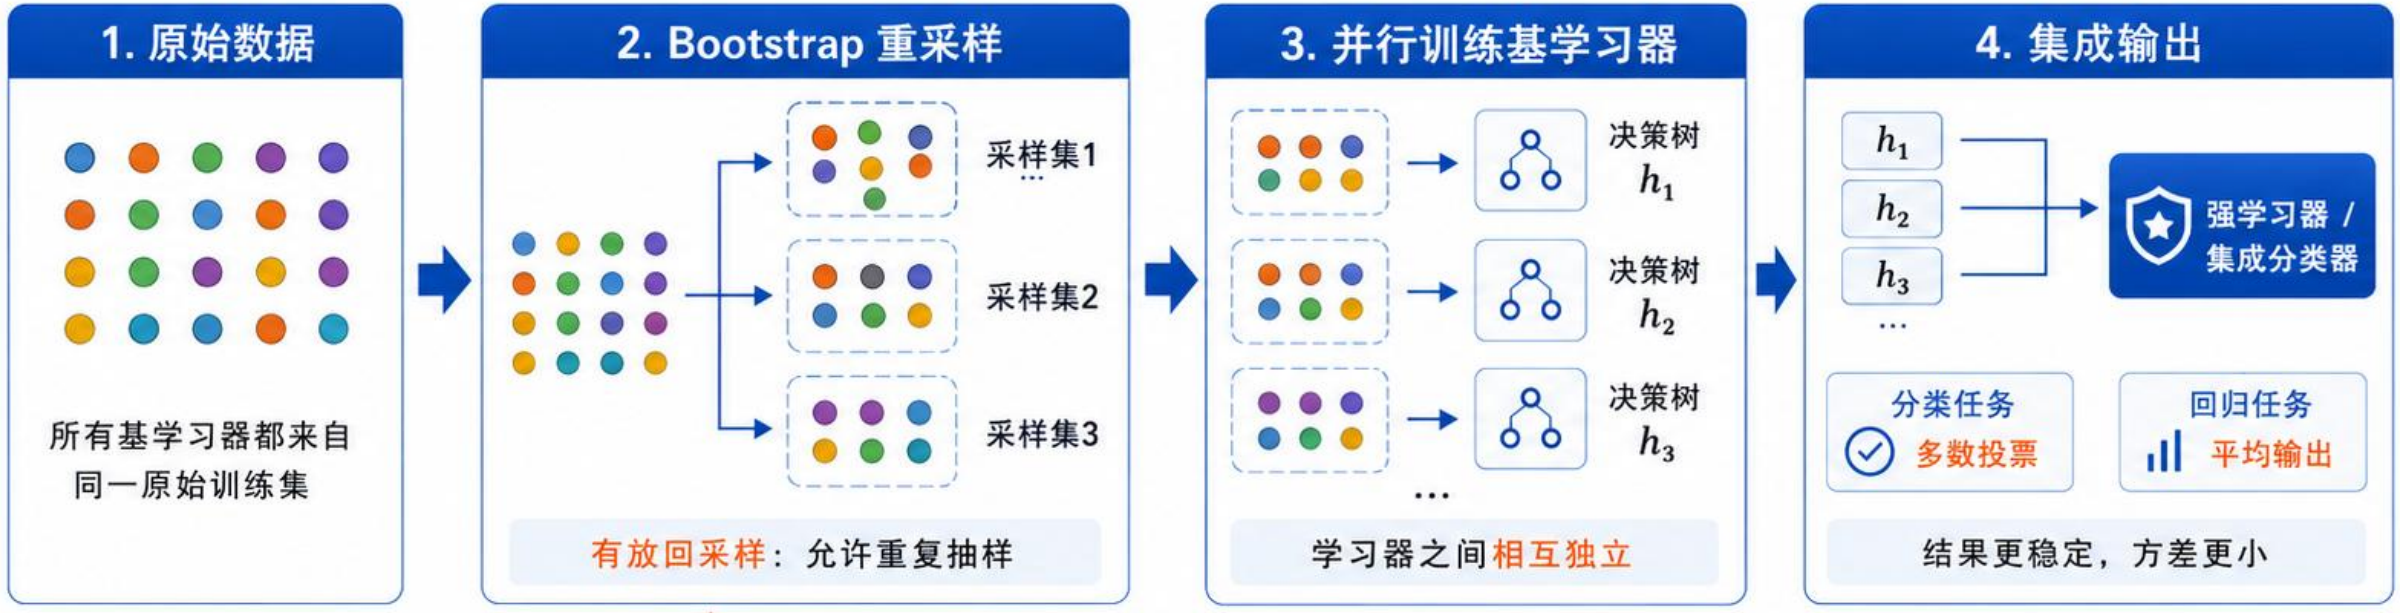


分层

一级学习器输出 → 元学习器融合

Bagging（Bootstrap Aggregating）

“好而不同”



每个学习器看到的是原始数据的不同重采样版本

Bagging 通过“并行 + 多样性”提升稳定性

1 顺序关系：并行训练

所有基学习器同时训练，互不依赖。

2 数据处理：Bootstrap 采样

对原始数据有放回采样，得到多个训练集。

3 集成方式：投票 / 平均

分类用多数投票，回归用平均输出。

Bootstrap抽样

假设有n个训练样本，对任一样本而言，在每次bootstrap抽样中，它没有被抽到的概率为

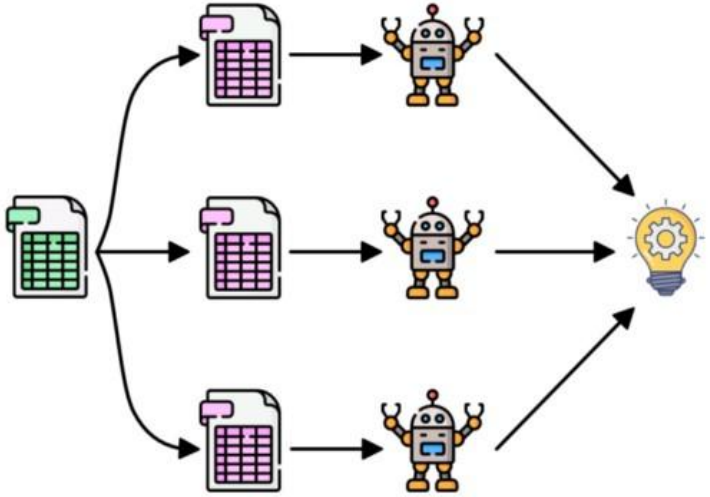
$$1-\frac{1}{n}$$

抽取n次后，该样本一次都没被抽中的概率为

$$\left(1-\frac{1}{n}\right)^{n} \approx e^{-1} = 0.368$$

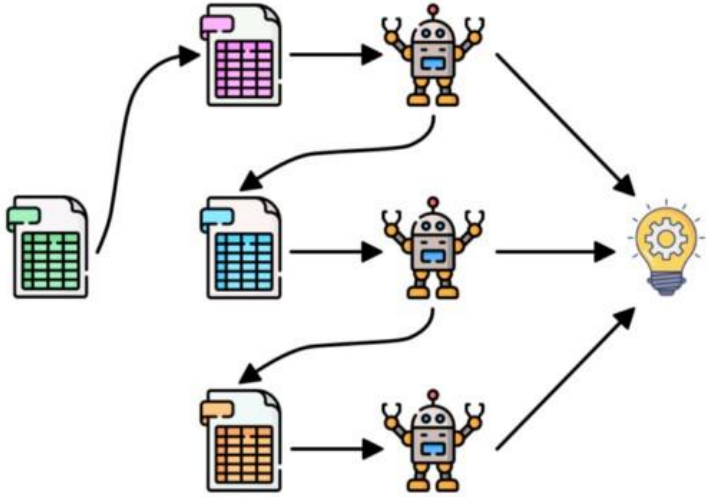
这表明，每次bootstrap抽样抽取了近**63.2%**的样本。

Bagging



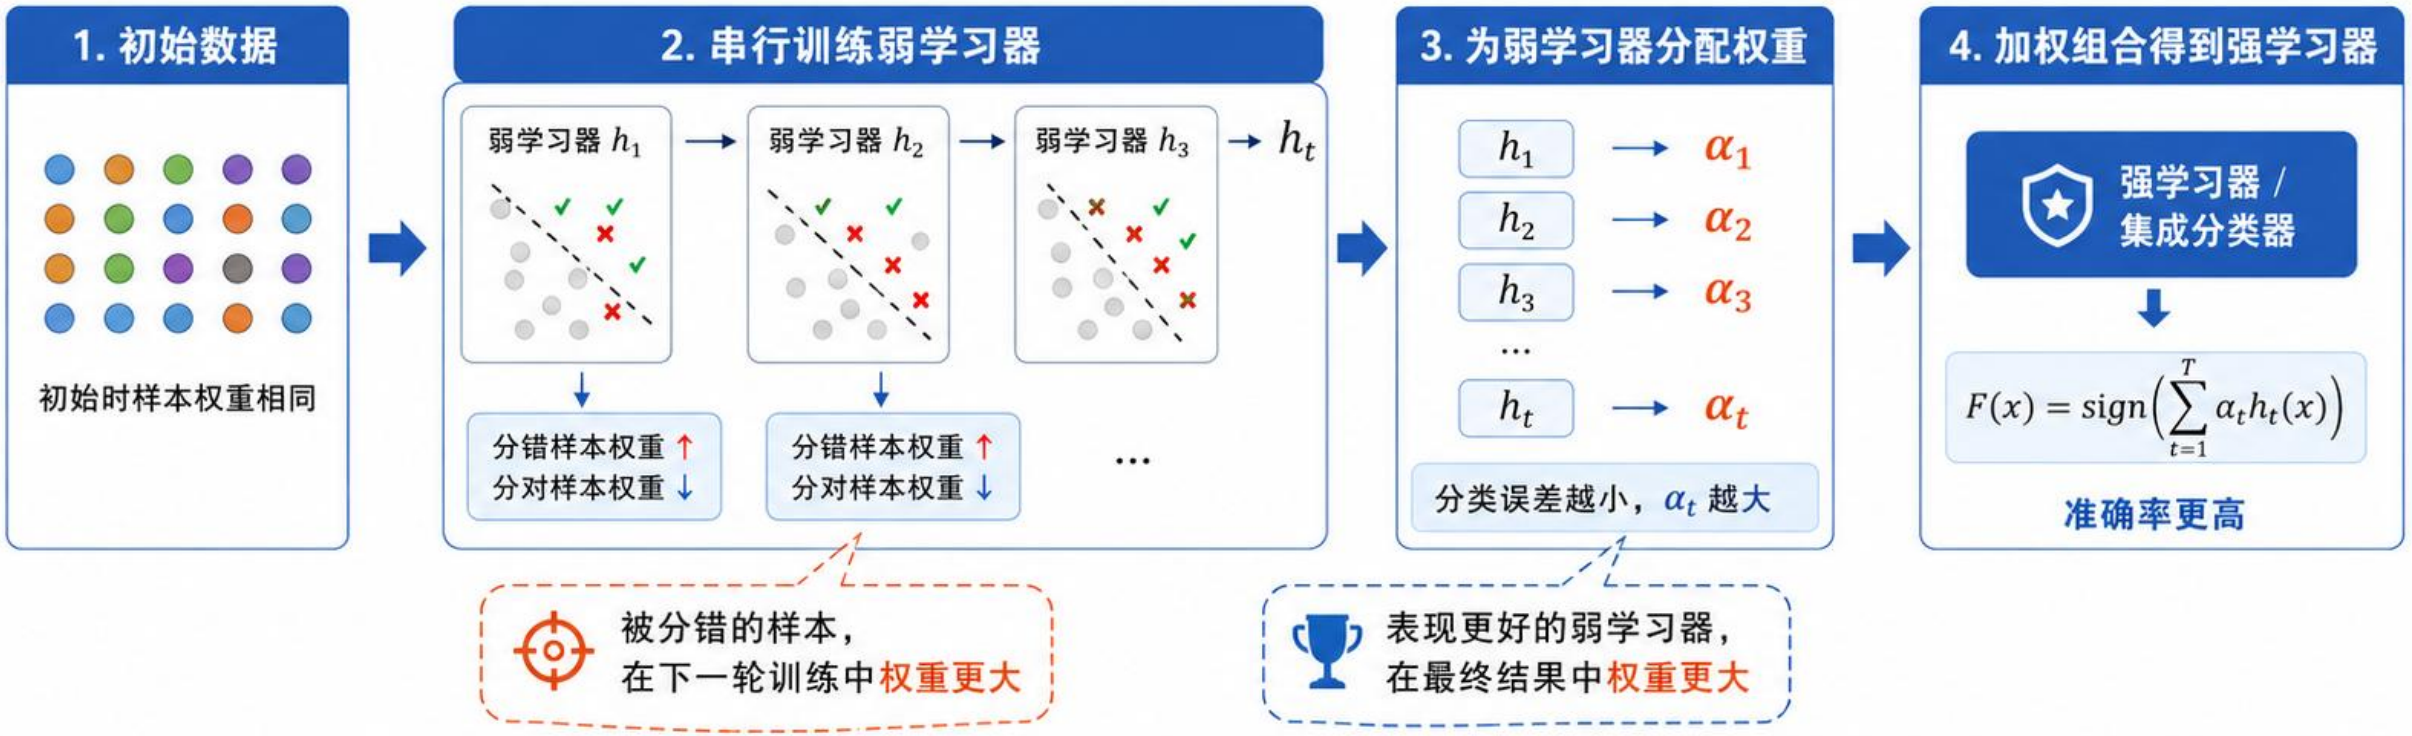
并联

Boosting



串联

Boosting



1 顺序训练

弱学习器按顺序训练，
每一轮都基于上一轮的结果。

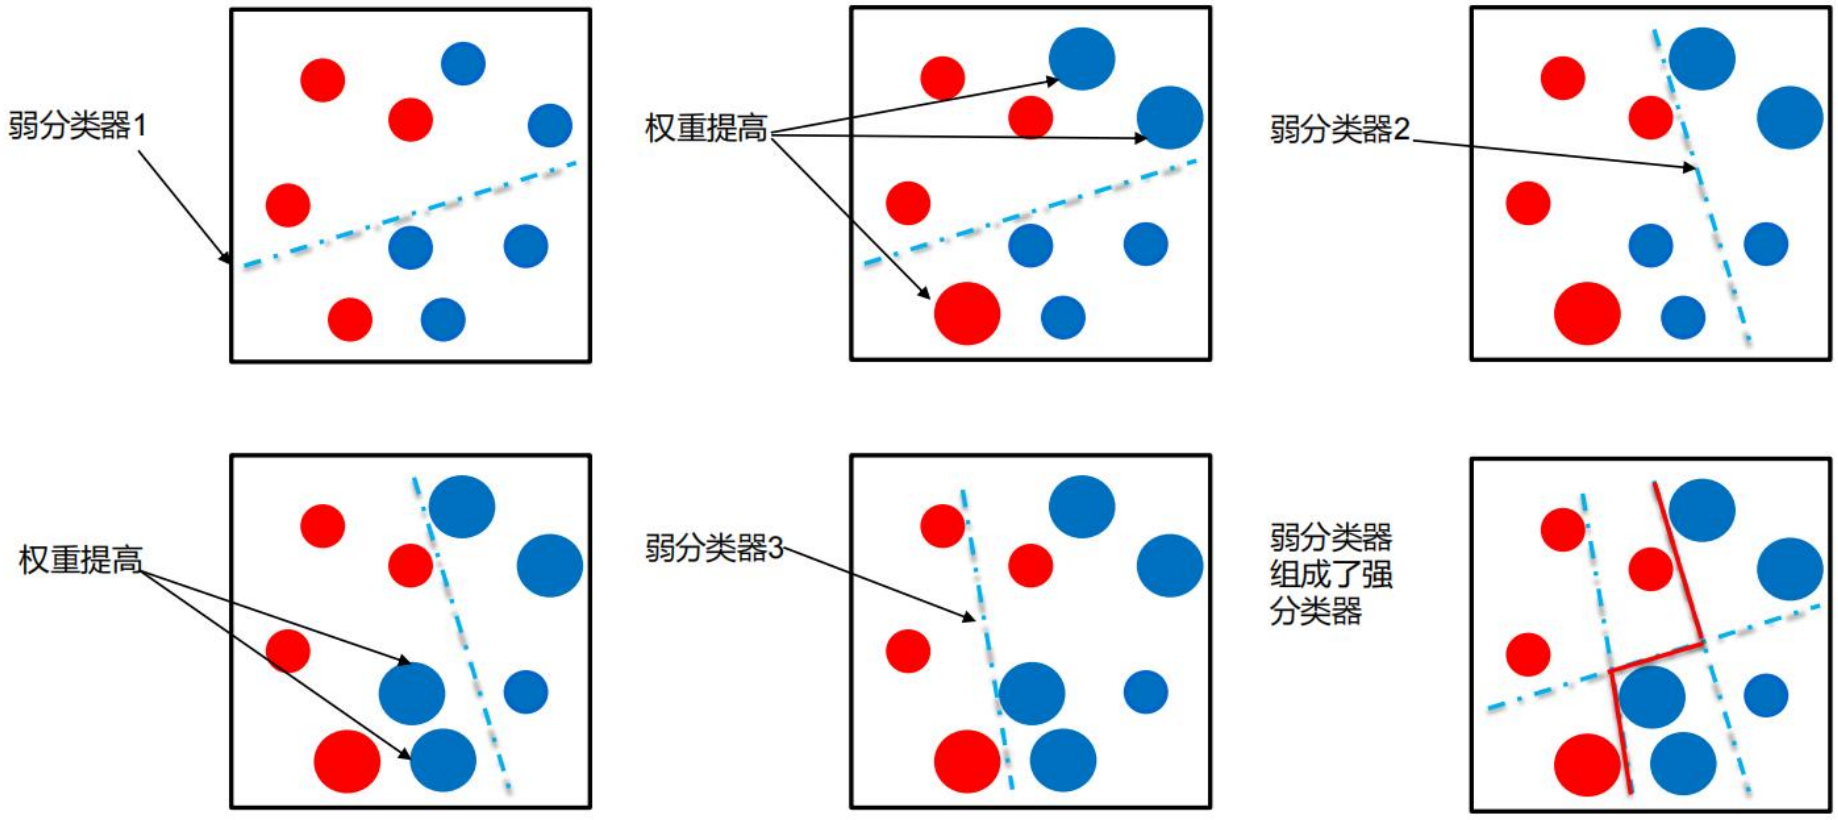
2 关注难分样本

被分错的样本权重增大，
下一轮更受关注。

3 加权集成

表现更好的弱学习器权重更大，
最终得到更强的分类器。

集成学习



AdaBoost

① PageRank
② Apriori
③ C4.5
④ 朴素贝叶斯
⑤ SVM
⑥ KNN
⑦ Adaboost
⑧ CART
⑨ K-Means
⑩ EM

AdaBoost是boosting框架下最成功的代表，被评为**数据挖掘十大算法之一**



AdaBoost

中心思想：决策函数是一个**加法模型**，可写为：

$$H(x) = \sum_{t=1}^{T} \alpha_t h_t(x)$$

（假设有T个基分类器，每个基分类器带有权重α_t）

方法：最小化**指数损失**：$Loss(x_i) = e^{-y_i H(x_i)}$，则有

$$\min_{(\alpha_t, h_t)_{t=1}^{T}} \sum_{i=1}^{m} L(x_i) = \sum_{i=1}^{m} e^{-y_i H(x_i)} \text{(m个样本)}$$

求解：直接求解太困难，通常采用**前向分布算法**

加法模型

+

指数损失

+

前向分布算法

AdaBoost

假设到第t次循环，已知$H_{t-1}(x)$，令

$$H_t(x) = H_{t-1}(x) + \alpha_t h_t(x)$$

最小化指数损失，求解α_t, h_t:

$$\min_{\alpha_t, h_t} \sum_{i=1}^{m} e^{-y_i H(x_i)} \quad \Longleftrightarrow \quad \min_{\alpha_t, h_t} \sum_{i=1}^{m} w_{ti}\, e^{-y_i \alpha_t h_t(x_i)}$$

$$\left(w_{ti} = e^{-y_i H_{t-1}(x_i)} \right)$$

- **求解$h_t(x)$【弱分类器】：**

  假设α_t已知，有：$h_t(x) = \underset{h_t(x)}{arg\,min} \sum_{i=1}^{m} w_{ti} I(y_i \neq h_t(x_i))$

AdaBoost

假设到第t次循环，已知$H_{t-1}(x)$，令

$$H_t(x) = H_{t-1}(x) + \alpha_t h_t(x)$$

最小化指数损失，求解α_t, h_t:

$$\min_{\alpha_t, h_t} \sum_{i=1}^{m} e^{-y_i H(x_i)} \quad \Longleftrightarrow \quad \min_{\alpha_t, h_t} \sum_{i=1}^{m} w_{ti}\, e^{-y_i \alpha_t h_t(x_i)}$$

$$\left(w_{ti} = e^{-y_i H_{t-1}(x_i)} \right)$$

- **求解α_t【弱分类器的集成权重】：**

  假设$h_t(x)$已知，有：

  $$\alpha_t = \frac{1}{2} ln \frac{1-\varepsilon_t}{\varepsilon_t}$$

  $\varepsilon_t = \sum_{i=1}^{m} w_{ti} I\left(y_i \neq h_t(x_i)\right) / \sum_{i=1}^{m} w_{ti}$，为$h_t(x_i)$的分类错误率

AdaBoost

假设到第t次循环，已知$H_{t-1}(x)$，令

$$H_t(x) = H_{t-1}(x) + \alpha_t h_t(x)$$

最小化指数损失，求解α_t, h_t:

$$\min_{\alpha_t, h_t} \sum_{i=1}^{m} e^{-y_i H(x_i)} \quad \Longleftrightarrow \quad \min_{\alpha_t, h_t} \sum_{i=1}^{m} w_{ti}\, e^{-y_i \alpha_t h_t(x_i)}$$

$$(w_{ti} = e^{-y_i H_{t-1}(x_i)})$$

- **更新$w_{ti} \rightarrow w_{t+1\,i}$【数据的分布更新】：**

$$w_{t+1\,i} = w_{ti} \times \begin{cases} \exp(-\alpha_t) & if\ h_t(x) = f(x) \\ \exp(\alpha_t) & if\ h_t(x) \neq f(x) \end{cases}$$

AdaBoost

加法模型

$$h_t(x) = \underset{h_t(x)}{arg\,min} \sum_{i=1}^{m} w_{ti} I(y_i \neq h_t(x_i))$$

找使加权误差最小的$h_t(x)$

+

指数损失

$$\alpha_t = \frac{1}{2} ln \frac{1-\varepsilon_t}{\varepsilon_t}$$

$\varepsilon_t \leq \frac{1}{2}$, 分类准确率越高的基分类器占比越大

+

前向分布算法

$$w_{t+1\,i} = w_{ti} \times \begin{cases} \exp(-\alpha_t) & if\ h_t(x) = f(x) \\ \exp(\alpha_t) & if\ h_t(x) \neq f(x) \end{cases}$$

分错的样本权重更大

AdaBoost算法

输入： 数据集$D = \{(x_1, y_1), (x_2, y_2), ..., (x_m, y_m)\}$;
基础学习算法$\mathfrak{L}$；学习回合数T.

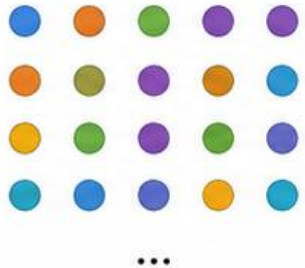
过程：

1. $\mathcal{D}_1(x) = 1/m.$ %初始化权重分布
2. **for** $t = 1, ..., T$:
3. $h_t = \mathfrak{L}(D, \mathcal{D}_t)$; %在分布$\mathcal{D}_t$下，从$D$中训练一个基分类器$h_t$
4. $\epsilon_t = P_{x\sim\mathcal{D}_t}(h_t(x) \neq f(x))$; %评估$h_t$的误差
5. **if** $\epsilon_t > 0.5$**then break**
6. $\alpha_t = \frac{1}{2}\ln(\frac{1-\epsilon_t}{\epsilon_t})$; %确定$h_t$的集成权重
7. $$\mathcal{D}_t(x) = \frac{\mathcal{D}_t(x)}{Z_t} \times \begin{cases} \exp(-\alpha_t) & if\ h_t(x) = f(x) \\ \exp(\alpha_t) & if\ h_t(x) \neq f(x) \end{cases}$$
$$= \frac{\mathcal{D}_t(x)\exp(-\alpha_t f(x)\, h_t(x))}{Z_t}$$ %更新数据分布，其中Z_t是标准化因子
8. **end**

输出： $H(x) = sign(\sum_{t=1}^{T} \alpha_t\, h_t(x))$

stacking

1. 原始数据



同一训练集输入给多个模型

2. 训练多种基学习器

基学习器1：决策树

基学习器2：SVM

基学习器3：KNN

模型类型可以不同

3. 生成一级预测

$h_1(x)$ → 0.81, 0.23, 0.67, ⋮, 0.45

$h_2(x)$ → 0.35, 0.72, 0.18, ⋮, 0.61

$h_3(x)$ → 0.60, 0.41, 0.55, ⋮, 0.33

一级预测特征 / 元特征

$h_1(x)$	$h_2(x)$	$h_3(x)$	…
0.81	0.35	0.60	…
0.23	0.72	0.41	…
0.67	0.18	0.55	…
⋮	⋮	⋮	…
0.45	0.61	0.33	…

把各模型输出拼接起来

4. 元学习器融合

一级预测特征 / 元特征

$h_1(x)$	$h_2(x)$	$h_3(x)$	…
⋮	⋮	⋮	…

元学习器

（如逻辑回归 / XGBoost 等）

最终预测

$$F(x) = g(h_1(x), h_2(x), h_3(x), \ldots)$$

融合多个模型的优势

第一层负责“各自学习”，第二层负责“综合判断”

Stacking 的关键：把基学习器输出再学一遍

1 模型多样性

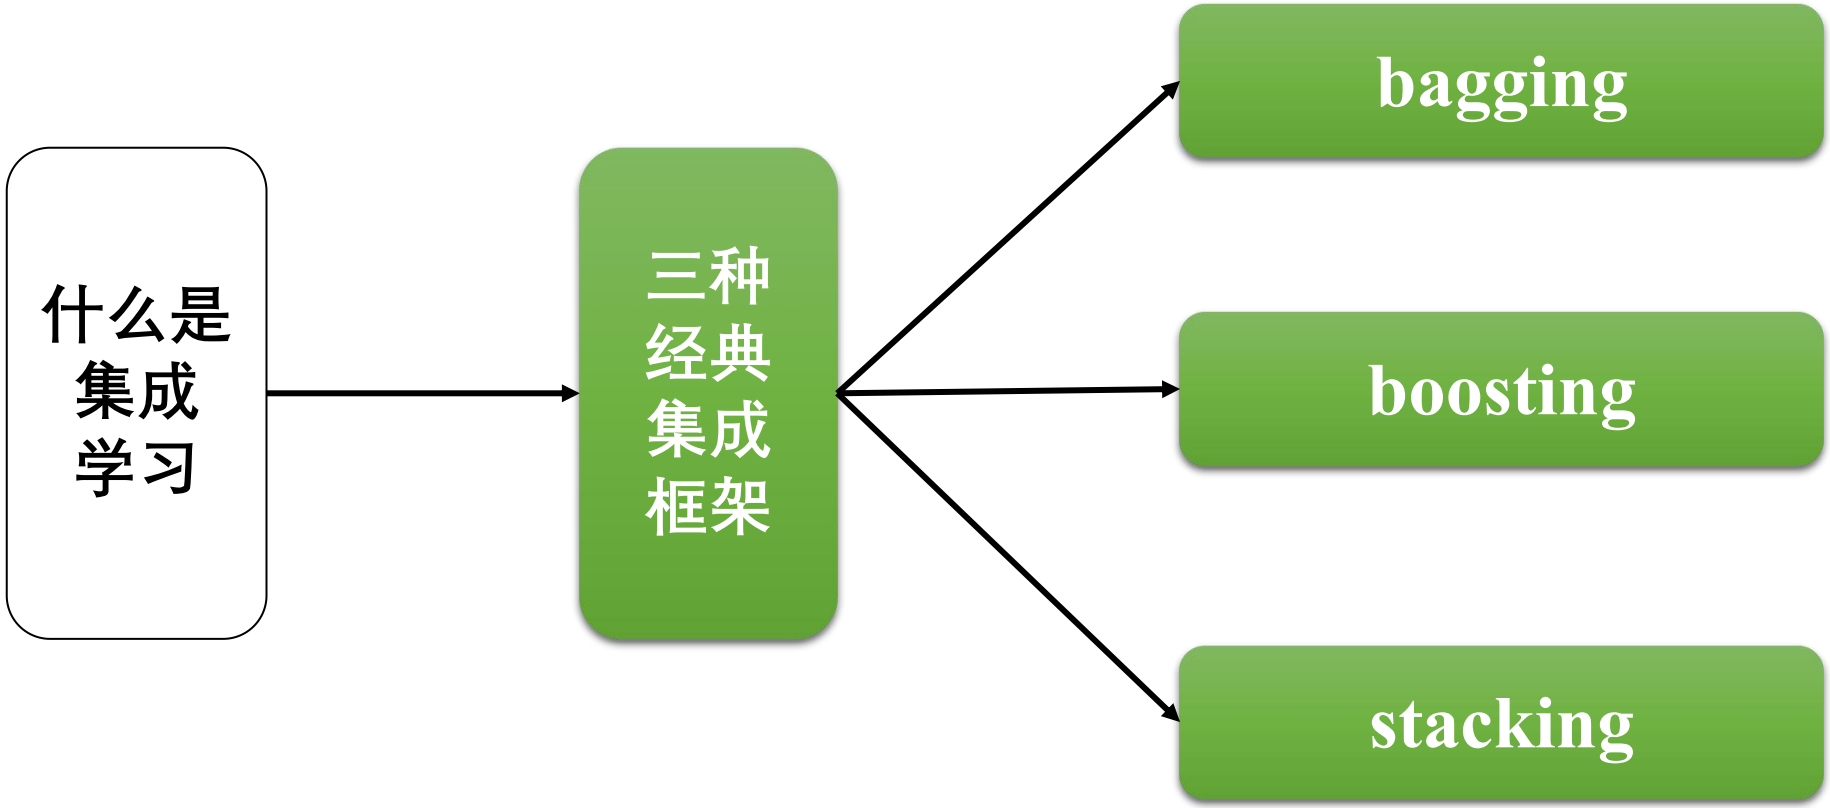
使用不同类型或结构的基学习器，提升整体泛化能力。

2 构造元特征

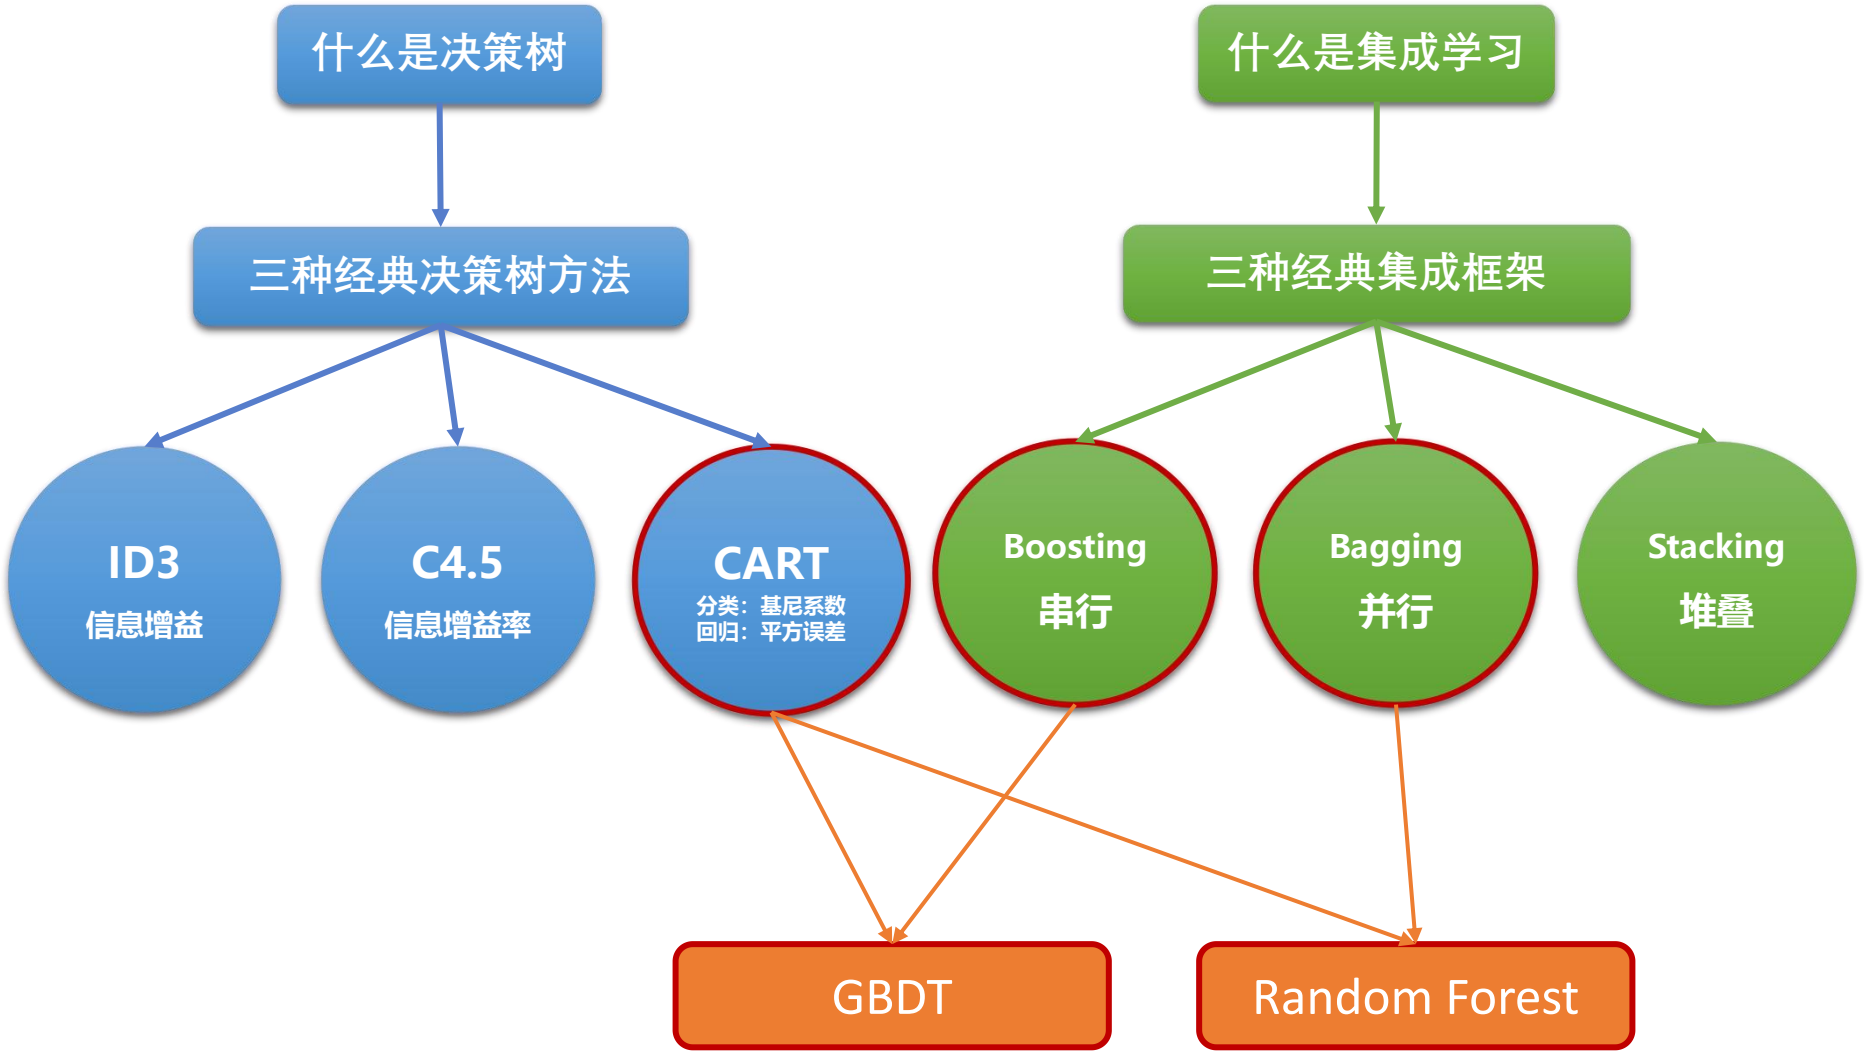
把各基学习器的预测结果作为新特征，形成更丰富的信息表达。

3 元学习器融合

元学习器学习如何组合各模型的输出，做出更准确的最终预测。


什么是集成学习
三种经典集成框架
bagging
boosting
stacking

大纲


什么是决策树
三种经典决策树方法
ID3
信息增益
C4.5
信息增益率
CART
分类：基尼系数
回归：平方误差
什么是集成学习
三种经典集成框架
Boosting
串行
Bagging
并行
Stacking
堆叠
GBDT
Random Forest

初筛：学历、收入、兴趣**（决策树）**

多人评价：闺蜜/家长打分**（Bagging）**

不断迭代：前几次失败经验反思**（Boosting）**

不同人推荐你不同对象，你再决定（Stacking）



你有没有对象啊


谢 谢
首都师范大学
CAPITAL NORMAL UNIVERSITY