首都师范大学
CAPITAL NORMAL UNIVERSITY



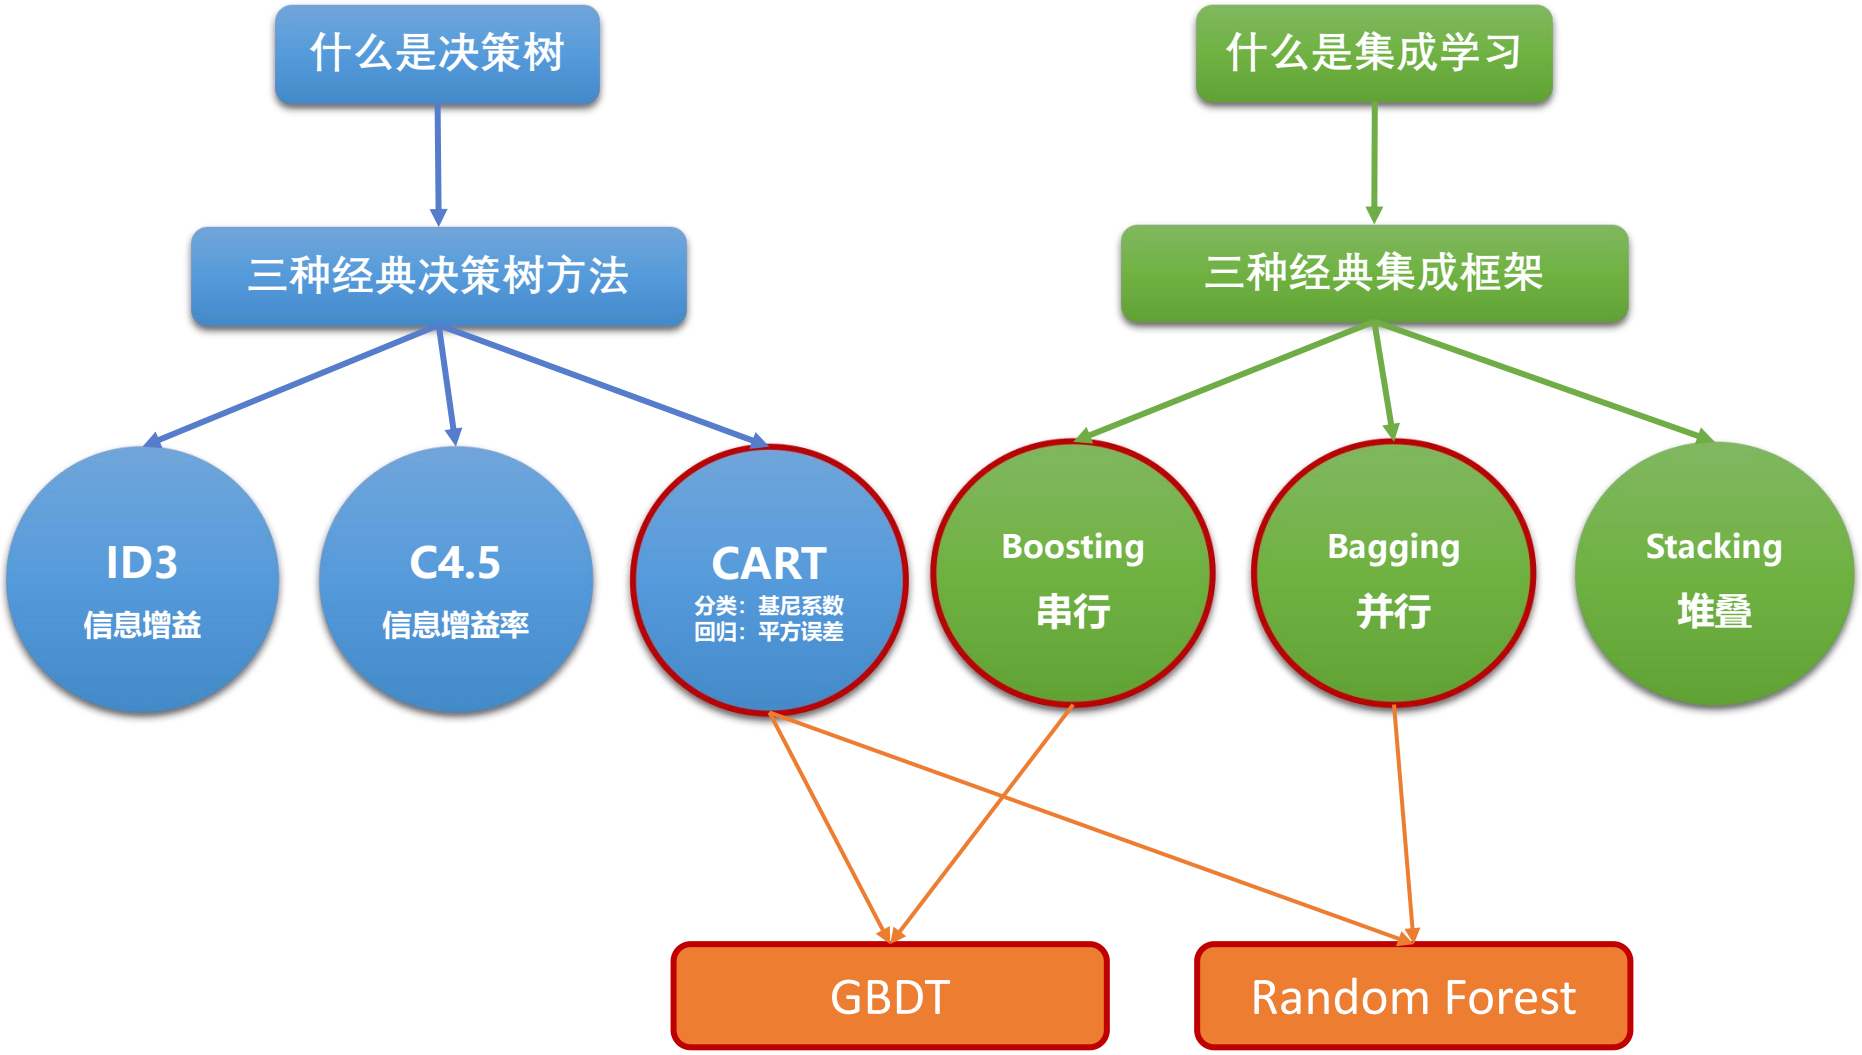
第九课
决策树和集成学习

授课教师：潘贤丽

Bagging vs Boosting vs stacking

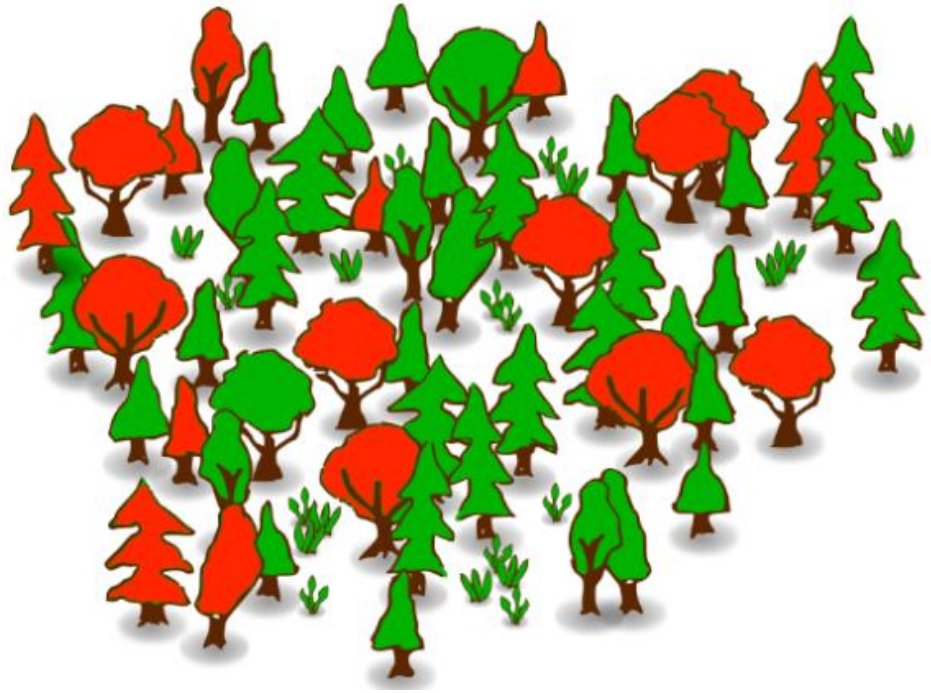
方法	样本选择	样本权重	基学习器	集成方式	组合方式
bagging	Bootstrap抽样	等权重	同质：高方差，如DT、NN	并行	等权重组合
boosting	全样本	分得越错则权重越大	同质：高偏差，如线性模型、决策树桩	串行	加权组合：正确率越高权重越大
stacking	全样本	等权重	异质	并行	通过新的学习器组合

大纲


什么是决策树
三种经典决策树方法
ID3
信息增益
C4.5
信息增益率
CART
分类：基尼系数
回归：平方误差
什么是集成学习
三种经典集成框架
Boosting
串行
Bagging
并行
Stacking
堆叠
GBDT
Random Forest

RF： 随机森林

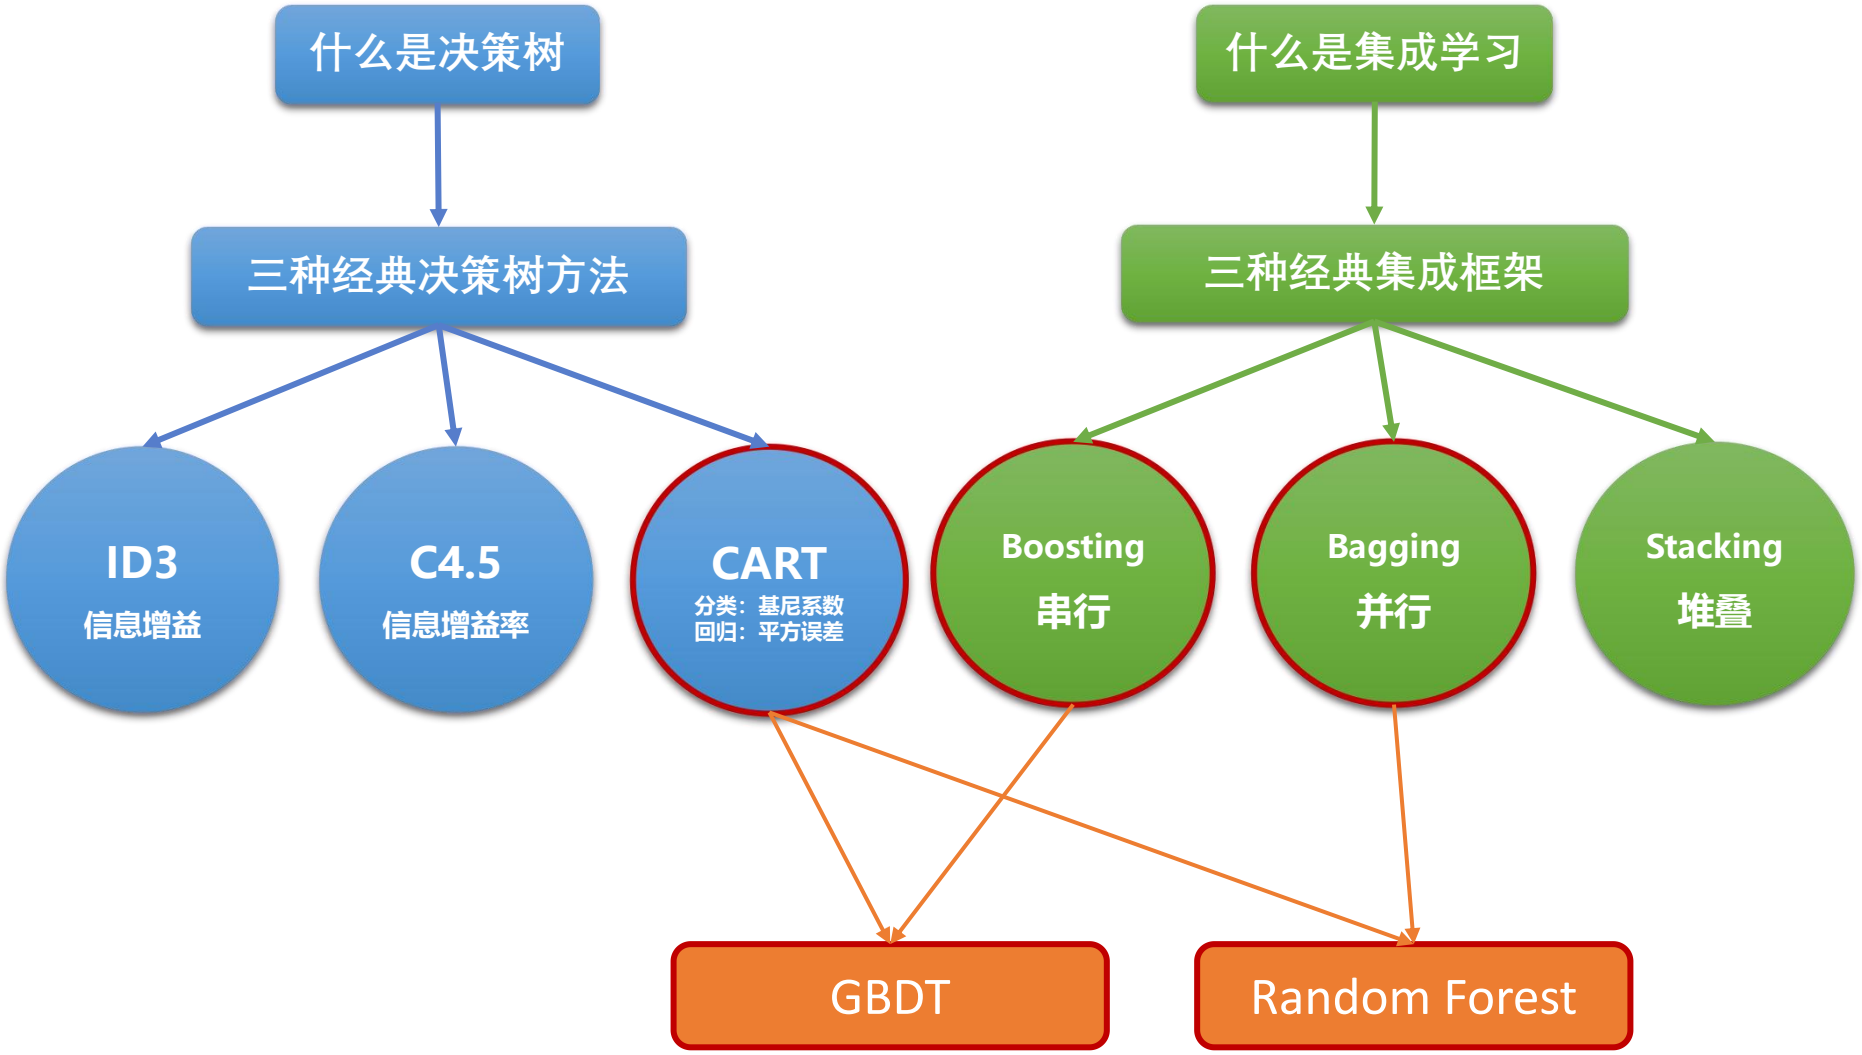


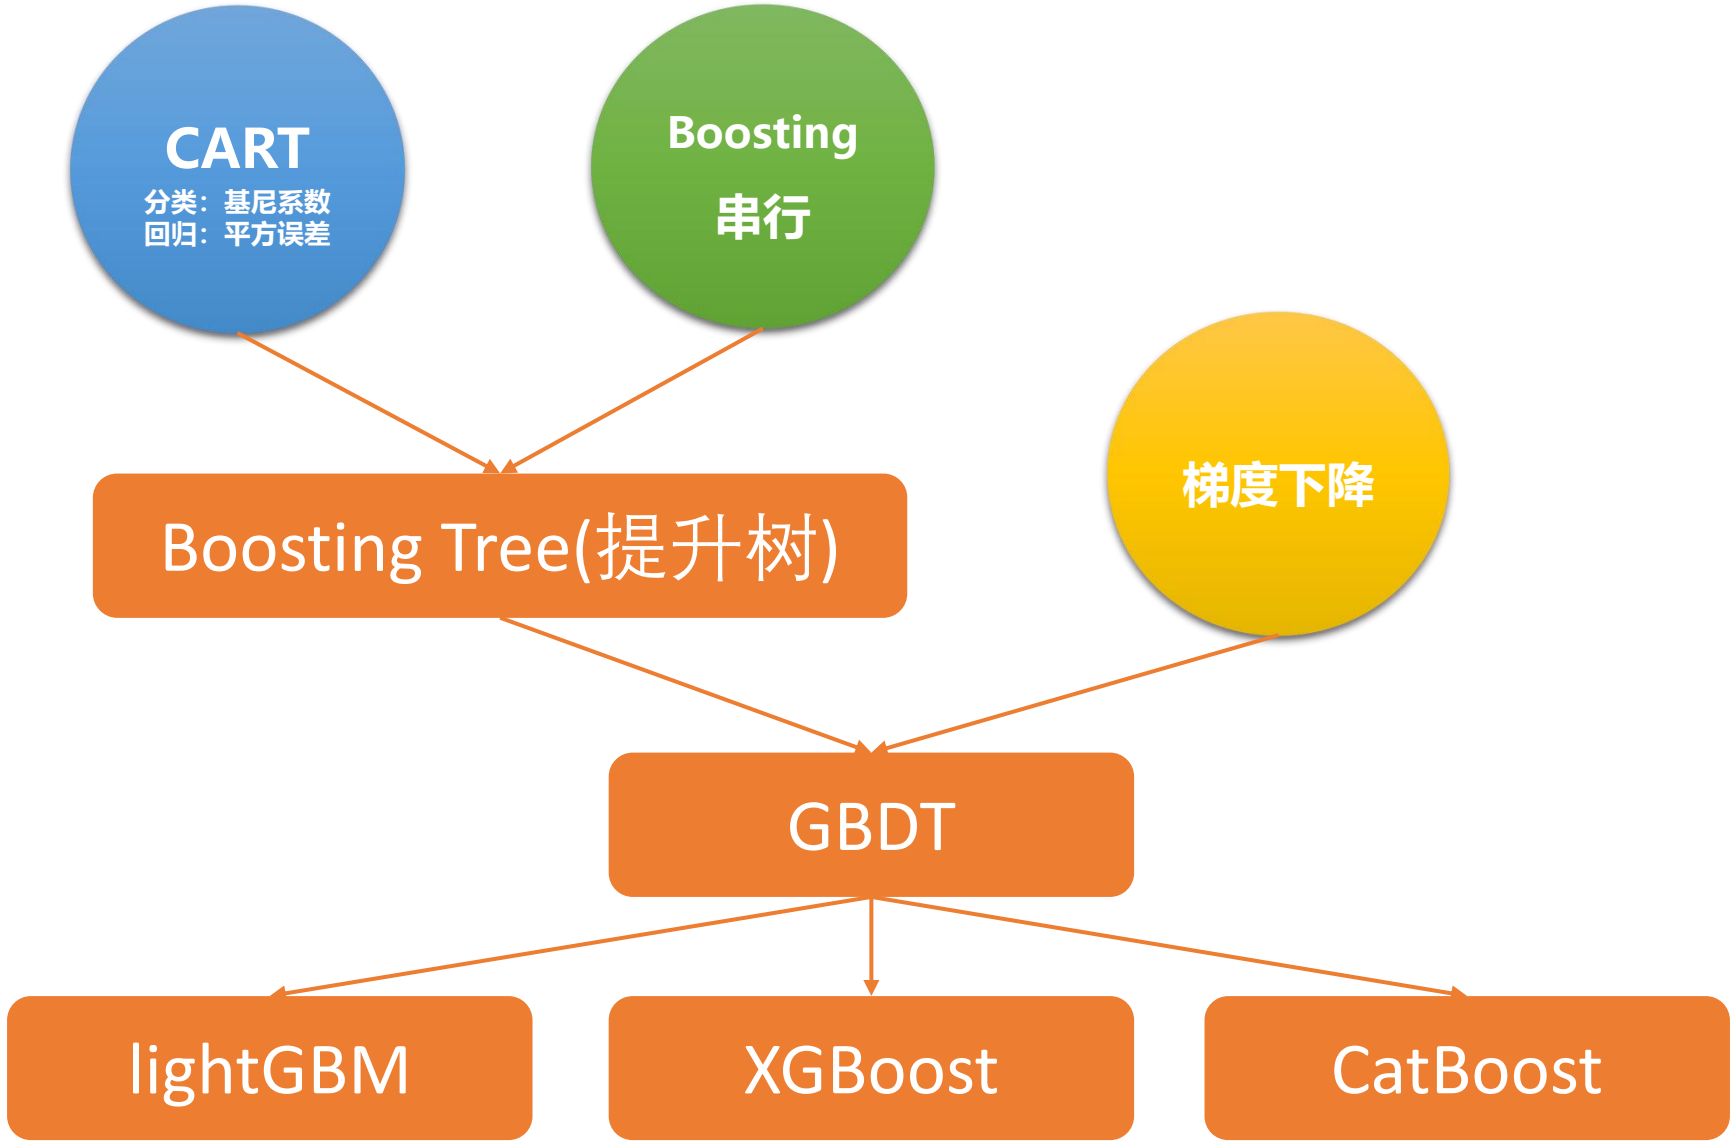


RF： 随机森林


Step 1
随机抽样
训练决策树
Step 2
随机选取属性
做节点分裂属性
Step 3
重复步骤 2
直到不能再分裂
Step 4
建立大量决策树
形成森林

大纲

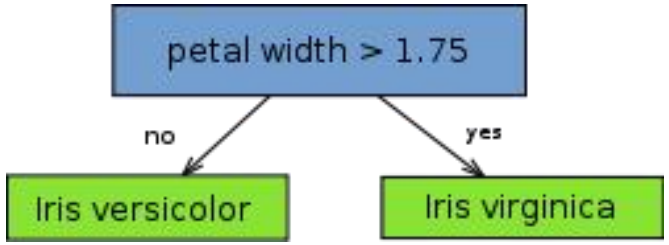

什么是决策树
三种经典决策树方法
ID3
信息增益
C4.5
信息增益率
CART
分类：基尼系数
回归：平方误差
什么是集成学习
三种经典集成框架
Boosting
串行
Bagging
并行
Stacking
堆叠
GBDT
Random Forest


CART
分类：基尼系数
回归：平方误差
Boosting
串行
Boosting Tree(提升树)
梯度下降
GBDT
lightGBM
XGBoost
CatBoost

Boosting Tree(提升树)

定义：以决策树作为基函数的boosting方法家族

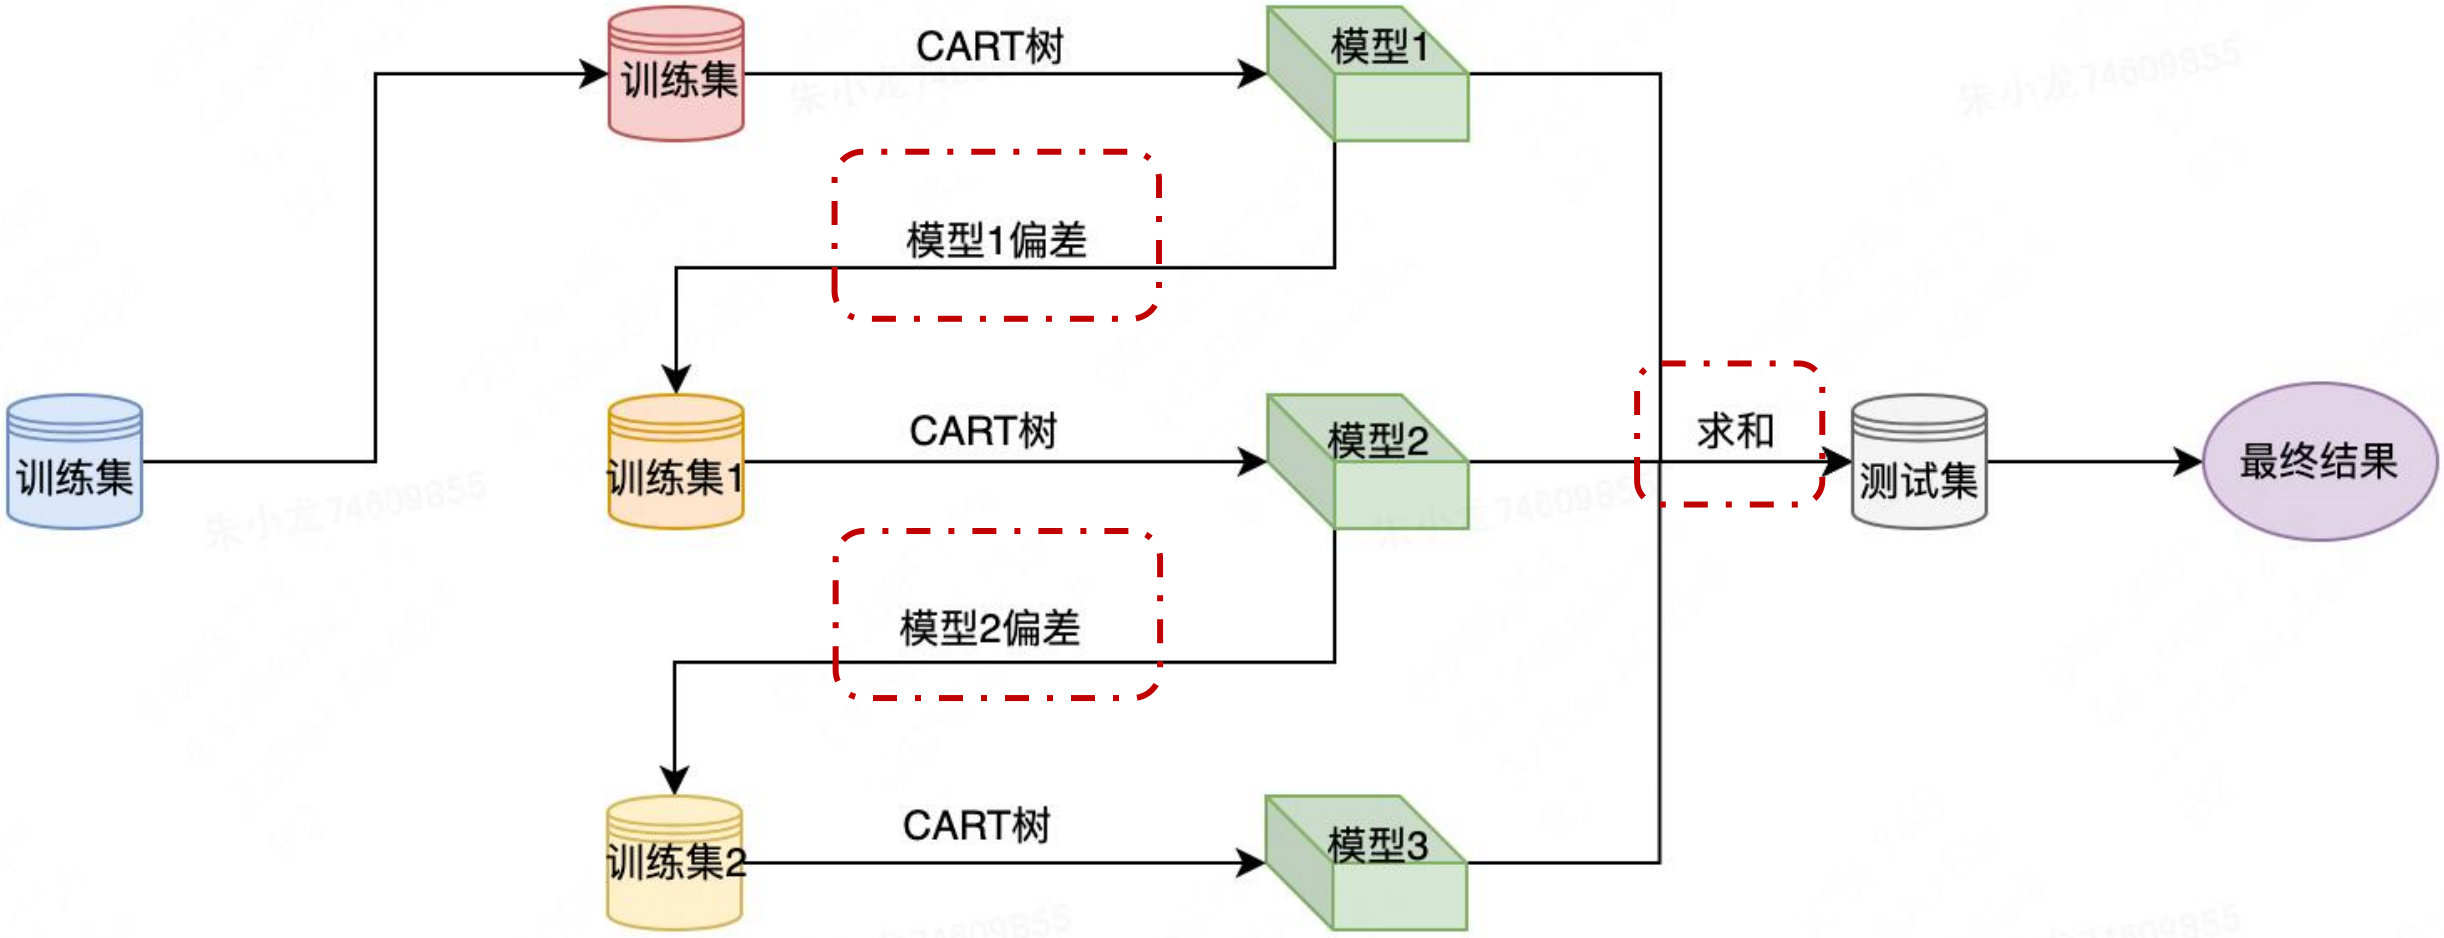
- **分类**：AdaBoost+简单决策树



决策树桩

- **回归**：？

集成学习


训练集
训练集
CART树
模型1
模型1偏差
训练集1
CART树
模型2
求和
测试集
最终结果
模型2偏差
训练集2
CART树
模型3

AdaBoost

加法模型

+

指数损失

+

前向分布算法

模型：

$$H(x) = \sum_{t=1}^{T} \alpha_t h_t(x)$$

（T个基分类器，每个基分类器带有权重α_t）

方法： $Loss(x_i) = e^{-y_i H(x_i)}$

$$\min_{(\alpha_t, h_t)_{t=1}^{T}} \sum_{i=1}^{m} L(x_i) = \sum_{i=1}^{m} e^{-y_i H(x_i)}$$ (m个样本)

求解： 直接求解太困难，通常采用**前向分布算法**

Boosting Tree(提升树)

加法模型

+

平方损失

+

前向分布算法

模型：

$$f_M(x) = \sum_{m=1}^{M} T(x;\theta_m)$$

方法：最小化**平方损失**

$$\min_{(\theta_m)_{m=1}^{M}} \sum_{i=1}^{N} (y_i - f_M(x_i))^2$$

求解：直接求解太困难，通常采用**前向分布算法**

Boosting Tree(提升树)

假设到第m次循环，已知$f_{m-1}(x)$，令

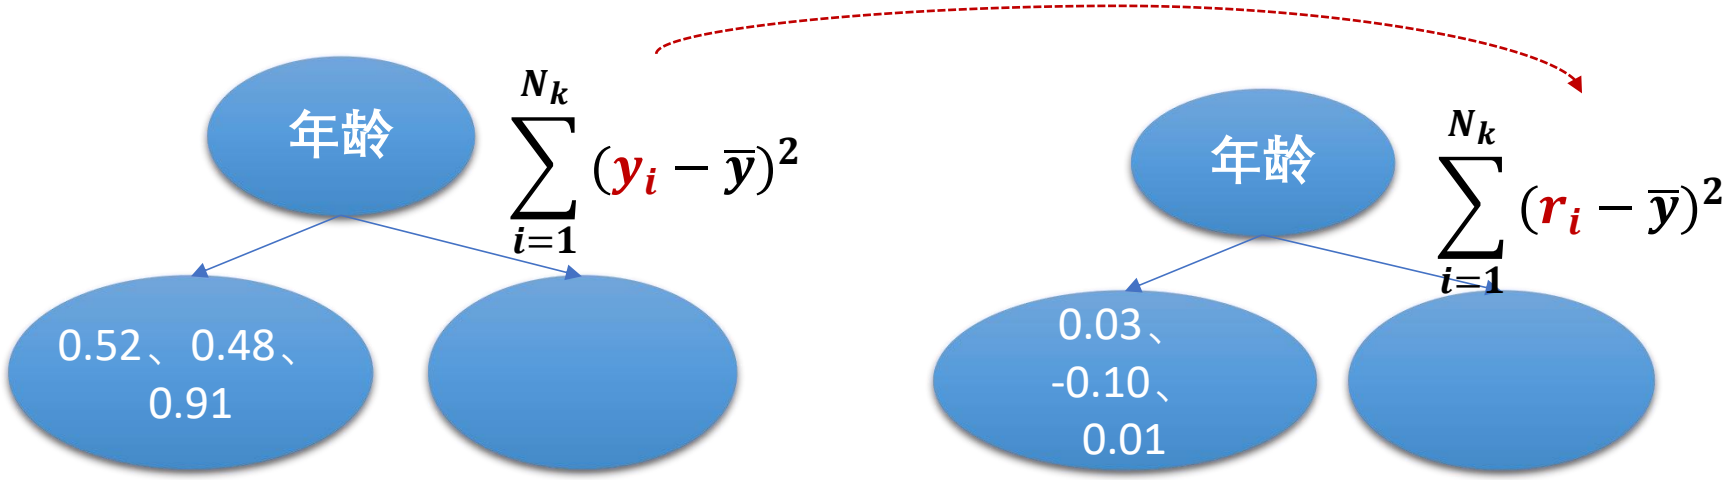
$$f_m(x) = f_{m-1}(x) + T(x;\theta_m)$$

最小化平方损失，求解θ_m：

$$\min_{\theta_m} \sum_{i=1}^{N} (y_i - f_{m-1}(x_i) - T(x;\theta_m))^2$$

残差 r_i

Boosting Tree(提升树)

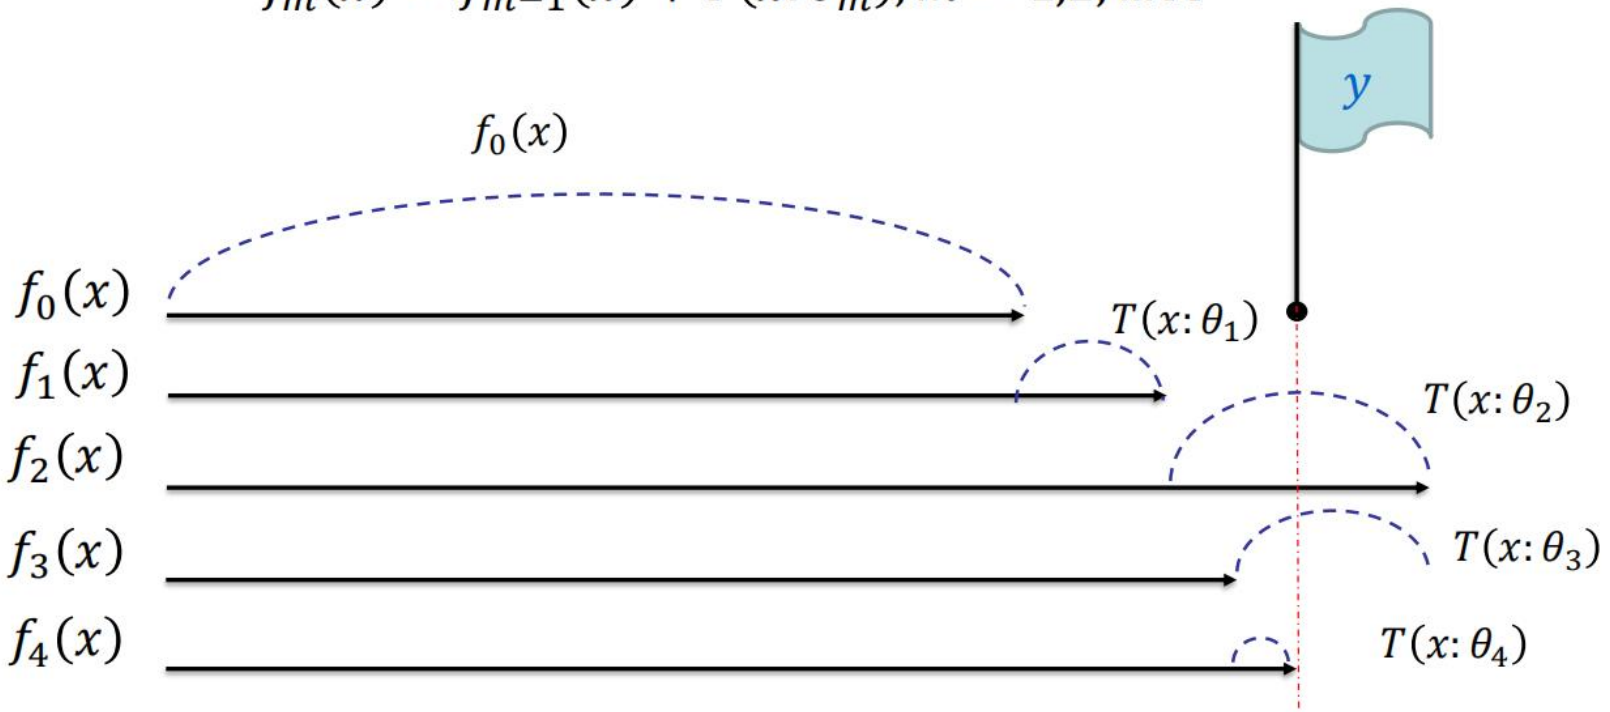


Boosting Tree(提升树)

前向分步算法：



$$f_m(x) = f_{m-1}(x) + T(x;\theta_m), m = 1,2,\dots M$$



Boosting Tree(提升树)

输入：训练数据集$T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$

输出：提升树$f_M(x)$

(1)初始化$f_0(x) = 0$

(2)对$m = 1,2, \dots M$

(a)计算残差 $r_{mi} = y_i - f_{m-1}(x_i), i = 1,2, \dots, N$

(b)拟合残差r_{mi}学习一个回归树，得到$T(x: \theta_m)$

(c)更新$f_m(x) = f_{m-1}(x) + T(x: \theta_m)$

(3)得到回归提升树

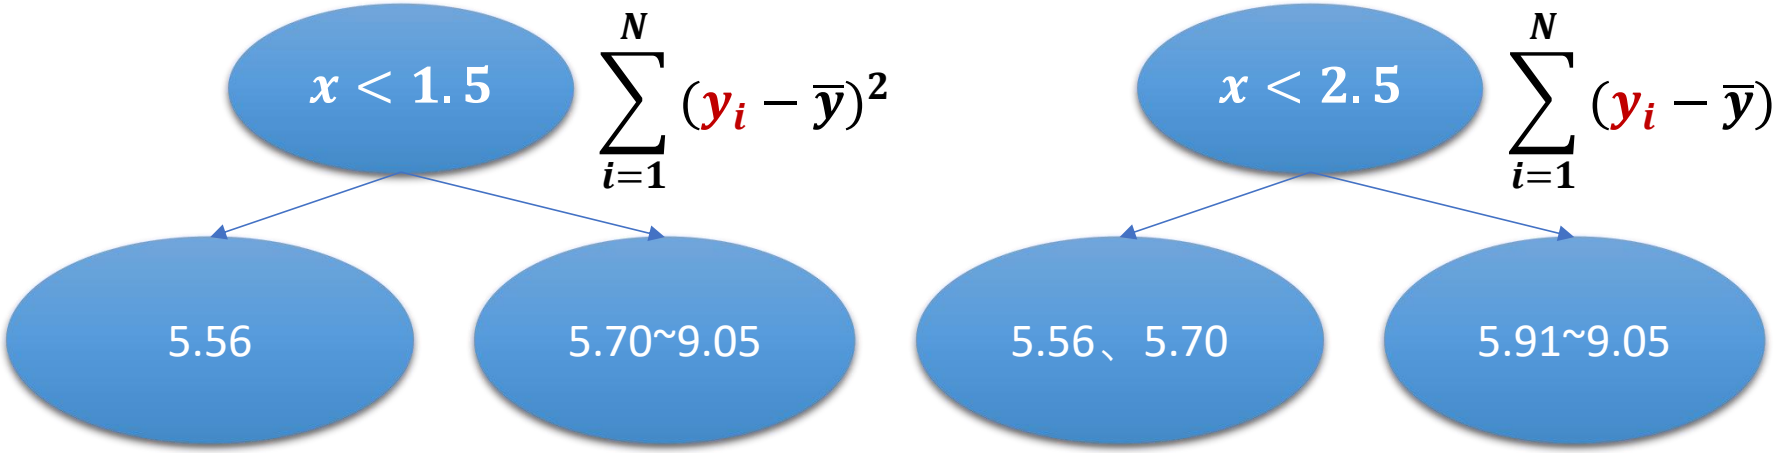
$$f_M(x) = \sum_{m=1}^{M} T(x: \theta_m)$$

Boosting Tree(提升树)

例 8.2 已知如表 8.2 所示的训练数据，x 的取值范围为区间 [0.5,10.5]，y 的取值范围为区间 [5.0,10.0]，学习这个回归问题的提升树模型，考虑只用树桩作为基函数。

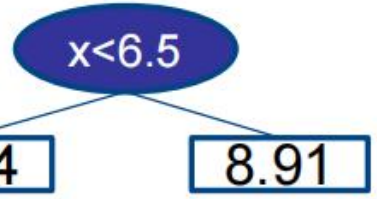
表 8.2 训练数据表

x_i	1	2	3	4	5	6	7	8	9	10
y_i	5.56	5.70	5.91	6.40	6.80	7.05	8.90	8.70	9.00	9.05



Boosting Tree(提升树)

s	1.5	2.5	3.5	4.5	5.5	6.5	7.5	8.5	9.5
m(s)	15.72	12.07	8.36	5.78	3.91	1.93	8.01	11.73	15.74



$$f_1(x) = T_1(x) =$$

x	y
1	5.56
2	5.7
3	5.91
4	6.4
5	6.8
6	7.05
7	8.9
8	8.7
9	9
10	9.05

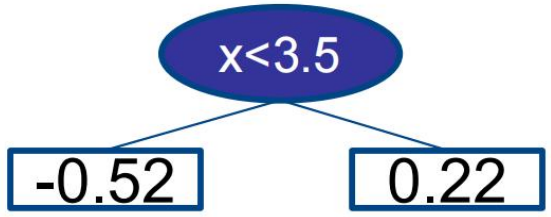
x	y	y-f(x)
1	5.56	-0.68
2	5.7	-0.54
3	5.91	-0.33
4	6.4	0.16
5	6.8	0.56
6	7.05	0.81
7	8.9	-0.01
8	8.7	-0.21
9	9	0.09
10	9.05	0.14

Boosting Tree(提升树)

表 8.4　残差表

x_i	1	2	3	4	5	6	7	8	9	10
r_{2i}	−0.68	−0.54	−0.33	0.16	0.56	0.81	−0.01	−0.21	0.09	0.14

$$T_2(x) =$$



$$T_1(x) = \begin{cases} 6.24, & x < 6.5 \\ 8.91, & x \geqslant 6.5 \end{cases}$$

$$T_2(x) = \begin{cases} -0.52, & x < 3.5 \\ 0.22, & x \geqslant 3.5 \end{cases}$$

$$f_2(x) = f_1(x) + T_2(x) = \begin{cases} 5.72, & x < 3.5 \\ 6.46, & 3.5 \leqslant x < 6.5 \\ 9.13, & x \geqslant 6.5 \end{cases}$$

Boosting Tree(提升树)

$$T_3(x)=\begin{cases}0.15, & x<6.5\\ -0.22, & x\geqslant 6.5\end{cases}$$

$$T_4(x)=\begin{cases}-0.16, & x<4.5\\ 0.11, & x\geqslant 4.5\end{cases}$$

$$T_5(x)=\begin{cases}0.07, & x<6.5\\ -0.11, & x\geqslant 6.5\end{cases}$$

$$T_6(x)=\begin{cases}-0.15, & x<2.5\\ 0.04, & x\geqslant 2.5\end{cases}$$

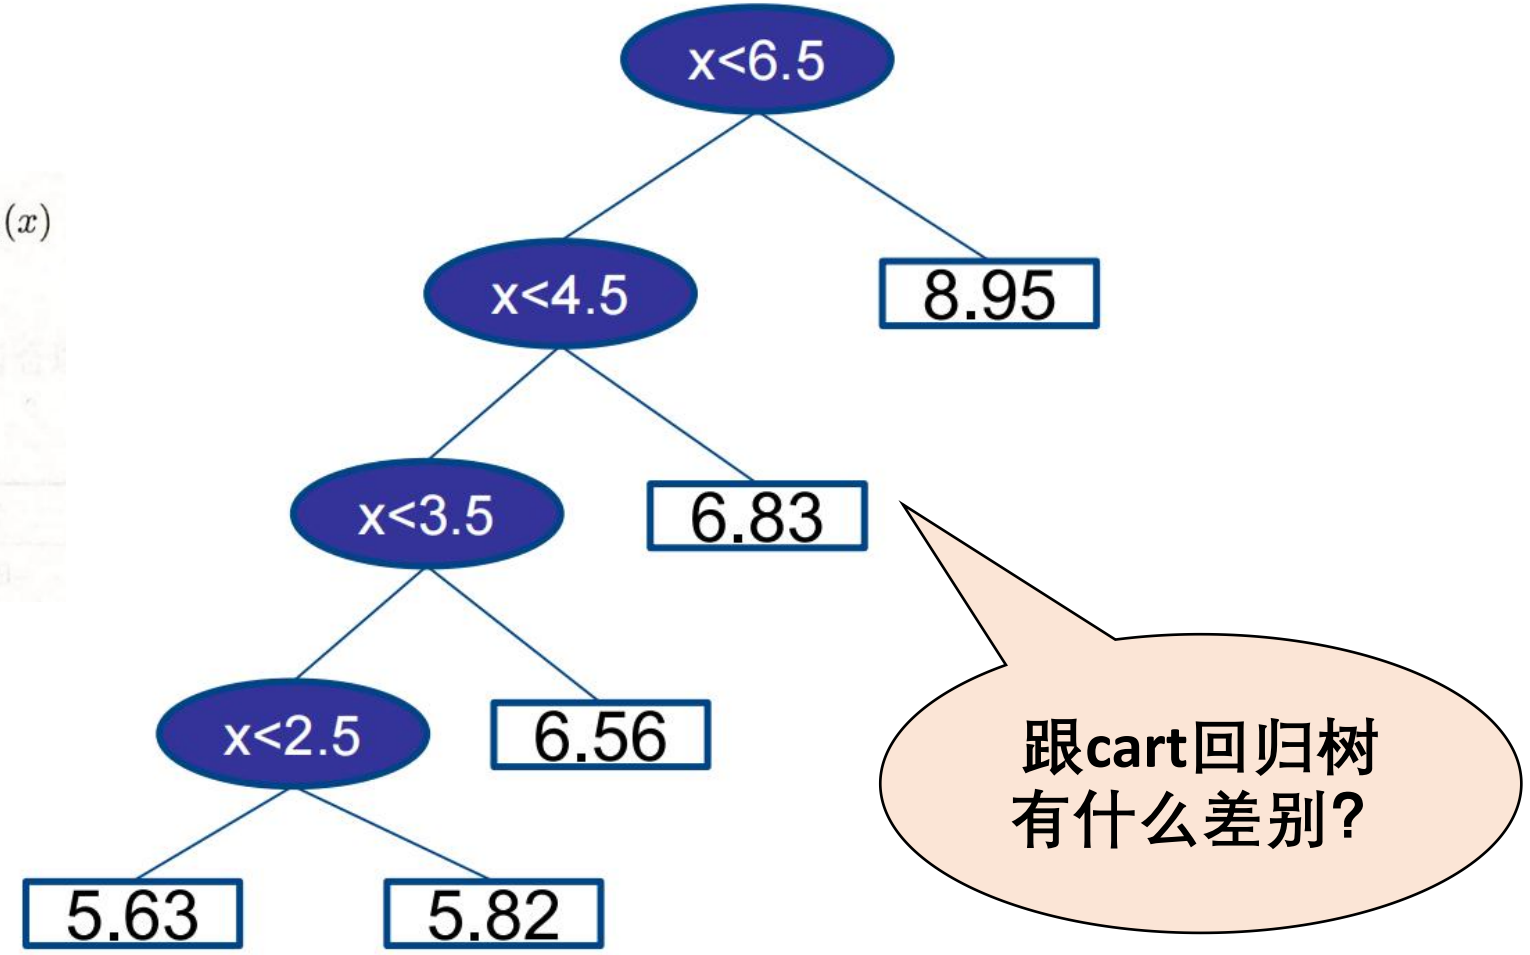
$$f_6(x)=f_5(x)+T_6(x)=T_1(x)+\cdots+T_5(x)+T_6(x)$$

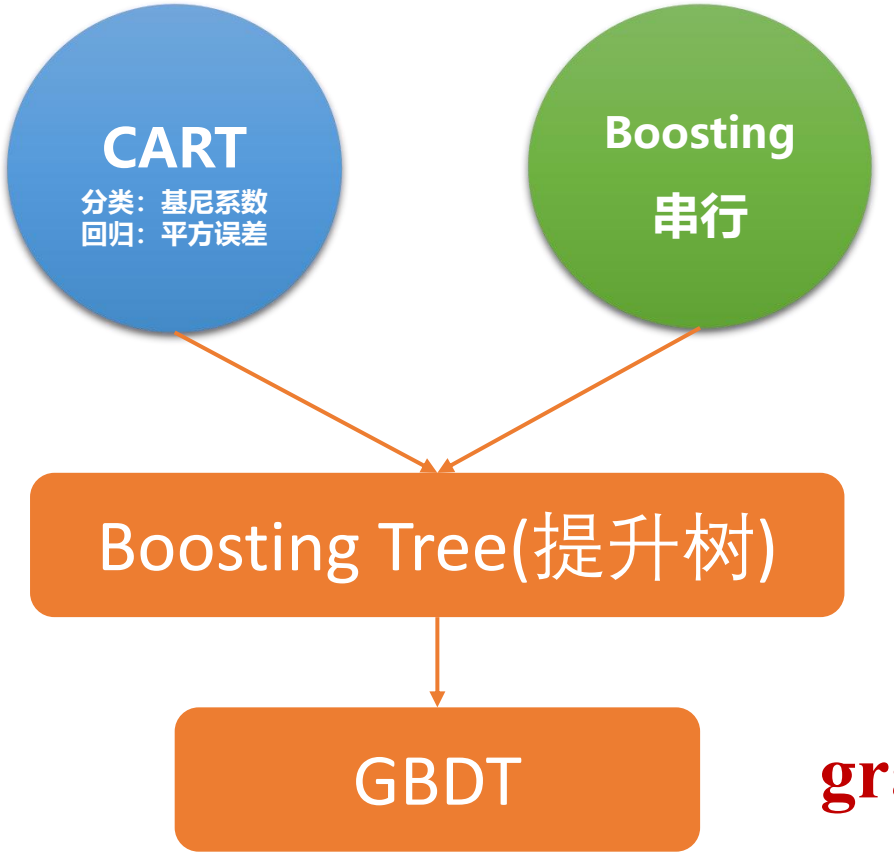
$$=\begin{cases}5.63, & x<2.5\\ 5.82, & 2.5\leqslant x<3.5\\ 6.56, & 3.5\leqslant x<4.5\\ 6.83, & 4.5\leqslant x<6.5\\ 8.95, & x\geqslant 6.5\end{cases}$$

Boosting Tree(提升树)

$$f_6(x) = f_5(x) + T_6(x) = T_1(x) + \cdots + T_5(x) + T_6(x)$$

$$= \begin{cases} 5.63, & x < 2.5 \\ 5.82, & 2.5 \leqslant x < 3.5 \\ 6.56, & 3.5 \leqslant x < 4.5 \\ 6.83, & 4.5 \leqslant x < 6.5 \\ 8.95, & x \geqslant 6.5 \end{cases}$$



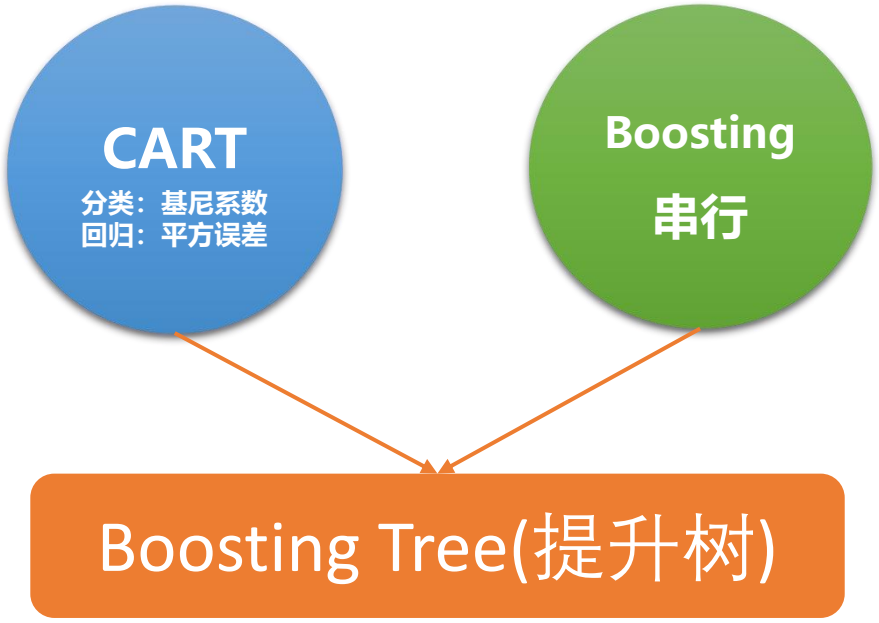


分类： Adaboost+决策树

回归： 平方损失+决策树

gradient boosting decision tree

GBDT





回归：**平方损失**+决策树

GBDT

假设到第m次循环，已知$f_{m-1}(x)$，令

$$f_m(x) = f_{m-1}(x) + T(x;\theta_m)$$

最小化平方损失，求解θ_m：

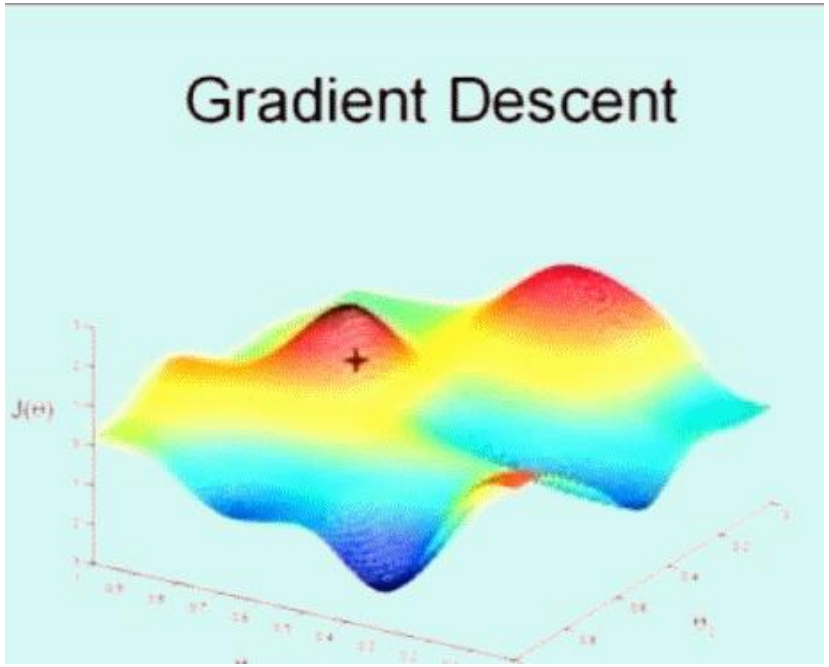
$$\min_{\theta_m} \sum_{i=1}^{N} (\boldsymbol{y_i - f_{m-1}(x_i)} - T(x_i;\theta_m))^2$$

用损失函数当前负梯度值近似残差

一般损失

$$-\left[\frac{\partial L(y_i, f(x_i))}{\partial f(x_i)}\right]_{f(x)=f_{m-1}(x)}$$

GBDT



$$w_{k+1} = w_k - \alpha \nabla f(w_k)$$

最小化**累加损失**：

$$Loss\left(y, f_m(x)\right)$$

已知： $f_{m-1}(x)$

求： $f_m(x)$

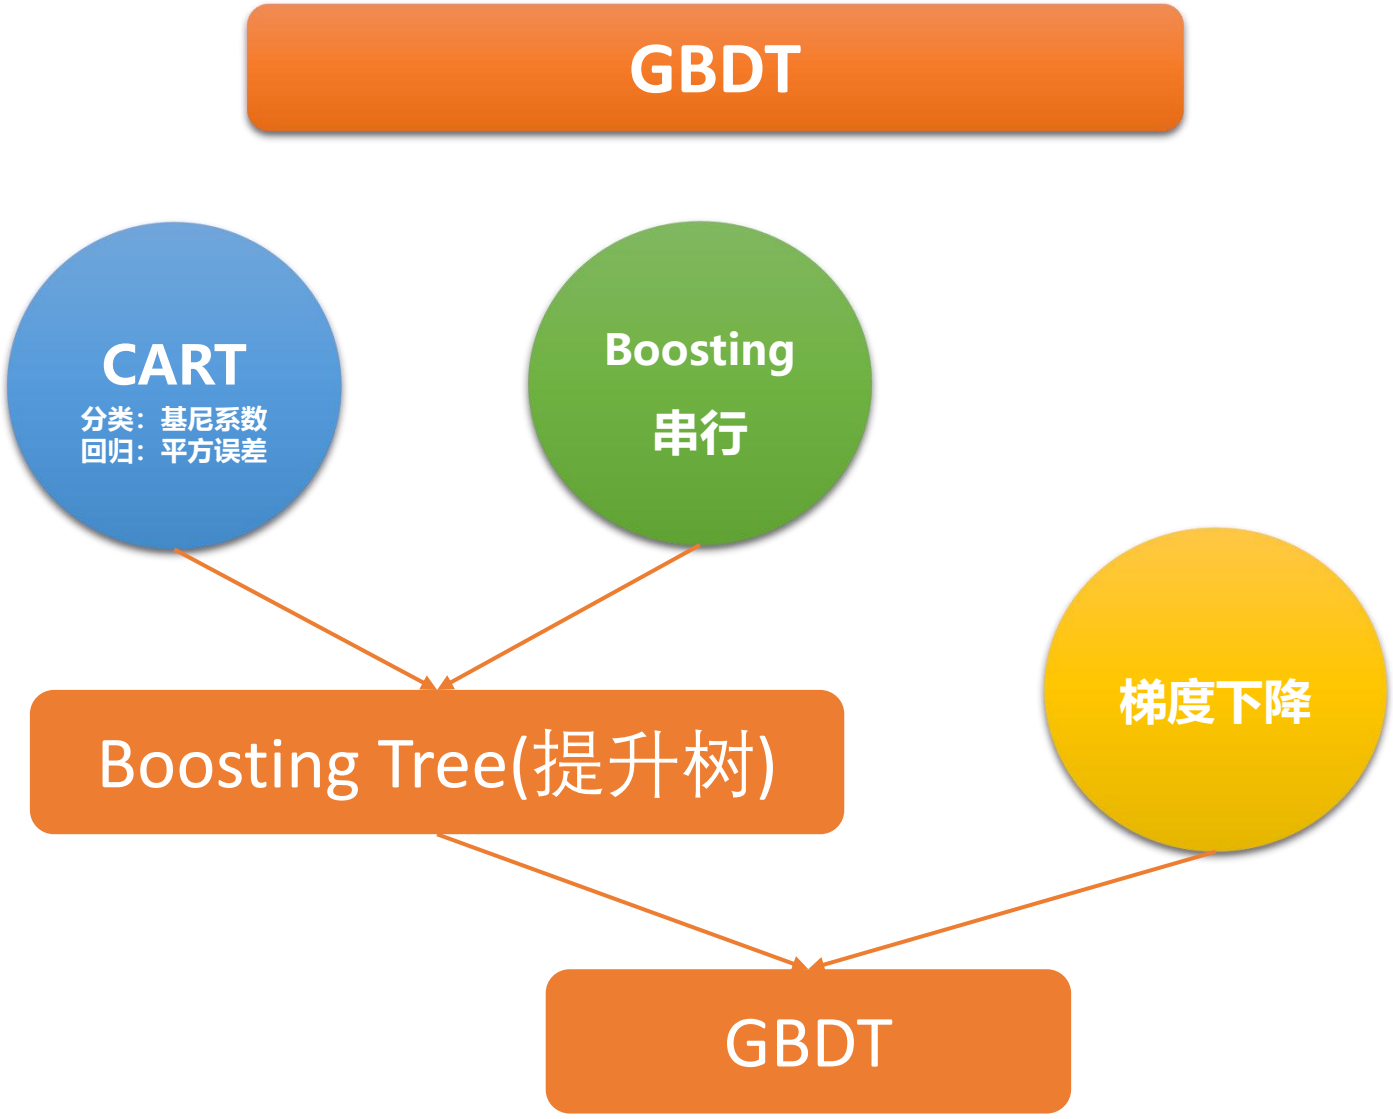
$$f_m(x) = f_{m-1}(x) - \alpha \nabla Loss\left(y, f_{m-1}(x)\right)$$

$$\Downarrow$$

$$f_m(x) = f_{m-1}(x) + T(x: \theta_m)$$

$$\Downarrow$$

$$T(x: \theta_m) = -\alpha \nabla Loss\left(y, f_{m-1}(x)\right)$$


GBDT
CART
分类：基尼系数
回归：平方误差
Boosting
串行
Boosting Tree(提升树)
梯度下降
GBDT

GBDT

输入：训练数据集$T=\{(x_1,y_1),(x_2,y_2),\dots,(x_N,y_N)\}$，损失函数$\mathrm{L}(y,f(x))$

输出：提升树$f_M(x)$

(1)初始化$f_0(x)=arg\min_c\sum_{i=1}^{N}L(y_i,c)$

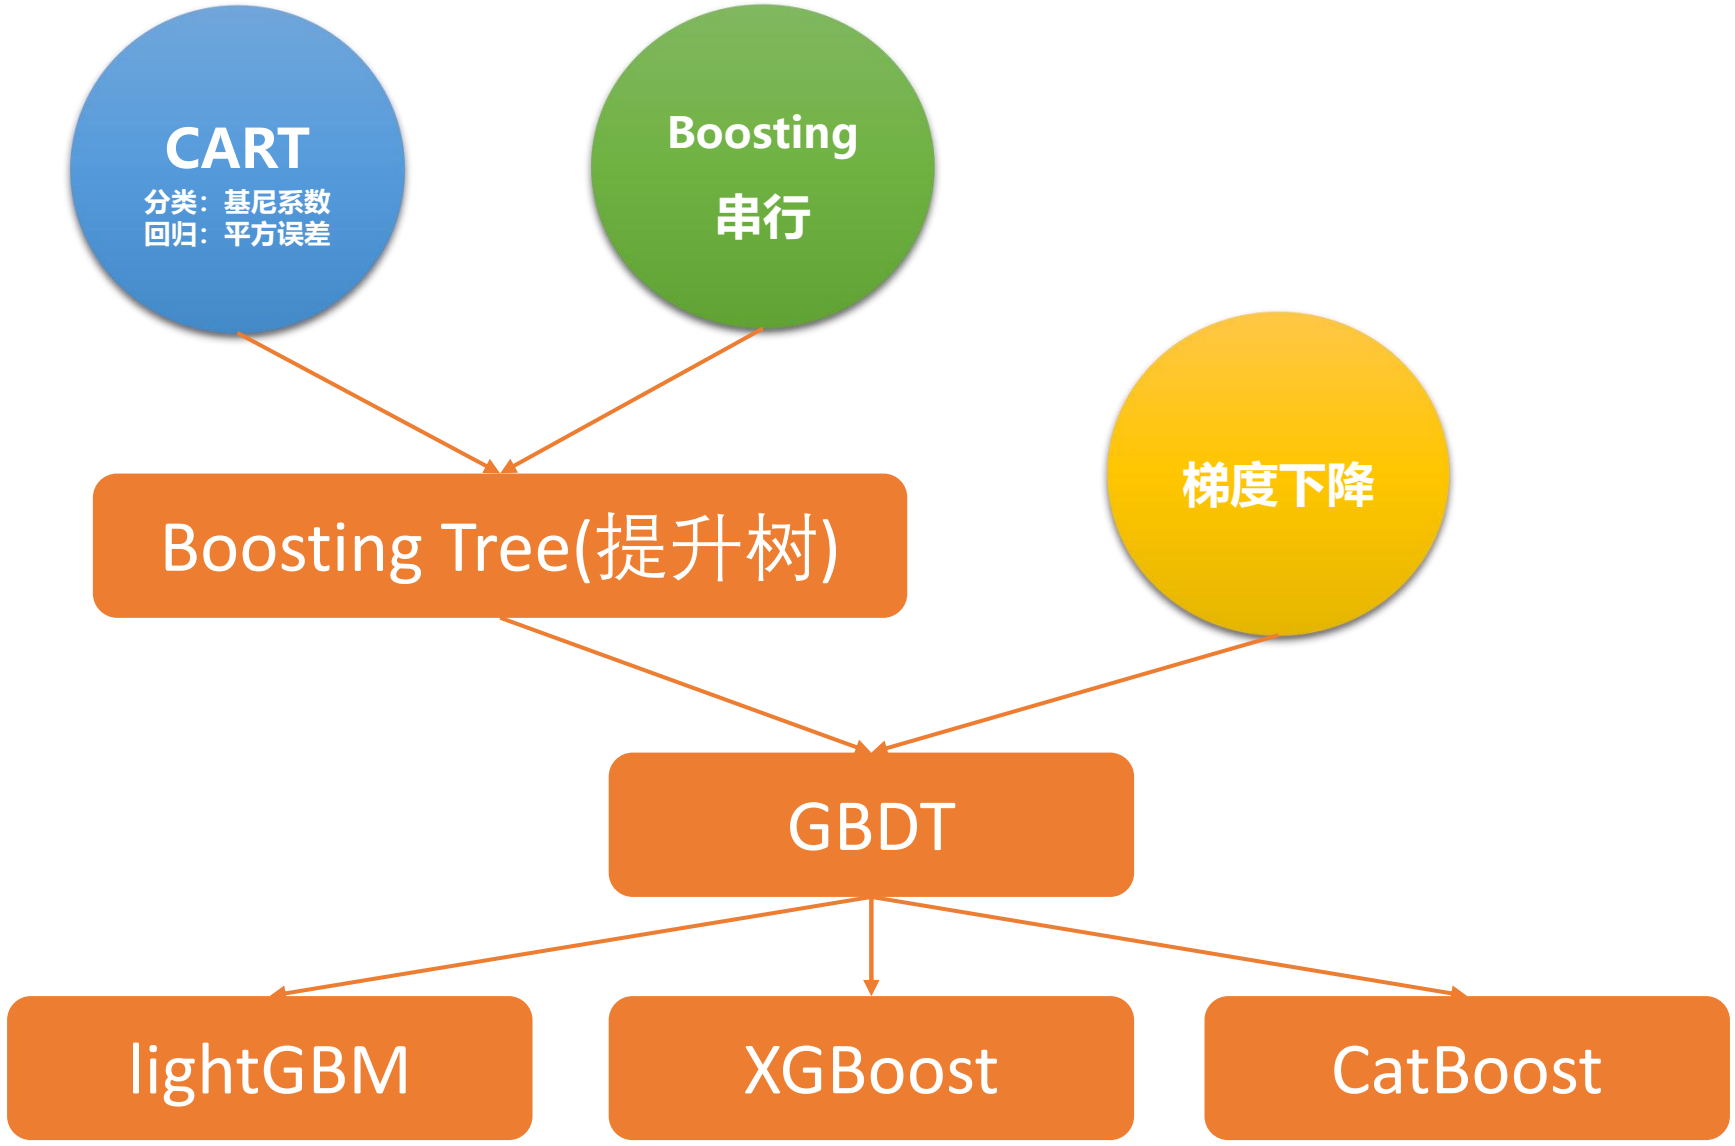
(2)对$m=1,2,\dots M$

(a)对$i=1,2\dots N$计算 $r_{mi}=-\left[\frac{\partial L(y_i,f(x_i))}{\partial f(x_i)}\right]_{f(x)=f_{m-1}(x)}$

(b)拟合r_{mi}学习一个回归树，得到$T(x:\theta_m)$

(c)计算步长，$\sigma_m=arg\min_\sigma\sum_{i=1}\mathrm{L}(y_i,f_{m-1}(x_i)+\sigma T(x:\theta_m))$

(d)更新$f_m(x)=f_{m-1}(x)+\sigma_m T(x:\theta_m)$


CART
分类：基尼系数
回归：平方误差
Boosting
串行
Boosting Tree(提升树)
梯度下降
GBDT
lightGBM
XGBoost
CatBoost

XGBoost: eXtreme Gradient Boosting



Tianqi Chen

Carnegie Mellon University

Email: tqchen at cmu dot edu
Google Scholar: Tianqi Chen
Github: @tqchen
Twitter: @tqchenml
Office: GHC 8221

I am an Assistant Professor in the Machine Learning Department and Computer Science Department at Carnegie Mellon University . I help run the Catalyst Group. I am also the Chief Technologist of OctoML. I recently received my Ph.D. from Paul G. Allen School of Computer Science & Engineering, University of Washington.

At UW, I was advised by Carlos Guestrin. I also worked closely with Luis Ceze and Arvind Krishnamurthy. I was a member of SAMPL Lab and MODE Lab. I recieved my Master and Bachelor's degree from Prof. Yong Yu's ACM Honors Class at Shanghai Jiao Tong University (SJTU).

Research

I am interested in the intersection of machine learning and systems. The real excitement of this area comes from what can enable when we bring advanced learning techniques and system together. On that end, I am also pushing the direction on deep learning, knowledge transfer and lifelong learning.

I am a believer of open source and open science. My group involves publishing algorithms in openly accessible mediums and building open-source machine learning systems that are widely adopted. Here are the ML systems that I created:

- Apache TVM, an Automated End-to-End Optimizing Compiler for Deep Learning.
- XGBoost, a scalable tree boosting system.
- Apache MXNet(co-creator)



知乎

写文章

机器学习科研的十年

陈天奇
CS. PhD 机器学习系统

+ 关注

编辑推荐

微调、杜少雷 等 1 万人赞同了该文章

十年前，MSRA的夏天，刚开始尝试机器学习研究的我面对科研巨大的不确定性，感到最多的是困惑和迷茫。十年之后，即将跨出下一步的时候，未来依然是如此不确定，但是期待又更多了一些。这其中的变化也带着这十年经历的影子。

起始： 科研是什么

我从大三开始进入交大APEX实验室，有幸随着戴文渊学长做机器学习，当时的我觉得“机器学习”这个名字十分高大上然后选择了这个方向，但是做了一年之后依然摸不着头脑，心中十分向往可以做科研，独立写论文的生活，却总是不知道如何下手。文渊在我进实验室的一年后去了百度。当时还没有得到学长真传的我，开始了我科研的第一阶段，从大四到硕士的第二年，期间一直自己摸索，不断地问自己“科研是什么”。

机器学习科研的十年 - 知乎 (zhihu.com)

Boosting Tree 是以决策树为基学习器的boosting框架的总称

GBDT 是其中最核心的具体实现方法

XGBoost、LightGBM、CatBoost 都是对 GBDT 的增强版本

✅ 拓展一下：GBDT 的常见“后代”

算法	特点
XGBoost	GBDT + 二阶导数优化 + 正则项 + 稀疏感知分裂
LightGBM	GBDT + 基于直方图 + Leaf-wise 增长策略
CatBoost	GBDT + 高效类别编码 + 对称树结构

天池-安泰杯跨境电商智能算法大赛 冠军方案分享

天池-跨境电商智能算法大赛

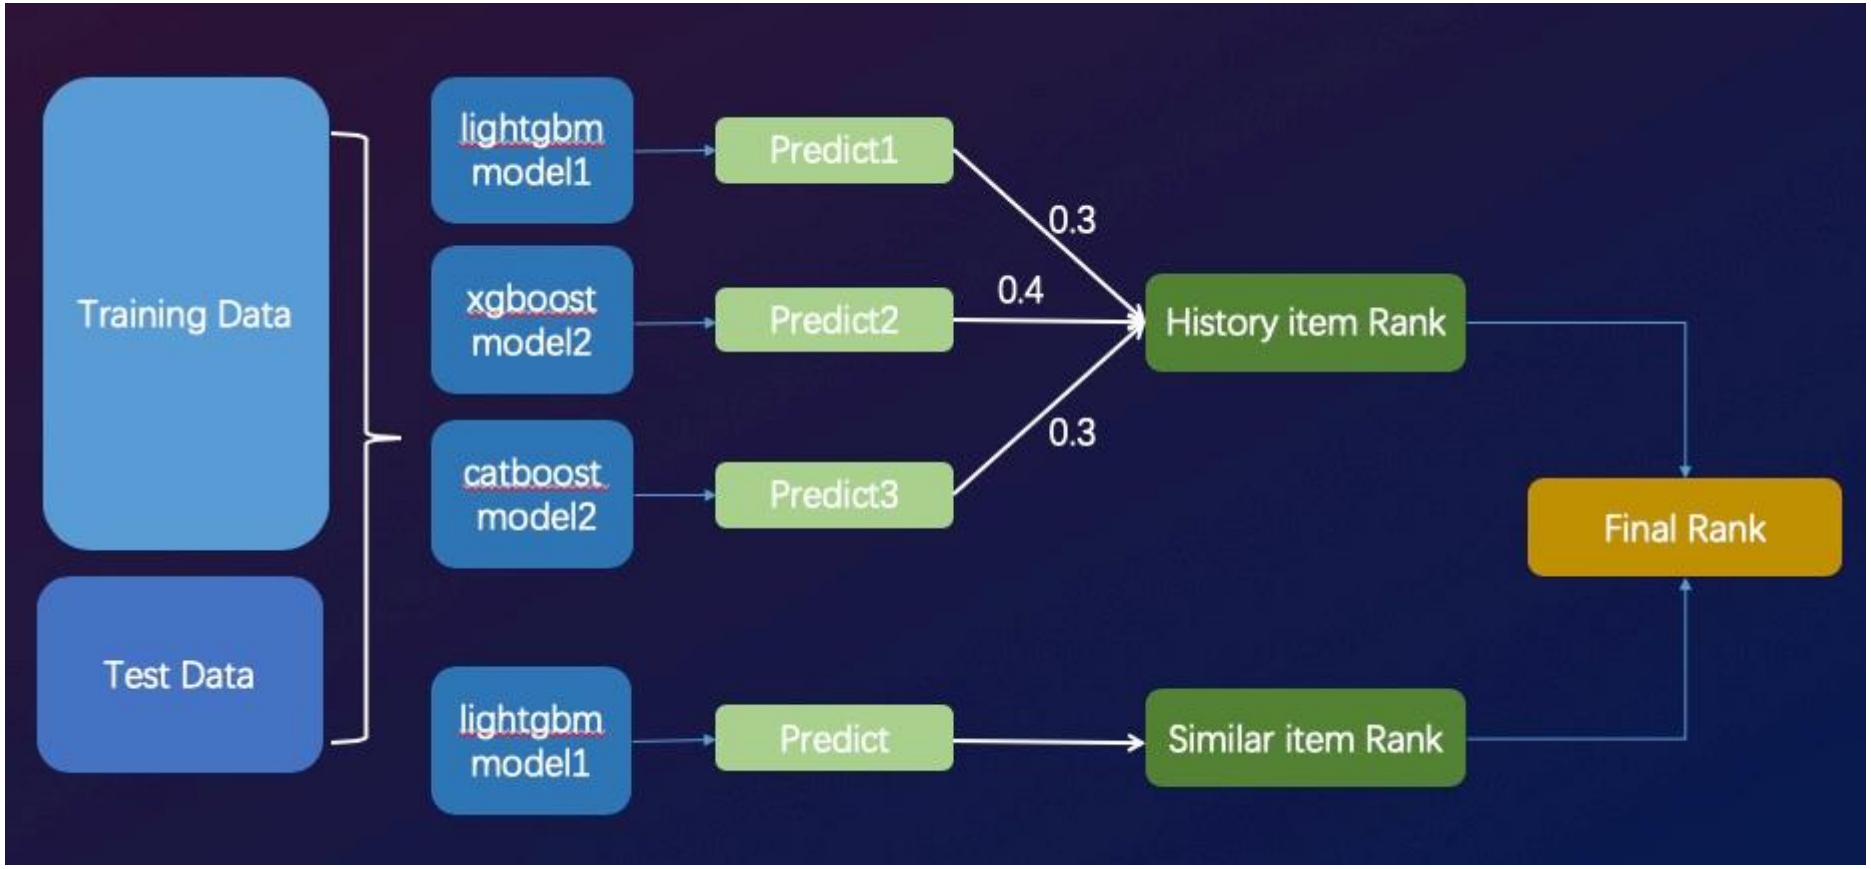
代码相关问题，请到Issues区进行留言

2019

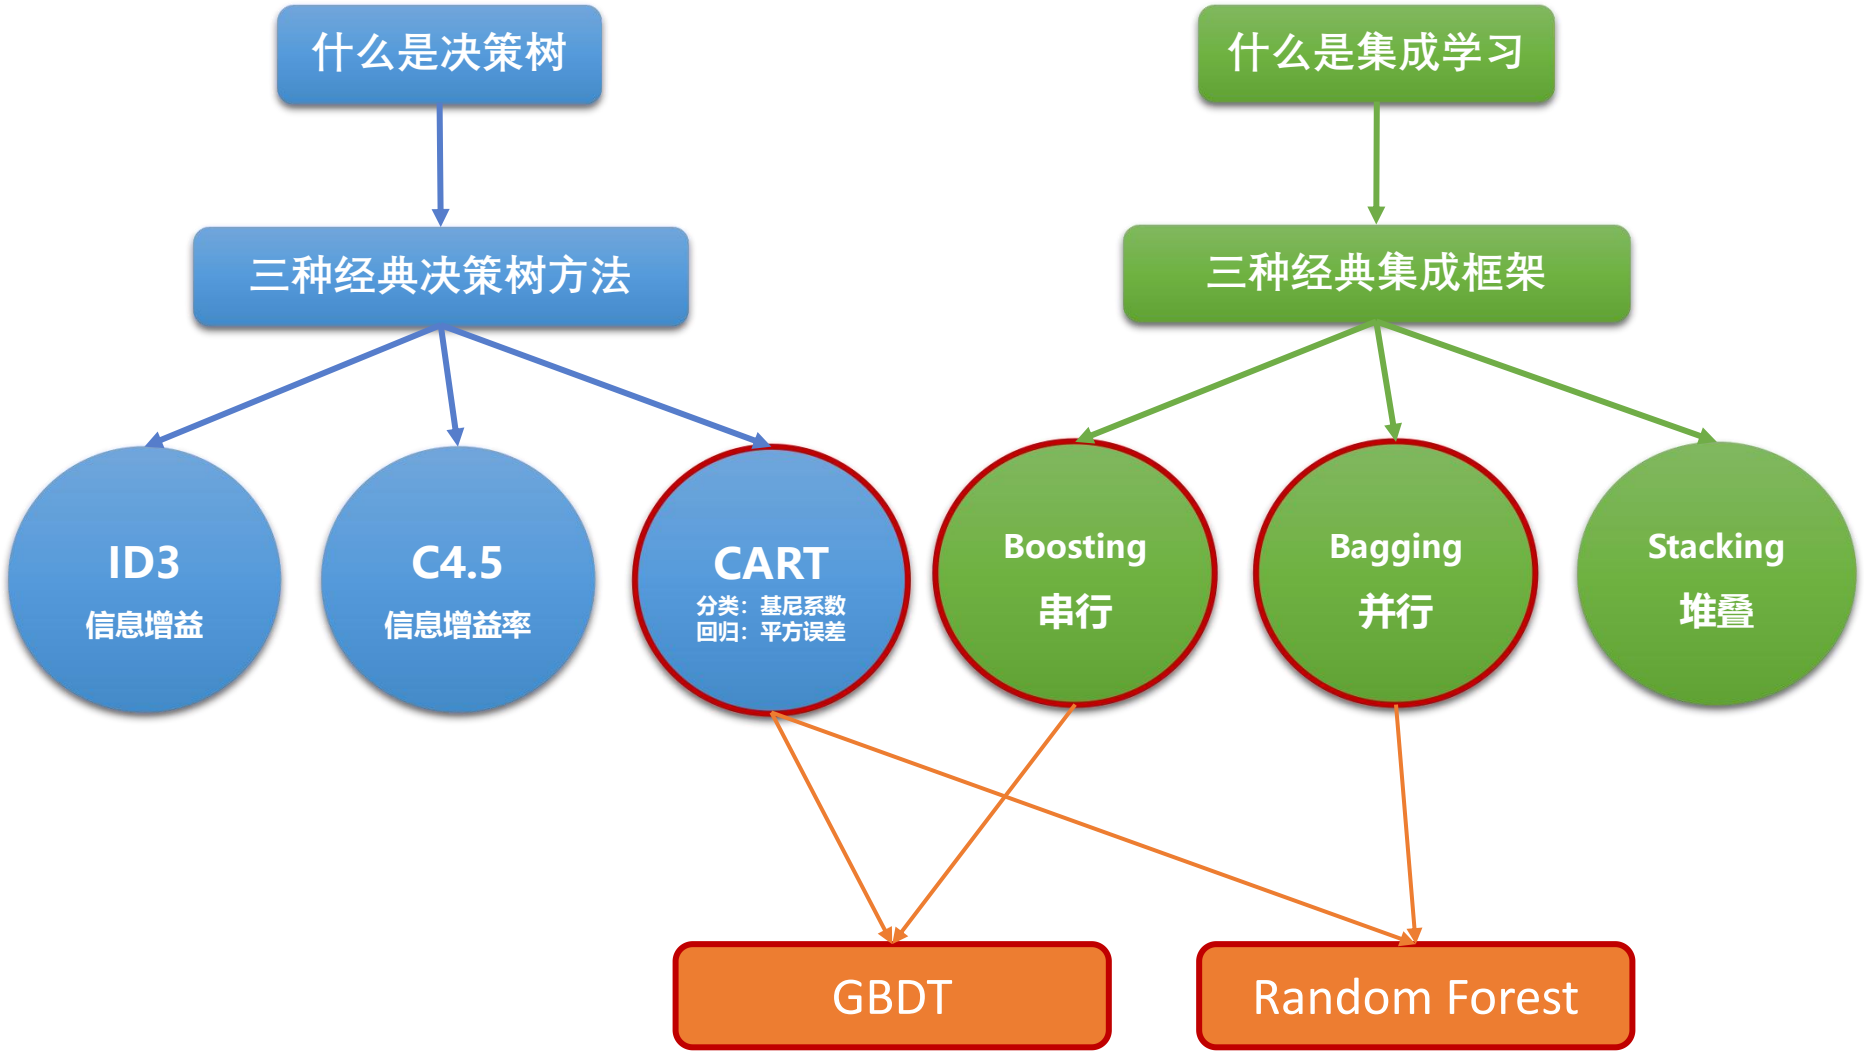
赛题

AliExpress是阿里巴巴海外购物网站，海外用户可以在AliExpress挑选购买自己心意的商品。AliExpress积累了大量的用户行为数据，本赛题旨在通过海量数据挖掘用户下一个可能交互商品，选手们可以提交预测的TOP30商品列表，排序越靠前命中得分越高。

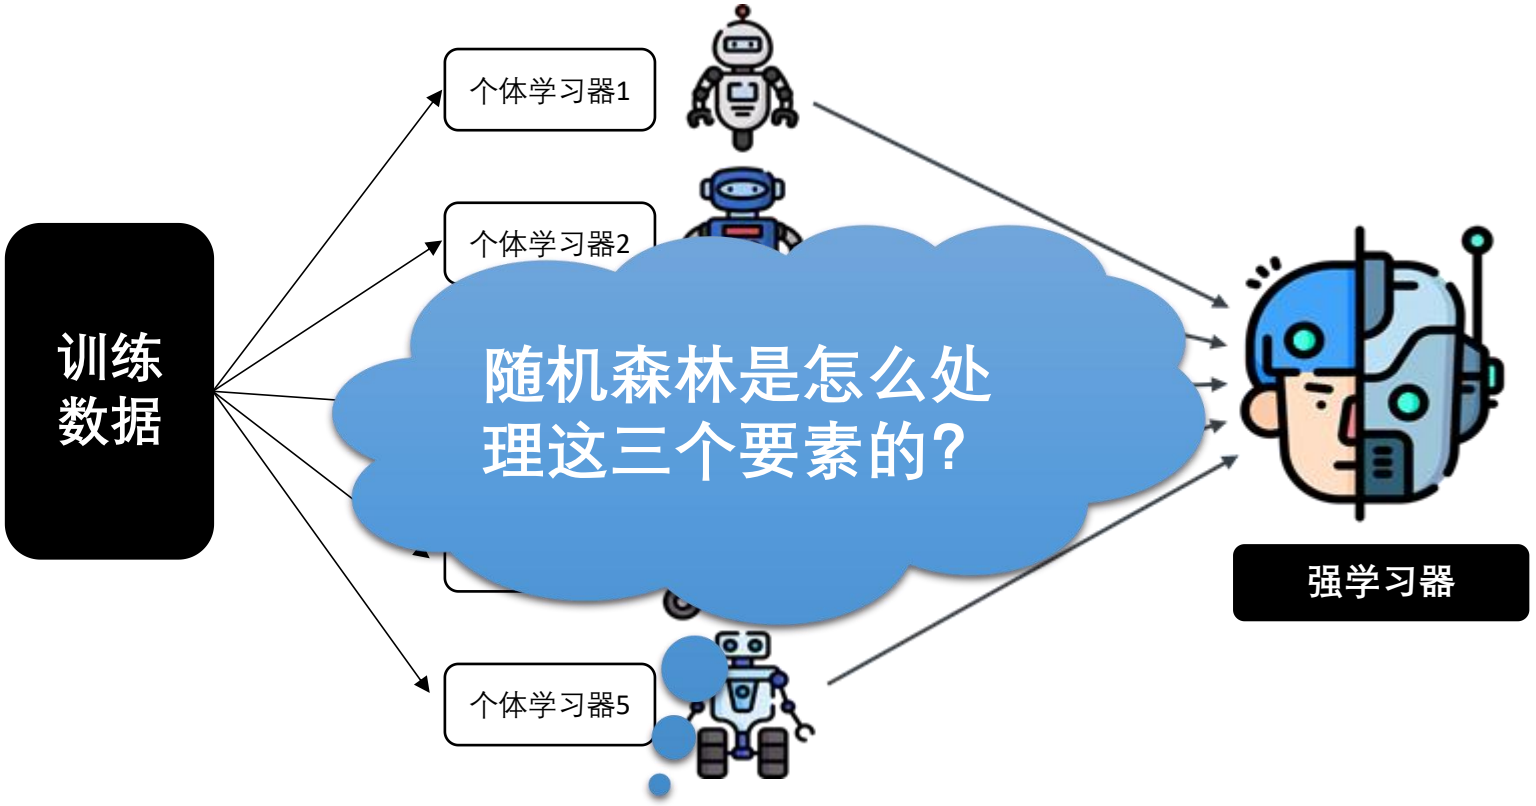
拓展


Training Data
Test Data
lightgbm model1
xgboost model2
catboost model2
lightgbm model1
Predict1
Predict2
Predict3
Predict
0.3
0.4
0.3
History item Rank
Similar item Rank
Final Rank

大纲


什么是决策树
三种经典决策树方法
ID3
信息增益
C4.5
信息增益率
CART
分类：基尼系数
回归：平方误差
什么是集成学习
三种经典集成框架
Boosting
串行
Bagging
并行
Stacking
堆叠
GBDT
Random Forest

集成学习是一个**学习框架**：“三个臭皮匠，顶个诸葛亮”



数据怎么用?

个体学习器怎么选?

最后怎么组合?

目标检测





考勤门禁

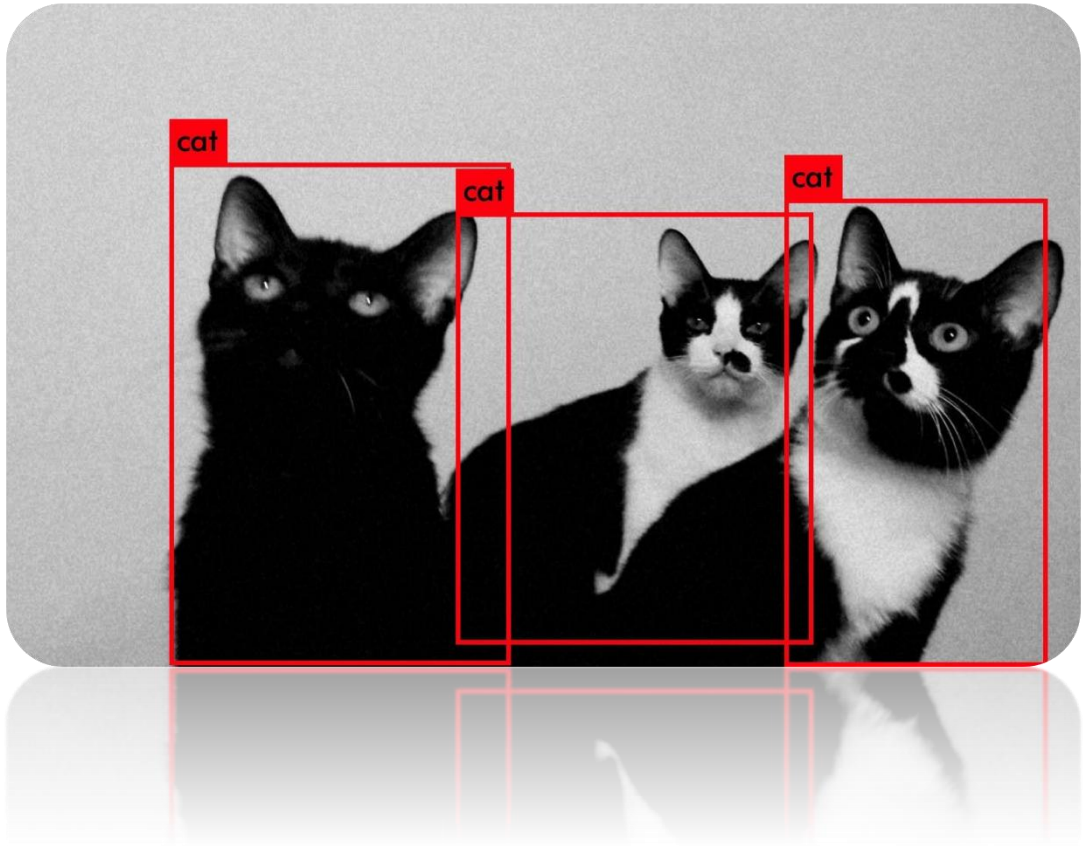


安防



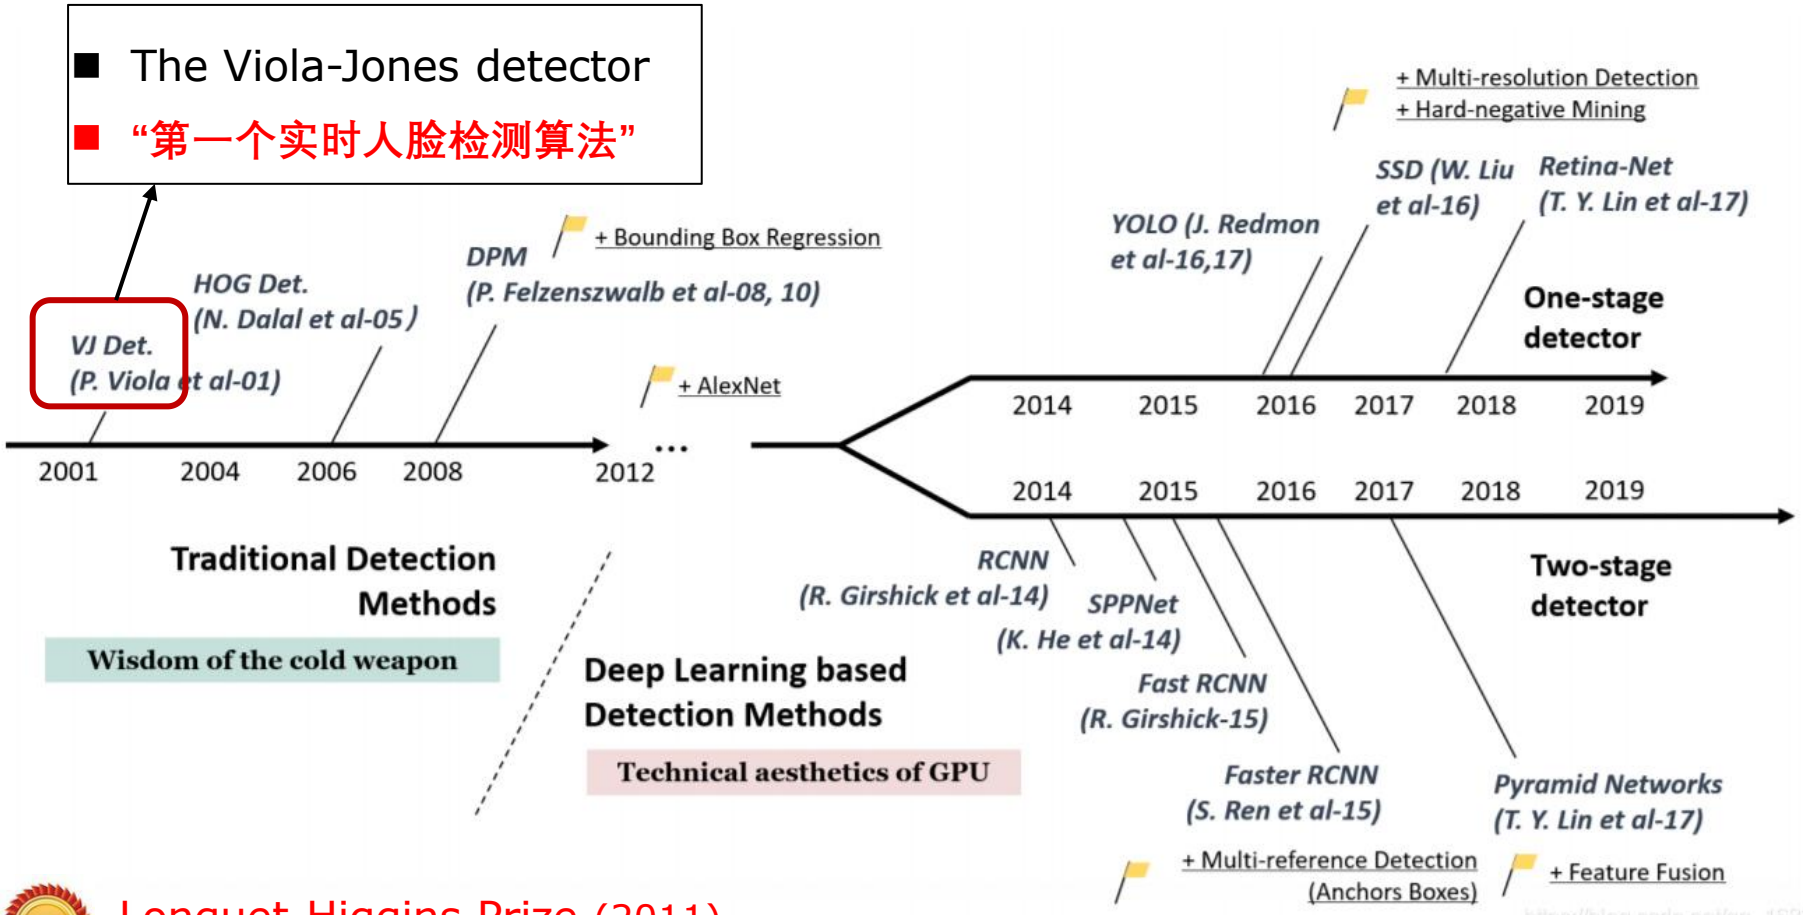
金融支付

目标检测



- 物体定位
- 物体分类

目标检测



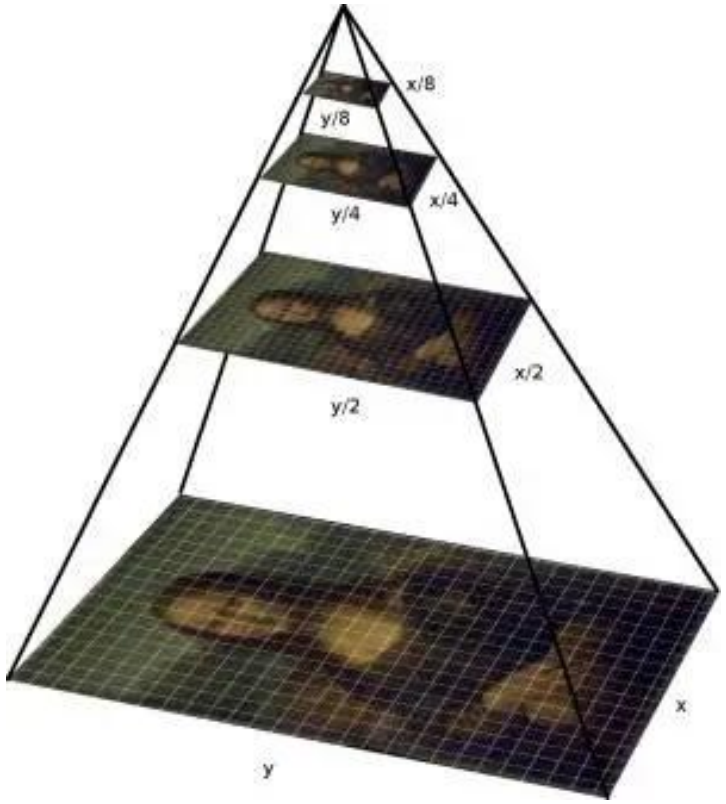
Longuet-Higgins Prize (2011)

Viola & Jones, Rapid object detection using a Boosted cascade of simple features. CVPR, 2001.

人脸检测

滑动窗口：





人脸检测



二分类



否



是

核心任务：判断每个窗口下的子图是否为人脸

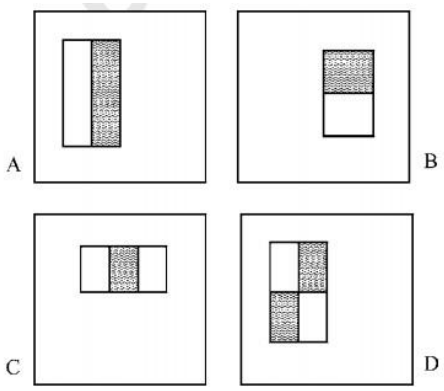
Viola-Jones Detector

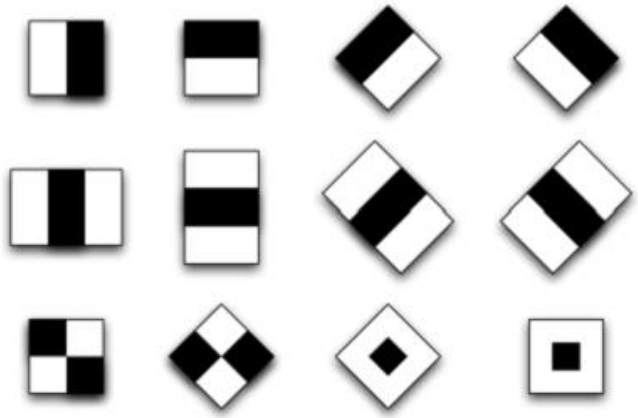
（人脸检测）

- 积分图（Haar特征提取）
- Adaboost（分类+特征选择）
- 级联结构(加速)

积分图（Haar特征提取）

Haar特征原型 --------· 平移、伸缩 ----------→ 矩形特征





特征值计算：白色-黑色

方法：积分图

Original

5	2	3	4	1
1	**5**	**4**	**2**	3
2	**2**	**1**	**3**	4
3	5	6	4	5
4	1	3	2	6

$5+4+2+2+1+3=17$

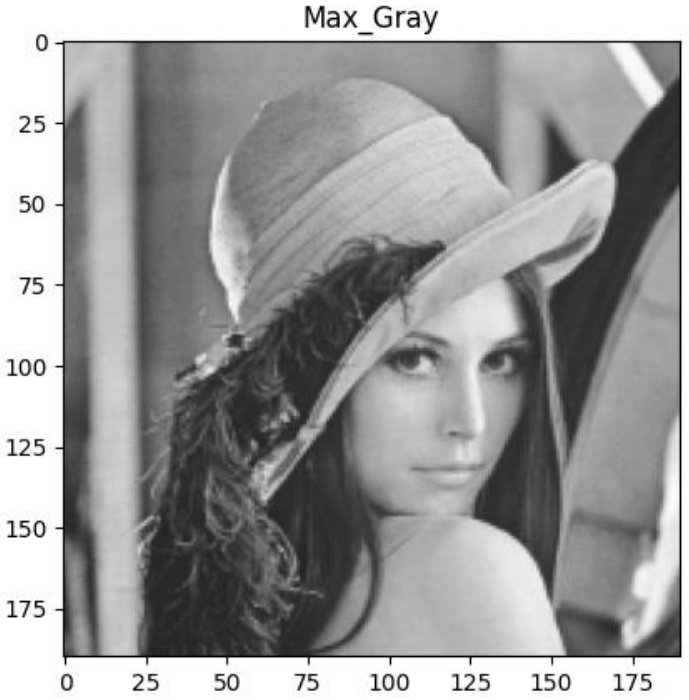
Integral

5	7	10	**14**	15
6	13	20	26	30
8	17	25	**34**	42
11	25	39	52	65
15	30	47	62	81

$34-14-8+5=17$

积分图（Haar特征提取）

Haar特征原型 --------· 平移、伸缩 ----------→ 矩形特征



24*24的灰度图，
有16w个特征值

Viola-Jones Detector

（人脸检测）

- 积分图（Haar特征提取）
- Adaboost（分类+特征选择）
- 级联结构(加速)



→

16w个特征
（数值）

Adaboost（分类+特征选择）

Adaboost:

① 初始化样本权重（等权重）

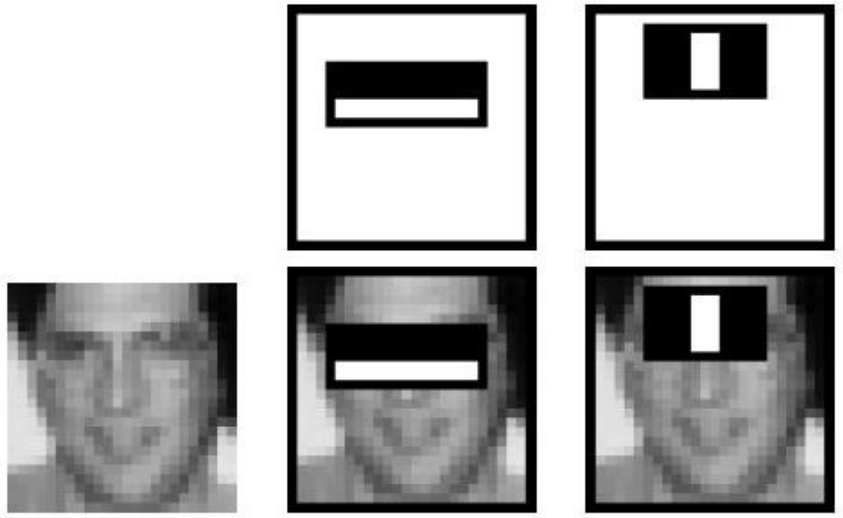
② **对16w特征中的每个特征构建分类器，选择误差最小的特征和分类器**

③ 根据分类器误差调整样本权重

④ 重复上述过程

⑤ 最终的分类器：加权投票

$$h_j(x) = \begin{cases} 1 & \text{if } p_j f_j(x) < p_j \theta_j \\ 0 & \text{otherwise} \end{cases}$$



Adaboost选出的前两名特征

Viola-Jones Detector

（人脸检测）

- 积分图（Haar特征提取）
- Adaboost（分类+特征选择）
- 级联结构(加速)



→ **16w个特征（数值）** →

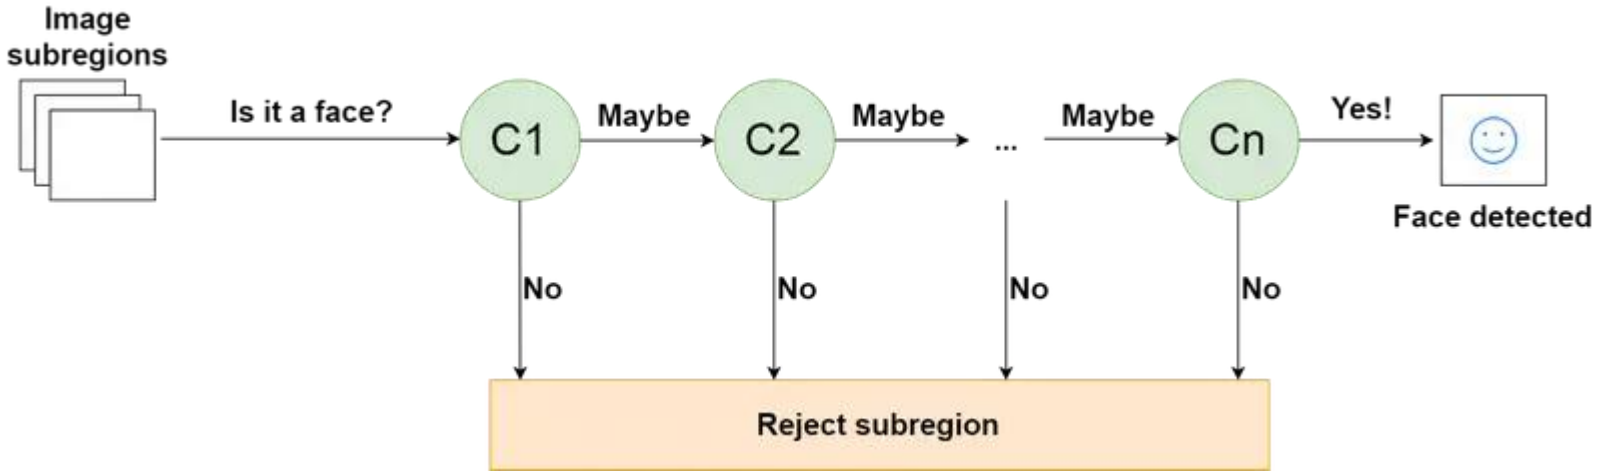
Adaboost分类

基分类器：一个特征构成的决策树桩

级联结构(加速)

滑动窗口：
一系列24*24的子图

最终结构：38级，6k多特征



在一个包含507张人脸和7500万个子窗口的数据集上，每个子窗口平均使用10次特征评估来检测人脸。

0.067s处理一张384*288的图片

级联结构(加速)

层数	每层弱分类器数	累计弱分类器数
1	1	1
2	10	11
3	25	36
4	25	61
...	...	...
38	213	**~6000**

- 检测率>99.5%
- 误检率<50%

$$F = (0.5)^N < 10^{-6} \Rightarrow N > \log_{0.5}(10^{-6}) \approx 20$$

Viola-Jones Detector

（人脸检测）

- 积分图（Haar特征提取）
- Adaboost（分类+特征选择）
- 级联结构(加速)



→ **16w个特征（数值）** → **Adaboost分类**

基分类器：一个特征构成的决策树桩

→ **级联结构加速**

Viola-Jones Detector

（人脸检测）

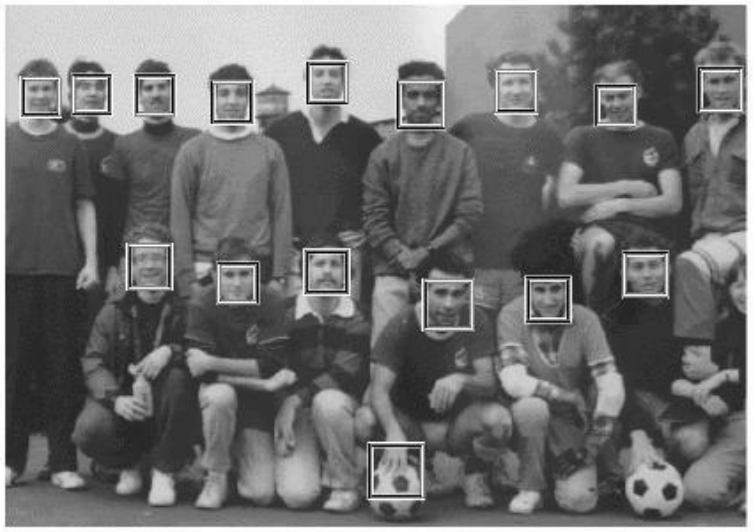
- 积分图（Haar特征提取）
- Adaboost（分类+特征选择）
- 级联结构(加速)

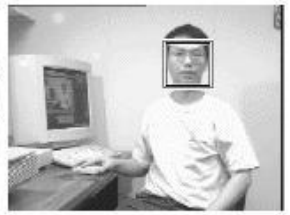
- ✓ *NMS*（非极大值抑制）
- ✓ 平均坐标
- ✓ 加权平均

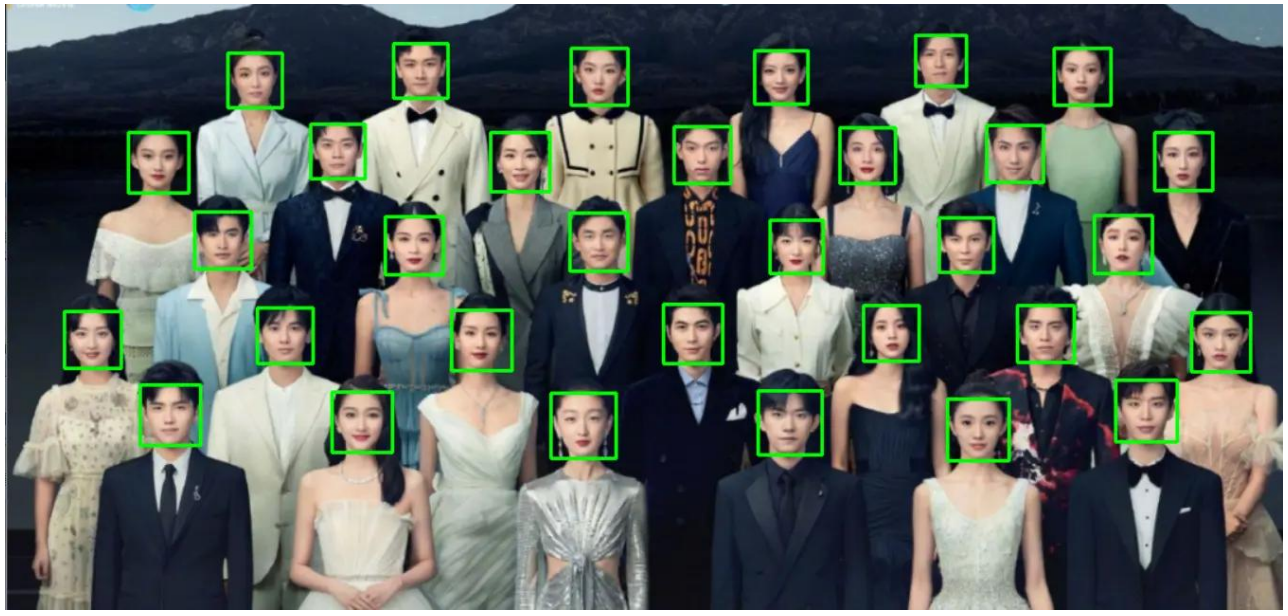


拓展









拓展


cs341 sample video
face detection
Viola-Jones method
00:53 / 00:56
发个友善的弹幕见证当 弹幕礼仪 >
发送
720P 高清
倍速


谢 谢
首都师范大学
CAPITAL NORMAL UNIVERSITY