首都师范大学
CAPITAL NORMAL UNIVERSITY

首都师范大学
CAPITAL NORMAL UNIVERSITY



第十四课 生成模型

授课教师：潘贤丽

AIGC(AI Generated Content):

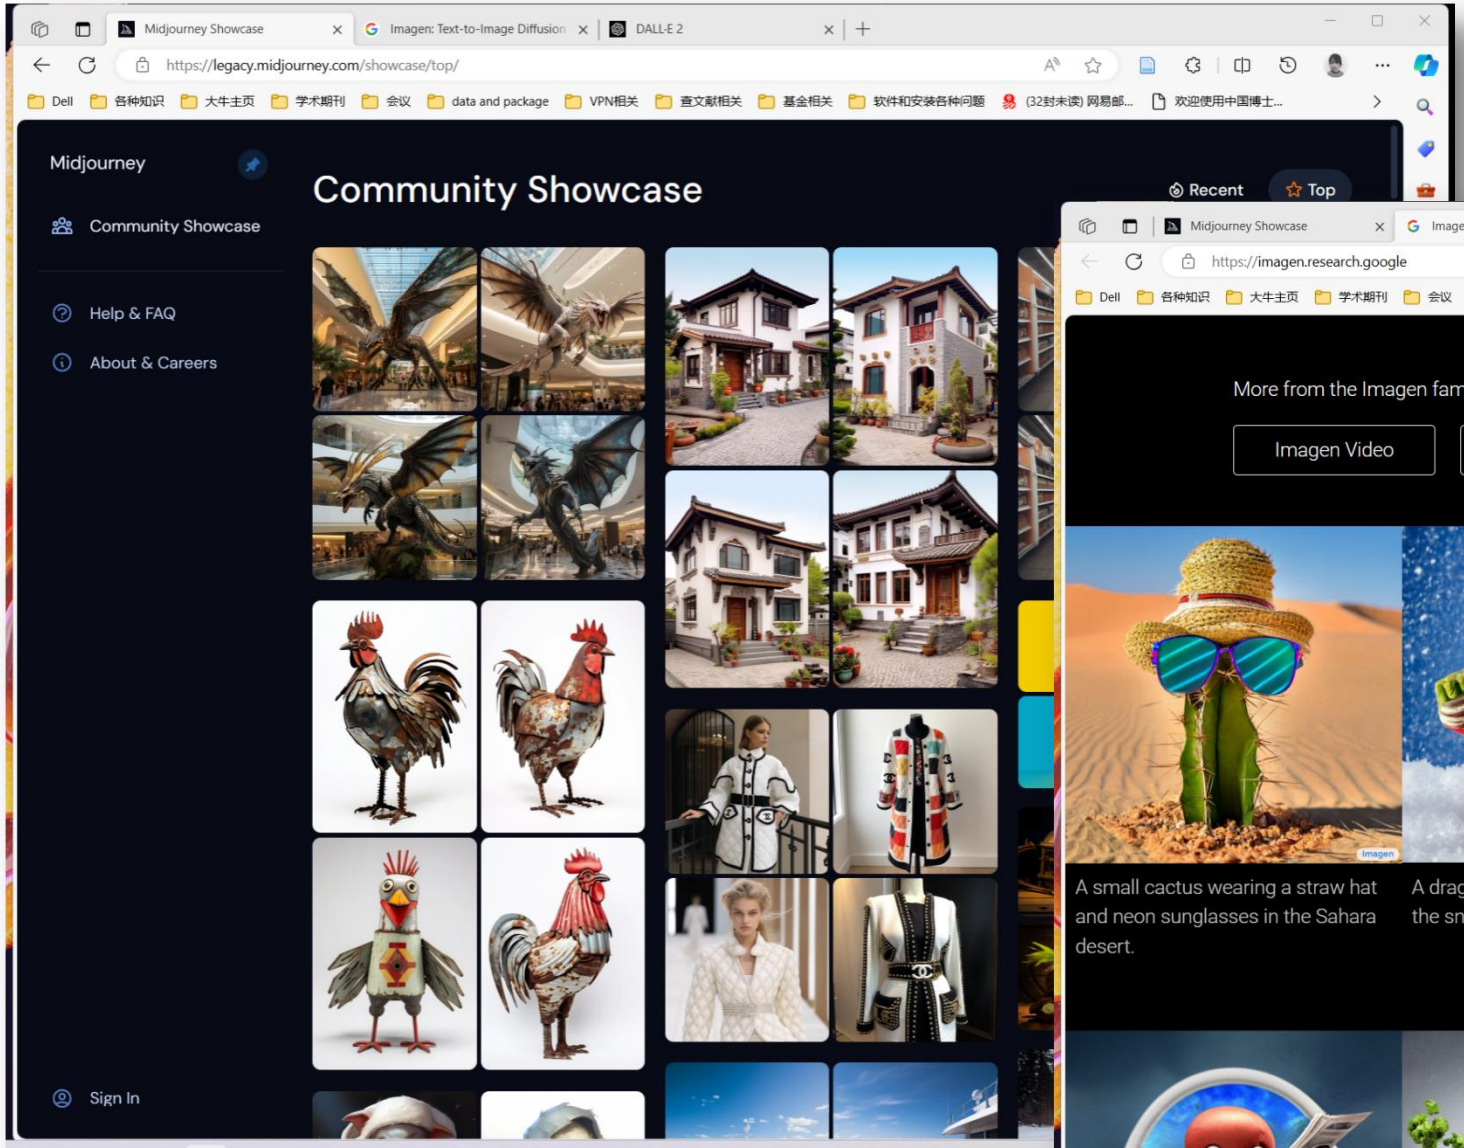
核心：文本、音频、图像、视频、代码等之间的相互转化

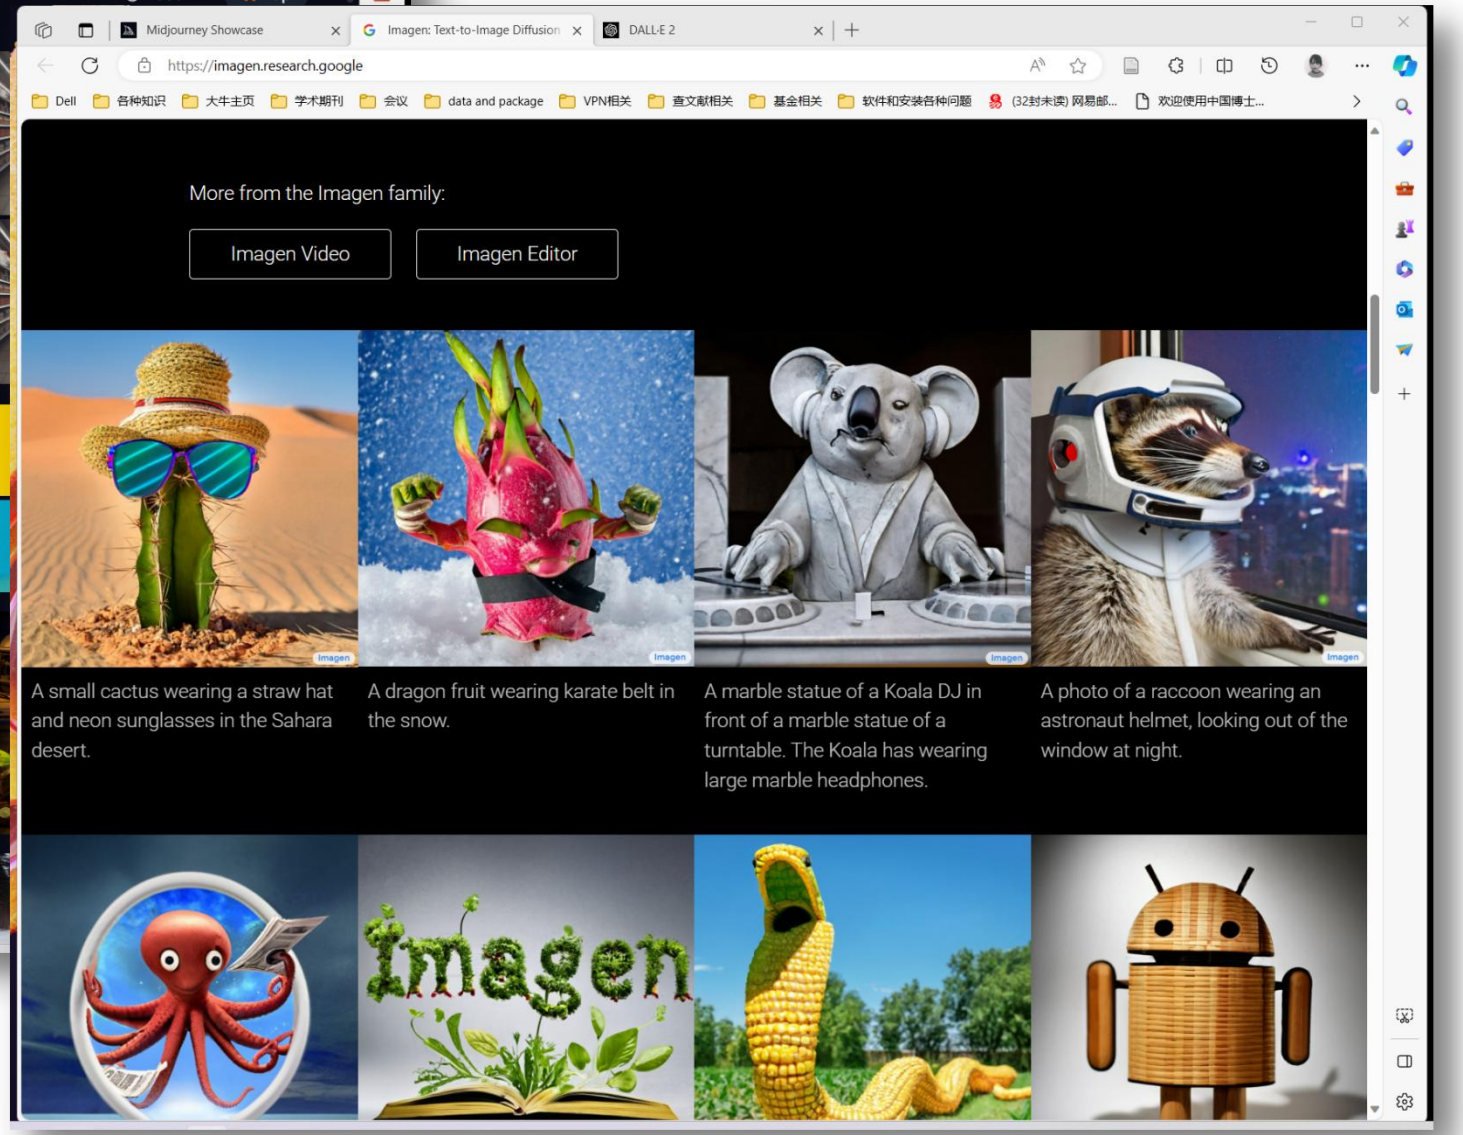
自然语言处理

计算机视觉

多模态学习




Midjourney Showcase
Imagen: Text-to-Image Diffusion
DALL·E 2
https://legacy.midjourney.com/showcase/top/
Midjourney
Community Showcase
Help & FAQ
About & Careers
Sign In
Community Showcase
Recent
Top


Midjourney Showcase
Imagen: Text-to-Image Diffusion
DALL·E 2
https://imagen.research.google
More from the Imagen family:
Imagen Video
Imagen Editor
A small cactus wearing a straw hat and neon sunglasses in the Sahara desert.
A dragon fruit wearing karate belt in the snow.
A marble statue of a Koala DJ in front of a marble statue of a turntable. The Koala has wearing large marble headphones.
A photo of a raccoon wearing an astronaut helmet, looking out of the window at night.
imagen

Midjourney Showcase | Imagen: Text-to-Image Diffu | DALL·E 3 | ChatGPT | dall-e-3.pdf

https://openai.com/dall-e-3

Dell 各种知识 大牛主页 学术期刊 会议 data and package VPN相关 查文献相关 基金相关 软件和安装各种问题 (32封未读) 网易邮... 欢迎使用中国博士...

OpenAI Research API ChatGPT Safety Company Search Log in Try ChatGPT

Research

DALL·E 3

DALL·E 3 understands significantly more nuance and detail than our previous systems, allowing you to easily translate your ideas into exceptionally accurate images.

Read research paper Try in ChatGPT



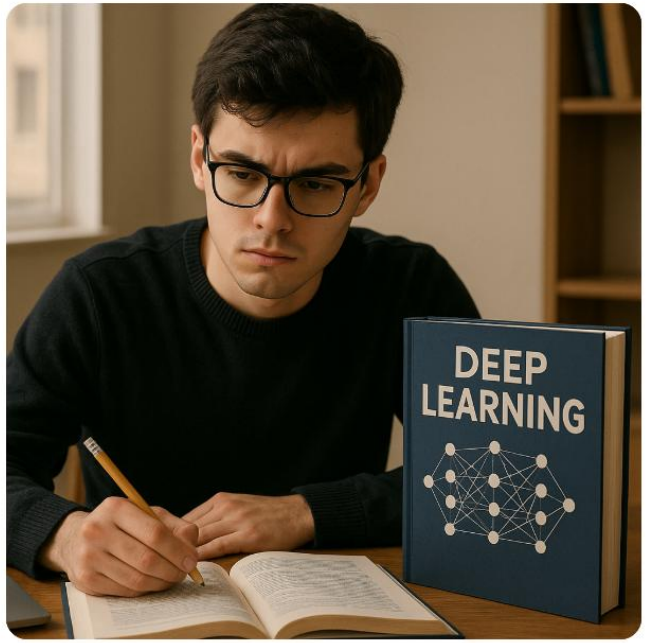
About DALL·E 3

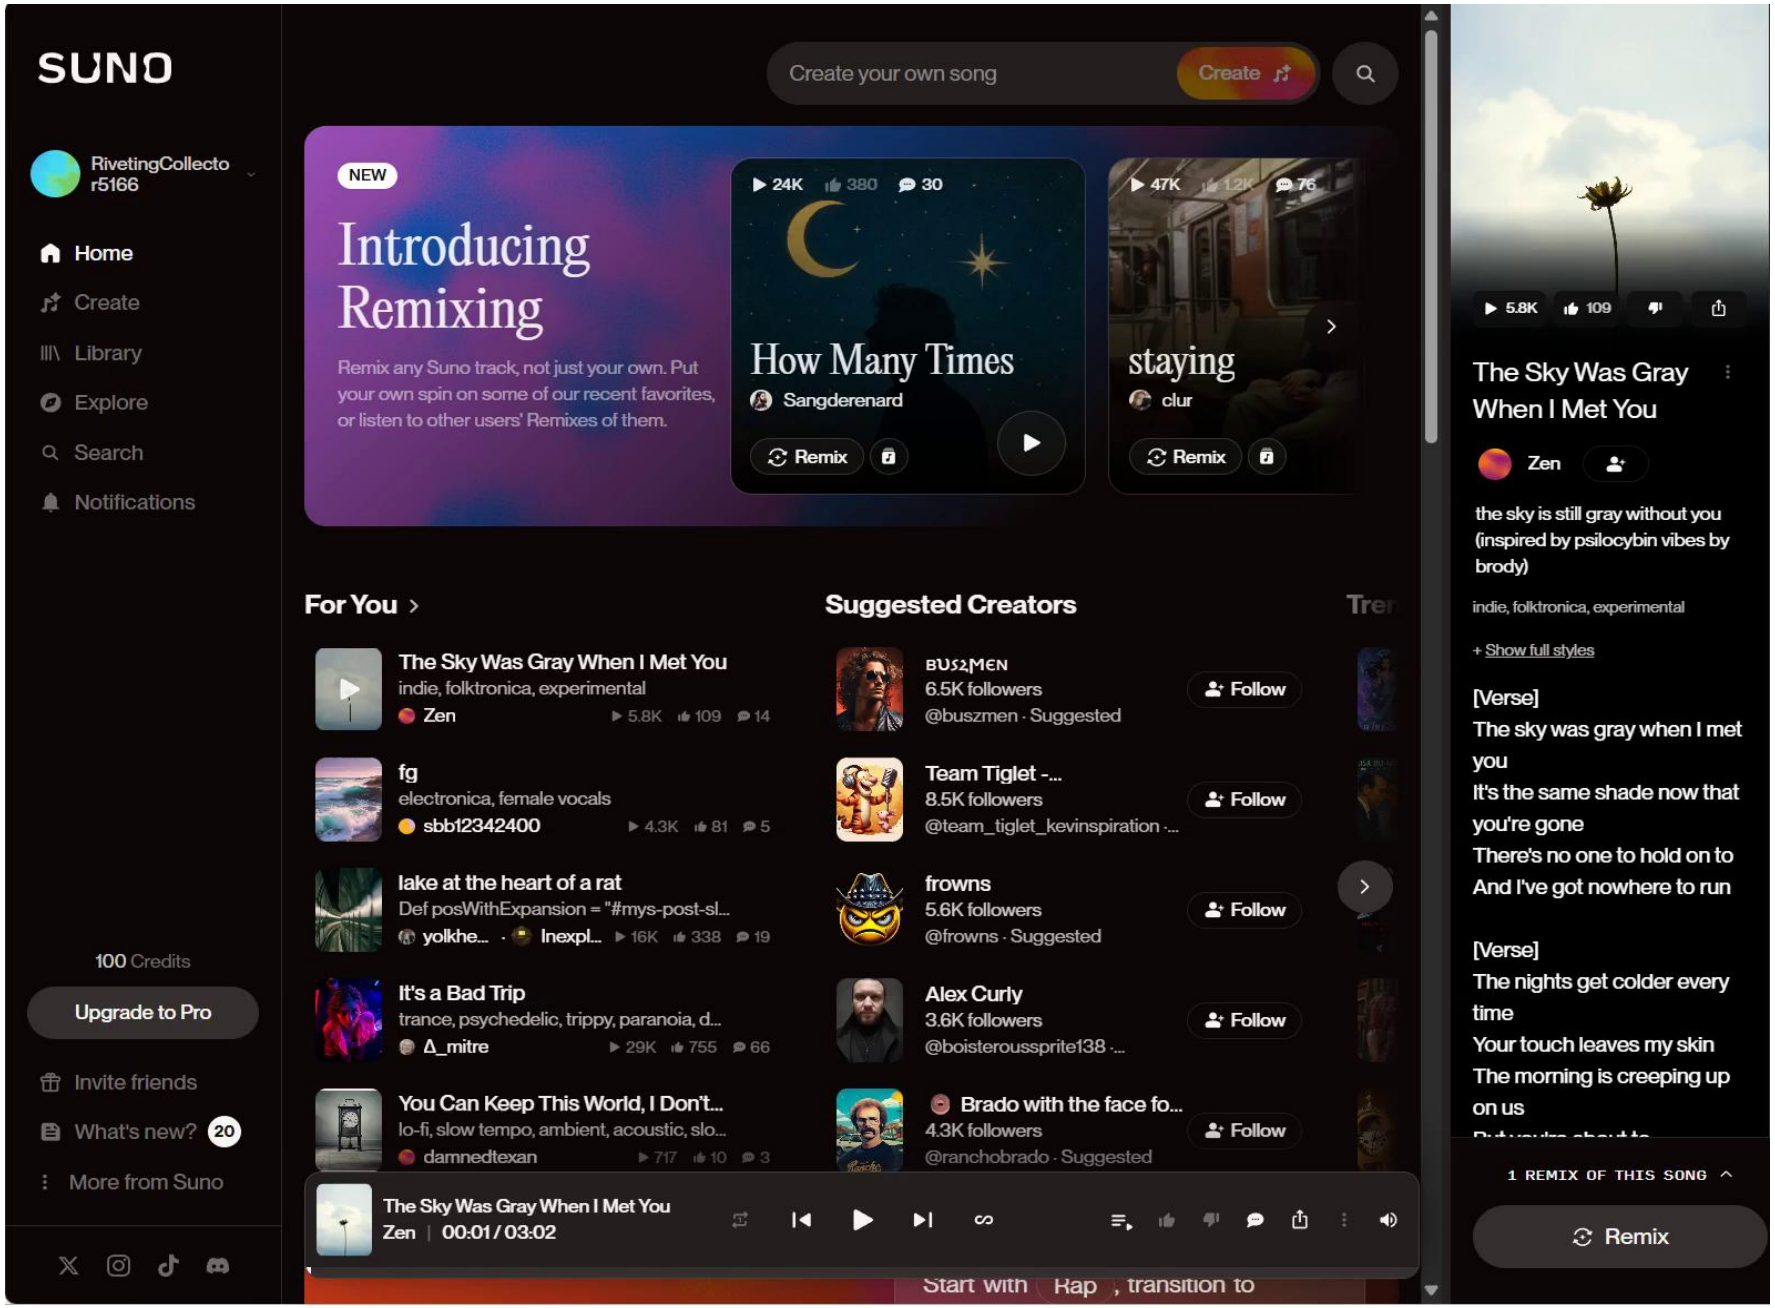
DALL·E 3 is now available to all ChatGPT Plus and Enterprise users, and will be available via the API and in Labs later this fall.

Modern text-to-image systems have a tendency to ignore words or

帮我生成一个戴着黑框眼镜，认真学习深度学习的研究生的形象

图片已创建





首都师范大学
CAPITAL NORMAL UNIVERSITY

Suno | AI Music


AIGC工作室
bilibili

AIGC短片《0.99》｜当AI介入率达到99% 哔哩哔哩 bilibili

生成模型

概率分布$p(x)$

↓

样本x

Python 示例（使用 NumPy）：

```python
import numpy as np

mu = 0          # 均值
sigma = 1       # 标准差
samples = np.random.normal(loc=mu, scale=sigma, size=1000)
```

$N(mu, sigma)$



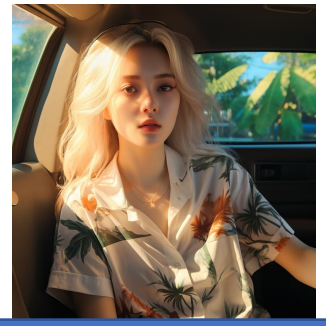
概率分布$p(x)$



样本x



概率分布$p(x)$



样本x

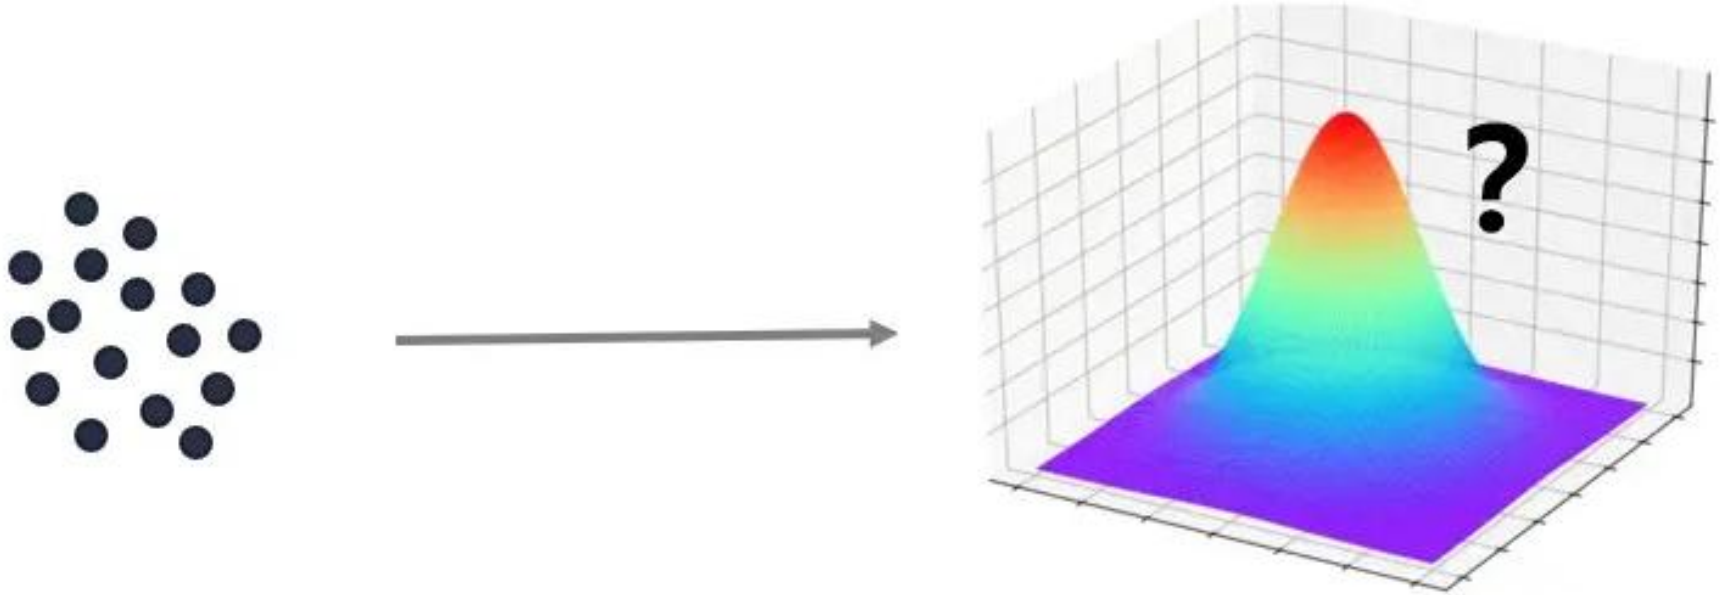


概率分布$p(x)$

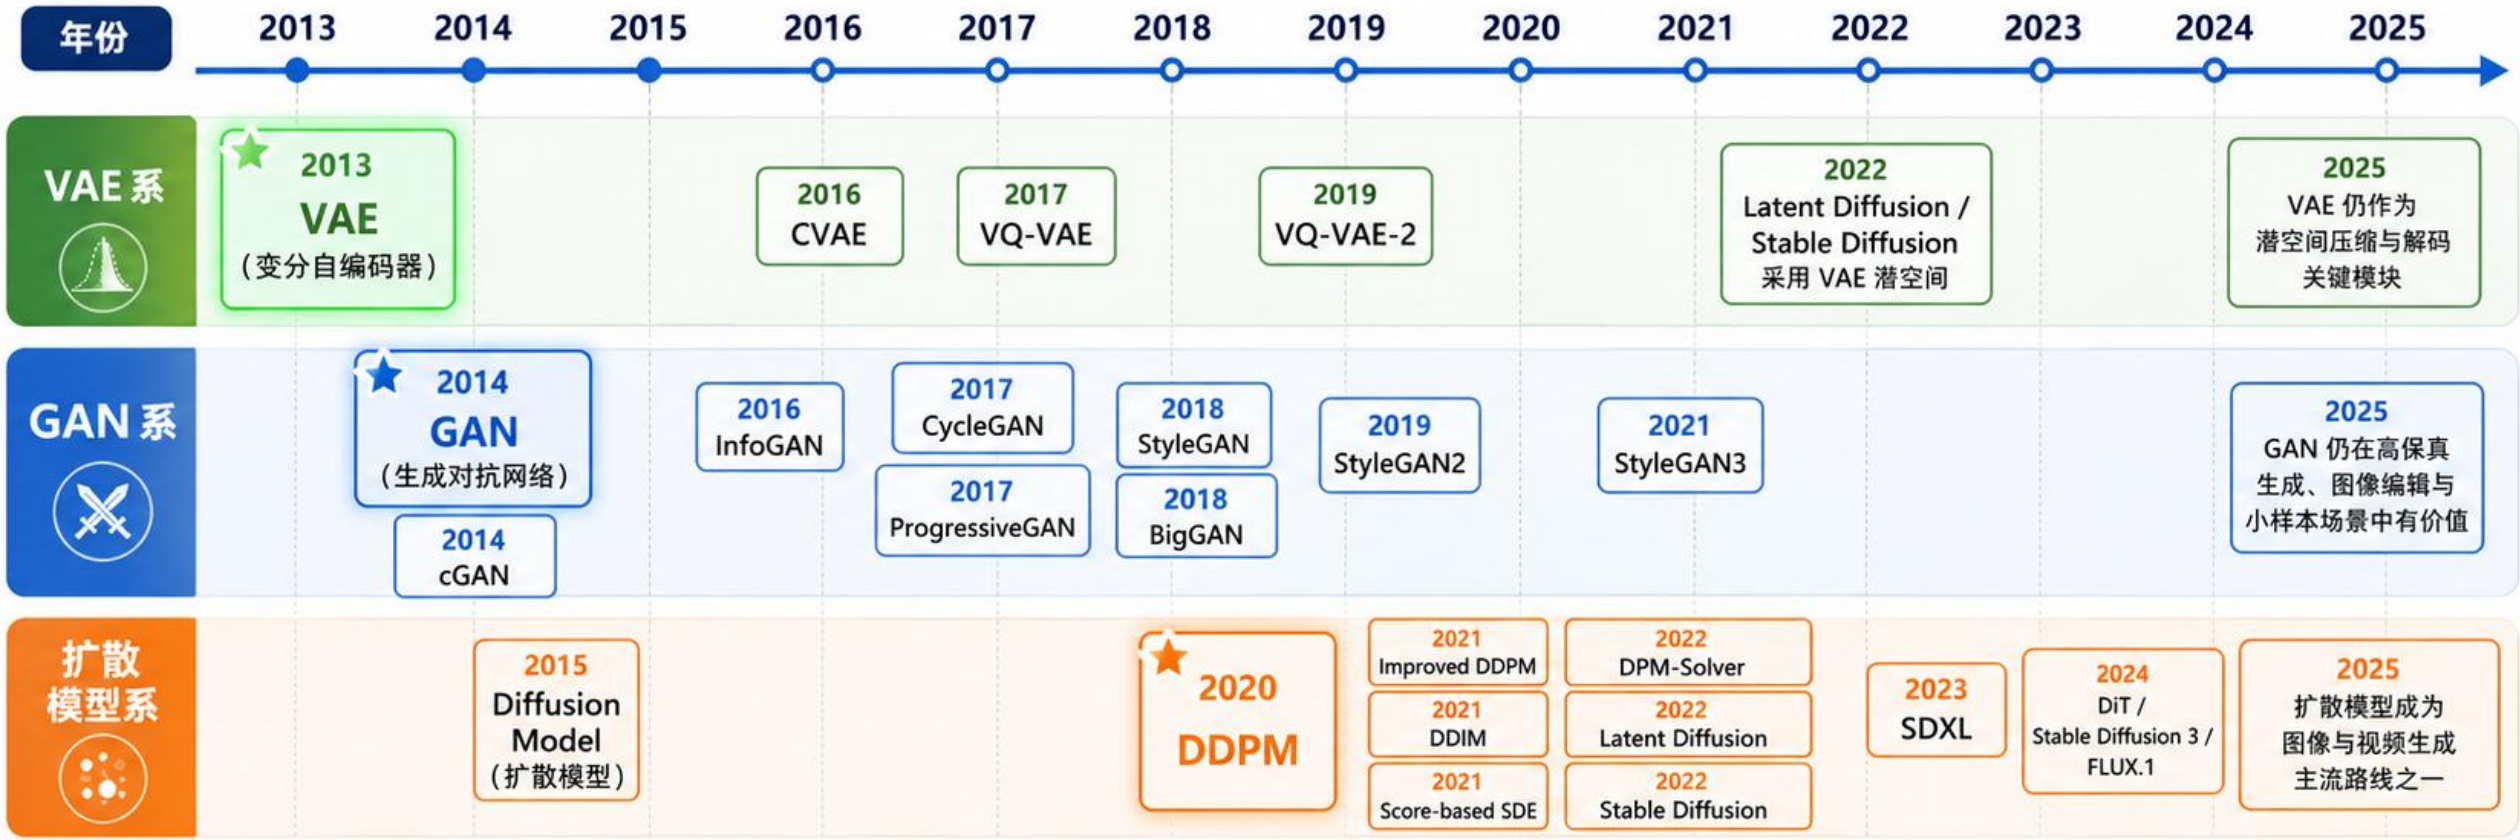


样本x

生成模型



生成模型发展史：


年份
2013
2014
2015
2016
2017
2018
2019
2020
2021
2022
2023
2024
2025
VAE 系
2013
VAE
（变分自编码器）
2016
CVAE
2017
VQ-VAE
2019
VQ-VAE-2
2022
Latent Diffusion /
Stable Diffusion
采用 VAE 潜空间
2025
VAE 仍作为
潜空间压缩与解码
关键模块
GAN 系
2014
GAN
（生成对抗网络）
2014
cGAN
2016
InfoGAN
2017
CycleGAN
2017
ProgressiveGAN
2018
StyleGAN
2018
BigGAN
2019
StyleGAN2
2021
StyleGAN3
2025
GAN 仍在高保真
生成、图像编辑与
小样本场景中有价值
扩散
模型系
2015
Diffusion
Model
（扩散模型）
2020
DDPM
2021
Improved DDPM
2021
DDIM
2021
Score-based SDE
2022
DPM-Solver
2022
Latent Diffusion
2022
Stable Diffusion
2023
SDXL
2024
DiT /
Stable Diffusion 3 /
FLUX.1
2025
扩散模型成为
图像与视频生成
主流路线之一

目录:

- GAN
- VAE
- DDPM

Generative adversarial nets

I Goodfellow, J Pouget-Abadie... - Advances in neural ..., 2014 - proceedings.neurips.cc

... We propose a new framework for estimating generative models via an adversarial process, in which we simultaneously train two models: a generative model G that captures the data ...

☆ 保存 99 引用 被引用次数：62499 相关文章 所有 61 个版本 »

Auto-encoding variational bayes

DP Kingma, M Welling - arXiv preprint arXiv:1312.6114, 2013 - arxiv.org

... variational lower bound yields a simple differentiable unbiased estimator of the lower bound; this SGVB (Stochastic Gradient Variational Bayes... , we propose the AutoEncoding VB (AEVB...

☆ 保存 99 引用 被引用次数：31270 相关文章 所有 44 个版本 »

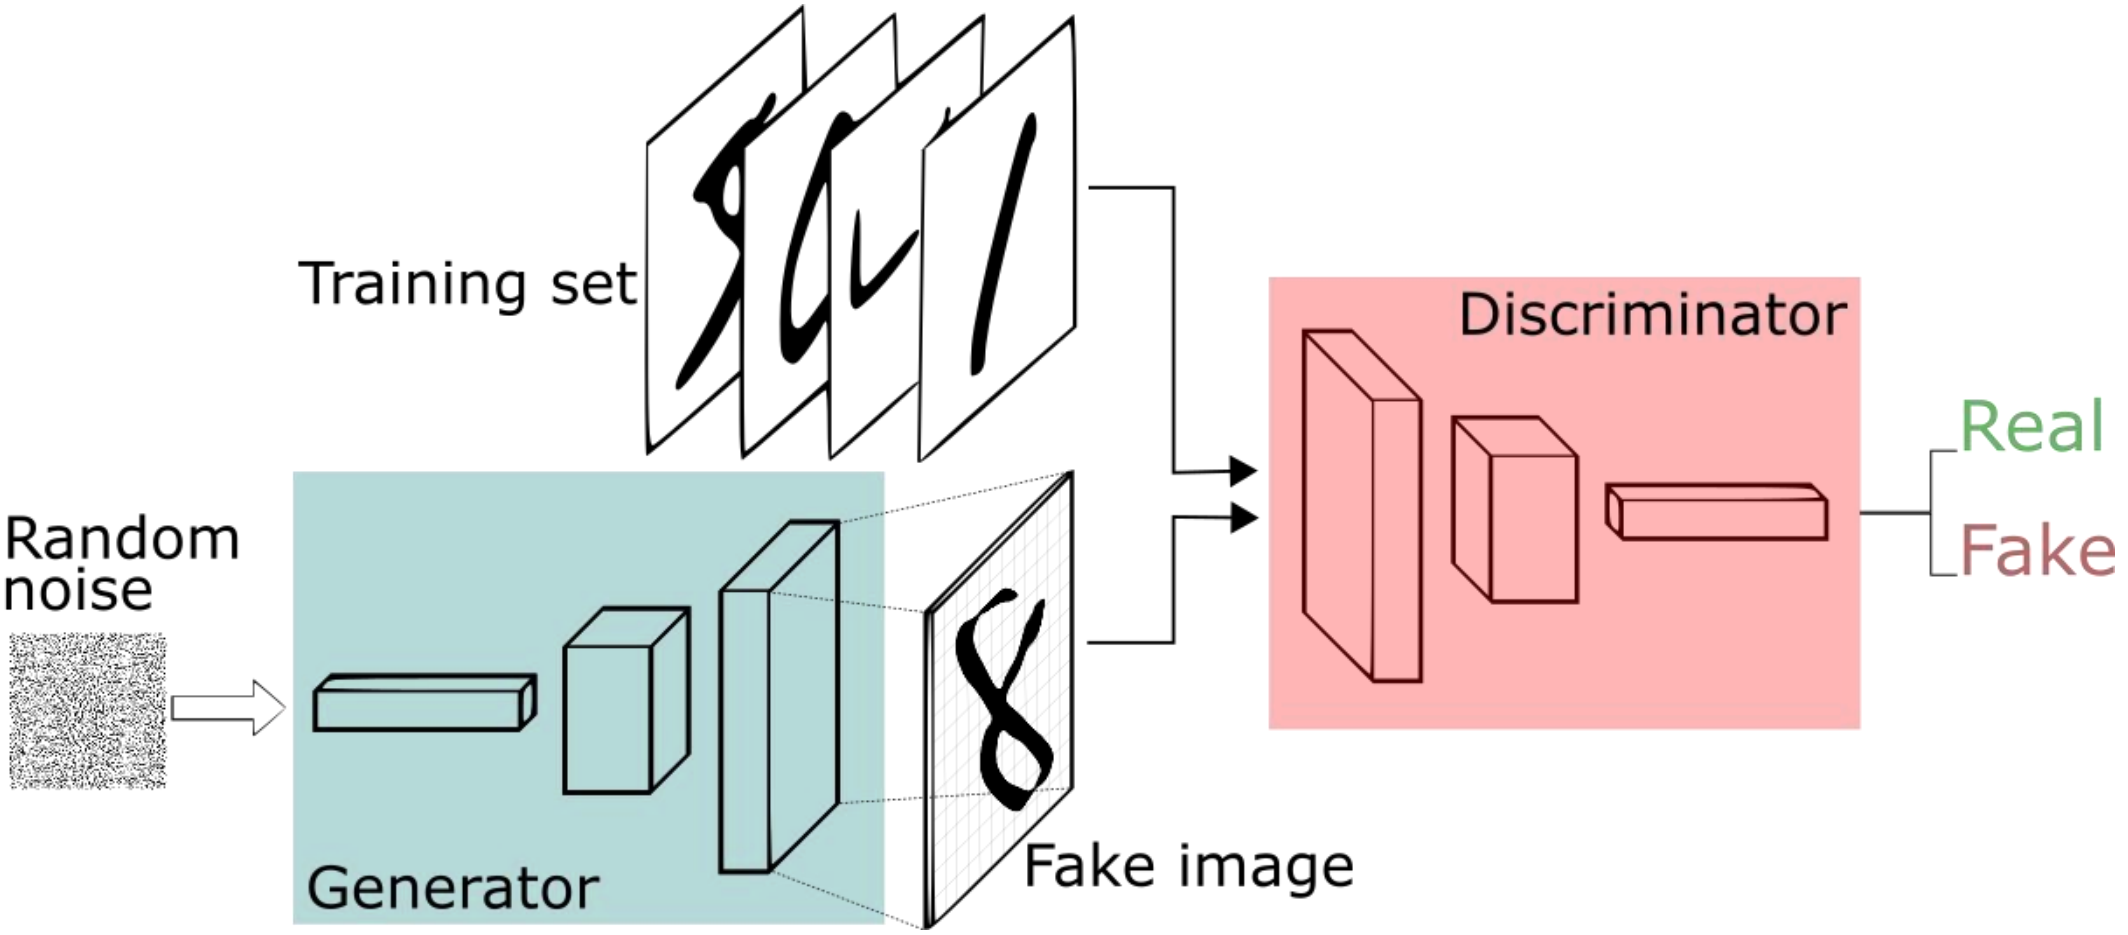
Denoising diffusion probabilistic models

J Ho, A Jain, P Abbeel - Advances in neural information ..., 2020 - proceedings.neurips.cc

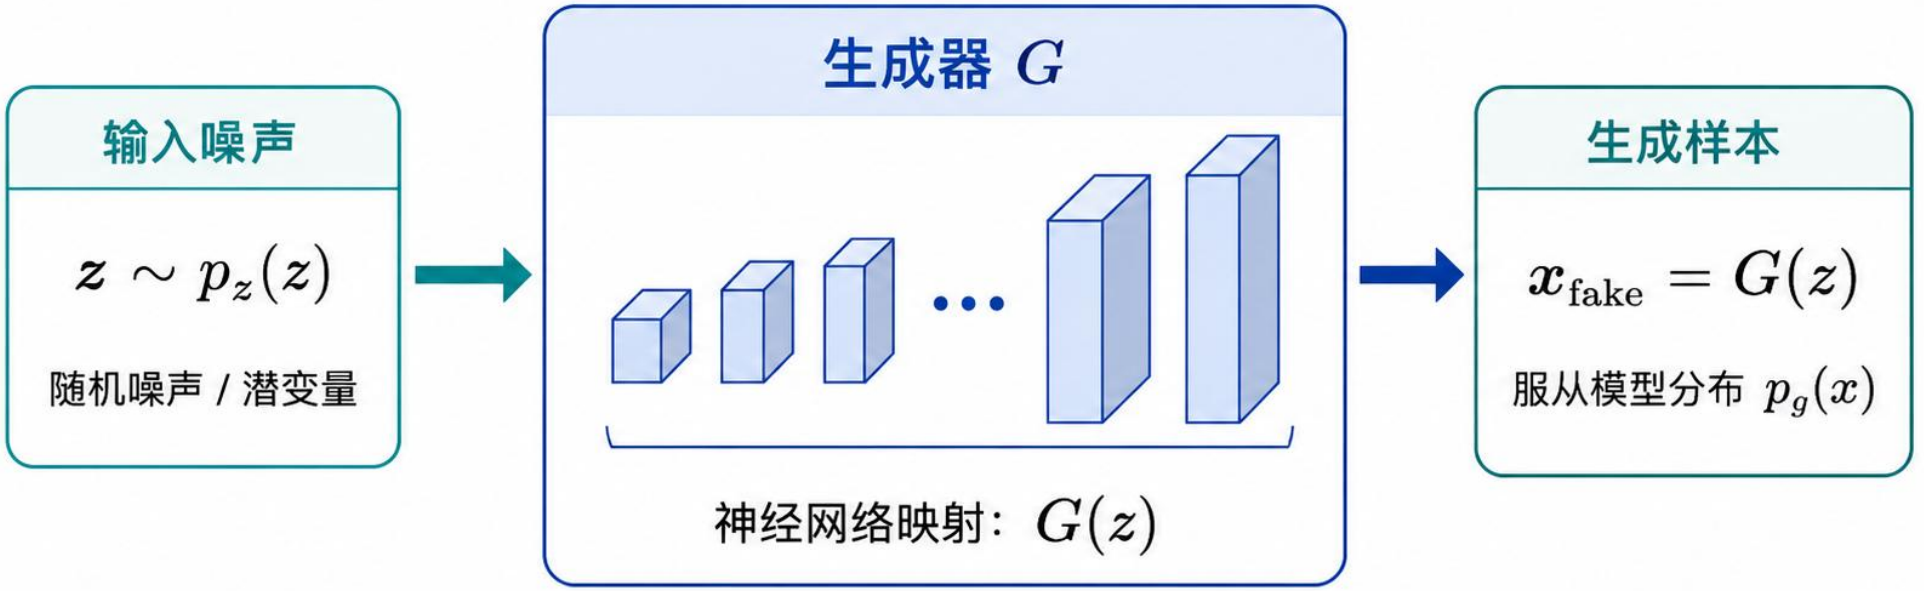
... This paper presents progress in diffusion probabilistic models [53]. A diffusion probabilistic model (which we will call a "diffusion model" for brevity) is a parameterized Markov chain ...

☆ 保存 99 引用 被引用次数：4893 相关文章 所有 6 个版本 »

GAN:


Training set
Random noise
Generator
Fake image
Discriminator
Real
Fake

GAN:



作用：把随机噪声映射为尽可能逼真的样本

输入：z | 输出：x_{fake}

GAN:

真实样本

$x \sim p_{\text{data}}(x)$

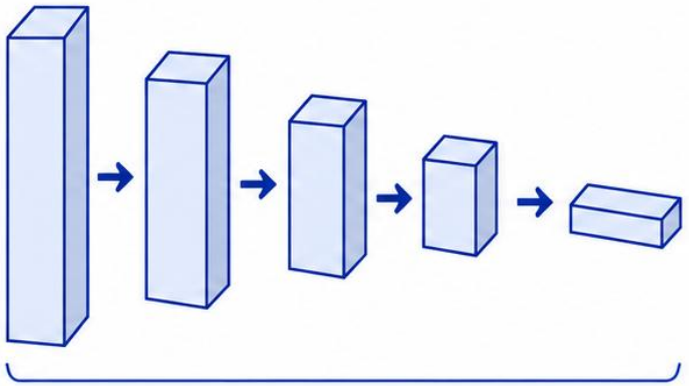
来自真实数据分布

生成样本

$x_{\text{fake}} = G(z)$

其中 $z \sim p_z(z)$

判别器 D



神经网络映射：$D(x)$

输出概率

$D(x) \in [0,1]$

表示样本为真实的概率

真实样本：$D(x) \to 1$

生成样本：$D(G(z)) \to 0$

作用： 判断输入样本是真实数据还是生成数据

输入： x 或 x_{fake} | **输出：** $D(x)$

GAN:

1 判别器损失

$$L_D = -\underbrace{\mathbb{E}_{x\sim p_{\text{data}}(x)}[\log D(x)]}_{\text{真实样本}} - \underbrace{\mathbb{E}_{z\sim p_z(z)}[\log(1-D(G(z)))]}_{\text{生成样本}}$$

目标：真实样本判为真，生成样本判为假

2 生成器损失

$$L_G = \mathbb{E}_{z\sim p_z(z)}[\log(1-D(G(z)))]$$

目标：让生成样本尽可能骗过判别器

3 最终极小极大目标

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{\text{data}}(x)}[\log D(x)] + \mathbb{E}_{z\sim p_z(z)}[\log(1-D(G(z)))]$$

判别器 D 最大化该目标；生成器 G 最小化该目标。

- 真实样本：$D(x)\uparrow$
- 生成样本：$D(G(z))\downarrow$（对判别器）
- 生成器目标：$D(G(z))\uparrow$

$$\min_G \max_D V(D,G) = \mathbb{E}_{\boldsymbol{x}\sim p_{\text{data}}(\boldsymbol{x})}[\log D(\boldsymbol{x})] + \mathbb{E}_{\boldsymbol{z}\sim p_{\boldsymbol{z}}(\boldsymbol{z})}[\log(1 - D(G(\boldsymbol{z})))].$$

首都师范大学 CAPITAL NORMAL UNIVERSITY

for each training iteration

阶段一：更新判别器 D（重复 k 步）

1 采样噪声

$$z^{(1)}, \ldots, z^{(m)} \sim p_z(z)$$

2 采样真实样本

$$x^{(1)}, \ldots, x^{(m)} \sim p_{\text{data}}(x)$$

3 生成假样本

$$x_{\text{fake}} = G(z)$$

4 更新判别器 D（重复 k 步）

最大化 $\frac{1}{m}\sum_{i=1}^{m}\left[\log D\left(x^{(i)}\right) + \log\left(1 - D\left(G\left(z^{(i)}\right)\right)\right)\right]$

阶段二：更新生成器 G（1 步）

5 重新采样噪声

$$z^{(1)}, \ldots, z^{(m)} \sim p_z(z)$$

6 更新生成器 G

最小化 $\frac{1}{m}\sum_{i=1}^{m}\log\left(1 - D\left(G\left(z^{(i)}\right)\right)\right)$

$$\min_G \max_D V(D,G) = \mathbb{E}_{\boldsymbol{x}\sim p_{\text{data}}(\boldsymbol{x})}[\log D(\boldsymbol{x})] + \mathbb{E}_{\boldsymbol{z}\sim p_{\boldsymbol{z}}(\boldsymbol{z})}[\log(1 - D(G(\boldsymbol{z})))].$$

理论分析：

固定生成器G

$$D_G^*(\boldsymbol{x}) = \frac{p_{data}(\boldsymbol{x})}{p_{data}(\boldsymbol{x}) + p_g(\boldsymbol{x})}$$

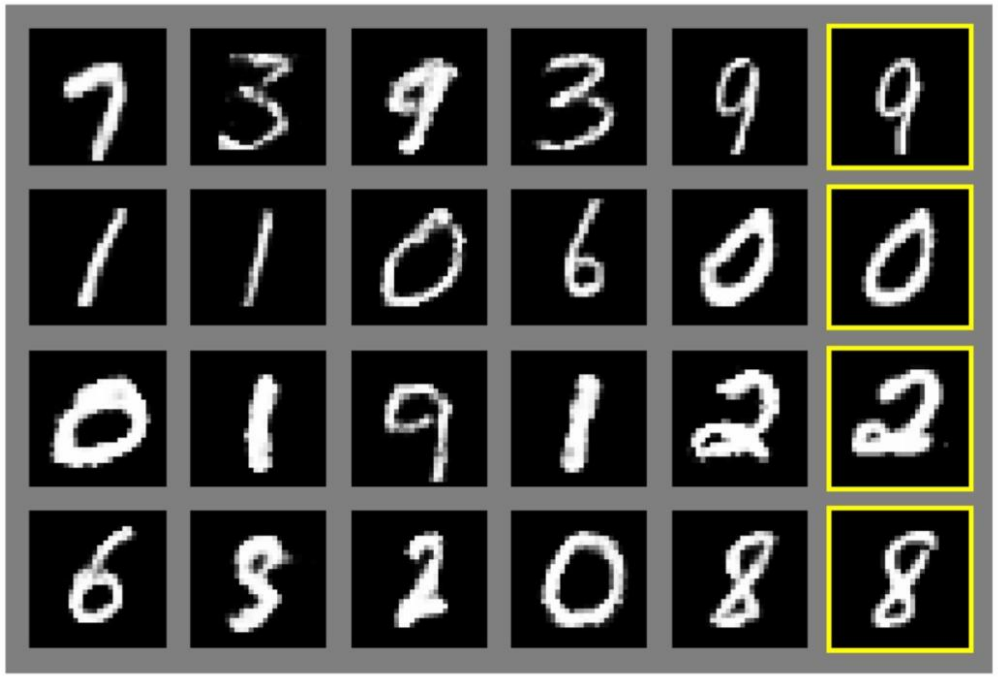
Jensen-Shannon

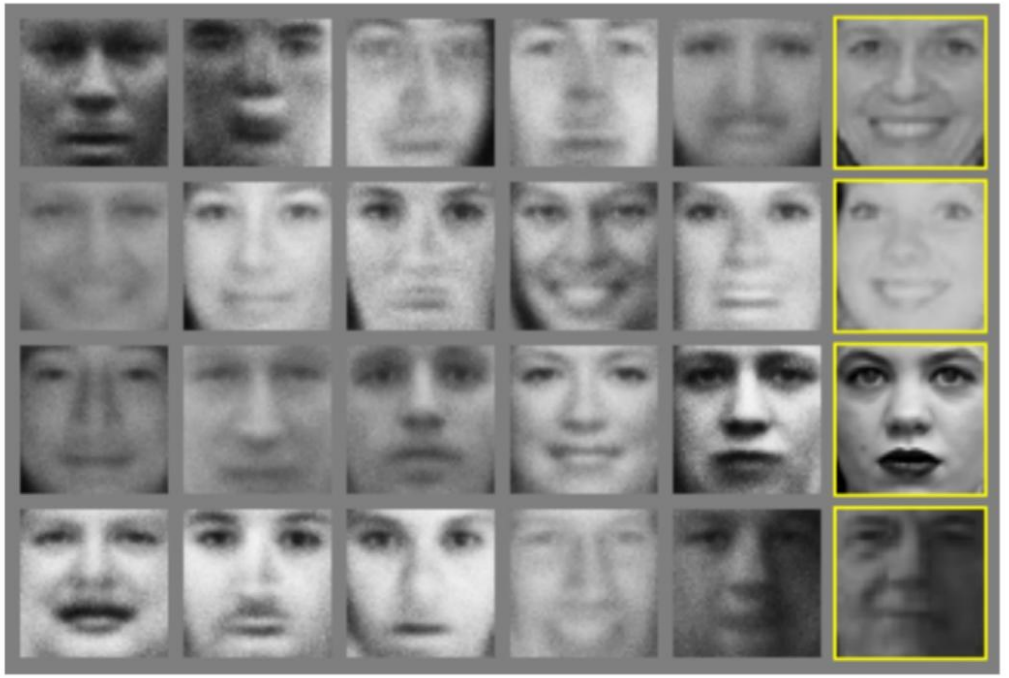
$$C(G) = -\log(4) + KL\left(p_{\text{data}} \middle\| \frac{p_{\text{data}} + p_g}{2}\right) + KL\left(p_g \middle\| \frac{p_{\text{data}} + p_g}{2}\right) \qquad 2 \cdot JSD\left(p_{\text{data}} \| p_g\right)$$

Theorem 1. *The global minimum of the virtual training criterion $C(G)$ is achieved if and only if $p_g = p_{data}$. At that point, $C(G)$ achieves the value $-\log 4$.*

实验结果:

Generated samples





Nearest neighbor from training set

Goodfellow et al, “Generative Adversarial Nets”, NeurIPS 2014

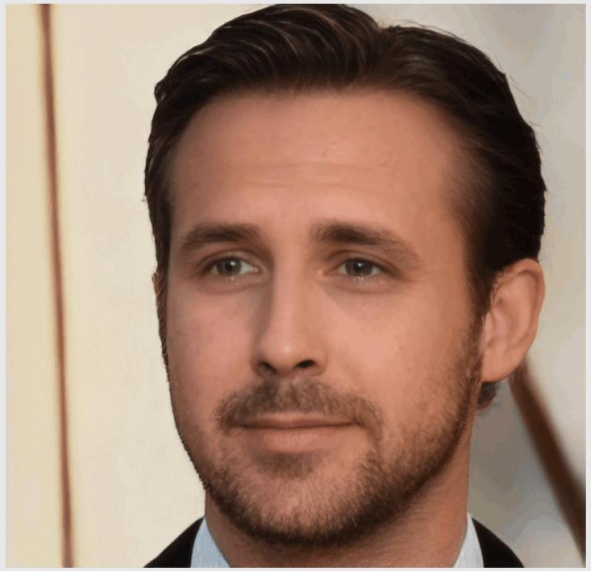
首都师范大学
CAPITAL NORMAL UNIVERSITY

Face Editing with Anycost GAN

original



projected



* select sample:

00_ryan.jpg

channel:

1/4 1/2 3/4 1

resolution:

128 256 512 1024

Reset

Finalize

smiling

young

narrow eye

wavy hair

blonde hair

eyeglass

mustache

Ready.

GAN:

最大贡献：引入了对抗的思想

优点：

- 生成过程较快
- 生成的图像很清晰

缺点：

- 训练不收敛（比较严重的问题）

  解释：当p_{data}和p_g不重合的时候，JS距离不能很好刻画远近

- 没有关于p_g的显示表达式
- 生成的图片多样性不高

目录:

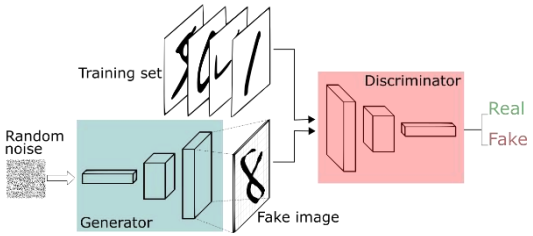
- GAN
- VAE
- DDPM

Generative adversarial nets

I Goodfellow, J Pouget-Abadie... - Advances in neural ..., 2014 - proceedings.neurips.cc

... We propose a new framework for estimating generative models via an adversarial process, in which we simultaneously train two models: a generative model G that captures the data ...

☆ 保存 99 引用 被引用次数：62499 相关文章 所有 61 个版本 »



Auto-encoding variational bayes

DP Kingma, M Welling - arXiv preprint arXiv:1312.6114, 2013 - arxiv.org

... variational lower bound yields a simple differentiable unbiased estimator of the lower bound; this SGVB (Stochastic Gradient Variational Bayes... , we propose the AutoEncoding VB (AEVB...

☆ 保存 99 引用 被引用次数：31270 相关文章 所有 44 个版本 »

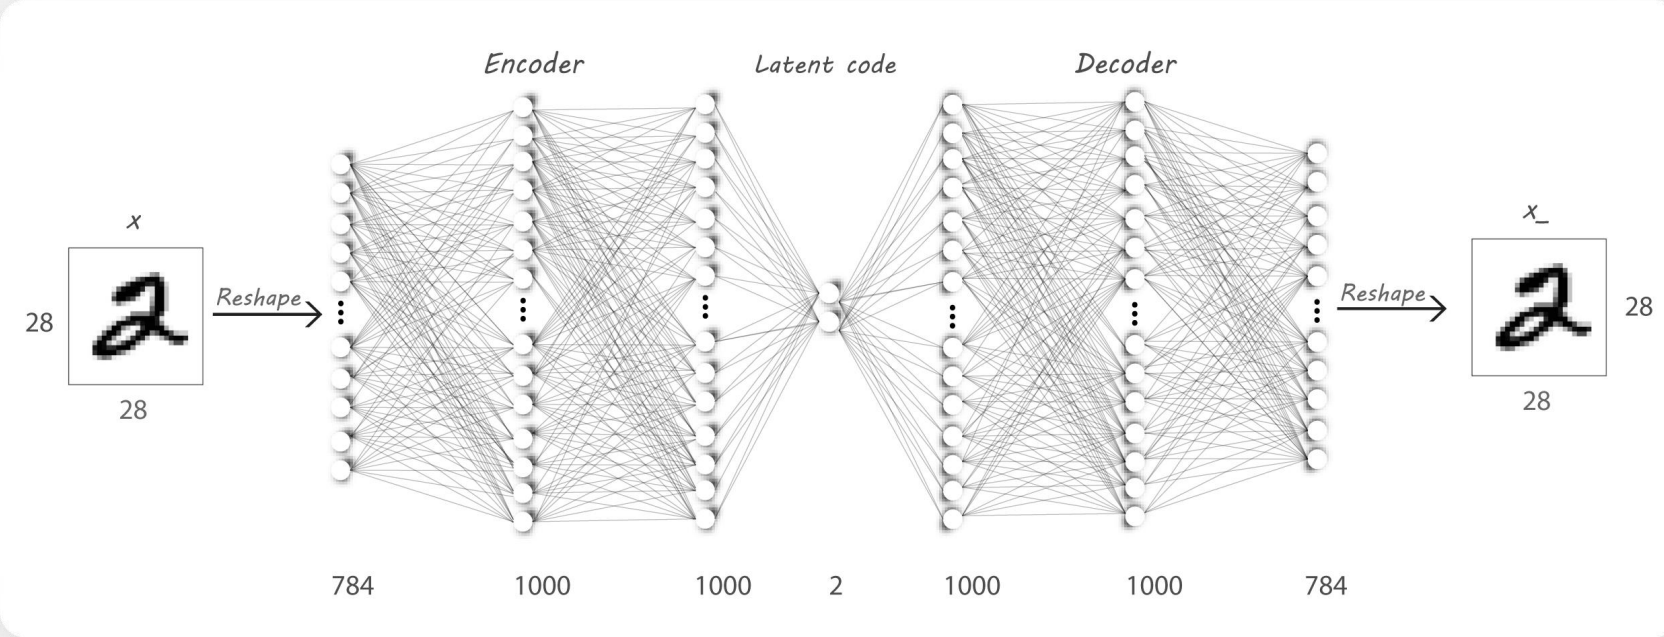
Denoising diffusion probabilistic models

J Ho, A Jain, P Abbeel - Advances in neural information ..., 2020 - proceedings.neurips.cc

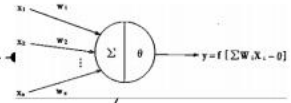
... This paper presents progress in diffusion probabilistic models [53]. A diffusion probabilistic model (which we will call a "diffusion model" for brevity) is a parameterized Markov chain ...

☆ 保存 99 引用 被引用次数：4893 相关文章 所有 6 个版本 »

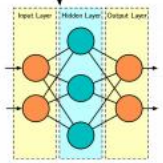
AutoEncoder (AE)







Perceptron(1958)

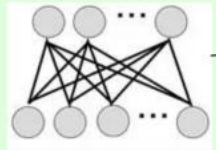


BPNN/MLP(1986)



Andrew Ng
Stanford University
Machine learning

RBM(1986/2006)





Geoffery Hinton
University of Toronto
deep learning

AutoEncoder(1986)

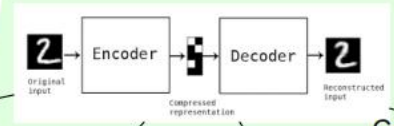
Deep Belief Nets(2006)



Max Welling
University of Amsterdam
statistical learning



Ian Goodfellow
Google Brain
deep adversarial learning

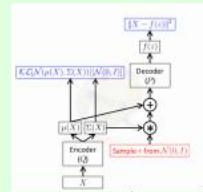


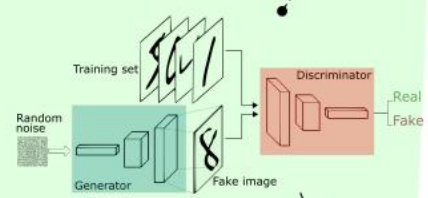
Regularization

Generative model

Variational AutoEncoder(2013)

GAN(2014)



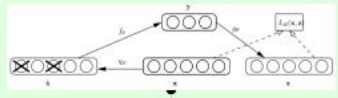


Sparse AutoEncoder(2007)

Noise tolerance

Specific domain

Dennoising AutoEncoder(2011)

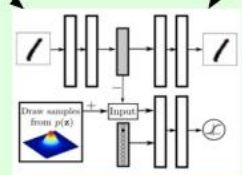


Convolutional AutoEncoder(2011)

Contractive AutoEncoder(2011)

LSTM AutoEncoder(2015)

Robust AutoEncoder(2014)



beta-VAE(2017)
info-VAE(2017)
factorVAE(2018)

adversarial AutoEncoder(2016)



Yoshua Bengio
University of Montreal
Deep learning



Jürgen Schmidhuber
IDSIA
Universal AI

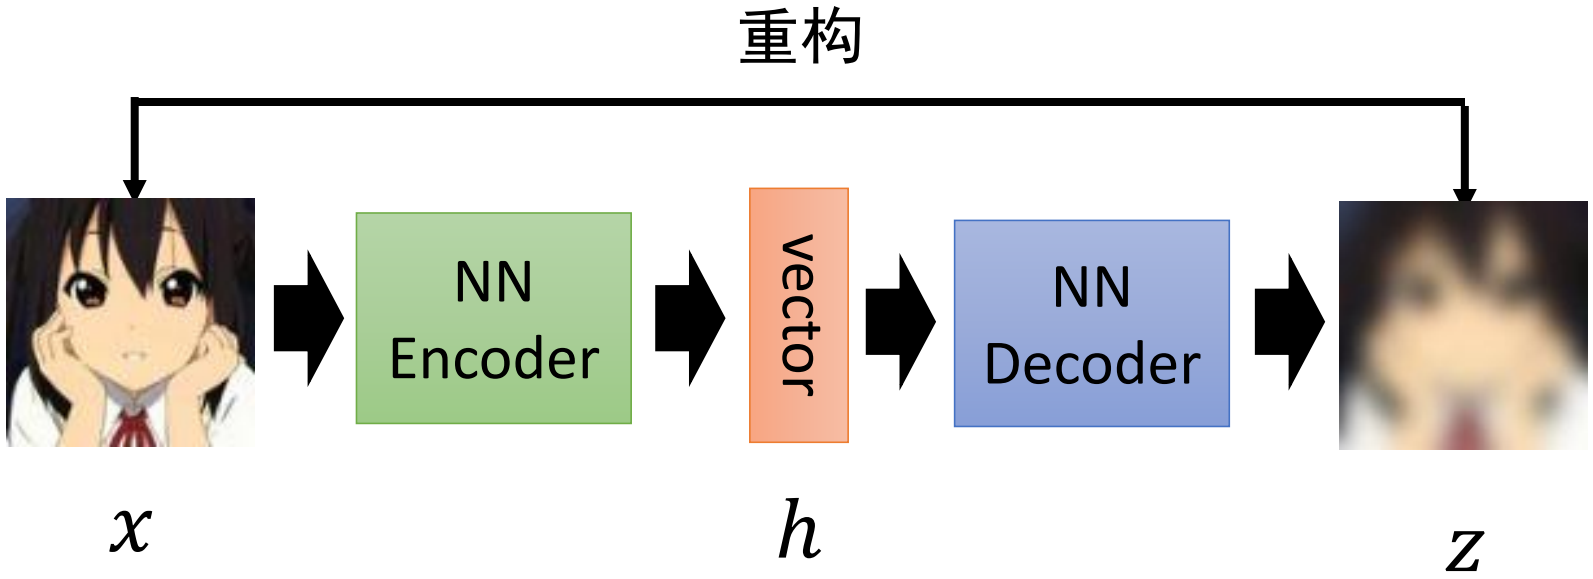

Sparse AE
稀疏自编码器
Denoising AE
去噪自编码器
Contractive AE
压缩自编码器
AE
Stacked AE
堆叠自编码器
Variational AE
变分自编码器E
An interesting case
语音转换

AE（自编码器）

- 最小化重构损失：

$$L(\mathbf{x}, \mathbf{z}) = ||\mathbf{x} - \mathbf{z}||^2$$

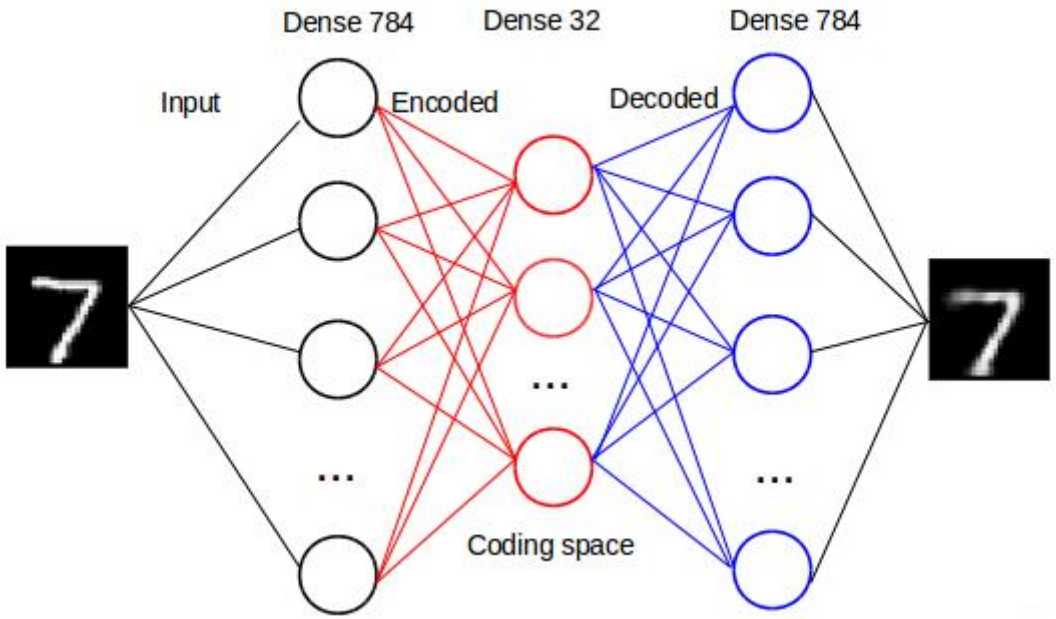
- 反向传播求解
- **用处：**特征提取、数据压缩

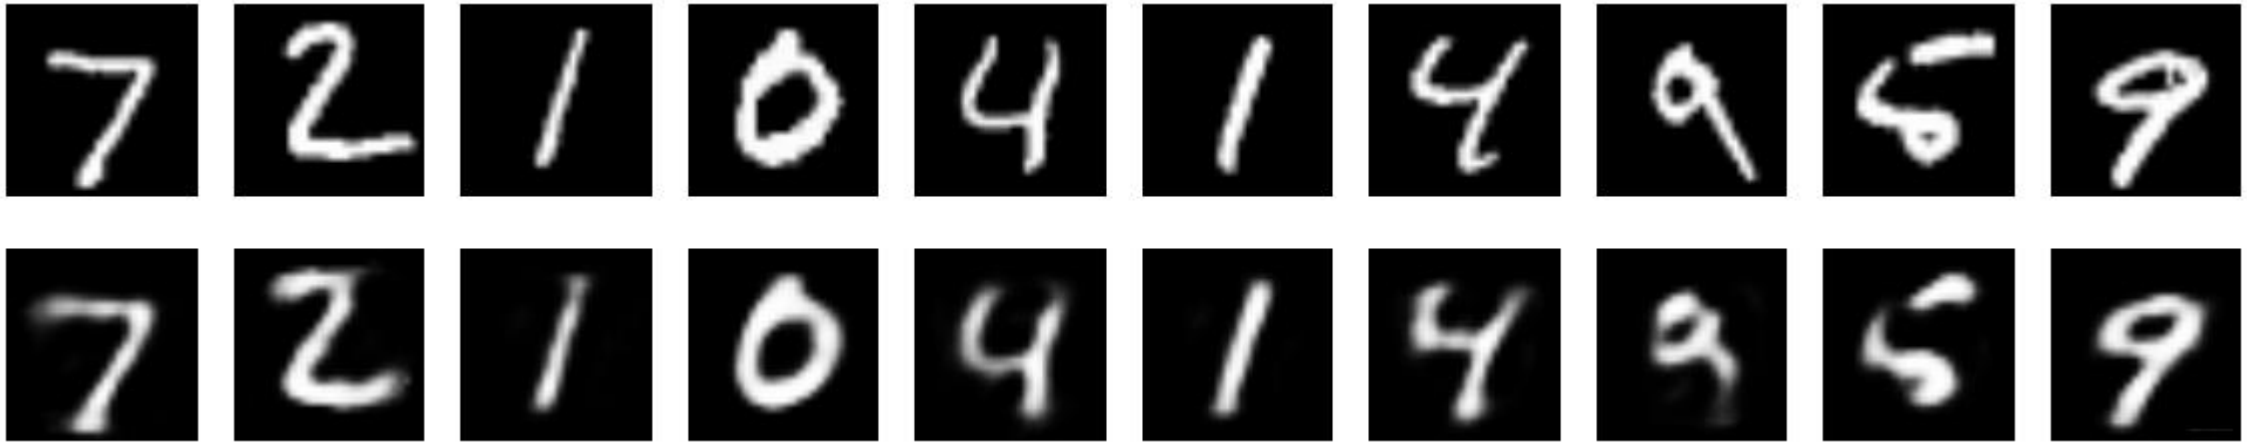


（嵌入、隐变量、编码、表征）

下游任务（分类、回归、聚类、异常检测）

AE（自编码器）


Dense 784
Dense 32
Dense 784
Input
Encoded
Decoded
Coding space




Sparse AE
稀疏自编码器
Denoising AE
去噪自编码器
Contractive AE
压缩自编码器
AE
Stacked AE
堆叠自编码器
Variational AE
变分自编码器E
An interesting case
语音转换

DAE（去噪自编码器）



x

重构原无噪声输入

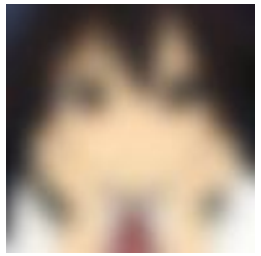
加入噪声



NN Encoder

vector

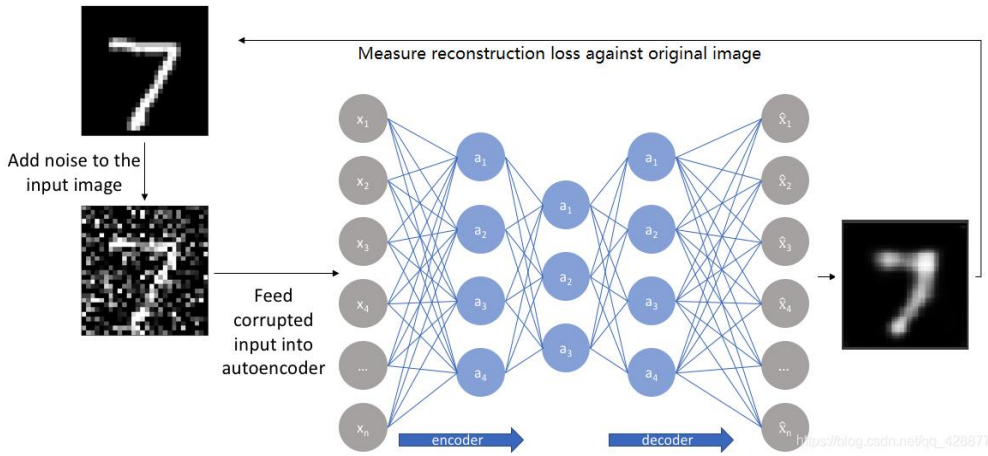
NN Decoder

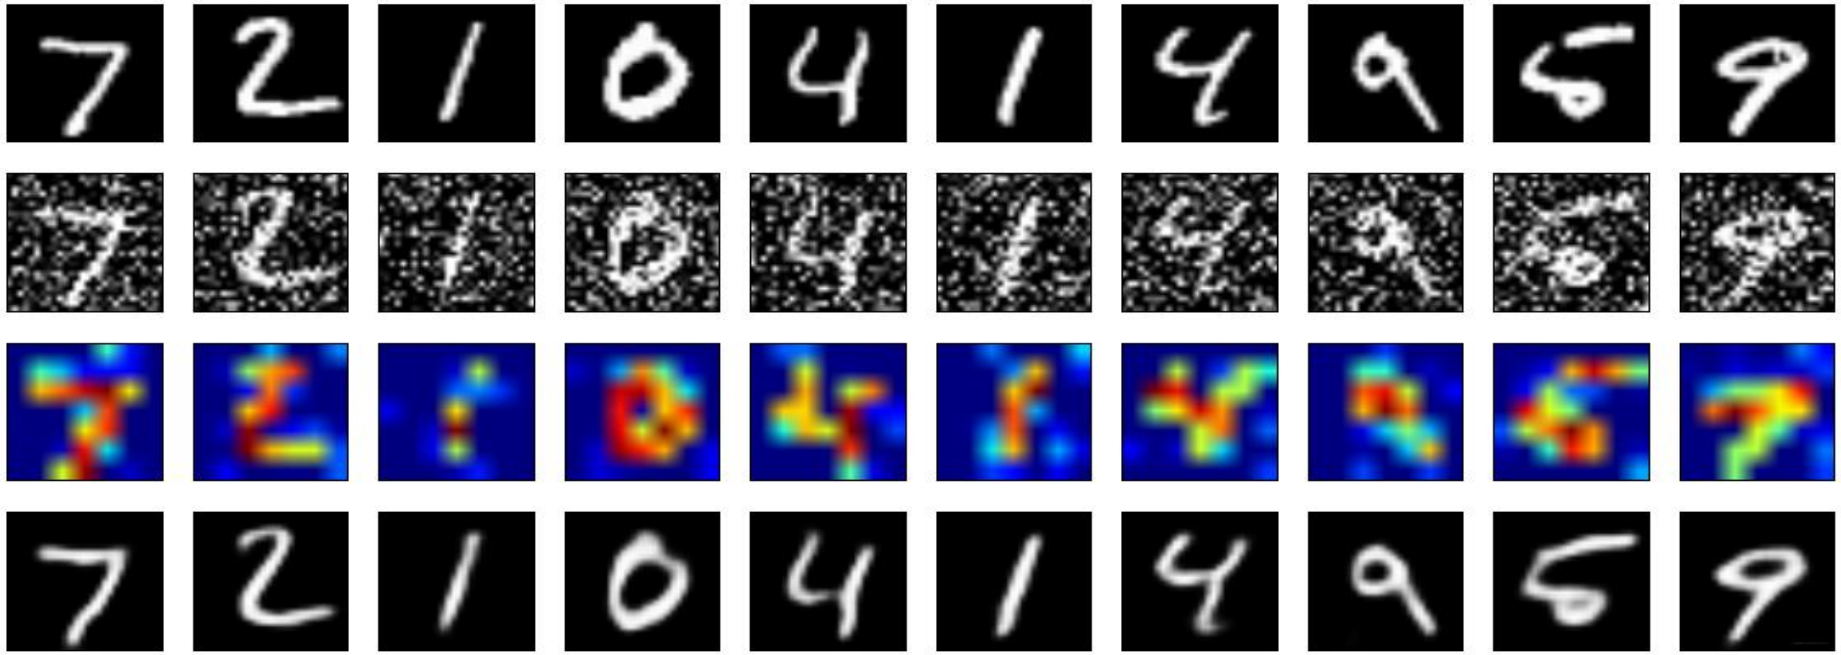


$\tilde{x}$ h z

- **加入噪声：**
  - 以一定概率随机置0
  - 加入一定高斯噪声
- **重构损失**

DAE（去噪自编码器）


Measure reconstruction loss against original image
Add noise to the input image
Feed corrupted input into autoencoder
encoder
decoder

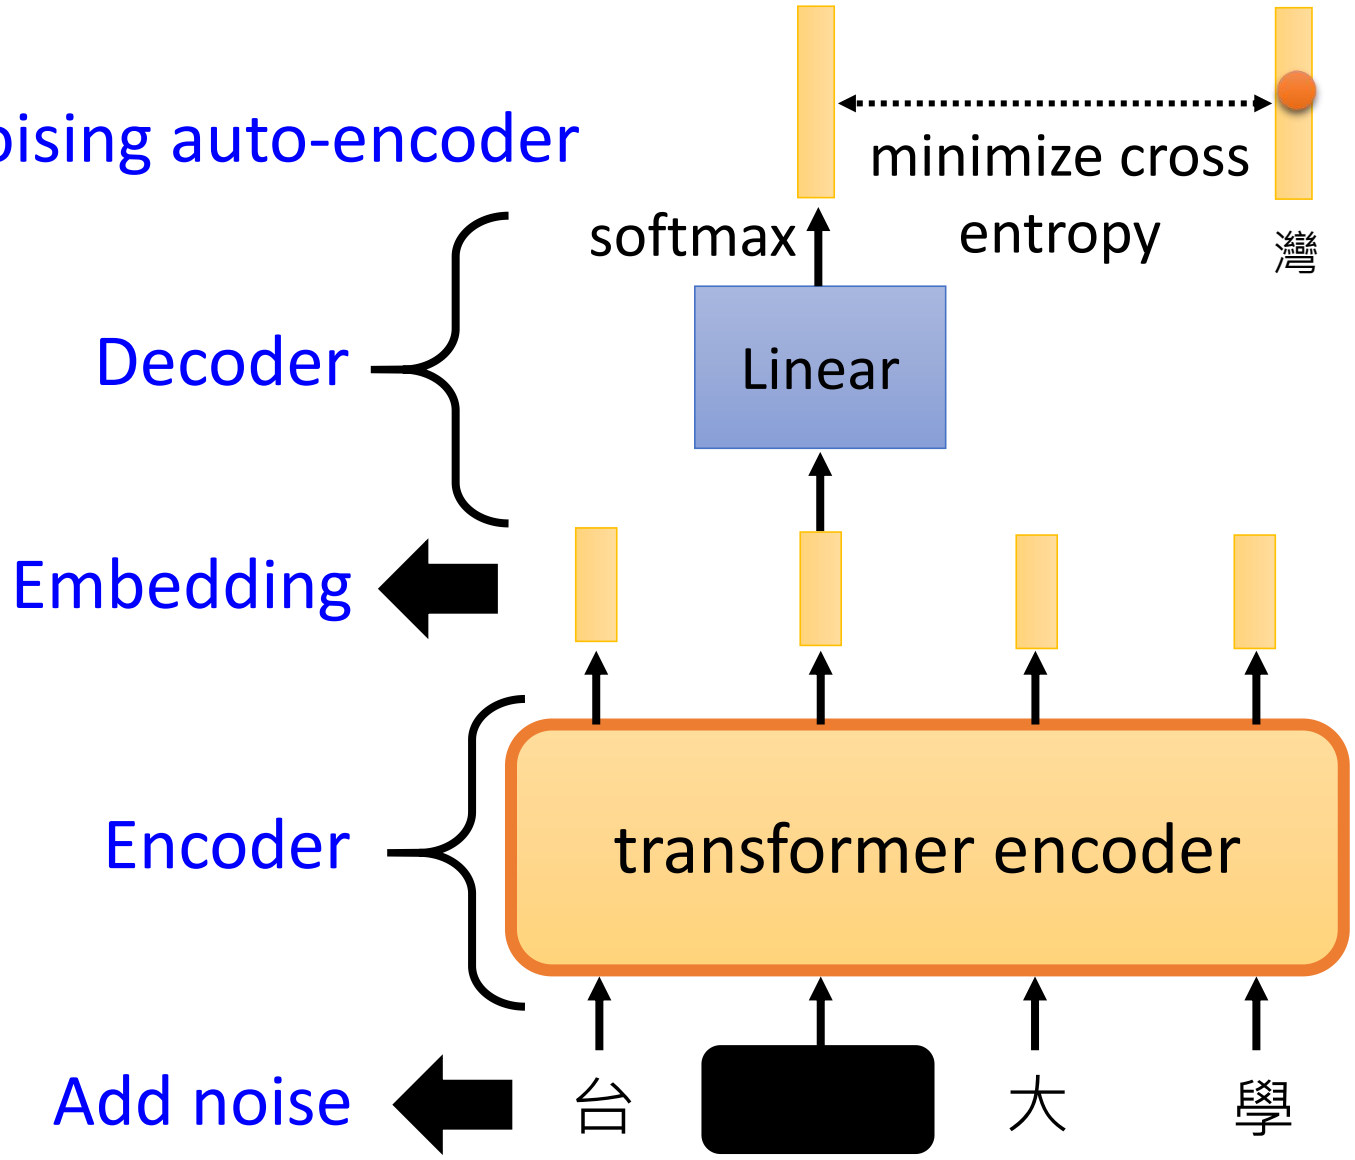


BERT≈DAE+transformer

Bidirectional
Encoder
Representations
from
Transformers

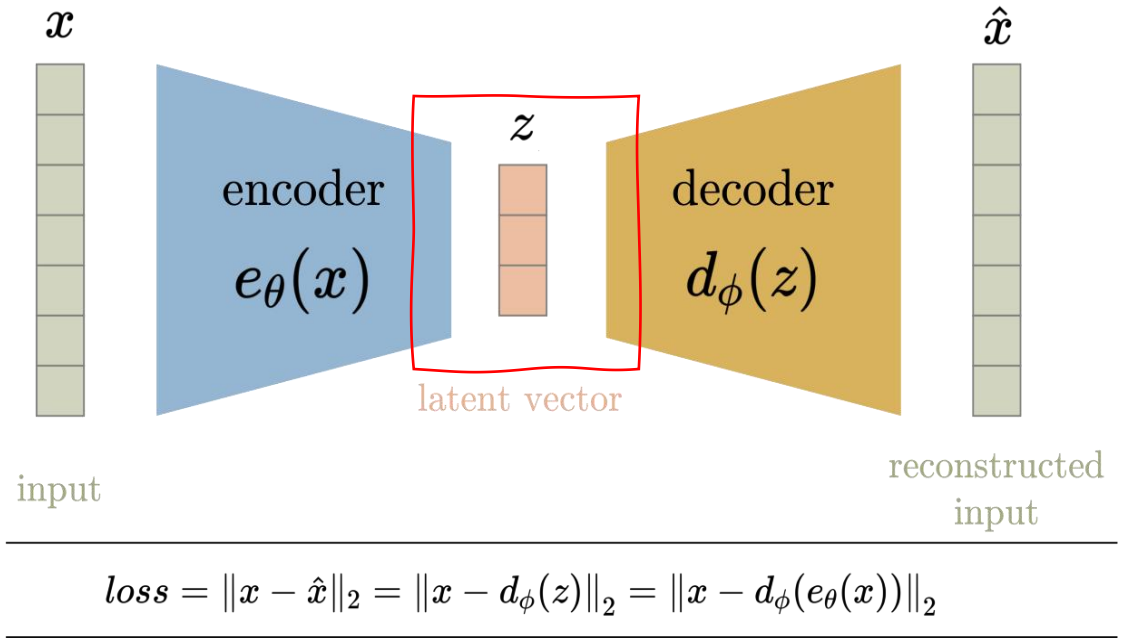


A de-noising auto-encoder




Sparse AE
稀疏自编码器
Denoising AE
去噪自编码器
Contractive AE
压缩自编码器
AE
Stacked AE
堆叠自编码器
Variational AE
变分自编码器E
An interesting case
语音转换

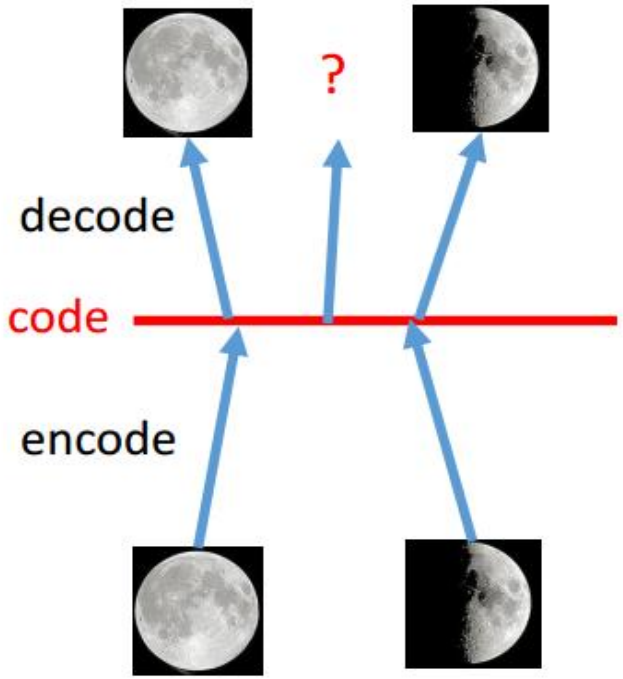
AE（Auto Encoder）：



用处
- 预训练特征提取
- 数据压缩和恢复（图像检索）

思考：怎么把它当成生成模型？

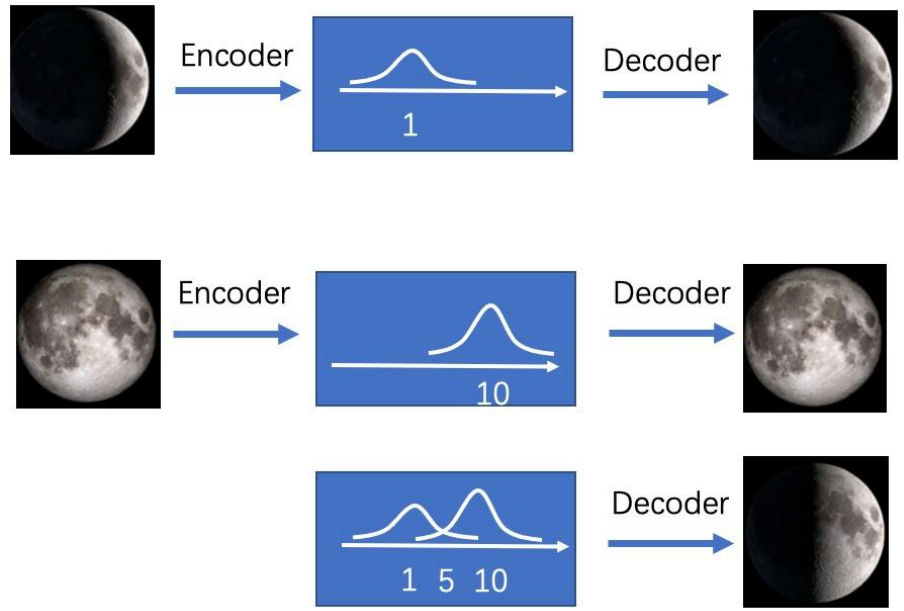
AE（Auto Encoder）：



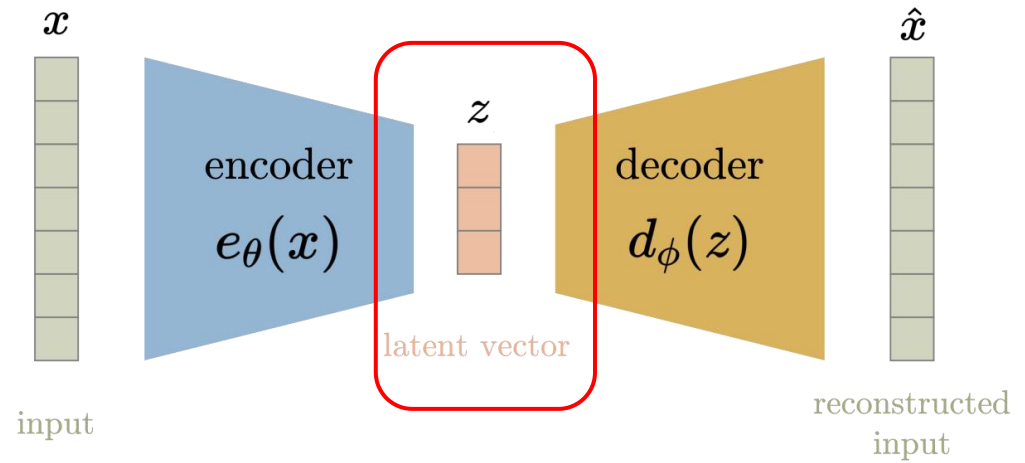
要求：

✓ 连续性

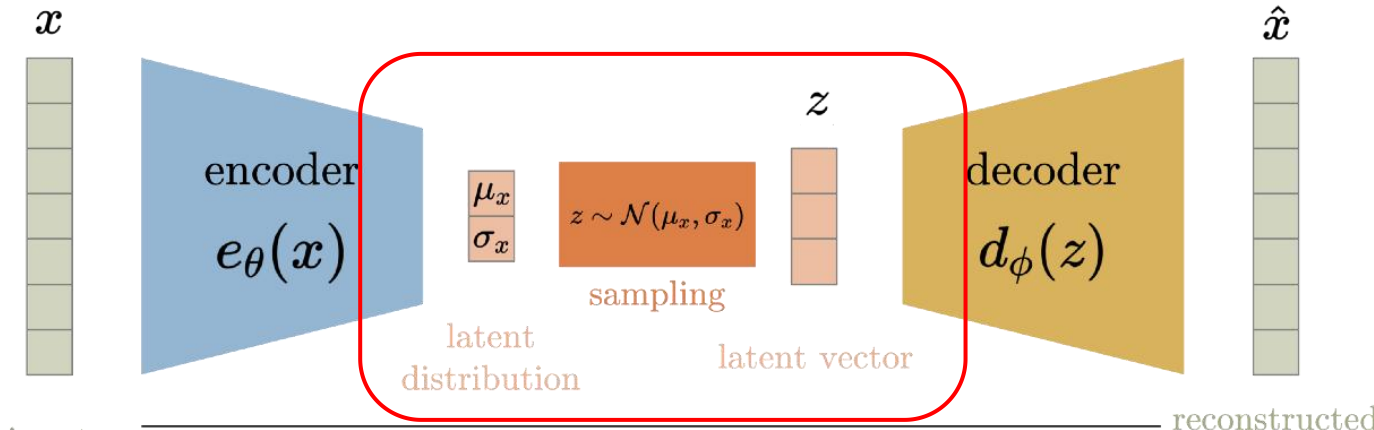
✓ 完备性



VAE（Variational Auto Encoder）：



$$loss = \|x - \hat{x}\|_2 = \|x - d_\phi(z)\|_2 = \|x - d_\phi(e_\theta(x))\|_2$$



$$\text{reconstruction loss} = \|x - \hat{x}\|_2 = \|x - d_\phi(z)\|_2 = \|x - d_\phi(\mu_x + \sigma_x \epsilon)\|_2$$

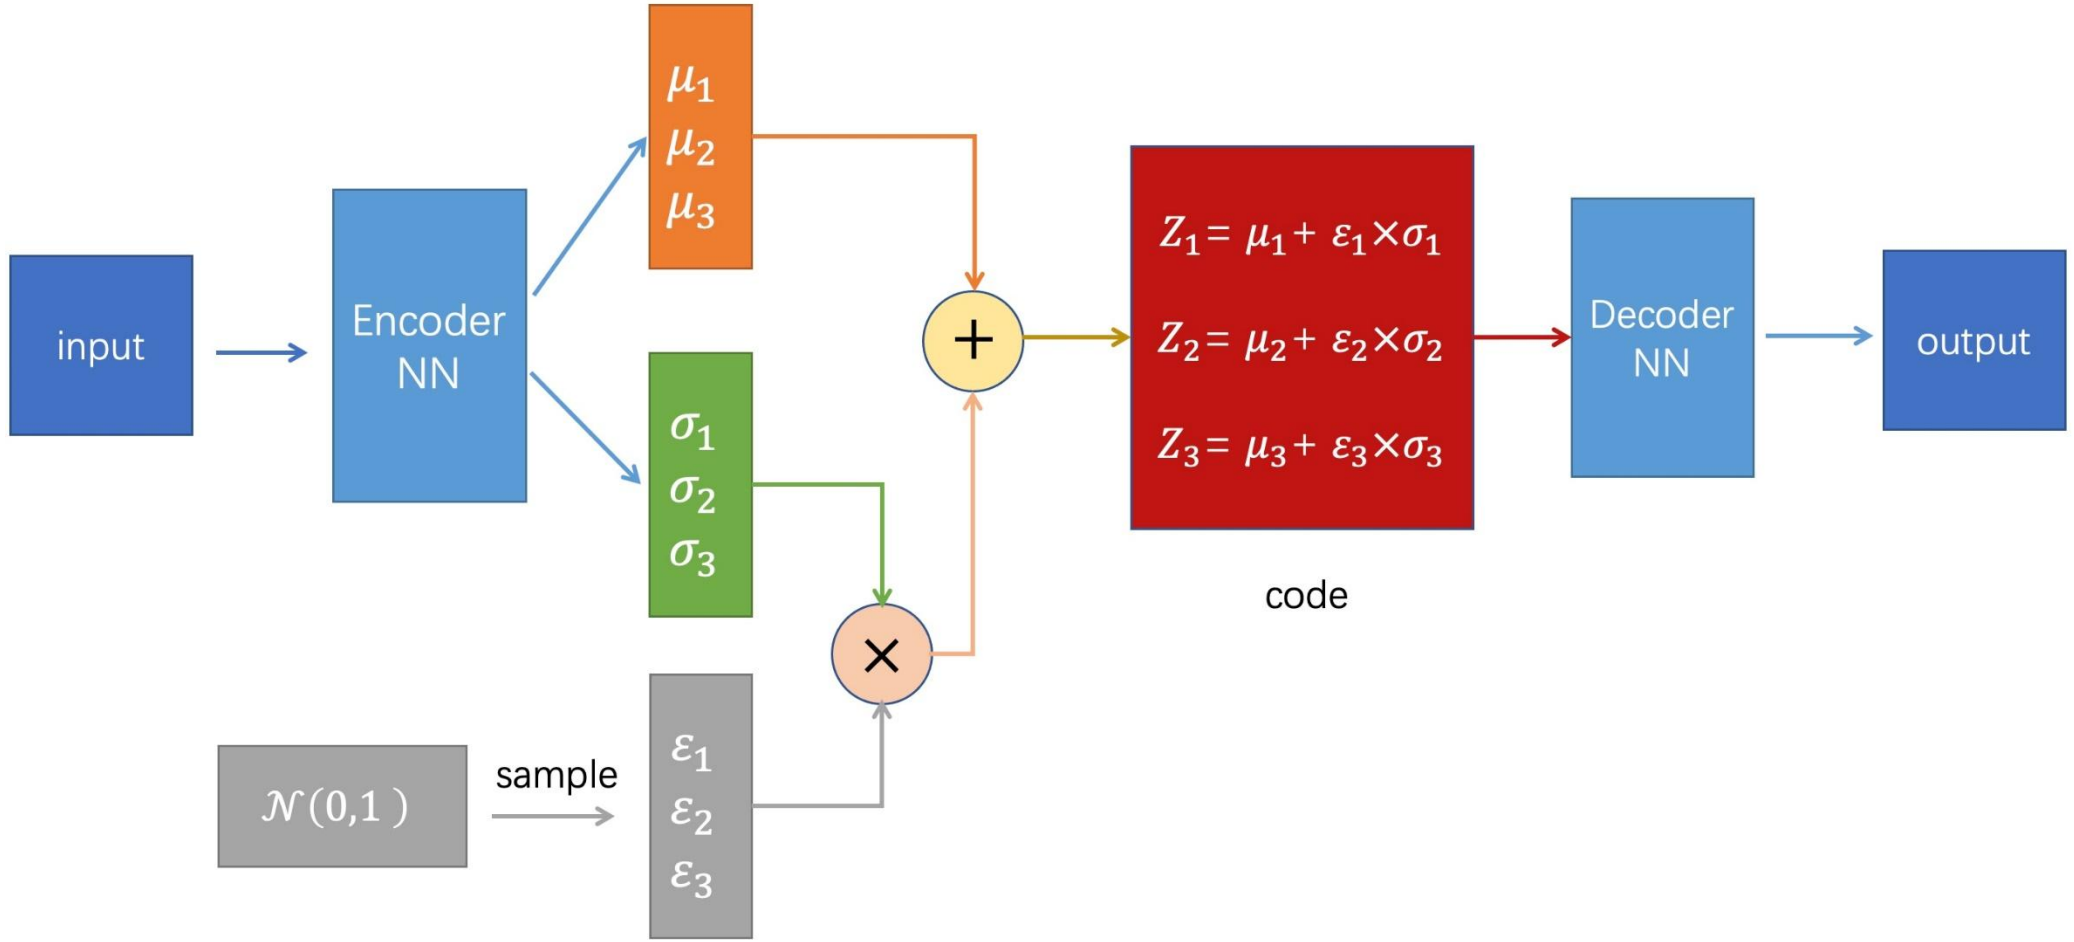
$$\mu_x, \sigma_x = e_\theta(x), \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

$$similarity\ loss = KL\ Divergence = D_{KL}(\mathcal{N}(\mu_x, \sigma_x) \parallel \mathcal{N}(\mathbf{0}, \mathbf{I}))$$

$$loss = reconstruction\ loss + similarity\ loss$$

$$z = \mu_x + \sigma_x \epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

VAE（Variational Auto Encoder）：



VAE（Variational Auto Encoder）：

生成网络（G）

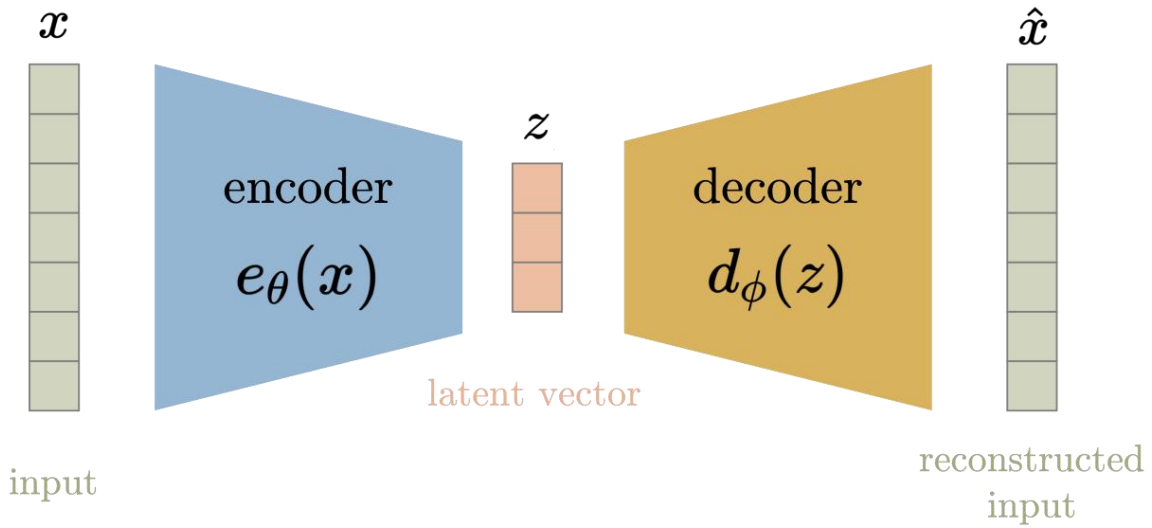
$$p_\theta(\mathrm{x}) = \frac{p_\theta(\mathrm{x}|\mathrm{z})p_\theta(z)}{p_\theta(\mathrm{z}|\mathrm{x})}$$

简单先验 $p_\theta(\mathrm{z})$

难以求解

设计一个 $q_\phi(z|\mathrm{x})$ 尽可能的逼近 $p_\theta(\mathrm{z}|\mathrm{x})$

Encoder 编码网络



VAE（Variational Auto Encoder）：

$$\mathrm{KL}\left(q_\phi(z|\mathrm{x})\,\|\,p_\theta(z|\mathrm{x})\right)=\sum_z q_\phi(z|\mathrm{x})\log\frac{q_\phi(z|\mathrm{x})}{p_\theta(z|\mathrm{x})}=\sum_z q_\phi(z|\mathrm{x})\log\frac{q_\phi(z|\mathrm{x})p_\theta(\mathrm{x})}{p_\theta(\mathrm{x}|z)p_\theta(z)}$$

$$=\sum_z q_\phi(z|\mathrm{x})\log q_\phi(z|\mathrm{x})+\sum_z q_\phi(z|\mathrm{x})\log p_\theta(\mathrm{x})-\sum_z q_\phi(z|\mathrm{x})\log p_\theta(\mathrm{x}|z)-\sum_z q_\phi(z|\mathrm{x})\log p_\theta(z)$$

$$=\log p_\theta(\mathrm{x})+\left(\sum_z q_\phi(z|\mathrm{x})\log q_\phi(z|\mathrm{x})-\sum_z q_\phi(z|\mathrm{x})\log p_\theta(z)\right)-\sum_z q_\phi(z|\mathrm{x})\log p_\theta(\mathrm{x}|z)$$

$$=\log p_\theta(\mathrm{x})+\mathrm{KL}\left(q_\phi(z|\mathrm{x})\,\|\,p_\theta(z)\right)-\underset{z\sim q_\phi(z|\mathrm{x})}{E}\left(\log p_\theta(\mathrm{x}|z)\right)$$

$$\log p_\theta(\mathrm{x})\geq\underbrace{\underset{z\sim q_\phi(z|\mathrm{x})}{E}\left(\log p_\theta(\mathrm{x}|z)\right)-\mathrm{KL}\left(q_\phi(z|\mathrm{x})\,\|\,p_\theta(z)\right)}$$

Evidence lower bound (ELBO) 证据下界　最大化

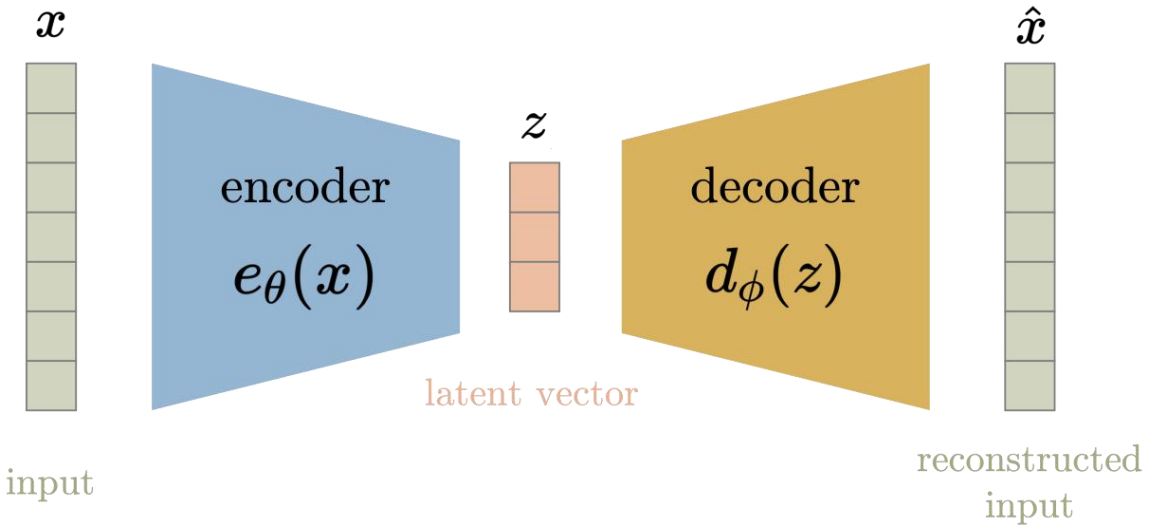
生成网络（G）

$p_\theta(\mathrm{x})=\dfrac{p_\theta(\mathrm{x}|z)p_\theta(z)}{p_\theta(z|\mathrm{x})}$ → 简单先验　$p_\theta(z)$

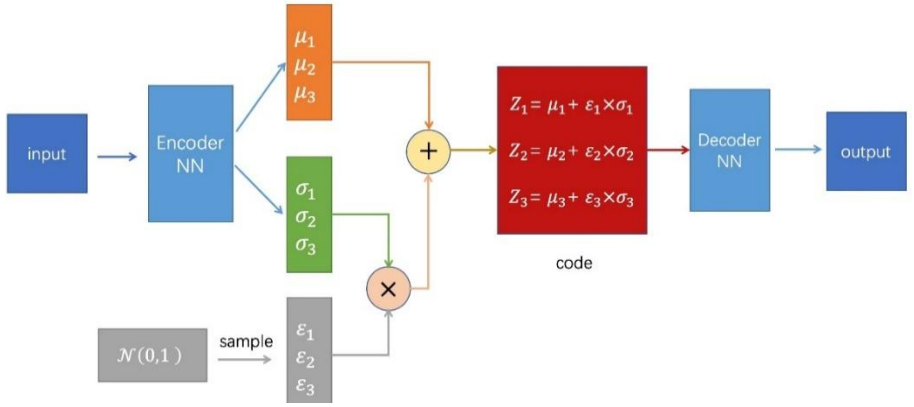
→ 难以求解

设计一个　$q_\phi(z|\mathrm{x})$　尽可能的逼近　$p_\theta(z|\mathrm{x})$

Encoder　编码网络



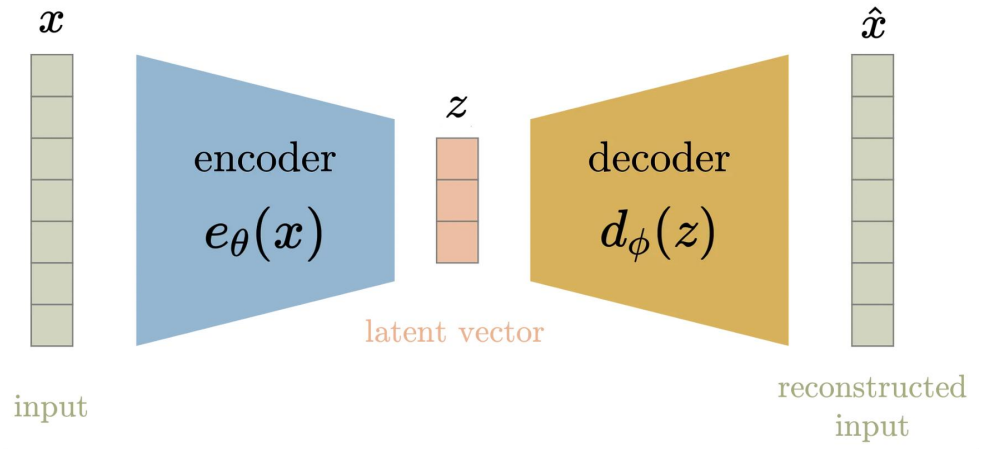
VAE（Variational Auto Encoder）：



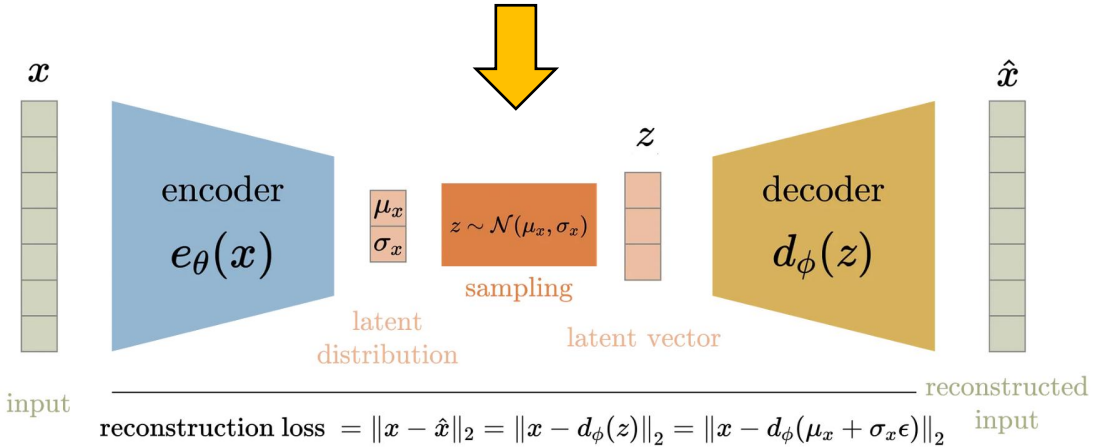
Algorithm 1 Minibatch version of the Auto-Encoding VB (AEVB) algorithm. Either of the two SGVB estimators in section 2.3 can be used. We use settings $M = 100$ and $L = 1$ in experiments.

$\boldsymbol{\theta}, \boldsymbol{\phi} \leftarrow$ Initialize parameters
repeat
  $\mathbf{X}^M \leftarrow$ Random minibatch of M datapoints (drawn from full dataset)
  $\boldsymbol{\epsilon} \leftarrow$ Random samples from noise distribution $p(\boldsymbol{\epsilon})$
  $\mathbf{g} \leftarrow \nabla_{\boldsymbol{\theta},\boldsymbol{\phi}} \widetilde{\mathcal{L}}^M(\boldsymbol{\theta}, \boldsymbol{\phi}; \mathbf{X}^M, \boldsymbol{\epsilon})$ (Gradients of minibatch estimator (8))
  $\boldsymbol{\theta}, \boldsymbol{\phi} \leftarrow$ Update parameters using gradients $\mathbf{g}$ (e.g. SGD or Adagrad [DHS10])
until convergence of parameters $(\boldsymbol{\theta}, \boldsymbol{\phi})$
return $\boldsymbol{\theta}, \boldsymbol{\phi}$

VAE（变分自编码器）



$$loss = \|x - \hat{x}\|_2 = \|x - d_\phi(z)\|_2 = \|x - d_\phi(e_\theta(x))\|_2$$



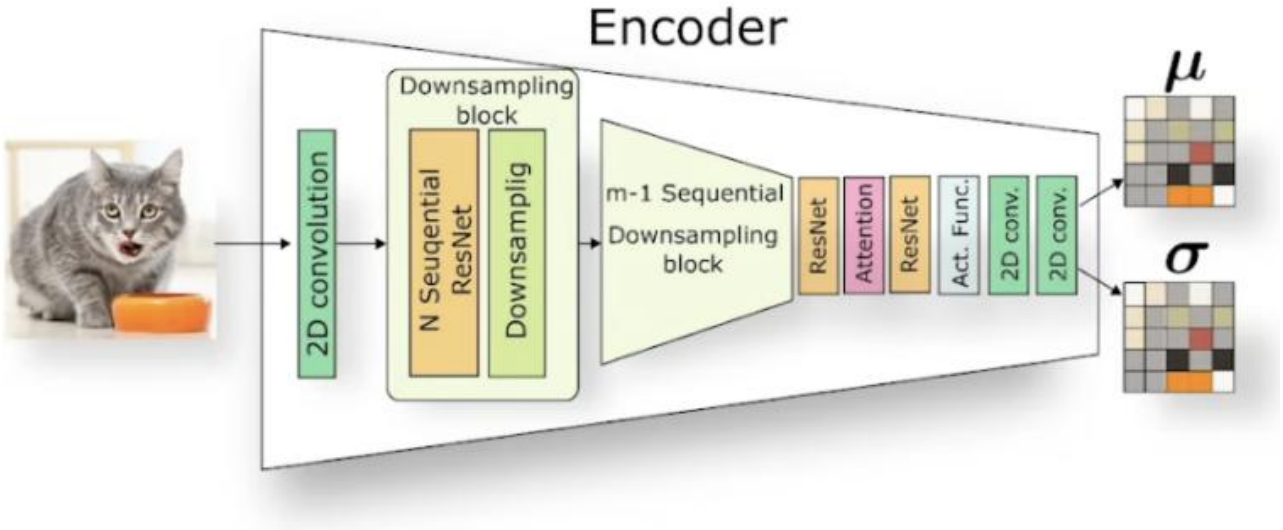
$$\text{reconstruction loss} = \|x - \hat{x}\|_2 = \|x - d_\phi(z)\|_2 = \|x - d_\phi(\mu_x + \sigma_x \epsilon)\|_2$$

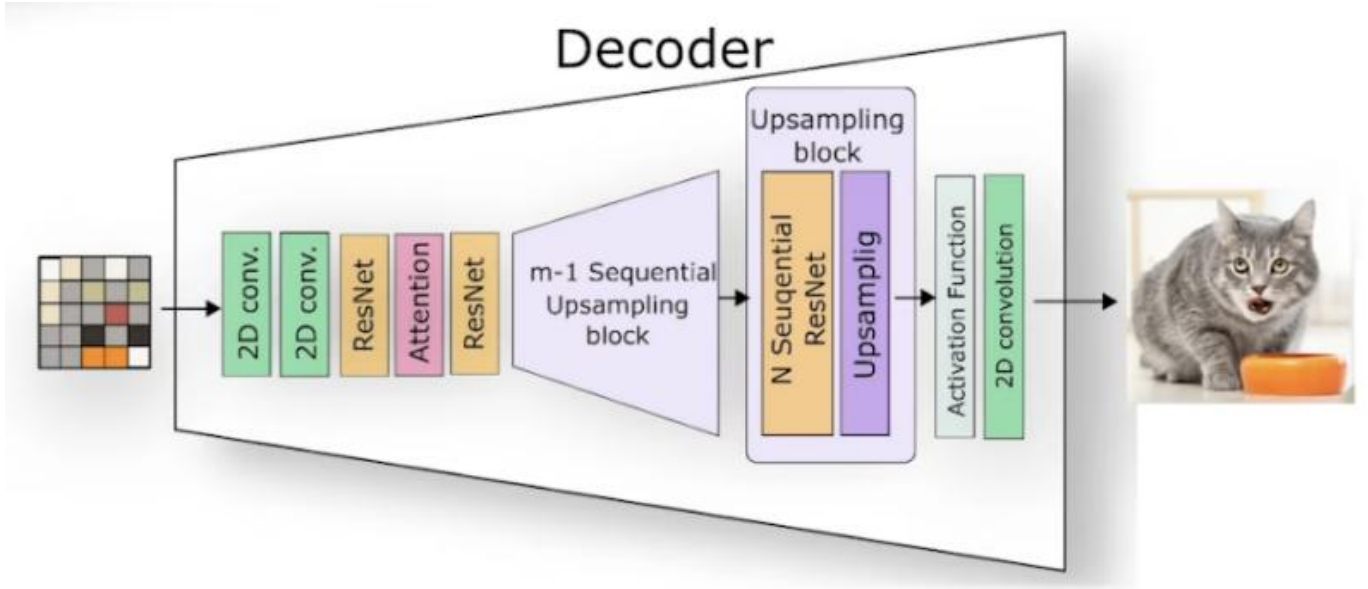
$$\mu_x, \sigma_x = e_\theta(x), \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

$$similarity\ loss = KL\ Divergence = D_{KL}(\mathcal{N}(\mu_x, \sigma_x) \parallel \mathcal{N}(\mathbf{0}, \mathbf{I}))$$

$$loss = reconstruction\ loss + similarity\ loss$$




Encoder
2D convolution
Downsampling block
N Seuqential ResNet
Downsamplig
m-1 Sequential Downsampling block
ResNet
Attention
ResNet
Act. Func.
2D conv.
2D conv.
μ
σ


Decoder
2D conv.
2D conv.
ResNet
Attention
ResNet
m-1 Sequential Upsampling block
Upsampling block
N Seuqential ResNet
Upsamplig
Activation Function
2D convolution

VAE（Variational Auto Encoder）：



原始图像

VAE



训练
1个
epoch
后的
生成结果

VAE



训练
10个
epoch
后的
生成结果



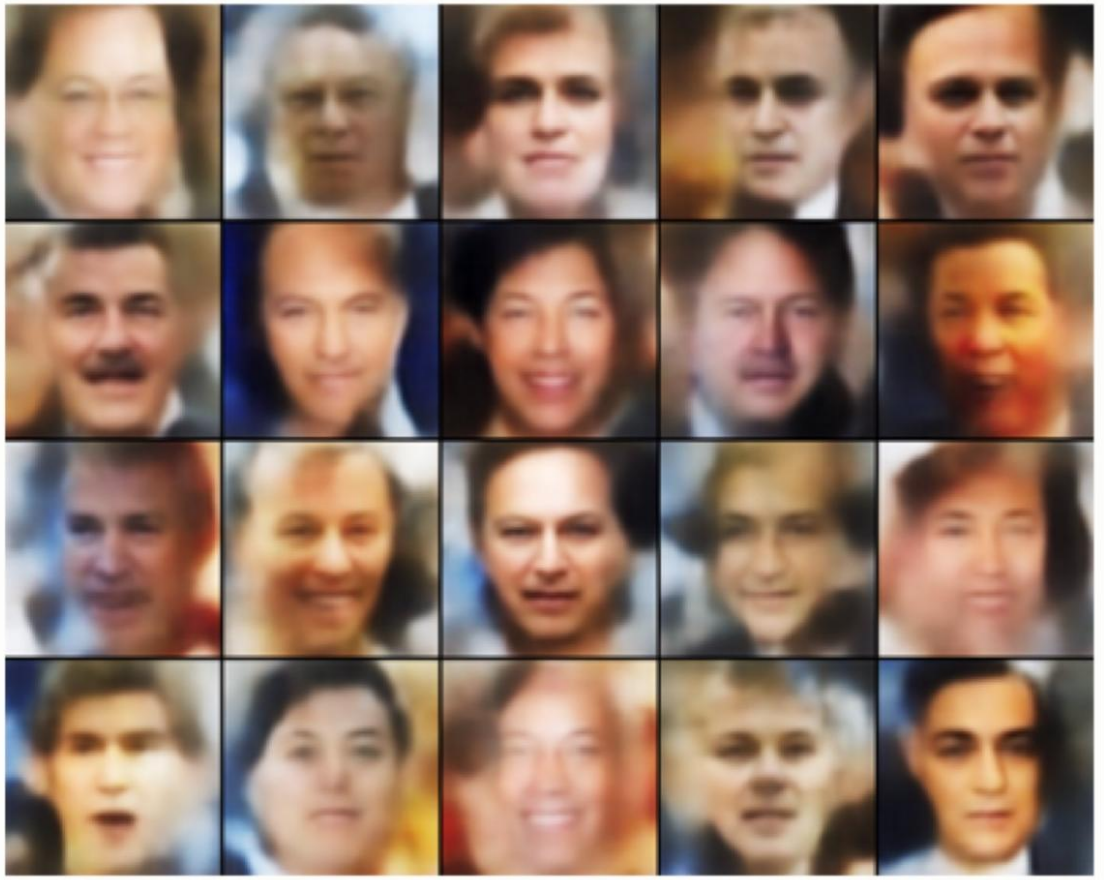
从正态分布中随机采样100个code
输入训练好的Decoder生成的结果

实验结果:

32x32 CIFAR-10



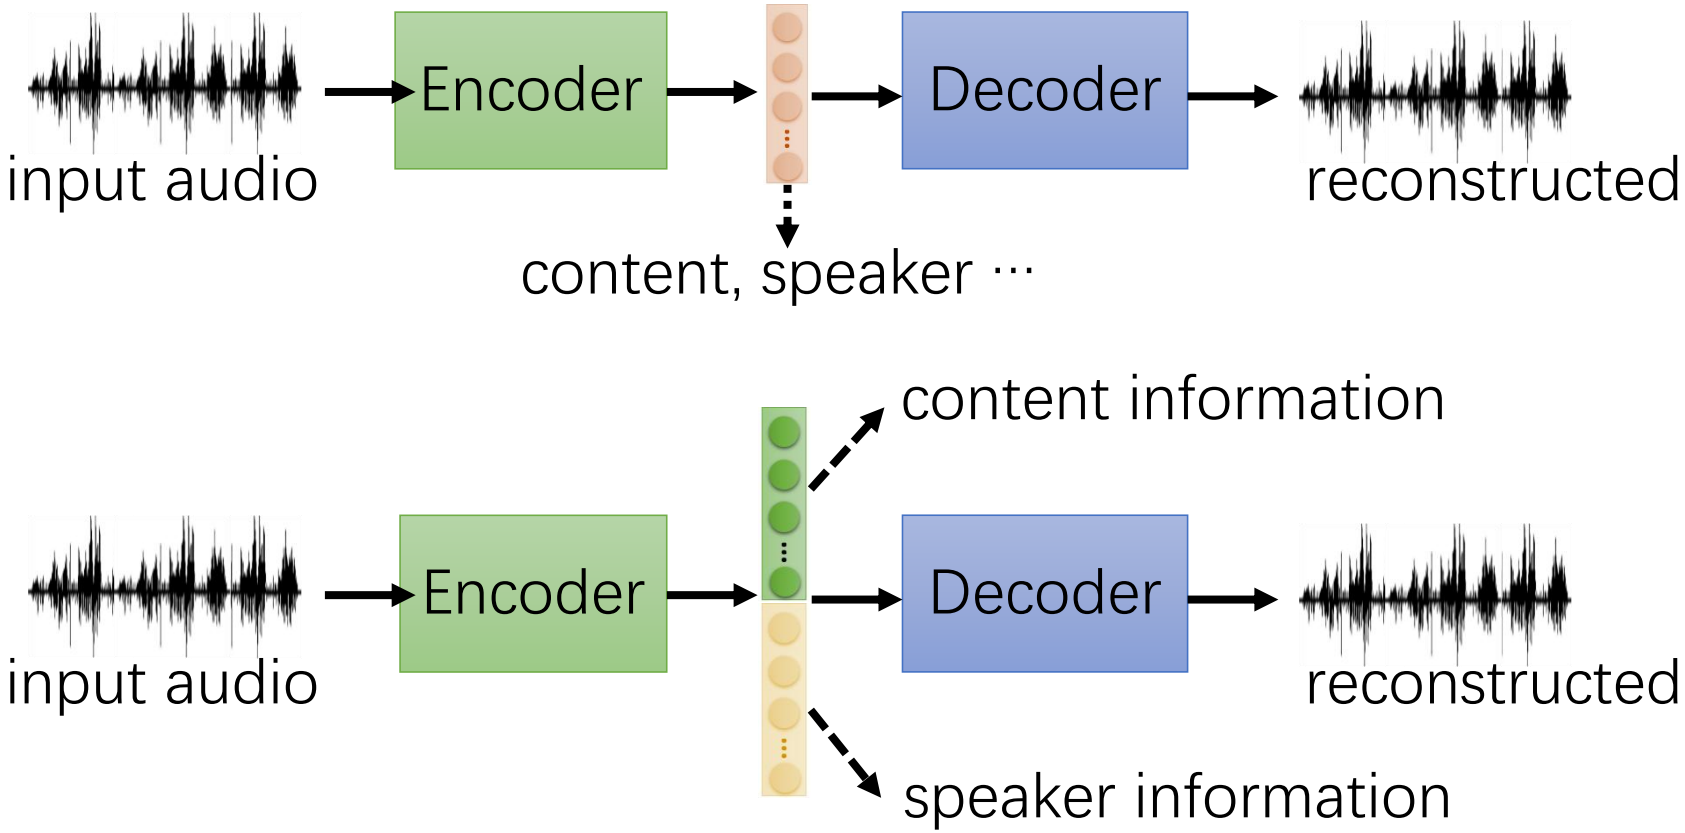
Labeled Faces in the Wild



Figures from (L) Dirk Kingma et al. 2016; (R) Anders Larsen et al. 2017.

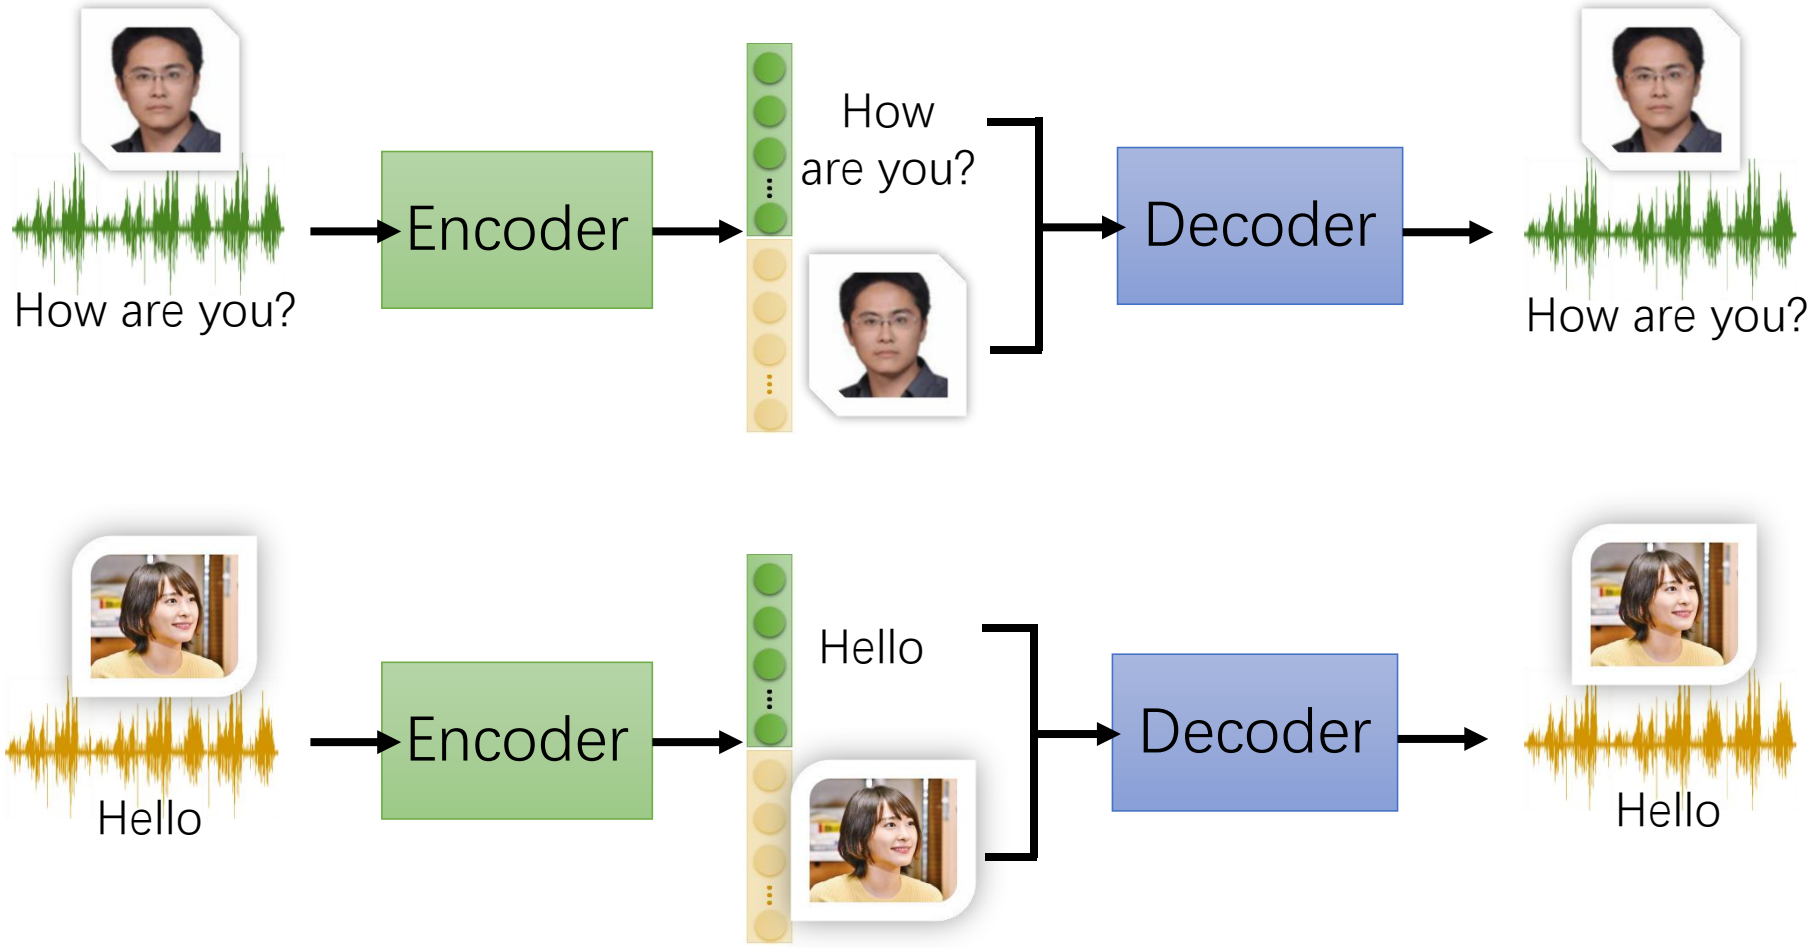

Sparse AE
稀疏自编码器
Denoising AE
去噪自编码器
Contractive AE
压缩自编码器
AE
Stacked AE
堆叠自编码器
Variational AE
变分自编码器E
An interesting case
语音转换

应用：语音转换

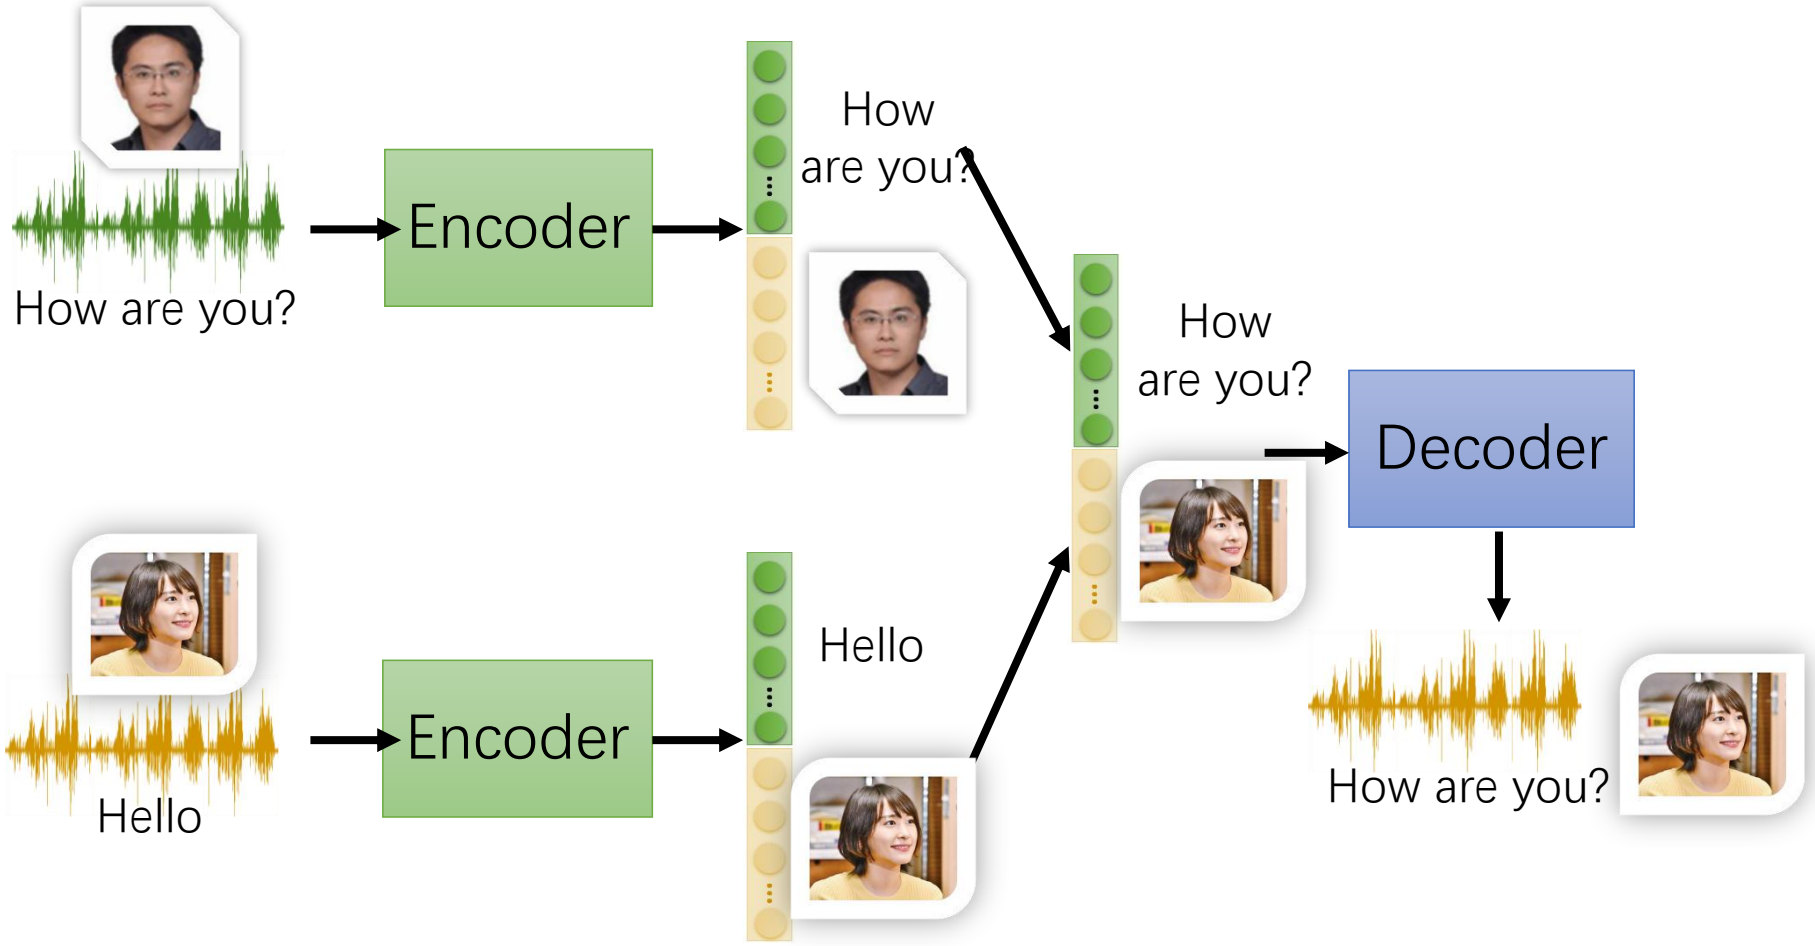


https://arxiv.org/abs/1904.05742
https://arxiv.org/abs/1804.02812
https://arxiv.org/abs/1905.05879

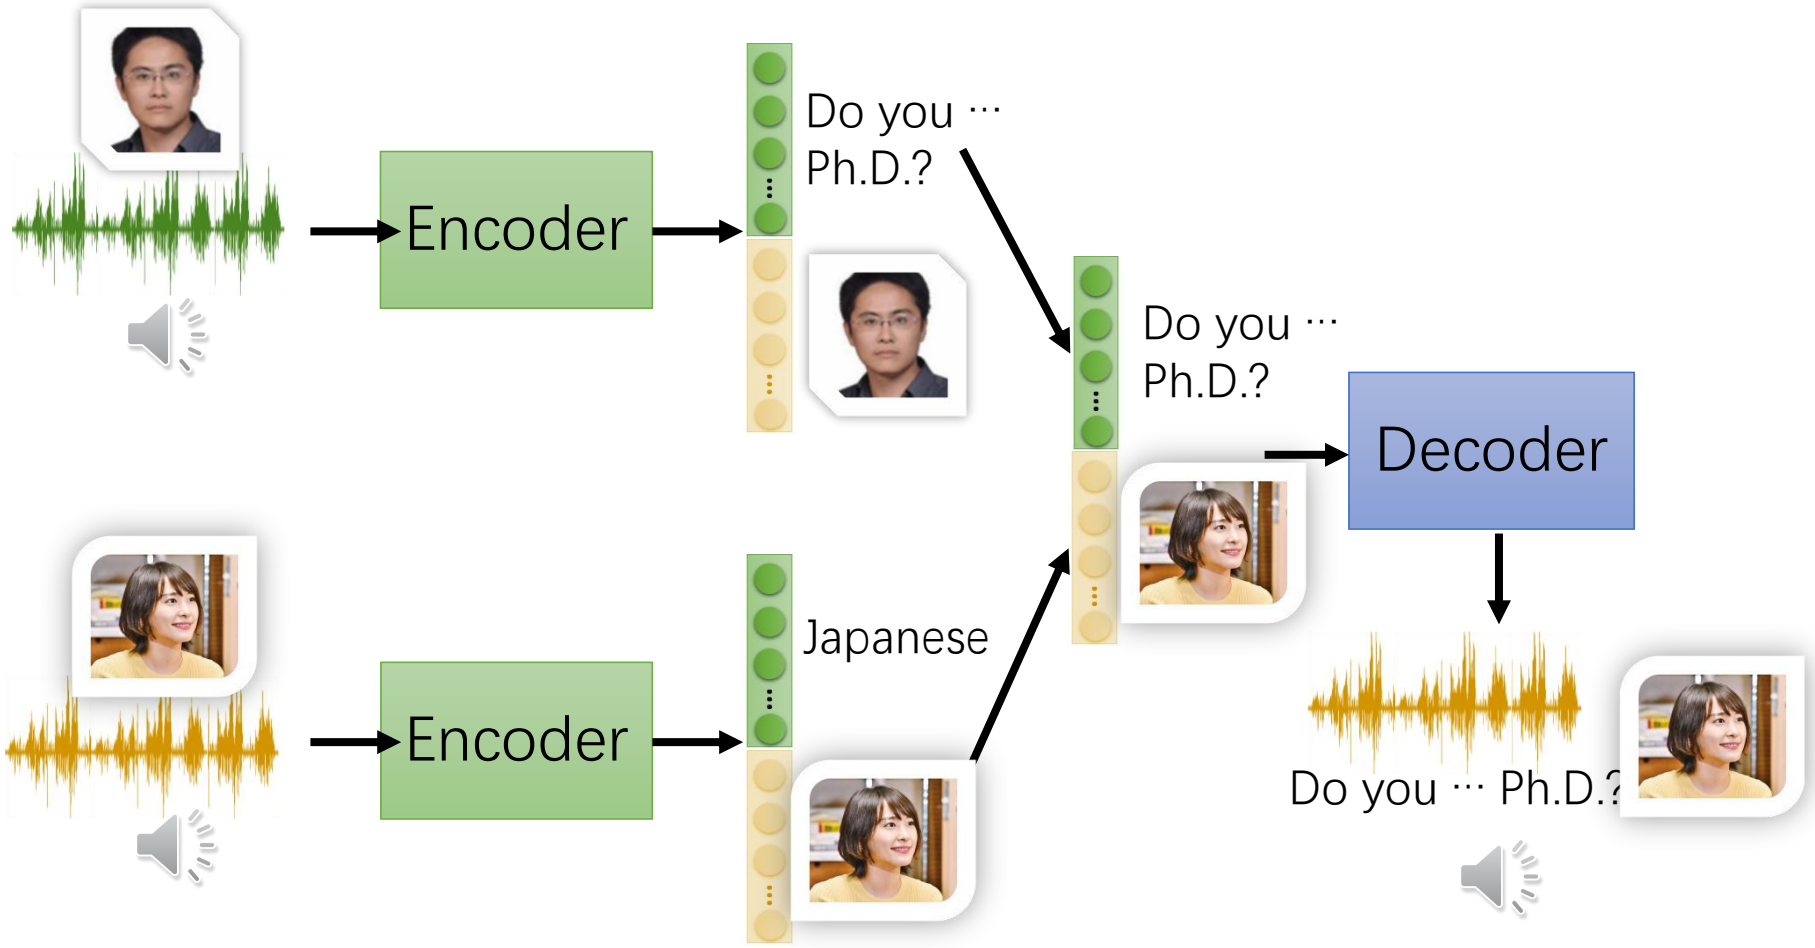
应用：语音转换


How are you?
Encoder
How
are you?
Decoder
How are you?
Hello
Encoder
Hello
Decoder
Hello

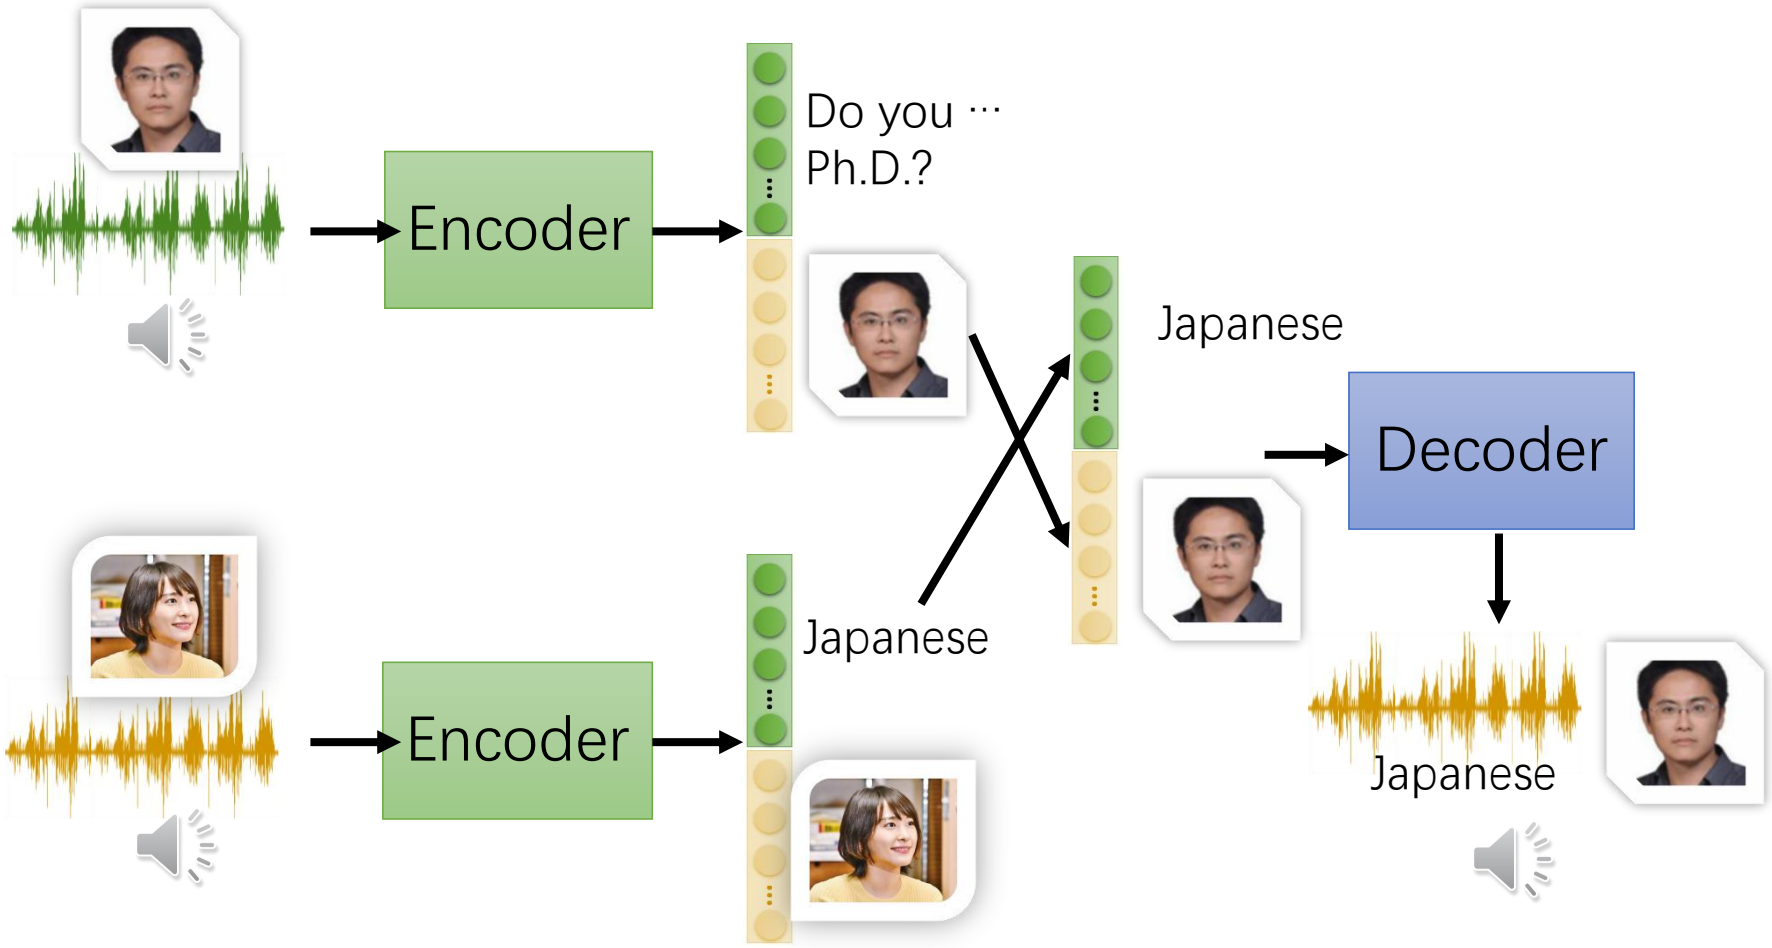
应用：语音转换


How are you?
Encoder
How are you?
How are you?
Hello
Encoder
Hello
How are you?
Decoder
How are you?

应用：语音转换


Encoder
Do you …
Ph.D.?
Encoder
Japanese
Do you …
Ph.D.?
Decoder
Do you … Ph.D.?

应用：语音转换


Encoder
Do you …
Ph.D.?
Encoder
Japanese
Japanese
Decoder
Japanese

目录:

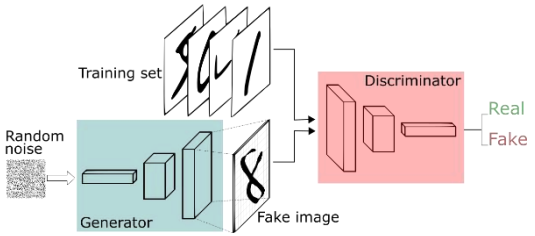
- GAN
- VAE
- DDPM

Generative adversarial nets

I Goodfellow, J Pouget-Abadie... - Advances in neural ..., 2014 - proceedings.neurips.cc

... We propose a new framework for estimating generative models via an adversarial process, in which we simultaneously train two models: a generative model G that captures the data ...

☆ 保存 99 引用 被引用次数：62499 相关文章 所有 61 个版本 »

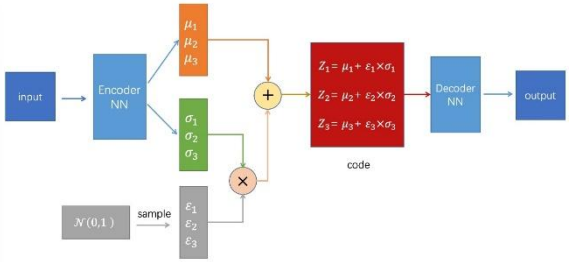


Auto-encoding variational bayes

DP Kingma, M Welling - arXiv preprint arXiv:1312.6114, 2013 - arxiv.org

... variational lower bound yields a simple differentiable unbiased estimator of the lower bound; this SGVB (Stochastic Gradient Variational Bayes... , we propose the AutoEncoding VB (AEVB...

☆ 保存 99 引用 被引用次数：31270 相关文章 所有 44 个版本 »



Denoising diffusion probabilistic models

J Ho, A Jain, P Abbeel - Advances in neural information ..., 2020 - proceedings.neurips.cc

... This paper presents progress in diffusion probabilistic models [53]. A diffusion probabilistic model (which we will call a "diffusion model" for brevity) is a parameterized Markov chain ...

☆ 保存 99 引用 被引用次数：4893 相关文章 所有 6 个版本 »

Diffusion:

启发： Non-equilibrium thermodynamics

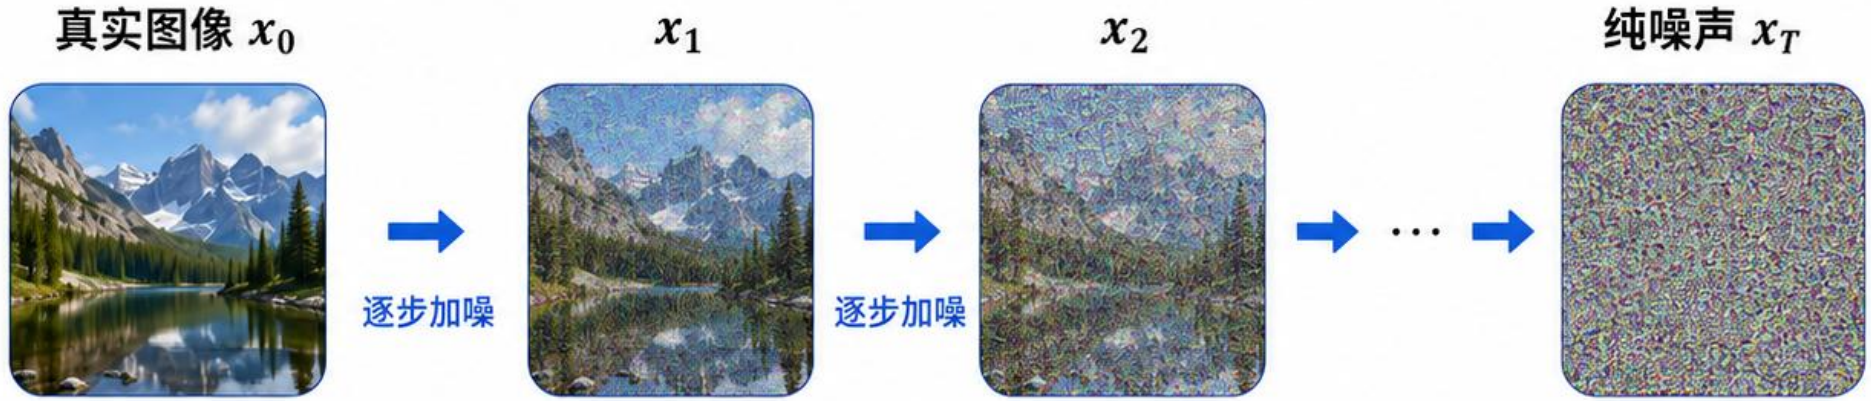
（非平衡热力学）



Diffusion

整体思想

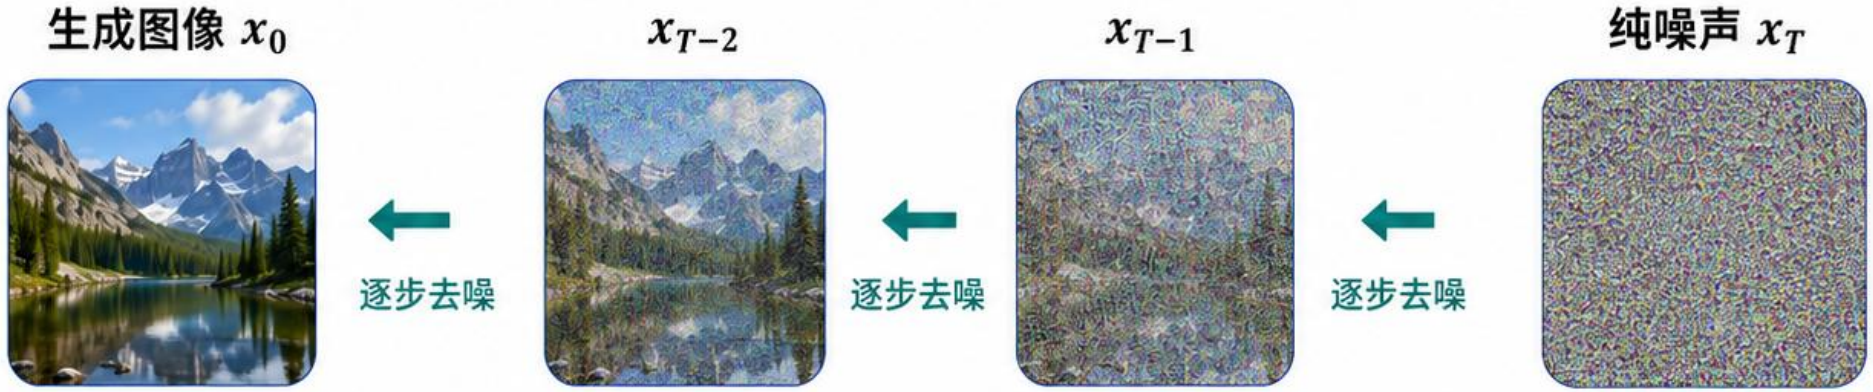
前向过程：
固定过程，不需要学习；
逐步向数据加入高斯噪声



核心思想： 先把图像一步步破坏成噪声，再学习如何把噪声一步步还原成图像

生成过程

反向过程：
学习过程，需要神经网络；
逐步预测噪声并恢复图像



上：加噪（固定过程） | 下：去噪（学习过程）

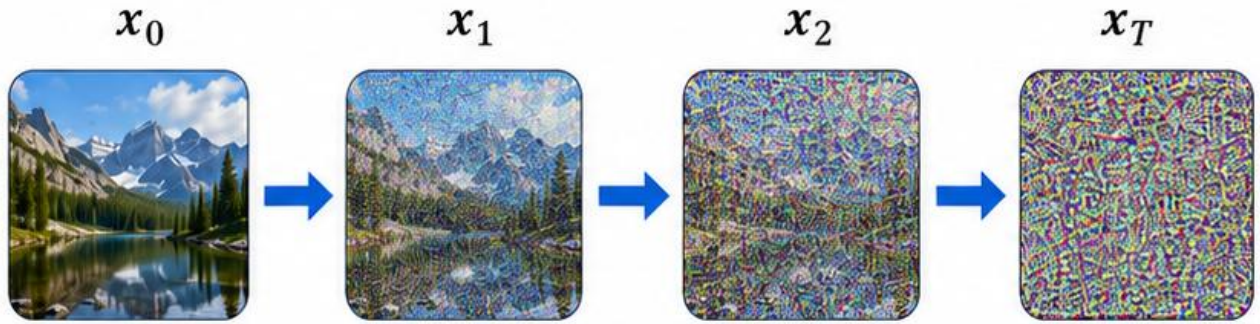
前向加噪：做法与含义

① 单步加噪（马尔可夫转移）

$$q(x_t \mid x_{t-1}) = \mathcal{N}\left(x_t; \sqrt{1-\beta_t}x_{t-1}, \beta_t I\right)$$

- β_t：第 t 步噪声强度，通常很小
- 每一步只加一点噪声

② 直观过程（示意）



随着 t 增大，图像结构逐渐被噪声淹没

③ 直通车（闭式公式：直接由 x_0 得到 x_t）

$$x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\, \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, I)$$

$$\alpha_t = 1 - \beta_t \qquad \bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$$

训练时不必一步步加到 t

可直接由 x_0 构造任意时刻 x_t

$x_t =$ **原图成分** $\sqrt{\bar{\alpha}_t}\, x_0$ + **噪声成分** $\sqrt{1-\bar{\alpha}_t}\, \varepsilon$

前向加噪的数学推导

1 从单步方程出发

① $x_1 = \sqrt{\alpha_1}\, x_0 + \sqrt{1-\alpha_1}\, \varepsilon_1$

② $x_2 = \sqrt{\alpha_2}\, x_1 + \sqrt{1-\alpha_2}\, \varepsilon_2$

将 x_1 代入 x_2：

$$x_2 = \sqrt{\alpha_2}\,(\sqrt{\alpha_1} x_0 + \sqrt{1-\alpha_1}\,\varepsilon_1) + \sqrt{1-\alpha_2}\,\varepsilon_2$$
$$= \sqrt{\alpha_2\alpha_1}\, x_0 + \sqrt{\alpha_2(1-\alpha_1)}\,\varepsilon_1 + \sqrt{1-\alpha_2}\,\varepsilon_2$$

2 得到展开式

$$x_2 = \sqrt{\alpha_2\alpha_1}\, x_0 + \sqrt{\alpha_2(1-\alpha_1)}\,\varepsilon_1 + \sqrt{1-\alpha_2}\,\varepsilon_2$$

独立高斯噪声的线性组合仍服从高斯分布。

3 合并方差并化简

由于 $\varepsilon_1, \varepsilon_2 \sim \mathcal{N}(0,I)$ 且独立，故其线性组合的方差为：

$$\alpha_2(1-\alpha_1) + (1-\alpha_2) = 1 - \alpha_1\alpha_2$$

$\Rightarrow$ 因此存在 $\varepsilon \sim \mathcal{N}(0,I)$，使得：

$$x_2 = \sqrt{\alpha_1\alpha_2}\, x_0 + \sqrt{1-\alpha_1\alpha_2}\,\varepsilon, \quad \varepsilon \sim \mathcal{N}(0,I)$$

4 推广到 t 步

定义累计保留系数：

$$\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$$

可由数学归纳法证明：

$$x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\,\varepsilon, \quad \varepsilon \sim \mathcal{N}(0,I)$$

因此前向加噪的边缘分布为：

$$q(x_t \mid x_0) = \mathcal{N}\left(x_t;\ \sqrt{\bar{\alpha}_t}\, x_0,\ (1-\bar{\alpha}_t)\, I\right)$$

结论： 由于高斯分布的闭包性，可以直接从 x_0 一步构造任意时刻 x_t，这使训练样本构造非常高效。

DDPM 训练 vs 推理：逆向去噪逻辑对比（图4）

训练时：随机学习任意噪声等级的去噪



真实图像 x_0



随机采样时间步 t



直接构造 x_t

(x_t, t)

输入 (x_t, t)



模型预测噪声



与真实噪声比较并更新参数

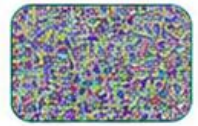
- 不需要逐步从 x_T 走回 x_0
- 训练时随机抽查某个时刻 t
- 目标：学会在任意 t 下识别噪声



训练： 随机抽一个时刻学去噪；

推理： 把所有时刻按顺序用起来。

推理时：把学到的能力按时间顺序串起来



纯噪声 x_T

(x_T, T)

输入 (x_T, T)



预测噪声



更新得到 x_{T-1}

$(x_{T-1}, T-1)$

输入 $(x_{T-1}, T-1)$



预测噪声



……



生成图像 x_0

- 从 T 到 1 逐步去噪
- 每一步都调用同一个 U-Net
- 不是一步到 x_0，而是一步到 x_{t-1}

DDPM 训练设置（图5）

A 训练样本构造



x_0
真实图像

随机采样 $t \sim U(1, T)$
随机时间步

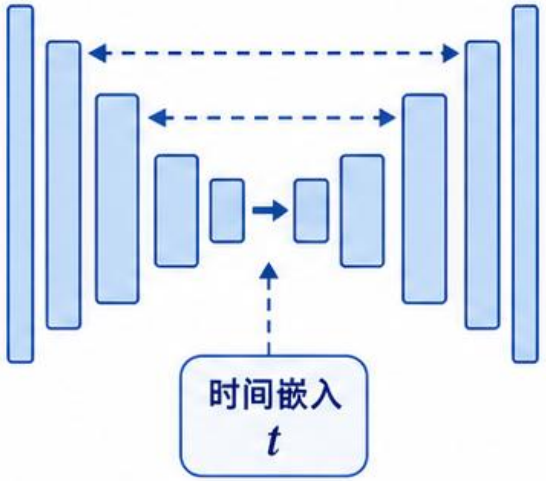
随机噪声 $\varepsilon \sim \mathcal{N}(0, I)$
标准高斯噪声

$$x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1 - \bar{\alpha}_t}\, \varepsilon$$

由真实图像直接构造
任意时刻的带噪图像

B 模型

时间条件 U-Net



输入：x_t 和 t

时间步 t 经过时间嵌入后注入 U-Net

C 输出

输出：
预测噪声
$\varepsilon_\theta(x_t, t)$

预测的是当前 x_t 中混入的噪声

D 损失函数

$$\mathcal{L}_{simple} = \mathbb{E}_{x_0,t,\varepsilon}\left[\|\varepsilon - \varepsilon_\theta(x_t, t)\|_2^2\right]$$

真实噪声是已知的

本质上是噪声回归问题

训练目标：
让预测噪声尽量接近真实噪声

训练阶段 = 构造 x_t → 输入 (x_t, t) → 预测噪声 $\varepsilon_\theta(x_t, t)$ → MSE 监督

训练目标的数学推导

1 原始学习目标：变分训练 / KL 分解

最大化对数似然的变分下界（ELBO）：

$$\log p_\theta(\boldsymbol{x}_0) \geq \mathbb{E}_q\left[\log \frac{p_\theta(\boldsymbol{x}_{0:T})}{q(\boldsymbol{x}_{1:T}|\boldsymbol{x}_0)}\right]$$

$$= -\mathbb{E}_q\left[\mathrm{KL}(q(\boldsymbol{x}_T|\boldsymbol{x}_0)\,\|\,p(\boldsymbol{x}_T))\right] - \sum_{t=1}^{T}\mathbb{E}_q\left[\mathrm{KL}(q(\boldsymbol{x}_{t-1}|\boldsymbol{x}_t,\boldsymbol{x}_0)\|p_\theta(\boldsymbol{x}_{t-1}|\boldsymbol{x}_t))\right]$$

前一项与 θ 无关（常数），因此最小化等价于：$\min_\theta \sum_{t=1}^{T}\mathbb{E}_q\left[\mathrm{KL}(q(\boldsymbol{x}_{t-1}|\boldsymbol{x}_t,\boldsymbol{x}_0)\,\|\,p_\theta(\boldsymbol{x}_{t-1}|\boldsymbol{x}_t))\right]$

2 后验与模型分布均高斯

真实后验（由前向过程可解析得到）

$$q(\boldsymbol{x}_{t-1}|\boldsymbol{x}_t,\boldsymbol{x}_0) = \mathcal{N}\left(\boldsymbol{x}_{t-1};\tilde{\boldsymbol{\mu}}_t(\boldsymbol{x}_t,\boldsymbol{x}_0),\tilde{\beta}_t I\right)$$

模型反向过程（参数化为各向同性高斯）

$$p_\theta(\boldsymbol{x}_{t-1}|\boldsymbol{x}_t) = \mathcal{N}\left(\boldsymbol{x}_{t-1};\boldsymbol{\mu}_\theta(\boldsymbol{x}_t,t),\sigma_t^2 I\right)$$

★ 两个高斯分布的 KL 主要转化为均值之间的二次误差（当协方差固定或与 θ 无关时）

3 用噪声参数化：将均值预测改写为噪声预测

前向过程有闭式形式：

$$\boldsymbol{x}_t = \sqrt{\bar{\alpha}_t}\boldsymbol{x}_0 + \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}, \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, I)$$

其中 $\bar{\alpha}_t = \prod_{s=1}^{t}\alpha_s,\ \alpha_s = 1-\beta_s$

常用的均值参数化（以 ϵ_θ 表示网络输出的噪声预测）为

$$\boldsymbol{\mu}_\theta(\boldsymbol{x}_t,t) = \frac{1}{\sqrt{\alpha_t}}\left(\boldsymbol{x}_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}_\theta(\boldsymbol{x}_t,t)\right)$$

→ 因此，预测均值等价于预测噪声：更直接、更稳定、与数据尺度解耦。

4 化简结果：得到噪声回归损失

将上式代入第 2 步的 KL 并可化简（去除与 θ 无关的常数），得到

$$L_{\text{simple}} = \mathbb{E}_{\boldsymbol{x}_0\sim q(\boldsymbol{x}_0),\, t\sim\mathcal{U}(\{1,\ldots,T\}),\,\boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},I)}\left[\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\boldsymbol{x}_t,t)\|_2^2\right]$$

直观理解

- 逐步 KL 之和 → 噪声预测的均方误差；
- 随机时间步采样等价于对所有步的期望；
- 固定均方差情形下最优解为 $\boldsymbol{\epsilon}_\theta(\boldsymbol{x}_t,t) = \boldsymbol{\epsilon}$。

★ **结论：** 理论上优化的是每一步反向去噪质量；实现上可化简为随机时间步 t 下的噪声回归。

DDPM 图7：推理 / 采样流程



纯噪声 x_T

输入 (x_t, t)

U-Net 预测噪声
$\varepsilon_\theta(x_t, t)$

调度器 / 反向更新
（利用 $\varepsilon_\theta(x_t, t)$）



得到 x_{t-1}

…

下一步再次输入 $(x_{t-1}, t-1)$



生成图像 x_0

重复 $T \to 1$ 步

输入： 当前样本 x_t 和当前时间步 t

输出： 当前 x_t 中的噪声估计，
不是直接输出 x_0

根据预测噪声，可以估计 x_0，
也可以更新得到 x_{t-1}

DDPM 采样时选择逐步更新到 x_{t-1}，
再重新预测，使过程更稳定

同一个 U-Net 在每一个时间步
被重复调用

☆ 训练学会任意 t 下的去噪；推理把这些能力从 T 到 1 依次使用。

推理过程的数学推导

1 真实后验的形式

从扩散模型的构造可得后验分布 $q(x_{t-1} \mid x_t, x_0)$ 为高斯分布：

$$q(x_{t-1} \mid x_t, x_0) = \mathcal{N}\left(x_{t-1};\ \tilde{\mu}_t(x_t, x_0),\ \tilde{\beta}_t \mathbf{I}\right)$$

真实后验依赖 x_t 和未知的 x_0

其中后验均值与方差为

$$\tilde{\mu}_t(x_t, x_0) = \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\,\beta_t}{1-\bar{\alpha}_t} x_0 \qquad \tilde{\beta}_t = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t$$

2 用噪声预测估计 x_0

在推理（生成）时，x_0 未知。基于前向过程

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon, \qquad \epsilon \sim \mathcal{N}(0, \mathbf{I})$$

可由模型预测的噪声 $\epsilon_\theta(x_t, t)$ 反推出当前对应的干净图像估计：

$$\hat{x}_0 = \frac{x_t - \sqrt{1-\bar{\alpha}_t}\,\epsilon_\theta(x_t, t)}{\sqrt{\bar{\alpha}_t}}$$

由噪声预测反推出
当前对应的干净图像估计

3 代入并化简得到实用的反向更新

将 $\hat{x}_0$ 代入后验均值 $\tilde{\mu}_t(x_t, x_0)$,, 得

$$\tilde{\mu}_t(x_t, \hat{x}_0) = \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\,\beta_t}{1-\bar{\alpha}_t} \hat{x}_0$$

$$= \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}}\,\epsilon_\theta(x_t, t)\right)$$

从后验分布中采样得到反向一步（通用 $t \geq 2$）：

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}}\,\epsilon_\theta(x_t, t)\right) + \sigma_t z, \qquad z \sim \mathcal{N}(0, \mathbf{I})$$

其中噪声系数

$$\sigma_t = \sqrt{\tilde{\beta}_t} = \sqrt{\frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t} \quad (t \geq 2) \qquad \sigma_1 = 0 \ \text{（最后一步无随机性）}$$

4 结果解读与生成流程

- **第一项：沿去噪方向更新** $\frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}}\,\epsilon_\theta(x_t, t)\right)$ 利用噪声预测 ϵ_θ 指引样本朝向更干净的图像。
- **第二项：加入少量随机性，保持生成多样性** $\sigma_t z,\ z \sim \mathcal{N}(0, \mathbf{I})$ 方差随 t 变化，符合后验不确定性。
- **重复过程：** 从 $x_T \sim \mathcal{N}(0, \mathbf{I})$ 出发，按 $x_{t-1} = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}}\,\epsilon_\theta(x_t, t)\right) + \sigma_t z$ 迭代 $t = T, T-1, \ldots, 1$，最终得到 x_0 。

实验结果:



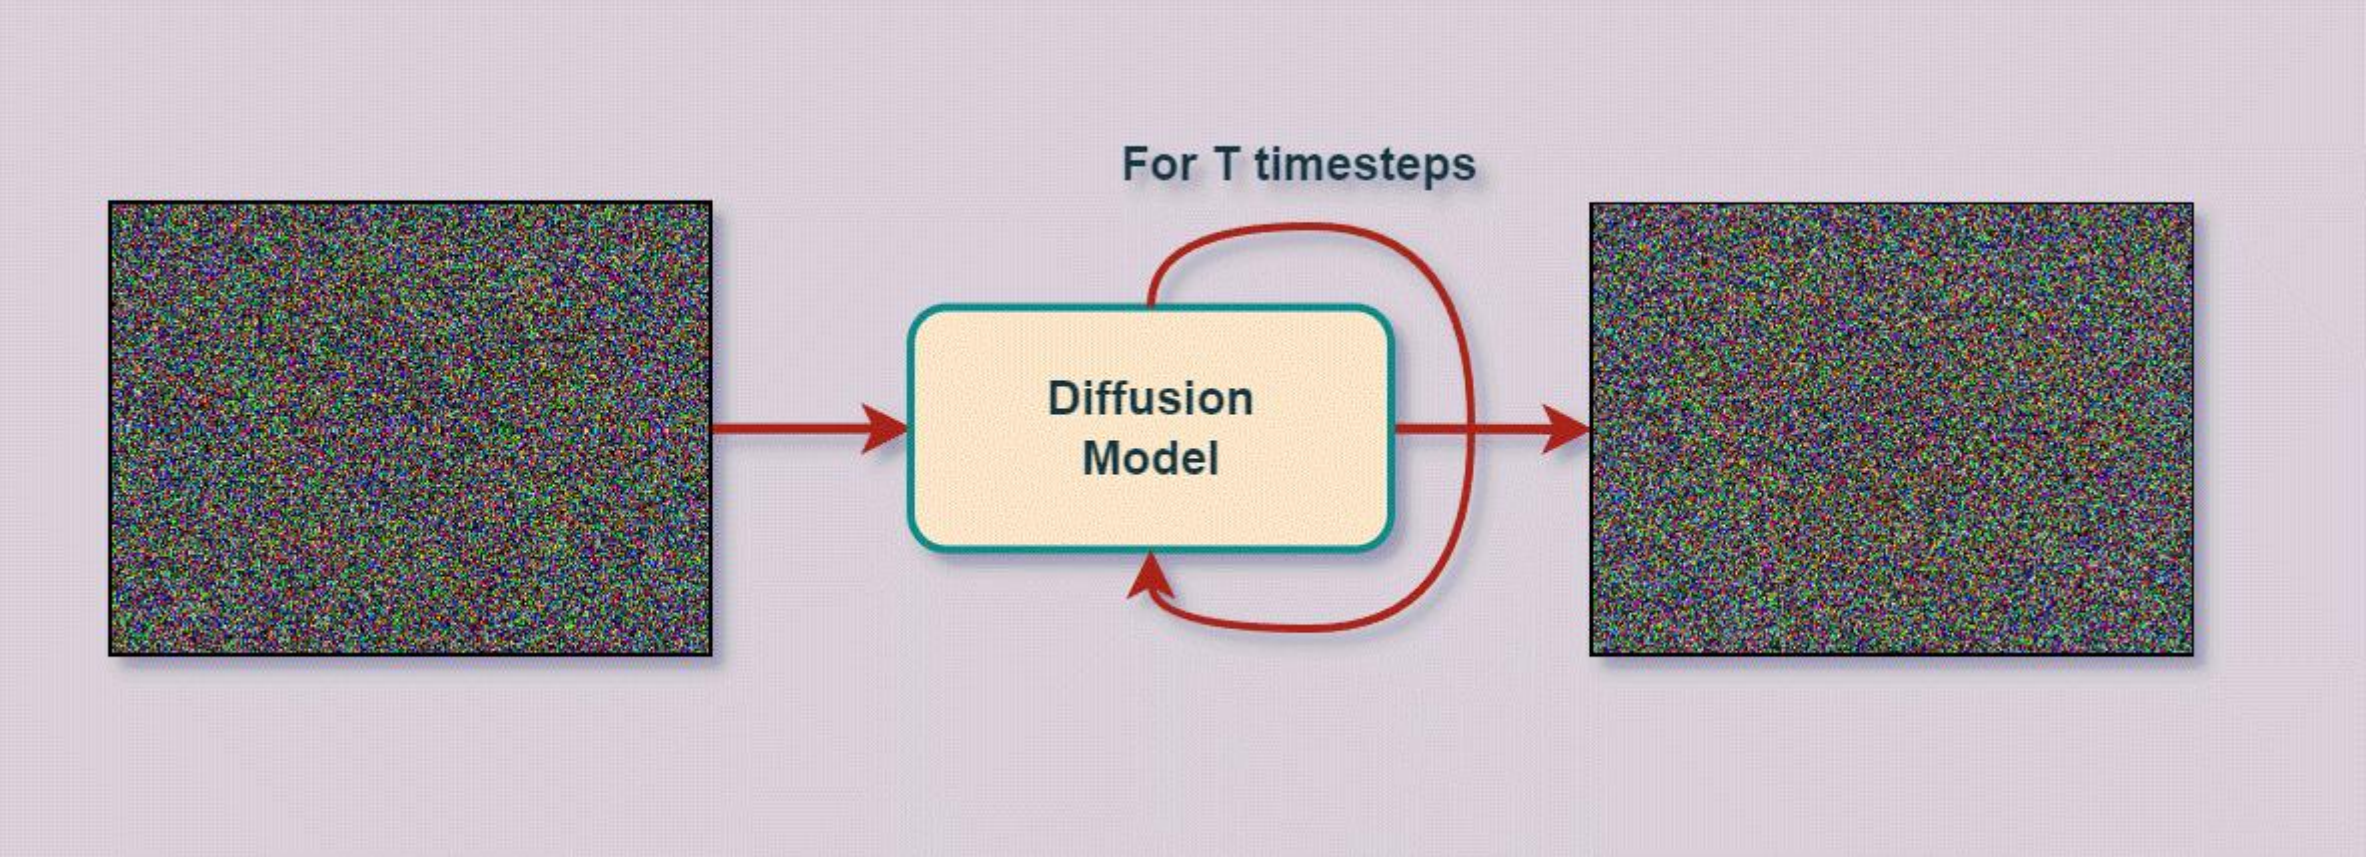
(b) Inception feature space nearest neighbors

实验结果:



Figure 19: LSUN Cat generated samples. FID=19.75

演示:



Diffusion:

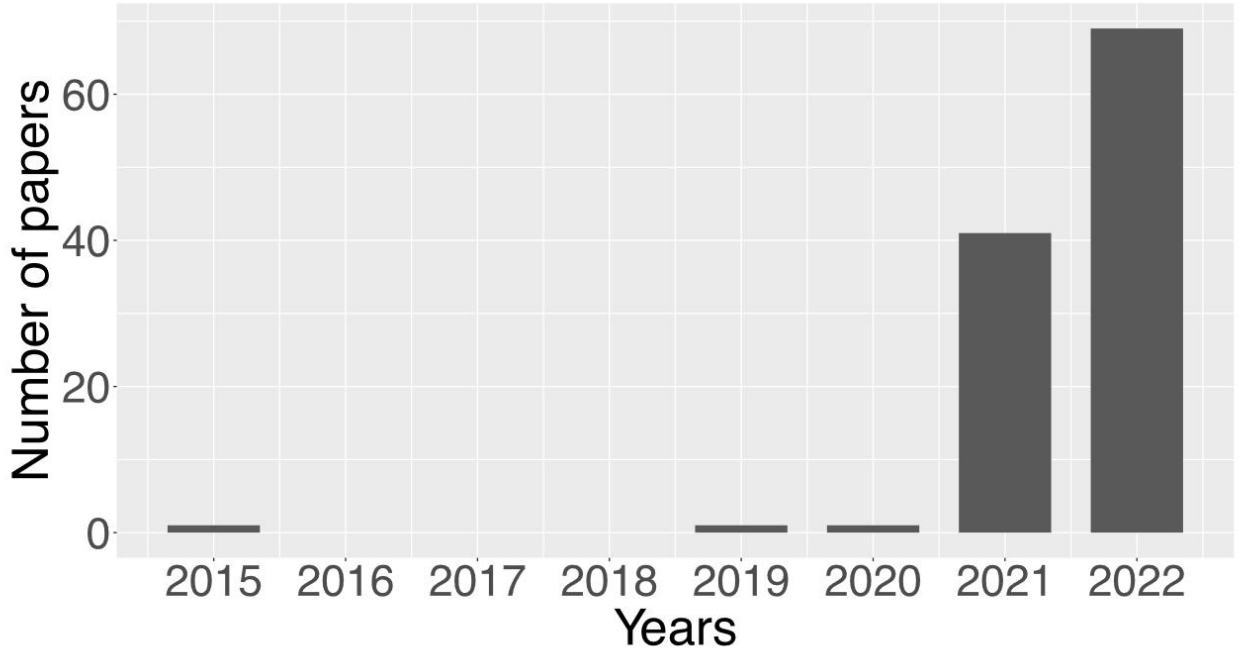


Fig. 1. The rough number of papers on diffusion models per year.

NIPS：38（2022）— 194（2023）

目录:

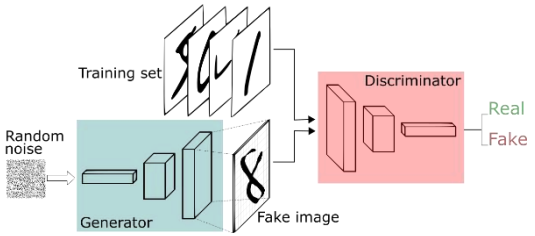
- GAN
- VAE
- DDPM

Generative adversarial nets

I Goodfellow, J Pouget-Abadie... - Advances in neural ..., 2014 - proceedings.neurips.cc

... We propose a new framework for estimating generative models via an adversarial process, in which we simultaneously train two models: a generative model G that captures the data ...

☆ 保存 99 引用 被引用次数：62499 相关文章 所有 61 个版本 »

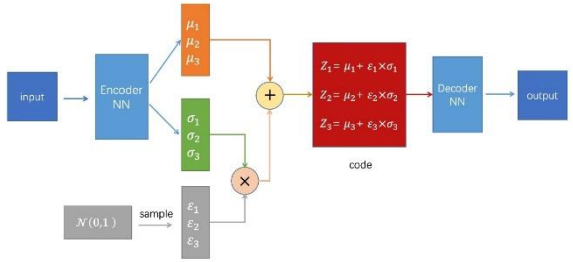


Auto-encoding variational bayes

DP Kingma, M Welling - arXiv preprint arXiv:1312.6114, 2013 - arxiv.org

... variational lower bound yields a simple differentiable unbiased estimator of the lower bound; this SGVB (Stochastic Gradient Variational Bayes... , we propose the AutoEncoding VB (AEVB...

☆ 保存 99 引用 被引用次数：31270 相关文章 所有 44 个版本 »

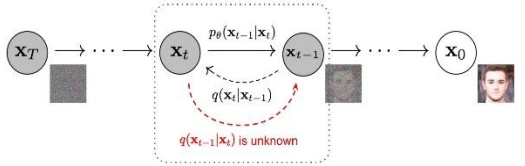


Denoising diffusion probabilistic models

J Ho, A Jain, P Abbeel - Advances in neural information ..., 2020 - proceedings.neurips.cc

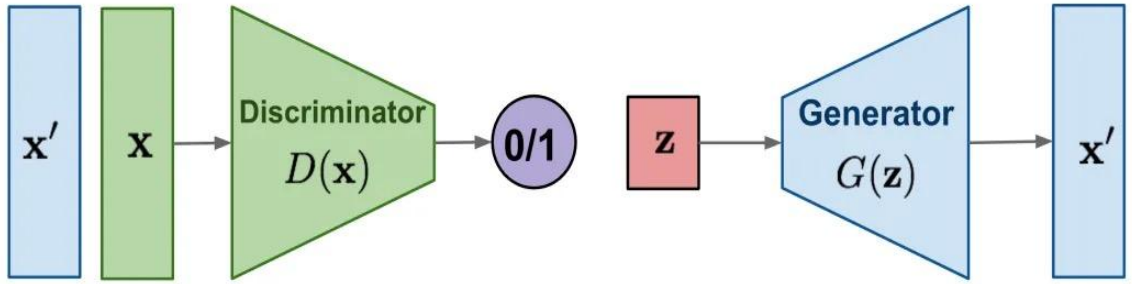
... This paper presents progress in diffusion probabilistic models [53]. A diffusion probabilistic model (which we will call a "diffusion model" for brevity) is a parameterized Markov chain ...

☆ 保存 99 引用 被引用次数：4893 相关文章 所有 6 个版本 »



对抗学习

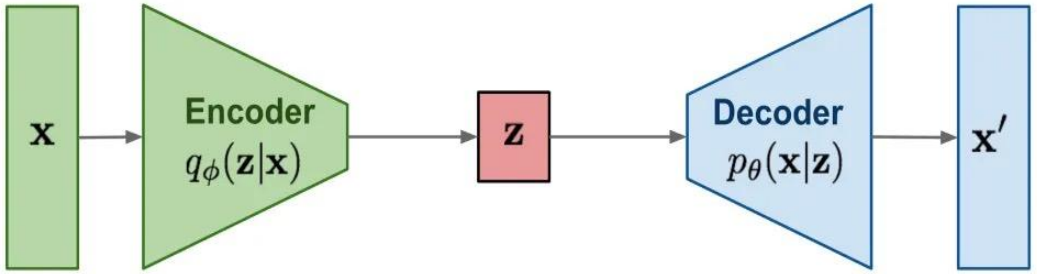
GAN: Adversarial training



训练过程不稳定

隐变量建模

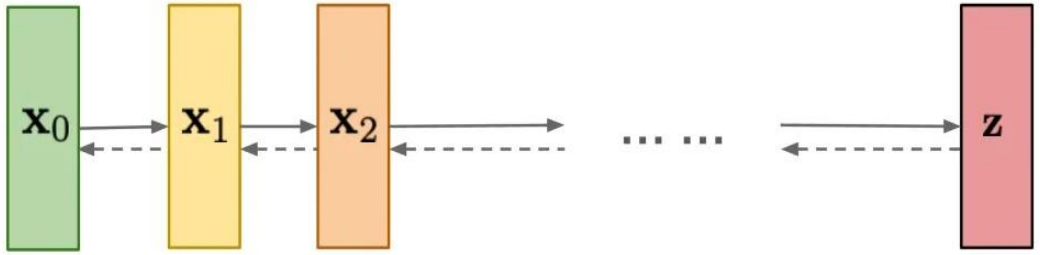
VAE: maximize variational lower bound



生成效果不好

逐步去噪

Diffusion models: Gradually add Gaussian noise and then reverse



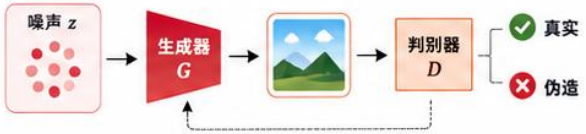
生成过程慢

首都师范大学 CAPITAL NORMAL UNIVERSITY

GAN / VAE / DDPM 生成模型总结对比

核心思想、优缺点与当前技术意义

GAN



核心思想
- 生成器 G 与判别器 D 对抗博弈
- 通过对抗学习逼近真实数据分布
- 代表“对抗式生成”范式

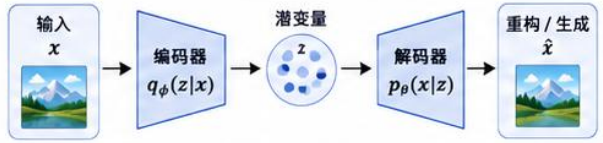
优点
- 生成速度快，一次前向即可出样本
- 图像通常较锐利、细节感强
- 在图像翻译、超分辨率等任务中表现突出

缺点
- 训练不稳定，易出现模式崩溃
- 缺乏显式似然，理论分析较复杂
- 对超参数和训练技巧较敏感

当前意义
- 生成模型发展史上的关键里程碑
- 今天不再是通用 AIGC 主线，但在特定视觉任务中仍有价值
- 帮助理解对抗学习与分布匹配思想

关键词：对抗学习

VAE



核心思想
- 引入隐变量 z，学习数据的概率生成过程
- Encoder 近似后验，Decoder 负责重构/生成
- 通过变分推断优化 ELBO

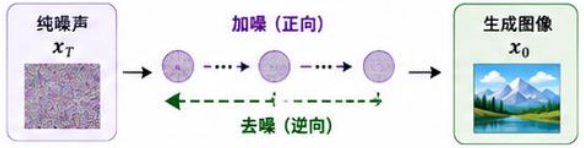
优点
- 概率解释清晰，训练相对稳定
- 潜空间连续，便于插值与表示学习
- 适合生成、压缩、异常检测等任务

缺点
- 生成结果往往偏平滑、细节较弱
- 重构与正则项之间需要权衡
- 高保真自然图像生成通常不如 GAN / DDPM

当前意义
- 是理解隐变量生成模型的核心代表
- 潜空间建模思想至今非常重要
- 为 Latent Diffusion 等现代模型提供基础

关键词：隐变量建模

DDPM



核心思想
- 正向过程逐步加噪，逆向过程逐步去噪
- 把生成问题转化为学习去噪过程
- 代表“扩散式生成”范式

优点
- 训练稳定，生成质量高
- 模式覆盖较好，多样性强
- 易于接入文本、图像、结构等条件控制

缺点
- 采样过程慢，需要多步迭代
- 训练与推理计算开销较大
- 原始像素空间 DDPM 效率不高

当前意义
- 当前视觉 AIGC 的核心基础之一
- Stable Diffusion 等模型的重要出发点
- 推动了文生图、图像编辑与可控生成发展

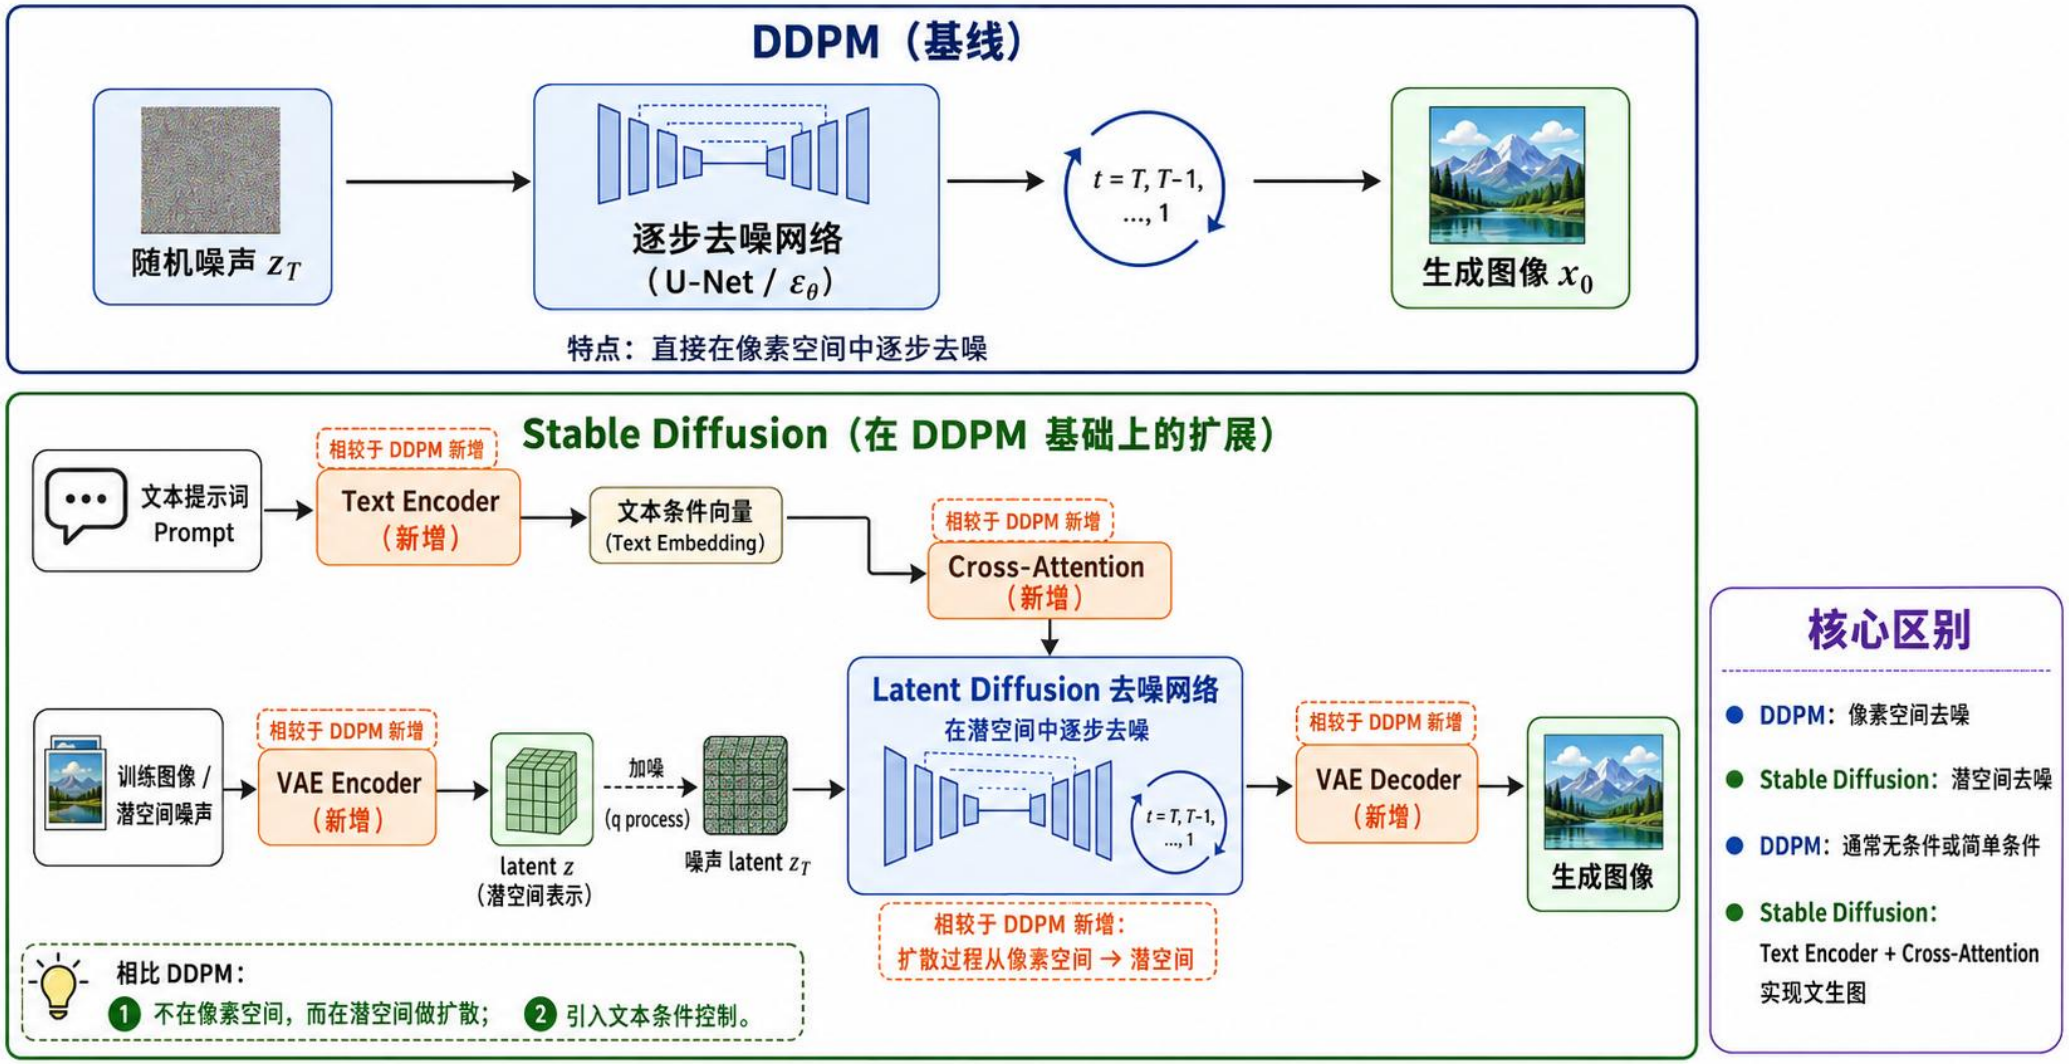
关键词：逐步去噪

一句话理解三类模型

- GAN：靠对抗博弈学会生成
- VAE：靠隐变量概率建模学会生成
- DDPM：靠逐步去噪学会生成

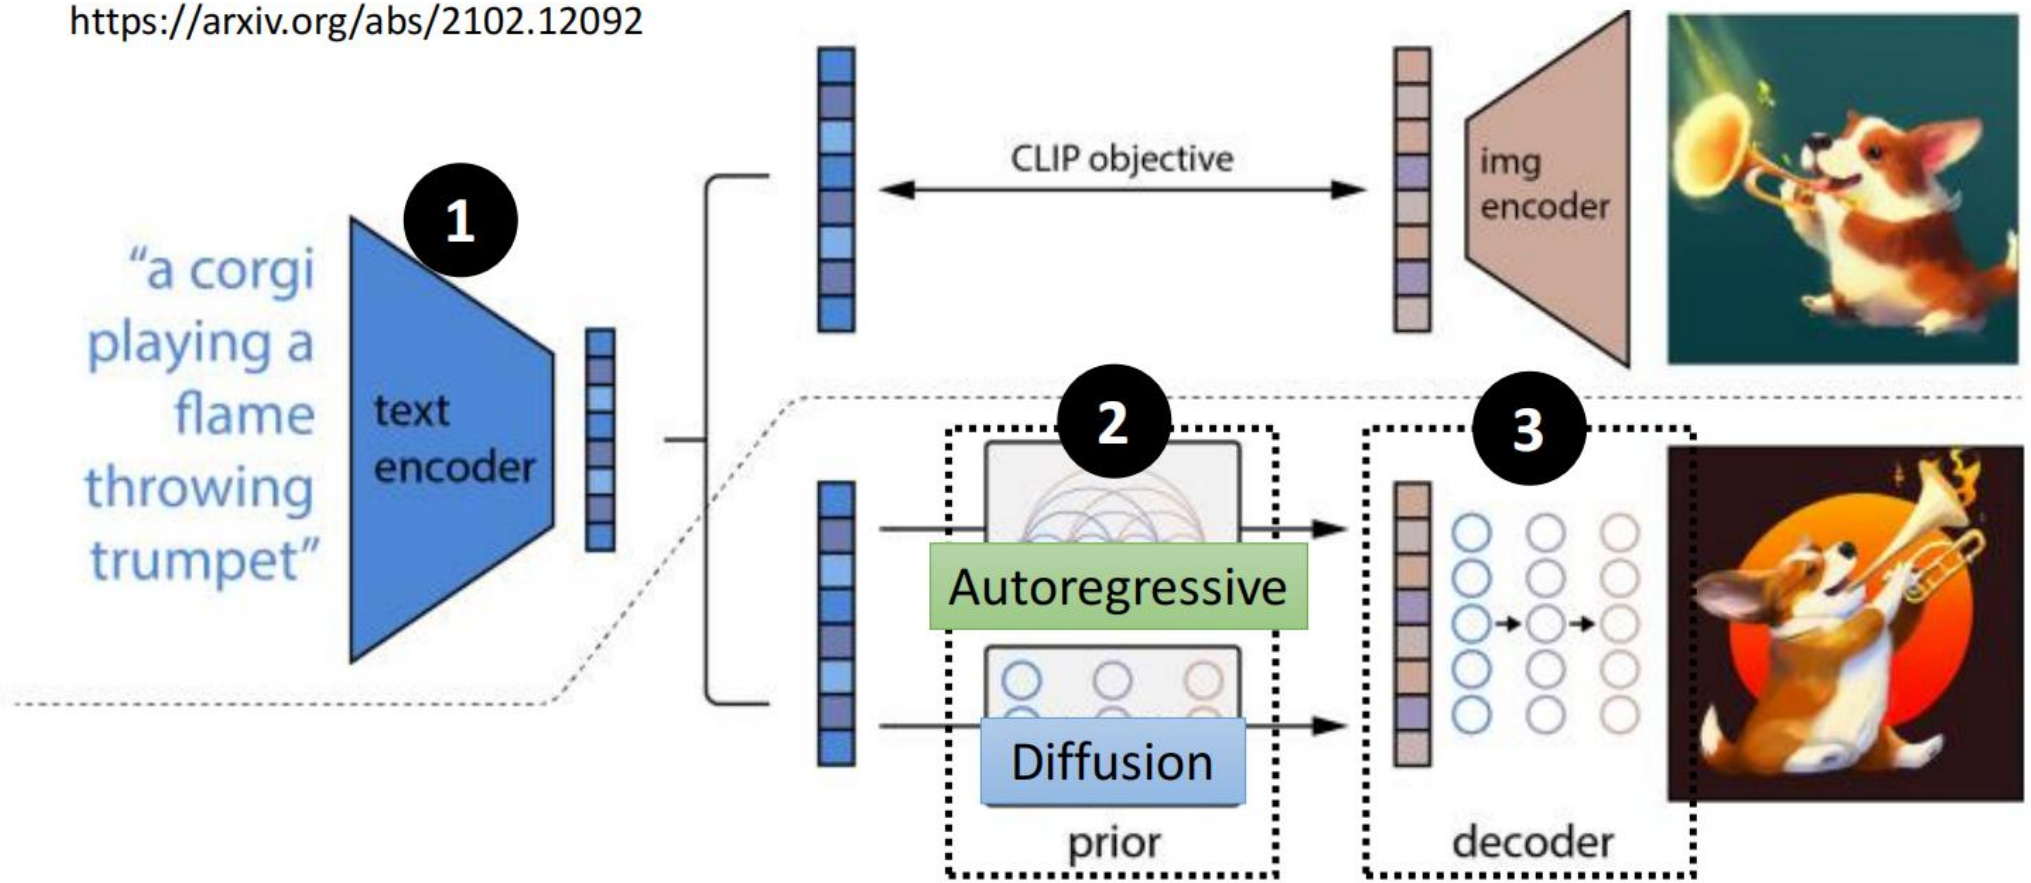
课堂结论

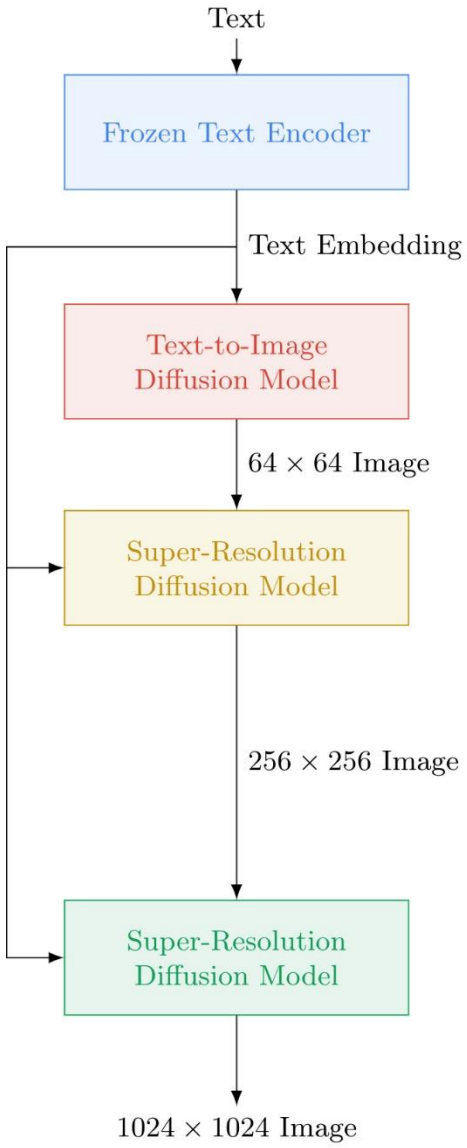
1. GAN：历史意义强，工程上仍有局部价值
2. VAE：理论清晰，是潜空间生成的重要基础
3. DDPM：当前最具代表性的视觉生成路线之一
4. 三者共同构成理解现代 AIGC 的核心起点


DDPM（基线）
随机噪声 z_T
逐步去噪网络
（U-Net / ε_θ）
$t = T, T-1, \ldots, 1$
生成图像 x_0
特点：直接在像素空间中逐步去噪
Stable Diffusion（在 DDPM 基础上的扩展）
文本提示词
Prompt
相较于 DDPM 新增
Text Encoder
（新增）
文本条件向量
(Text Embedding)
相较于 DDPM 新增
Cross-Attention
（新增）
Latent Diffusion 去噪网络
在潜空间中逐步去噪
$t = T, T-1, \ldots, 1$
相较于 DDPM 新增
VAE Decoder
（新增）
生成图像
训练图像 /
潜空间噪声
相较于 DDPM 新增
VAE Encoder
（新增）
latent z
（潜空间表示）
加噪
(q process)
噪声 latent z_T
相较于 DDPM 新增：
扩散过程从像素空间 → 潜空间
相比 DDPM：
1 不在像素空间，而在潜空间做扩散；
2 引入文本条件控制。
核心区别
DDPM：像素空间去噪
Stable Diffusion：潜空间去噪
DDPM：通常无条件或简单条件
Stable Diffusion：
Text Encoder + Cross-Attention
实现文生图
橙色模块：相较于 DDPM 新增的模块
相较于 DDPM 新增：表示该部分是 Stable Diffusion 相比 DDPM 的改进或新增

DALL-E series

https://arxiv.org/abs/2204.06125
https://arxiv.org/abs/2102.12092




Text
Frozen Text Encoder
Text Embedding
Text-to-Image Diffusion Model
64 × 64 Image
Super-Resolution Diffusion Model
256 × 256 Image
Super-Resolution Diffusion Model
1024 × 1024 Image

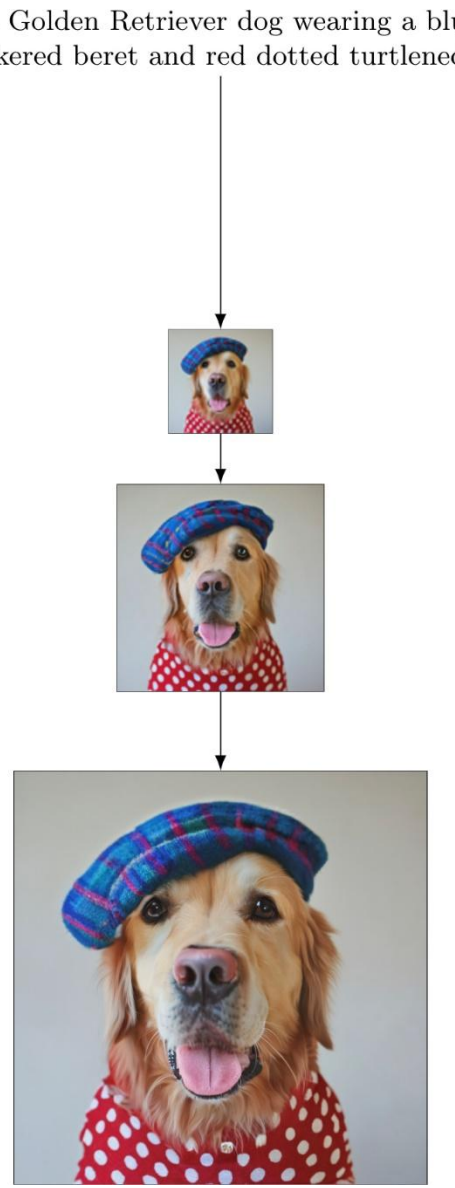

"A Golden Retriever dog wearing a blue checkered beret and red dotted turtleneck."


imagen
A photo of a Corgi dog riding a bike in Times Square. It is wearing sunglasses and a beach hat.

参考文献:

标题	创建者	年	
gemini_1_report.pdf			
Generative Adversarial Nets	Goodfellow 等	2014	
Deep Unsupervised Learning using Nonequilibrium Thermodynamics	Sohl-Dickstein 等	2015	
NIPS 2016 Tutorial: Generative Adversarial Networks	Goodfellow	2017	
Denoising Diffusion Probabilistic Models	Ho 等	2020	
Generative Modeling by Estimating Gradients of the Data Distribution	Song 和 Ermon	2020	
Learning Transferable Visual Models From Natural Language Supervision	Radford 等	2021	
On Analyzing Generative and Denoising Capabilities of Diffusion-based Deep Generative Models	Deja 和 Kuzina	2022	
Maximum Likelihood Training of Implicit Nonlinear Diffusion Models	Kim 等	2022	
Auto-Encoding Variational Bayes	Kingma 和 Welling	2022	
Understanding Diffusion Models: A Unified Perspective	Luo	2022	
Diffusion Models in Vision: A Survey	Croitoru 等	2023	
Diffusion Models: A Comprehensive Survey of Methods and Applications	Yang 等	2024	